Diseño de injertos vasculares multicapa que reproducen la curva tensión–estiramiento de cada arteria: bases de materiales, láminas enteras, pared gruesa y una red neuronal

Pablo Silvoni

3 de noviembre de 2026

Resumen

Un injerto vascular que se distiende distinto que la arteria que reemplaza favorece la trombosis y la hiperplasia de la íntima. Los métodos de diseño publicados ajustan un único número —la compliancia de una arteria promedio—. Aquí se presenta un método para diseñar, paciente por paciente, un injerto multicapa que reproduzca la *curva completa* de la arteria, con su forma de J. Cada material del injerto se idealiza como una fibra que no tira hasta un estiramiento propio (recta truncada), y la arteria se aproxima por una suma de esos materiales, elegidos una vez para toda la población. El método se valida primero sobre la curva tensión circunferencial–estiramiento circunferencial, $\sigma_{\theta\theta}(\lambda_\theta)$, que no depende de la presión ni de la geometría de la pared: con 41 carótidas humanas (Masson et al.) y 22 500 curvas sintéticas, el ajuste por mínimos cuadrados y el redondeo minimax a láminas enteras cumplen la meta (peor error ≤ 3 % del rango) en los 41 sujetos con 6 materiales; una red neuronal entrenada sobre 50 000 curvas reproduce ese ajuste en una evaluación y generaliza a una ley constitutiva que nunca vio (exceso de error de 2,8 a 4,6 %). Luego el método se aplica a la curva presión–diámetro, para la que el injerto es un tubo de pared gruesa: diseñado con la ley de Laplace ningún sujeto cumple al fabricarse, mientras que con pared gruesa cumplen 40–41 de 41. El diseño se vuelve un problema no lineal entero, que se resuelve en tres pasos: arranque, mínimos cuadrados no lineales y búsqueda entera minimax contra la curva ajustada. En el caso lineal la red no mejora la solución exacta; en el no lineal, usada como punto de partida, evita los mínimos locales que con curvas medidas producen diseños inservibles (peor error de 468,7 % a 2,3 %).

Índice

1. Introducción **1**

2. Datos **2**
2.1. Ley constitutiva y sujetos 2
2.2. Curvas de tensión 2

3. Validación del método sobre la curva tensión–estiramiento **3**
3.1. Materiales: rectas truncadas 3
3.2. Métrica 4
3.3. Cantidades reales: mínimos cuadrados 4
3.4. Láminas enteras: tres redondeos 5
3.5. La red neuronal 6

4. Aplicación: la curva presión–diámetro y el tubo de pared gruesa **8**
4.1. De la tensión a la presión 8
4.2. Pared delgada y pared gruesa 9
4.3. El injerto de pared gruesa 11
4.4. Métodos de diseño 12
4.5. Resultados 13

5. Discusión **16**

6. Conclusiones **16**

A. Parámetros de los 41 sujetos **17**

1. Introducción

La falla de los injertos vasculares de diámetro pequeño (trombosis, hiperplasia de la íntima) se debe en buena parte a factores mecánicos: flujo perturbado, resistencia insuficiente y desajuste de compliancia entre el injerto y la arteria [10]. En la aorta de cerdo, un injerto con una capa que iguala la compliancia mantuvo la presión de pulso, la velocidad de onda y la distensibilidad, que se deterioraron al quitar la capa [34]; en ratas, un injerto con composición optimizada para la compliancia del vaso receptor siguió ajustado a las cuatro semanas, con menos inflamación y más músculo liso contráctil [14]. Igualar la mecánica de la arteria mejora el resultado.

Varios trabajos optimizan el diseño con ese fin: tiempo de entrecruzado y espesor de un biopolímero [18], proporción y espesor de las capas de un injerto multicapa [37], un refuerzo de nitinol [33] o una espiral de refuerzo [23], y andamios degradables que se transforman en neovaso [36, 20]. Todos ajustan *un número* (compliancia o distensibilidad) de una arteria *promedio*. La respuesta de una arteria, en cambio, tiene forma de J: blanda a bajo estiramiento, cuando trabajan la elastina y el músculo, y rígida a alto estiramiento, cuando se reclutan las fibras de colágeno [19, 22]. Un número no describe esa forma, y la forma cambia de un paciente a otro y de una arteria a otra.

Este trabajo diseña el injerto para que copie la *curva completa* de *cada* arteria. El método tiene dos niveles, que se presentan en ese orden:

1. **Nivel del material (validación).** La curva objetivo es la tensión circunferencial en función del estiramiento circunferencial, $\sigma_{\theta\theta}(\lambda_\theta)$. Es una propiedad del tejido: no depende de la presión, del radio ni del espesor de la pared, y por eso es común a cualquier arteria cuya pared tenga respuesta en J. En este nivel el injerto es una suma de materiales, el diseño es lineal y cada paso del método puede compararse con una solución exacta.
2. **Nivel del tubo (aplicación).** La curva objetivo es la presión que soporta la pared en función del diámetro. Aquí entran la geometría y el modelo de pared gruesa, el diseño deja de ser lineal y se usan las conclusiones del primer nivel.

Las contribuciones son: (i) una base de materiales tipo fibra elegida una vez para toda la población; (ii) el paso exacto de cantidades reales a láminas enteras por programación lineal entera (minimax); (iii) una red neuronal que da el diseño en una evaluación y generaliza a leyes no vistas; (iv) la demostración de que, a nivel del tubo, el diseño debe hacerse en pared gruesa, lo que lo vuelve no lineal entero; y (v) un procedimiento de tres pasos en el que la red cumple el papel de punto de partida.

2. Datos

2.1. Ley constitutiva y sujetos

Masson et al. [26] midieron en forma no invasiva, a lo largo del ciclo cardíaco, el diámetro y la presión de la carótida común de 16 sujetos normotensos (NT) y 25 hipertensos tratados (HT), y

ajustaron a cada uno un modelo de la pared íntima–media con tres aportes: elastina neo-Hookeana, cuatro familias de fibras de colágeno de respuesta exponencial (axial, circunferencial y dos diagonales a $\pm\alpha$) [19] y tono del músculo liso [31]. Con estiramiento axial λ_z fijo e incompresibilidad,

$$\sigma_{\theta\theta} - \sigma_{rr} = c\,(\lambda_\theta^2 - \lambda_r^2) + \lambda_\theta^2 \sum_{k=1}^{4} c_{1,k} E_k\, e^{c_{2,k} E_k^2} \sin^2 \varphi_k + T_m \lambda_\theta \Big[1 - \Big(\frac{\lambda_m - \lambda_\theta}{\lambda_m - \lambda_0}\Big)^2\Big], \tag{1}$$

con $E_k = \lambda_k^2 - 1$, $\lambda_r = 1/(\lambda_\theta \lambda_z)$ y λ_k el estiramiento de cada familia (λ_z, λ_θ y $\sqrt{\lambda_\theta^2 \sin^2\alpha + \lambda_z^2 \cos^2\alpha}$). Los 14 parámetros de cada sujeto están en sus Tablas 2 y 4 (Anexo A). Diez sujetos (4 NT y 6 HT) se reservan para prueba y no intervienen en ninguna elección del método.

2.2. Curvas de tensión

La curva objetivo del primer nivel es $\sigma_{\theta\theta}(\lambda_\theta)$ en el borde media–adventicia, en 999 valores de λ_θ entre 1,02 y 1,16, calculada con (1); en ese borde la tensión radial es la presión perivascular del modelo de Masson. Recalculada así, reproduce las curvas medias publicadas (Figs. 5a y 7a de [26]) con un error cuadrático medio de 1,2 a 1,7 % de su valor medio, del orden del error de digitalización. Las 41 curvas tienen forma de J (monótonas y convexas) y van de 4,7 a 49 kPa en $\lambda_\theta = 1{,}02$ y de 54 a 290 kPa en 1,16 (Fig. 1). En forma adimensional, $(\sigma - \sigma_{\text{mín}})/\Delta\sigma$, normotensos e hipertensos tienen casi la misma forma; la diferencia está en el nivel de tensión.

Dos curvas límite encierran a los 41 sujetos: y_1, una curva de la ley de Masson con parámetros dentro del rango de los sujetos, que parte de la menor tensión medida y queda debajo de todos, e y_2, el sujeto más rígido extendido hasta 300 kPa. El *espacio de trabajo* son 22 500 curvas sintéticas de la ley de Masson dentro de esa franja, con parámetros de 2 a 4 sujetos de entrenamiento mezclados y perturbados, o sorteados entre el mínimo y el máximo de los sujetos.

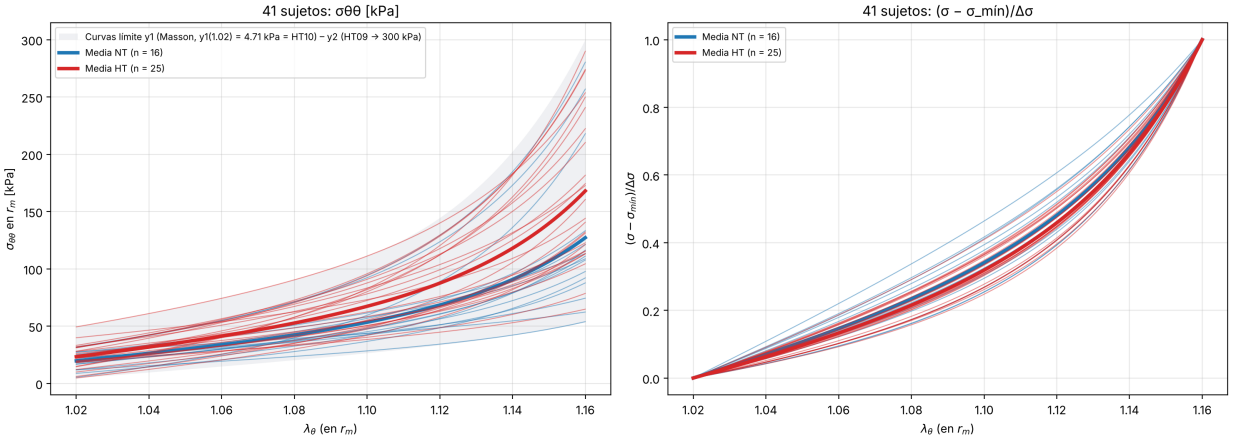


Figura 1: Los 41 sujetos: tensión circunferencial en el borde media–adventicia (izquierda; franja gris: curvas límite y_1–y_2) y forma adimensional (derecha). Azul: normotensos; rojo: hipertensos; trazo grueso: medias de cada grupo.

3. Validación del método sobre la curva tensión–estiramiento

3.1. Materiales: rectas truncadas

Una lámina del material j aporta

$$A_j(\lambda) = S_j\ \text{máx}(0,\ \lambda - k_j)\,: \tag{2}$$

nada hasta su *nudo* k_j, y luego una recta de pendiente S_j. Es la idealización de una fibra rizada que no tira hasta estirarse. El injerto es la suma $\sigma_{\text{inj}} = \sum_j c_j A_j = A\,c$, con c_j la cantidad de láminas de cada material y $A \in \mathbb{R}^{999\times N}$ la *base*. Para nudos fijos, el problema es lineal.

Elección de los nudos. Los nudos se eligen una sola vez, para toda la población, minimizando una función que reúne tres exigencias sobre el espacio de trabajo y los sujetos de entrenamiento: precisión (promedio del 1 % de las curvas con peor error, CVaR 99 % [32]), estabilidad (número de condición de la base con columnas normalizadas [38] menor que 30) y signo (sin cantidades negativas, que no se fabrican). La búsqueda es global por evolución diferencial [35] y se refina con Nelder–Mead [28]. Restricciones: k_1 entre 0,6 y 0,98, los demás dentro del dominio, separados al menos 0,008 y a más de 0,012 del extremo.

Pendientes. $S_j = \mathrm{PEND}_{\mathrm{máx},j}/20$, donde $\mathrm{PEND}_{\mathrm{máx},j}$ es la mayor pendiente que el material j debe aportar en el espacio de trabajo: así ninguna curva necesita más de 20 láminas de un material. La escala no cambia la curva (lo que cuenta es $c_j S_j$), pero fija el tamaño de una lámina.

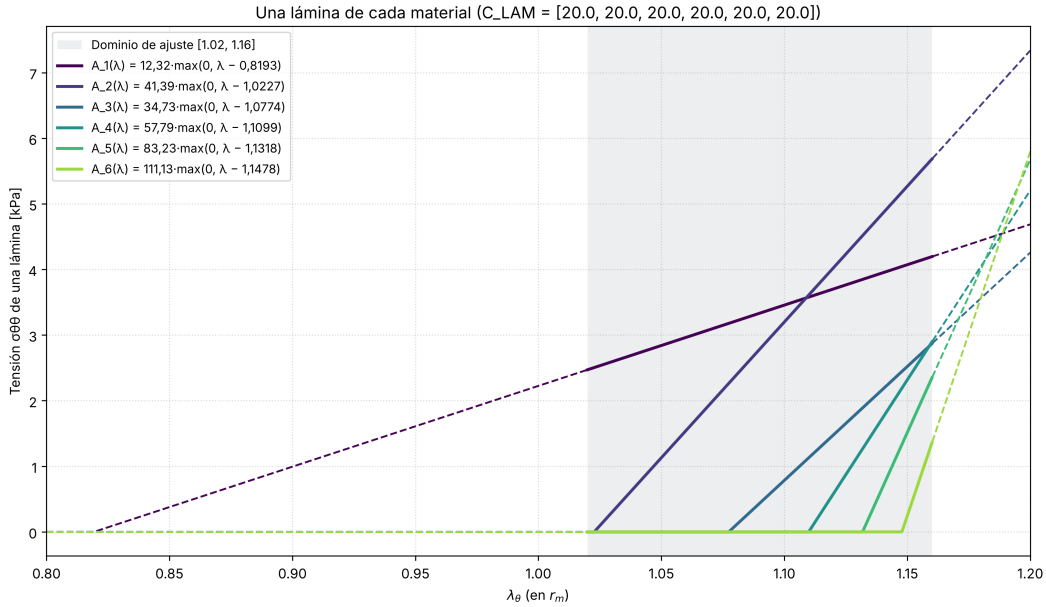


Figura 2: La base de 6 materiales: una lámina de cada uno. El primer nudo (0,82) está antes del dominio, como la elastina, que ya trabaja con la arteria descargada; los demás se agrupan donde la curva arterial se curva más.

Tabla 1: Bases adoptadas: nudos k_j y pendiente de una lámina S_j [kPa].

	1	2	3	4	5	6
6 materiales, k_j	0,8193	1,0227	1,0774	1,1099	1,1318	1,1478
S_j	12,32	41,39	34,73	57,79	83,23	111,13
5 materiales, k_j	0,8228	1,0243	1,0881	1,1226	1,1447	—
S_j	12,56	43,57	51,92	88,74	129,08	—

3.2. Métrica

Para una curva objetivo y con rango $\Delta = \max y - \min y$,

$$e_{\mathrm{máx}} = \frac{100}{\Delta} \max_i |y_i - \hat{y}_i| \quad [\,\%], \qquad E_{\mathrm{rms}} = \frac{100}{\Delta} \sqrt{\frac{1}{n} \sum_i (y_i - \hat{y}_i)^2}, \tag{3}$$

con $\hat{y}$ la curva del injerto. $e_{\mathrm{máx}}$ es el peor punto; E_{rms} (o NRMSE), el apartamiento típico. Dividir por el rango hace el criterio igual de exigente con una arteria blanda que con una rígida. Meta: $e_{\mathrm{máx}} \leq 3$ %. Todo diseño se evalúa contra la curva original.

3.3. Cantidades reales: mínimos cuadrados

Con la base fija, el mejor ajuste cuadrático es $c = A^{+}y$, con A^{+} la seudoinversa de Moore–Penrose [29], calculada por descomposición en valores singulares [15]: exacta, única e instantánea. Con los nudos adoptados el número de condición es 19,0 (5 materiales) y 28,0 (6 materiales), debajo del umbral de 30, y ninguna curva del espacio de trabajo ni ningún sujeto necesita una cantidad negativa. El ajuste cumple la meta en los 41 sujetos, con peor error de 0,88 % (6 materiales; mediana 0,67 %) y 1,41 % (5 materiales; mediana 1,07 %), y en todas las curvas del espacio de trabajo.

3.4. Láminas enteras: tres redondeos

Un injerto se fabrica con un número entero de láminas, $z \in \mathbb{Z}^{N}_{\geq 0}$. Se compararon tres maneras de pasar de c a z:

- **Simple:** cada cantidad al entero más cercano.
- **Conjunto (menor E_{rms}):** como el residuo de mínimos cuadrados es ortogonal a las columnas de A, $E_{\mathrm{rms}}(z)^2 = E_{\mathrm{rms}}(c)^2 + (z-c)^{\top}\tilde{M}(z-c)$, con $\tilde{M} \propto A^{\top}A$ de $N \times N$. Buscar el mejor entero es buscar el punto más cercano de un retículo, que se resuelve en forma exacta por búsqueda en árbol con poda de Schnorr–Euchner [3]. El óptimo puede quedar fuera del piso y el techo de cada cantidad.
- **Minimax (menor $e_{\mathrm{máx}}$):** se busca el túnel más angosto alrededor de la curva que contiene al injerto,

  $$\min_{z,\tau} \ \tau \quad \text{s.a.} \quad -\tau \leq \frac{100}{\Delta}(y_i - (Az)_i) \leq \tau, \qquad z \in \mathbb{Z}^{N}_{\geq 0},$$

  un programa lineal entero mixto (aproximación de Chebyshev [8] con enteros) resuelto por ramificación y acotación con HiGHS [21], en unos 70 ms por curva.

Tabla 2: 41 sujetos, láminas enteras: $e_{\mathrm{máx}}$ mediano / peor [%] y sujetos que cumplen la meta. El espacio de trabajo se evalúa en 2000 curvas al azar con meta de 4 %.

	6 materiales		5 materiales	
Método	41 sujetos	2000 curvas	41 sujetos	2000 curvas
Reales (mínimos cuadrados)	0,67 / 0,88 · 41/41	—	1,07 / 1,41 · 41/41	—
Redondeo simple	2,34 / 7,45 · 25/41	1706	2,23 / 7,48 · 26/41	1616
Conjunto (Schnorr–Euchner)	1,18 / 2,46 · 41/41	1998	1,70 / 3,56 · 40/41	1997
Minimax (MILP)	1,02 / 2,35 · 41/41	2000	1,47 / 3,50 · 40/41	2000

Cada redondeo es el mejor en su propia medida: el conjunto en E_{rms}, el minimax en $e_{\mathrm{máx}}$, que es la medida del criterio de diseño (Tabla 2, Fig. 3). El redondeo simple no es recomendable. Con 6 materiales los 41 sujetos cumplen con láminas enteras; con 5, un sujeto queda en 3,5 %: el límite lo pone tener solo 5 materiales, no el método. **Se adopta el minimax.**

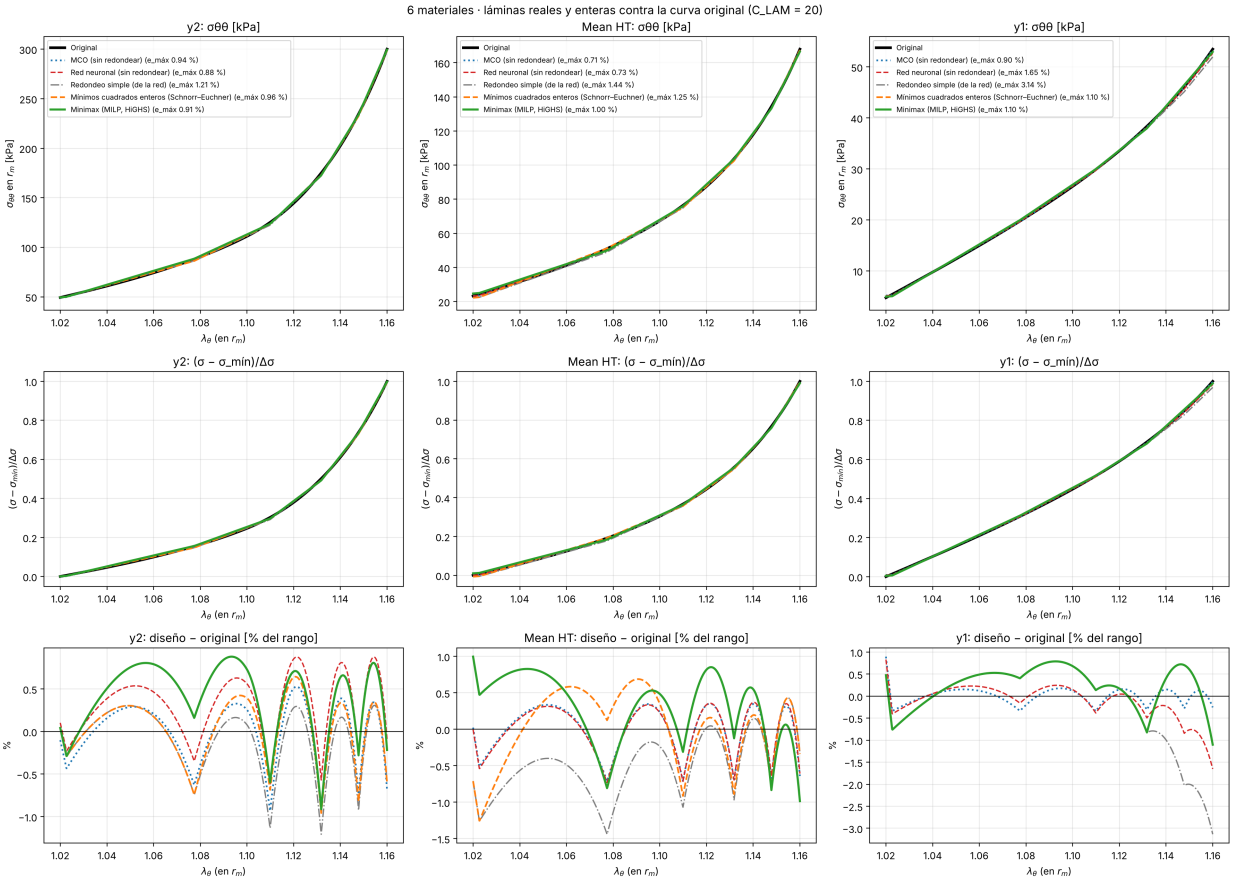


Figura 3: 6 materiales: la curva más rígida de la franja (y_2), la media de los hipertensos y la más blanda (y_1). Arriba: tensión; al medio: forma adimensional; abajo: diseño − original en % del rango. El minimax (verde) reparte el error para que el peor punto sea lo más chico posible.

3.5. La red neuronal

Una red neuronal recibe la curva y devuelve las cantidades de cada material en una sola evaluación: aprende la función $y \mapsto A^{+}y$ para la clase de curvas en J.

Datos. 50 000 curvas en siete familias: de bases (sumas de una o varias láminas de la propia base, 40 %), que enseñan qué hace cada material por separado, y fisiológicas (60 %): ley de Masson mezclada, perturbada o sorteada (las tres familias del espacio de trabajo), otra ley exponencial de cuatro parámetros ajustada a los sujetos, y los sujetos de entrenamiento. La entrada lleva ruido gaussiano de 1 %; la etiqueta es el ajuste de la curva limpia. Partición estratificada: 35 000 de entrenamiento, 5000 de validación y 10 000 de prueba.

Arquitectura y entrenamiento. Perceptrón multicapa [16] $999 \to 256 \to 128 \to 64 \to N$, con entrada $\log(y + 22)$ estandarizada, ReLU [27], normalización por capa [5] y regularización L2 (10^{-5}); unos 298 000 parámetros. Pérdida: error cuadrático de las cantidades, más 5 veces el error de la curva reconstruida, más 5 veces la cantidad asignada a materiales ausentes en las curvas de bases (*crosstalk*). Adam [24] con recorte del gradiente, lotes de 256, reducción de la tasa en meseta y parada temprana [30]; TensorFlow/Keras [2].

Control de clase. Antes de usar la red se verifica que la curva admita una aproximación no negativa con 40 rectas truncadas (NRMSE ≤ 2 %), por mínimos cuadrados no negativos [25]. Una curva que no la admite no tiene forma de J y no puede reproducirse con capas.

Resultados. En los 41 sujetos, la red cumple la meta en todos, con un NRMSE apenas mayor que el óptimo (exceso medio de +3,1 % con 6 materiales y +1,6 % con 5; peor $e_{\text{máx}}$ 1,11 y 1,38 %). En las 10 000 curvas de prueba, las familias fisiológicas quedan entre +1,0 y +3,1 % del óptimo, y la red cumple la meta en el 99,9 al 100 % de cada familia (Tabla 3). Un paso de mínimos cuadrados sobre la salida de la red (pulido) lleva al óptimo exacto. La red tarda 0,06 ms por curva en lote, lo mismo que el ajuste lineal.

Tabla 3: Red frente al ajuste exacto en las 10 000 curvas de prueba (con ruido de 1 % en la entrada), por familia: exceso de NRMSE y porcentaje de curvas en que la red cumple la meta. El ajuste exacto cumple en todas.

		6 materiales		5 materiales	
Familia	n	exceso	cumple	exceso	cumple
Masson, mezcla y perturbación chica	2000	+1,2 %	100 %	+0,6 %	100 %
Masson, mezcla amplia y extrapolación	1500	+1,7 %	100 %	+1,1 %	100 %
Masson, parámetros uniformes	1000	+1,7 %	100 %	+0,7 %	100 %
Otra ley exponencial	1000	+3,1 %	99,9 %	+1,7 %	99,8 %
Sujetos de entrenamiento	500	+1,0 %	100 %	+0,3 %	100 %
De bases, un material	2000	+30,6 %	99,95 %	+17,4 %	100 %
De bases, combinada	2000	+54,6 %	98,5 %	+33,1 %	99,6 %

En las familias de bases el exceso relativo es alto sobre óptimos muy bajos: son poligonales de muy poca tensión, que no representan arterias.

Una ley nunca vista. Se generaron 300 curvas de una ley exponencial de tipo Fung [13], $\sigma = C + a(e^{b(\lambda-\lambda_{\text{mín}})} - 1)$, con parámetros mezclados de los ajustes a los sujetos de entrenamiento y ruido de 1 %; esta ley no está en el entrenamiento. La red las reproduce con un exceso de +4,6 % (6 materiales) y +2,8 % (5) sobre el óptimo, con $R^2 \geq 0{,}996$, y todas admiten un diseño sin cantidades negativas. El control de clase acepta el 100 % de las curvas de Fung y de los sujetos, y rechaza el 98 % de las curvas que dejan de tener forma de J al modularlas con una oscilación.

¿Mejora la red al método exacto? Se probaron tres variantes. (a) Entrenada directamente sobre la curva reconstruida, sin etiquetas, la red llega al mismo ajuste (E_{rms} mediano 0,284 contra 0,280 % con 6 materiales). (b) Entrenada con láminas enteras como etiqueta, sigue dando números con decimales y sus peores casos empeoran. (c) Como suavizador de curvas medidas, antes del minimax, queda prácticamente igual que el ajuste lineal (6 materiales, ruido de 3 %: peor error 2,90 contra 3,84 %; con 5 materiales, 5,31 contra 4,59 %). Lo que sí importa con ruido es no aplicar el minimax a la curva medida, que la copia ruido incluido (mediana 3,86 % con ruido de 3 %), sino a la curva ajustada (1,38 %).

Conclusión del primer nivel

Con materiales tipo fibra y una base elegida una vez, la curva tensión–estiramiento de las 41 carótidas y de las 22 500 curvas del espacio de trabajo se reproduce con láminas enteras dentro de la meta (6 materiales). El método exacto es lineal: mínimos cuadrados y minimax entero. La red lo reproduce en una evaluación y generaliza a una ley que no vio, pero no puede mejorarlo: en el caso lineal la red no es necesaria. Su papel aparece cuando la relación entre la curva y el diseño deja de ser lineal.

4. Aplicación: la curva presión–diámetro y el tubo de pared gruesa

4.1. De la tensión a la presión

Un injerto se implanta como tubo, y lo que debe coincidir con la arteria es su diámetro a cada presión. Para pasar de la tensión a la presión hacen falta la geometría y una hipótesis sobre la pared. La configuración libre de tensiones de la arteria es un sector anular abierto de semiángulo Θ_0 y radio R_m en el borde media–adventicia, que representa las tensiones residuales (Fig. 4). Un punto de radio R en el sector pasa al radio r en la arteria cerrada; su estiramiento y la conservación del volumen dan [26]

$$\lambda_\theta = \frac{\pi r}{\Theta_0 R}, \qquad \Theta_0\,(R_m^2 - R^2) = \pi\lambda_z\,(r_m^2 - r^2). \tag{4}$$

El equilibrio radial integrado sobre el espesor da la presión que soporta la pared íntima–media [26, 22]:

$$P = P_i - P_a = \int_{r_i}^{r_m} \frac{\sigma_{\theta\theta} - \sigma_{rr}}{r}\, dr, \tag{5}$$

con P_i la presión de la sangre y P_a la que ejercen la adventicia y el tejido que rodea a la arteria. Como P_a depende del sitio, el diseño se plantea sobre P, la presión que soporta la pared, que es la que el injerto debe soportar con la misma deformación. El espesor íntima–media h se toma de la mediana de referencia por edad y sexo medida con ecotracking [11] (0,43 a 0,68 mm), porque Masson et al. no publican el de cada sujeto, y $r_i = r_m - h$.

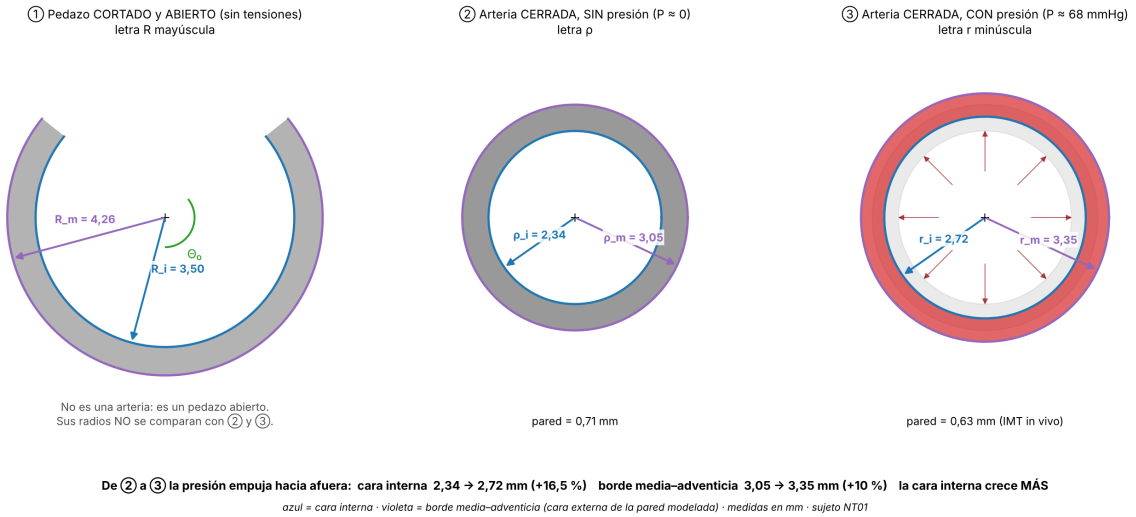


Figura 4: Sujeto NT01 en sus tres estados: (1) sector abierto sin tensiones, (2) arteria cerrada sin presión, (3) arteria con presión. De (2) a (3) la cara interna crece 16,5 % y el borde media–adventicia 10 %.

Ventana de presión. Lo que define si un estado es fisiológico es la presión, no el estiramiento: en $\lambda_\theta = 1{,}16$ el sujeto más rígido soporta unos 400 mmHg y uno blando joven, unos 70. Por eso, en este nivel, todos los sujetos se evalúan en la misma ventana, P de 60 a 200 mmHg (8,0 a 26,7 kPa) en 141 valores, que cubre con margen las presiones medias medidas (64/116 mmHg en NT y 73/127 mmHg en HT [26]). La curva objetivo es el estiramiento del borde media–adventicia, $\lambda(P_k)$, proporcional al diámetro (Fig. 5): los sujetos rígidos llegan a 200 mmHg con λ entre 1,12 y 1,15, los blandos con λ entre 1,20 y 1,23.

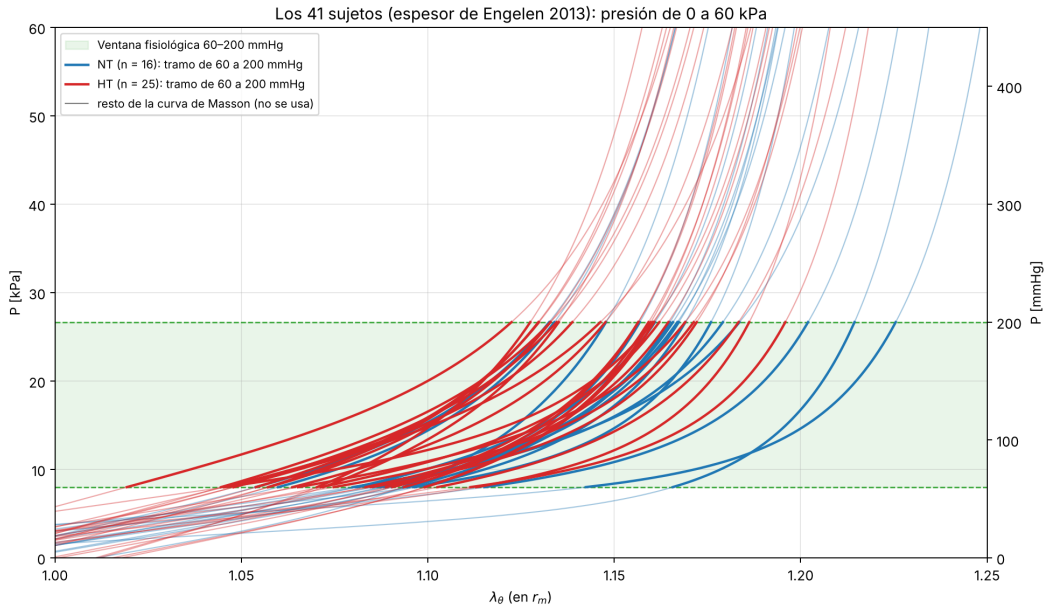


Figura 5: Los 41 sujetos: presión que soporta la pared, $P = P_i - P_a$, en función del estiramiento del borde media–adventicia (izquierda en kPa, derecha en mmHg). Trazo grueso: tramo de 60 a 200 mmHg, que es la curva objetivo.

4.2. Pared delgada y pared gruesa

Si la pared es delgada frente al radio, todas sus fibras se estiran lo mismo y el equilibrio de medio tubo da la ley de Laplace, $P = \sum_j \sigma_j h_j / r$ [13]: la presión es lineal en los espesores de las capas y el diseño hereda todo el método del primer nivel. La carótida, sin embargo, tiene $h/r \approx 0{,}2$. Con pared incompresible y sin alargamiento, el área entre la cara interna y una fibra que estaba en el radio R se conserva,

$$r^2 - r_i^2 = R^2 - R_i^2, \qquad \lambda(r) = \frac{r}{R}, \tag{6}$$

y las fibras internas se estiran más que las externas (Fig. 6). La presión es la suma exacta del aporte de cada capa delgada, cada una con su propio estiramiento:

$$P = \sum_{j=1}^{N} \int_{\text{capa } j} \frac{\sigma_j\big(\lambda(r)\big)}{r}\, dr. \tag{7}$$

Si $h \ll r$, (7) se reduce a Laplace. Con rectas truncadas, la diferencia de estiramiento decide si una capa tira o no: un material de nudo 1,08 tira en la cara interna de un tubo inflado ($\lambda = 1{,}10$) y no en la externa ($\lambda = 1{,}07$). Además las capas interactúan: si crece una capa interna, las de afuera se corren a radios mayores, se estiran menos y aportan menos. En pared gruesa la presión deja de ser lineal en los espesores.

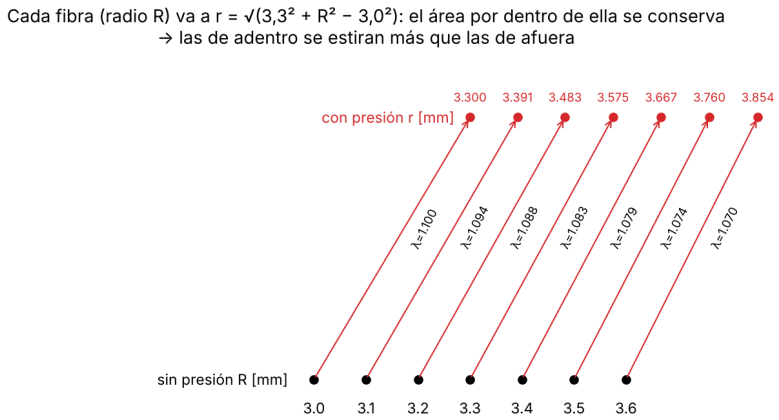


Figura 6: Tubo de 3,0 a 3,6 mm inflado hasta una cara interna de 3,3 mm: cada fibra conserva el área que tiene por dentro; la cara interna se estira 10 % y la externa 7 %.

La pared delgada falla al fabricar. Se diseñó cada sujeto con tres hipótesis —Laplace, Laplace con el radio medio deformado (como en [39]) y pared gruesa— y cada diseño se evaluó en el tubo real, de pared gruesa (Tabla 4, Fig. 7). En su propio modelo Laplace parece perfecto ($e_{\text{máx}} \leq 1{,}7$ %); el error aparece al fabricar y crece con el espesor de la pared. Corregir el radio no ayuda, porque el problema no es el radio sino que cada capa se estira distinto y engancha en otro momento. Con la ventana de presión y la base adoptada, el diseño lineal de pared delgada tampoco cumple en ningún sujeto (mediana 27,3 % con 6 materiales y 29,9 % con 5). **El diseño a nivel del tubo debe hacerse en pared gruesa.**

Tabla 4: Comparación de hipótesis sobre curvas de presión en λ de 1,02 a 1,16 (etapa previa, con otro juego de nudos): diseño con cada hipótesis, evaluado en el tubo de pared gruesa. 41 sujetos; cumplen / mediana / peor $e_{\text{máx}}$.

Hipótesis de diseño	5 materiales	6 materiales
Laplace	0/41 · 13,6 % · 22,7 %	0/41 · 14,8 % · 32,5 %
Laplace con radio medio	0/41 · 13,7 % · 24,5 %	0/41 · 15,4 % · 34,4 %
Pared gruesa	41/41 · 0,96 % · 2,97 %	41/41 · 0,72 % · 2,10 %

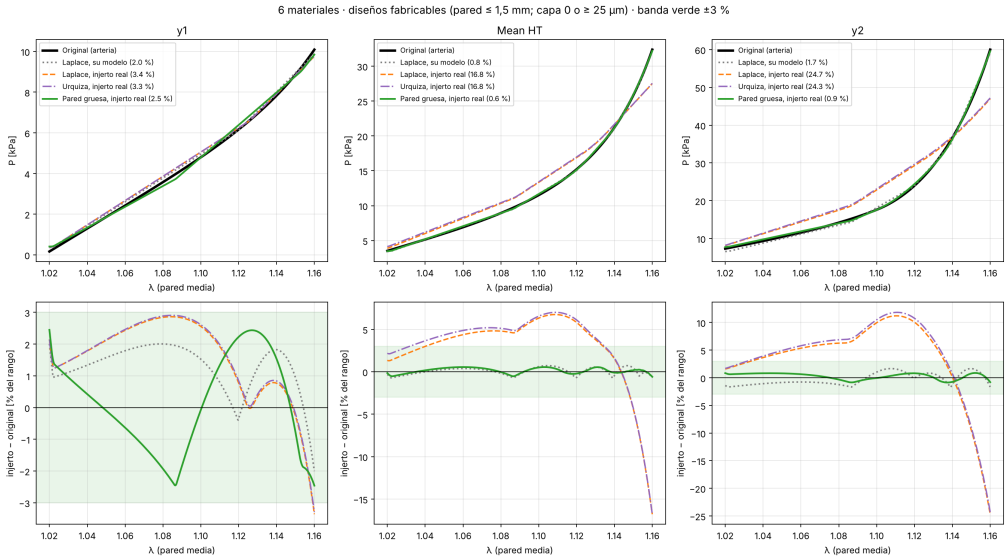


Figura 7: Etapa de la Tabla 4, 6 materiales: curva más rígida (y_2), media de los hipertensos y más blanda (y_1). Arriba de cada par: curvas; abajo: injerto − arteria en % del rango (banda ±3 %). El diseño de Laplace evaluado en su propio modelo (naranja) parece perfecto; fabricado (rojo), se aparta hasta 25 %.

4.3. El injerto de pared gruesa

El injerto es un tubo cerrado, incompresible y en deformación plana, con una capa por material apilada de adentro hacia afuera por nudo creciente (el orden inverso duplica o triplica el error), centrado en $R_{\text{ref}} = 3{,}421\,\text{mm}$ (mediana de $\Theta_0 R_m/\pi$ de los 41 sujetos). Los materiales son los del primer nivel: los mismos nudos y rectas $\sigma_j = E_j\,\text{máx}(0, \lambda - \kappa_j)$, con módulos E_j calibrados una vez para que el sujeto de entrenamiento que más necesita de cada material use 0,2 mm de él (6 materiales: de 452 a 4966 kPa). El diseño es

$$\theta = (h_1, \ldots, h_N,\ \delta), \qquad 0 \le h_j \le 3\ \text{mm}, \quad |\delta| \le 0{,}25. \tag{8}$$

- **Espesores** h_j, que se fabrican con n_j láminas enteras de espesor e.
- **Enganche y preestiramiento.** Cada capa engancha cuando la pared media llega a $k_j + \delta$; su enganche local κ_j es el estiramiento del centro de la capa en ese momento, por (6). En fabricación, κ_j es el rizado de las fibras de esa capa. El preestiramiento común δ corre todos los nudos juntos: cada sujeto ocupa su propio tramo de estiramiento (de 1,02 a 1,23), y sin δ vería solo uno o dos nudos, con un error típico de 11 %.

La presión (7) se integra en cada capa con cuadratura de Gauss–Legendre de 8 nodos [9] en 651 valores de λ entre 0,80 y 1,45, y se invierte por interpolación lineal para obtener $\lambda_{\text{inj}}(P_k; \theta)$. La función $\theta \mapsto \lambda_{\text{inj}}$ es no lineal: los espesores fijan los límites de integración y los enganches, y δ entra dentro del máx$(0, \cdot)$. Con láminas enteras, encontrar los n_j es un problema **no lineal entero mixto**. La métrica es (3) sobre $\lambda(P_k)$.

4.4. Métodos de diseño

Tabla 5: Bloques de cálculo a nivel del tubo. "Lineal" se refiere a la dependencia del modelo respecto de las incógnitas.

Bloque	Variables	¿Lineal?	Algoritmo	Implementación
A1 MCO lineal (pared delgada)	reales	sí, con δ fijo	mínimos cuadrados por SVD; δ por grilla y Brent	`numpy.linalg.lstsq` [17]; `minimize_scalar` [7, 40]
A2 MCO no lineal (pared gruesa)	reales	no	región de confianza reflexiva con cotas (TRF)	`scipy.optimize.least_squares` [6, 40]
A3 Minimax entero (pared gruesa)	láminas enteras, δ real	no	enumeración piso/techo, δ por Brent acotado, búsqueda local	propio; `minimize_scalar` [7]
A4 Red neuronal	reales	— (una evaluación)	perceptrón multicapa; optimización amortizada	TensorFlow/Keras [2]

A1 · MCO lineal de pared delgada. Con la ley de Laplace y δ fijo, la presión es lineal en $c_j = E_j h_j / R_{\text{ref}}$: $P_k \approx \sum_j c_j \,\text{máx}(0, y_k - k_j - \delta)$. Para cada δ de una grilla de 101 valores se resuelve por mínimos cuadrados; el residuo en presión se pasa a λ con la pendiente local de la curva; el mejor δ se refina por Brent [7] y $h_j = c_j R_{\text{ref}}/E_j$, recortados a $[0; 3]$ mm. Es el método del primer nivel, trasladado al tubo.

A2 · MCO no lineal de pared gruesa. Minimiza $\sum_k \big((\lambda_{\text{inj}}(P_k;\theta) - y_k)/\Delta\big)^2$ con las cotas (8), por el método de región de confianza reflexiva (*Trust Region Reflective*, TRF) [6]. En cada iteración calcula el jacobiano de los residuos por diferencias finitas, aproxima el problema por su modelo cuadrático de Gauss–Newton y toma el paso que lo minimiza dentro de una *región de confianza*, un entorno donde el modelo es creíble; agranda la región si el paso funcionó y la achica si no, y refleja hacia adentro los pasos que cruzan una cota. Tolerancias 10^{-10}, a lo sumo 300 evaluaciones. Encuentra un mínimo *local*: el resultado depende del punto de partida.

A3 · Minimax entero. Es el minimax del primer nivel, llevado al caso no lineal, donde ya no hay programa lineal que lo resuelva en forma exacta. A partir de un diseño real $\theta^\star$ y una curva de referencia $\tilde{y}$: (1) $n_j \in \{\lfloor h_j^\star/e \rfloor, \lceil h_j^\star/e \rceil\}$; se evalúan las 2^N combinaciones por $e_{\text{máx}}$ contra $\tilde{y}$; (2) para las 8 mejores se reajusta δ en $\pm 0{,}03$ por Brent acotado; (3) búsqueda local [1]: vecinos que suman o restan una lámina a un material o pasan una lámina de uno a otro, aceptando el mejor si baja el peor error, hasta 20 veces. Es una heurística: no garantiza el óptimo entero global.

A4 · Red neuronal. La misma arquitectura del primer nivel, $141 \to 256 \to 128 \to 64 \to N{+}1$: recibe la curva $\lambda(P_k)$ estandarizada y devuelve θ. Datos: 6000 injertos con diseño sorteado, cuya etiqueta es exactamente su diseño, y 9000 arterias sintéticas de la ley de Masson más los 31 sujetos de entrenamiento, cuya etiqueta es el ajuste A2; ruido nuevo de 0 a 1 % del rango de λ en cada época. Partición 11 220 / 1530 / 2250; 425 épocas (6 materiales) y 629 (5). Se usa como *optimización amortizada* [4]: un modelo aprendido sobre muchos casos resueltos propone la solución de uno nuevo, y un optimizador clásico la termina.

El procedimiento. Los bloques se encadenan en tres pasos (Fig. 8): (1) arranque, A1 (camino A) o la red A4 (camino B); (2) A2, que ajusta el diseño a la curva; (3) A3, que elige las láminas contra la *curva ajustada* del paso 2. Es la conclusión del primer nivel sobre el ruido: el paso 2 suaviza, porque la curva de un injerto no puede tener los saltos del ruido, y el paso 3 no lo persigue.

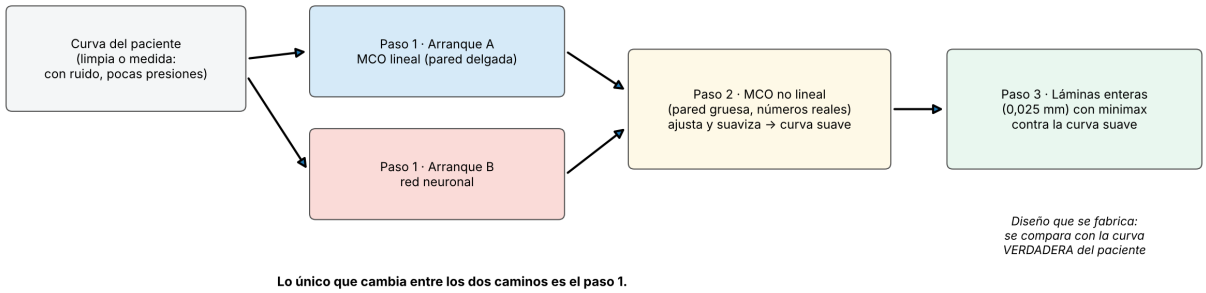


Figura 8: El procedimiento de diseño a nivel del tubo. Los dos caminos solo difieren en el paso 1.

Curvas medidas. En la práctica la curva del paciente se mide, con ruido y en pocas presiones. Se simulan: (a) ruido gaussiano proporcional de 0,3 % en λ (el ecotracking resuelve unos 20 µm en 7 mm); (b) medición en 10 presiones con interpolación cúbica monótona (PCHIP) [12] a las 141; (c) ambas, con ruido de 0,2 %. Cada camino recibe la curva medida y su diseño entero se compara con la curva verdadera; una realización por sujeto y caso. Como $\lambda \approx 1{,}1$ y su rango es de unos 0,07, un ruido de 0,3 % de λ equivale a alrededor del 5 % del rango: mayor que la meta.

4.5. Resultados

Diseño real. Desde el arranque lineal, A2 deja 40 de los 41 sujetos dentro de la meta (6 materiales: mediana 0,84 %, peor 3,43 %; 5 materiales: 40/41, peor 3,14 %), con paredes de 0,75 a 1,89 mm y δ de $-0{,}04$ a $+0{,}09$. Arrancando desde la red llega a 41 de 41 con 6 materiales (peor 1,79 %), con la mitad de evaluaciones del modelo (16 contra 35 por sujeto). Sola, la red no alcanza: mediana 3,43 % y peor 89,6 %. En los 10 sujetos de prueba el híbrido da 0,93 % de mediana y 1,79 % el peor.

Espesor de lámina. Con láminas de 0,1, 0,05 y 0,025 mm cumplieron la meta 38, 40 y 41 de los 41 sujetos (6 materiales; peor 5,44, 3,69 y 1,64 %; unas 10, 23 y 46 láminas). Se adoptó $e = 0{,}025$ mm.

El procedimiento completo. Con curvas limpias los dos arranques empatan (Tabla 6, Fig. 9). La diferencia está en el peor caso con curvas medidas: con 10 presiones, el arranque lineal cae en un mínimo local en dos sujetos (NT03 y HT04, 468,7 %), que el arranque de la red evita; con ruido de 0,3 %, la red aumenta los sujetos dentro de la meta (31 contra 23 con 6 materiales; 32 contra 25 con 5). Con 10 presiones y ruido ninguno pasa de 8 de 41: ese ruido ya es comparable a la meta. El tiempo es de 0,2 a 0,5 s por sujeto con cualquiera de los dos arranques.

Tabla 6: Procedimiento completo con láminas de 0,025 mm: peor error contra la curva verdadera [%], 41 sujetos.

		6 materiales			5 materiales		
Curva	Arranque	mediana	peor	cumplen	mediana	peor	cumplen
limpia	MCO lineal	1,13	3,26	40/41	1,69	3,21	40/41
	red	1,14	2,19	41/41	1,68	3,19	40/41
10 presiones	MCO lineal	1,26	468,7	38/41	1,62	3,13	40/41
	red	1,19	2,27	41/41	1,61	2,70	41/41
ruido 0,3 %	MCO lineal	2,67	11,87	23/41	2,66	7,52	25/41
	red	2,19	6,59	31/41	2,32	9,24	32/41
10 pres. + ruido 0,2 %	MCO lineal	4,36	8,07	8/41	4,62	8,77	6/41
	red	3,78	8,54	8/41	4,75	10,35	6/41

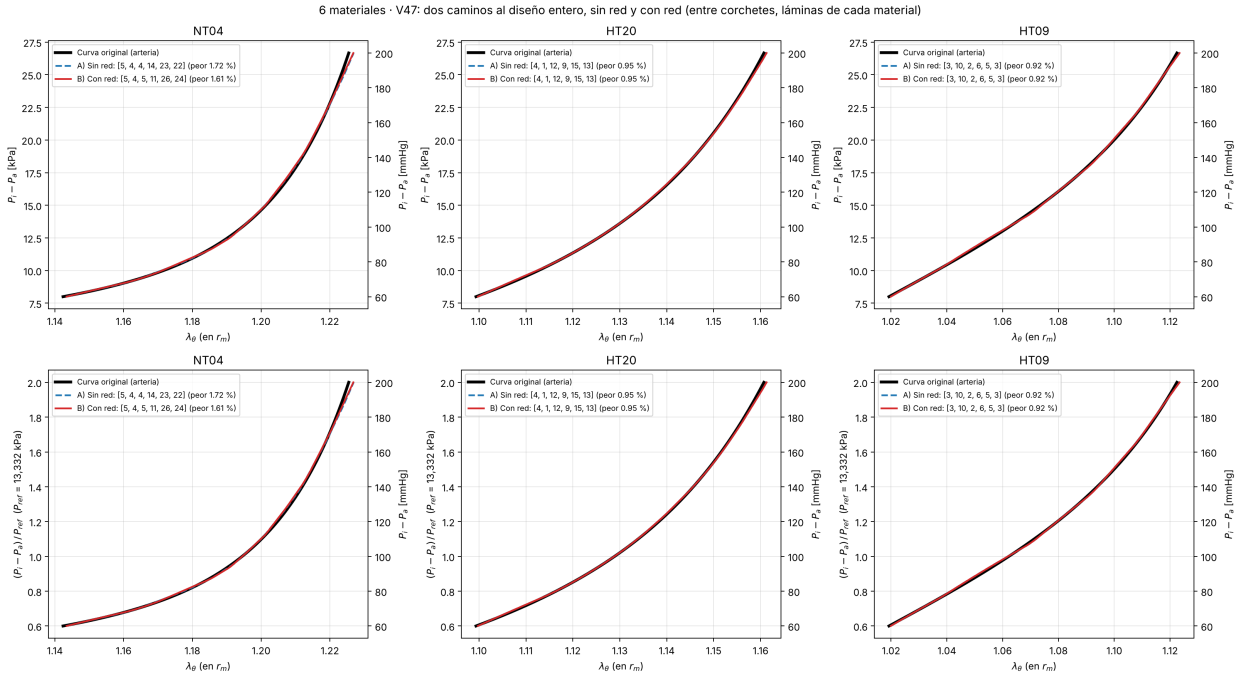


Figura 9: 6 materiales, curvas limpias: el sujeto más blando, uno intermedio y el más rígido. Negra: arteria; azul: camino A (arranque MCO lineal); roja: camino B (arranque red). Ordenada: presión que soporta la pared, arriba en kPa y abajo relativa a 13,332 kPa; a la derecha, mmHg. Entre corchetes, láminas de cada material.



Figura 10: 6 materiales, curvas medidas: peor error de cada sujeto contra la curva verdadera (escala logarítmica; azul, arranque MCO lineal; rojo, arranque red; punteada, meta).

Contra qué curva elegir las láminas. Si el paso 3 elige las láminas contra la curva tal como viene medida, persigue el peor punto, que con ruido es un salto del ruido (Fig. 11). Contra la curva ajustada del paso 2, con ruido de 0,3 % y arranque red, cumplen 31 sujetos en lugar de 10 (6 materiales) y 32 en lugar de 5 (5 materiales); el costo con curvas limpias es de 0,2 puntos de mediana.

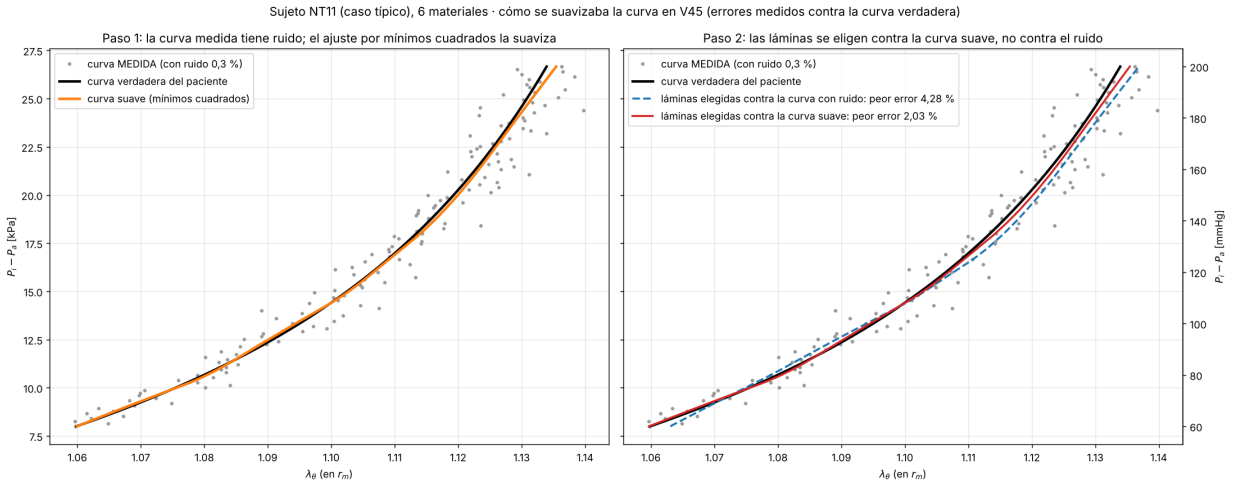


Figura 11: Sujeto NT11, 6 materiales, ruido de 0,3 %. Izquierda: la curva ajustada por el paso 2 (naranja) pasa por el medio de la medida (gris). Derecha: láminas elegidas contra la curva medida ($e_{\text{máx}} = 4{,}28$ %) y contra la ajustada (2,03 %), ambas evaluadas contra la verdadera.

5. Discusión

Por qué dos niveles. La curva tensión–estiramiento es una propiedad del tejido. Trabajar primero sobre ella permite validar cada pieza del método —la base, el ajuste, el redondeo, la red— contra soluciones exactas, sin que intervengan la geometría ni la presión, que dependen de cada arteria y de cada sitio. El paso al tubo agrega la geometría y la hipótesis de pared gruesa, pero conserva los materiales, la métrica, el criterio minimax y la conclusión sobre el ruido.

Generalidad. Lo que se valida en el primer nivel no es propio de la carótida: los materiales tipo fibra, la base elegida sobre un espacio amplio de curvas en J, el redondeo minimax y una red que reproduce el ajuste en curvas de una ley que nunca vio. Para otra arteria cambian la geometría, el espesor y la ventana de presión, que entran recién en el segundo nivel; la franja de curvas y, si hiciera falta, los nudos se recalculan con el mismo procedimiento. El control de clase indica cuándo una curva queda fuera del alcance del método. La prueba con mediciones de otras arterias es el paso siguiente.

El papel de la red neuronal. En el caso lineal la solución exacta es inmediata y la red solo puede imitarla, aunque lo hace en una evaluación y generaliza. En pared gruesa el ajuste es iterativo, local y depende del punto de partida: el arranque clásico, heredado del caso lineal, ignora el gradiente de estiramiento en el espesor y, con curvas medidas, puede llevar a mínimos locales que dan diseños inservibles. La red, entrenada sobre miles de diseños resueltos, deja al ajuste cerca del mínimo correcto. Es la idea de la optimización amortizada [4]: la red no reemplaza al optimizador, lo inicia. Su ventaja es de robustez, clara con 6 materiales y menor con 5.

Por qué pared gruesa. La diferencia entre los modelos está en una sola hipótesis: en pared delgada todas las fibras se estiran igual; en pared gruesa cada una tiene su estiramiento, fijado por la incompresibilidad. Con materiales que no tiran hasta su nudo, esa diferencia de pocos centésimos decide si una capa trabaja. El enganche de cada capa (su rizado) es tan importante como su espesor: entre un diseño de Laplace y uno de pared gruesa los espesores cambian pocos micrómetros, pero las capas externas enganchan antes.

Limitaciones. (1) Las curvas objetivo son las de la ley ajustada por Masson et al., no las mediciones crudas, y el espesor arterial es el de referencia para la edad y el sexo. (2) Los materiales son ideales (rectas truncadas de rigidez constante); el injerto no tiene alargamiento axial ni tensiones residuales, y no se consideran viscoelasticidad ni fatiga. (3) La búsqueda entera en pared gruesa es heurística, y se usó una sola realización de ruido por sujeto y caso. (4) El preestiramiento δ y el rizado por capa son variables de fabricación que deben validarse. (5) No hay validación experimental.

6. Conclusiones

1. Un injerto de capas de materiales tipo fibra (rectas truncadas), con una base elegida una vez para toda la población, reproduce la curva tensión–estiramiento de 41 carótidas humanas y de 22 500 curvas sintéticas. Con 6 materiales y láminas enteras por minimax, los 41 sujetos cumplen la meta de 3 %.
2. En el caso lineal, el método exacto es mínimos cuadrados más minimax entero (programación lineal entera). La red neuronal lo reproduce en una evaluación y generaliza a una ley constitutiva no vista (exceso de 2,8 a 4,6 %), pero no lo mejora.
3. A nivel del tubo el diseño debe hacerse en pared gruesa: diseñado con la ley de Laplace, ningún sujeto cumple al fabricarse; en pared gruesa cumplen 40–41 de 41. El problema es no lineal entero.

4. El procedimiento de tres pasos —arranque, mínimos cuadrados no lineales y láminas enteras por minimax contra la curva ajustada— cumple en 40–41 de 41 sujetos con curvas limpias, en menos de medio segundo por sujeto.

5. En pared gruesa, la red como punto de partida evita los mínimos locales que, con curvas medidas, producen diseños inservibles (peor caso de 468,7 a 2,3 %) y aumenta los sujetos dentro de la meta con ruido. Es el papel justificado de la red: iniciar el optimizador, no reemplazarlo.

Próximos pasos. Probar el método con curvas medidas de otras arterias; ensayar materiales reales para reemplazar las rectas ideales y validar el rizado como variable de fabricación; usar el espesor y la presión medidos de cada sujeto; y fabricar y ensayar un injerto.

A. Parámetros de los 41 sujetos

Tabla 7: Parámetros de Masson et al. [26] (sus Tablas 2 y 4). †: sujeto reservado para prueba.

Sujeto	Edad [años]	Sexo	R_m [mm]	Θ_0 [°]	λ_z	c [kPa]	c_1 [kPa]	c_2	c_1^{circ} [kPa]	c_2^{circ}	α [°]	T_m [kPa]	λ_0	λ_m	a [kPa]	b
NT01	62	F	4,26	128,70	1,11	29,82	9,44	14,14	16,13	15,11	65,74	39,73	0,960	1,70	0,122	3,52
NT02†	60	M	4,69	128,90	1,08	20,42	8,47	13,10	14,16	15,12	44,46	41,84	0,680	1,92	0,126	3,40
NT03	31	M	4,30	132,20	1,09	27,23	10,34	13,10	7,01	12,82	48,62	43,37	0,820	1,65	0,139	3,57
NT04	31	M	4,67	133,90	1,10	23,59	6,58	11,77	6,38	10,69	32,04	39,81	0,680	1,59	0,118	3,53
NT05	34	F	4,20	130,10	1,10	35,68	13,62	13,18	13,38	13,17	50,72	50,07	0,860	1,62	0,103	3,58
NT06	53	F	3,96	130,10	1,11	33,37	11,38	13,63	13,30	14,26	57,14	46,59	0,950	1,69	0,093	3,44
NT07	21	F	3,83	132,00	1,10	44,28	21,79	13,17	8,27	12,73	51,15	53,58	0,920	1,62	0,111	3,58
NT08†	25	M	4,86	133,20	1,07	23,25	6,34	12,93	8,11	13,17	42,93	31,90	0,820	1,77	0,173	3,57
NT09	42	F	4,51	129,50	1,10	34,90	16,14	13,58	19,64	13,89	57,21	47,01	0,930	1,65	0,084	3,55
NT10†	55	M	4,77	129,10	1,10	38,57	36,31	13,31	56,88	13,61	54,22	46,36	0,890	1,66	0,006	3,75
NT11†	64	M	5,57	129,50	1,10	34,89	40,16	13,45	66,88	13,53	54,54	41,12	0,850	1,79	0,005	3,23
NT12	60	F	4,88	130,10	1,09	33,94	10,78	13,95	12,79	15,42	60,97	45,77	0,930	1,73	0,099	3,37
NT13	61	F	4,92	130,60	1,09	35,15	17,69	13,43	18,40	13,22	55,04	45,59	0,940	1,66	0,085	3,51
NT14	39	F	3,54	131,50	1,09	28,97	8,22	13,13	19,02	13,16	50,22	41,30	0,890	1,67	0,105	3,53
NT15	58	F	3,92	132,40	1,08	26,71	15,79	13,36	16,68	13,11	53,60	35,32	0,950	1,71	0,166	3,60
NT16	60	M	5,72	129,70	1,10	27,79	28,23	13,46	57,77	13,63	55,73	36,50	1,05	1,77	0,141	3,58
HT01	68	M	4,96	130,90	1,10	35,91	12,57	14,08	15,52	14,91	67,18	48,42	0,990	1,66	0,098	3,50
HT02	54	M	4,93	129,80	1,10	38,20	16,40	13,20	16,44	13,20	51,11	52,44	0,860	1,62	0,137	3,58
HT03†	64	F	4,87	129,50	1,10	36,01	14,55	13,96	18,35	14,48	62,66	47,02	1,00	1,74	0,113	3,62
HT04	58	F	4,57	131,20	1,09	22,42	8,57	13,03	6,43	13,36	46,38	38,53	0,810	1,68	0,099	3,51
HT05†	62	F	4,78	130,10	1,10	48,19	35,06	13,23	43,19	13,03	53,24	52,86	0,910	1,63	0,033	3,56
HT06	66	F	5,06	129,10	1,10	39,78	37,75	13,35	60,89	13,45	56,01	46,44	0,910	1,64	0,004	3,54
HT07	54	F	4,30	129,60	1,11	50,45	25,51	13,32	39,43	13,24	53,47	64,91	0,930	1,66	0,078	3,72
HT08	63	F	4,44	129,00	1,10	34,44	30,62	13,29	60,33	13,21	54,67	44,94	0,930	1,65	0,084	3,56
HT09	68	M	5,09	128,20	1,12	51,48	33,77	13,17	44,26	13,49	51,83	66,41	0,840	1,62	0,023	3,55
HT10	55	F	4,30	129,00	1,10	37,04	12,32	14,13	15,04	14,93	65,14	48,19	1,04	1,71	0,114	3,47
HT11	69	M	5,54	131,20	1,08	29,64	9,76	13,23	9,10	15,12	48,16	37,83	0,830	1,74	0,115	3,59
HT12	54	M	5,43	131,80	1,09	32,23	17,81	13,35	14,03	12,15	53,73	44,93	0,920	1,65	0,090	3,58
HT13†	61	M	5,17	128,40	1,11	30,45	15,87	13,08	23,03	13,84	47,86	52,58	0,750	1,61	0,009	3,49
HT14†	60	M	4,64	129,90	1,10	30,43	13,74	13,45	18,01	13,35	54,90	42,43	0,910	1,66	0,088	3,52
HT15	53	M	4,65	130,40	1,10	40,83	28,98	13,36	31,16	12,62	54,44	49,57	0,930	1,65	0,085	3,63
HT16	54	M	4,71	129,60	1,10	45,26	29,27	14,00	33,48	14,82	67,16	67,68	1,02	1,65	0,039	3,52
HT17	53	M	5,04	130,00	1,10	37,25	39,18	13,24	66,29	13,15	54,90	48,26	0,910	1,64	0,099	3,60
HT18	52	M	4,92	129,70	1,10	29,28	10,50	13,21	19,76	13,39	50,96	46,42	0,850	1,63	0,094	3,56
HT19†	57	F	4,27	130,30	1,10	33,49	14,47	13,22	17,35	13,27	53,18	46,18	0,900	1,64	0,097	3,55
HT20	61	F	5,14	129,20	1,10	40,09	15,72	14,09	16,78	14,83	65,17	53,40	1,04	1,70	0,100	3,47
HT21	57	F	4,88	129,90	1,10	35,31	14,57	13,26	15,58	13,30	52,07	48,97	0,870	1,63	0,094	3,57
HT22	44	F	4,17	131,00	1,10	55,25	35,78	13,23	19,51	12,55	52,36	59,58	0,930	1,61	0,097	3,61
HT23	51	M	4,83	130,60	1,08	30,77	12,80	13,60	41,10	14,20	49,79	41,06	0,870	1,90	0,094	3,56
HT24†	65	M	4,57	129,60	1,10	38,91	25,76	13,20	35,01	13,20	51,94	50,28	0,870	1,62	0,043	3,58
HT25	67	F	4,72	129,20	1,10	40,29	31,78	13,75	60,40	14,29	63,50	46,06	1,03	1,72	0,025	3,46

Referencias

[1] Aarts, E., Lenstra, J. K. (eds.) (1997). *Local Search in Combinatorial Optimization*. Wiley.

[2] Abadi, M., et al. (2016). TensorFlow: a system for large-scale machine learning. *Proc. 12th USENIX OSDI*, 265–283.

[3] Agrell, E., Eriksson, T., Vardy, A., Zeger, K. (2002). Closest point search in lattices. *IEEE Trans. Inf. Theory* 48(8), 2201–2214.

[4] Amos, B. (2023). Tutorial on amortized optimization. *Found. Trends Mach. Learn.* 16(5), 592–732.

[5] Ba, J. L., Kiros, J. R., Hinton, G. E. (2016). Layer normalization. arXiv:1607.06450.

[6] Branch, M. A., Coleman, T. F., Li, Y. (1999). A subspace, interior, and conjugate gradient method for large-scale bound-constrained minimization problems. *SIAM J. Sci. Comput.* 21(1), 1–23.

[7] Brent, R. P. (1973). *Algorithms for Minimization without Derivatives*. Prentice-Hall.

[8] Cheney, E. W. (1966). *Introduction to Approximation Theory*. McGraw-Hill.

[9] Davis, P. J., Rabinowitz, P. (1984). *Methods of Numerical Integration*, 2.ª ed. Academic Press.

[10] Ding, X., Sha, D., Sun, K., Fan, Y. (2025). Biomechanical insights into the development and optimization of small-diameter vascular grafts. *Acta Biomater.* doi:10.1016/j.actbio.2025.04.028.

[11] Engelen, L., Ferreira, I., Stehouwer, C. D. A., Boutouyrie, P., Laurent, S.; Reference Values for Arterial Measurements Collaboration (2013). Reference intervals for common carotid intima-media thickness measured with echotracking: relation with risk factors. *Eur. Heart J.* 34(30), 2368–2380.

[12] Fritsch, F. N., Carlson, R. E. (1980). Monotone piecewise cubic interpolation. *SIAM J. Numer. Anal.* 17(2), 238–246.

[13] Fung, Y. C. (1993). *Biomechanics: Mechanical Properties of Living Tissues*, 2.ª ed. Springer.

[14] Furdella, K. J., Higuchi, S., Behrangzade, A., Kim, K., Wagner, W. R., Vande Geest, J. P. (2021). In-vivo assessment of a tissue engineered vascular graft computationally optimized for target vessel compliance. *Acta Biomater.* 123, 298–311.

[15] Golub, G. H., Van Loan, C. F. (2013). *Matrix Computations*, 4.ª ed. Johns Hopkins University Press.

[16] Goodfellow, I., Bengio, Y., Courville, A. (2016). *Deep Learning*. MIT Press.

[17] Harris, C. R., et al. (2020). Array programming with NumPy. *Nature* 585, 357–362.

[18] Harrison, S., Tamimi, E., Uhlorn, J., Leach, T., Vande Geest, J. P. (2016). Computationally optimizing the compliance of a biopolymer based tissue engineered vascular graft. *J. Biomech. Eng.* 138(1), 014505.

[19] Holzapfel, G. A., Gasser, T. C., Ogden, R. W. (2000). A new constitutive framework for arterial wall mechanics and a comparative study of material models. *J. Elasticity* 61, 1–48.

[20] Hsu, R., Szafron, J. M., Carvalho, C. C., Humphrey, J. D., Marsden, A. L. (2025). Constrained optimization of scaffold behavior for improving tissue engineered vascular grafts. *J. Biomech.* doi:10.1016/j.jbiomech.2025.112670.

[21] Huangfu, Q., Hall, J. A. J. (2018). Parallelizing the dual revised simplex method. *Math. Program. Comput.* 10, 119–142.

[22] Humphrey, J. D. (2002). *Cardiovascular Solid Mechanics: Cells, Tissues, and Organs*. Springer.

[23] Jiang, D., Robinson, A. J., Nkansah, A., et al. (2025). A computational framework to optimize the mechanical behavior of synthetic vascular grafts. *J. Mech. Behav. Biomed. Mater.* 163, 106847.

[24] Kingma, D. P., Ba, J. (2015). Adam: a method for stochastic optimization. *Proc. ICLR*.

[25] Lawson, C. L., Hanson, R. J. (1995). *Solving Least Squares Problems*. SIAM.

[26] Masson, I., Beaussier, H., Boutouyrie, P., Laurent, S., Humphrey, J. D., Zidi, M. (2011). Carotid artery mechanical properties and stresses quantified using in vivo data from normotensive and hypertensive humans. *Biomech. Model. Mechanobiol.* 10(6), 867–882.

[27] Nair, V., Hinton, G. E. (2010). Rectified linear units improve restricted Boltzmann machines. *Proc. ICML*.

[28] Nelder, J. A., Mead, R. (1965). A simplex method for function minimization. *Computer J.* 7(4), 308–313.

[29] Penrose, R. (1955). A generalized inverse for matrices. *Math. Proc. Cambridge Philos. Soc.* 51(3), 406–413.

[30] Prechelt, L. (1998). Early stopping — but when? En *Neural Networks: Tricks of the Trade*, LNCS 1524, 55–69.

[31] Rachev, A., Hayashi, K. (1999). Theoretical study of the effects of vascular smooth muscle contraction on strain and stress distributions in arteries. *Ann. Biomed. Eng.* 27, 459–468.

[32] Rockafellar, R. T., Uryasev, S. (2000). Optimization of conditional value-at-risk. *J. Risk* 2(3), 21–41.

[33] Rovas, G., Bikia, V., Stergiopulos, N. (2023). Design and computational optimization of compliance-matching aortic grafts. *Front. Bioeng. Biotechnol.* 11, 1179174.

[34] Rovas, G., Reymond, P., van Steenberghe, M., et al., Stergiopulos, N. (2025). Evaluation of a novel compliance-matching aortic graft in a swine model. *J. Biomech.* doi:10.1016/j.jbiomech.2025.112629.

[35] Storn, R., Price, K. (1997). Differential evolution: a simple and efficient heuristic for global optimization over continuous spaces. *J. Global Optim.* 11, 341–359.

[36] Szafron, J. M., Ramachandra, A. B., Breuer, C. K., Marsden, A. L., Humphrey, J. D. (2019). Optimization of tissue-engineered vascular graft design using computational modeling. *Tissue Eng. Part C.* doi:10.1089/ten.tec.2019.0086.

[37] Tamimi, E. A., Ardila, D. C., Ensley, B. D., Kellar, R. S., Vande Geest, J. P. (2019). Computationally optimizing the compliance of multilayered biomimetic tissue engineered vascular grafts. *J. Biomech. Eng.* doi:10.1115/1.4042902.

[38] Trefethen, L. N., Bau, D. (1997). *Numerical Linear Algebra.* SIAM.

[39] Urquiza, S. A. (2012). Tesis doctoral, cap. 3: Modelos hemodinámicos unidimensionales.

[40] Virtanen, P., et al. (2020). SciPy 1.0: fundamental algorithms for scientific computing in Python. *Nat. Methods* 17, 261–272.