Diseño de injertos vasculares multicapa que reproducen la curva tensión–estiramiento de cada arteria: bases de materiales, láminas enteras, pared gruesa y una red neuronal

Pablo Silvoni

9 de noviembre de 2026

Resumen

Un injerto vascular que se distiende distinto que la arteria que reemplaza favorece la trombosis y la hiperplasia de la íntima. Los métodos de diseño publicados ajustan un único número —la compliancia de una arteria promedio—. Aquí se presenta un método para diseñar, paciente por paciente, un injerto multicapa que reproduzca la *curva completa* de la arteria, con su forma de J. Cada material del injerto se idealiza como una fibra que no tira hasta un estiramiento propio (recta truncada), y la arteria se aproxima por una suma de esos materiales, elegidos una vez para toda la población, con a lo sumo 20 láminas por material. El método se valida primero sobre la curva tensión circunferencial–estiramiento circunferencial, $\sigma_{\theta\theta}(\lambda_\theta)$, que no depende de la presión ni de la geometría de la pared. Con 41 carótidas humanas (Masson et al.), el diseño entero minimax —el mejor diseño entero que existe, por programación lineal entera— cumple la meta (peor error ≤ 3 % del rango) en los 41 sujetos con 6 materiales. Una sola red neuronal, que elige las láminas de cada material sabiendo las de los anteriores (red en cadena), con una salida ordinal que respeta el orden de las cantidades, y se entrena dentro de la franja de curvas de la población, su dominio de validez, da directamente las láminas enteras en una evaluación, sin optimizar: con una búsqueda de ± 1 lámina cumple la meta en los 31 sujetos de entrenamiento, en los 10 de prueba y en 50 de 63 curvas de otros tres estudios —carótidas común, externa e interna, capas aisladas, pacientes con placa, mediciones in vivo—, con otras leyes constitutivas; el minimax cumple en 57 de esas 63, y en las demás ningún diseño entero llega a la meta. Luego el método se aplica a la curva presión–diámetro, para la que el injerto es un tubo de pared gruesa: diseñado con la ley de Laplace ningún sujeto cumple al fabricarse, mientras que con pared gruesa cumplen 40–41 de 41. El diseño se vuelve un problema no lineal entero, que se resuelve en tres pasos: arranque, mínimos cuadrados no lineales y búsqueda entera minimax contra la curva ajustada. Allí una red usada como punto de partida evita los mínimos locales que con curvas medidas producen diseños inservibles (peor error de 468,7 % a 2,3 %).

Índice

1. Introducción **2**

2. Datos **3**
2.1. Ley constitutiva y sujetos 3
2.2. Curvas de tensión 3

3. Validación del método sobre la curva tensión–estiramiento **4**
3.1. Materiales: rectas truncadas 4
3.2. Métrica 6
3.3. Cantidades reales: mínimos cuadrados 6

3.4. Láminas enteras: el diseño minimax . . . 7
3.5. La red neuronal en cadena . . . 7
3.6. Dominio de validez y entrenamiento . . . 10
3.7. Resultados en la población de Masson . . . 10
3.8. Validación externa: mediciones de otros autores . . . 12

4. Aplicación: la curva presión–diámetro y el tubo de pared gruesa **16**
4.1. De la tensión a la presión . . . 16
4.2. Pared delgada y pared gruesa . . . 17
4.3. El injerto de pared gruesa . . . 19
4.4. Métodos de diseño . . . 20
4.5. Resultados . . . 22

5. Discusión **25**

6. Conclusiones **26**

A. Parámetros de los 41 sujetos **27**

B. Ejemplo de diseño de pared gruesa, paso a paso **27**
B.1. La arteria y el injerto . . . 28
B.2. Incompresibilidad: el área del anillo no cambia . . . 28
B.3. La pared gruesa como pila de paredes delgadas . . . 28
B.4. En pared gruesa importa dónde va cada capa . . . 30
B.5. El preestiramiento δ . . . 32

C. Entrenamiento de las redes neuronales **34**

D. Láminas y errores de cada curva **36**

1. Introducción

La falla de los injertos vasculares de diámetro pequeño (trombosis, hiperplasia de la íntima) se debe en buena parte a factores mecánicos: flujo perturbado, resistencia insuficiente y desajuste de compliancia entre el injerto y la arteria [17]. En la aorta de cerdo, un injerto con una capa que iguala la compliancia mantuvo la presión de pulso, la velocidad de onda y la distensibilidad, que se deterioraron al quitar la capa [54]; en ratas, un injerto con composición optimizada para la compliancia del vaso receptor siguió ajustado a las cuatro semanas, con menos inflamación y más músculo liso contráctil [22]. Igualar la mecánica de la arteria mejora el resultado.

Varios trabajos optimizan el diseño con ese fin: tiempo de entrecruzado y espesor de un biopolímero [26], proporción y espesor de las capas de un injerto multicapa [59], un refuerzo de nitinol [53] o una espiral de refuerzo [32], y andamios degradables que se transforman en neovaso [58, 29]. Todos ajustan *un número* (compliancia o distensibilidad) de una arteria *promedio*. La respuesta de una arteria, en cambio, tiene forma de J: blanda a bajo estiramiento, cuando trabajan la elastina y el músculo, y rígida a alto estiramiento, cuando se reclutan las fibras de colágeno [27, 31]. Un número no describe esa forma, y la forma cambia de un paciente a otro y de una arteria a otra.

Este trabajo diseña el injerto para que copie la *curva completa* de *cada* arteria. El método tiene dos niveles, que se presentan en ese orden:

1. **Nivel del material (validación).** La curva objetivo es la tensión circunferencial en función del estiramiento circunferencial, $\sigma_{\theta\theta}(\lambda_\theta)$. Es una propiedad del tejido: no depende de la presión, del radio ni del espesor de la pared, y por eso es común a cualquier arteria cuya pared tenga respuesta en J. En este nivel el injerto es una suma de materiales, el diseño es lineal y cada paso del método puede compararse con una solución exacta.

2. **Nivel del tubo (aplicación).** La curva objetivo es la presión que soporta la pared en función del diámetro. Aquí entran la geometría y el modelo de pared gruesa, el diseño deja de ser lineal y se usan las conclusiones del primer nivel.

Las contribuciones son: (i) una base de materiales tipo fibra elegida una vez para toda la población; (ii) el diseño entero óptimo, con a lo sumo 20 láminas por material, por programación lineal entera (minimax); (iii) una sola red neuronal, en cadena y con salida ordinal, que da directamente las láminas enteras en una evaluación, validada por separado en sujetos de entrenamiento, de prueba y de otros tres estudios, dentro de un dominio de validez fijado de antemano; (iv) la demostración de que, a nivel del tubo, el diseño debe hacerse en pared gruesa, lo que lo vuelve no lineal entero; y (v) un procedimiento de tres pasos en el que una red cumple el papel de punto de partida.

2. Datos

2.1. Ley constitutiva y sujetos

Masson et al. [42] midieron en forma no invasiva, a lo largo del ciclo cardíaco, el diámetro y la presión de la carótida común de 16 sujetos normotensos (NT) y 25 hipertensos tratados (HT), y ajustaron a cada uno un modelo de la pared íntima–media con tres aportes: elastina neo-Hookeana, cuatro familias de fibras de colágeno de respuesta exponencial (axial, circunferencial y dos diagonales a $\pm\alpha$) [27] y tono del músculo liso [49]. Con estiramiento axial λ_z fijo e incompresibilidad,

$$\sigma_{\theta\theta} - \sigma_{rr} = c\,(\lambda_\theta^2 - \lambda_r^2) + \lambda_\theta^2 \sum_{k=1}^{4} c_{1,k} E_k\, e^{c_{2,k} E_k^2} \sin^2 \varphi_k + T_m \lambda_\theta \Big[1 - \Big(\frac{\lambda_m - \lambda_\theta}{\lambda_m - \lambda_0}\Big)^2\Big], \qquad (1)$$

con $E_k = \lambda_k^2 - 1$, $\lambda_r = 1/(\lambda_\theta \lambda_z)$ y λ_k el estiramiento de cada familia (λ_z, λ_θ y $\sqrt{\lambda_\theta^2 \sin^2\alpha + \lambda_z^2 \cos^2\alpha}$). Los 14 parámetros de cada sujeto están en sus Tablas 2 y 4 (Anexo A). Diez sujetos (4 NT y 6 HT) se reservan para prueba y no intervienen en ninguna elección del método.

2.2. Curvas de tensión

La curva objetivo del primer nivel es $\sigma_{\theta\theta}(\lambda_\theta)$ en el borde media–adventicia, en 999 valores de λ_θ entre 1,02 y 1,16, calculada con (1); en ese borde la tensión radial está fijada por la condición de contorno de Masson et al., $\sigma_{rr}(r_m) = -P_a$, donde $P_a = a\, e^{b\, r_m / r_m(t_d)}$ es una presión de tipo perivascular que representa en un solo término la acción de la adventicia y del tejido perivascular sobre la media (sus Ecs. 10 y 12; t_d, la diástole). Así, $\sigma_{\theta\theta} = (\sigma_{\theta\theta} - \sigma_{rr}) - P_a$, con P_a en su valor diastólico, $a\,e^b$. Recalculada así, reproduce las curvas medias publicadas (Figs. 5a y 7a de [42]) con un error cuadrático medio de 1,2 a 1,7 % de su valor medio, del orden del error de digitalización. Las 41 curvas tienen forma de J (monótonas y convexas) y van de 4,7 a 49 kPa en $\lambda_\theta = 1{,}02$ y de 54 a 290 kPa en 1,16 (Fig. 1). En la figura se superponen las curvas medias publicadas por Masson et al. (Fig. 5a: jóvenes y mayores; Fig. 7a: normotensos e hipertensos), que caen sobre las curvas recalculadas. Como la presión se expresa también en forma relativa a 13,332 kPa (100 mmHg), la tensión se muestra además relativa a una tensión de referencia de 150 kPa. En forma adimensional, $(\sigma - \sigma_{\text{mín}})/\Delta\sigma$, normotensos e hipertensos tienen casi la misma forma; la diferencia está en el nivel de tensión.

Dos curvas límite encierran a los 41 sujetos: y_1, una curva de la ley de Masson con parámetros dentro del rango de los sujetos, que parte de la menor tensión medida y queda debajo de todos, e y_2, el sujeto más rígido extendido hasta 300 kPa. El *espacio de trabajo* son 22 500 curvas sintéticas de la ley de Masson dentro de esa franja, con parámetros de 2 a 4 sujetos de entrenamiento mezclados y perturbados, o sorteados entre el mínimo y el máximo de los sujetos.

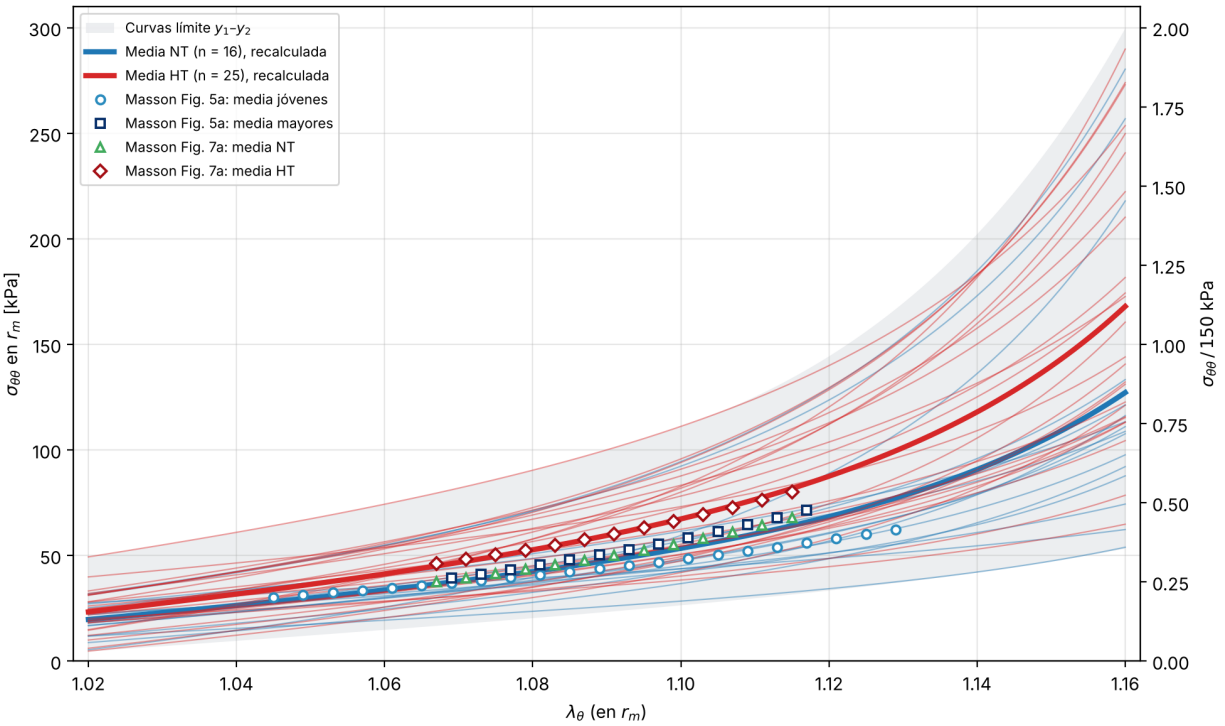


Figura 1: Los 41 sujetos: tensión circunferencial en el borde media–adventicia; eje izquierdo en kPa, eje derecho relativo a 150 kPa. Franja gris: curvas límite y_1–y_2. Azul: normotensos; rojo: hipertensos; trazo grueso: medias recalculadas de cada grupo. Marcadores: curvas medias digitalizadas de Masson et al. [42], Fig. 5a (jóvenes, mayores) y Fig. 7a (normotensos de 39 años o más, hipertensos); cubren el tramo de λ_θ que muestra el trabajo original.

3. Validación del método sobre la curva tensión–estiramiento

3.1. Materiales: rectas truncadas

Una lámina del material j aporta

$$A_j(\lambda) = S_j \ \text{máx}(0,\ \lambda - k_j)\ : \tag{2}$$

nada hasta su *nudo* k_j, y luego una recta de pendiente S_j. Es la idealización de una fibra rizada que no tira hasta estirarse. El injerto es la suma $\sigma_{\text{inj}} = \sum_j c_j A_j = A\,c$, con c_j la cantidad de láminas de cada material y $A \in \mathbb{R}^{999\times N}$ la *base*. Para nudos fijos, el problema es lineal.

Elección de los nudos. Los nudos se eligen una sola vez, para toda la población, minimizando una *función de costo* $\Phi(k)$ —la llamamos así para no confundirla con la forma de J de las curvas— que reúne tres exigencias sobre el espacio de trabajo y los sujetos de entrenamiento:

- **Precisión: CVaR 99 %.** Para cada curva se calcula el error máximo punto a punto del ajuste por mínimos cuadrados, $e_{\text{máx}}$ (ec. 4). El CVaR 99 % (*conditional value at risk*, valor en riesgo condicional [52]) es el promedio de $e_{\text{máx}}$ sobre el 1 % de las curvas con mayor error. A ese término se suma uno menor, 0,25 veces el NRMSE medio, para que el ajuste típico también mejore. Minimizar el promedio de todas las curvas dejaría sin control a las peores; minimizar solo la peor haría depender la elección de una única curva. El CVaR está entre ambos: atiende la cola de las peores curvas sin depender de una sola.
- **Estabilidad: número de condición.** Con las columnas de A escaladas a máximo 1, el número de condición es $\kappa(A) = s_{\text{máx}}/s_{\text{mín}}$, el cociente entre el mayor y el menor valor singular [60]. Mide cuánto puede amplificarse, en las cantidades c, un error relativo de la

curva: un error de 1 % en y puede producir hasta $\kappa(A)$ % de error en c. Si dos nudos están muy juntos, sus columnas se parecen, $s_{\text{mín}} \to 0$ y el diseño se vuelve inestable (cantidades grandes y de signo opuesto que se compensan). Se exige $\kappa(A) < 30$; las bases adoptadas tienen 28,0 (6 materiales) y 19,0 (5).

- **Signo.** Las cantidades del ajuste libre, $c = A^{+}y$, deben ser no negativas (con tolerancia de 0,01 lámina) en las 22 500 curvas del espacio de trabajo, en los sujetos de entrenamiento y en las curvas límite, porque una cantidad negativa de material no se fabrica. La función Φ suma una penalización proporcional a las cantidades negativas. Como el signo de c_j no depende de la pendiente S_j (que solo escala la columna), esta condición queda fijada por los nudos.

En resumen,

$$\Phi(k) = \text{CVaR}_{99}(e_{\text{máx}}) + 0{,}25\,\overline{\text{NRMSE}} + 50\ \text{máx}\big(0,\ \kappa(A) - 29\big) + 1000\,\overline{n^{-}}, \tag{3}$$

donde $\overline{n^{-}}$ es la suma de las cantidades negativas de cada curva (en láminas), promediada sobre las curvas. Si los nudos no cumplen las restricciones de separación o de dominio (párrafo siguiente), $\Phi = 10^9$: ese juego de nudos queda descartado. La búsqueda es global por *evolución diferencial* [57]: una población de juegos de nudos candidatos se mejora generación a generación; cada candidato se perturba sumándole la diferencia entre otros dos, escalada, y el resultado reemplaza al candidato si da un Φ menor. No usa derivadas, que Φ no tiene (el máx, la ordenación del CVaR y las penalizaciones la hacen no diferenciable), y explora todo el dominio, por lo que no se queda en el primer mínimo local. El mejor candidato se refina con el método simplex de *Nelder–Mead* [46], que tampoco usa derivadas: mueve un poliedro de $N + 1$ vértices por reflexiones, expansiones y contracciones hasta cerrarlo sobre el mínimo.

Restricciones de los nudos. Los nudos 2 a N quedan dentro del dominio, separados al menos 0,008 (si se juntan, $\kappa(A)$ crece) y el último a más de 0,012 del extremo 1,16 (si no, su material actúa en muy pocos puntos y no se distingue del resto). El primero, k_1, se busca entre 0,6 y 0,98, *antes* del dominio, por una razón física: en $\lambda_\theta = 1{,}02$ todas las arterias ya tienen tensión (de 4,7 a 49 kPa), y en ese punto el único material que puede aportarla es uno que ya esté trabajando. Ese material hace el papel de la elastina, que sostiene carga con la arteria descargada. Un nudo $k_1 < 1$ significa que la lámina se monta preestirada: con $k_1 = 0{,}82$, en $\lambda = 1$ ya está estirada $1/0{,}82 = 1{,}22$. El límite superior 0,98 asegura que esté activa en todo el dominio con margen. El inferior, 0,6 (preestiramiento de 1,67), acota la búsqueda a valores fabricables. Ninguno de los dos límites está activo en el óptimo ($k_1 = 0{,}82$ con 5 y con 6 materiales): la elección no depende de ellos.

Pendientes. $S_j = \text{PEND}_{\text{máx},j}/20$, donde $\text{PEND}_{\text{máx},j}$ es la mayor pendiente que el material j debe aportar en el espacio de trabajo: así ninguna curva necesita más de 20 láminas de un material. La escala no cambia la curva (lo que cuenta es $c_j S_j$), pero fija el tamaño de una lámina.

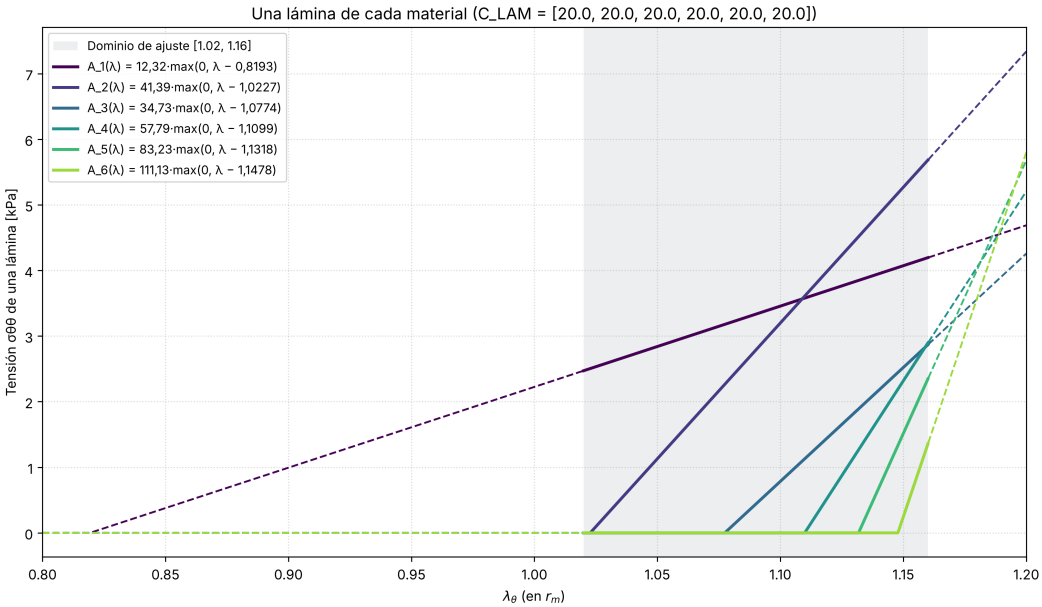


Figura 2: La base de 6 materiales: una lámina de cada uno. El primer nudo (0,82) está antes del dominio, como la elastina, que ya trabaja con la arteria descargada; los demás se agrupan donde la curva arterial se curva más.

Tabla 1: Bases adoptadas: nudos k_j y pendiente de una lámina S_j [kPa].

	1	2	3	4	5	6
6 materiales, k_j	0,8193	1,0227	1,0774	1,1099	1,1318	1,1478
S_j	12,32	41,39	34,73	57,79	83,23	111,13
5 materiales, k_j	0,8228	1,0243	1,0881	1,1226	1,1447	—
S_j	12,56	43,57	51,92	88,74	129,08	—

3.2. Métrica

Para una curva objetivo y con rango $\Delta = \max y - \min y$,

$$e_{\max} = \frac{100}{\Delta} \max_i |y_i - \hat{y}_i| \quad [\,\%], \qquad E_{\mathrm{rms}} = \frac{100}{\Delta} \sqrt{\frac{1}{n} \sum_i (y_i - \hat{y}_i)^2}, \tag{4}$$

con $\hat{y}$ la curva del injerto. $e_{\max}$ es el peor punto; E_{rms} (o NRMSE), el apartamiento típico. Dividir por el rango hace el criterio igual de exigente con una arteria blanda que con una rígida. Meta: $e_{\max} \leq 3$ %. Todo diseño se evalúa contra la curva original.

3.3. Cantidades reales: mínimos cuadrados

Con la base fija, el mejor ajuste cuadrático es $c = A^{+}y$, con A^{+} la seudoinversa de Moore–Penrose [47], calculada por descomposición en valores singulares [23]: exacta, única e instantánea. Con los nudos adoptados el número de condición es 19,0 (5 materiales) y 28,0 (6 materiales), debajo del umbral de 30, y ninguna curva del espacio de trabajo ni ningún sujeto necesita una cantidad negativa. El ajuste cumple la meta en los 41 sujetos, con peor error de 0,88 % (6 materiales; mediana 0,67 %) y 1,41 % (5 materiales; mediana 1,07 %), y en todas las curvas del espacio de trabajo.

3.4. Láminas enteras: el diseño minimax

Un injerto se fabrica con un número entero de láminas de cada material, $z \in \{0, 1, \ldots, 20\}^N$: a lo sumo 20 láminas por material, para no complicar la fabricación (con las pendientes adoptadas, ninguna curva del espacio de trabajo necesita más). El diseño entero de referencia no redondea ninguna solución real: busca directamente los enteros que dejan el túnel más angosto alrededor de la curva de la arteria,

$$\min_{z,\tau} \ \tau \quad \text{s.a.} \quad -\tau \le \frac{100}{\Delta}(y_i - (Az)_i) \le \tau, \qquad z_j \in \{0, 1, \ldots, 20\},$$

un programa lineal entero mixto (aproximación de Chebyshev [13] con enteros) resuelto por ramificación y acotación con HiGHS [30], en unos 50 a 65 ms por curva. Sus únicos datos son la curva y y la base A, y lo que se obtiene es el *óptimo global*: el diseño entero de menor $e_{\text{máx}}$ que existe. Si el minimax no cumple la meta en una curva, ninguna combinación de láminas enteras la cumple. Por eso es la referencia contra la que se mide la red neuronal. Dentro del dominio de validez (Sección 3.6) el tope de 20 láminas no limita: sin tope, ninguna de las 63 curvas externas de la Sección 3.8 necesita más de 18 láminas de un material, y en ellas y en los 41 sujetos el $e_{\text{máx}}$ del minimax es el mismo con y sin tope (a menos de 0,01 punto).

3.5. La red neuronal en cadena

El minimax resuelve un problema de optimización entera por cada curva. Una red neuronal, en cambio, aprende de una vez la relación entre la curva y su diseño, y después da las láminas enteras de un injerto nuevo en una sola evaluación, sin optimizar. Para que dé enteros, la salida de cada material es *ordinal*: en lugar de elegir una entre 21 categorías sin orden, la red responde, para el material j, las 20 preguntas "¿lleva más de k láminas?" ($k = 0, 1, \ldots, 19$), y el número de láminas es la cantidad de respuestas afirmativas. Así, la red sabe que 6 láminas está cerca de 5 y lejos de 20. Se usa una sola red, la de la Fig. 3, en todo el primer nivel.

Arquitectura. Un tronco común, $999 \to 256 \to 128 \to 64$ (ReLU [44], normalización por capa [5] y regularización L2 de 10^{-5}), resume la curva en un vector h de 64 números; la entrada es $\log(y + 22)$ estandarizada. Hay una cabeza por material. La cabeza j recibe h y las láminas ya elegidas $n_1 \ldots n_{j-1}$ (divididas por 20), pasa por dos capas (128 y 64 neuronas, ReLU) y calcula un único puntaje s_j. Las 20 preguntas comparten ese puntaje y difieren solo en un umbral propio, $P(n_j > k) = \sigma(s_j + b_{jk})$, con σ la función logística [11]; la respuesta es $\hat{n}_j = \#\{k : \ P(n_j > k) > 1/2\}$. Se usa en orden —material 1, después el 2 sabiendo el 1, y así hasta el último—, de modo que puede compensar entre materiales: si en uno puso una lámina de más, en el siguiente puede poner una de menos. Tiene 399 928 parámetros con 6 materiales y 382 628 con 5.

Cómo trabaja, paso a paso. Una red neuronal común recibe la curva y entrega todas sus salidas de una vez. La red en cadena, en cambio, arma el diseño de a un material y usa sus propias respuestas como parte de la entrada. Por eso tiene dos entradas: la curva $\mathbf{y}$ y un vector de N casillas con las láminas ya decididas, divididas por 20 para que queden entre 0 y 1 como el resto de las entradas.

(1) *Paso 1.* Las N casillas están en cero. El tronco resume la curva en h, y la cabeza 1 responde las 20 preguntas "¿más de k láminas del material 1?"; $\hat{n}_1$ es la cantidad de respuestas con probabilidad mayor que 1/2.

(2) *Paso j, para $j = 2, \ldots, N$.* Se vuelve a evaluar la red con la misma curva y con las casillas $(\hat{n}_1, \ldots, \hat{n}_{j-1}, 0, \ldots, 0)/20$, y se lee solo la cabeza j, que da $\hat{n}_j$. Cada cabeza mira únicamente las casillas de los materiales anteriores a ella.

(3) Después de N evaluaciones, $(\hat{n}_1, \ldots, \hat{n}_N)$ es el diseño.

Por ejemplo, para el sujeto NT01 con 6 materiales, la cabeza 1 elige 5 láminas; la cabeza 2, sabiendo ese 5, elige 7; la 3, sabiendo 5 y 7, elige 5; y así hasta $[5, 7, 5, 6, 6, 7]$ (Tabla 12). Como el tronco depende solo de la curva, h es el mismo en los N pasos: lo que cambia de un paso a otro es lo que la red sabe de los materiales ya decididos. Al entrenar no se hacen los N pasos: cada cabeza recibe en las casillas las láminas del minimax de los materiales anteriores y aprende a elegir la siguiente (punto (c) del fundamento). La diferencia con una red común es la que hay entre acertar todas las cantidades a la vez, sin que un error pueda corregirse, y decidir cada material sabiendo cómo quedaron los anteriores, con la posibilidad de compensarlos.

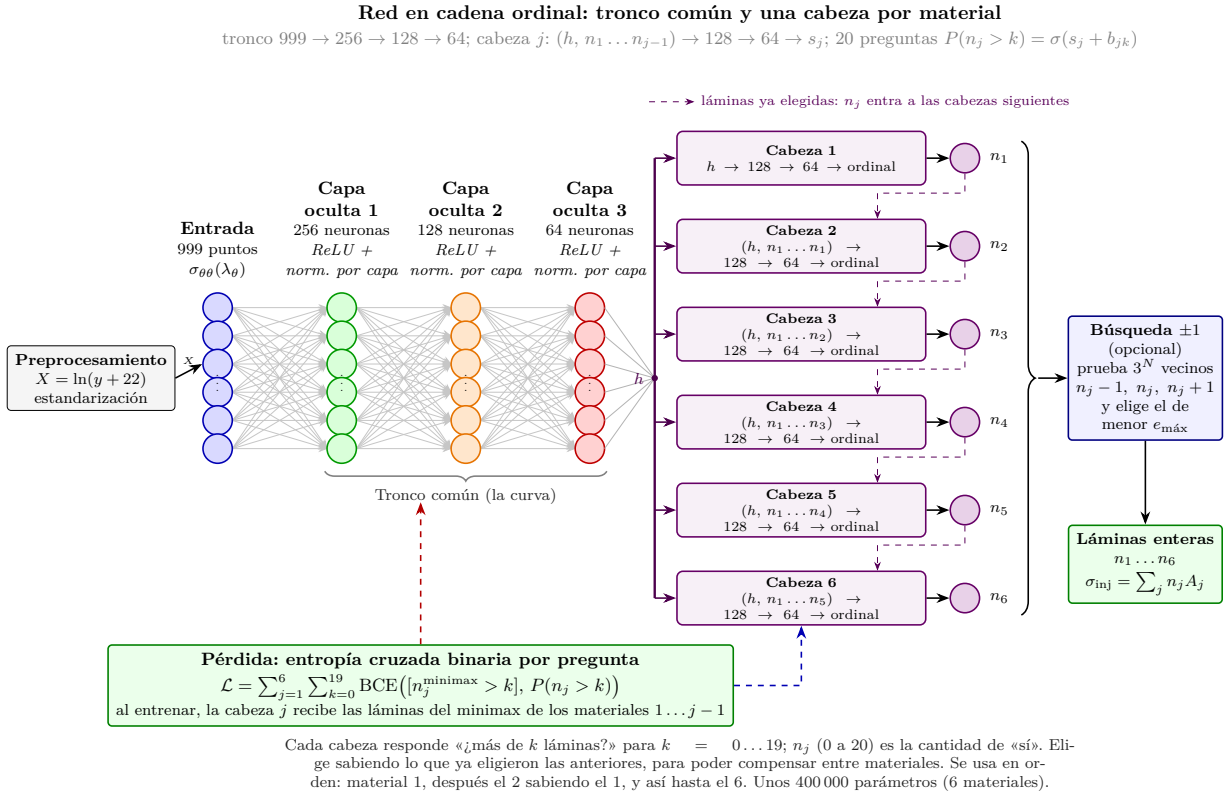


Figura 3: Red en cadena para 6 materiales. Un tronco común ($999 \to 256 \to 128 \to 64$, ReLU y normalización por capa) resume la curva en el vector h; la cabeza j recibe h y las láminas $n_1 \dots n_{j-1}$ que ya eligieron las cabezas anteriores (flechas de trazos violetas), y responde las 20 preguntas "¿más de k láminas?" con un puntaje y 20 umbrales; n_j, de 0 a 20, es la cantidad de respuestas afirmativas. La pérdida es la entropía cruzada binaria de esas preguntas contra el entero del minimax. La búsqueda de ± 1, opcional, revisa las 3^N combinaciones vecinas de la respuesta.

Fundamento de la red en cadena. Se apoya en cinco resultados.

(a) *Aproximación universal.* Una red de capas con suficientes neuronas aproxima cualquier función continua en un conjunto acotado [14, 28, 37]. Lo que aprende cada cabeza son las probabilidades $P(n_{ij} > k)$ de que la curva i lleve más de k láminas del material j, que varían en forma continua con la curva; el paso a un entero se hace recién al final, contando las respuestas afirmativas.

(b) *Regla de la cadena de la probabilidad.* La probabilidad de un diseño completo se descompone siempre, sin ninguna hipótesis, como

$$p(n_1, \dots, n_N \mid \mathbf{y}) = \prod_{j=1}^{N} p(n_j \mid \mathbf{y}, n_1, \dots, n_{j-1}), \tag{5}$$

y cada factor es lo que calcula una cabeza. Es la idea de los modelos autorregresivos [34] y de las cadenas de clasificadores [50]. Elegir cada material por separado supondría $\prod_j p(n_j \mid \mathbf{y})$,

es decir, materiales independientes; como los materiales se compensan entre sí, esa hipótesis es falsa.

(c) *Máxima verosimilitud.* Para la curva i y el material j, la etiqueta del minimax n^*_{ij} se escribe como 20 respuestas, $y_{ijk} = 1$ si $n^*_{ij} > k$ y 0 si no ($k = 0, \ldots, 19$), y la cabeza da $p_{ijk} = P(n_{ij} > k) = \sigma(s_{ij} + b_{jk})$. La pérdida es la entropía cruzada binaria sumada sobre las preguntas y los materiales, más una regularización L2 de los pesos del tronco:

$$\mathcal{L}(\theta) = \frac{1}{B} \sum_{i=1}^{B} \sum_{j=1}^{N} \sum_{k=0}^{19} \Big[-y_{ijk} \ln p_{ijk} - (1 - y_{ijk}) \ln(1 - p_{ijk}) \Big] + \lambda \sum_{W \in \text{tronco}} \|W\|^2, \qquad \lambda = 10^{-5}, \tag{6}$$

con $B = 256$ curvas por lote. Cada término es menos el logaritmo de la probabilidad que la red da a la respuesta correcta de una pregunta: minimizar $\mathcal{L}$ es maximizar la verosimilitud de las respuestas del minimax, material por material y en el orden de (5). Para entrenar cada factor de (5), la cabeza j recibe las láminas del minimax de los materiales anteriores (*teacher forcing* [63]); al usarla recibe las que eligieron las cabezas anteriores, $\hat{n}_{ij} = \#\{k : \ p_{ijk} > 1/2\}$.

(d) *Representación compartida h.* Las N cabezas resuelven tareas que dependen de la misma curva; un tronco común obliga a que h guarde lo que sirve a todas y mejora la generalización frente a redes separadas [12, 7]. Las curvas dependen de pocos parámetros: la ley de Masson usa unos 8 por sujeto y el ajuste lineal reproduce cualquier curva del espacio de trabajo con N coeficientes y error menor al 1 %. Los 64 números de h alcanzan con margen. El tamaño 64, como 256 y 128, es una elección de diseño y no sale de un teorema.

(e) *Salida ordinal.* Las láminas son cantidades ordenadas: equivocarse por una lámina no es lo mismo que equivocarse por diez, pero una salida de 21 categorías sin orden trata igual los dos errores. Frank y Hall [19] propusieron convertir una clasificación ordenada en una serie de preguntas binarias "¿más que k?", y Li y Lin [38] mostraron que así el problema se reduce a una clasificación binaria con costos que crecen con la distancia al valor correcto. Cao et al. [11] lo llevaron a redes neuronales con un mismo puntaje y un umbral por pregunta, y demostraron que en el óptimo los umbrales quedan ordenados, de modo que las respuestas son coherentes: si la red dice que lleva más de 6 láminas, también dice que lleva más de 5. Es la salida que usa cada cabeza.

La teoría garantiza que una red así existe, no que el entrenamiento la encuentre: eso se comprueba con los datos. Elegir en orden la respuesta de cada material tampoco asegura la combinación más probable en conjunto, y al usarla una cabeza puede recibir un error que no vio al entrenar (*exposure bias* [6]).

Antecedentes de la red en cadena. Entrenar una red con las soluciones óptimas de un problema entero para que proponga al instante la de un caso nuevo es uno de los esquemas centrales del aprendizaje automático para optimización combinatoria, tal como lo sistematizan Bengio, Lodi y Prouvost [8]. Nair et al. [43] lo aplican a programas lineales enteros mixtos: una red propone valores enteros y un resolvedor completa la solución. Aquí la red propone las láminas, la búsqueda de ± 1 las corrige y el minimax es la referencia. Para que la red proponga varios enteros que dependen entre sí, se los elige de a uno, cada uno condicionado a los anteriores: es la idea de las cadenas de clasificadores [50]. Dembczyński et al. [16] les dieron su base probabilística —la regla de la cadena (5)— y mostraron que elegir en orden la opción más probable aproxima, sin garantizarla, la mejor combinación; Read et al. [51] revisan sus variantes, y Nam et al. [45] las llevan a redes neuronales con parámetros compartidos entre las salidas. El antecedente más cercano en diseño es OptoGPT [41], que diseña recubrimientos ópticos multicapa eligiendo, capa por capa, el material y el espesor de cada una entre opciones discretas, condicionado a la respuesta óptica buscada y a las capas ya elegidas; tratar la multicapa como una secuencia es hoy una de las vías principales del diseño inverso de esas estructuras [40]. Aquí cada paso es un material y la opción discreta, su número de láminas.

Búsqueda de ±1. A la respuesta de la red se le puede aplicar una revisión: se prueban las 3^N combinaciones que difieren en a lo sumo una lámina por material (729 con 6 materiales, sin salir de 0 a 20) y se elige la de menor $e_{\text{máx}}$ contra la curva. Es solo evaluar Az para cada combinación: no hay optimización.

3.6. Dominio de validez y entrenamiento

Dominio de validez. La red se entrena dentro de la franja y_1–y_2 de la población de Masson (Sección 2.2), y solo ahí se puede asegurar la calidad de su diseño: una curva que sale de la franja está fuera de lo que la red aprendió. Esa franja es el *dominio de validez* del método, fijado con los sujetos de Masson antes de mirar ninguna curva externa. Antes de usar la red se verifican dos condiciones: que la curva esté dentro de y_1–y_2 en todo el dominio de λ_θ, y que tenga forma de J (*control de clase*: que admita una aproximación no negativa con 40 rectas truncadas con NRMSE ≤ 2 %, por mínimos cuadrados no negativos [35]). Una curva que no cumple la segunda no puede reproducirse con capas; una que no cumple la primera queda fuera del alcance de la red, y para ella solo vale el minimax.

Datos. Se generan 50 000 curvas en siete familias: tres de la ley de Masson (parámetros de 2 a 4 sujetos de entrenamiento mezclados y perturbados poco; mezclados con pesos que permiten salir algo del rango de los sujetos; o sorteados entre el mínimo y el máximo de cada parámetro), otra ley exponencial de cuatro parámetros ajustada a los sujetos, los 31 sujetos de entrenamiento, y dos familias de sumas de láminas de la propia base (de un material o de varios). Se conservan solo las que quedan enteras dentro de y_1–y_2: 34 503 con 6 materiales y 34 624 con 5. Quedan todas las curvas de Masson y de los sujetos, el 92 % de las exponenciales, la mitad de las sumas de varios materiales y apenas el 1 % de las de un solo material, que casi siempre caen fuera de la franja. La entrada lleva ruido gaussiano de 1 %; la etiqueta de cada curva son sus láminas del minimax. Partición estratificada por familia: 24 151 de entrenamiento, 3451 de validación y 6901 de prueba (6 materiales; 24 236, 3463 y 6925 con 5).

Entrenamiento. Adam [33] con recorte del gradiente, lotes de 256, reducción de la tasa en meseta y parada temprana [48]; TensorFlow/Keras [2]. Las dos redes llegaron al máximo de 800 épocas, con la pérdida de validación ya casi estable, en unos 16 minutos de CPU cada una. Las curvas de aprendizaje y las pérdidas están en el Anexo C.

3.7. Resultados en la población de Masson

Los resultados se informan por separado para los 31 sujetos de entrenamiento, que la red vio (con ruido) al entrenarse, y para los 10 sujetos de prueba, que no intervinieron en ninguna elección del método. Se agregan 2000 curvas del espacio de trabajo, al azar, con meta de 4 % (Tabla 2).

Tabla 2: Resumen de resultados con láminas enteras: $e_{\text{máx}}$ mediano / peor [%] · curvas que cumplen la meta (3 %; 4 % en las 2000 curvas del espacio de trabajo). Todos los errores, contra la curva original. Validación externa: las curvas de otros autores dentro de y_1–y_2 (Sección 3.8).

	Conjunto	Minimax (referencia)	Red en cadena	Red en cadena + ±1
6 materiales	Masson, entrenamiento (31)	1,01 / 2,34 · 31	1,26 / 2,34 · 31	1,09 / 2,34 · 31
	Masson, prueba (10)	1,04 / 1,61 · 10	1,27 / 2,82 · 10	1,07 / 1,61 · 10
	Espacio de trabajo (2000)	1,06 / 3,28 · 2000	1,22 / 4,93 · 1998	1,10 / 4,93 · 1999
	Validación externa (63)	1,91 / 5,71 · 57	2,26 / 9,44 · 46	2,12 / 6,16 · 50
5 materiales	Masson, entrenamiento (31)	1,48 / 3,50 · 30	1,67 / 3,50 · 30	1,57 / 3,50 · 30
	Masson, prueba (10)	1,32 / 2,03 · 10	1,42 / 2,35 · 10	1,32 / 2,03 · 10
	Espacio de trabajo (2000)	1,44 / 3,48 · 2000	1,61 / 3,88 · 2000	1,50 / 3,74 · 2000
	Validación externa (63)	2,29 / 5,98 · 54	2,63 / 7,55 · 43	2,45 / 5,98 · 48

(I) **Sujetos de prueba.** Con 6 y con 5 materiales, la red en cadena cumple la meta en los 10 sujetos de prueba, sola (peor 2,82 y 2,35 %) y con la búsqueda de ±1, que en los 10 llega al mismo peor caso que el minimax (1,61 y 2,03 %).

(II) **Sujetos de entrenamiento.** Con 6 materiales cumplen los 31 con los tres métodos. Con 5, el sujeto NT04 queda en 3,50 % también con el minimax: no hay diseño entero de 5 materiales que lo lleve a la meta, y el límite lo pone tener solo 5 materiales, no la red.

(III) **Láminas distintas, curva casi igual.** La red da exactamente las láminas del minimax en 6 de los 41 sujetos (6 materiales) y en 18 (5); con la búsqueda de ±1, en 16 y 27. Donde difiere, lo hace en una o dos láminas con errores parecidos: hay varias combinaciones enteras que reproducen casi igual la misma curva. Como el minimax minimiza el peor punto y no el error medio, la red tiene un E_{rms} menor o igual al del minimax en 30 de los 41 sujetos (6 materiales). Las láminas y los errores de cada sujeto están en las Tablas 12 y 13 (Anexo D).

(IV) **Sin errores grandes.** Como la salida es ordinal, cuando la red se equivoca lo hace por poco. En las 2000 curvas del espacio de trabajo, la red sola cumple la meta de 4 % en 1998 (6 materiales; peor 4,93 %) y en las 2000 (5 materiales; peor 3,88 %); con la búsqueda de ±1, en 1999 y 2000. Lo mismo en los bordes de la franja, donde hay menos curvas de entrenamiento: en y_1 y en y_2, con 6 materiales, la red sola da 2,46 y 2,69 %, y con la búsqueda de ±1, 1,10 y 1,00 %, frente a 1,10 y 0,91 % del minimax (Fig. 4, Tabla 3).

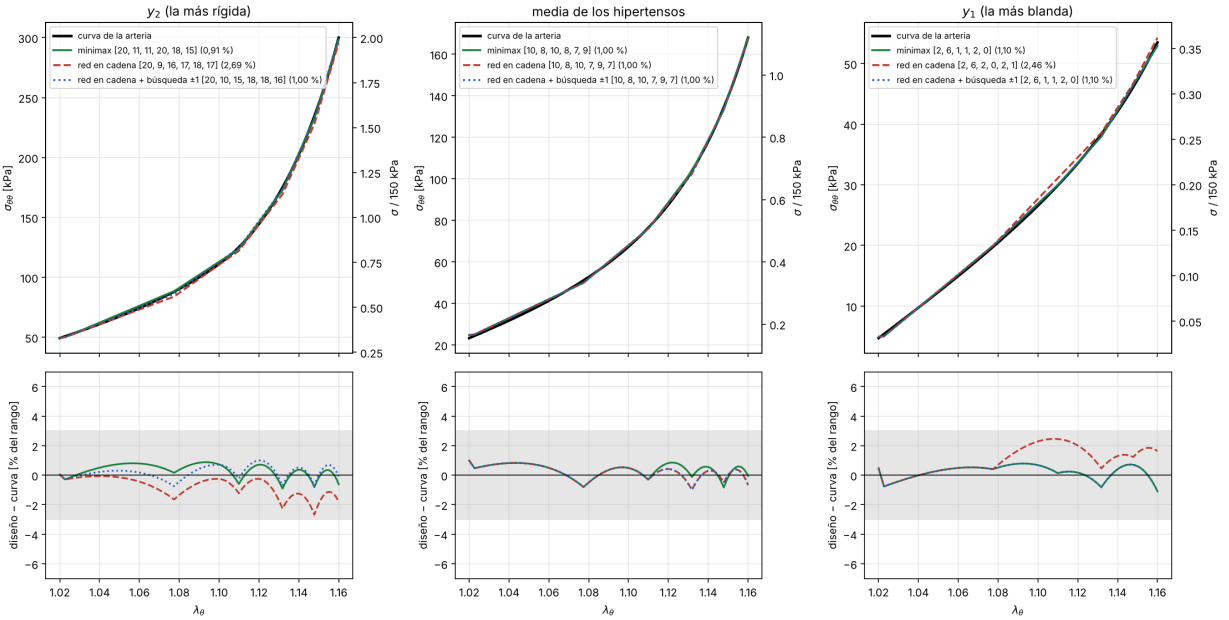


Figura 4: 6 materiales: la curva más rígida de la franja (y_2), la media de los hipertensos y la más blanda (y_1). Arriba: tensión (eje izquierdo en kPa, eje derecho relativo a 150 kPa), con las láminas de cada material y el $e_{\mathrm{máx}}$ de cada diseño; abajo: diseño − curva en % del rango (franja gris: meta de ±3 %).

Tabla 3: Diseños de la Fig. 4 (6 materiales): láminas de cada material c_j (reales en la primera fila de cada curva, enteras en las demás) y errores contra la curva original, E_{rms} y $e_{\mathrm{máx}}$ [% del rango].

Curva	Método	c_1	c_2	c_3	c_4	c_5	c_6	E_{rms}	$e_{\mathrm{máx}}$
y_2	Mínimos cuadrados (reales)	19,86	10,33	12,85	20,00	17,78	14,58	0,32	0,94
	Minimax (MILP, referencia)	20	11	11	20	18	15	0,54	0,91
	Red en cadena	20	9	16	17	18	17	0,98	2,69
	Red en cadena + búsqueda ±1	20	10	15	18	18	16	0,44	1,00
Media HT	Mínimos cuadrados (reales)	9,43	8,86	8,54	8,17	7,96	7,59	0,30	0,71
	Minimax (MILP, referencia)	10	8	10	8	7	9	0,54	1,00
	Red en cadena	10	8	10	7	9	7	0,50	1,00
	Red en cadena + búsqueda ±1	10	8	10	7	9	7	0,50	1,00
y_1	Mínimos cuadrados (reales)	2,08	5,72	1,41	1,32	1,18	1,07	0,16	0,90
	Minimax (MILP, referencia)	2	6	1	1	2	0	0,49	1,10
	Red en cadena	2	6	2	0	2	1	1,36	2,46
	Red en cadena + búsqueda ±1	2	6	1	1	2	0	0,49	1,10

Tiempo. El minimax tarda unos 50 a 65 ms por curva y no se acelera en lote, porque resuelve un problema por curva. La red, en lote, tarda 0,3 ms por curva (0,2 con 5 materiales), y con la búsqueda de ±1, 2,0 ms (0,7 con 5): de 30 a 200 veces menos. Para una sola curva el tiempo lo fija la llamada a la biblioteca de redes (unos 0,3 s con TensorFlow), no el cálculo. La ventaja de la red no es solo el tiempo: da el diseño sin resolver ninguna optimización, con la misma operación para cualquier curva del dominio de validez.

3.8. Validación externa: mediciones de otros autores

Para comprobar que el método no depende de la arteria con que se construyó, se aplicó a curvas $\sigma_{\theta\theta}(\lambda_\theta)$ de tres estudios independientes, con otras leyes constitutivas, otras arterias, capas aisladas y mediciones in vivo. **No se cambió nada**: los mismos nudos y pendientes (Tabla 1), la misma red, el mismo dominio de validez y el mismo minimax. Ninguna de estas leyes está en el entrenamiento de la red.

Curvas y leyes constitutivas. Cada curva se recalcula con la ley constitutiva y los parámetros que publicaron sus autores. La ley se usa tal cual porque es la que esos autores ajustaron a sus mediciones: es la que fija la forma de la curva y, con ella, lo que el injerto tiene que reproducir.

- **Sommer y Holzapfel** [56]: carótidas común (CCA) e interna (ICA) de 11 donantes (77,6 años en promedio), ensayadas por extensión–inflado como tubos de pared intacta, de adventicia y de media–íntima [55]. Los autores ajustaron a cada espécimen la ley de Holzapfel, Gasser y Ogden [27] con dispersión de fibras,

$$\Psi = \tfrac{\mu}{2}(I_1 - 3) + \tfrac{k_1}{k_2}(e^{Q} - 1),$$
$$Q = k_2\big[(1-\rho)(I_1-3)^2 + \rho\,(I_4-1)^2\big], \qquad I_4 = \lambda_\theta^2\cos^2\varphi + \lambda_z^2\sin^2\varphi,$$

  donde μ es la rigidez de la matriz (elastina), k_1 y k_2 la rigidez y el endurecimiento del colágeno, φ el ángulo de las fibras y ρ su grado de alineación; las fibras no trabajan en compresión ($I_4 < 1$). Los cinco parámetros de cada espécimen están en sus Tablas 1 y 2. Se usa $\sigma_{\theta\theta} - \sigma_{rr}$ con $\lambda_z = 1{,}10$, el estiramiento axial in vivo que adoptan los autores [55].

- **Liu et al.** [39]: 12 carótidas humanas con placa, caracterizadas in vivo con resonancia magnética cine y multicontraste. Los autores identificaron para cada paciente un Mooney–Rivlin modificado en tracción uniaxial,

$$\sigma = 2\lambda(\lambda - \lambda^{-2})\Big(c_1 + D_1 D_2\, e^{D_2(\lambda^2 + 2/\lambda - 3)}\Big), \qquad D_2 = 2,$$

con c_1 y D_1 de su Tabla 1. Publican también la contracción circunferencial S entre el estado sin carga y la diástole y los perímetros diastólico y sistólico, que dan la ventana medida.

- **Kamenskiy et al.** [36]: 16 pacientes, carótidas común, externa (ECA) e interna medidas in vivo por ultrasonido a lo largo del ciclo cardíaco (48 curvas). Por cada arteria publican la tensión y el módulo tangente en diástole y en sístole y los diámetros. La ley más simple que reproduce esos datos con forma de J es la exponencial, $\sigma(\varepsilon) = \sigma_d + \alpha\big(e^{\beta\varepsilon} - 1\big)$ en $\varepsilon \in [0, \varepsilon_s]$: con $\sigma(\varepsilon_s) = \sigma_s$ exacta y β que reproduce las dos pendientes. En las 48 arterias la pendiente sistólica supera a la diastólica: todas son J.

Se excluyó la carótida de conejo de Holzapfel et al. [27]: como capas aisladas, con la geometría del conejo, a esas presiones da tensiones de 900 a 3300 kPa, lejos de cualquier carótida humana.

Un solo escalamiento: la ventana de presión. Cada curva vive en su propio rango de λ y se lleva a [1,02; 1,16] con un cambio afín de λ: el estiramiento a la presión baja va a 1,02 y el de la presión alta a 1,16. **La tensión no se toca**: cada curva conserva las suyas, sin fijar de antemano su valor en los extremos. El cambio de λ equivale a lo que el injerto real permite: un preestiramiento (corrimiento de los nudos, el δ de la Sección 4) y la elección del radio de referencia. La ventana sale de la presión:

- **M (in vivo, medida):** Liu y Kamenskiy, entre la diástole y la sístole de cada paciente.
- **P (ex vivo, calculada):** Sommer y Holzapfel, entre 60 y 200 mmHg, la misma ventana de presión del nivel tubo (Sección 4). El estiramiento a cada presión sale del equilibrio de pared delgada que usan Sommer et al. [55] (sus ecs. 1 y 2),

$$\sigma_{\theta\theta} = p\Big(\frac{r}{h} - 1\Big), \qquad r = R\,\lambda_\theta, \qquad R^2 - (R-H)^2 = \big[r^2 - (r-h)^2\big]\lambda_z,$$

con el radio externo R y el espesor H sin carga medios de cada arteria y capa (su Tabla 2): pared intacta 4,15 y 1,17 mm (CCA) y 2,67 y 0,86 mm (ICA); adventicia 4,00 y 0,47 y 2,51 y 0,33 mm; media–íntima 3,61 y 0,70 y 2,15 y 0,53 mm. Tres adventicias (CCA II l y VIII r, ICA VIII r) ya soportan sin carga más de 60 mmHg y no tienen ventana: se excluyen.

Con 60 mmHg las curvas ex vivo arrancan entre 21 y 92 kPa y con 200 mmHg llegan a entre 76 y 325 kPa; las in vivo recorren de 13 a 389 kPa. En total, 98 curvas: 38 de Sommer y Holzapfel, 12 de Liu y 48 de Kamenskiy (Fig. 5).

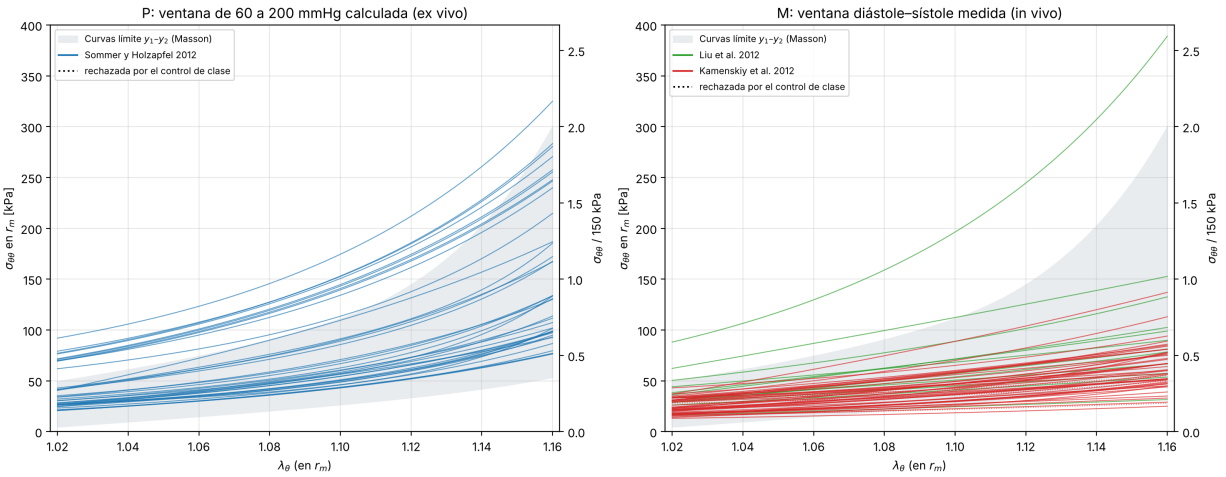


Figura 5: Las 98 curvas externas en el dominio de diseño, con las escalas de la Fig. 1: eje izquierdo en kPa, eje derecho relativo a 150 kPa (aquí hasta 400 kPa, porque una curva de Liu et al. llega a 389 kPa). Las dos con el mismo escalamiento: cada curva entre su presión baja y su presión alta, con sus propias tensiones. Izquierda: ventana de 60 a 200 mmHg calculada con la geometría de cada arteria y capa (Sommer y Holzapfel); derecha: ventana diástole–sístole medida in vivo (Liu, Kamenskiy). Franja gris: curvas límite y_1–y_2 de la población de Masson, el dominio de validez del método; solo las curvas que quedan enteras dentro de ella forman la validación externa. Punteadas: rechazadas por el control de clase.

Curvas dentro del dominio de validez. De las 98 curvas, el control de clase rechazó 3: las tres ventanas in vivo más cortas de Kamenskiy (ECA de los pacientes 11 y 15 e ICA del 15, con $\varepsilon_s \leq 3$ %). De las 95 restantes, 63 quedan enteras dentro de y_1–y_2 y forman la validación externa: las 28 paredes intactas y media–íntimas de Sommer y Holzapfel, 8 curvas de Liu y 27 de Kamenskiy. Las 32 que salen de la franja no se usan, porque la red no puede asegurar en ellas la meta: las 10 adventicias aisladas, que a 200 mmHg superan a y_2; 4 de Liu (P11 llega a 389 kPa); y 18 de Kamenskiy.

Resultados. La Tabla 4 resume, por estudio, las 63 curvas; la Fig. 6 muestra el $e_{\text{máx}}$ de cada curva, y las Tablas 14 y 15 (Anexo D), las láminas y los errores de cada una.

Tabla 4: Validación externa: las 63 curvas dentro de y_1–y_2. Curvas que cumplen la meta de 3 % con láminas enteras y peor $e_{\text{máx}}$ [%] de cada método.

		6 materiales			5 materiales		
Estudio	Curvas	Minimax	Red	Red $+\pm 1$	Minimax	Red	Red $+\pm 1$
Sommer y Holzapfel [56] (pared y media–íntima)	28	28 · 2,52	28 · 2,64	28 · 2,64	28 · 2,76	27 · 3,31	27 · 3,31
Liu et al. [39]	8	5 · 3,74	4 · 5,64	5 · 5,64	5 · 3,91	4 · 3,91	5 · 3,91
Kamenskiy et al. [36]	27	24 · 5,71	14 · 9,44	17 · 6,16	21 · 5,98	12 · 7,55	16 · 5,98
Total	63	57	46	50	54	43	48

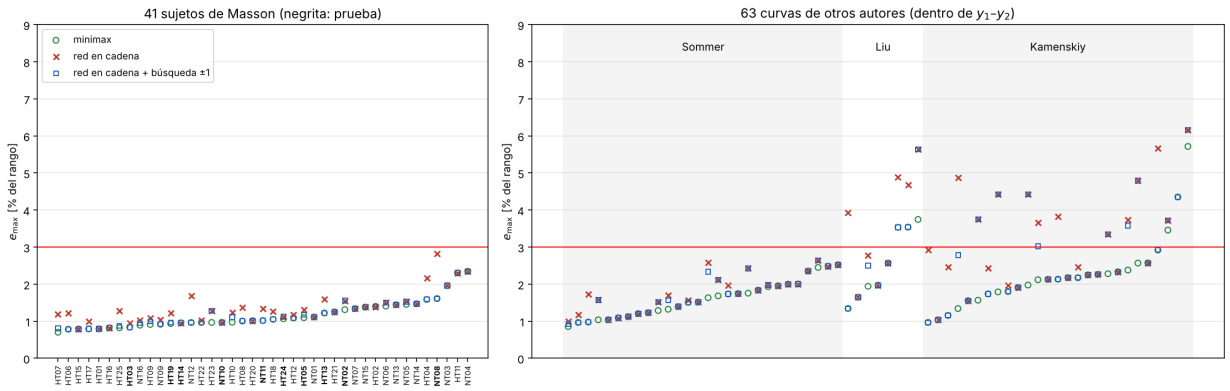


Figura 6: Peor error de cada curva con láminas enteras, 6 materiales: minimax (círculos), red en cadena (cruces) y red en cadena con búsqueda de ±1 (cuadrados). Izquierda: los 41 sujetos de Masson, ordenados por el error del minimax (en negrita, los de prueba). Derecha: las 63 curvas externas dentro de y_1–y_2, por estudio. Línea roja: meta de 3 %.

(I) **La base alcanza.** Con mínimos cuadrados, las 63 curvas cumplen la meta: peor error de 1,28 % con 6 materiales y 1,84 % con 5.

(II) **El techo de las láminas enteras.** El minimax cumple en 57 de las 63 (6 materiales) y en 54 (5). Las que no cumplen ni con el minimax son curvas in vivo de poco recorrido de tensión (de 26 a 36 kPa con 6 materiales, contra una mediana de 56 kPa en las 63), casi rectas, en las que el primer material lleva casi todo el diseño: una lámina de más o de menos mueve la curva más de lo que permite la meta, que en ellas es de 1 kPa o menos. El peor error del minimax en esas curvas es de 1,0 a 1,7 kPa. Con cantidades reales cumplen todas: el límite lo pone la división en 20 láminas por material, no la base ni la red.

(III) **La red.** Sola, cumple en 46 de 63 (6 materiales) y 43 (5); con la búsqueda de ±1, en 50 y 48. En las 28 curvas de Sommer y Holzapfel, con 6 materiales, la red cumple en todas ya sin la búsqueda, como el minimax; en Liu, con la búsqueda, en las mismas 5 que el minimax. Donde queda por debajo del minimax —7 curvas in vivo de Kamenskiy con 6 materiales— la red se equivocó en más de una lámina, y una revisión de ±1 no alcanza. Da exactamente el diseño del minimax en 8 curvas (18 con la búsqueda).

Resultado global. Sumando los 41 sujetos y las 63 curvas externas (6 materiales), el minimax cumple en 98 de 104: es el techo, porque ningún diseño entero cumple en las otras 6. La red en cadena con búsqueda de ±1 cumple en 91, el 93 % de lo alcanzable con láminas enteras, sin resolver ninguna optimización; sola, en 87. Separado por conjunto: 31 de 31 sujetos de entrenamiento, 10 de 10 de prueba y 50 de 63 curvas externas.

Conclusión del primer nivel

Con materiales tipo fibra y una base elegida una vez, la curva tensión–estiramiento de las 41 carótidas se reproduce con láminas enteras dentro de la meta (6 materiales, a lo sumo 20 láminas por material). El minimax da el mejor diseño entero que existe y es la referencia. Una sola red neuronal, la red en cadena con salida ordinal, entrenada dentro de la franja y_1–y_2 —su dominio de validez—, da directamente las láminas enteras en una evaluación: con una búsqueda de ±1 lámina cumple en los 10 sujetos de prueba y en 50 de 63 curvas de otros tres estudios, con otras leyes constitutivas, y llega a 91 de los 98 casos que admiten un diseño entero dentro de la meta. Fuera de la franja la red no se usa.

4. Aplicación: la curva presión–diámetro y el tubo de pared gruesa

4.1. De la tensión a la presión

Un injerto se implanta como tubo, y lo que debe coincidir con la arteria es su diámetro a cada presión. Para pasar de la tensión a la presión hacen falta la geometría y una hipótesis sobre la pared. La configuración libre de tensiones de la arteria es un sector anular abierto de semiángulo Θ_0 y radio R_m en el borde media–adventicia, que representa las tensiones residuales (Fig. 7). Un punto de radio R en el sector pasa al radio r en la arteria cerrada; su estiramiento y la conservación del volumen dan [42]

$$\lambda_\theta = \frac{\pi r}{\Theta_0 R}, \qquad \Theta_0\,(R_m^2 - R^2) = \pi\lambda_z\,(r_m^2 - r^2). \tag{7}$$

El equilibrio radial integrado sobre el espesor da la presión que soporta la pared íntima–media [42, 31]:

$$P = P_i - P_a = \int_{r_i}^{r_m} \frac{\sigma_{\theta\theta} - \sigma_{rr}}{r}\,dr, \tag{8}$$

con P_i la presión de la sangre y P_a la que ejercen la adventicia y el tejido que rodea a la arteria. Como P_a depende del sitio, el diseño se plantea sobre P, la presión que soporta la pared, que es la que el injerto debe soportar con la misma deformación. El espesor íntima–media h se toma de la mediana de referencia por edad y sexo medida con ecotracking [18] (0,43 a 0,68 mm), porque Masson et al. no publican el de cada sujeto, y $r_i = r_m - h$.

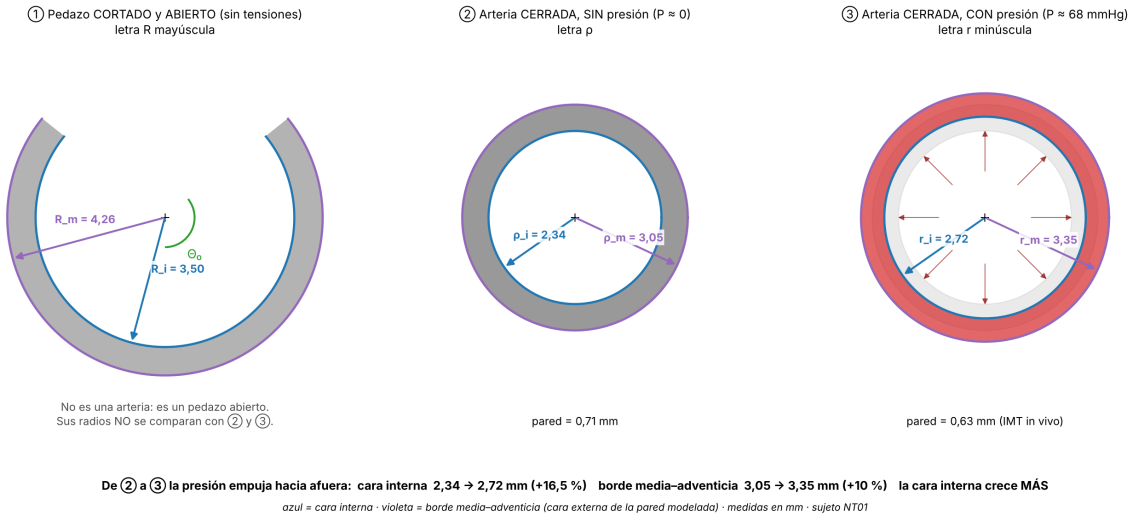


Figura 7: Sujeto NT01 en sus tres estados: (1) sector abierto sin tensiones, (2) arteria cerrada sin presión, (3) arteria con presión. De (2) a (3) la cara interna crece 16,5 % y el borde media–adventicia 10 %.

Ventana de presión. Lo que define si un estado es fisiológico es la presión, no el estiramiento: en $\lambda_\theta = 1{,}16$ el sujeto más rígido soporta unos 400 mmHg y uno blando joven, unos 70. Por eso, en este nivel, todos los sujetos se evalúan en la misma ventana, P de 60 a 200 mmHg (8,0 a 26,7 kPa) en 141 valores, que cubre con margen las presiones medias medidas (64/116 mmHg en NT y 73/127 mmHg en HT [42]). La curva objetivo es el estiramiento del borde media–adventicia, $\lambda(P_k)$, proporcional al diámetro (Fig. 8): los sujetos rígidos llegan a 200 mmHg con λ entre 1,12 y 1,15, los blandos con λ entre 1,20 y 1,23.

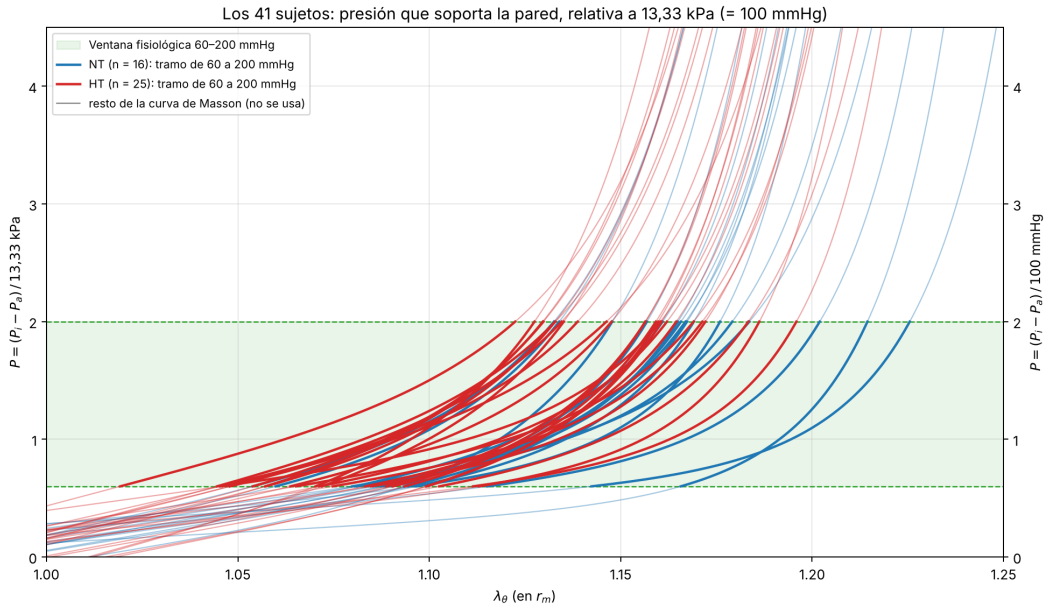


Figura 8: Los 41 sujetos: presión que soporta la pared, en función del estiramiento del borde media–adventicia, en forma relativa: $P = (P_i - P_a)/13{,}33\,\text{kPa}$ a la izquierda y $P = (P_i - P_a)/100\,\text{mmHg}$ a la derecha. Como $13{,}33\,\text{kPa} = 100\,\text{mmHg}$, las dos escalas coinciden; la ventana de 60 a 200 mmHg va de 0,6 a 2. Trazo grueso: tramo de 60 a 200 mmHg, que es la curva objetivo.

4.2. Pared delgada y pared gruesa

Si la pared es delgada frente al radio, todas sus fibras se estiran lo mismo y el equilibrio de medio tubo da la ley de Laplace, $P = \sum_j \sigma_j h_j / r$ [21]: la presión es lineal en los espesores de las capas y el diseño hereda todo el método del primer nivel. Urquiza [61] (ec. 3.13 de su tesis) escribe el mismo equilibrio de pared delgada con el radio y el espesor *instantáneos*, $(P_i - P_a)\,R = \sigma\,h$. Tomando como R el radio medio deformado, $\bar{r} = r_i + h/2$, y llamando $u = 1 + h/r_i$,

$$P = \frac{\sigma\,h}{r_i + h/2} = \sigma\,\frac{2\,(u-1)}{u+1}. \tag{9}$$

Para una pared homogénea con tensión uniforme, (8) da exactamente $P = \sigma \ln u$, y $2(u-1)/(u+1)$ es la aproximación de Padé [1/1] de $\ln u$: con $h/r_i \le 0{,}2$ el error es menor que 0,3 %, mientras que Laplace con el radio interno, $P = \sigma\,(u-1)$, sobreestima la presión hasta en un 10 %. Llamamos *ley de Urquiza* a (9) aplicada al injerto multicapa con un único estiramiento, el del radio medio: $P = \sum_j \sigma_j(\bar{\lambda})\,h_j/\bar{r}$, con $\bar{\lambda} = \bar{r}/\bar{R}$. Sigue siendo lineal en los espesores. La carótida, sin embargo, tiene $h/r \approx 0{,}2$. Con pared incompresible y sin alargamiento, el área entre la cara interna y una fibra que estaba en el radio R se conserva,

$$r^2 - r_i^2 = R^2 - R_i^2, \qquad \lambda(r) = \frac{r}{R}, \tag{10}$$

y las fibras internas se estiran más que las externas (Fig. 9). La presión es la suma exacta del aporte de cada capa delgada, cada una con su propio estiramiento:

$$P = \sum_{j=1}^{N} \int_{\text{capa } j} \frac{\sigma_j\big(\lambda(r)\big)}{r}\,dr. \tag{11}$$

Si $h \ll r$, (11) se reduce a Laplace. Con rectas truncadas, la diferencia de estiramiento decide si una capa tira o no: un material de nudo 1,08 tira en la cara interna de un tubo inflado ($\lambda = 1{,}10$) y no en la externa ($\lambda = 1{,}07$). Además las capas interactúan: si crece una capa interna, las de afuera se corren a radios mayores, se estiran menos y aportan menos. En pared gruesa la presión deja de ser lineal en los espesores.

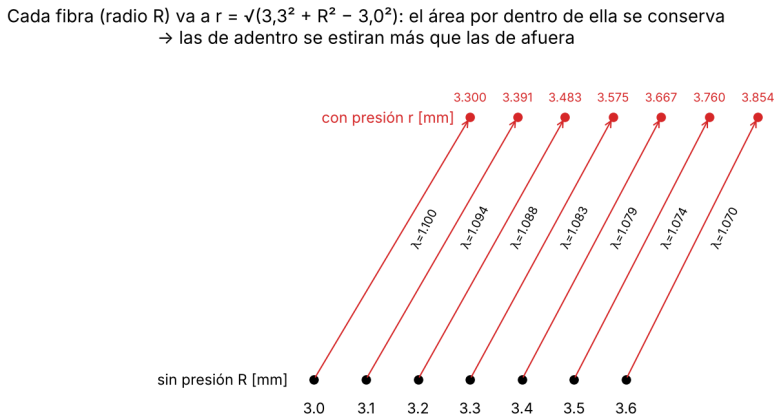


Figura 9: Tubo de 3,0 a 3,6 mm inflado hasta una cara interna de 3,3 mm: cada fibra conserva el área que tiene por dentro; la cara interna se estira 10 % y la externa 7 %.

La pared delgada falla al fabricar. Se diseñó cada sujeto con tres hipótesis —Laplace (pared delgada, $P = \sigma h/r$ con el radio y el espesor sin deformar), la ley de Urquiza (9), con el radio medio deformado, y pared gruesa (ec. 11, cada capa con su propio estiramiento)— y cada diseño se evaluó en el tubo real, de pared gruesa (Tabla 5, Fig. 10). En su propio modelo Laplace parece perfecto ($e_{\text{máx}} \leq 1{,}7$ %); el error aparece al fabricar y crece con el espesor de la pared. Corregir el radio no ayuda, porque el problema no es el radio sino que cada capa se estira distinto y engancha en otro momento. Con la ventana de presión y la base adoptada, el diseño lineal de pared delgada tampoco cumple en ningún sujeto (mediana 27,3 % con 6 materiales y 29,9 % con 5). **El diseño a nivel del tubo debe hacerse en pared gruesa.**

Tabla 5: Comparación de hipótesis sobre curvas de presión en λ de 1,02 a 1,16, con un juego de nudos ajustado a esas curvas de presión (distinto del de la Tabla 1). Cada fila es la hipótesis con que se *diseña*; todos los diseños se *evalúan* en el tubo de pared gruesa, que es lo que se fabrica. En cada celda, para los 41 sujetos: cuántos cumplen $e_{\text{máx}} \leq 3$ %, la mediana de $e_{\text{máx}}$ y el peor $e_{\text{máx}}$, con 5 o 6 materiales.

Hipótesis de diseño	5 materiales	6 materiales
Laplace	0/41 · 13,6 % · 22,7 %	0/41 · 14,8 % · 32,5 %
Urquiza (radio medio deformado)	0/41 · 13,7 % · 24,5 %	0/41 · 15,4 % · 34,4 %
Pared gruesa	41/41 · 0,96 % · 2,97 %	41/41 · 0,72 % · 2,10 %

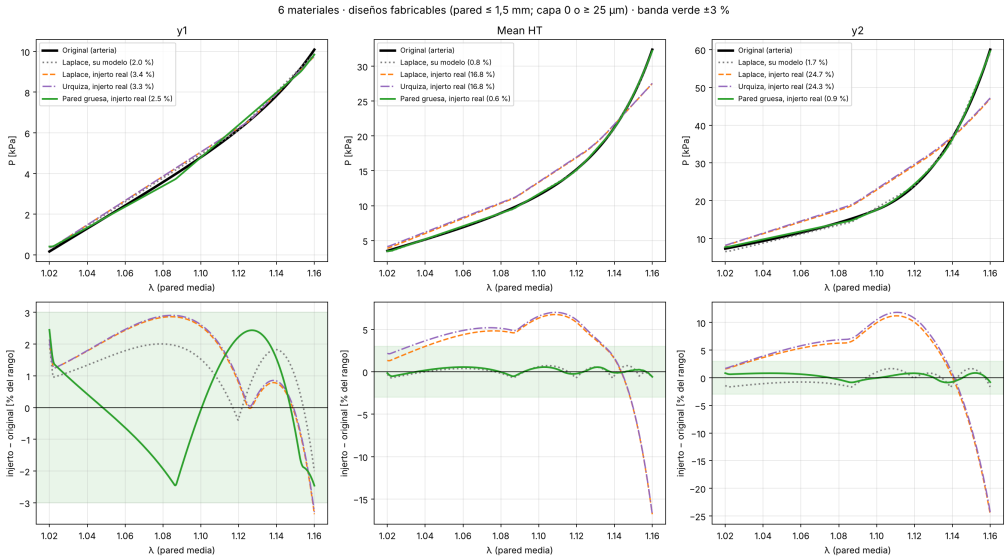


Figura 10: Condiciones de la Tabla 5, 6 materiales, de izquierda a derecha: curva más blanda (y_1), media de los hipertensos y más rígida (y_2). Arriba de cada par: curvas; abajo: injerto − arteria en % del rango (banda ±3 %). El diseño de Laplace evaluado en su propio modelo (gris, punteado) parece perfecto; fabricado (naranja, a trazos), se aparta hasta 25 %.

Tabla 6: Diseños de la Fig. 10 (curvas de presión en λ de 1,02 a 1,16, 6 materiales; nudos 0,8271; 1,0219; 1,0867; 1,1197; 1,1391; 1,1531 y módulos 0,18; 1,33; 4,86; 2,72; 12,94; 6,35 MPa): espesor de la capa de cada material h_j [µm] (capa 1 junto a la sangre; 0: no se usa), pared total [µm] y errores contra la curva de presión de la arteria, E_{rms} y $e_{\text{máx}}$ [% del rango]. "Laplace, en su modelo" y "Laplace, injerto real" son el mismo diseño evaluado con dos modelos.

Curva	Diseño y evaluación	h_1	h_2	h_3	h_4	h_5	h_6	pared	E_{rms}	$e_{\text{máx}}$
y_1	Laplace, en su modelo	25	153	0	56	0	0	233	1,47	2,01
	Laplace, injerto real	25	153	0	56	0	0	233	1,98	3,36
	Urquiza, injerto real	25	153	0	56	0	0	233	2,01	3,29
	Pared gruesa, injerto real	25	130	25	0	0	29	210	1,47	2,46
Media HT	Laplace, en su modelo	235	203	59	205	67	136	905	0,41	0,76
	Laplace, injerto real	235	203	59	205	67	136	905	5,14	16,79
	Urquiza, injerto real	250	196	62	204	66	132	909	5,40	16,79
	Pared gruesa, injerto real	129	158	48	218	0	467	1020	0,34	0,60
y_2	Laplace, en su modelo	449	229	139	461	193	30	1500	1,08	1,73
	Laplace, injerto real	449	229	139	461	193	30	1500	7,95	24,69
	Urquiza, injerto real	453	241	141	454	187	25	1500	8,24	24,30
	Pared gruesa, injerto real	203	122	67	626	206	277	1500	0,61	0,87

4.3. El injerto de pared gruesa

El injerto es un tubo cerrado, incompresible y en deformación plana, con una capa por material apilada de adentro hacia afuera por nudo creciente (el orden inverso duplica o triplica el error), centrado en $R_{\text{ref}} = 3{,}421\,\text{mm}$ (mediana de $\Theta_0 R_m/\pi$ de los 41 sujetos). Los materiales son los del primer nivel: los mismos nudos y rectas $\sigma_j = E_j\,\text{máx}(0, \lambda - \kappa_j)$, con módulos E_j calibrados una vez para que el sujeto de entrenamiento que más necesita de cada material use 0,2 mm de él (6 materiales: de 452 a 4966 kPa). El diseño es

$$\theta = (h_1, \ldots, h_N,\ \delta), \qquad 0 \le h_j \le 3\ \text{mm}, \quad |\delta| \le 0{,}25. \tag{12}$$

Aquí h_j es el espesor de la capa del material j y δ es el *preestiramiento común*: un corrimiento de todos los nudos juntos, en unidades de estiramiento (adimensional). La capa j empieza a trabajar cuando la pared media llega a $k_j + \delta$ en lugar de k_j:

- $\delta < 0$ adelanta el enganche de todas las capas (se montan más tensas: tiran desde antes);
- $\delta = 0$ deja los nudos de la base del primer nivel;
- $\delta > 0$ lo atrasa (se montan más flojas: tiran desde después).

Qué significa $|\delta| \leq 0{,}25$. $|\delta|$ es el valor absoluto de δ, de modo que la condición equivale a $-0{,}25 \leq \delta \leq 0{,}25$: los nudos pueden correrse como mucho 0,25 hacia la izquierda o hacia la derecha. Por ejemplo, con $\delta = -0{,}25$ el nudo 1,08 pasa a 0,83, y con $\delta = +0{,}25$, a 1,33. Es un límite de la búsqueda, no una propiedad del material: se eligió más ancho que todo el tramo de estiramiento que recorre un sujeto (de 1,02 a 1,23, es decir 0,21), para que ningún sujeto quede fuera por la cota. No está activa: en los 82 diseños (41 sujetos, 5 y 6 materiales) δ quedó entre $-0{,}04$ y $+0{,}09$. El Anexo B muestra con un ejemplo que se puede verificar a mano qué hace δ en un tubo de dos capas.

- **Espesores** h_j, que se fabrican con n_j láminas enteras de espesor e.
- **Enganche y preestiramiento.** Cada capa engancha cuando la pared media llega a $k_j + \delta$; su enganche local κ_j es el estiramiento del centro de la capa en ese momento, por (10). En fabricación, κ_j es el rizado de las fibras de esa capa. El preestiramiento común δ corre todos los nudos juntos: cada sujeto ocupa su propio tramo de estiramiento (de 1,02 a 1,23), y sin δ vería solo uno o dos nudos, con un error típico de 11 %.

La presión (11) se integra en cada capa con cuadratura de Gauss–Legendre de 8 nodos [15] en 651 valores de λ entre 0,80 y 1,45, y se invierte por interpolación lineal para obtener $\lambda_{\text{inj}}(P_k; \theta)$. La función $\theta \mapsto \lambda_{\text{inj}}$ es no lineal: los espesores fijan los límites de integración y los enganches, y δ entra dentro del $\max(0, \cdot)$. Con láminas enteras, encontrar los n_j es un problema **no lineal entero mixto**. La métrica es (4) sobre $\lambda(P_k)$.

4.4. Métodos de diseño

Tabla 7: Bloques de cálculo a nivel del tubo. "Lineal" se refiere a la dependencia del modelo respecto de las incógnitas.

Bloque	Variables	¿Lineal?	Algoritmo	Implementación
A1 MCO lineal (pared delgada)	reales	sí, con δ fijo	mínimos cuadrados por SVD; δ por grilla y Brent	`numpy.linalg.lstsq` [25]; `minimize_scalar` [10, 62]
A2 MCO no lineal (pared gruesa)	reales	no	región de confianza reflexiva con cotas (TRF)	`scipy.optimize.least_squares` [9, 62]
A3 Minimax entero (pared gruesa)	láminas enteras, δ real	no	enumeración piso/techo, δ por Brent acotado, búsqueda local	propio; `minimize_scalar` [10]
A4 Red neuronal	reales	— (una evaluación)	perceptrón multicapa; optimización amortizada	TensorFlow/Keras [2]

A1 · MCO lineal de pared delgada. Con la ley de Laplace y δ fijo, la presión es lineal en $c_j = E_j h_j / R_{\text{ref}}$: $P_k \approx \sum_j c_j \max(0, y_k - k_j - \delta)$. Para cada δ de una grilla de 101 valores se resuelve por mínimos cuadrados; el residuo en presión se pasa a λ con la pendiente local de la curva; el mejor δ se refina por Brent [10] y $h_j = c_j R_{\text{ref}} / E_j$, recortados a $[0; 3]$ mm. Es el método del primer nivel, trasladado al tubo.

A2 · MCO no lineal de pared gruesa. Minimiza $\sum_k \big((\lambda_{\text{inj}}(P_k; \theta) - y_k)/\Delta\big)^2$ con las cotas (12), por el método de región de confianza reflexiva (*Trust Region Reflective*, TRF) [9]. En cada iteración calcula el jacobiano de los residuos por diferencias finitas, aproxima el problema por su

modelo cuadrático de Gauss–Newton y toma el paso que lo minimiza dentro de una *región de confianza*, un entorno donde el modelo es creíble; agranda la región si el paso funcionó y la achica si no, y refleja hacia adentro los pasos que cruzan una cota. Tolerancias 10^{-10}, a lo sumo 300 evaluaciones. Encuentra un mínimo *local*: el resultado depende del punto de partida.

A3 · Minimax entero. Es el minimax del primer nivel, llevado al caso no lineal, donde ya no hay programa lineal que lo resuelva en forma exacta. A partir de un diseño real $\theta^\star$ y una curva de referencia $\tilde{y}$: (1) $n_j \in \{\lfloor h_j^\star/e \rfloor, \lceil h_j^\star/e \rceil\}$; se evalúan las 2^N combinaciones por $e_{\text{máx}}$ contra $\tilde{y}$; (2) para las 8 mejores se reajusta δ en $\pm 0{,}03$ por Brent acotado; (3) búsqueda local [1]: vecinos que suman o restan una lámina a un material o pasan una lámina de uno a otro, aceptando el mejor si baja el peor error, hasta 20 veces. Es una heurística: no garantiza el óptimo entero global. A diferencia del primer nivel, aquí sí se parte de una solución real: es la estrategia habitual en problemas no lineales enteros, resolver el problema continuo y buscar los enteros en su vecindad, y es razonable porque con láminas de 0,025 mm un diseño tiene unas 46 láminas y una lámina mueve poco la curva. La distancia de esta heurística al óptimo se mide más abajo (*Distancia al óptimo entero*).

A4 · Red neuronal. Un perceptrón multicapa con el mismo tronco que la red del primer nivel y salidas lineales, $141 \to 256 \to 128 \to 64 \to N{+}1$: recibe la curva $\lambda(P_k)$ estandarizada y devuelve θ. Datos: 6000 injertos con diseño sorteado, cuya etiqueta es exactamente su diseño, y 9000 arterias sintéticas de la ley de Masson más los 31 sujetos de entrenamiento, cuya etiqueta es el ajuste A2; ruido nuevo de 0 a 1 % del rango de λ en cada época. Partición 11 220 / 1530 / 2250; 425 épocas (6 materiales) y 629 (5). Se usa como *optimización amortizada* [4]: un modelo aprendido sobre muchos casos resueltos propone la solución de uno nuevo, y un optimizador clásico la termina. Curvas de aprendizaje y métricas en el Anexo C.

El procedimiento. Los bloques se encadenan en tres pasos (Fig. 11): (1) arranque, A1 (camino A) o la red A4 (camino B); (2) A2, que ajusta el diseño a la curva; (3) A3, que elige las láminas contra la *curva ajustada* del paso 2. Es la conclusión del primer nivel sobre el ruido: el paso 2 suaviza, porque la curva de un injerto no puede tener los saltos del ruido, y el paso 3 no lo persigue.

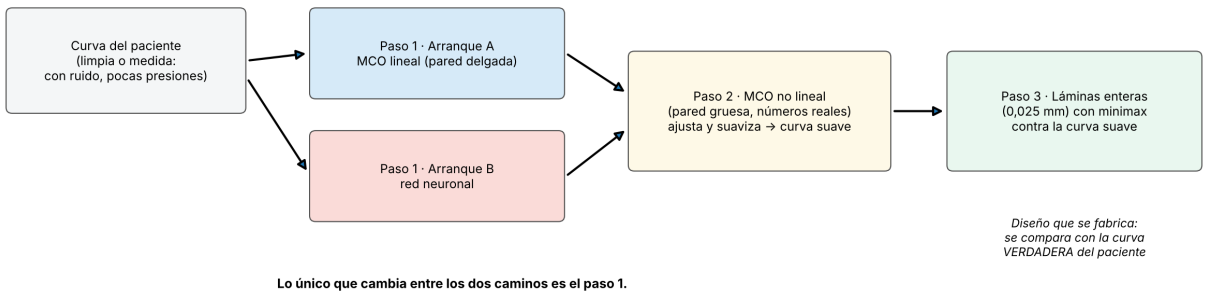


Figura 11: El procedimiento de diseño a nivel del tubo. Los dos caminos solo difieren en el paso 1.

Curvas medidas. En la práctica la curva del paciente se mide, con ruido y en pocas presiones. Se simulan: (a) ruido gaussiano proporcional de 0,3 % en λ (el ecotracking resuelve unos 20 µm en 7 mm); (b) medición en 10 presiones con interpolación cúbica monótona (PCHIP) [20] a las 141; (c) ambas, con ruido de 0,2 %. Cada camino recibe la curva medida y su diseño entero se compara con la curva verdadera; una realización por sujeto y caso. Como $\lambda \approx 1{,}1$ y su rango es de unos 0,07, un ruido de 0,3 % de λ equivale a alrededor del 5 % del rango: mayor que la meta.

4.5. Resultados

Diseño real. Desde el arranque lineal, A2 deja 40 de los 41 sujetos dentro de la meta (6 materiales: mediana 0,84 %, peor 3,43 %; 5 materiales: 40/41, peor 3,14 %), con paredes de 0,75 a 1,89 mm y δ de $-0{,}04$ a $+0{,}09$. Arrancando desde la red llega a 41 de 41 con 6 materiales (peor 1,79 %), con la mitad de evaluaciones del modelo (16 contra 35 por sujeto). Sola, la red no alcanza: mediana 3,43 % y peor 89,6 %. En los 10 sujetos de prueba el híbrido da 0,93 % de mediana y 1,79 % el peor.

Espesor de lámina. Con láminas de 0,1, 0,05 y 0,025 mm cumplieron la meta 38, 40 y 41 de los 41 sujetos (6 materiales; peor 5,44, 3,69 y 1,64 %; unas 10, 23 y 46 láminas). Se adoptó $e = 0{,}025$ mm.

El procedimiento completo. Con curvas limpias los dos arranques empatan (Tabla 8, Fig. 12). La diferencia está en el peor caso con curvas medidas: con 10 presiones, el arranque lineal cae en un mínimo local en dos sujetos (NT03 y HT04, 468,7 %), que el arranque de la red evita; con ruido de 0,3 %, la red aumenta los sujetos dentro de la meta (31 contra 23 con 6 materiales; 32 contra 25 con 5). Con 10 presiones y ruido ninguno pasa de 8 de 41: ese ruido ya es comparable a la meta. El tiempo es de 0,2 a 0,5 s por sujeto con cualquiera de los dos arranques.

Distancia al óptimo entero. Para medir cuánto pierde la heurística A3, en los 41 sujetos (curvas limpias, arranque MCO lineal) se recorrieron *todas* las combinaciones de láminas a ± 2 de las del diseño real del paso 2 (hasta $5^6 = 15\,625$ combinaciones), cada una con δ en una grilla de 13 valores y refinado por Brent en las 200 mejores, con el mismo objetivo que el A3 (peor punto contra la curva ajustada). La búsqueda exhaustiva da el mismo diseño que el A3 en 24 de los 41 sujetos (6 materiales) y en 34 (5 materiales); el peor punto baja en 20 sujetos (6 materiales), en promedio 0,15 y como máximo 0,44 puntos, y en 10 sujetos con 5 materiales (0,14 y 0,43; a veces con las mismas láminas y otro δ). Contra la curva verdadera, la mediana pasa de 1,13 a 1,03 % (6 materiales) y de 1,69 a 1,62 % (5), y no cambia ni el peor caso (3,26 y 3,21 %) ni cuántos sujetos cumplen (40 de 41 en ambos casos). La heurística queda, por lo tanto, a pocas décimas del óptimo en esa vecindad, en 0,5 s en lugar de los 2 min por sujeto de la búsqueda exhaustiva (6 materiales).

Tabla 8: Procedimiento completo con láminas de 0,025 mm: peor error contra la curva verdadera [%], 41 sujetos.

		6 materiales			5 materiales		
Curva	Arranque	mediana	peor	cumplen	mediana	peor	cumplen
limpia	MCO lineal	1,13	3,26	40/41	1,69	3,21	40/41
	red	1,14	2,19	41/41	1,68	3,19	40/41
10 presiones	MCO lineal	1,26	468,7	38/41	1,62	3,13	40/41
	red	1,19	2,27	41/41	1,61	2,70	41/41
ruido 0,3 %	MCO lineal	2,67	11,87	23/41	2,66	7,52	25/41
	red	2,19	6,59	31/41	2,32	9,24	32/41
10 pres. + ruido 0,2 %	MCO lineal	4,36	8,07	8/41	4,62	8,77	6/41
	red	3,78	8,54	8/41	4,75	10,35	6/41

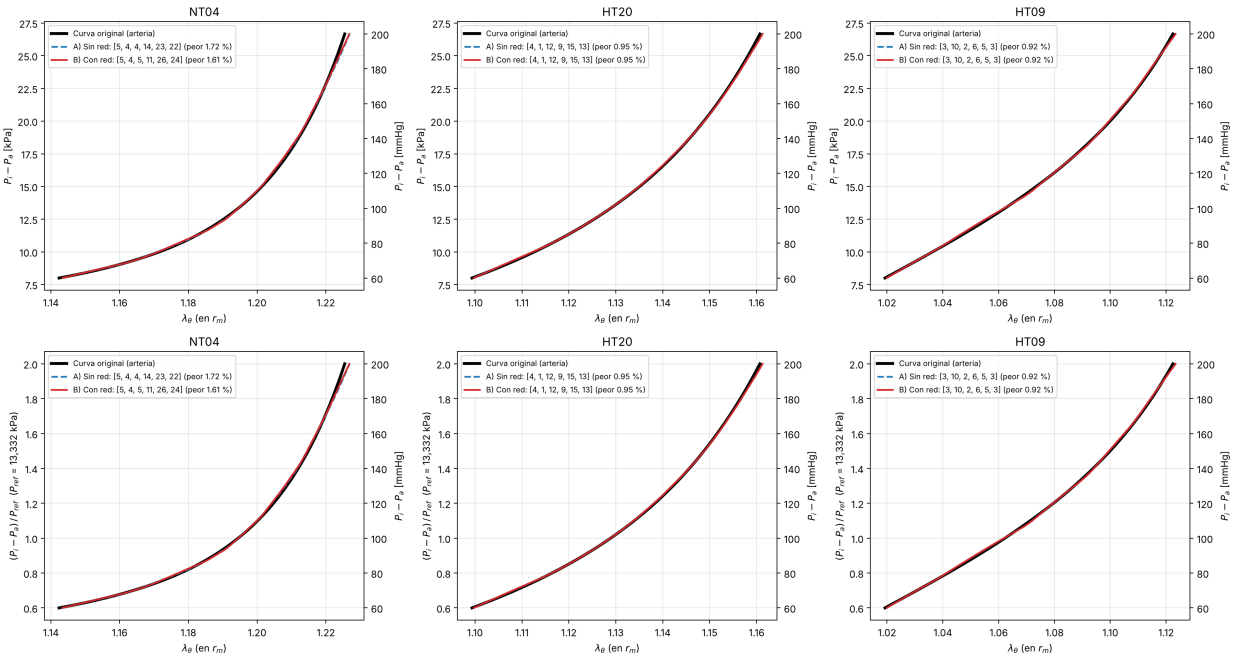


Figura 12: 6 materiales, curvas limpias: el sujeto más blando, uno intermedio y el más rígido. Negra: arteria; azul: camino A (arranque MCO lineal); roja: camino B (arranque red). Ordenada: presión que soporta la pared, arriba en kPa y abajo relativa a 13,332 kPa; a la derecha, mmHg. Entre corchetes, láminas de cada material.

Tabla 9: Diseños enteros de la Fig. 12 (6 materiales, láminas de 0,025 mm, curvas limpias): número de láminas de cada material n_j (material 1 junto a la sangre), total de láminas, pared [mm], preestiramiento δ y errores contra la curva $\lambda(P)$ de la arteria, E_{rms} y $e_{\text{máx}}$ [% del rango]. Camino A: arranque MCO lineal; camino B: arranque red.

Sujeto	Camino	n_1	n_2	n_3	n_4	n_5	n_6	láminas	pared	δ	E_{rms}	$e_{\text{máx}}$
NT04 (el más blando)	A	5	4	4	14	23	22	72	1,800	+0,0861	0,59	1,72
	B	5	4	5	11	26	24	75	1,875	+0,0890	0,58	1,61
HT20 (intermedio)	A	4	1	12	9	15	13	54	1,350	+0,0103	0,37	0,95
	B	4	1	12	9	15	13	54	1,350	+0,0103	0,37	0,95
HT09 (el más rígido)	A	3	10	2	6	5	3	29	0,725	−0,0394	0,42	0,92
	B	3	10	2	6	5	3	29	0,725	−0,0394	0,42	0,92



Figura 13: 6 materiales, curvas medidas: peor error de cada sujeto contra la curva verdadera (escala logarítmica; azul, arranque MCO lineal; rojo, arranque red; punteada, meta).

Contra qué curva elegir las láminas. Si el paso 3 elige las láminas contra la curva tal como viene medida, persigue el peor punto, que con ruido es un salto del ruido (Fig. 14). Contra la curva ajustada del paso 2, con ruido de 0,3 % y arranque red, cumplen 31 sujetos en lugar de 10 (6 materiales) y 32 en lugar de 5 (5 materiales); el costo con curvas limpias es de 0,2 puntos de mediana.

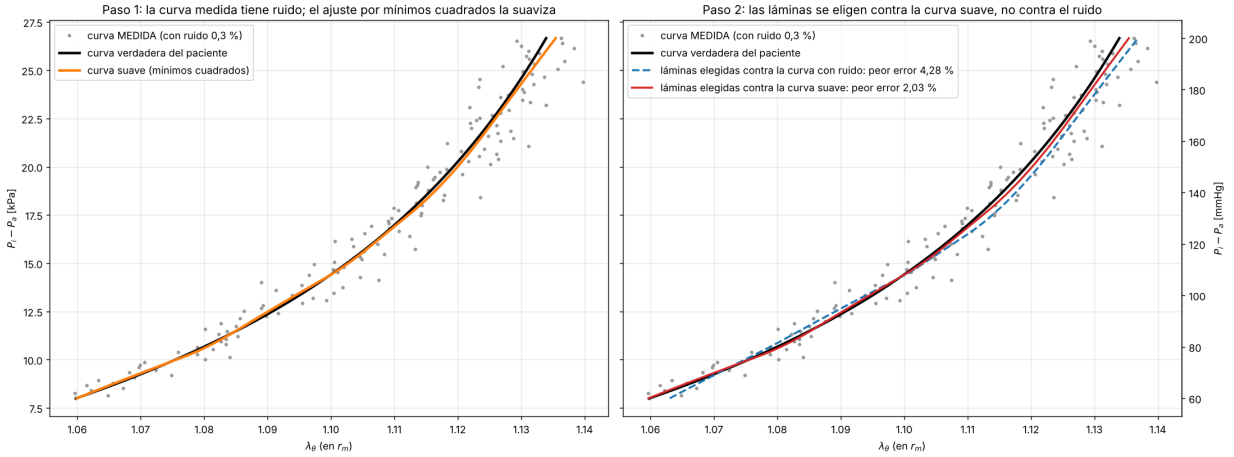


Figura 14: Sujeto NT11, 6 materiales, ruido de 0,3 %. Izquierda: la curva ajustada por el paso 2 (naranja) pasa por el medio de la medida (gris). Derecha: láminas elegidas contra la curva medida ($e_{\text{máx}} = 4{,}28$ %) y contra la ajustada (2,03 %), ambas evaluadas contra la verdadera.

5. Discusión

Por qué dos niveles. La curva tensión–estiramiento es una propiedad del tejido. Trabajar primero sobre ella permite validar cada pieza del método —la base, el ajuste, el redondeo, la red— contra soluciones exactas, sin que intervengan la geometría ni la presión, que dependen de cada arteria y de cada sitio. El paso al tubo agrega la geometría y la hipótesis de pared gruesa, pero conserva los materiales, la métrica, el criterio minimax y la conclusión sobre el ruido.

Generalidad. Lo que se valida en el primer nivel no es propio de la carótida: los materiales tipo fibra, la base elegida sobre un espacio amplio de curvas en J, el diseño entero minimax y una red que da ese diseño en curvas de leyes que nunca vio. Para otra arteria cambian la geometría, el espesor y la ventana de presión, que entran recién en el segundo nivel; la franja de curvas y, si hiciera falta, los nudos se recalculan con el mismo procedimiento, y la red se reentrena dentro de la nueva franja. La validación externa (Sección 3.8) lo confirma con datos: la base elegida con las carótidas de Masson reproduce, sin cambios, curvas de carótida común, externa e interna, de paredes intactas y media–íntimas y de pacientes con placa, de tres leyes constitutivas distintas, cada una en su ventana de presión. Lo que limita en algunas curvas in vivo es la división en 20 láminas por material frente a un recorrido de tensión pequeño, no la forma de la curva ni la red.

El papel de la red neuronal. En el primer nivel, el minimax da el mejor diseño entero, pero resolviendo un problema de optimización por cada curva. La red en cadena da el diseño entero directamente, con la misma operación para cualquier curva de su dominio de validez: sola, cumple la meta en los 41 sujetos (6 materiales); con una búsqueda de ± 1 lámina, que solo evalúa 729 combinaciones, llega a 91 de los 98 casos que admiten un diseño entero dentro de la meta. No tiene la garantía de óptimo del minimax, que sigue siendo la referencia para comprobar cualquier diseño, y no se usa fuera de la franja y_1–y_2, donde no puede asegurar la meta. En pared gruesa el ajuste es iterativo, local y depende del punto de partida: el arranque clásico, heredado del caso lineal, ignora el gradiente de estiramiento en el espesor y, con curvas medidas, puede llevar a mínimos locales que dan diseños inservibles. Una red entrenada sobre miles de diseños resueltos deja al ajuste cerca del mínimo correcto. Es la idea de la optimización amortizada [4]: la red no reemplaza al optimizador, lo inicia. Su ventaja es de robustez, clara con 6 materiales y menor con 5.

Por qué pared gruesa. La diferencia entre los modelos está en una sola hipótesis: en pared delgada todas las fibras se estiran igual; en pared gruesa cada una tiene su estiramiento, fijado por la incompresibilidad. Con materiales que no tiran hasta su nudo, esa diferencia de pocos centésimos decide si una capa trabaja. El enganche de cada capa (su rizado) es tan importante como su espesor: entre un diseño de Laplace y uno de pared gruesa los espesores cambian pocos micrómetros, pero las capas externas enganchan antes.

Limitaciones. (1) Las curvas objetivo son las de la ley ajustada por Masson et al., no las mediciones crudas, y el espesor arterial es el de referencia para la edad y el sexo. (2) Los materiales son ideales (rectas truncadas de rigidez constante); el injerto no tiene alargamiento axial ni tensiones residuales, y no se consideran viscoelasticidad ni fatiga. (3) La búsqueda entera en pared gruesa es heurística: queda a menos de medio punto del óptimo en una vecindad de ± 2 láminas, pero no se demostró el óptimo global; se usó una sola realización de ruido por sujeto y caso. (4) El preestiramiento δ y el rizado por capa son variables de fabricación que deben validarse. (5) La red del primer nivel vale dentro de la franja y_1–y_2 de la población de Masson; para curvas fuera de ella hay que ampliar la franja y reentrenarla, o usar solo el minimax. (6) No hay validación experimental.

6. Conclusiones

1. Un injerto de capas de materiales tipo fibra (rectas truncadas), con una base elegida una vez para toda la población y a lo sumo 20 láminas por material, reproduce la curva tensión–estiramiento de 41 carótidas humanas: con 6 materiales y láminas enteras por minimax, los 41 sujetos cumplen la meta de 3 %.
2. Una sola red neuronal, en cadena y con salida ordinal, entrenada dentro de la franja y_1–y_2 —su dominio de validez—, da directamente las láminas enteras en una evaluación, sin optimizar. Con una búsqueda de ± 1 lámina cumple la meta en los 31 sujetos de entrenamiento y en los 10 de prueba, con 6 y con 5 materiales salvo un sujeto que tampoco cumple con el minimax.
3. Sin ningún cambio, la misma base y la misma red se aplicaron a 63 curvas de otros tres estudios (Sommer y Holzapfel, Liu et al., Kamenskiy et al.) dentro del dominio de validez, cada una con su ley constitutiva y su ventana de presión: con 6 materiales, la red con búsqueda de ± 1 cumple en 50 y el minimax en 57; en las otras 6 ningún diseño entero cumple, porque su recorrido de tensión es pequeño frente al paso de una lámina. Sumando los 104 casos, la red llega a 91 de los 98 alcanzables con láminas enteras.
4. A nivel del tubo el diseño debe hacerse en pared gruesa: diseñado con la ley de Laplace, ningún sujeto cumple al fabricarse; en pared gruesa cumplen 40–41 de 41. El problema es no lineal entero.
5. El procedimiento de tres pasos —arranque, mínimos cuadrados no lineales y láminas enteras por minimax contra la curva ajustada— cumple en 40–41 de 41 sujetos con curvas limpias, en menos de medio segundo por sujeto.
6. En pared gruesa, la red como punto de partida evita los mínimos locales que, con curvas medidas, producen diseños inservibles (peor caso de 468,7 a 2,3 %) y aumenta los sujetos dentro de la meta con ruido. Es el papel justificado de la red: iniciar el optimizador, no reemplazarlo.

Próximos pasos. Probar el método con curvas medidas de otras arterias; ensayar materiales reales para reemplazar las rectas ideales y validar el rizado como variable de fabricación; usar el espesor y la presión medidos de cada sujeto; y fabricar y ensayar un injerto.

A. Parámetros de los 41 sujetos

Tabla 10: Parámetros de Masson et al. [42] (sus Tablas 2 y 4). †: sujeto reservado para prueba.

Sujeto	Edad [años]	Sexo	R_m [mm]	Θ_0 [°]	λ_z	c [kPa]	c_1 [kPa]	c_2	c_1^{circ} [kPa]	c_2^{circ}	α [°]	T_m [kPa]	λ_0	λ_m	a [kPa]	b
NT01	62	F	4,26	128,70	1,11	29,82	9,44	14,14	16,13	15,11	65,74	39,73	0,960	1,70	0,122	3,52
NT02†	60	M	4,69	128,90	1,08	20,42	8,47	13,10	14,16	15,12	44,46	41,84	0,680	1,92	0,126	3,40
NT03	31	M	4,30	132,20	1,09	27,23	10,34	13,10	7,01	12,82	48,62	43,37	0,820	1,65	0,139	3,57
NT04	31	M	4,67	133,90	1,10	23,59	6,58	11,77	6,38	10,69	32,04	39,81	0,680	1,59	0,118	3,53
NT05	34	F	4,20	130,10	1,10	35,68	13,62	13,18	13,38	13,17	50,72	50,07	0,860	1,62	0,103	3,58
NT06	53	F	3,96	130,10	1,11	33,37	11,38	13,63	13,30	14,26	57,14	46,59	0,950	1,69	0,093	3,44
NT07	21	F	3,83	132,00	1,10	44,28	21,79	13,17	8,27	12,73	51,15	53,58	0,920	1,62	0,111	3,58
NT08†	25	M	4,86	133,20	1,07	23,25	6,34	12,93	8,11	13,17	42,93	31,90	0,820	1,77	0,173	3,57
NT09	42	F	4,51	129,50	1,10	34,90	16,14	13,58	19,64	13,89	57,21	47,01	0,930	1,65	0,084	3,55
NT10†	55	M	4,77	129,10	1,10	38,57	36,31	13,31	56,88	13,61	54,22	46,36	0,890	1,66	0,006	3,75
NT11†	64	M	5,57	129,50	1,10	34,89	40,16	13,45	66,88	13,53	54,54	41,12	0,850	1,79	0,005	3,23
NT12	60	F	4,88	130,10	1,09	33,94	10,78	13,95	12,79	15,42	60,97	45,77	0,930	1,73	0,099	3,37
NT13	61	F	4,92	130,60	1,09	35,15	17,69	13,43	18,40	13,22	55,04	45,59	0,940	1,66	0,085	3,51
NT14	39	F	3,54	131,50	1,09	28,97	8,22	13,13	19,02	13,16	50,22	41,30	0,890	1,67	0,105	3,53
NT15	58	F	3,92	132,40	1,08	26,71	15,79	13,36	16,68	13,11	53,60	35,32	0,950	1,71	0,166	3,60
NT16	60	M	5,72	129,70	1,10	27,79	28,23	13,46	57,77	13,63	55,73	36,50	1,05	1,77	0,141	3,58
HT01	68	M	4,96	130,90	1,10	35,91	12,57	14,08	15,52	14,91	67,18	48,42	0,990	1,66	0,098	3,50
HT02	54	M	4,93	129,80	1,10	38,20	16,40	13,20	16,44	13,20	51,11	52,44	0,860	1,62	0,137	3,58
HT03†	64	F	4,87	129,50	1,10	36,01	14,55	13,96	18,35	14,48	62,66	47,02	1,00	1,74	0,113	3,62
HT04	58	F	4,57	131,20	1,09	22,42	8,57	13,03	6,43	13,36	46,38	38,53	0,810	1,68	0,099	3,51
HT05†	62	F	4,78	130,10	1,10	48,19	35,06	13,23	43,19	13,03	53,24	52,86	0,910	1,63	0,033	3,56
HT06	66	F	5,06	129,10	1,10	39,78	37,75	13,35	60,89	13,45	56,01	46,44	0,910	1,64	0,004	3,54
HT07	54	F	4,30	129,60	1,11	50,45	25,51	13,32	39,43	13,24	53,47	64,91	0,930	1,66	0,078	3,72
HT08	63	F	4,44	129,00	1,10	34,44	30,62	13,29	60,33	13,21	54,67	44,94	0,930	1,65	0,084	3,56
HT09	68	M	5,09	128,20	1,12	51,48	33,77	13,17	44,26	13,49	51,83	66,41	0,840	1,62	0,023	3,55
HT10	55	F	4,30	129,00	1,10	37,04	12,32	14,13	15,04	14,93	65,14	48,19	1,04	1,71	0,114	3,47
HT11	69	M	5,54	131,20	1,08	29,64	9,76	13,23	9,10	15,12	48,16	37,83	0,830	1,74	0,115	3,59
HT12	54	M	5,43	131,80	1,09	32,23	17,81	13,35	14,03	12,15	53,73	44,93	0,920	1,65	0,090	3,58
HT13†	61	M	5,17	128,40	1,11	30,45	15,87	13,08	23,03	13,84	47,86	52,58	0,750	1,61	0,009	3,49
HT14†	60	M	4,64	129,90	1,10	30,43	13,74	13,45	18,01	13,35	54,90	42,43	0,910	1,66	0,088	3,52
HT15	53	M	4,65	130,40	1,10	40,83	28,98	13,36	31,16	12,62	54,44	49,57	0,930	1,65	0,085	3,63
HT16	54	M	4,71	129,60	1,10	45,26	29,27	14,00	33,48	14,82	67,16	67,68	1,02	1,65	0,039	3,52
HT17	53	M	5,04	130,00	1,10	37,25	39,18	13,24	66,29	13,15	54,90	48,26	0,910	1,64	0,099	3,60
HT18	52	M	4,92	129,70	1,10	29,28	10,50	13,21	19,76	13,39	50,96	46,42	0,850	1,63	0,094	3,56
HT19†	57	F	4,27	130,30	1,10	33,49	14,47	13,22	17,35	13,27	53,18	46,18	0,900	1,64	0,097	3,55
HT20	61	F	5,14	129,20	1,10	40,09	15,72	14,09	16,78	14,83	65,17	53,40	1,04	1,70	0,100	3,47
HT21	57	F	4,88	129,90	1,10	35,31	14,57	13,26	15,58	13,30	52,07	48,97	0,870	1,63	0,094	3,57
HT22	44	F	4,17	131,00	1,10	55,25	35,78	13,23	19,51	12,55	52,36	59,58	0,930	1,61	0,097	3,61
HT23	51	M	4,83	130,60	1,08	30,77	12,80	13,60	41,10	14,20	49,79	41,06	0,870	1,90	0,094	3,56
HT24†	65	M	4,57	129,60	1,10	38,91	25,76	13,20	35,01	13,20	51,94	50,28	0,870	1,62	0,043	3,58
HT25	67	F	4,72	129,20	1,10	40,29	31,78	13,75	60,40	14,29	63,50	46,06	1,03	1,72	0,025	3,46

B. Ejemplo de diseño de pared gruesa, paso a paso

Este anexo muestra, con números que se pueden verificar con calculadora, las ideas que usa la Sección 4: el injerto reproduce el comportamiento de la arteria con capas de distintos materiales; cada fibra de una pared gruesa se estira distinto; la presión es la suma de los aportes de rebanadas delgadas; el lugar de cada capa cambia lo que aporta; y el preestiramiento δ corre todos los nudos. Para que las cuentas sean cortas el tubo es cerrado, sin tensiones residuales y sin alargamiento axial, y el nudo de cada material se aplica directamente al estiramiento local de cada franja (en el modelo completo el nudo se define en la pared media y se traduce a cada capa por incompresibilidad, ec. 10).

B.1. La arteria y el injerto

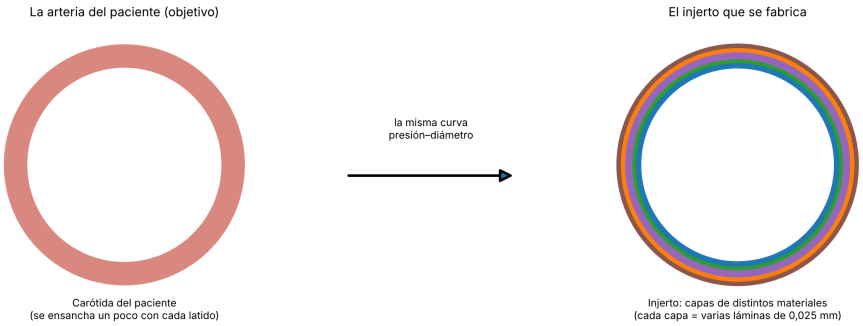


Figura 15: La carótida del paciente (izquierda) y el injerto (derecha), hecho de capas de distintos materiales, cada capa con un número entero de láminas. El objetivo es que el injerto tenga la misma curva presión–diámetro que la arteria: que los dos se ensanchen igual con la presión.

B.2. Incompresibilidad: el área del anillo no cambia

El tejido es casi todo agua: se deforma sin cambiar de volumen. Si el tubo no se alarga, el área del anillo es la misma antes y después de inflarlo:

$$\pi\,(R_o^2 - R_i^2) = \pi\,(r_o^2 - r_i^2) \qquad \Longrightarrow \qquad r = \sqrt{r_i^2 + R^2 - R_i^2} \quad \text{para cualquier radio } R \text{ de la pared.}$$

Tubo de ejemplo: sin presión de $R_i = 3{,}0$ a $R_o = 3{,}6\,\text{mm}$; con presión la cara interna llega a $r_i = 3{,}3\,\text{mm}$. Entonces $r = \sqrt{1{,}89 + R^2}$ (porque $3{,}3^2 - 3{,}0^2 = 1{,}89$) y $r_o = \sqrt{14{,}85} = 3{,}854\,\text{mm}$. La cara interna se estira $3{,}3/3{,}0 = 1{,}100$ y la externa $3{,}854/3{,}6 = 1{,}070$ (Fig. 9): **en pared gruesa no hay un solo estiramiento**.

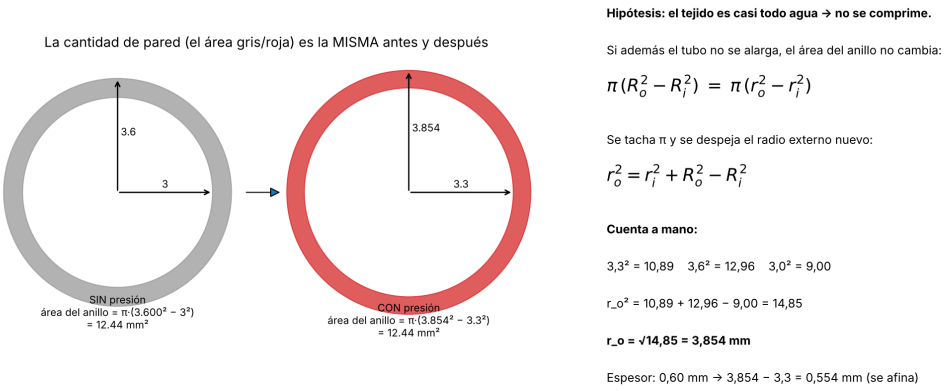
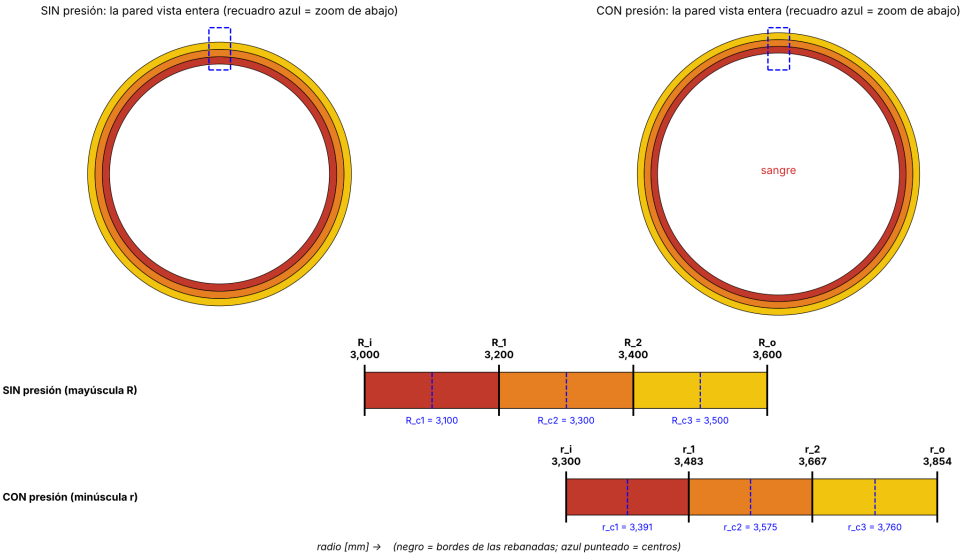


Figura 16: El área del anillo (gris sin presión, roja con presión) es la misma: $\pi(3{,}6^2 - 3{,}0^2) = \pi(3{,}854^2 - 3{,}3^2) = 12{,}44\,\text{mm}^2$.

B.3. La pared gruesa como pila de paredes delgadas

Se corta la pared en rebanadas finas. Cada rebanada es una pared delgada, con su propio estiramiento $\lambda = r_c/R_c$ (en su centro), y aporta $\sigma\,\Delta r/r_c$ (Laplace); la presión es la suma, que en el límite es la integral de la ec. (11).



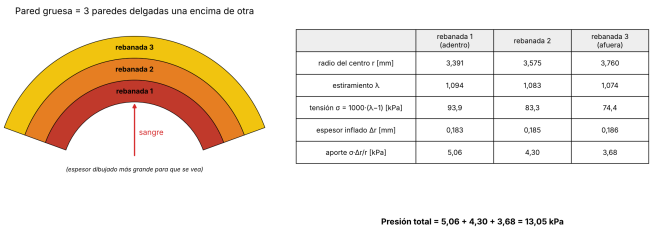
Nombre	Qué es	Sin presión R [mm]	Cuenta: r = √(3,3² + R² − 3,0²) = √(1,89 + R²)	Con presión r [mm]
R_i → r_i	cara interna (borde)	3,0	√(1,89 + 9,00) = √10,89	3,300
R_c1 → r_c1	centro de la rebanada 1	3,1	√(1,89 + 9,61) = √11,50	3,391
R_1 → r_1	borde entre rebanadas 1 y 2	3,2	√(1,89 + 10,24) = √12,13	3,483
R_c2 → r_c2	centro de la rebanada 2	3,3	√(1,89 + 10,89) = √12,78	3,575
R_2 → r_2	borde entre rebanadas 2 y 3	3,4	√(1,89 + 11,56) = √13,45	3,667
R_c3 → r_c3	centro de la rebanada 3	3,5	√(1,89 + 12,25) = √14,14	3,760
R_o → r_o	cara externa (borde)	3,6	√(1,89 + 12,96) = √14,85	3,854

Figura 17: El tubo de ejemplo en 3 rebanadas: bordes (negro) y centros (azul), sin presión (R) y con presión ($r = \sqrt{1{,}89 + R^2}$).

Con un material sin nudo, $\sigma = 1000\,(\lambda - 1)$ kPa:

	Rebanada 1 (adentro)	Rebanada 2	Rebanada 3 (afuera)
centro sin presión R_c [mm]	3,1	3,3	3,5
centro con presión $r_c = \sqrt{1{,}89 + R_c^2}$ [mm]	3,391	3,575	3,760
estiramiento $\lambda = r_c/R_c$	1,094	1,083	1,074
tensión σ [kPa]	93,9	83,3	74,4
espesor inflado Δr [mm]	0,183	0,185	0,186
aporte $\sigma\,\Delta r/r_c$ [kPa]	5,06	4,30	3,68

La presión total es $5{,}06 + 4{,}30 + 3{,}68 = 13{,}05$ kPa (con miles de rebanadas, 13,07). La rebanada de adentro aporta más porque se estira más.



	rebanada 1 (adentro)	rebanada 2	rebanada 3 (afuera)
radio del centro r [mm]	3,391	3,575	3,760
estiramiento λ	1,094	1,083	1,074
tensión σ = 1000·(λ−1) [kPa]	93,9	83,3	74,4
espesor inflado Δr [mm]	0,183	0,185	0,186
aporte σ·Δr/r [kPa]	5,06	4,30	3,68

Figura 18: Pared gruesa = tres paredes delgadas, una encima de otra.

B.4. En pared gruesa importa dónde va cada capa

Ahora la pared tiene dos materiales con nudo, $\sigma = E\,\text{máx}(0, \lambda - k)$: una capa azul ($k = 1{,}02$, $E = 400\,\text{kPa}$) de 3,0 a 3,3 mm y una verde ($k = 1{,}08$, $E = 1500\,\text{kPa}$) de 3,3 a 3,6 mm, cada una cortada en 3 franjas.

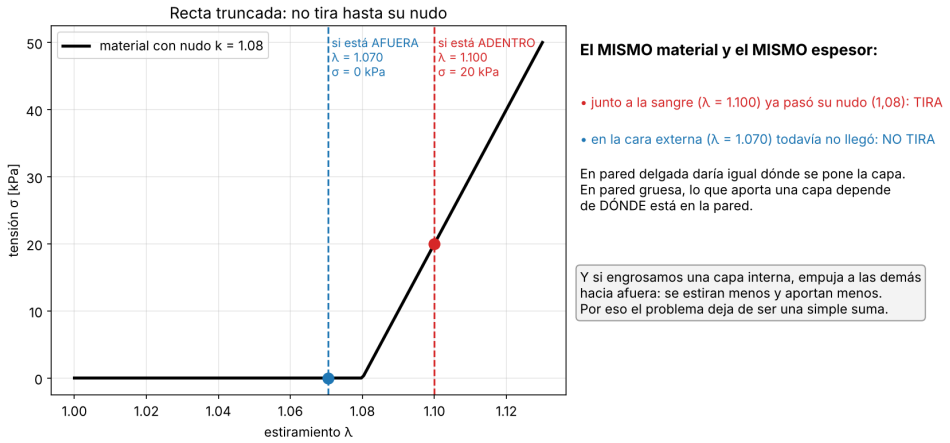


Figura 19: Un material con nudo 1,08 (en el dibujo, $E = 1000\,\text{kPa}$) tira si está junto a la sangre ($\lambda = 1{,}100$: $\sigma = 1000 \times 0{,}020 = 20\,\text{kPa}$) y no tira en la cara externa ($\lambda = 1{,}070 < 1{,}08$: $\sigma = 0$). El mismo material y el mismo espesor aportan distinto según dónde estén.

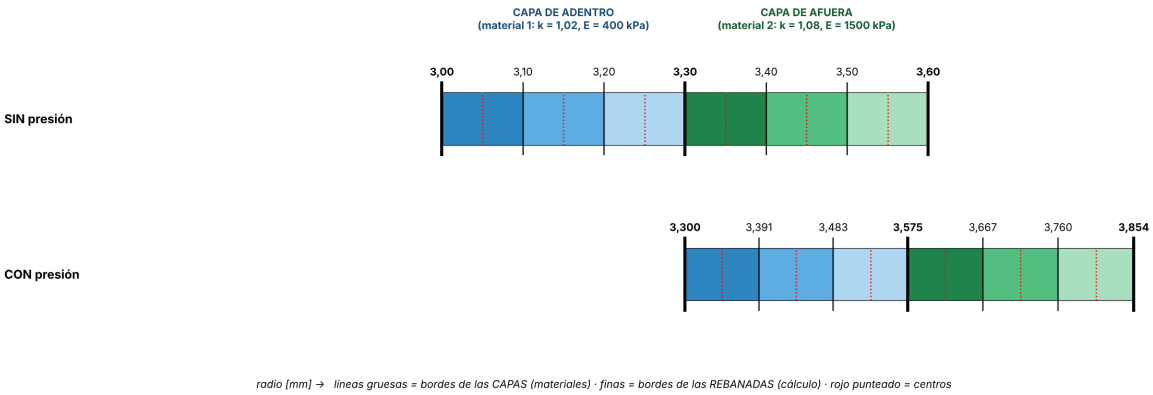


Figura 20: Dos capas de 0,3 mm, sin presión (arriba) y con presión (abajo). La capa azul aporta $0{,}84 + 0{,}76 + 0{,}69 = 2{,}28\,\text{kPa}$; de la verde solo tira la primera franja ($\lambda = 1{,}081$): 0,04 kPa.

Si se cambia solo el espesor de la capa azul, la verde —que no se tocó— cambia lo que aporta, porque queda empujada hacia afuera y se estira menos:

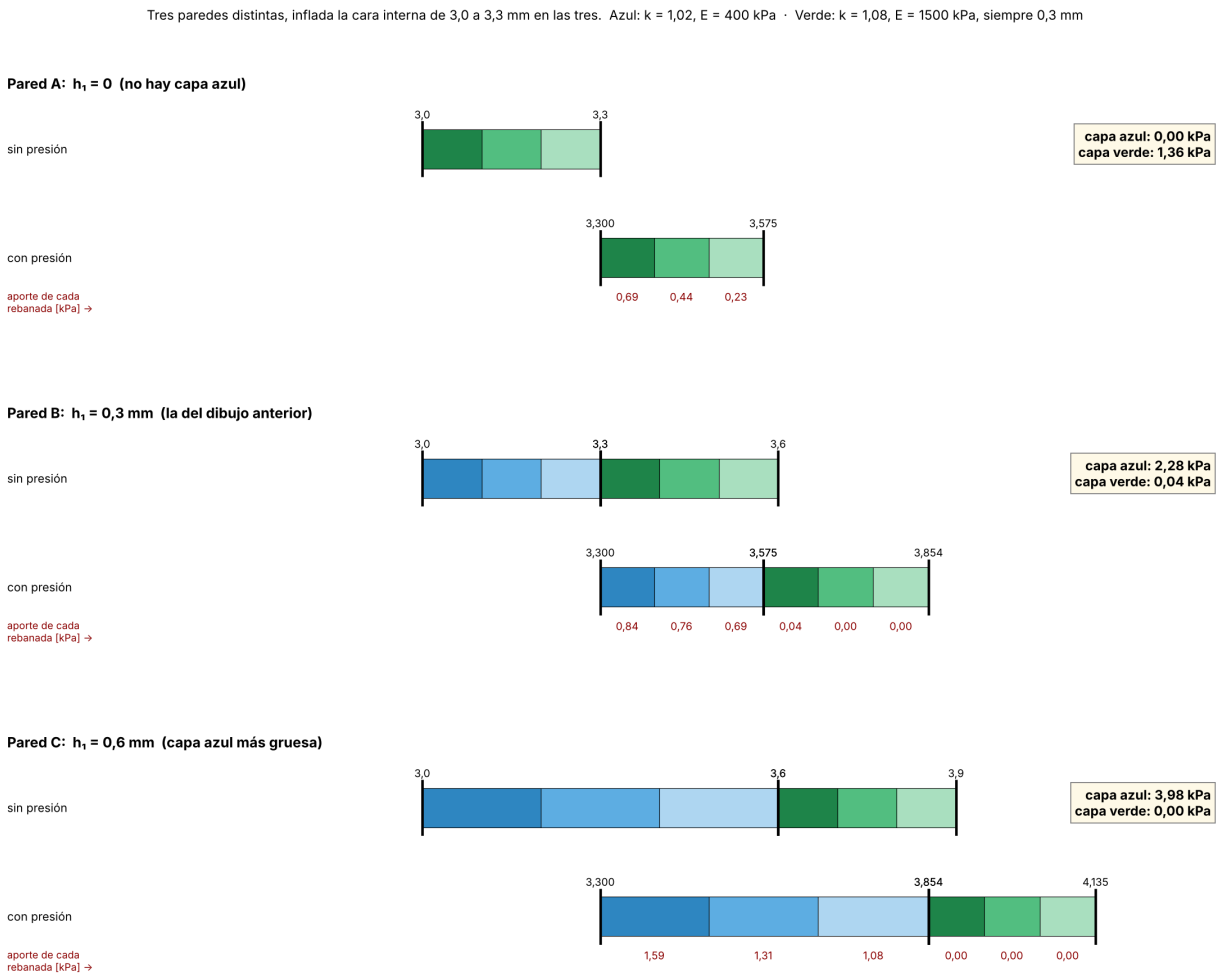


Figura 21: Tres paredes con la misma capa verde de 0,3 mm y la misma cara interna inflada a 3,3 mm. Sin capa azul la verde aporta 1,36 kPa; con 0,3 mm de azul, 0,04; con 0,6 mm, nada. Al duplicar la azul su aporte pasa de 2,28 a 3,98 kPa, que no es el doble: el problema es no lineal en los espesores.

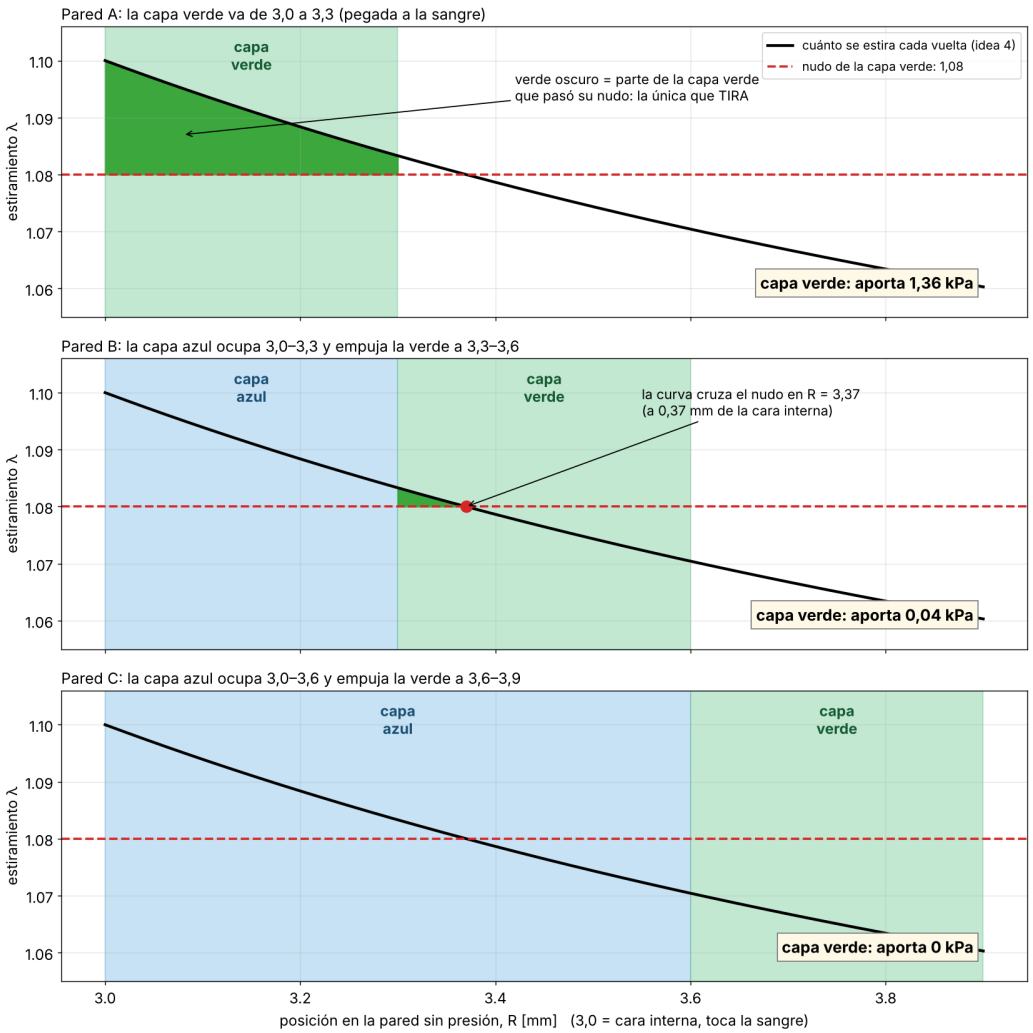


Figura 22: Las mismas tres paredes vistas como estiramiento de cada vuelta en función de su radio sin presión (curva negra) y nudo de la capa verde (línea roja). La capa verde solo aporta en la parte de ella que queda por encima de 1,08 (verde oscuro): en A toda su cara interna; en B, una astilla junto a $R = 3{,}37\,\text{mm}$; en C, nada.

B.5. El preestiramiento δ

δ corre todos los nudos juntos: el azul pasa a $1{,}02 + \delta$ y el verde a $1{,}08 + \delta$. Se repite la cuenta de la pared de dos capas (azul de 3,0 a 3,3, verde de 3,3 a 3,6 mm, cara interna inflada a 3,3 mm) con tres valores de δ. Los estiramientos de las franjas no cambian (dependen solo de la geometría); cambia desde dónde tira cada material.

		λ	σ [kPa]		
Capa	centro R [mm]		$\delta = -0{,}03$	$\delta = 0$	$\delta = +0{,}03$
azul, $\sigma = 400\,\text{máx}(0, \lambda - 1{,}02 - \delta)$	3,05	1,097	42,8	30,8	18,8
	3,15	1,091	40,4	28,4	16,4
	3,25	1,086	38,3	26,3	14,3
verde, $\sigma = 1500\,\text{máx}(0, \lambda - 1{,}08 - \delta)$	3,35	1,081	46,4	1,4	0
	3,45	1,076	39,7	0	0
	3,55	1,072	33,6	0	0
aporte de la capa azul [kPa]			3,24	2,28	1,32
aporte de la capa verde [kPa]			3,00	0,04	0
presión total [kPa]			6,25	2,33	1,32

Ejemplo de verificación: primera franja azul con $\delta = -0{,}03$: el nudo es $1{,}02 - 0{,}03 = 0{,}99$ y $\sigma = 400 \times (1{,}097 - 0{,}99) = 42{,}8\,\text{kPa}$; su aporte es $42{,}8 \times 0{,}091/3{,}346 = 1{,}16\,\text{kPa}$. Con $\delta = -0{,}03$ toda la capa verde pasa su nudo (1,05) y aporta tanto como la azul; con $\delta = +0{,}03$ el nudo verde sube a 1,11 y la capa verde no trabaja. Así, δ elige *qué materiales están activos* en el tramo de estiramiento de cada sujeto: un sujeto blando, que se estira mucho, necesita nudos más a la derecha ($\delta > 0$), y uno rígido, más a la izquierda ($\delta < 0$). Sin δ, cada sujeto vería solo uno o dos de los nudos de la base.

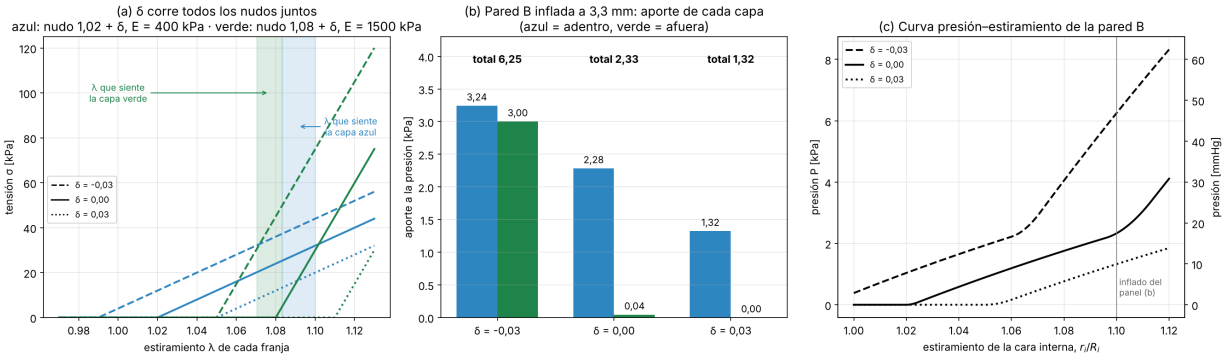


Figura 23: Efecto de δ en la pared de dos capas. (a) Ley de cada material para $\delta = -0{,}03$, 0 y $+0{,}03$; las franjas sombreadas son los estiramientos que siente cada capa con la cara interna en 3,3 mm. (b) Aporte de cada capa a la presión en ese estado. (c) Curva presión–estiramiento de la cara interna (eje derecho en mmHg): δ corre el punto donde engancha cada capa y cambia la forma de la curva. Los valores son de un ejemplo de juguete (capas de 0,3 mm y módulos bajos), no de un diseño.

C. Entrenamiento de las redes neuronales

Se entrenaron cuatro redes: la red en cadena del primer nivel, que va de la curva $\sigma_{\theta\theta}(\lambda_\theta)$ a las láminas enteras de cada material (Sección 3.5), y la de pared gruesa (bloque A4), cada una con 6 y con 5 materiales. La Fig. 24 muestra la pérdida en entrenamiento y en validación época por época, y la Tabla 11 resume el entrenamiento y la pérdida final en los tres conjuntos de datos. La pérdida de prueba se calcula sobre curvas que la red nunca vio, ni para ajustar los pesos ni para decidir cuándo parar.

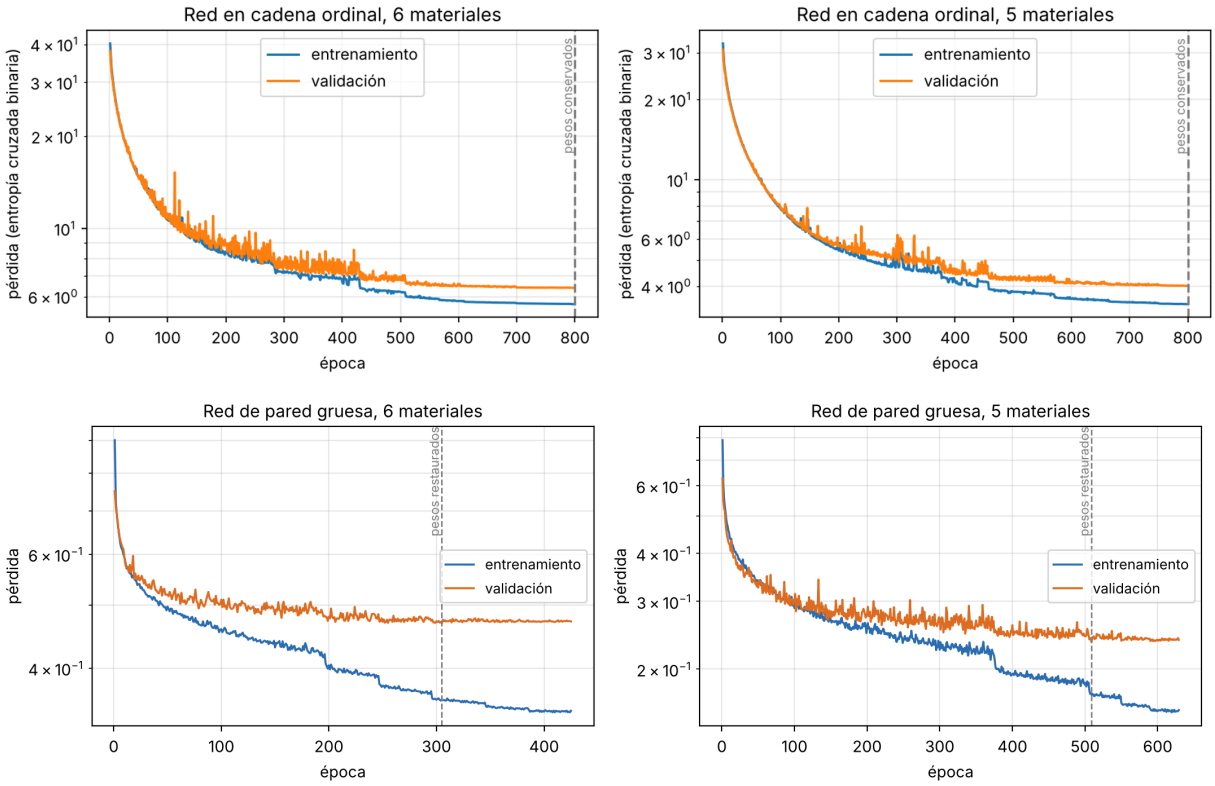


Figura 24: Curvas de aprendizaje: pérdida en entrenamiento (azul) y en validación (naranja) por época, en escala logarítmica. La línea de trazos marca la época cuyos pesos se conservan. La pérdida registrada durante el entrenamiento incluye el término de regularización L2. Arriba, la red en cadena del primer nivel (entropía cruzada binaria sumada sobre las 20 preguntas y los materiales); abajo, la red de pared gruesa (error cuadrático medio del diseño estandarizado).

Tabla 11: Resumen del entrenamiento. Épocas: total corridas y época cuyos pesos se conservan. Pérdida sin el término L2, calculada con los pesos conservados; la red en cadena usa la entropía cruzada binaria sumada sobre las preguntas y los materiales (en nats) y la de pared gruesa el error cuadrático medio del diseño estandarizado, por lo que los valores de las dos redes no se comparan entre sí. La última columna es la pérdida de prueba dividida por la de entrenamiento.

Red	Datos (entr./val./prueba)	Épocas	Reducc. de la tasa	Entr.	Val.	Prueba	Prueba/entr.
Red en cadena, 6 mat.	24 151 / 3451 / 6901	800 / 800	7	5,65	6,39	6,39	1,13
Red en cadena, 5 mat.	24 236 / 3463 / 6925	800 / 800	5	3,40	3,98	3,99	1,17
Pared gruesa, 6 mat.	11 220 / 1530 / 2250	425 / 305	5	0,342	0,462	0,484	1,42
Pared gruesa, 5 mat.	11 220 / 1530 / 2250	629 / 509	4	0,153	0,227	0,250	1,64

Red en cadena del primer nivel. Las dos redes llegaron al máximo de 800 épocas; en las últimas la pérdida de validación ya casi no baja, y se conservan los pesos finales. La pérdida de validación queda algo por encima de la de entrenamiento (cociente de 1,13 y 1,17), y la de prueba

queda igual a la de validación (6,39 y 3,99 contra 6,39 y 3,98): la red no se degrada con curvas nuevas. Que la pérdida no baje más tiene una razón propia del problema: varias combinaciones enteras reproducen casi igual la misma curva, y la etiqueta (el minimax de la curva con ruido) elige una sola. La red da exactamente las láminas del minimax en el 8,9 % de las curvas de prueba con 6 materiales y en el 21,7 % con 5, y a lo sumo a una lámina de él en cada material en el 30,2 y el 55,8 %; aun así, su diseño cumple la meta en 1998 y 2000 de las 2000 curvas del espacio de trabajo (Tabla 2). Por eso la red se juzga por el error en la curva, que es el criterio de diseño, y no por coincidir con el minimax.

Red de pared gruesa. Aquí la validación se separa del entrenamiento desde las primeras 50 épocas y se estabiliza, mientras el entrenamiento sigue bajando. La parada temprana conserva los pesos del mínimo de validación, y la pérdida de prueba queda cerca de la de validación (0,484 contra 0,462 y 0,250 contra 0,227): la red no se degrada con datos nuevos. La pérdida, sin embargo, es alta, y la razón está en el problema y no en la red: el problema inverso de pared gruesa (de la curva al diseño) está mal condicionado.

Condicionamiento. Para 60 arterias de las familias fisiológicas se calculó la matriz jacobiana $\mathbf{D}$ de la curva del injerto respecto del diseño $\theta = (h_1 \dots h_N, \delta)$, por diferencias finitas, con cada parámetro medido en desvíos estándar (la escala que usa la red) y la curva en % de su rango. Sus valores singulares dicen cuánto se mueve la curva al mover el diseño en cada dirección. Con 6 materiales, en la dirección más sensible la curva cambia un 850 % de su rango por desvío (8,5 veces el rango); en la menos sensible, apenas un 1 % (con 5 materiales: 750 % y 2,6 %). El número de condición $\kappa(\mathbf{D})$ tiene una mediana de 900 con 6 materiales y 300 con 5 (percentil 90: $2{,}4 \cdot 10^4$ y $1{,}5 \cdot 10^4$), contra $\mathrm{cond}(A) = 28$ en el primer nivel. La dirección menos sensible es, típicamente, más espesor de un material y menos de su vecino: cambia el diseño en un desvío estándar y la curva en 1 %, el mismo orden que el ruido de 0 a 1 % con que se entrena la red. Desde la curva, esos diseños son indistinguibles para cualquier método, y la red no puede adivinar cuál de ellos es la etiqueta. Esto explica la pérdida alta y que 5 materiales, mejor condicionado, tenga la mitad de pérdida que 6.

La medida que importa. Para el injerto, dos diseños cuyas curvas difieren en menos del 1 % son igual de buenos; el mal condicionamiento significa que hay muchos diseños aceptables, no que el diseño sea incierto. Por eso la red se juzga por el error en la curva, que es el criterio de diseño. Sobre 500 curvas de prueba, la curva del diseño que propone la red tiene un peor error mediano de 6,1 % del rango con 6 materiales y 4,3 % con 5: de 3 a 4 % en las arterias y de 11 a 12 % en los injertos de diseño sorteado, que cubren todo el espacio de diseños. Eso no alcanza para diseñar, y la red no se usa así: es el punto de partida del ajuste A2, que lleva el diseño a la meta (Sección 4).

D. Láminas y errores de cada curva

Láminas enteras de cada material y errores de la red en cadena, de la red en cadena con búsqueda de ±1 y del minimax, en los 41 sujetos de Masson y en las 63 curvas externas dentro de y_1–y_2, con 6 y con 5 materiales. Las láminas se listan del material 1 al N.

Tabla 12: Los 41 sujetos de Masson, 6 materiales: láminas enteras de cada material ($n_1 \dots n_6$) y errores contra la curva del sujeto, E_{rms} y $e_{\text{máx}}$ [% del rango]. Conj.: E, entrenamiento; P, prueba. En negrita, $e_{\text{máx}} > 3$ %.

Sujeto	Conj.	Red en cadena			Red en cadena + ±1			Minimax		
		láminas	E_{rms}	$e_{\text{máx}}$	láminas	E_{rms}	$e_{\text{máx}}$	láminas	E_{rms}	$e_{\text{máx}}$
NT01	E	5 7 5 6 6 7	0,66	1,11	5 7 5 6 6 7	0,66	1,11	5 7 5 6 7 5	0,72	1,11
NT02	P	9 3 2 5 3 4	0,54	1,55	9 3 2 5 3 4	0,54	1,55	9 3 3 3 4 5	0,66	1,31
NT03	E	9 4 0 3 1 2	1,11	1,96	9 4 0 3 1 2	1,11	1,96	9 4 0 3 2 0	1,21	1,96
NT04	E	11 2 0 0 2 0	1,41	2,34	11 2 0 0 2 0	1,41	2,34	11 2 0 0 2 0	1,41	2,34
NT05	E	11 5 5 3 3 3	0,55	1,53	11 5 5 2 4 3	0,62	1,53	11 6 1 5 4 1	0,94	1,45
NT06	E	7 6 6 4 4 4	0,48	1,51	7 6 6 4 4 4	0,48	1,51	7 7 3 5 4 4	0,89	1,41
NT07	E	10 8 2 4 2 3	0,49	1,34	10 8 2 4 2 2	0,52	1,34	10 8 2 3 4 1	0,55	1,34
NT08	P	5 3 2 1 2 1	0,81	2,82	5 3 2 2 1 1	0,74	1,61	5 3 2 2 1 1	0,74	1,61
NT09	E	8 8 5 6 6 6	0,41	1,04	8 8 5 7 5 6	0,49	0,92	8 8 5 7 5 6	0,49	0,92
NT10	P	13 12 13 15 15 13	0,57	0,97	13 12 13 15 15 12	0,56	0,97	13 12 13 15 15 12	0,56	0,97
NT11	P	13 12 16 17 16 17	0,61	1,33	12 13 16 17 16 16	0,41	1,02	12 13 16 18 15 16	0,47	1,02
NT12	E	7 6 5 5 5 4	0,40	1,69	7 6 6 4 5 5	0,47	0,96	7 6 6 4 5 5	0,47	0,96
NT13	E	8 7 5 6 4 5	0,77	1,44	8 7 5 5 5 5	0,81	1,44	8 7 5 5 7 1	0,87	1,44
NT14	E	7 6 3 4 4 3	0,62	1,47	7 6 3 4 4 3	0,62	1,47	7 6 3 4 4 3	0,62	1,47
NT15	E	4 6 5 4 4 4	0,56	1,38	4 6 5 4 4 4	0,56	1,38	4 6 5 4 4 5	0,61	1,38
NT16	E	2 13 16 12 15 13	0,43	1,02	2 13 16 12 16 12	0,46	0,94	2 13 15 14 14 13	0,38	0,89
HT01	E	5 9 5 7 7 6	0,46	0,79	5 9 5 7 7 6	0,46	0,79	5 9 5 7 7 6	0,46	0,79
HT02	E	11 7 3 5 3 5	0,50	1,38	11 7 3 5 3 4	0,52	1,38	11 7 3 4 6 1	0,60	1,40
HT03	P	4 9 7 6 7 6	0,36	0,95	4 9 7 6 7 7	0,39	0,84	4 9 7 6 7 7	0,39	0,84
HT04	E	8 3 1 2 1 2	0,86	2,16	8 3 2 1 1 2	0,75	1,59	8 3 2 1 1 2	0,75	1,59
HT05	P	14 10 14 10 9 11	0,47	1,31	14 10 13 11 10 10	0,47	1,17	13 12 10 11 12 7	0,42	1,09
HT06	E	13 12 17 15 15 15	0,46	1,22	13 12 18 14 16 14	0,49	0,78	13 12 18 14 16 14	0,49	0,78
HT07	E	13 11 10 10 9 10	0,41	1,18	13 11 11 9 10 9	0,45	0,81	13 11 11 9 10 8	0,43	0,70
HT08	E	10 11 16 14 12 15	0,45	1,37	10 11 16 14 13 14	0,44	1,00	10 11 17 12 16 10	0,51	1,00
HT09	E	20 11 11 12 11 11	0,67	1,08	20 11 10 13 11 10	0,56	0,99	20 10 14 10 12 12	0,38	0,91
HT10	E	2 10 5 6 6 7	0,54	1,23	2 10 5 6 7 6	0,58	1,11	2 10 5 6 7 5	0,54	0,97
HT11	E	7 5 0 4 2 3	0,87	2,30	7 5 0 4 2 3	0,87	2,30	7 5 1 2 3 3	1,11	2,30
HT12	E	8 6 5 4 2 4	0,47	1,18	8 6 5 4 3 3	0,55	1,09	8 6 5 4 3 3	0,55	1,09
HT13	P	16 4 7 4 6 5	0,51	1,59	16 4 7 4 7 4	0,45	1,22	16 4 7 4 7 4	0,45	1,22
HT14	P	8 6 5 5 4 5	0,43	0,95	8 6 5 5 4 5	0,43	0,95	8 6 5 5 4 5	0,43	0,95
HT15	E	10 10 8 9 7 7	0,39	0,79	10 10 8 9 7 7	0,39	0,79	10 10 8 9 7 7	0,39	0,79
HT16	E	6 16 12 15 15 14	0,47	0,82	6 16 12 15 15 14	0,47	0,82	6 16 12 15 15 14	0,47	0,82
HT17	E	11 14 16 15 16 14	0,40	0,99	11 14 16 16 15 14	0,42	0,79	11 14 16 16 15 15	0,43	0,79
HT18	E	10 5 5 4 5 3	0,38	1,26	10 5 5 4 5 4	0,42	1,05	10 5 5 4 5 4	0,42	1,05
HT19	P	9 6 5 5 4 3	0,39	1,22	9 6 5 5 4 4	0,42	0,97	9 6 6 3 5 4	0,39	0,94
HT20	E	3 10 8 7 8 6	0,41	1,01	3 10 8 7 8 6	0,41	1,01	3 10 8 7 8 7	0,44	1,01
HT21	E	11 5 6 3 4 4	0,51	1,25	11 5 6 3 4 4	0,51	1,25	11 5 5 5 3 4	0,59	1,25
HT22	E	13 10 8 6 6 4	0,34	1,02	13 10 8 6 6 5	0,33	0,97	13 10 9 5 6 5	0,37	0,97
HT23	E	8 6 11 9 9 10	0,58	1,28	8 6 11 9 9 10	0,58	1,28	7 8 8 9 10 9	0,42	0,97
HT24	P	13 8 10 8 8 8	0,36	1,12	13 8 10 8 8 7	0,35	1,12	13 9 7 9 9 6	0,70	1,07
HT25	E	5 16 19 18 19 19	0,51	1,28	6 15 19 19 18 19	0,37	0,88	6 15 19 19 19 17	0,40	0,82

Tabla 13: Los 41 sujetos de Masson, 5 materiales: láminas enteras de cada material ($n_1 \dots n_5$) y errores contra la curva del sujeto, E_{rms} y $e_{\text{máx}}$ [% del rango]. Conj.: E, entrenamiento; P, prueba. En negrita, $e_{\text{máx}} > 3$ %.

Sujeto	Conj.	Red en cadena			Red en cadena + ±1			Minimax		
		láminas	E_{rms}	$e_{\text{máx}}$	láminas	E_{rms}	$e_{\text{máx}}$	láminas	E_{rms}	$e_{\text{máx}}$
NT01	E	5 7 5 7 5	0,72	1,86	5 7 5 7 6	0,77	1,49	5 7 5 7 6	0,77	1,49
NT02	P	9 3 3 4 4	0,88	2,03	9 3 3 4 4	0,88	2,03	9 3 3 4 4	0,88	2,03
NT03	E	9 4 0 3 1	1,57	2,56	9 4 0 3 1	1,57	2,56	9 4 0 3 1	1,57	2,56
NT04	E	11 2 0 1 0	2,32	**3,50**	11 2 0 1 0	2,32	**3,50**	11 2 0 1 0	2,32	**3,50**
NT05	E	11 5 5 2 3	0,78	1,99	11 5 4 3 4	0,86	1,99	11 6 2 4 3	1,18	1,90
NT06	E	7 7 3 5 4	1,00	1,68	7 7 3 5 4	1,00	1,68	7 7 3 5 4	1,00	1,68
NT07	E	10 8 2 3 3	0,80	1,76	10 8 2 3 3	0,80	1,76	10 8 2 4 1	0,87	1,76

Sujeto	Conj.	Red en cadena			Red en cadena + ±1			Minimax		
		láminas	E_{rms}	$e_{\text{máx}}$	láminas	E_{rms}	$e_{\text{máx}}$	láminas	E_{rms}	$e_{\text{máx}}$
NT08	P	5 3 2 1 2	0,57	1,62	5 3 2 1 2	0,57	1,62	5 3 2 1 2	0,57	1,62
NT09	E	8 8 5 7 5	0,59	1,57	8 8 5 7 5	0,59	1,57	8 8 6 5 6	0,69	1,36
NT10	P	13 12 15 14 14	0,72	1,13	13 12 15 14 14	0,72	1,13	13 12 15 14 14	0,72	1,13
NT11	P	12 13 18 15 17	0,62	1,44	13 12 18 16 16	0,69	1,21	13 12 18 16 16	0,69	1,21
NT12	E	7 6 5 5 5	0,54	1,52	7 6 5 5 5	0,54	1,52	7 6 5 5 5	0,54	1,52
NT13	E	7 8 5 5 4	0,69	2,01	8 7 6 4 5	0,96	1,48	8 7 6 4 5	0,96	1,48
NT14	E	7 6 3 4 4	0,74	1,81	7 6 3 4 4	0,74	1,81	7 6 3 4 4	0,74	1,81
NT15	E	4 6 5 4 4	0,65	1,40	4 6 5 4 4	0,65	1,40	4 6 5 4 4	0,65	1,40
NT16	E	3 12 16 14 13	0,72	1,67	3 12 16 14 13	0,72	1,67	2 14 13 16 12	0,75	1,40
HT01	E	5 9 6 6 7	0,70	1,42	5 9 6 6 8	0,73	1,42	5 9 6 6 8	0,73	1,42
HT02	E	11 7 3 5 3	0,69	1,70	11 7 3 5 3	0,69	1,70	11 7 3 5 3	0,69	1,70
HT03	P	4 9 7 6 7	0,52	1,31	4 9 7 6 7	0,52	1,31	4 9 7 6 7	0,52	1,31
HT04	E	8 3 1 2 1	0,73	2,00	8 3 1 2 1	0,73	2,00	8 3 1 2 1	0,73	2,00
HT05	P	14 11 11 11 9	0,69	1,40	14 11 12 10 9	0,79	1,24	14 11 12 10 9	0,79	1,24
HT06	E	13 13 16 15 15	0,80	1,33	12 14 15 16 14	0,59	1,26	12 14 15 16 14	0,59	1,26
HT07	E	13 11 11 9 9	0,53	1,22	13 11 11 9 9	0,53	1,22	13 11 11 9 10	0,58	1,22
HT08	E	10 12 14 14 13	0,71	1,41	10 12 15 13 13	0,77	1,22	10 12 15 13 13	0,77	1,22
HT09	E	20 10 14 9 12	0,70	2,21	20 10 14 10 11	0,56	1,78	20 11 11 13 9	0,71	1,19
HT10	E	3 8 8 5 7	0,87	2,33	3 8 8 5 7	0,87	2,33	2 10 5 7 6	0,73	1,44
HT11	E	7 5 1 3 3	1,32	2,63	7 5 1 3 3	1,32	2,63	8 3 4 2 2	1,09	2,50
HT12	E	8 6 5 3 3	0,56	1,48	8 6 5 3 3	0,56	1,48	8 6 5 3 3	0,56	1,48
HT13	P	16 4 6 6 4	0,73	2,35	16 4 6 6 5	0,70	1,92	16 5 4 7 4	1,11	1,65
HT14	P	8 6 5 5 4	0,54	1,02	8 6 5 5 4	0,54	1,02	8 6 5 5 4	0,54	1,02
HT15	E	10 10 9 7 8	0,57	1,04	10 10 9 7 8	0,57	1,04	10 10 9 7 8	0,57	1,04
HT16	E	6 16 13 15 15	0,58	1,35	6 16 14 14 15	0,68	1,27	6 16 13 16 13	0,61	1,27
HT17	E	11 14 17 14 16	0,59	1,84	12 13 18 14 16	0,77	1,19	12 13 17 16 14	0,71	1,19
HT18	E	10 5 5 4 4	0,54	1,67	10 5 5 4 5	0,57	1,59	10 5 5 4 5	0,57	1,59
HT19	P	9 6 5 4 5	0,55	1,63	9 6 6 3 5	0,79	1,51	9 6 6 3 5	0,79	1,51
HT20	E	3 10 8 7 7	0,56	1,64	3 10 8 7 7	0,56	1,64	3 11 6 8 6	1,01	1,58
HT21	E	11 5 5 4 4	0,71	1,82	11 5 5 4 4	0,71	1,82	11 5 6 3 4	0,96	1,82
HT22	E	13 10 8 5 6	0,47	1,55	13 10 8 5 5	0,51	1,55	13 11 5 8 3	0,88	1,47
HT23	E	7 8 9 9 10	0,66	1,28	7 8 9 9 10	0,66	1,28	7 8 9 9 10	0,66	1,28
HT24	P	13 9 8 8 8	0,79	1,34	13 9 8 8 8	0,79	1,34	13 9 8 8 8	0,79	1,34
HT25	E	6 16 18 19 19	0,65	1,20	6 16 18 19 19	0,65	1,20	6 16 18 19 19	0,65	1,20

Tabla 14: Validación externa, 6 materiales: las 63 curvas de otros autores dentro de y_1–y_2. Láminas enteras de cada material y errores E_{rms} y $e_{\text{máx}}$ [% del rango]. En negrita, $e_{\text{máx}} > 3$ %.

Estudio · espécimen · curva	Red en cadena			Red en cadena + ±1			Minimax		
	láminas	E_{rms}	$e_{\text{máx}}$	láminas	E_{rms}	$e_{\text{máx}}$	láminas	E_{rms}	$e_{\text{máx}}$
Sommer · CCA pared · I l	10 6 3 2 0 1	0,46	1,17	10 6 3 2 0 2	0,39	0,97	10 6 3 2 0 2	0,39	0,97
Sommer · CCA pared · II l	11 5 8 2 2 2	0,70	2,12	11 5 7 3 2 2	0,80	2,12	11 6 4 4 2 2	0,94	1,68
Sommer · CCA pared · II r	13 4 7 6 5 3	0,72	1,39	13 4 7 6 4 4	0,77	1,39	13 4 7 7 3 5	0,83	1,39
Sommer · CCA pared · IV l	11 2 8 1 3 1	1,06	2,64	11 2 7 2 3 1	1,37	2,64	11 3 5 3 2 1	1,50	2,45
Sommer · CCA pared · V l	11 5 4 4 1 1	0,59	1,96	11 5 4 3 2 1	0,80	1,96	11 5 4 3 3 0	0,67	1,96
Sommer · CCA pared · V r	13 5 8 5 4 3	0,62	1,96	14 4 7 6 4 3	1,06	1,73	14 4 9 3 7 1	1,07	1,73
Sommer · CCA pared · VI l	10 3 6 3 3 2	0,59	1,98	10 3 6 3 3 2	0,59	1,98	10 4 3 4 4 0	1,21	1,93
Sommer · CCA pared · VI r	13 2 9 7 5 7	0,83	1,57	13 2 9 7 5 6	0,84	1,57	12 4 6 7 6 6	0,50	1,04
Sommer · CCA pared · VII r	11 1 7 4 6 2	0,74	1,70	11 1 6 5 6 3	0,74	1,56	11 1 7 4 5 4	0,60	1,32
Sommer · CCA pared · VIII r	11 2 8 2 4 2	0,80	1,84	11 2 8 2 4 1	0,82	1,84	11 2 8 2 5 0	0,95	1,84
Sommer · CCA pared · IX r	11 4 5 3 1 2	0,90	1,74	11 4 5 3 1 2	0,90	1,74	11 4 5 2 3 0	0,97	1,74
Sommer · CCA media-íntima · II l	17 9 6 6 8 6	0,48	0,99	17 9 6 7 7 6	0,55	0,92	17 9 6 7 6 8	0,51	0,86
Sommer · CCA media-íntima · IV l	17 6 9 7 4 4	0,56	1,52	17 6 9 6 5 4	0,73	1,52	17 7 7 6 7 1	0,79	1,29
Sommer · CCA media-íntima · V r	17 8 6 7 5 4	0,61	1,12	17 8 6 7 5 4	0,61	1,12	17 8 7 6 5 4	0,66	1,12
Sommer · CCA media-íntima · VI r	16 16 4 3 2 2	0,59	1,72	17 15 4 4 2 1	0,49	0,98	17 15 4 4 3 0	0,52	0,98
Sommer · ICA pared · III l	8 4 4 2 1 1	0,94	2,00	8 4 4 1 2 1	1,03	2,00	8 4 4 1 3 0	1,05	2,00
Sommer · ICA pared · IV l	11 5 5 5 3 3	1,05	1,56	11 5 4 6 3 2	0,84	1,51	11 5 4 7 1 3	0,95	1,51
Sommer · ICA pared · V r	11 2 9 1 4 1	1,29	2,57	11 2 9 1 4 2	1,21	2,33	10 4 6 2 4 1	0,77	1,63
Sommer · ICA pared · VI l	8 4 4 1 2 1	0,88	2,48	8 4 3 2 2 0	0,90	2,48	8 4 3 3 1 0	0,90	2,48
Sommer · ICA pared · VI r	12 5 4 4 1 2	0,65	1,20	12 5 4 4 1 2	0,65	1,20	12 5 4 4 2 0	0,64	1,20
Sommer · ICA pared · VII r	8 4 4 1 2 1	0,89	2,52	8 4 3 2 2 0	1,38	2,52	8 4 4 1 3 0	1,09	2,52
Sommer · ICA pared · VIII r	11 2 6 4 4 2	1,06	2,00	11 2 6 4 4 2	1,06	2,00	11 2 7 3 5 0	1,34	2,00
Sommer · ICA pared · IX r	9 3 4 3 1 2	1,46	2,35	9 3 3 3 2 2	1,52	2,35	9 3 3 5 0 2	1,59	2,35
Sommer · ICA pared · X r	10 2 7 2 2 2	1,27	2,43	10 2 6 3 2 1	1,36	2,43	9 4 3 4 1 2	0,89	1,76
Sommer · ICA pared · XI r	11 4 5 3 2 1	0,56	1,23	11 4 5 3 2 1	0,56	1,23	11 4 5 3 2 1	0,56	1,23
Sommer · ICA media-íntima · IX r	17 8 8 6 2 3	0,53	1,09	17 8 8 6 2 3	0,53	1,09	17 8 8 5 5 0	0,53	1,09
Sommer · ICA media-íntima · X r	14 5 7 5 3 4	0,57	1,04	14 5 7 5 3 3	0,59	1,04	14 5 7 5 4 2	0,59	1,04

Estudio · espécimen · curva	Red en cadena			Red en cadena + ±1			Minimax		
	láminas	E_{rms}	$e_{\text{máx}}$	láminas	E_{rms}	$e_{\text{máx}}$	láminas	E_{rms}	$e_{\text{máx}}$
Sommer · ICA media-íntima · XI r	14 5 9 3 3 1	0,73	1,52	14 5 8 4 2 2	0,61	1,52	14 5 9 3 3 0	0,72	1,52
Liu · carótida con placa · P2	13 2 3 1 0 1	1,02	2,57	13 2 3 0 1 1	1,37	2,57	13 2 4 0 0 1	1,45	2,57
Liu · carótida con placa · P4	18 2 0 1 0 0	1,03	1,65	18 2 0 1 0 0	1,03	1,65	18 2 0 1 0 0	1,03	1,65
Liu · carótida con placa · P5	11 0 3 0 0 0	2,84	**5,64**	11 0 2 0 0 1	4,04	**5,64**	11 1 0 0 1 0	2,37	**3,74**
Liu · carótida con placa · P6	13 2 0 0 1 0	2,19	**4,89**	13 2 0 0 0 0	1,66	**3,53**	13 2 0 0 0 0	1,66	**3,53**
Liu · carótida con placa · P7	12 1 0 0 0 0	2,12	**4,68**	12 1 0 0 1 0	1,61	**3,54**	12 1 0 0 1 0	1,61	**3,54**
Liu · carótida con placa · P8	12 4 2 0 1 0	1,84	2,77	12 5 1 0 0 0	1,87	2,50	12 5 0 0 1 0	1,17	1,94
Liu · carótida con placa · P9	15 6 1 0 0 0	1,22	**3,92**	15 6 1 0 1 0	0,60	1,34	15 6 1 1 0 0	0,72	1,34
Liu · carótida con placa · P10	16 5 0 1 0 0	1,01	1,97	16 5 0 1 0 0	1,01	1,97	16 5 0 1 0 0	1,01	1,97
Kamenskiy · CCA · pac. 1	15 11 2 1 0 0	0,87	2,92	15 11 2 1 1 0	0,39	0,97	15 11 2 1 1 0	0,39	0,97
Kamenskiy · ECA · pac. 1	9 2 5 3 2 1	0,77	1,55	9 2 5 3 2 1	0,77	1,55	9 2 6 1 3 1	0,99	1,55
Kamenskiy · ICA · pac. 1	14 6 3 3 1 0	0,53	1,04	14 6 3 3 1 0	0,53	1,04	14 6 4 1 2 1	0,66	1,04
Kamenskiy · CCA · pac. 4	9 5 0 2 0 0	0,79	2,33	9 5 0 1 1 0	1,21	2,33	9 5 1 0 1 0	0,94	2,33
Kamenskiy · CCA · pac. 5	13 3 1 0 0 0	1,28	2,57	13 3 1 0 0 0	1,28	2,57	13 3 1 0 0 0	1,28	2,57
Kamenskiy · ECA · pac. 5	8 4 3 0 1 0	1,93	**3,75**	8 4 3 0 0 1	2,16	**3,75**	8 5 1 0 1 0	0,96	1,57
Kamenskiy · CCA · pac. 6	7 3 0 3 0 1	2,09	**4,79**	7 3 0 2 1 0	2,10	**4,79**	8 1 3 2 1 0	1,38	2,57
Kamenskiy · ECA · pac. 6	8 3 0 1 1 1	1,93	**3,72**	8 3 0 1 1 0	2,04	**3,72**	9 1 3 1 1 0	1,73	**3,46**
Kamenskiy · ECA · pac. 7	12 1 2 1 1 0	1,51	2,43	12 1 3 0 1 0	0,89	1,74	12 1 3 0 1 0	0,89	1,74
Kamenskiy · ICA · pac. 7	13 3 4 0 1 0	1,82	**3,66**	14 2 4 0 1 1	1,81	**3,02**	13 4 1 1 1 0	0,81	2,12
Kamenskiy · CCA · pac. 8	13 0 6 1 0 2	1,85	**4,42**	13 0 5 1 1 1	2,31	**4,42**	13 1 2 3 1 0	1,08	1,97
Kamenskiy · ECA · pac. 8	15 2 2 1 0 1	1,02	2,47	15 2 3 0 1 0	0,66	1,15	15 2 3 0 1 0	0,66	1,15
Kamenskiy · ICA · pac. 8	14 2 4 2 0 2	1,09	1,97	14 2 4 2 0 1	1,04	1,80	14 2 4 1 2 0	0,94	1,80
Kamenskiy · ECA · pac. 9	9 4 3 0 1 0	2,03	**3,74**	10 3 3 0 1 0	1,85	**3,58**	9 5 0 1 1 0	0,87	2,38
Kamenskiy · ICA · pac. 9	17 1 4 1 0 2	0,98	2,13	17 1 4 1 0 2	0,98	2,13	17 1 4 1 0 2	0,98	2,13
Kamenskiy · ICA · pac. 10	10 3 2 0 0 0	2,26	**4,42**	10 3 2 0 0 0	2,26	**4,42**	10 4 0 0 0 0	1,33	1,79
Kamenskiy · ICA · pac. 11	12 1 2 0 0 0	3,72	**6,16**	12 1 1 0 0 0	4,59	**6,16**	12 2 0 0 0 0	2,98	**5,71**
Kamenskiy · CCA · pac. 12	9 2 3 0 1 0	0,70	2,17	9 2 3 0 1 0	0,70	2,17	9 2 3 0 1 0	0,70	2,17
Kamenskiy · ECA · pac. 12	12 4 3 0 1 0	2,34	**3,83**	13 3 3 1 0 0	1,21	2,13	13 3 3 1 0 0	1,21	2,13
Kamenskiy · ICA · pac. 12	14 2 3 0 0 0	2,83	**4,87**	14 3 2 0 0 0	1,85	2,78	14 3 1 0 1 0	0,87	1,34
Kamenskiy · ICA · pac. 13	13 2 2 1 0 1	0,88	2,25	13 2 2 1 0 1	0,88	2,25	13 2 2 1 1 0	1,05	2,25
Kamenskiy · CCA · pac. 14	12 1 2 1 1 0	1,44	2,45	12 1 3 0 1 0	0,75	2,17	12 1 3 0 1 0	0,75	2,17
Kamenskiy · ICA · pac. 14	11 1 2 0 1 0	2,50	**5,66**	12 0 2 1 1 0	1,62	2,92	12 0 2 1 1 0	1,62	2,92
Kamenskiy · CCA · pac. 15	13 0 0 0 0 0	4,64	**9,44**	13 0 0 1 0 0	2,37	**4,35**	13 0 0 1 0 0	2,37	**4,35**
Kamenskiy · CCA · pac. 16	13 0 5 2 1 1	1,32	**3,35**	13 0 4 3 0 2	1,89	**3,35**	13 1 2 2 2 1	1,43	2,28
Kamenskiy · ECA · pac. 16	10 2 3 1 1 0	1,01	1,91	10 2 3 1 1 0	1,01	1,91	10 2 3 1 1 0	1,01	1,91
Kamenskiy · ICA · pac. 16	13 4 1 0 0 0	1,36	2,26	13 4 1 0 0 0	1,36	2,26	13 4 1 0 0 0	1,36	2,26

Tabla 15: Validación externa, 5 materiales: las 63 curvas de otros autores dentro de y_1–y_2. Láminas enteras de cada material y errores E_{rms} y $e_{\text{máx}}$ [% del rango]. En negrita, $e_{\text{máx}} > 3$ %.

Estudio · espécimen · curva	Red en cadena			Red en cadena + ±1			Minimax		
	láminas	E_{rms}	$e_{\text{máx}}$	láminas	E_{rms}	$e_{\text{máx}}$	láminas	E_{rms}	$e_{\text{máx}}$
Sommer · CCA pared · I l	10 6 3 1 0	0,73	1,51	10 6 3 1 0	0,73	1,51	10 6 3 1 0	0,73	1,51
Sommer · CCA pared · II l	11 6 4 3 2	1,00	1,87	11 6 4 3 2	1,00	1,87	11 6 5 2 2	1,23	1,87
Sommer · CCA pared · II r	13 4 8 4 4	0,93	1,55	13 4 8 4 4	0,93	1,55	13 4 8 4 5	0,97	1,55
Sommer · CCA pared · IV l	11 3 5 2 2	1,55	2,63	11 3 4 3 2	1,46	2,63	11 3 5 2 1	1,57	2,63
Sommer · CCA pared · V l	11 5 4 3 0	0,76	2,11	11 5 4 3 0	0,76	2,11	11 5 5 1 2	1,01	2,11
Sommer · CCA pared · V r	13 5 8 3 4	0,93	2,27	14 4 8 4 3	1,03	1,85	14 4 8 4 4	0,99	1,85
Sommer · CCA pared · VI l	10 4 3 4 2	1,22	2,23	10 4 3 4 2	1,22	2,23	10 4 3 4 2	1,22	2,23
Sommer · CCA pared · VI r	12 4 7 6 6	0,72	1,33	12 4 7 6 6	0,72	1,33	12 4 7 6 6	0,72	1,33
Sommer · CCA pared · VII r	11 2 4 6 4	1,57	2,67	11 2 4 6 4	1,57	2,67	11 2 4 7 2	1,79	2,67
Sommer · CCA pared · VIII r	10 4 5 3 2	1,43	2,76	10 4 4 4 2	0,91	2,76	10 4 5 2 4	1,22	2,76
Sommer · CCA pared · IX r	11 4 5 2 1	1,13	1,87	11 4 5 1 2	1,11	1,87	11 4 5 1 2	1,11	1,87
Sommer · CCA media-íntima · II l	17 8 8 6 7	0,74	2,07	17 9 7 5 8	0,87	1,70	17 9 6 7 7	0,61	1,01
Sommer · CCA media-íntima · IV l	16 8 7 5 4	0,77	2,31	17 7 7 6 4	0,80	1,49	17 7 7 6 4	0,80	1,49
Sommer · CCA media-íntima · V r	17 8 7 5 5	0,73	1,26	17 8 7 5 5	0,73	1,26	17 8 7 5 5	0,73	1,26
Sommer · CCA media-íntima · VI r	17 14 5 2 2	0,94	1,92	17 15 4 2 2	0,79	1,20	17 15 3 3 2	0,72	1,20
Sommer · ICA pared · III l	8 5 1 3 0	1,79	2,79	8 5 1 2 1	1,78	2,79	8 4 4 1 0	1,30	2,54
Sommer · ICA pared · IV l	11 5 5 4 3	1,00	1,79	11 5 5 4 3	1,00	1,79	11 5 5 4 3	1,00	1,79
Sommer · ICA pared · V r	10 4 6 2 2	1,27	2,30	10 4 5 3 2	0,64	1,73	10 4 5 3 2	0,64	1,73
Sommer · ICA pared · VI l	8 4 3 2 0	0,91	2,69	8 4 3 2 0	0,91	2,69	8 4 4 0 2	1,35	2,69
Sommer · ICA pared · VI r	12 5 4 3 1	0,74	1,44	12 5 4 3 1	0,74	1,44	12 5 4 3 1	0,74	1,44
Sommer · ICA pared · VII r	8 5 1 3 0	2,22	**3,31**	8 5 1 2 1	2,06	**3,31**	9 3 3 3 0	1,68	2,69
Sommer · ICA pared · VIII r	10 4 4 4 3	1,77	2,53	10 4 3 5 2	1,48	2,53	11 2 7 2 4	1,33	2,14
Sommer · ICA pared · IX r	9 3 4 2 1	1,48	2,51	9 3 4 2 1	1,48	2,51	9 3 4 2 1	1,48	2,51
Sommer · ICA pared · X r	9 4 4 2 2	1,32	2,05	9 4 3 3 2	1,02	1,86	9 4 3 4 0	1,12	1,86
Sommer · ICA pared · XI r	11 4 5 2 1	0,76	1,44	11 4 5 2 1	0,76	1,44	11 4 5 2 1	0,76	1,44

Estudio · espécimen · curva	Red en cadena			Red en cadena + ±1			Minimax		
	láminas	E_{rms}	$e_{\mathrm{máx}}$	láminas	E_{rms}	$e_{\mathrm{máx}}$	láminas	E_{rms}	$e_{\mathrm{máx}}$
Sommer · ICA media-íntima · IX r	17 8 8 3 3	0,78	1,60	17 8 8 4 2	0,64	1,25	17 8 8 4 3	0,71	1,25
Sommer · ICA media-íntima · X r	14 5 7 4 3	0,70	1,31	14 5 7 4 3	0,70	1,31	14 5 7 4 3	0,70	1,31
Sommer · ICA media-íntima · XI r	14 5 7 3 2	1,19	2,87	14 6 6 2 3	1,35	2,30	14 6 5 4 2	1,20	2,30
Liu · carótida con placa · P2	12 3 2 0 1	2,11	**3,35**	13 2 2 1 0	1,51	2,68	13 2 2 1 0	1,51	2,68
Liu · carótida con placa · P4	18 2 0 0 1	1,65	2,45	18 2 0 0 1	1,65	2,45	18 2 0 0 1	1,65	2,45
Liu · carótida con placa · P5	11 1 0 0 1	2,83	**3,91**	11 1 0 0 1	2,83	**3,91**	11 1 0 0 1	2,83	**3,91**
Liu · carótida con placa · P6	13 2 0 0 0	2,68	**3,75**	13 2 0 0 0	2,68	**3,75**	13 2 0 0 0	2,68	**3,75**
Liu · carótida con placa · P7	12 1 0 0 0	1,67	**3,16**	12 1 0 0 0	1,67	**3,16**	12 1 0 0 0	1,67	**3,16**
Liu · carótida con placa · P8	12 4 2 0 0	1,28	2,84	12 4 2 0 0	1,28	2,84	12 5 0 0 1	1,78	2,45
Liu · carótida con placa · P9	15 6 0 1 0	0,80	1,44	15 6 0 1 0	0,80	1,44	15 6 0 1 0	0,80	1,44
Liu · carótida con placa · P10	16 5 0 0 1	1,51	2,17	16 5 0 0 1	1,51	2,17	16 5 0 0 1	1,51	2,17
Kamenskiy · CCA · pac. 1	15 11 1 1 1	0,51	1,52	15 11 1 1 0	0,60	1,52	15 11 1 1 1	0,51	1,52
Kamenskiy · ECA · pac. 1	9 3 3 3 1	2,78	**4,22**	9 2 4 3 1	1,87	**3,98**	9 2 6 0 3	1,42	2,63
Kamenskiy · ICA · pac. 1	14 6 3 2 0	0,72	1,33	14 6 3 2 0	0,72	1,33	14 6 3 2 0	0,72	1,33
Kamenskiy · CCA · pac. 4	9 5 0 1 0	1,24	2,72	9 5 0 1 0	1,24	2,72	9 5 0 1 1	1,18	2,72
Kamenskiy · CCA · pac. 5	13 3 0 1 0	1,52	**3,04**	13 3 0 1 0	1,52	**3,04**	13 3 0 1 0	1,52	**3,04**
Kamenskiy · ECA · pac. 5	8 5 0 1 0	1,11	1,90	8 5 0 1 0	1,11	1,90	8 5 0 1 0	1,11	1,90
Kamenskiy · CCA · pac. 6	7 3 1 1 1	2,90	**4,82**	7 2 2 2 0	2,86	**4,82**	8 1 3 1 1	1,56	2,69
Kamenskiy · ECA · pac. 6	8 3 0 2 0	2,78	**3,98**	8 3 0 1 1	2,46	**3,98**	9 1 3 0 1	1,91	**3,56**
Kamenskiy · ECA · pac. 7	12 1 3 0 0	2,21	**3,74**	12 1 2 1 0	1,39	2,40	12 1 2 1 0	1,39	2,40
Kamenskiy · ICA · pac. 7	13 4 1 1 0	1,06	2,29	13 4 1 1 0	1,06	2,29	13 4 1 1 0	1,06	2,29
Kamenskiy · CCA · pac. 8	13 1 3 1 1	1,64	2,46	13 1 2 2 1	1,17	2,19	13 1 2 2 1	1,17	2,19
Kamenskiy · ECA · pac. 8	15 2 2 0 1	0,73	1,92	15 2 2 0 1	0,73	1,92	15 2 2 0 1	0,73	1,92
Kamenskiy · ICA · pac. 8	13 4 1 1 2	1,97	**3,67**	13 4 0 2 1	2,37	**3,67**	14 2 3 2 0	1,20	2,01
Kamenskiy · ECA · pac. 9	9 5 0 1 0	1,25	2,78	9 5 0 1 0	1,25	2,78	9 5 0 1 0	1,25	2,78
Kamenskiy · ICA · pac. 9	17 1 4 0 1	1,38	2,88	17 1 3 1 1	1,24	2,88	17 1 4 0 0	1,35	2,88
Kamenskiy · ICA · pac. 10	10 3 1 0 0	2,54	**4,38**	10 3 1 0 0	2,54	**4,38**	10 3 1 0 0	2,54	**4,38**
Kamenskiy · ICA · pac. 11	12 1 1 0 0	3,55	**5,98**	12 1 1 0 0	3,55	**5,98**	12 1 1 0 0	3,55	**5,98**
Kamenskiy · CCA · pac. 12	9 2 3 0 0	2,22	**3,97**	9 2 2 1 0	1,37	2,97	9 2 2 1 0	1,37	2,97
Kamenskiy · ECA · pac. 12	12 5 0 1 0	1,24	**3,52**	13 4 0 1 1	2,15	**3,20**	13 3 3 0 0	1,14	2,77
Kamenskiy · ICA · pac. 12	14 3 1 0 1	1,59	**3,65**	14 3 1 0 0	1,38	1,78	14 3 1 0 0	1,38	1,78
Kamenskiy · ICA · pac. 13	13 2 2 0 1	0,81	2,23	13 2 2 0 1	0,81	2,23	13 2 2 0 1	0,81	2,23
Kamenskiy · CCA · pac. 14	12 1 2 0 1	1,82	**4,01**	12 1 2 1 0	1,25	2,86	12 1 2 1 0	1,25	2,86
Kamenskiy · ICA · pac. 14	11 2 0 0 2	4,15	**6,34**	11 1 1 1 1	2,76	**5,52**	12 0 2 1 0	2,09	**3,29**
Kamenskiy · CCA · pac. 15	13 0 0 0 0	3,74	**7,55**	13 0 0 1 0	2,59	**5,21**	13 0 0 1 0	2,59	**5,21**
Kamenskiy · CCA · pac. 16	13 1 2 2 2	1,62	2,76	13 1 2 2 1	1,66	2,76	13 1 2 2 1	1,66	2,76
Kamenskiy · ECA · pac. 16	9 4 0 2 0	2,73	**4,64**	9 4 0 1 0	2,53	**4,64**	10 2 3 0 1	1,26	2,03
Kamenskiy · ICA · pac. 16	13 4 0 1 0	1,33	2,72	13 4 0 1 0	1,33	2,72	13 4 0 1 0	1,33	2,72

Referencias

[1] Aarts, E., Lenstra, J. K. (eds.) (1997). *Local Search in Combinatorial Optimization*. Wiley.

[2] Abadi, M., et al. (2016). TensorFlow: a system for large-scale machine learning. *Proc. 12th USENIX OSDI*, 265–283. https://www.usenix.org/conference/osdi16/technical-sessions/presentation/abadi

[3] Agrell, E., Eriksson, T., Vardy, A., Zeger, K. (2002). Closest point search in lattices. *IEEE Trans. Inf. Theory* 48(8), 2201–2214. doi:10.1109/TIT.2002.800499

[4] Amos, B. (2023). Tutorial on amortized optimization. *Found. Trends Mach. Learn.* 16(5), 592–732. doi:10.1561/2200000102

[5] Ba, J. L., Kiros, J. R., Hinton, G. E. (2016). Layer normalization. arXiv:1607.06450. https://arxiv.org/abs/1607.06450

[6] Bengio, S., Vinyals, O., Jaitly, N., Shazeer, N. (2015). Scheduled sampling for sequence prediction with recurrent neural networks. *Advances in Neural Information Processing Systems* 28. https://arxiv.org/abs/1506.03099

[7] Bengio, Y., Courville, A., Vincent, P. (2013). Representation learning: a review and new perspectives. *IEEE Trans. Pattern Anal. Mach. Intell.* 35(8), 1798–1828. doi:10.1109/TPAMI.2013.50

[8] Bengio, Y., Lodi, A., Prouvost, A. (2021). Machine learning for combinatorial optimization: a methodological tour d'horizon. *Eur. J. Oper. Res.* 290, 405–421. doi:10.1016/j.ejor.2020.07.063

[9] Branch, M. A., Coleman, T. F., Li, Y. (1999). A subspace, interior, and conjugate gradient method for large-scale bound-constrained minimization problems. *SIAM J. Sci. Comput.* 21(1), 1–23. doi:10.1137/S1064827595289108

[10] Brent, R. P. (1973). *Algorithms for Minimization without Derivatives*. Prentice-Hall.

[11] Cao, W., Mirjalili, V., Raschka, S. (2020). Rank consistent ordinal regression for neural networks with application to age estimation. *Pattern Recognit. Lett.* doi:10.1016/j.patrec.2020.11.008

[12] Caruana, R. (1997). Multitask learning. *Machine Learning* 28, 41–75. doi:10.1023/A:1007379606734

[13] Cheney, E. W. (1966). *Introduction to Approximation Theory*. McGraw-Hill.

[14] Cybenko, G. (1989). Approximation by superpositions of a sigmoidal function. *Math. Control Signals Syst.* 2, 303–314. doi:10.1007/BF02551274

[15] Davis, P. J., Rabinowitz, P. (1984). *Methods of Numerical Integration*, 2.ª ed. Academic Press.

[16] Dembczyński, K., Cheng, W., Hüllermeier, E. (2010). Bayes optimal multilabel classification via probabilistic classifier chains. En *Proc. 27th Int. Conf. Machine Learning (ICML)*. https://mlanthology.org/icml/2010/dembczynski2010icml-bayes

[17] Ding, X., Sha, D., Sun, K., Fan, Y. (2025). Biomechanical insights into the development and optimization of small-diameter vascular grafts. *Acta Biomater.* doi:10.1016/j.actbio.2025.04.028.

[18] Engelen, L., Ferreira, I., Stehouwer, C. D. A., Boutouyrie, P., Laurent, S.; Reference Values for Arterial Measurements Collaboration (2013). Reference intervals for common carotid intima-media thickness measured with echotracking: relation with risk factors. *Eur. Heart J.* 34(30), 2368–2380. doi:10.1093/eurheartj/ehs380

[19] Frank, E., Hall, M. (2001). A simple approach to ordinal classification. En *Machine Learning: ECML 2001*, LNCS 2167. doi:10.1007/3-540-44795-4_13

[20] Fritsch, F. N., Carlson, R. E. (1980). Monotone piecewise cubic interpolation. *SIAM J. Numer. Anal.* 17(2), 238–246. doi:10.1137/0717021

[21] Fung, Y. C. (1993). *Biomechanics: Mechanical Properties of Living Tissues*, 2.ª ed. Springer.

[22] Furdella, K. J., Higuchi, S., Behrangzade, A., Kim, K., Wagner, W. R., Vande Geest, J. P. (2021). In-vivo assessment of a tissue engineered vascular graft computationally optimized for target vessel compliance. *Acta Biomater.* 123, 298–311. doi:10.1016/j.actbio.2020.12.058

[23] Golub, G. H., Van Loan, C. F. (2013). *Matrix Computations*, 4.ª ed. Johns Hopkins University Press.

[24] Goodfellow, I., Bengio, Y., Courville, A. (2016). *Deep Learning*. MIT Press.

[25] Harris, C. R., et al. (2020). Array programming with NumPy. *Nature* 585, 357–362. doi:10.1038/s41586-020-2649-2

[26] Harrison, S., Tamimi, E., Uhlorn, J., Leach, T., Vande Geest, J. P. (2016). Computationally optimizing the compliance of a biopolymer based tissue engineered vascular graft. *J. Biomech. Eng.* 138(1), 014505. doi:10.1115/1.4032060

[27] Holzapfel, G. A., Gasser, T. C., Ogden, R. W. (2000). A new constitutive framework for arterial wall mechanics and a comparative study of material models. *J. Elasticity* 61, 1–48. doi:10.1023/A:1010835316564

[28] Hornik, K. (1991). Approximation capabilities of multilayer feedforward networks. *Neural Networks* 4, 251–257. doi:10.1016/0893-6080(91)90009-T

[29] Hsu, R., Szafron, J. M., Carvalho, C. C., Humphrey, J. D., Marsden, A. L. (2025). Constrained optimization of scaffold behavior for improving tissue engineered vascular grafts. *J. Biomech.* doi:10.1016/j.jbiomech.2025.112670.

[30] Huangfu, Q., Hall, J. A. J. (2018). Parallelizing the dual revised simplex method. *Math. Program. Comput.* 10, 119–142. doi:10.1007/s12532-017-0130-5

[31] Humphrey, J. D. (2002). *Cardiovascular Solid Mechanics: Cells, Tissues, and Organs*. Springer.

[32] Jiang, D., Robinson, A. J., Nkansah, A., et al. (2025). A computational framework to optimize the mechanical behavior of synthetic vascular grafts. *J. Mech. Behav. Biomed. Mater.* 163, 106847. doi:10.1016/j.jmbbm.2024.106847

[33] Kingma, D. P., Ba, J. (2015). Adam: a method for stochastic optimization. *Proc. ICLR*. https://arxiv.org/abs/1412.6980

[34] Larochelle, H., Murray, I. (2011). The neural autoregressive distribution estimator. *Proc. 14th Int. Conf. Artificial Intelligence and Statistics (AISTATS)*, 29–37. https://proceedings.mlr.press/v15/larochelle11a.html

[35] Lawson, C. L., Hanson, R. J. (1995). *Solving Least Squares Problems*. SIAM.

[36] Kamenskiy, A. V., Dzenis, Y. A., MacTaggart, J. N., Lynch, T. G., Jaffar Kazmi, S. A., Pipinos, I. I. (2012). Nonlinear mechanical behavior of the human common, external, and internal carotid arteries in vivo. *J. Surg. Res.* 176(1), 329–336. doi:10.1016/j.jss.2011.09.058

[37] Leshno, M., Lin, V. Ya., Pinkus, A., Schocken, S. (1993). Multilayer feedforward networks with a nonpolynomial activation function can approximate any function. *Neural Networks* 6, 861–867. doi:10.1016/S0893-6080(05)80131-5

[38] Li, L., Lin, H.-T. (2007). Ordinal regression by extended binary classification. *Advances in Neural Information Processing Systems* 19. https://proceedings.neurips.cc/paper/2006/hash/019f8b946a256d9357eadc5ace2c8678-Abstract.html

[39] Liu, H., et al. (2012). Using in vivo Cine and 3D multi-contrast MRI to determine human atherosclerotic carotid artery material properties and circumferential shrinkage rate and their impact on stress/strain predictions. *J. Biomech. Eng.* 134, 011008. doi:10.1115/1.4005685

[40] Ma, T., Ma, M., Guo, L. J. (2025). Optical multilayer thin film structure inverse design: from optimization to deep learning. *iScience* 28, 112222. doi:10.1016/j.isci.2025.112222

[41] Ma, T., Wang, H., Guo, L. J. (2024). OptoGPT: a foundation model for inverse design in optical multilayer thin film structures. *Opto-Electron. Adv.* 7, 240062. doi:10.29026/oea.2024.240062

[42] Masson, I., Beaussier, H., Boutouyrie, P., Laurent, S., Humphrey, J. D., Zidi, M. (2011). Carotid artery mechanical properties and stresses quantified using in vivo data from normotensive and hypertensive humans. *Biomech. Model. Mechanobiol.* 10(6), 867–882. doi:10.1007/s10237-010-0279-6

[43] Nair, V., Bartunov, S., Gimeno, F., et al. (2020). Solving mixed integer programs using neural networks. arXiv:2012.13349. https://arxiv.org/abs/2012.13349

[44] Nair, V., Hinton, G. E. (2010). Rectified linear units improve restricted Boltzmann machines. *Proc. ICML*. https://mlanthology.org/icml/2010/nair2010icml-rectified

[45] Nam, J., Loza Mencía, E., Kim, H. J., Fürnkranz, J. (2017). Maximizing subset accuracy with recurrent neural networks in multi-label classification. En *Advances in Neural Information Processing Systems* 30. https://papers.nips.cc/paper/2017/hash/2eb5657d37f474e4c4cf01e4882b8962-Abstract.html

[46] Nelder, J. A., Mead, R. (1965). A simplex method for function minimization. *Computer J.* 7(4), 308–313. doi:10.1093/comjnl/7.4.308

[47] Penrose, R. (1955). A generalized inverse for matrices. *Math. Proc. Cambridge Philos. Soc.* 51(3), 406–413. doi:10.1017/S0305004100030401

[48] Prechelt, L. (1998). Early stopping — but when? En *Neural Networks: Tricks of the Trade*, LNCS 1524, 55–69. doi:10.1007/3-540-49430-8_3

[49] Rachev, A., Hayashi, K. (1999). Theoretical study of the effects of vascular smooth muscle contraction on strain and stress distributions in arteries. *Ann. Biomed. Eng.* 27, 459–468. doi:10.1114/1.191

[50] Read, J., Pfahringer, B., Holmes, G., Frank, E. (2011). Classifier chains for multi-label classification. *Machine Learning* 85, 333–359. doi:10.1007/s10994-011-5256-5

[51] Read, J., Pfahringer, B., Holmes, G., Frank, E. (2021). Classifier chains: a review and perspectives. *J. Artif. Intell. Res.* 70, 683–718. doi:10.1613/jair.1.12376

[52] Rockafellar, R. T., Uryasev, S. (2000). Optimization of conditional value-at-risk. *J. Risk* 2(3), 21–41. doi:10.21314/JOR.2000.038

[53] Rovas, G., Bikia, V., Stergiopulos, N. (2023). Design and computational optimization of compliance-matching aortic grafts. *Front. Bioeng. Biotechnol.* 11, 1179174. doi:10.3389/fbioe.2023.1179174

[54] Rovas, G., Reymond, P., van Steenberghe, M., et al., Stergiopulos, N. (2025). Evaluation of a novel compliance-matching aortic graft in a swine model. *J. Biomech.* doi:10.1016/j.jbiomech.2025.112629.

[55] Sommer, G., Regitnig, P., Költringer, L., Holzapfel, G. A. (2010). Biaxial mechanical properties of intact and layer-dissected human carotid arteries at physiological and supraphysiological loadings. *Am. J. Physiol. Heart Circ. Physiol.* 298, H898–H912. doi:10.1152/ajpheart.00378.2009

[56] Sommer, G., Holzapfel, G. A. (2012). 3D constitutive modeling of the biaxial mechanical response of intact and layer-dissected human carotid arteries. *J. Mech. Behav. Biomed. Mater.* 5, 116–128. https://www.sciencedirect.com/science/article/pii/S1751616111002177

[57] Storn, R., Price, K. (1997). Differential evolution: a simple and efficient heuristic for global optimization over continuous spaces. *J. Global Optim.* 11, 341–359. doi:10.1023/A:1008202821328

[58] Szafron, J. M., Ramachandra, A. B., Breuer, C. K., Marsden, A. L., Humphrey, J. D. (2019). Optimization of tissue-engineered vascular graft design using computational modeling. *Tissue Eng. Part C.* doi:10.1089/ten.tec.2019.0086.

[59] Tamimi, E. A., Ardila, D. C., Ensley, B. D., Kellar, R. S., Vande Geest, J. P. (2019). Computationally optimizing the compliance of multilayered biomimetic tissue engineered vascular grafts. *J. Biomech. Eng.* doi:10.1115/1.4042902.

[60] Trefethen, L. N., Bau, D. (1997). *Numerical Linear Algebra.* SIAM.

[61] Urquiza, S. A. (2009). *Hemodinámica computacional del sistema arterial humano.* Tesis doctoral en Ciencias de la Ingeniería, Instituto Balseiro, Universidad Nacional de Cuyo, San Carlos de Bariloche. Cap. 3: Modelos hemodinámicos unidimensionales, ec. (3.13).

[62] Virtanen, P., et al. (2020). SciPy 1.0: fundamental algorithms for scientific computing in Python. *Nat. Methods* 17, 261–272. doi:10.1038/s41592-019-0686-2

[63] Williams, R. J., Zipser, D. (1989). A learning algorithm for continually running fully recurrent neural networks. *Neural Comput.* 1(2), 270–280. doi:10.1162/neco.1989.1.2.270