

Fundamentación Teórica: Aproximación con Red Neuronal y Optimización Convexa KKT

Justificación del Abordaje Frente al Método de Mínimos Cuadrados Puros (MCO)

Documento Técnico de Discusión para la Dirección del Trabajo

Resumen Ejecutivo

Este documento sintetiza la fundamentación teórica que justifica la transición desde el método de **Mínimos Cuadrados Ordinarios (MCO) discretos** hacia un esquema de **Red Neuronal con Optimización Convexa y Restricciones KKT** para la predicción de Curvas J. Se exponen las limitaciones numéricas del MCO clásico, la garantía de mínimo global por convexidad, y el rol del algoritmo de Lagrange (**trust-constr**) bajo las condiciones de Karush-Kuhn-Tucker.

1. Planteo del Problema y Modelo de Aproximación

La representación de la Curva J objetivo se formula mediante una combinación lineal de $N + 1 = 5$ funciones base $g_i(x)$:

$$\hat{y}(x) = c_0 g_0(x) + c_1 g_1(x) + c_2 g_2(x) + c_3 g_3(x) + c_4 g_4(x) = \sum_{i=0}^4 c_i g_i(x) \quad (1)$$

donde $g_0(x) = 1$ representa el nivel inicial, $g_1(x) = x - x_0$ la pendiente base, y $g_k(x) = \max(0, x - x_k)$ ($k = 2, 3, 4$) son funciones bisagra o rampas con nodos de quiebre (*knots*) en x_k .

2. Limitaciones del Método de Mínimos Cuadrados Puros (MCO)

El método MCO libre minimiza la función de error cuadrático $E(c) = \|y - Ac\|^2$ mediante la resolución de la **Ecuación Normal**:

$$A^T A c = A^T y \implies c = (A^T A)^{-1} A^T y \quad (2)$$

A pesar de su simplicidad analítica, presenta tres serias restricciones teóricas y numéricas:

1. Incapacidad de Imponer Restricciones de Dominio ($0 \leq c_i \leq 20$):

La solución analítica no puede garantizar que los coeficientes permanezcan acotados. Para exponenciales de alta curvatura (p. ej., $\alpha = 3.20$), MCO asigna un peso sin acotar de $c_4 = 23.7054$, violando los límites físicos del modelo.

2. Dependencia Lineal por Rampas Paralelas ($m = 1$):

En el MCO discreto estándar, todas las funciones bisagra comparten la misma pendiente unitaria. En el tramo final del dominio ($x \geq x_3$), las columnas de la matriz de diseño A se convierten en combinaciones lineales paralelas entre sí, introduciendo colinealidad.

3. Degradación del Condicionamiento y Deformación de la Hessiana:

La colinealidad eleva el número de condición de la matriz a $\text{cond}(A) = 84.14$ (zona de colinealidad moderada-fuerte según Belsley, Kuh & Welsch, 1980). Dado que la matriz Hessiana del error es $\nabla^2 E = 2A^T A$, su condicionamiento se eleva al cuadrado:

$$\text{cond}(\nabla^2 E) = \text{cond}(A^T A) = \text{cond}(A)^2 \approx (84.14)^2 \approx 7079.57 \quad (3)$$

Esto transforma la superficie de costo de la Red Neuronal en un valle híper-estrecho y alargado, provocando oscilaciones violentas en los optimizadores por gradiente e inutilizando el entrenamiento.

3. Abordaje Propuesto: Optimización Convexa con Red Neuronal

Para resolver las deficiencias de MCO, el modelo implementado introduce dos pilares teóricos:

3.1. Optimización de Knots y Pendientes ($\text{cond}(A) < 30$)

Al optimizar de forma desacoplada tanto la ubicación de los *knots* como las pendientes m_k de cada rampa, se elimina el paralelismo en el tramo final. Esto eleva el valor singular mínimo $\sigma_{\min}$, reduciendo el número de condición a la zona verde de estabilidad ($\text{cond}(A) < 30$), garantizando una Hessiana bien condicionada ($\text{cond}(A^T A) < 900$).

3.2. Garantía de Mínimo Global Único por Convexidad

El entrenamiento de la red bajo este esquema constituye un **Programa Cuadrático Convexo**:

- **Función Objetivo Convexa:** La Hessiana $\nabla^2 E = 2A^T A$ es definida positiva (al ser $\text{rango}(A) = 5$).
- **Conjunto Factible Convexo:** El espacio de restricciones $0 \leq c_i \leq 20$ es un hipercubo cerrado (conjunto convexo).

Por el *Teorema Fundamental de Optimización Convexa*, **no existen mínimos locales espurios**. Cualquier mínimo local hallado es estrictamente el **mínimo global único**.

4. Condiciones Karush-Kuhn-Tucker (KKT) y Solver trust-constr

Al incorporar restricciones de caja $0 \leq c_i \leq 20$, la ecuación normal deja de aplicar y se requiere el marco dual de Karush-Kuhn-Tucker (KKT). Formulando el Lagrangiano:

$$\mathcal{L}(c, \lambda) = E(c) + \sum_{i=0}^4 \lambda_{i,\text{sup}}(c_i - 20) + \sum_{i=0}^4 \lambda_{i,\text{inf}}(-c_i) \quad (4)$$

El solver **trust-constr** (basado en el Método de los Multiplicadores de Lagrange) resuelve el sistema satisfaciendo las cuatro condiciones KKT:

Condición KKT	Expresión Matemática	Significado Físico / Intuitivo
1. Estacionariedad	$\nabla E(c^*) + \sum \lambda_i^* \nabla g_i(c^*) = 0$	Equilibrio de fuerzas entre el gradiente del error y las restricciones.
2. Factibilidad Primal	$0 \leq c_i^* \leq 20$	Los coeficientes respetan estrictamente los límites de caja.
3. Factibilidad Dual	$\lambda_i^* \geq 0$	Los multiplicadores de Lagrange son no negativos.
4. Holgura Complementaria	$\lambda_i^* \cdot g_i(c^*) = 0$	Regla del interruptor: $\lambda_i = 0$ si el peso está holgado; $\lambda_i > 0$ si el peso se satura en la frontera.

4.1. Interpretación Teórica de la Holgura Complementaria (λ_i)

- **Coefficiente Holgado** ($0 < c_i < 20 \implies \lambda_i = 0$): La base aporta libremente sin interferencia de la frontera.
- **Coefficiente Saturado** ($c_4 = 20.0000 \implies \lambda_4 > 0$): En curvas de alta curvatura ($\alpha = 3.20$), la restricción se vuelve activa. El multiplicador $\lambda_4 > 0$ ejerce la fuerza exacta para anular el gradiente excedente que intentaba llevar a c_4 a 23.70, fijándolo en 20.0000 con absoluta estabilidad numérica.

5. Cuadro Comparativo Resumen para Discusión

Método / Criterio	Restricciones ($0 \leq c_i \leq 20$)	$\text{cond}(A)$	Garantía KKT	Apto para Red Neuronal
MCO Discreto Puro	No admite	84.14 (Inestable)	No	No (Gradiente oscila)
Red Neuronal + trust-constr	Sí (Estricto)	< 30 (Zona Verde)	Sí (Mínimo Global)	Sí ($R^2 = 0.9984$)

6. Conclusión

El paso hacia el enfoque con Red Neuronal y el solver **trust-constr** no fue una preferencia arbitraria, sino una **necesidad de álgebra lineal y optimización numérica**: desarmó la colinealidad de las rampas MCO ($\text{cond}(A) < 30$), garantizó la existencia de un mínimo global único mediante convexidad estricta, e introdujo estabilidad en la frontera mediante las condiciones duales KKT y los multiplicadores de Lagrange.