Del número real al número entero de láminas: métodos de redondeo

Pablo

24 de octubre de 2026

Resumen

El método de diseño da el número de láminas de cada material como un número real; un injerto se fabrica con números enteros. Se comparan tres maneras de pasar de uno a otro: redondeo simple, redondeo conjunto (mínimos cuadrados enteros) y redondeo minimax (programación lineal entera). Todas las aproximaciones se miden contra la curva original con dos números: el error cuadrático medio E_{rms} y el error en el peor punto $e_{\text{máx}}$. Cada redondeo es el mejor en su propia medida: el conjunto minimiza E_{rms} y el minimax minimiza $e_{\text{máx}}$, que es la medida del criterio de diseño.

Índice

1. Definiciones **2**

2. Las aproximaciones **2**

3. Redondeo conjunto: MCO con enteros **3**
3.1. Por qué no alcanza con redondear cada número 3
3.2. Método 1: ventana de ±3 3
3.3. Método 2: Schnorr–Euchner 4

4. Redondeo minimax: programación lineal entera **5**

5. Resultados con $C_{LAM} = 20$ **6**
5.1. Tres curvas 6
5.2. Los 41 sujetos 8
5.3. Espacio de trabajo 9

6. Conclusiones **9**

A. Fórmulas y definiciones de los métodos de redondeo **10**
A.1. Piso y techo 10
A.2. Ventana de ±3 10
A.3. Búsqueda exacta en árbol 11
A.4. Descomposición de Cholesky 11
A.5. Aproximación de Chebyshev (minimax) 11
A.6. HiGHS 12

B. La ley de Masson y los datos de partida **12**

C. Glosario de métodos y términos **17**

1. Definiciones

- **Curva objetivo** y: presión de la arteria en función del estiramiento circunferencial $\lambda \in [1{,}02;\ 1{,}16]$, en 999 puntos $\lambda_1, \ldots, \lambda_{999}$. Rango: $\Delta y = \max y - \min y$.
- **Lámina** del material j: aporta $A_j(\lambda) = S_j \max(0, \lambda - k_j)$, con nudo k_j y pendiente S_j.
- **Base** $A \in \mathbb{R}^{999\times N}$: una columna por material ($N = 5$ o 6).
- **Diseño**: láminas de cada material; $c \in \mathbb{R}^N$ si es real, $z \in \mathbb{Z}^N_{\geq 0}$ si es entero. Curva del injerto: Az.
- **Errores** contra la curva original, en % de Δy:

$$E_{\text{rms}}(z) = \frac{100}{\Delta y}\sqrt{\frac{1}{999}\sum_i \left(y_i - (Az)_i\right)^2}, \qquad e_{\text{máx}}(z) = \frac{100}{\Delta y}\max_i |y_i - (Az)_i|.$$

  E_{rms} es el apartamiento típico; $e_{\text{máx}}$, el peor punto. Siempre $E_{\text{rms}} \leq e_{\text{máx}}$.
- **Criterios** (en $e_{\text{máx}}$): método, con láminas reales, ≤ 3 %; injerto fabricable, con láminas enteras, ≤ 4 %.
- **Escala** C_{LAM}: $S_j = \texttt{PEND_MAX}_j / C_{LAM}$, de modo que $0 \leq c_j \leq C_{LAM}$ en toda la franja. Se adopta $C_{LAM} = 20$.

La escala no cambia la curva. Pasar de C a C' divide cada pendiente por C'/C y multiplica cada coeficiente por C'/C: el producto $c_j S_j$, y por lo tanto la curva, no cambia. Es una identidad exacta. Con láminas enteras sí cambia: los saltos de una lámina se achican y el redondeo mejora.

Curvas usadas. Las de 41 carótidas humanas (16 normotensas y 25 hipertensas), calculadas con la *ley de Masson*: la ley constitutiva de la pared que Masson et al. [1] ajustaron a mediciones in vivo de cada sujeto, con aportes de la elastina, de cuatro familias de fibras de colágeno [2] y del tono muscular [3] (ecuaciones, tablas y validación en el Anexo B). Además, tres curvas de ejemplo (y_2, la más rígida; Mean HT, media de los 25 hipertensos; y_1, la más blanda), y las 22 500 curvas del espacio de trabajo, entre y_1 e y_2.

Tabla 1: Bases. S_j con $C_{LAM} = 20$.

	5 materiales		6 materiales	
j	k_j	S_j [kPa]	k_j	S_j [kPa]
1	0,8291	1,92	0,8271	1,90
2	1,0231	9,32	1,0219	9,07
3	1,0942	12,06	1,0867	9,08
4	1,1273	24,78	1,1197	19,60
5	1,1472	40,72	1,1391	28,24
6	–	–	1,1531	40,28

2. Las aproximaciones

Aproximación	Qué da	Referencia
MCO (reales)	el diseño real de menor E_{rms}: $c_{MCO} = A^+ y$	[4, 5]
Red neuronal (reales)	aproxima c_{MCO} en una sola evaluación	informe de la red
Redondeo simple	cada coeficiente de la red al entero más cercano	–
Redondeo conjunto	el entero de menor E_{rms}	[6, 7]
Redondeo minimax	el entero de menor $e_{\text{máx}}$	[8, 10, 11]

El MCO es la cota inferior de E_{rms}: ningún entero lo mejora. A^+ es la *seudoinversa de Moore–Penrose* [4]: la matriz que resuelve mínimos cuadrados; si las columnas de A son independientes, $A^+ = (A^\mathsf{T}A)^{-1}A^\mathsf{T}$. Los términos técnicos se definen también en el glosario (Anexo C).

3. Redondeo conjunto: MCO con enteros

$$z_{conj} = \arg\min_{z \in \mathbb{Z}^N_{\geq 0}} E_{\text{rms}}(z).$$

Es un problema de *mínimos cuadrados enteros* [6]: las curvas Az con z entero forman un *retículo* (una grilla de puntos en el espacio de las curvas), y se busca el punto del retículo más cercano a la curva.

Atajo de Pitágoras. El residuo del MCO es ortogonal a las columnas de A (ecuaciones normales, $A^\mathsf{T}(y - Ac_{MCO}) = 0$) [5]. Por eso

$$\boxed{E_{\text{rms}}(z)^2 = E_{\text{rms}}(c_{MCO})^2 + D(z)}, \qquad D(z) = (z - c_{MCO})^\mathsf{T}\widetilde{M}(z - c_{MCO}), \quad \widetilde{M} = \frac{10^4}{999\,\Delta y^2}A^\mathsf{T}A.$$

El primer término es fijo; minimizar E_{rms} es minimizar D, una cuenta con una matriz de $N \times N$.

3.1. Por qué no alcanza con redondear cada número

Ejemplo: y_2, 6 materiales. $c_{MCO} = (19{,}78;\ 8{,}43;\ 14{,}98;\ 20{,}00;\ 13{,}79;\ 10{,}68)$, $E_{\text{rms}}(c_{MCO})^2 = 0{,}2422$ ($E_{\text{rms}} = 0{,}492\ \%$) y

$$\widetilde{M} = \begin{pmatrix} 0{,}9197 & 1{,}2120 & 0{,}3683 & 0{,}2492 & 0{,}0988 & 0{,}0158 \\ 1{,}2120 & 1{,}8565 & 0{,}6477 & 0{,}4641 & 0{,}1897 & 0{,}0310 \\ 0{,}3683 & 0{,}6477 & 0{,}2792 & 0{,}2234 & 0{,}0962 & 0{,}0162 \\ 0{,}2492 & 0{,}4641 & 0{,}2234 & 0{,}2166 & 0{,}1044 & 0{,}0187 \\ 0{,}0988 & 0{,}1897 & 0{,}0962 & 0{,}1044 & 0{,}0630 & 0{,}0132 \\ 0{,}0158 & 0{,}0310 & 0{,}0162 & 0{,}0187 & 0{,}0132 & 0{,}0047 \end{pmatrix}.$$

Tabla 2: y_2, 6 materiales: tres combinaciones enteras. $E_{\text{rms}} = \sqrt{0{,}2422 + D}$.

Combinación	z	$D(z)$	E_{rms} [%]
Redondeo de c_{MCO}	20, 8, 15, 20, 14, 11	0,1253	0,606
Mejor piso/techo ($2^6 = 64$ pruebas)	20, 8, 15, 21, 13, 11	0,0523	0,543
Óptimo	**20, 8, 16, 20, 13, 11**	**0,0230**	**0,515**

El óptimo tiene $z_3 = 16$, fuera del *piso* (14) y del *techo* (15) de 14,98. El piso $\lfloor x \rfloor$ es el mayor entero $\leq x$ y el techo $\lceil x \rceil$ el menor entero $\geq x$; la fila «mejor piso/techo» prueba las 2^N combinaciones de pisos y techos (Anexo A.1). Una lámina más del material 3 y una menos del 4 casi se compensan en el dominio, así que el óptimo puede desplazarse en esa dirección.

3.2. Método 1: ventana de ±3

Es una búsqueda exhaustiva en una zona acotada: se prueban *todas* las combinaciones enteras que se apartan a lo sumo 3 unidades del redondeo de cada coeficiente del MCO, y se elige la de menor E_{rms}. Fórmulas y ejemplo en el Anexo A.2.

1. Calcular c_{MCO} y redondear cada coeficiente.
2. Tomar 7 candidatos por material: el redondeo y 3 enteros a cada lado (sin negativos).

3. Evaluar las 7^N combinaciones ($7^5 = 16\,807$; $7^6 = 117\,649$) con $D(z)$.
4. Quedarse con la de menor D, es decir, de menor E_{rms}.

¿Por qué ±3? Se midió, en las 22 500 curvas, cuántas veces cada ventana contiene al óptimo exacto (Tabla 3). ±3 es la menor que nunca falla. Es una comprobación empírica; el Método 2 es exacto siempre.

Tabla 3: Espacio de trabajo (22 500 curvas), $C_{LAM} = 20$: curvas en que cada ventana contiene al óptimo.

Ventana	5 materiales	6 materiales
±0 (redondear sin buscar)	15 %	5 %
±1	88 %	65 %
±2	100 %	98,6 %
±3	**100 %**	**100 %**

3.3. Método 2: Schnorr–Euchner

Algoritmo exacto para el punto más cercano de un retículo [7, 6], del tipo *búsqueda en árbol con poda*: decide los coeficientes de a uno (cada decisión es una rama del árbol) y abandona toda rama que ya no puede mejorar la mejor combinación encontrada, sin perder el óptimo (Anexo A.3). Usa la *descomposición de Cholesky* [5] (Anexo A.4), que escribe la matriz simétrica definida positiva $\widetilde{M}$ como $\widetilde{M} = R^{\mathsf{T}}R$, con R triangular superior. Entonces

$$D(z) = \sum_{k=1}^{N} R_{kk}^2\,(z_k - s_k)^2, \qquad s_k = c_k - \frac{1}{R_{kk}} \sum_{l>k} R_{kl}(z_l - c_l).$$

El término k depende solo de $z_k, \ldots, z_N$, y cada término es ≥ 0. Por eso:

1. Presupuesto inicial: la D del redondeo.
2. Se elige z_N, luego z_{N-1}, …, probando cada uno del más cercano a su centro s_k al más lejano.
3. Si la suma parcial supera el presupuesto, la rama se descarta sin completarla.
4. Cada combinación completa mejor baja el presupuesto. Al terminar, la mejor es el óptimo exacto.

Ejemplo con dos materiales (Mean HT, 6 materiales, $C_{LAM} = 10$, materiales 1–4 fijos; Fig. 1). Centro efectivo (3,81; 2,59), $R = \begin{pmatrix} 0{,}9171 & 0{,}1927 \\ 0 & 0{,}1602 \end{pmatrix}$.

Tabla 4: Traza de Schnorr–Euchner. Unidades: (% del rango)^2.

Inicio	Redondeo $(3, 3)$: presupuesto 0,4445.
$z_6 = 3$	Parcial 0,0043; $s_5 = 3{,}72$. $z_5 = 4$: total 0,0687, **nueva mejor**. $z_5 = 3$: 0,4445, no mejora.
$z_6 = 2$	Parcial 0,0089; $s_5 = 3{,}93$. $z_5 = 4$: total 0,0126, **nueva mejor**.
$z_6 = 4, 1, 5, 0, 6$	Parciales 0,051; 0,065; 0,149; 0,172; 0,299, todas $>$ 0,0126: **se descartan**.
Resultado	Óptimo $(4, 2)$ con 3 combinaciones completas evaluadas.

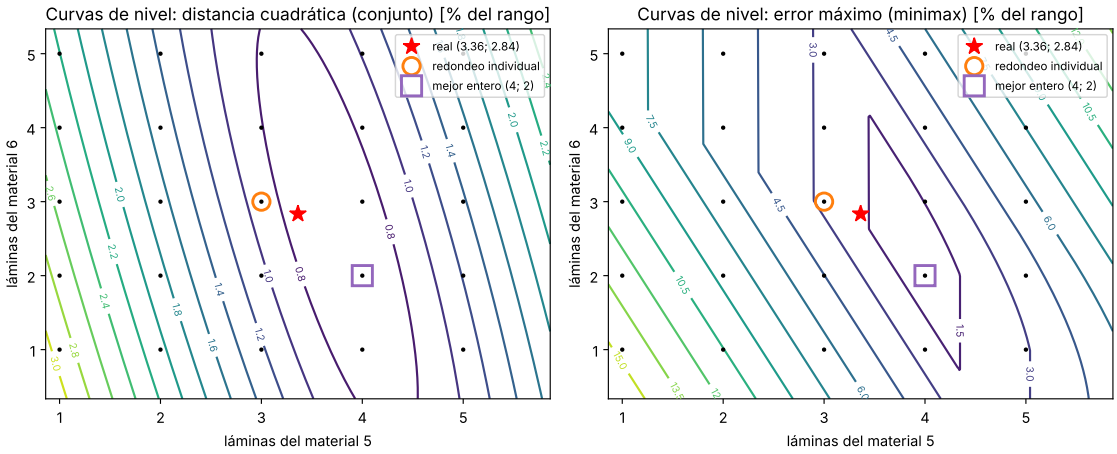


Figura 1: Mean HT, 6 materiales, $C_{LAM} = 10$, materiales 1–4 fijos. Curvas de nivel de E_{rms} (izquierda) y $e_{\text{máx}}$ (derecha) en función de las láminas de los materiales 5 y 6. Estrella: MCO; círculo: redondeo; cuadrado: mejor entero.

Verificación. Los Métodos 1 y 2 dan la misma combinación en las 22 500 curvas y en las 44 curvas de los sujetos y ejemplos, con 5 y 6 materiales.

4. Redondeo minimax: programación lineal entera

La idea: el túnel

Se dibuja un túnel de semiancho τ alrededor de la arteria. Se busca el túnel más angosto dentro del cual entra la curva del injerto; su semiancho es el peor error. Estar dentro del túnel en cada punto son dos desigualdades lineales; con enteros, el problema se resuelve por ramificación y acotación.

$$\min_{z\in\mathbb{Z}^N_{\geq 0}} \max_i |y_i - (Az)_i| \quad\Longleftrightarrow\quad \min_{z,\tau} \tau \quad \text{s.a.} \quad \begin{pmatrix} A & -\mathbf{1} \\ -A & -\mathbf{1} \end{pmatrix} \begin{pmatrix} z \\ \tau \end{pmatrix} \leq \begin{pmatrix} y \\ -y \end{pmatrix}, \; z \in \mathbb{Z}^N_{\geq 0}.$$

- Con z real es un *programa lineal* (minimizar una función lineal sujeta a desigualdades lineales): la *aproximación de Chebyshev*, que elige los coeficientes que minimizan el error máximo en lugar del cuadrático [8] (Anexo A.5). El método símplex lo resuelve exactamente recorriendo vértices de la región factible [9].
- Con z entero es un programa lineal entero mixto, resuelto por ramificación y acotación [10]: si un z_j sale fraccionario (por ejemplo 15,66), se abren dos ramas, $z_j \leq 15$ y $z_j \geq 16$; toda rama cuya cota supera la mejor solución entera se descarta.
- Implementación: HiGHS [11], un programa de código abierto que resuelve programas lineales y enteros (Anexo A.6), vía `scipy.optimize.milp` [12], con 500 puntos (uno de cada dos) y verificación en los 999. Unos 0,07 s por curva.

Ejemplo (y_2, 6 materiales): con z real, $\tau = 1{,}20$ %; con z entero, $z = (20, 8, 17, 18, 16, 9)$ y $\tau = 1{,}29$ % (Fig. 2).

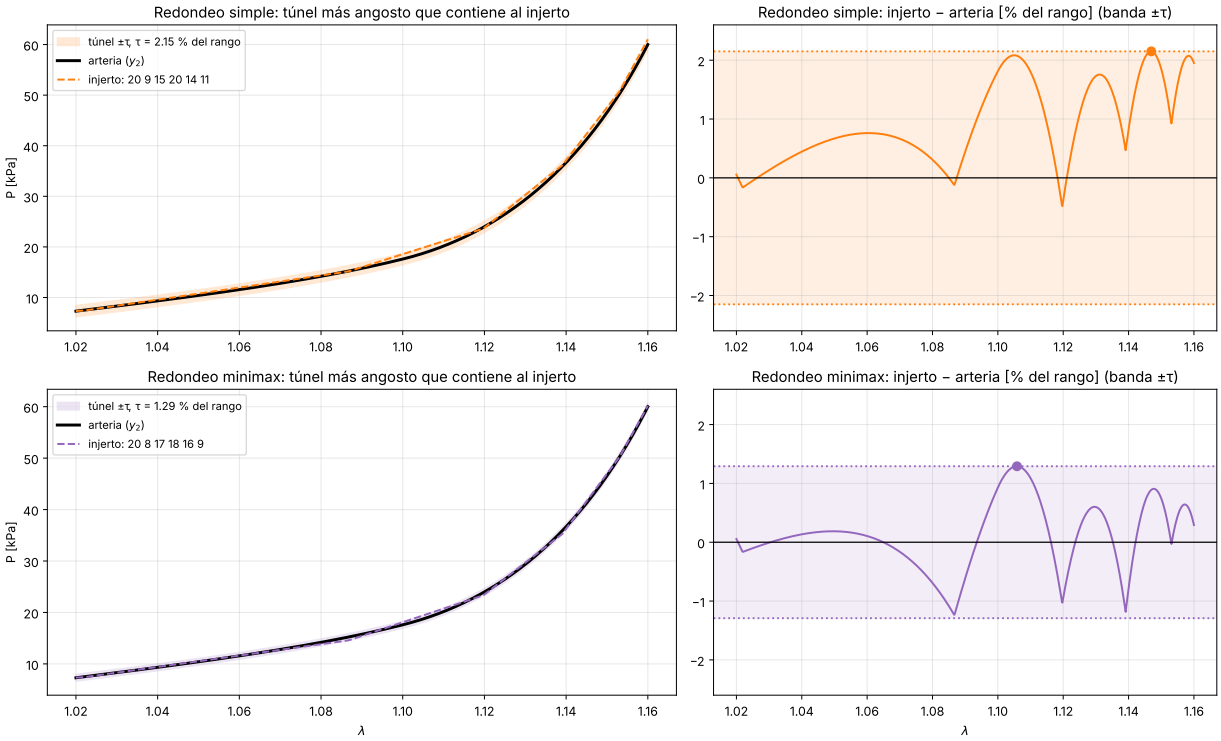


Figura 2: y_2, 6 materiales, $C_{LAM} = 20$. Izquierda: túnel más angosto que contiene al injerto, con el redondeo simple (arriba, $\tau = 2{,}15$ %) y con el minimax (abajo, $\tau = 1{,}29$ %). Derecha: diferencia injerto − arteria en % del rango; la banda es $\pm\tau$ y el punto marca el peor punto. El minimax reparte el error para que el peor punto sea lo más chico posible.

5. Resultados con $C_{LAM} = 20$

5.1. Tres curvas

En negrita, el menor E_{rms} y el menor $e_{\text{máx}}$ entre las filas enteras.

Tabla 5: y_2. Errores contra la curva original [% del rango].

Mat.	Aproximación	c_1	c_2	c_3	c_4	c_5	c_6	E_{rms}	$e_{\text{máx}}$
5	MCO (sin redondear)	19,77	8,53	17,31	20,00	11,60	–	0,673	2,25
	Red neuronal (sin redondear)	19,74	8,68	17,17	21,06	11,56	–	0,845	2,11
	Redondeo simple (de la red)	20	9	17	21	12	–	1,246	2,93
	Método 1: ventana ±3	20	8	18	20	12	–	**0,717**	2,46
	Método 2: Schnorr–Euchner	20	8	18	20	12	–	**0,717**	2,46
	Minimax	19	9	18	20	10	–	0,807	**1,70**
6	MCO (sin redondear)	19,78	8,43	14,98	20,00	13,79	10,68	0,492	1,68
	Red neuronal (sin redondear)	19,72	8,68	14,71	20,04	14,16	11,12	0,551	1,48
	Redondeo simple (de la red)	20	9	15	20	14	11	1,134	2,15
	Método 1: ventana ±3	20	8	16	20	13	11	**0,515**	1,59
	Método 2: Schnorr–Euchner	20	8	16	20	13	11	**0,515**	1,59
	Minimax	20	8	17	18	16	9	0,570	**1,29**

Tabla 6: Mean HT.

Mat.	Aproximación	c_1	c_2	c_3	c_4	c_5	c_6	E_{rms}	$e_{\text{máx}}$
5	MCO (sin redondear)	9,52	8,23	7,99	7,27	6,30	–	0,509	1,31
	Red neuronal (sin redondear)	9,51	8,25	8,01	7,26	6,28	–	0,511	1,27
	Redondeo simple (de la red)	10	8	8	7	6	–	0,682	2,21
	Método 1: ventana ±3	10	8	8	7	7	–	**0,639**	**1,52**
	Método 2: Schnorr–Euchner	10	8	8	7	7	–	**0,639**	**1,52**
	Minimax	10	8	8	7	7	–	**0,639**	**1,52**
6	MCO (sin redondear)	9,52	8,10	7,94	6,74	6,72	5,67	0,368	0,96
	Red neuronal (sin redondear)	9,55	8,12	7,93	6,75	6,73	5,67	0,376	0,87
	Redondeo simple (de la red)	10	8	8	7	7	6	0,945	2,27
	Método 1: ventana ±3	9	9	6	8	6	5	**0,591**	1,23
	Método 2: Schnorr–Euchner	9	9	6	8	6	5	**0,591**	1,23
	Minimax	10	8	8	6	8	4	0,665	**1,17**

Tabla 7: y_1.

Mat.	Aproximación	c_1	c_2	c_3	c_4	c_5	c_6	E_{rms}	$e_{\text{máx}}$
5	MCO (sin redondear)	0,85	5,97	0,96	0,95	0,69	–	0,210	1,49
	Red neuronal (sin redondear)	0,85	5,94	0,95	0,93	0,57	–	0,432	1,59
	Redondeo simple (de la red)	1	6	1	1	1	–	1,302	3,35
	Método 1: ventana ±3	1	6	1	1	0	–	**1,041**	**2,03**
	Método 2: Schnorr–Euchner	1	6	1	1	0	–	**1,041**	**2,03**
	Minimax	1	6	1	1	0	–	**1,041**	**2,03**
6	MCO (sin redondear)	0,72	6,12	0,93	0,91	0,78	0,62	0,140	0,97
	Red neuronal (sin redondear)	0,67	6,13	0,98	0,86	0,76	0,46	0,229	0,82
	Redondeo simple (de la red)	1	6	1	1	1	0	1,036	2,04
	Método 1: ventana ±3	1	6	1	1	0	2	**0,876**	**2,02**
	Método 2: Schnorr–Euchner	1	6	1	1	0	2	**0,876**	**2,02**
	Minimax	1	6	1	1	0	2	**0,876**	**2,02**

- Métodos 1 y 2 coinciden siempre y dan el menor E_{rms} entero; el minimax da el menor $e_{\text{máx}}$.
- El redondeo simple es siempre el peor: en Mean HT con 6 materiales, $E_{\text{rms}} = 0{,}945$ % contra 0,591 % del conjunto.
- El minimax puede bajar el $e_{\text{máx}}$ del propio MCO (y_2, 6 materiales: 1,29 contra 1,68 %), porque el MCO minimiza E_{rms}, no el peor punto.

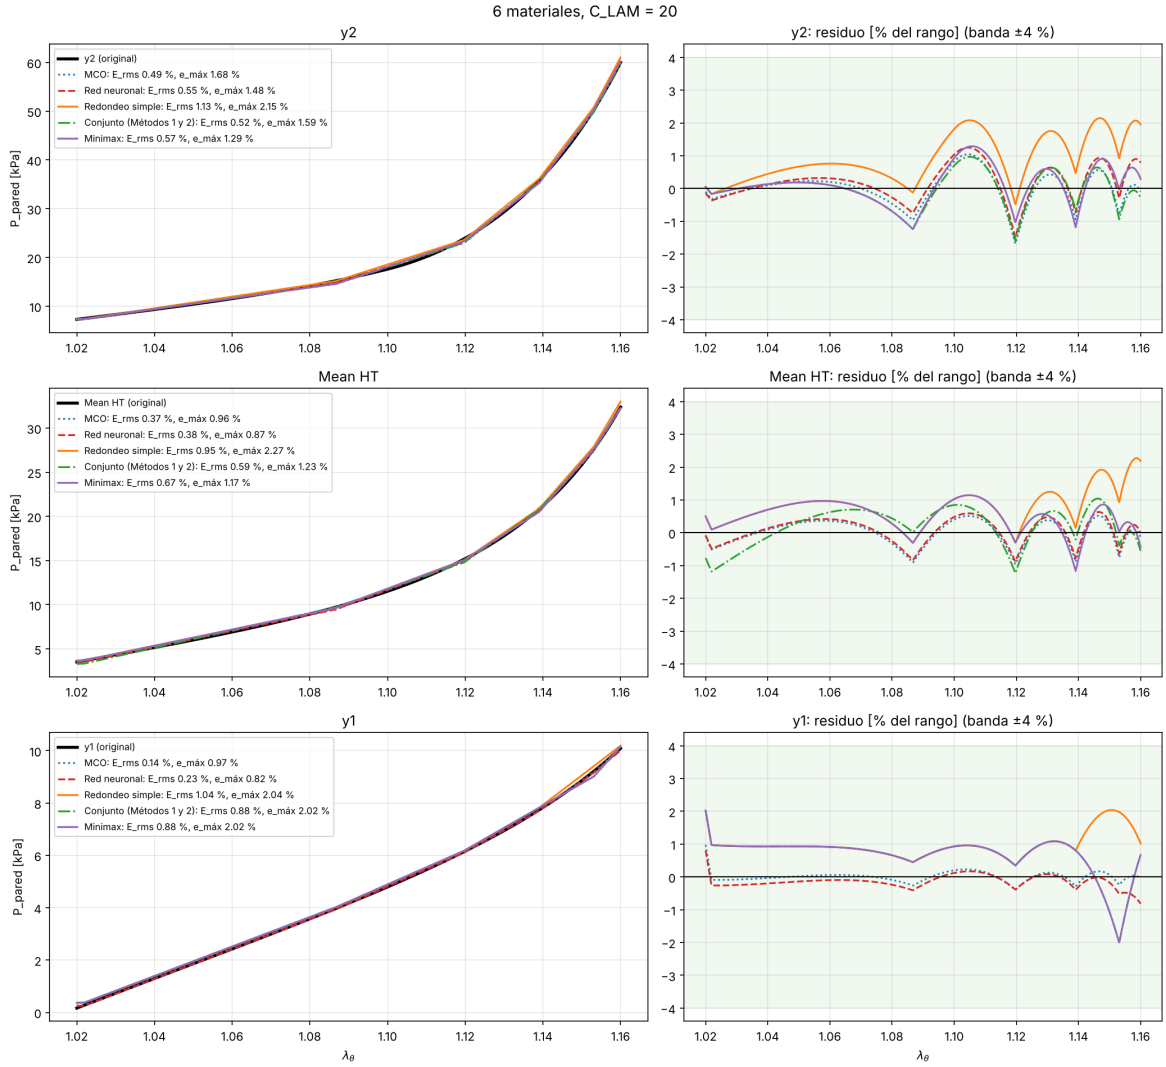


Figura 3: 6 materiales: curvas y residuos [% del rango] de las seis aproximaciones. Banda verde: ±4 %.

5.2. Los 41 sujetos

Tabla 8: Sujetos que cumplen el 3 % y el 4 % de $e_{\text{máx}}$, y peor $e_{\text{máx}}$ [%].

		Cumplen el 3 %			Cumplen el 4 %			Peor $e_{\text{máx}}$ [%]		
Mat.	C_{LAM}	simple	conj.	minimax	simple	conj.	minimax	simple	conj.	minimax
5	10	9	28	31	19	33	35	42,72	8,79	8,79
	20	30	38	39	35	40	41	21,75	4,07	3,84
	30	33	41	41	38	41	41	5,07	2,56	2,56
	40	37	41	41	40	41	41	4,60	2,60	2,43
	50	37	41	41	39	41	41	7,57	2,01	1,51
6	10	10	34	36	18	38	38	43,72	8,54	8,54
	20	26	38	39	32	41	41	23,46	3,41	3,41
	30	37	41	41	39	41	41	7,10	2,52	2,27
	40	36	41	41	38	41	41	10,13	2,11	2,11
	50	39	41	41	39	41	41	5,54	1,52	1,33

Con $C_{LAM} = 20$ el minimax cumple el 4 % en los 41 sujetos con 5 y con 6 materiales (peor caso 3,84 y 3,41 %). En E_{rms}, el conjunto nunca es superado por el minimax en ningún sujeto; en $e_{\text{máx}}$, el minimax nunca es superado por el conjunto.

5.3. Espacio de trabajo

Tabla 9: 22 500 curvas: porcentaje que cumple el 3 % y el 4 % de $e_{\text{máx}}$, y peor caso. Minimax en negrita: curva por curva; resto de las escalas: 2000 curvas al azar.

		Cumplen el 3 % [%]			Cumplen el 4 % [%]			Peor $e_{\text{máx}}$ [%]		
Mat.	C_{LAM}	simple	conj.	minimax	simple	conj.	minimax	simple	conj.	minimax
5	10	27,13	61,16	76,35	44,39	85,89	92,65	49,78	12,81	9,75
	20	61,04	94,97	**98,56**	78,83	99,36	**99,88**	27,32	6,38	**6,26**
	30	79,54	99,45	**99,95**	91,69	99,98	**100**	14,47	4,64	**3,89**
	40	89,98	99,95	100	96,77	100	100	10,30	3,21	2,12
	50	94,44	100	100	98,55	100	100	12,11	3,02	1,90
6	10	31,11	80,02	86,75	47,16	93,36	96,35	50,63	11,89	8,87
	20	67,03	98,47	**99,48**	81,86	99,83	**99,96**	28,54	5,98	**5,98**
	30	84,79	99,88	**99,98**	93,42	100	**100**	15,35	4,13	**3,48**
	40	92,99	100	100	97,70	100	100	13,63	3,01	1,96
	50	96,69	100	100	99,04	100	100	9,55	2,70	1,69

Tabla 10: 22 500 curvas, $C_{LAM} = 20$: mediana, percentil 99 y peor caso [% del rango].

		E_{rms}			$e_{\text{máx}}$		
Mat.	Aproximación	mediana	p99	peor	mediana	p99	peor
5	MCO	0,46	0,62	0,68	1,23	1,65	2,06
	Red	0,46	0,62	1,12	1,23	1,68	3,74
	Redondeo simple	1,06	4,72	11,71	2,58	9,95	27,32
	Conjunto (Mét. 1 y 2)	0,68	1,71	3,70	1,91	3,78	6,38
	Minimax	0,80	1,91	3,70	1,56	3,14	6,26
6	MCO	0,33	0,45	0,49	0,89	1,18	1,38
	Red	0,34	0,47	1,53	0,86	1,26	4,50
	Redondeo simple	1,01	4,72	12,50	2,31	10,14	28,54
	Conjunto (Mét. 1 y 2)	0,54	1,46	3,28	1,47	3,19	5,98
	Minimax	0,64	1,65	3,70	1,24	2,69	5,98

Con $C_{LAM} = 20$ y el 4 %, el minimax deja fuera 28 (5 materiales) y 10 (6 materiales) de las 22 500 curvas, todas del extremo blando de la franja. Con $C_{LAM} = 30$ cumplen todas. El minimax optimiza sobre 500 puntos; medido en 999, en menos del 1,5 % de las curvas el conjunto lo supera en $e_{\text{máx}}$, por a lo sumo 0,05 puntos.

6. Conclusiones

1. Todas las aproximaciones se comparan contra la curva original con E_{rms} y $e_{\text{máx}}$.
2. El redondeo conjunto es el MCO con enteros; por Pitágoras se reduce a minimizar una forma cuadrática de $N \times N$. La ventana ± 3 y Schnorr–Euchner dan el mismo óptimo en todas las curvas evaluadas.

3. El redondeo minimax minimiza el peor punto, la medida del criterio. Es un programa lineal entero, exacto y rápido. **Es el método recomendado.**
4. El redondeo simple no es recomendable.
5. Con $C_{LAM} = 20$ el minimax cumple el 4 % en los 41 sujetos y en el 99,88 % (5 materiales) y 99,96 % (6) de la franja.
6. La escala de láminas es una elección de unidades para los coeficientes reales. Al fijar el espesor de cada capa, el diseño entero se obtiene con los mismos métodos.

A. Fórmulas y definiciones de los métodos de redondeo

Este anexo explica, con ejemplos, las herramientas que usan los métodos de redondeo.

A.1. Piso y techo

Para un número real x:

$$\lfloor x \rfloor = \text{piso de } x = \text{el mayor entero} \le x, \qquad \lceil x \rceil = \text{techo de } x = \text{el menor entero} \ge x.$$

Ejemplos: $\lfloor 14{,}98 \rfloor = 14$ y $\lceil 14{,}98 \rceil = 15$; $\lfloor 8{,}43 \rfloor = 8$ y $\lceil 8{,}43 \rceil = 9$. Si x ya es entero, piso y techo coinciden; para $c = 20{,}00$ se toman igualmente 20 y 21 como candidatos. El *redondeo* al entero más cercano elige uno de los dos: round(14,98) = 15.

Mejor combinación de piso y techo. Con N coeficientes, cada uno puede tomar su piso o su techo: hay 2^N combinaciones ($2^6 = 64$ con 6 materiales). Se evalúan todas y se elige la de menor E_{rms}. Es mejor que redondear, pero no alcanza: el óptimo puede quedar fuera de $\{\lfloor c_j \rfloor, \lceil c_j \rceil\}$, como $z_3 = 16$ para $c_3 = 14{,}98$ (Sec. 3).

A.2. Ventana de ±3

Es una búsqueda exhaustiva en una zona acotada alrededor del redondeo de los coeficientes del MCO.

1. **Centro**: $r_j = \text{round}(c_{MCO,j})$ para cada material.
2. **Candidatos de cada material**: los enteros a distancia ≤ 3 de r_j, sin negativos:

   $$\mathcal{C}_j = \{\, r_j - 3,\ \ldots,\ r_j + 3 \,\} \cap \{0, 1, 2, \ldots\}.$$

   Por ejemplo, para $c_3 = 14{,}98$: $r_3 = 15$ y $\mathcal{C}_3 = \{12, 13, 14, 15, 16, 17, 18\}$; para $c = 0{,}72$: $r = 1$ y $\mathcal{C} = \{0, 1, 2, 3, 4\}$.
3. **Ventana**: todas las combinaciones que toman un candidato de cada material, $\mathcal{W} = \mathcal{C}_1 \times \cdots \times \mathcal{C}_N$. Tiene a lo sumo 7^N elementos ($7^5 = 16\,807$; $7^6 = 117\,649$).
4. **Evaluación**: para cada $z \in \mathcal{W}$ se calcula $D(z) = (z - c_{MCO})^{\mathsf{T}} \widetilde{M} (z - c_{MCO})$, que cuesta unas N^2 multiplicaciones, y $E_{\text{rms}}(z) = \sqrt{E_{\text{rms}}(c_{MCO})^2 + D(z)}$.
5. **Resultado**: la combinación de menor D. Una computadora evalúa las 117 649 en milisegundos.

Garantía. La ventana encuentra el óptimo si y solo si ningún coeficiente óptimo se aparta más de 3 del redondeo. Eso se comprobó en las 22 500 curvas del espacio de trabajo; para cualquier otra curva, el Método 2 (exacto) sirve de verificación.

A.3. Búsqueda exacta en árbol

Una *búsqueda en árbol* recorre las combinaciones decidiendo una variable por vez:

- la *raíz* es el problema sin ninguna variable elegida;
- cada *nivel* del árbol corresponde a un material: en el primer nivel se elige z_N, en el segundo z_{N-1}, y así;
- cada *rama* es un valor posible de la variable de ese nivel;
- cada *hoja* (el final de un camino) es una combinación completa z.

Recorrer todas las hojas es la búsqueda exhaustiva. La búsqueda *exacta con poda* evita la mayoría: en cada nodo calcula una *cota inferior* del valor de cualquier hoja que cuelgue de él. Si esa cota ya supera la mejor combinación completa encontrada, toda la rama se descarta sin recorrerla (*poda*). Es exacta porque solo descarta ramas que con seguridad no contienen algo mejor.

En Schnorr–Euchner [7, 6] la cota es la suma parcial de cuadrados $\sum_{k\geq \ell} R_{kk}^2 (z_k - s_k)^2$: como los términos que faltan son ≥ 0, ninguna hoja de esa rama puede tener una D menor. Además, en cada nivel prueba primero los valores más cercanos al centro s_k, para encontrar pronto una buena combinación y podar más. En el ejemplo de la Tabla 4, el árbol tiene 7 ramas en el nivel de z_6; se completan solo 3 hojas y las otras 5 ramas se podan enteras. La ramificación y acotación del minimax (Sec. 4) usa la misma idea, con otra cota.

A.4. Descomposición de Cholesky

Toda matriz M simétrica y *definida positiva* (es decir, $d^{\mathsf{T}} M d > 0$ para todo $d \neq 0$, como $\widetilde{M}$, que mide una distancia) se puede escribir como

$$M = R^{\mathsf{T}} R, \qquad R \text{ triangular superior, con } R_{kk} > 0.$$

Es la "raíz cuadrada" de una matriz [5]. Para 2×2:

$$\begin{pmatrix} m_{11} & m_{12} \\ m_{12} & m_{22} \end{pmatrix} = \begin{pmatrix} R_{11} & 0 \\ R_{12} & R_{22} \end{pmatrix} \begin{pmatrix} R_{11} & R_{12} \\ 0 & R_{22} \end{pmatrix} \Longrightarrow R_{11} = \sqrt{m_{11}}, \quad R_{12} = \frac{m_{12}}{R_{11}}, \quad R_{22} = \sqrt{m_{22} - R_{12}^2}.$$

Ejemplo (el de la Tabla 4): $M = \begin{pmatrix} 0{,}8411 & 0{,}1767 \\ 0{,}1767 & 0{,}0628 \end{pmatrix}$ da $R_{11} = 0{,}9171$, $R_{12} = 0{,}1927$, $R_{22} = \sqrt{0{,}0628 - 0{,}0371} = 0{,}1602$.

Para qué sirve aquí. Con $d = z - c$,

$$D = d^{\mathsf{T}} M d = d^{\mathsf{T}} R^{\mathsf{T}} R d = \|Rd\|^2 = \sum_k \Big(\textstyle\sum_{l \geq k} R_{kl} d_l \Big)^2.$$

Como R es triangular, el término k depende solo de $d_k, \ldots, d_N$. Eso permite elegir las variables de la última a la primera y saber, en cada paso, cuánto ya se "gastó" (Sec. 3.3).

A.5. Aproximación de Chebyshev (minimax)

Aproximar una función y con una combinación Ac eligiendo los coeficientes que minimizan el error *máximo*, en lugar del cuadrático:

$$\text{MCO: } \min_c \sum_i \big(y_i - (Ac)_i\big)^2, \qquad \text{Chebyshev: } \min_c \max_i \big|y_i - (Ac)_i\big|.$$

Lleva el nombre de P. L. Chebyshev, que la estudió para polinomios [8]. **Ejemplo:** aproximar $y = x^2$ en $[0, 1]$ con una recta $a + bx$.

- MCO: $y \approx x - \frac{1}{6}$. Error máximo $\frac{1}{6} \approx 0{,}167$, en los extremos.

- Chebyshev: $y \approx x - \frac{1}{8}$. Error máximo $\frac{1}{8} = 0{,}125$, alcanzado en $x = 0$, $\frac{1}{2}$ y 1 con signos alternados (+, −, +).

El minimax reparte el error para que el peor punto sea lo más chico posible; el MCO, en cambio, achica el error típico. Por eso el minimax puede tener menor $e_{\text{máx}}$ que el MCO y mayor E_{rms}. Con la variable auxiliar τ se convierte en un programa lineal (Sec. 4).

A.6. HiGHS

HiGHS [11] es un programa (*solver*) de código abierto, desarrollado en la Universidad de Edimburgo, que resuelve problemas de optimización lineal:

- programas lineales, con el método símplex dual o con puntos interiores;
- programas lineales enteros mixtos, con ramificación y acotación [10] reforzada con *cortes* (desigualdades extra que ajustan la cota sin perder soluciones enteras).

Es libre (licencia MIT) y es el solver que usa SciPy en `scipy.optimize.linprog` y `scipy.optimize.milp` [12]. Aquí se le pasa la matriz de restricciones del túnel, el vector y y la lista de variables enteras, y devuelve el óptimo entero z y el τ mínimo.

B. La ley de Masson y los datos de partida

Este anexo reúne lo que el método toma de Masson et al. [1], para que el informe sea autocontenido.

Qué midieron. Los autores midieron in vivo, en forma no invasiva y a lo largo del ciclo cardíaco, el diámetro y la presión de la carótida común de 16 sujetos normotensos (NT) y 25 hipertensos tratados (HT). A cada sujeto le ajustaron un modelo constitutivo de la pared arterial y publicaron sus parámetros (Tablas 11 y 12).

La ley constitutiva ("ley de Masson"). La pared es un material incompresible cuya energía de deformación tiene tres partes [1]:

- **Elastina**: material neo-Hookeano de módulo c, de respuesta casi lineal.
- **Colágeno**: cuatro familias de fibras con respuesta exponencial (extensión del modelo de Holzapfel, Gasser y Ogden [2]): axial, circunferencial y dos diagonales a $\pm\alpha$. Una fibra no aporta mientras no se estira y luego se rigidiza muy rápido: es lo que da la forma de J.
- **Tono muscular activo** (modelo de Rachev y Hayashi [3]): tensión máxima T_m y estiramientos característicos λ_0 (sin tensión activa) y λ_m (tensión máxima).

Con estiramiento axial fijo λ_z e incompresibilidad ($\lambda_r = 1/(\lambda_\theta \lambda_z)$), la diferencia de tensiones circunferencial y radial es

$$\sigma_{\theta\theta} - \sigma_{rr} = \underbrace{c\left(\lambda_\theta^2 - \lambda_r^2\right)}_{\text{elastina}} + \underbrace{\lambda_\theta^2 \sum_{k=1}^{4} c_{1,k}\, E_k\, e^{\,c_{2,k} E_k^2} \sin^2 \varphi_k}_{\text{colágeno}} + \underbrace{T_m \lambda_\theta \left[1 - \left(\frac{\lambda_m - \lambda_\theta}{\lambda_m - \lambda_0}\right)^2\right]}_{\text{tono activo}},$$

con $E_k = \lambda_k^2 - 1$:

Familia	Ángulo φ_k (desde el eje)	Estiramiento λ_k	$c_{1,k}$	$c_{2,k}$
axial	0	λ_z	c_1	c_2
circunferencial	90°	λ_θ	c_1^{circ}	c_2^{circ}
diagonales	$\pm\alpha$	$\sqrt{\lambda_\theta^2 \sin^2\alpha + \lambda_z^2 \cos^2\alpha}$	c_1	c_2

La familia axial no aporta en la dirección circunferencial ($\sin 0 = 0$).

Cinemática. La configuración libre de tensiones es un sector anular abierto (ángulo de apertura Θ_0, radio medio R_m), que representa las tensiones residuales. Un punto de radio R pasa al radio r en la arteria cerrada; por incompresibilidad,

$$R^2 = R_m^2 - \frac{\pi\lambda_z}{\Theta_0}\left(r_m^2 - r^2\right), \qquad \lambda_\theta(r) = \frac{\pi r}{\Theta_0 R}.$$

La abscisa de todas las curvas es el estiramiento en el radio medio, $\lambda = \lambda_\theta(r_m) = r_m/R_{ref}$, con $R_{ref} = \Theta_0 R_m/\pi$: es proporcional al diámetro.

De la tensión a la presión. El equilibrio radial de un cilindro de pared gruesa, $\partial\sigma_{rr}/\partial r + (\sigma_{rr} - \sigma_{\theta\theta})/r = 0$, integrado sobre el espesor de la pared, da la presión que soporta la pared [1]:

$$P(\lambda) = P_i - P_a = \int_{r_i}^{r_m} \frac{\sigma_{\theta\theta} - \sigma_{rr}}{r}\, dr,$$

con P_i la presión interna y P_a la presión perivascular, que no interviene. La integral se calcula con la regla del trapecio. Repitiendo el cálculo en los 999 puntos de λ se obtiene la curva $P(\lambda)$ de cada sujeto (Fig. 6).

Validación. Las Figs. 5a y 7a del artículo grafican la tensión circunferencial $\sigma_{\theta\theta}$ en r_m. Recalculada con la ley y los parámetros de las tablas, reproduce las curvas medias publicadas con un error cuadrático medio de 1,2 a 1,7 % de su valor medio (Figs. 4 y 5), del orden del error de digitalización de las figuras.

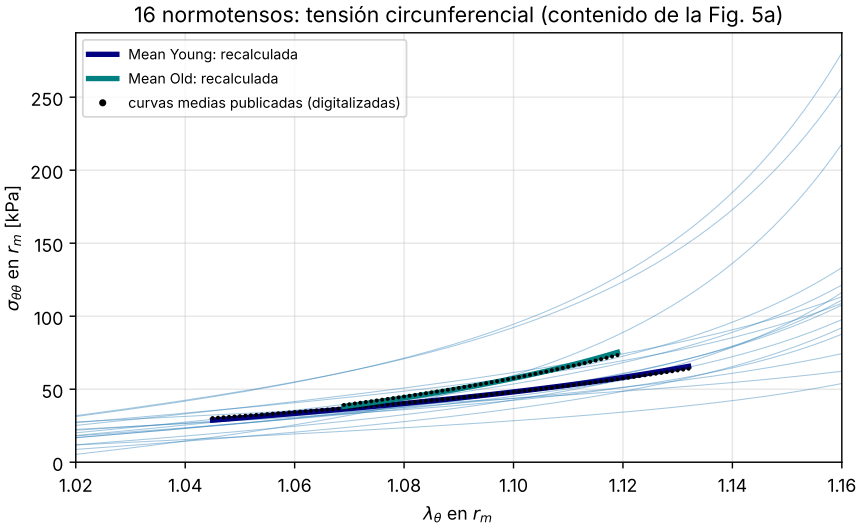


Figura 4: Contenido de la Fig. 5a de Masson et al. [1], recalculado: tensión circunferencial de los 16 normotensos (finas) y curvas medias de jóvenes (edad ≤ 42) y mayores (edad ≥ 53). Puntos: curvas medias publicadas, digitalizadas.

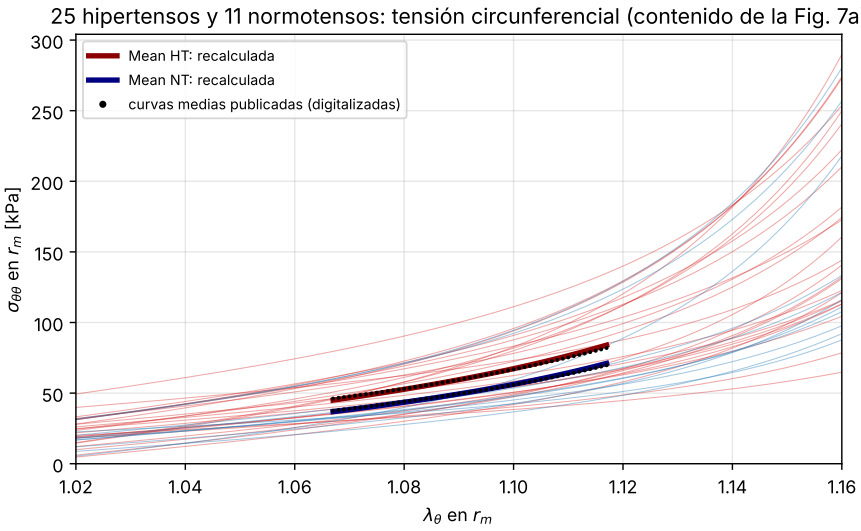


Figura 5: Contenido de la Fig. 7a de Masson et al. [1], recalculado: 25 hipertensos (rojo) y 11 normotensos de edad comparable (azul), con sus medias. Puntos: curvas medias publicadas, digitalizadas.

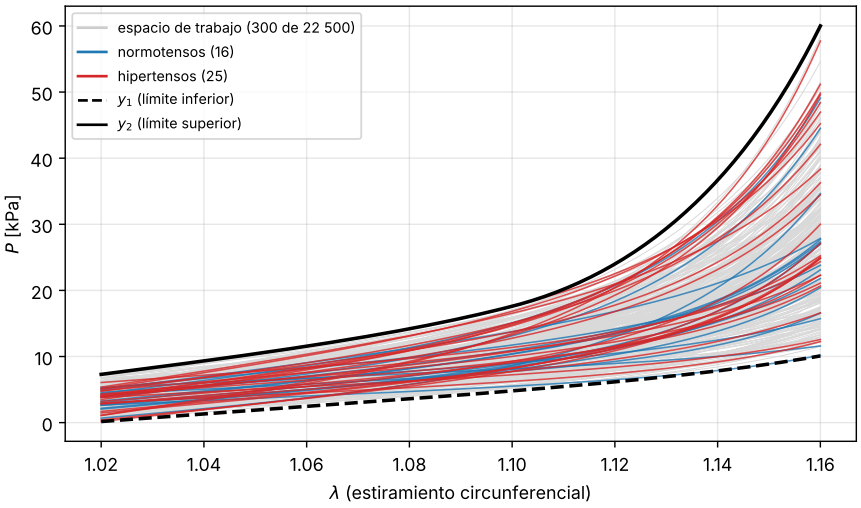


Figura 6: Resultado: presión $P(\lambda)$ de los 41 sujetos, que son las curvas objetivo, con las curvas límite y_1, y_2 y una muestra del espacio de trabajo.

Parámetros de las tablas.

- Geometría: R_m, Θ_0 (configuración libre de tensiones) y λ_z (estiramiento axial in vivo).
- Elastina: c. Colágeno: c_1, c_2 (axiales y diagonales), c_1^{circ}, c_2^{circ} (circunferenciales) y α (ángulo de las diagonales).
- Tono activo: T_m, λ_0, λ_m. Presión perivascular: a, b (no intervienen en P).

Los sujetos marcados con † son los 10 reservados para test.

Tabla 11: Tabla 2 de Masson et al. [1]: parámetros de los 16 sujetos normotensos. †: sujeto reservado para test. RMSE: error del ajuste del modelo a los datos, informado por los autores.

Sujeto	Edad [años]	Sexo	R_m [mm]	Θ_0 [°]	λ_z	c [kPa]	c_1 [kPa]	c_2	c_1^{circ} [kPa]	c_2^{circ}	α [°]	T_m [kPa]	λ_0	λ_m	a [kPa]	b	RMSE [kPa]
NT01	62	F	4,261	128,7	1,11	29,82	9,44	14,14	16,13	15,11	65,74	39,73	0,96	1,70	0,122	3,52	0,174
NT02†	60	M	4,691	128,9	1,08	20,42	8,47	13,10	14,16	15,12	44,46	41,84	0,68	1,92	0,126	3,40	0,288
NT03	31	M	4,305	132,2	1,09	27,23	10,34	13,10	7,01	12,82	48,62	43,37	0,82	1,65	0,139	3,57	0,131
NT04	31	M	4,672	133,9	1,10	23,59	6,58	11,77	6,38	10,69	32,04	39,81	0,68	1,59	0,118	3,53	0,146
NT05	34	F	4,203	130,1	1,10	35,68	13,62	13,18	13,38	13,17	50,72	50,07	0,86	1,62	0,103	3,58	0,123
NT06	53	F	3,957	130,1	1,11	33,37	11,38	13,63	13,30	14,26	57,14	46,59	0,95	1,69	0,093	3,44	0,269
NT07	21	F	3,827	132,0	1,10	44,28	21,79	13,17	8,27	12,73	51,15	53,58	0,92	1,62	0,111	3,58	0,215
NT08†	25	M	4,856	133,2	1,07	23,25	6,34	12,93	8,11	13,17	42,93	31,90	0,82	1,77	0,173	3,57	0,367
NT09	42	F	4,506	129,5	1,10	34,90	16,14	13,58	19,64	13,89	57,21	47,01	0,93	1,65	0,084	3,55	0,209
NT10†	55	M	4,770	129,1	1,10	38,57	36,31	13,31	56,88	13,61	54,22	46,36	0,89	1,66	0,006	3,75	0,652
NT11†	64	M	5,566	129,5	1,10	34,89	40,16	13,45	66,88	13,53	54,54	41,12	0,85	1,79	0,005	3,23	0,375
NT12	60	F	4,876	130,1	1,09	33,94	10,78	13,95	12,79	15,42	60,97	45,77	0,93	1,73	0,099	3,37	0,362
NT13	61	F	4,924	130,6	1,09	35,15	17,69	13,43	18,40	13,22	55,04	45,59	0,94	1,66	0,085	3,51	0,240
NT14	39	F	3,539	131,5	1,09	28,97	8,22	13,13	19,02	13,16	50,22	41,30	0,89	1,67	0,105	3,53	0,262
NT15	58	F	3,922	132,4	1,08	26,71	15,79	13,36	16,68	13,11	53,60	35,32	0,95	1,71	0,166	3,60	0,302
NT16	60	M	5,718	129,7	1,10	27,79	28,23	13,46	57,77	13,63	55,73	36,50	1,05	1,77	0,141	3,58	0,283

Tabla 12: Tabla 4 de Masson et al. [1]: parámetros de los 25 sujetos hipertensos tratados. †: sujeto reservado para test. RMSE: error del ajuste del modelo a los datos, informado por los autores.

Sujeto	Edad [años]	Sexo	R_m [mm]	Θ_0 [°]	λ_z	c [kPa]	c_1 [kPa]	c_2	c_1^{circ} [kPa]	c_2^{circ}	α [°]	T_m [kPa]	λ_0	λ_m	a [kPa]	b	RMSE [kPa]
HT01	68	M	4,965	130,9	1,10	35,91	12,57	14,08	15,52	14,91	67,18	48,42	0,99	1,66	0,098	3,50	0,300
HT02	54	M	4,927	129,8	1,10	38,20	16,40	13,20	16,44	13,20	51,11	52,44	0,86	1,62	0,137	3,58	0,213
HT03†	64	F	4,869	129,5	1,10	36,01	14,55	13,96	18,35	14,48	62,66	47,02	1,00	1,74	0,113	3,62	0,419
HT04	58	F	4,574	131,2	1,09	22,42	8,57	13,03	6,43	13,36	46,38	38,53	0,81	1,68	0,099	3,51	0,346
HT05†	62	F	4,779	130,1	1,10	48,19	35,06	13,23	43,19	13,03	53,24	52,86	0,91	1,63	0,033	3,56	0,218
HT06	66	F	5,062	129,1	1,10	39,78	37,75	13,35	60,89	13,45	56,01	46,44	0,91	1,64	0,004	3,54	0,349
HT07	54	F	4,298	129,6	1,11	50,45	25,51	13,32	39,43	13,24	53,47	64,91	0,93	1,66	0,078	3,72	0,341
HT08	63	F	4,436	129,0	1,10	34,44	30,62	13,29	60,33	13,21	54,67	44,94	0,93	1,65	0,084	3,56	0,518
HT09	68	M	5,090	128,2	1,12	51,48	33,77	13,17	44,26	13,49	51,83	66,41	0,84	1,62	0,023	3,55	0,277
HT10	55	F	4,300	129,0	1,10	37,04	12,32	14,13	15,04	14,93	65,14	48,19	1,04	1,71	0,114	3,47	0,270
HT11	69	M	5,545	131,2	1,08	29,64	9,76	13,23	9,10	15,12	48,16	37,83	0,83	1,74	0,115	3,59	0,263
HT12	54	M	5,426	131,8	1,09	32,23	17,81	13,35	14,03	12,15	53,73	44,93	0,92	1,65	0,090	3,58	0,185
HT13†	61	M	5,169	128,4	1,11	30,45	15,87	13,08	23,03	13,84	47,86	52,58	0,75	1,61	0,009	3,49	0,315
HT14†	60	M	4,640	129,9	1,10	30,43	13,74	13,45	18,01	13,35	54,90	42,43	0,91	1,66	0,088	3,52	0,158
HT15	53	M	4,649	130,4	1,10	40,83	28,98	13,36	31,16	12,62	54,44	49,57	0,93	1,65	0,085	3,63	0,311
HT16	54	M	4,713	129,6	1,10	45,26	29,27	14,00	33,48	14,82	67,16	67,68	1,02	1,65	0,039	3,52	0,194
HT17	53	M	5,043	130,0	1,10	37,25	39,18	13,24	66,29	13,15	54,90	48,26	0,91	1,64	0,099	3,60	0,252
HT18	52	M	4,922	129,7	1,10	29,28	10,50	13,21	19,76	13,39	50,96	46,42	0,85	1,63	0,094	3,56	0,200
HT19†	57	F	4,270	130,3	1,10	33,49	14,47	13,22	17,35	13,27	53,18	46,18	0,90	1,64	0,097	3,55	0,228
HT20	61	F	5,143	129,2	1,10	40,09	15,72	14,09	16,78	14,83	65,17	53,40	1,04	1,70	0,100	3,47	0,265
HT21	57	F	4,881	129,9	1,10	35,31	14,57	13,26	15,58	13,30	52,07	48,97	0,87	1,63	0,094	3,57	0,442
HT22	44	F	4,170	131,0	1,10	55,25	35,78	13,23	19,51	12,55	52,36	59,58	0,93	1,61	0,097	3,61	0,335
HT23	51	M	4,827	130,6	1,08	30,77	12,80	13,60	41,10	14,20	49,79	41,06	0,87	1,90	0,094	3,56	0,337
HT24†	65	M	4,565	129,6	1,10	38,91	25,76	13,20	35,01	13,20	51,94	50,28	0,87	1,62	0,043	3,58	0,212
HT25	67	F	4,718	129,2	1,10	40,29	31,78	13,75	60,40	14,29	63,50	46,06	1,03	1,72	0,025	3,46	0,412

C. Glosario de métodos y términos

Definiciones breves, en orden alfabético. Cada una remite a una referencia que la desarrolla.

Término	Definición	Ref.
A^+ (seudoinversa de Moore–Penrose)	Matriz que da la solución de mínimos cuadrados: si las columnas de A son independientes, $A^+ = (A^\mathsf{T}A)^{-1}A^\mathsf{T}$, y $c = A^+y$ minimiza $\|y - Ac\|_2$.	[4, 5]
Aproximación de Chebyshev	Elegir los coeficientes que minimizan el error *máximo* (norma ℓ_∞) en lugar del cuadrático. Se escribe como un programa lineal. Ver Anexo A.5.	[8]
Búsqueda en árbol con poda	Recorre las combinaciones decidiendo una variable por vez; descarta toda rama cuya cota inferior ya supera la mejor solución encontrada. Ver Anexo A.3.	[6]
Cholesky (descomposición)	Toda matriz simétrica definida positiva se escribe $M = R^\mathsf{T}R$, con R triangular superior. Convierte una forma cuadrática en una suma de cuadrados. Ver Anexo A.4.	[5]
cond(A) (número de condición)	Cociente entre el mayor y el menor valor singular de A. Acota cuánto se amplifica un error relativo de la curva en los coeficientes. Se calcula con las columnas normalizadas (cada una dividida por su máximo).	[5]
Ecuaciones normales	$A^\mathsf{T}Ac = A^\mathsf{T}y$: condición del mínimo de mínimos cuadrados. Equivale a que el residuo $y - Ac$ sea perpendicular a todas las columnas de A; de ahí sale el "atajo de Pitágoras".	[5]
E_{rms}, $e_{\text{máx}}$	Error cuadrático medio y error máximo contra la curva original, en % del rango. E_{rms} es el apartamiento típico; $e_{\text{máx}}$, el peor punto.	–
Forma cuadrática	Expresión $d^\mathsf{T}Md$ con M simétrica; aquí $D(z) = (z-c)^\mathsf{T}\widetilde{M}(z-c)$ mide la distancia cuadrática entre la curva entera y la del MCO.	[5]
HiGHS	Biblioteca de código abierto para programación lineal y lineal entera mixta (símplex dual, ramificación y acotación). Ver Anexo A.6.	[11]
Ley de Masson	Ley constitutiva de la pared de la carótida (elastina, cuatro familias de colágeno, tono muscular activo) con los parámetros de 41 sujetos. Ver Anexo B.	[1]
MCO	Mínimos cuadrados ordinarios: los coeficientes reales que minimizan la suma de los cuadrados de las diferencias con la curva. Solución exacta: $c = A^+y$.	[5]
Mediana, percentil 99	La mediana deja la mitad de los casos por debajo; el percentil 99, el 99 %.	–
Mínimos cuadrados enteros	Mínimos cuadrados con coeficientes enteros. Equivale a buscar el punto de un retículo más cercano a un punto dado.	[6]
Piso, techo	$\lfloor x \rfloor$: mayor entero $\le x$; $\lceil x \rceil$: menor entero $\ge x$. Ver Anexo A.1.	–
Programa lineal	Minimizar una función lineal sujeta a desigualdades lineales. Se resuelve exactamente con el método símplex.	[8, 9]
Programa lineal entero mixto	Programa lineal en el que algunas variables deben ser enteras.	[10]
Ramificación y acotación	Método exacto para programas enteros: resuelve el problema con variables reales; si una variable sale fraccionaria (por ejemplo 15,66), lo divide en dos ramas (≤ 15 y ≥ 16) y descarta toda rama cuya cota ya es peor que la mejor solución entera encontrada.	[10]
Red neuronal	Función con muchos parámetros, organizada en capas, que se ajusta con datos. Aquí da los coeficientes reales a partir de la curva.	informe de la red
Retículo	Conjunto de puntos $\{Az : z \in \mathbb{Z}^N\}$: todas las curvas que se obtienen con cantidades enteras.	[6]

Término	Definición	Ref.
Schnorr–Euchner	Algoritmo exacto para el punto más cercano de un retículo. Elige las coordenadas de a una, de la última a la primera, probando cada valor del más cercano al más lejano, y descarta toda rama cuya suma parcial de cuadrados ya supera la mejor distancia encontrada.	[7, 6]
Símplex (método)	Algoritmo que resuelve un programa lineal recorriendo vértices de la región factible, siempre mejorando, hasta el óptimo.	[9]
Ventana ± 3	Enumeración de todas las combinaciones enteras a ± 3 unidades del redondeo de cada coeficiente (7^N combinaciones).	–

Referencias

[1] Masson, I., Beaussier, H., Boutouyrie, P., Laurent, S., Humphrey, J. D., Zidi, M. (2011). Carotid artery mechanical properties and stresses quantified using in vivo data from normotensive and hypertensive humans. *Biomech. Model. Mechanobiol.* 10(6), 867–882. https://doi.org/10.1007/s10237-010-0279-6

[2] Holzapfel, G. A., Gasser, T. C., Ogden, R. W. (2000). A new constitutive framework for arterial wall mechanics and a comparative study of material models. *J. Elasticity* 61, 1–48. https://doi.org/10.1023/A:1010835316564

[3] Rachev, A., Hayashi, K. (1999). Theoretical study of the effects of vascular smooth muscle contraction on strain and stress distributions in arteries. *Ann. Biomed. Eng.* 27, 459–468. https://doi.org/10.1114/1.191

[4] Penrose, R. (1955). A generalized inverse for matrices. *Math. Proc. Cambridge Philos. Soc.* 51(3), 406–413. https://doi.org/10.1017/S0305004100030401

[5] Trefethen, L. N., Bau, D. (1997). *Numerical Linear Algebra*. SIAM (mínimos cuadrados, SVD, Cholesky). https://doi.org/10.1137/1.9780898719574

[6] Agrell, E., Eriksson, T., Vardy, A., Zeger, K. (2002). Closest point search in lattices. *IEEE Trans. Inf. Theory* 48(8), 2201–2214. https://doi.org/10.1109/TIT.2002.800499

[7] Schnorr, C. P., Euchner, M. (1994). Lattice basis reduction: improved practical algorithms and solving subset sum problems. *Math. Programming* 66, 181–199. https://doi.org/10.1007/BF01581144

[8] Boyd, S., Vandenberghe, L. (2004). *Convex Optimization*. Cambridge Univ. Press, Sec. 6.1 (aproximación en norma ℓ_∞ como programa lineal). https://web.stanford.edu/~boyd/cvxbook/

[9] Dantzig, G. B. (1963). *Linear Programming and Extensions*. Princeton Univ. Press. https://doi.org/10.1515/9781400884179

[10] Land, A. H., Doig, A. G. (1960). An automatic method of solving discrete programming problems. *Econometrica* 28(3), 497–520. https://doi.org/10.2307/1910129

[11] Huangfu, Q., Hall, J. A. J. (2018). Parallelizing the dual revised simplex method. *Math. Programming Computation* 10, 119–142. https://doi.org/10.1007/s12532-017-0130-5. Software HiGHS: https://highs.dev

[12] Virtanen, P. et al. (2020). SciPy 1.0: fundamental algorithms for scientific computing in Python. *Nature Methods* 17, 261–272. https://doi.org/10.1038/s41592-019-0686-2. Función `milp`: https://docs.scipy.org/doc/scipy/reference/generated/scipy.optimize.milp.html