# Diseño de injertos vasculares biomiméticos con láminas de materiales mediante una red neuronal: elección óptima de la base y validación con 41 carótidas humanas

Pablo

20 de octubre de 2026

**Resumen**

Se presenta un método para diseñar injertos vasculares multicapa a partir de la curva presión–diámetro de una arteria. Cada función base es la curva de *una lámina* de un material, idealizada como una línea truncada $A_j(\lambda) = S_j\,\max(0, \lambda - k_j)$. Cada coeficiente es el *número de láminas* de ese material, y se obtiene por mínimos cuadrados ordinarios (MCO). Una red neuronal aprende a dar esas láminas directamente a partir de la curva. El criterio de diseño es un error punto a punto de a lo sumo el 3 % del rango de la curva.

**Curvas objetivo.** Son las presiones de pared de 41 carótidas humanas, calculadas con la ley constitutiva y los parámetros publicados por Masson et al. (2011), en $\lambda_\theta \in [1{,}02;\ 1{,}16]$, el rango respaldado por las mediciones. El espacio de trabajo es la franja entre dos curvas límite que contienen a los 41 sujetos. La inferior es también una curva de la ley de Masson, que parte de la menor presión medida en $\lambda_\theta = 1{,}02$ y pasa por debajo de los 41 sujetos; la superior llega a 60 kPa.

**Bases.** El objetivo es elegir la base de modo que el ajuste sea MCO *sin condiciones* (sin cotas ni restricciones sobre las láminas): $c = A^{+}y$, con $A^{+}$ la seudoinversa de Moore–Penrose, la matriz que resuelve mínimos cuadrados. Toda la exigencia se traslada a la elección de los nudos $k_j$: se minimiza la media del peor 1 % de los errores punto a punto del MCO (CVaR 99 %, *conditional value at risk*), con la restricción $\mathrm{cond}(A) < 25$ (el número de condición, que acota cuánto se amplifica en las láminas un error de la curva) y una penalización por láminas negativas evaluada en todo el espacio de trabajo. La búsqueda se hace con evolución diferencial (búsqueda global con una población de candidatos) y un refinamiento con Nelder–Mead (búsqueda local con un simplex que rueda cuesta abajo). Con 5 materiales, el MCO libre cumple el criterio en las 22 500 curvas del espacio de trabajo (máximo 2,06 %) y en los 41 sujetos, con $\mathrm{cond}(A) = 18{,}0$, y **ninguna curva ni ningún sujeto da láminas negativas**. Con 4 materiales no alcanza; con 6 mejora moderadamente, con $\mathrm{cond}(A)$ en el límite.

**Red neuronal.** Entrenada con 50 000 curvas sintéticas, la red sola cumple el 3 % en los 41 sujetos y queda a +1,0 % del NRMSE óptimo, con mediana de +0,6 % en los sujetos de test. En las familias fisiológicas del dataset de test el exceso queda entre +0,4 y +1,2 %. En una ley constitutiva nunca vista (tipo Fung) es de +1,3 %. Reproduce láminas aisladas con un crosstalk de 0,004 láminas, y su diseño para la curva media de los hipertensos coincide con el óptimo en 0,012 láminas. *Los términos técnicos se definen en su primera aparición y se reúnen en el Glosario (Apéndice C).*

**Palabras clave**— Mínimos cuadrados ordinarios, Líneas truncadas, Aproximación minimax, CVaR, Número de condición, Evolución diferencial, Nelder–Mead, Red neuronal, Injerto vascular biomimético, Curva presión–diámetro.

## Índice

**1. Planteo del problema** **3**

1.1. Qué se quiere diseñar . . . 3
1.2. Variable objetivo, dominio y grilla . . . 3

**2. De las Tablas de Masson a las curvas presión–estiramiento 3**
2.1. Qué se toma del artículo y qué es elaboración propia . . . 3
2.2. Cinemática: de la configuración libre de tensiones a la arteria in vivo . . . 4
2.3. La ley constitutiva . . . 5
2.4. Equilibrio radial: de la tensión a la presión . . . 6
2.5. El cálculo, paso a paso . . . 6
2.6. Validación . . . 7

**3. Curvas límite y espacio de trabajo 7**
3.1. La curva límite superior $y_2$ . . . 8
3.2. La curva límite inferior $y_1$ . . . 8
3.3. El espacio de trabajo . . . 9
3.4. Comportamiento fuera del dominio . . . 10

**4. Elección óptima de la base: nudos y pendientes 10**
4.1. Qué es una base . . . 11
4.2. El ajuste por mínimos cuadrados . . . 12
4.3. Visión general del procedimiento . . . 13
4.4. Rango de búsqueda y ubicación de los nudos . . . 13
4.5. El criterio minimax: cómo se califica un juego de nudos . . . 14
4.5.1. Paso 1: el error de *una* curva . . . 14
4.5.2. Paso 2: de una curva a la población . . . 15
4.5.3. Paso 3: por qué la media del peor 1 % y no el máximo . . . 15
4.5.4. Paso 4: el número de condición, cond$(A)$ . . . 19
4.5.5. Paso 5: el signo de las láminas . . . 20
4.5.6. Paso 6: la función objetivo completa $J$ . . . 22
4.6. El método de búsqueda: evolución diferencial y refinamiento con Nelder–Mead . . . 22
4.6.1. Etapa 1: búsqueda global con evolución diferencial . . . 22
4.6.2. Etapa 2: refinamiento local con Nelder–Mead . . . 23
4.7. Por qué este optimizador y no otro . . . 24
4.8. Robustez del resultado . . . 27
4.9. Las pendientes: cuánto aporta una lámina . . . 28
4.10. Resultados: 4, 5 o 6 bases . . . 30
4.11. Qué garantiza la base elegida y qué no . . . 30
4.12. Cómo se usa en el cuaderno . . . 31

**5. Dataset sintético y red neuronal 32**
5.1. Dataset . . . 32
5.2. Red y entrenamiento . . . 33

**6. Resultados de la red 35**
6.1. Entrenamiento . . . 35
6.2. Los 41 sujetos y las curvas medias . . . 35
6.3. Test por familia . . . 36
6.4. Generalización a una ley nunca vista y control de clase . . . 38
6.5. Reproducción de láminas aisladas . . . 38

**7. Diseño: la curva media de los hipertensos 39**

**8. Conclusiones 39**

**A. El cuaderno** **41**

**B. Datos de partida: Masson et al. (2011)** **41**
B.1. Figuras 5a y 7a: de la tensión a la presión de pared . . . . . 41
B.2. Tablas 2 y 4: parámetros de los 41 sujetos . . . . . 42

**C. Glosario** **46**

# 1. Planteo del problema

## 1.1. Qué se quiere diseñar

Un injerto vascular debe reproducir la respuesta mecánica de la arteria que reemplaza: al recibir la misma presión, debe dilatarse lo mismo. Esa respuesta se resume en la curva presión–diámetro. El injerto se arma superponiendo láminas de $N$ materiales (4 a 6). Cada material tiene sus fibras flojas hasta un cierto estiramiento, el *nudo* $k_j$, y a partir de ahí aporta presión en forma proporcional al estiramiento. El problema es doble:

1. **Elegir los materiales** (sus nudos y pendientes): es la elección de la *base*, y se hace una sola vez (Sección 4).
2. **Para cada arteria, elegir cuántas láminas de cada material** usar: es el ajuste, que se hace por MCO y que la red neuronal aprende a reproducir (Secciones 5 y siguientes).

## 1.2. Variable objetivo, dominio y grilla

La curva objetivo es la **presión de pared**, $P_{pared} = P_i - P_a$ (presión interna menos la presión que ejercen sobre la capa íntima–media la adventicia y el tejido perivascular), en función del estiramiento circunferencial $\lambda_\theta$ en el radio medial $r_m$ (la interfaz media–adventicia), que es proporcional al diámetro. La Sección 2 explica en detalle cómo se calcula a partir de los datos de Masson et al. (2011).

El dominio es $\lambda_\theta \in [1{,}02;\ 1{,}16]$. El modelo constitutivo de cada sujeto se ajustó en el rango de $\lambda_\theta$ medido durante su ciclo cardíaco: aproximadamente 1,085–1,122 para el sujeto más rígido (HT09) y hasta $\approx 1{,}16$ en los más distensibles. Fuera de ese rango la ley es una extrapolación sin datos:

- por debajo de $\lambda_\theta \approx 0{,}95$ el término activo vuelve negativa la presión;
- por encima de 1,16 el colágeno crece sin límite.

Por eso **el ajuste se hace solo en** [1,02; 1,16].

**La grilla.** Una computadora no maneja funciones continuas sino listas de números. Por eso el dominio se *discretiza*: se lo representa con una **grilla** de 999 valores de $\lambda_\theta$ equiespaciados,

$$\lambda_1 = 1{,}02, \quad \lambda_2 = 1{,}02014, \quad \ldots, \quad \lambda_{999} = 1{,}16,$$

con paso $(1{,}16 - 1{,}02)/998 \approx 0{,}00014$. Cada curva queda representada por el vector de sus 999 valores. Todas las sumas, máximos y errores de este informe se calculan sobre esos 999 puntos, y ese mismo vector es la entrada de la red. Se reservan 10 sujetos para test (NT02, NT08, NT10, NT11, HT03, HT05, HT13, HT14, HT19, HT24): no participan ni en la elección de las bases ni en el generador de datos.

# 2. De las Tablas de Masson a las curvas presión–estiramiento

## 2.1. Qué se toma del artículo y qué es elaboración propia

La ley constitutiva **no es de elaboración propia**: es la del artículo de Masson et al. (2011), que a su vez extiende a cuatro familias de fibras el modelo de dos familias de Holzapfel, Gasser

y Ogden (2000) y usa para el músculo liso el modelo de Rachev y Hayashi (1999). Los autores midieron in vivo, en forma no invasiva, el diámetro, el espesor íntima–media y la presión de la carótida común de 16 sujetos normotensos y 25 hipertensos tratados, y ajustaron a cada uno los 14 parámetros del modelo. La Tabla 1 separa lo que se toma del artículo de lo que es elaboración de este trabajo.

**Tabla 1:** Origen de cada elemento del cálculo de las curvas. Los números de ecuación son los del artículo de Masson et al. (2011).

| Elemento | Origen |
|---|---|
| Cinemática: configuración de referencia como sector abierto, mapeo $(R, \Theta, Z) \to (r, \theta, z)$, incompresibilidad | Masson et al., Ecs. (1)–(3) |
| Energía de deformación: elastina neo-Hookeana + 4 familias de colágeno | Masson et al., Ecs. (4)–(5) (extensión de Holzapfel et al., 2000) |
| Tensión activa del músculo liso | Masson et al., Ec. (7) (modelo de Rachev y Hayashi, 1999) |
| Componentes de la tensión de Cauchy | Masson et al., Ec. (8) |
| Equilibrio radial e integración de la presión | Masson et al., Ecs. (9)–(11) |
| Parámetros de los 41 sujetos | Masson et al., Tablas 2 y 4 (reproducidas en el Apéndice B) |
| Espesor íntima–media $h = 0{,}6\,\text{mm}$, igual para todos los sujetos y todos los estiramientos | **Elaboración propia**: el artículo usa el espesor medido de cada sujeto, que no está publicado |
| Abscisa $\lambda_\theta = r_m/R_{ref}$ y dominio [1,02; 1,16] | **Elaboración propia**; la misma abscisa que las Figs. 5a y 7a del artículo |
| Integración numérica (trapecios, 60 puntos) y grilla de 999 puntos | **Elaboración propia** |
| Validación contra las curvas medias de las Figs. 5a y 7a | **Elaboración propia** (curvas digitalizadas del artículo) |
| Curvas límite $y_1$, $y_2$ y espacio de trabajo | **Elaboración propia** (Sección 3) |

## 2.2. Cinemática: de la configuración libre de tensiones a la arteria in vivo

La pared (capa íntima–media) se modela como un cilindro de pared gruesa, incompresible. Para tener en cuenta las tensiones residuales, la configuración de referencia libre de tensiones es un *sector anular abierto*: si se corta la arteria longitudinalmente, se abre y forma un sector con ángulo de apertura $\Theta_0$ (Fig. 1 de Masson). Un punto material de coordenadas $(R, \Theta, Z)$ en el sector pasa a $(r, \theta, z)$ en la arteria cerrada y estirada (Ec. 1 de Masson):

$$r = r(R), \qquad \theta = \frac{\pi}{\Theta_0}\,\Theta, \qquad z = \lambda_z Z.$$

El factor $\pi/\Theta_0$ cierra el sector: el ángulo $\Theta_0$ pasa a ocupar media vuelta ($\pi$) en cada mitad del tubo. Los estiramientos principales (Ec. 2 de Masson) son

$$\lambda_r = \frac{\partial r}{\partial R}, \qquad \lambda_\theta = \frac{\pi\, r}{\Theta_0\, R}, \qquad \lambda_z,$$

con $\lambda_z$ el estiramiento axial in vivo, constante (el parámetro $\lambda$ de las tablas; Masson toma igual a 1 el estiramiento axial residual).

**Incompresibilidad.** El material no cambia de volumen: $\lambda_r \lambda_\theta \lambda_z = 1$. Integrando esa condición entre un punto cualquiera y el radio medial $r_m$ se obtiene la posición de referencia $R$ de cada punto

$r$ de la pared deformada (Ec. 3 de Masson):

$$R(r) = \sqrt{R_m^2 - \frac{\pi\lambda_z}{\Theta_0}\,(r_m^2 - r^2)},$$

donde $R_m$ es el radio medial en la referencia (parámetro de las tablas). Con $R(r)$ se calcula $\lambda_\theta(r) = \pi r/(\Theta_0 R)$ en cada punto del espesor, y $\lambda_r = 1/(\lambda_\theta\lambda_z)$.

**La abscisa.** En el radio medial, $R = R_m$ y $\lambda_\theta(r_m) = \pi r_m/(\Theta_0 R_m)$. Definiendo

$$R_{ref} = \frac{\Theta_0 R_m}{\pi}, \qquad \text{resulta} \qquad \lambda_\theta = \frac{r_m}{R_{ref}}.$$

$R_{ref}$ es el radio medial que tendría la arteria cerrada con estiramiento circunferencial unitario en $r_m$. Así, la abscisa de todas las curvas es proporcional al radio (y al diámetro) medial deformado. Es la misma abscisa que usan las Figs. 5a y 7a del artículo (tensiones "en la media externa $r_m$").

## 2.3. La ley constitutiva

La energía de deformación por unidad de volumen tiene una parte isótropa (matriz dominada por elastina) y una anisótropa (cuatro familias de fibras de colágeno, $k = 1, \ldots, 4$) (Ec. 4 de Masson):

$$W = \frac{c}{2}\,(I_1 - 3) + \sum_{k=1}^{4} \frac{c_{1(k)}}{4\,c_{2(k)}} \left\{ \exp\left[ c_{2(k)} \left( I_{4(k)} - 1 \right)^2 \right] - 1 \right\},$$

con $I_1 = \operatorname{tr}\mathbf{C}$ y $I_{4(k)} = \lambda_k^2$, el cuadrado del estiramiento de la familia $k$. Cada familia forma un ángulo $\alpha_k$ con el eje de la arteria, y su estiramiento es $\lambda_k = \sqrt{\lambda_\theta^2 \sin^2\alpha_k + \lambda_z^2 \cos^2\alpha_k}$.

- **Elastina:** el término $\frac{c}{2}(I_1 - 3)$ es un material neo-Hookeano, de respuesta casi lineal.
- **Colágeno:** el término exponencial no aporta nada mientras la fibra no se estira ($\lambda_k = 1$) y luego crece muy rápido. Es el responsable de la forma J de la curva.
- Las familias son: axial ($\alpha_1 = 0$), circunferencial ($\alpha_2 = 90°$) y dos diagonales simétricas ($\alpha_3 = \alpha$, $\alpha_4 = -\alpha$). Las axial y diagonales comparten parámetros $(c_1, c_2)$; la circunferencial tiene los suyos, $(c_1^{circ}, c_2^{circ})$, porque también representa el aporte pasivo del músculo liso.

**Tono muscular activo** (Ec. 7 de Masson, modelo de Rachev y Hayashi, 1999). El músculo liso, orientado circunferencialmente, aporta la tensión

$$\sigma^a_{\theta\theta} = T_m\,\lambda_\theta \left[ 1 - \left( \frac{\lambda_m - \lambda_\theta}{\lambda_m - \lambda_0} \right)^2 \right],$$

donde $T_m$ es el nivel de activación, $\lambda_m$ el estiramiento de contracción máxima y $\lambda_0$ el estiramiento por debajo del cual el músculo deja de generar fuerza.

**Componentes de la tensión.** Derivando $W$ y sumando el término activo, la diferencia de tensiones circunferencial y radial, que es lo único que interviene en la presión, resulta (de la Ec. 8 de Masson; la presión hidrostática $p$ se cancela en la resta):

$$\sigma_{\theta\theta} - \sigma_{rr} = \underbrace{c\left(\lambda_\theta^2 - \lambda_r^2\right)}_{\text{elastina}} + \underbrace{\lambda_\theta^2 \sum_{k=1}^{4} c_{1(k)} \left(\lambda_k^2 - 1\right) e^{\,c_{2(k)}(\lambda_k^2 - 1)^2} \sin^2\alpha_k}_{\text{colágeno}} + \underbrace{T_m\,\lambda_\theta \left[ 1 - \left( \frac{\lambda_m - \lambda_\theta}{\lambda_m - \lambda_0} \right)^2 \right]}_{\text{tono activo}}.$$

La familia axial no contribuye, porque $\sin^2 0 = 0$.

## 2.4. Equilibrio radial: de la tensión a la presión

Sin fuerzas de volumen y despreciando la inercia (Masson la estima en un 0,1 % de la presión), el equilibrio en dirección radial es (Ec. 9 de Masson)

$$\frac{\partial \sigma_{rr}}{\partial r} + \frac{\sigma_{rr} - \sigma_{\theta\theta}}{r} = 0.$$

Las condiciones de borde son $\sigma_{rr}(r_i) = -P_i$ en la superficie interna (la sangre) y $\sigma_{rr}(r_m) = -P_a$ en el radio medial (adventicia y tejido perivascular) (Ec. 10). Integrando la ecuación de equilibrio entre $r_i$ y $r_m$ (Ec. 11 de Masson):

$$\boxed{P_{pared} = P_i - P_a = \int_{r_i}^{r_m} \frac{\sigma_{\theta\theta} - \sigma_{rr}}{r}\, dr}$$

Esta es la curva objetivo. Tiene dos ventajas:

- **No depende de la presión perivascular** $P_a$ (Ec. 12 de Masson), cuyo modelo exponencial ajustado tiene poca base física. Los parámetros $a$ y $b$ de las tablas no intervienen.
- **Es la carga que soporta la pared**, que es lo que el injerto debe reproducir.

**El espesor.** Masson integra entre el radio interno $r_i$ y el medial $r_m$ *medidos* en cada instante para cada sujeto. El artículo no publica esos espesores, de modo que aquí se toma $r_i = r_m - h$ con $h = 0{,}6\,\text{mm}$, un valor típico del espesor íntima–media de la carótida común, igual para todos los sujetos y todos los estiramientos. Es la principal suposición propia del cálculo. Dos consecuencias:

- $P_{pared}$ es aproximadamente proporcional a $h$: con un espesor real mayor, todas las presiones crecerían en la misma proporción y la forma de las curvas no cambiaría.
- Con $h$ fijo en la configuración deformada, el punto material que ocupa la superficie interna varía levemente con el estiramiento. En el rango de trabajo el efecto es chico, porque $\lambda_\theta$ casi no varía a lo largo del espesor (ver el ejemplo).

## 2.5. El cálculo, paso a paso

Para cada sujeto se leen sus 12 parámetros mecánicos y geométricos de la Tabla 2 o 4 de Masson ($R_m$, $\Theta_0$, $\lambda_z$, $c$, $c_1$, $c_2$, $c_1^{circ}$, $c_2^{circ}$, $\alpha$, $T_m$, $\lambda_0$, $\lambda_m$). Luego, para cada uno de los 999 valores $\lambda_\theta$ de la grilla:

1. **Radio medial deformado:** $r_m = \lambda_\theta\, R_{ref}$, con $R_{ref} = \Theta_0 R_m/\pi$.
2. **Radio interno:** $r_i = r_m - h$, con $h = 0{,}6\,\text{mm}$.
3. **Puntos de integración:** 60 radios equiespaciados $r_1 = r_i, \ldots, r_{60} = r_m$.
4. **En cada punto $r_n$:**
   (a) su radio de referencia $R_n = \sqrt{R_m^2 - (\pi\lambda_z/\Theta_0)(r_m^2 - r_n^2)}$;
   (b) el estiramiento circunferencial local $\lambda_{\theta,n} = \pi r_n/(\Theta_0 R_n)$ y el radial $\lambda_{r,n} = 1/(\lambda_{\theta,n}\lambda_z)$;
   (c) el estiramiento de las fibras diagonales $\lambda_{d,n} = \sqrt{\lambda_{\theta,n}^2 \sin^2\alpha + \lambda_z^2 \cos^2\alpha}$;
   (d) la diferencia de tensiones $(\sigma_{\theta\theta} - \sigma_{rr})_n$ con la ley constitutiva.
5. **Integración por la regla del trapecio:** $P_{pared}(\lambda_\theta) \approx \sum_{n=1}^{59} \frac{1}{2}\left[\frac{(\sigma_{\theta\theta}-\sigma_{rr})_n}{r_n} + \frac{(\sigma_{\theta\theta}-\sigma_{rr})_{n+1}}{r_{n+1}}\right](r_{n+1} - r_n)$.

El resultado es el vector $P_{pared}(\lambda_1), \ldots, P_{pared}(\lambda_{999})$ de ese sujeto: su curva objetivo.

**Ejemplo numérico: sujeto NT01 en $\lambda_\theta = 1{,}10$.** Sus parámetros (Tabla 2 de Masson) son $R_m = 4{,}261\,\text{mm}$, $\Theta_0 = 128{,}7°$, $\lambda_z = 1{,}11$, $c = 29{,}82\,\text{kPa}$, $c_1 = 9{,}44\,\text{kPa}$, $c_2 = 14{,}14$, $c_1^{circ} = 16{,}13\,\text{kPa}$, $c_2^{circ} = 15{,}11$, $\alpha = 65{,}74°$, $T_m = 39{,}73\,\text{kPa}$, $\lambda_0 = 0{,}96$ y $\lambda_m = 1{,}70$.

1. $R_{ref} = \Theta_0 R_m/\pi = (2{,}2463 \cdot 4{,}261)/\pi = 3{,}0466\,\text{mm}$, y $r_m = 1{,}10 \cdot 3{,}0466 = 3{,}3513\,\text{mm}$.
2. $r_i = 3{,}3513 - 0{,}6 = 2{,}7513\,\text{mm}$.
3. En la superficie interna, $R(r_i) = 3{,}5315\,\text{mm}$ y $\lambda_\theta(r_i) = 1{,}0896$; a mitad del espesor, $\lambda_\theta = 1{,}0956$; en $r_m$, $R = R_m = 4{,}261\,\text{mm}$ y $\lambda_\theta = 1{,}1000$, con $\lambda_r = 1/(1{,}10 \cdot 1{,}11) = 0{,}819$.
4. En $r_m$, la diferencia de tensiones vale 46,8 kPa: elastina 16,1; colágeno circunferencial 8,0; colágeno diagonal 7,7; tono activo 15,0.
5. Integrando sobre el espesor: $P_{pared} = 8{,}69\,\text{kPa}$ (65 mmHg), de los que la elastina aporta 3,07, el colágeno circunferencial 1,39, el diagonal 1,38 y el tono activo 2,85 kPa.

Repitiendo el cálculo en toda la grilla se obtiene la curva de NT01, que va de 2,17 kPa en $\lambda_\theta = 1{,}02$ a 27,2 kPa en 1,16. La Fig. 1 muestra el integrando para tres estiramientos: a medida que el vaso se dilata, el colágeno circunferencial pasa de no aportar casi nada a dominar.

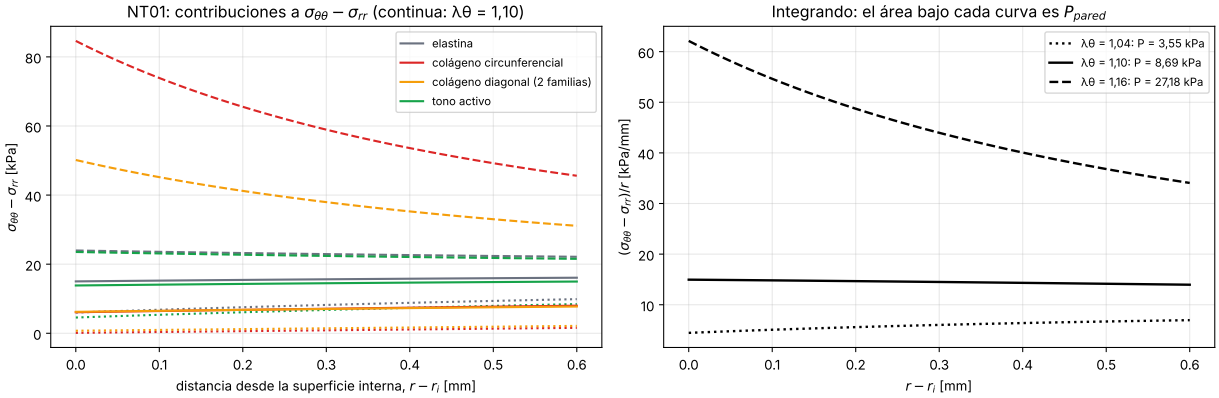



**Figura 1:** Sujeto NT01. Izquierda: contribuciones a $\sigma_{\theta\theta} - \sigma_{rr}$ a lo largo del espesor íntima–media, para $\lambda_\theta = 1{,}04$ (punteado), 1,10 (continuo) y 1,16 (discontinuo). Derecha: el integrando $(\sigma_{\theta\theta} - \sigma_{rr})/r$; el área bajo cada curva es la presión de pared.

### 2.6. Validación

Para verificar la implementación se reconstruyó la tensión circunferencial $\sigma_{\theta\theta}$ en $r_m$ de las curvas medias de las Figs. 5a y 7a del artículo (digitalizadas). Como $\sigma_{rr}(r_m) = -P_a$, a la diferencia $\sigma_{\theta\theta} - \sigma_{rr}$ se le resta el término perivascular $a\,e^b$ de cada sujeto (Ec. 12 de Masson en diástole). El error cuadrático medio entre las curvas reconstruidas y las publicadas es de 0,6 a 0,9 kPa, entre el 1,2 y el 1,7 % de su valor medio: Mean Young 1,7 %, Mean Old 1,5 %, Mean NT 1,2 % y Mean HT 1,4 %. La diferencia es del orden del error de digitalización de las figuras.

Las Figs. 20 y 21 (Apéndice B) muestran, junto a las figuras originales, las presiones de pared de los mismos sujetos.

## 3. Curvas límite y espacio de trabajo

El *espacio de trabajo* son las curvas generadas con la ley de Masson que quedan entre dos curvas límite, $y_1(\lambda) \le y(\lambda) \le y_2(\lambda)$, en todo el dominio. Es el conjunto de arterias para el que se diseña y sobre el que se dan las garantías de la base (Fig. 2).

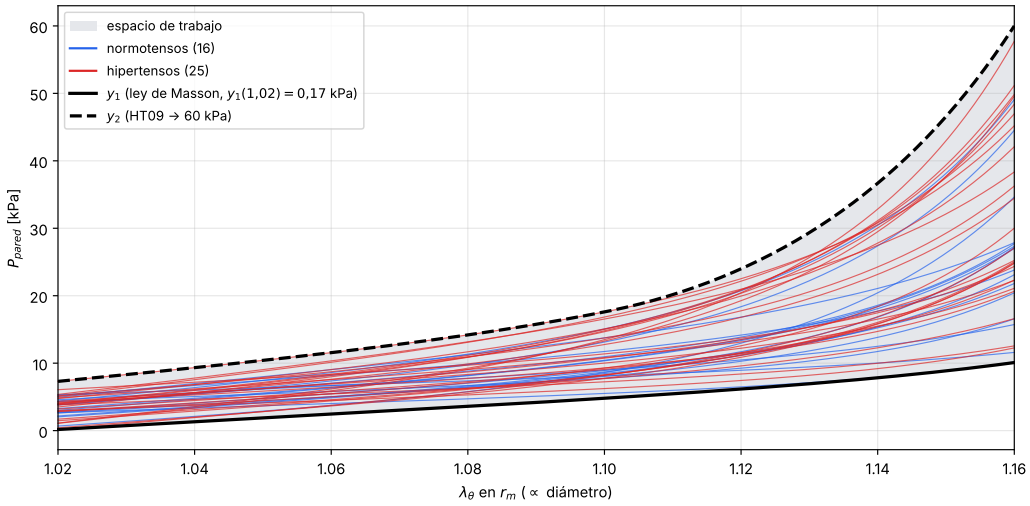



**Figura 2:** Presión de pared de los 41 sujetos de Masson et al. (2011) y curvas límite $y_1$, $y_2$ del espacio de trabajo.

### 3.1. La curva límite superior $y_2$

$y_2$ coincide con la del sujeto más rígido (HT09) hasta $\lambda = 1{,}10$. Desde allí le suma un término con la forma exponencial del colágeno circunferencial de Masson:

$$y_2(\lambda) = P_{HT09}(\lambda) + a\left(e^{\,b\,E^2} - 1\right), \qquad E = \text{máx}\Big(0,\ (\lambda/1{,}10)^2 - 1\Big),$$

con $b = c_2^{circ}$ de HT09 (13,49) y $a = 80{,}2\,\text{kPa}$, elegido para que $y_2(1{,}16) = 60\,\text{kPa}$. Así la franja cubre arterias algo más rígidas que la más rígida medida.

### 3.2. La curva límite inferior $y_1$

**Requisitos.** $y_1$ debe cumplir tres condiciones:

1. **Partir de la menor presión medida en el comienzo del dominio:** $y_1(1{,}02) = \text{mín}_i\, P_i(1{,}02) = 0{,}166\,\text{kPa}$, que corresponde al sujeto HT10.
2. **Pasar por debajo de los 41 sujetos** en todo el dominio.
3. **Ser una curva fisiológica:** calculada con la misma ley de Masson y con parámetros dentro del rango de los 41 sujetos, de modo que tenga la forma de una arteria.

**Por qué importa el valor en $\lambda = 1{,}02$.** El primer material tiene su nudo antes del dominio ($k_1 \approx 0{,}83$) y los demás dentro ($k_2 \approx 1{,}023$, etc.). Por eso en $\lambda = 1{,}02$ solo trabaja el material 1, y el injerto vale ahí

$$P_{injerto}(1{,}02) = c_1\, S_1\, (1{,}02 - k_1) \approx 0{,}73\, c_1 \text{ kPa}.$$

Una curva que arranca en presión casi nula obliga al ajuste a usar $c_1 \approx 0$ o incluso $c_1 < 0$, una lámina negativa, que no es fabricable. Si la curva límite inferior partiera de cero, el espacio de trabajo contendría curvas que ninguna arteria medida presenta y que fuerzan láminas negativas. Fijar $y_1(1{,}02)$ en el mínimo medido deja fuera esas curvas sin excluir a ningún sujeto real.

**Cómo se calcula.** $y_1$ es la presión de pared de un "sujeto sintético" de la ley de Masson:

- **Geometría y fibras de un sujeto real** ($R_m$, $\Theta_0$, $\lambda_z$, $c_2$, $\alpha$, $\lambda_0$, $\lambda_m$).
- **Cinco parámetros libres:** $c$, $c_1$, $c_1^{circ}$, $c_2^{circ}$ y $T_m$, cada uno acotado al rango que toma en los 41 sujetos ($c \in [20{,}4;\ 55{,}3]\,\text{kPa}$, $c_1 \in [6{,}3;\ 40{,}2]\,\text{kPa}$, $c_1^{circ} \in [6{,}4;\ 66{,}9]\,\text{kPa}$, $c_2^{circ} \in [10{,}7;\ 15{,}4]$, $T_m \in [31{,}9;\ 67{,}7]\,\text{kPa}$).

- **Objetivo:** que $y_1$ quede lo más cerca posible de la envolvente inferior de los sujetos, $e(\lambda) = \min_i P_i(\lambda)$, sin cruzarla. Se minimiza

$$\overline{e - y_1} \;+\; 1000 \cdot \max_{\lambda} \max\left(0,\, y_1 - e\right) \;+\; 1000 \cdot \left|y_1(1{,}02) - 0{,}166\right|,$$

  donde la barra indica el promedio sobre la grilla. Los dos términos con peso 1000 actúan como restricciones: cualquier cruce con un sujeto o cualquier apartamiento del valor inicial pesa mucho más que la distancia.

- **Búsqueda:** evolución diferencial (Sección 4.6) sobre los cinco parámetros, repetida con la geometría de cada uno de los 41 sujetos; se conserva la mejor.

**Resultado.** La mejor curva usa la geometría y las fibras de NT16 con $c = 38{,}48\,\text{kPa}$, $c_1 = 6{,}44\,\text{kPa}$, $c_1^{circ} = 6{,}85\,\text{kPa}$, $c_2^{circ} = 10{,}82$ y $T_m = 55{,}06\,\text{kPa}$ (los demás parámetros, los de NT16: $R_m = 5{,}718\,\text{mm}$, $\Theta_0 = 129{,}7°$, $\lambda_z = 1{,}10$, $c_2 = 13{,}46$, $\alpha = 55{,}73°$, $\lambda_0 = 1{,}05$, $\lambda_m = 1{,}77$). La distancia media a la envolvente es 0,60 kPa. Con otras geometrías la distancia es mayor (HT20: 1,14 kPa) o no se logra cumplir las restricciones. Las fibras de colágeno quedan en el extremo blando del rango ($c_1$ y $c_1^{circ}$ cerca de su mínimo), como corresponde a la curva más distensible.

- $y_1(1{,}02) = 0{,}166\,\text{kPa}$, $y_1(1{,}10) = 4{,}80\,\text{kPa}$ e $y_1(1{,}16) = 10{,}09\,\text{kPa}$ (la envolvente vale 5,51 y 10,19 kPa).
- Toca la envolvente solo en $\lambda = 1{,}02$ (en HT10). En el resto del dominio queda por debajo de todos los sujetos: la menor distancia es 0,004 kPa y la mayor, 1,43 kPa, en $\lambda \approx 1{,}067$.
- Es monótona y convexa (forma J). El cuaderno verifica las tres condiciones al ejecutarse.

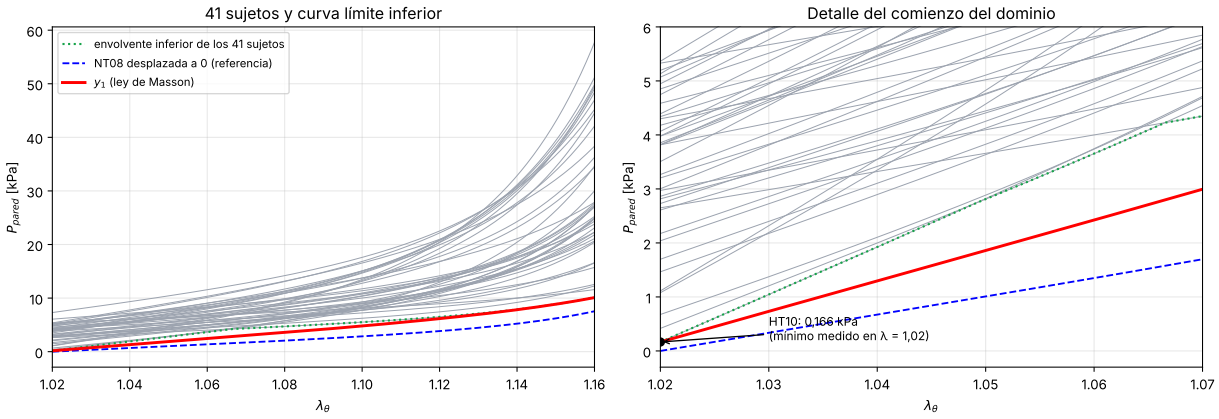



**Figura 3:** Curva límite inferior $y_1$ (rojo): ley de Masson, por debajo de los 41 sujetos (gris) y con $y_1(1{,}02)$ igual a la menor presión medida (HT10). En verde, la envolvente inferior de los sujetos. En azul, como referencia, una curva que parte de cero (NT08 desplazada): admitiría arterias que arrancan sin presión, que no existen entre los sujetos medidos.

## 3.3. El espacio de trabajo

El espacio de trabajo se genera mezclando y perturbando los parámetros de los 31 sujetos de entrenamiento (detalle en la Sección 5):

- **constitutiva** (10 000 curvas): ley de Masson con una mezcla de 2–3 sujetos, perturbación moderada de los parámetros y amplitud entre 0,85 y 1,20;
- **amplia** (7 500): igual, con 2–4 sujetos, perturbaciones mayores, extrapolación desde el centro de la población y amplitud entre 0,65 y 1,50;
- **uniforme** (5 000): cada parámetro independiente, uniforme entre el mínimo y el máximo de los sujetos de entrenamiento.

Cada curva se acepta solo si es positiva, monótona, convexa desde $\lambda = 1{,}05$, no supera 1,5 veces la presión máxima de los sujetos y queda dentro de $y_1$–$y_2$. Se aceptan el 95,5, el 80,4 y el 87,5 % de las curvas sorteadas, respectivamente. El resultado son 22 500 curvas. En $\lambda = 1{,}16$ sus presiones van de 11,4 kPa (*percentil 1*: el 1 % de las curvas queda por debajo) a 60,0 kPa, con mediana de 26,0 kPa. Los 41 sujetos están dentro de la franja.

### 3.4. Comportamiento fuera del dominio

La extrapolación del injerto se muestra solo como información (Fig. 4). Más allá de 1,16 el injerto es lineal, y en $\lambda = 1{,}20$ da entre la mitad y el 60 % de la presión que predice la ley (NT08: 15,3 frente a 25,6 kPa; Mean HT: 57,2 frente a 114,8 kPa; HT09: 77,8 frente a 149,1 kPa). Hacia $\lambda$ bajo, el injerto tiende a cero sin volverse negativo, mientras que la ley da presiones negativas por el tono activo. Si se quisiera un tope de dilatación ante sobrepresiones, la alternativa que no depende de extrapolar la ley es un material "freno" con nudo cerca de 1,16, con su número de láminas fijado por un criterio de seguridad explícito.

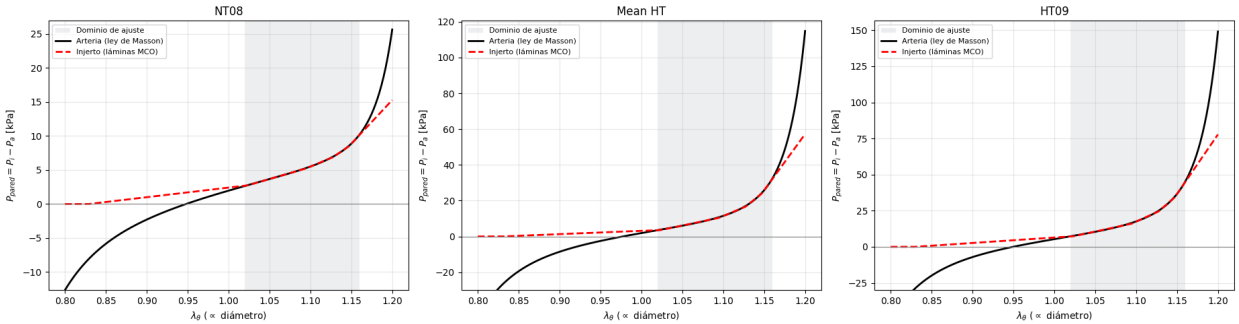



**Figura 4:** Injerto (láminas MCO ajustadas en [1,02; 1,16], sombreado) frente a la ley de Masson fuera del dominio de ajuste, para NT08, la media de los hipertensos y HT09.

## 4. Elección óptima de la base: nudos y pendientes

**Objetivo.** Elegir la base apropiada (la posición de los nudos $k_1, \ldots, k_N$ y las pendientes $S_1, \ldots, S_N$) para que el ajuste de cualquier curva del espacio de trabajo pueda hacerse por MCO **sin condiciones**: sin cotas ni restricciones sobre las láminas y sin regularización.

- Con una base así, el ajuste es la fórmula cerrada $c = A^{+}y$: exacta, única e instantánea, y es lo que la red aprende a reproducir.
- Toda la exigencia se traslada a la elección de la base, que se hace una sola vez.

Para que el ajuste libre sea aceptable, la base debe garantizar tres propiedades en todo el espacio de trabajo:

1. **Precisión:** toda curva se ajusta con error punto a punto $\leq 3$ %.
2. **Estabilidad:** cond$(A)$ acotado, para que pequeños errores en la curva no produzcan grandes cambios en las láminas.
3. **Signo:** las láminas que da el MCO libre resultan $\geq 0$, es decir, fabricables. El MCO no impone el signo; es la base la que debe hacer que salga positivo.

Las tres dependen solo de los **nudos**: las pendientes fijan la escala de cada lámina, pero no cambian el ajuste ni el signo (Sección 4.9). Por eso la elección se hace en dos etapas: primero los nudos, con una calificación $J(k)$ que reúne las tres propiedades (Secciones 4.5 a 4.8); después las pendientes (Sección 4.9). Esta sección explica ambas desde cero y paso a paso; es lo que hace la Celda 3 del cuaderno.

**Dos problemas distintos: las láminas (MCO) y los nudos (búsqueda numérica)**

El diseño tiene dos tipos de incógnitas, que se resuelven con métodos distintos:

1. **Las láminas $c_j$, con los nudos fijos.** La curva del injerto depende de las láminas en forma *lineal*. Por eso el mejor ajuste se obtiene con **mínimos cuadrados ordinarios (MCO)**, que dan una solución exacta mediante una fórmula cerrada (Sección 4.2). Se resuelve una vez por cada curva arterial, y es lo que la red aprende a reproducir.
2. **Los nudos $k_j$.** La curva depende de los nudos en forma *no lineal* (a través de $\max(0, \lambda - k_j)$), y no hay fórmula para el mejor juego de nudos. Se busca numéricamente en dos etapas (Sección 4.6):
   - una **búsqueda global** con el método de **evolución diferencial**, que explora todo el rango permitido con una población de juegos de nudos;
   - un **refinamiento local** con el método de **Nelder–Mead**, que parte del mejor juego hallado y lo ajusta fino.

   Se resuelve una sola vez, al construir las bases.

Los métodos trabajan anidados. La búsqueda de nudos es el *lazo exterior*: propone un juego de nudos. El MCO es el *lazo interior*: con esos nudos, ajusta todas las curvas y devuelve sus errores y sus láminas, con los que se calcula $J$ y la búsqueda decide qué probar después.
**Ni la evolución diferencial ni Nelder–Mead son métodos de mínimos cuadrados**: son métodos para buscar el mínimo de una función que solo se sabe evaluar.
**Sobre las restricciones.** El signo de las láminas se exige *al elegir la base*, no *en el ajuste*. El ajuste de cada curva es siempre $c = A^{+}y$, sin ninguna condición; si a una curva le correspondiera una lámina negativa, el MCO la daría negativa. La base está elegida para que, en todo el espacio de trabajo, eso no ocurra.

## 4.1. Qué es una base

Cada base representa *una lámina* de un material. Se idealiza como una *línea truncada*:

$$A_j(\lambda) = S_j \ \max(0,\ \lambda - k_j), \qquad j = 1, \ldots, N.$$

- **El nudo** $k_j$ (*knot* en inglés) es el estiramiento en el que se tensan las fibras de ese material. Mientras $\lambda < k_j$, la lámina está floja y no aporta presión.
- **La pendiente** $S_j$ [kPa por unidad de $\lambda$] es la presión que aporta una lámina por cada unidad de estiramiento adicional, una vez tensa. Depende de la rigidez y el espesor de la lámina.

El injerto superpone $c_j$ láminas de cada material, y su presión es la suma:

$$P_{injerto}(\lambda) = \sum_{j=1}^{N} c_j \, A_j(\lambda),$$

que es una *poligonal*: una sucesión de tramos rectos que se quiebran en cada nudo. En cada quiebre la pendiente aumenta, porque entra en carga un material nuevo. $c_j$ es un número real, porque el espesor de cada capa puede variar en forma continua. La Fig. 5 muestra las 5 bases adoptadas.

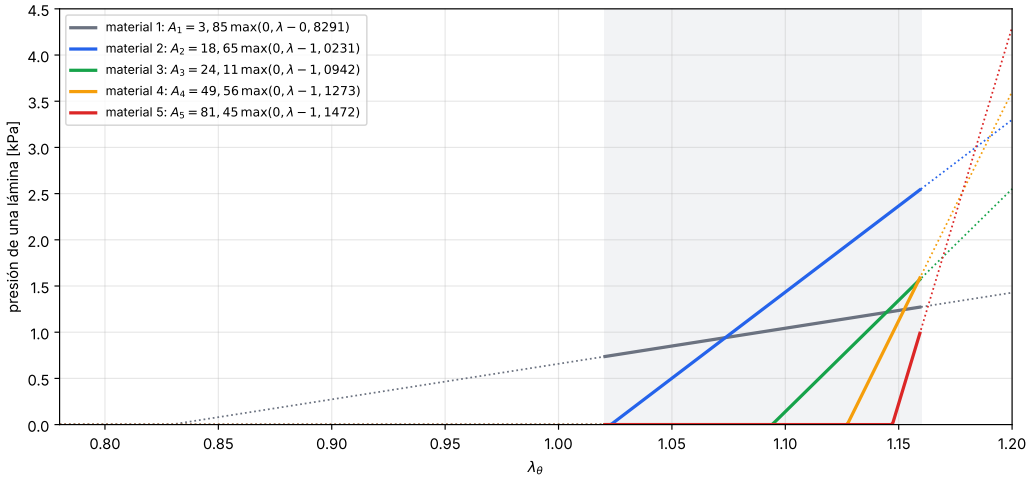



**Figura 5:** Una lámina de cada material ($C_{LAM} = 10$). Continua: dominio de ajuste (sombreado); punteada: la misma fórmula fuera de él.

## 4.2. El ajuste por mínimos cuadrados

Dada una curva arterial $y(\lambda)$ y los nudos, el número de láminas $c = (c_1, \ldots, c_N)$ se obtiene por mínimos cuadrados ordinarios:

$$c = A^{+}y = \arg\min_{c} \sum_{i=1}^{999} \big(y(\lambda_i) - (Ac)(\lambda_i)\big)^2,$$

donde $A$ es la matriz de $999 \times N$ cuyas columnas son las bases evaluadas en los 999 puntos de la grilla.

**Qué son los mínimos cuadrados ordinarios (MCO).** Se eligen las láminas $c$ que hacen mínima la suma de los cuadrados de las diferencias entre la curva arterial y la del injerto, punto por punto de la grilla. Como la curva del injerto es lineal en $c$ y las columnas de $A$ son linealmente independientes, el mínimo es único y tiene solución exacta:

$$c = (A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}y \equiv A^{+}y.$$

$A^{+}$ es la **pseudoinversa** (de Moore–Penrose) de $A$. En la práctica se calcula con la descomposición en valores singulares, que es numéricamente más estable (Trefethen y Bau, 1997, Lecturas 11–12; Lawson y Hanson, 1974).

**El MCO elige las láminas; los nudos se eligen antes, una sola vez, para todas las curvas.**

**Por qué importa dónde están los nudos.** Una poligonal solo puede doblarse donde tiene quiebres. La curva J arterial es suave y se curva cada vez más hacia $\lambda$ alto. Si los quiebres están mal ubicados (por ejemplo, equiespaciados), la poligonal no puede seguir la curvatura del final. La Fig. 6 lo muestra con la curva media de los hipertensos (Mean HT):

- **Con los nudos adoptados**, el error máximo es 1,31 % del rango.
- **Con 5 nudos equiespaciados** es 7,93 %. Sobre las 22 500 curvas del espacio de trabajo, el peor 1 % pasa de 1,72 % a 11,54 %, y solo el 0,2 % de las curvas cumple el 3 %.

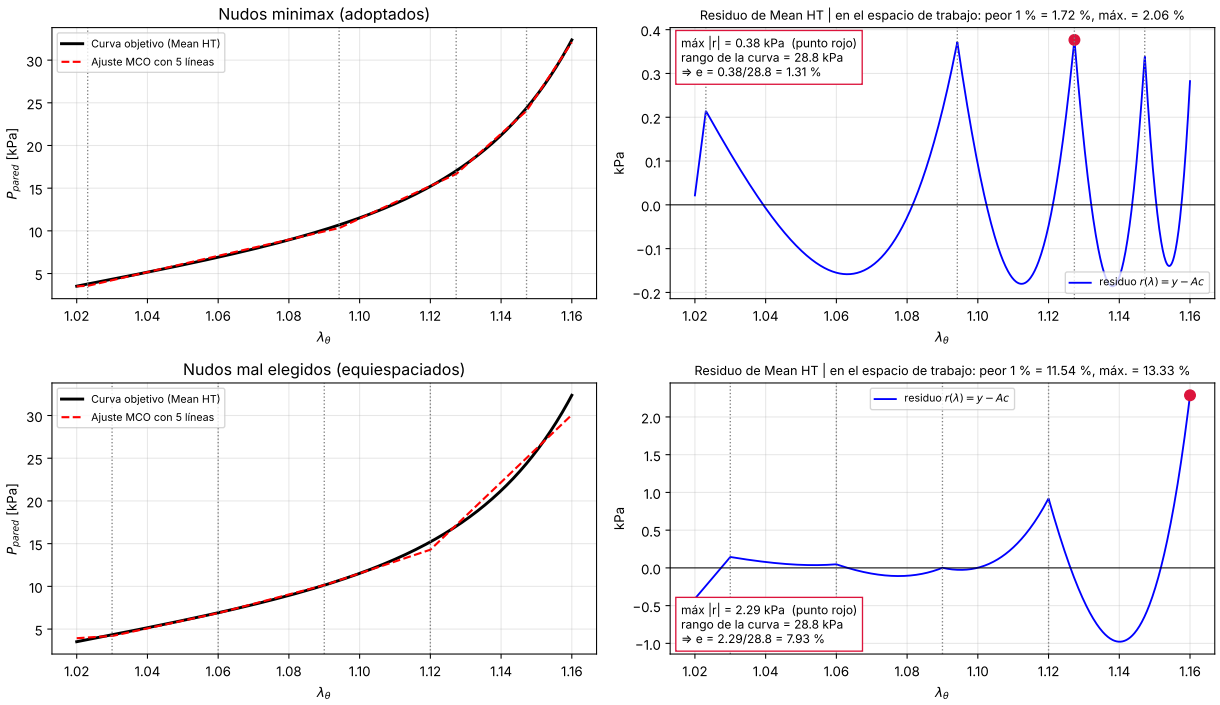



**Figura 6:** La misma curva (Mean HT) ajustada con 5 líneas truncadas por MCO, con dos juegos de nudos (líneas punteadas verticales). Arriba, los nudos adoptados; abajo, nudos equiespaciados. A la derecha, el residuo y su máximo (punto rojo). Con los mismos 5 materiales, el error cambia por un factor 6 según dónde se quiebre la poligonal.

## 4.3. Visión general del procedimiento

Elegir la base es un proceso en cinco etapas:

1. **Rango de búsqueda** (Sección 4.4): se fija entre qué valores puede estar cada nudo.
2. **Calificación** (Sección 4.5): para un juego de nudos se calcula un único número, $J(k)$. Mide qué tan bien ajusta el MCO a las *peores* curvas del espacio de trabajo, y penaliza si $\mathrm{cond}(A)$ es grande o si aparece alguna lámina negativa. Cuanto menor es $J$, mejor es la base. Este es el **criterio minimax**: *qué* se considera una buena base.
3. **Búsqueda** (Sección 4.6): la evolución diferencial prueba miles de juegos de nudos en todo el rango, quedándose siempre con los mejores, hasta que la población deja de mejorar; Nelder–Mead refina el mejor. Este es el **método**: *cómo* se encuentra la mejor base. La Sección 4.7 justifica la elección de este método frente a otros.
4. **Pendientes** (Sección 4.9): con los nudos fijos, se calcula la pendiente de una lámina de cada material.
5. **Verificación** (Secciones 4.8, 4.10 y 4.11): que el resultado no dependa del azar de la búsqueda, y que la base final cumpla precisión, estabilidad y signo en las 22 500 curvas y en los 41 sujetos.

## 4.4. Rango de búsqueda y ubicación de los nudos

La evolución diferencial (Sección 4.6) no necesita un punto de partida elegido a mano: solo necesita el **rango** en que puede estar cada nudo, y dentro de él sortea su población inicial. El rango es:

- **primer nudo:** $k_1 \in [0{,}60;\ 0{,}98]$, es decir, *antes* del dominio [1,02; 1,16]. Así, el primer material ya está en carga en todo el dominio y aporta la pendiente inicial de la curva. El

límite inferior 0,60 evita nudos absurdos (fibras que se tensan con el vaso reducido a menos de dos tercios de su radio de referencia);

- **demás nudos:** $k_j \in [1{,}00;\ 1{,}156]$, $j = 2, \ldots, N$. El tope $1{,}156 = 1{,}16 - 0{,}004$ asegura que cada material tenga al menos unos 28 puntos de la grilla donde actuar.

Además se exige que dos nudos consecutivos estén separados al menos 0,004 (Paso 6).

**Dónde terminan los nudos, y por qué.** La Tabla 2 muestra los nudos que resultan de la búsqueda. En los tres casos siguen el mismo patrón:

- **Los nudos se juntan hacia $\lambda$ alto.** La curva J arterial es casi recta al comienzo del dominio y se curva cada vez más hacia $\lambda = 1{,}16$. Una poligonal solo puede doblarse en sus nudos, así que necesita más quiebres, y más próximos entre sí, donde la curvatura es mayor. Con 5 bases, las separaciones entre nudos consecutivos dentro del dominio son 0,071; 0,033 y 0,020: cada una es aproximadamente la mitad de la anterior.
- **El primer nudo queda cerca de 0,83**, bien antes del dominio. Su posición casi no influye en el error de ajuste, pero sí en el signo de las láminas (Paso 5).

Este patrón sirve como intuición y para controlar el resultado, pero el método no lo usa: la búsqueda lo encuentra sola desde un sorteo en todo el rango.

**Tabla 2:** Rango de búsqueda y nudos que resultan del método, para 4, 5 y 6 bases. Con 5 bases son los nudos con los que se entrenó la red.

| Bases | Nudos |
|---|---|
| 4 | 0,834; 1,0264; 1,108; 1,1416 |
| 5 | 0,8291; 1,0231; 1,0942; 1,1273; 1,1472 |
| 6 | 0,8271; 1,0219; 1,0867; 1,1197; 1,1391; 1,1531 |
| Rango | $k_1 \in [0{,}60;\ 0{,}98]$; $k_2, \ldots, k_N \in [1{,}00;\ 1{,}156]$ |

## 4.5. El criterio minimax: cómo se califica un juego de nudos

Los Pasos 1 a 6 definen cómo se calcula $J(k)$ para un juego de nudos $k$ *cualquiera*: cualquiera de los que propone la búsqueda. En los ejemplos se usan los nudos adoptados, $k = (0{,}8291;\ 1{,}0231;\ 1{,}0942;\ 1{,}1273;\ 1{,}1472)$, que son el resultado final del procedimiento, para mostrar números concretos.

### 4.5.1. Paso 1: el error de *una* curva

Para unos nudos $k$ dados y una curva $y$:

1. Se calculan las láminas por MCO: $c = A^{+}y$.
2. Se calcula el residuo en cada punto: $r(\lambda_i) = y(\lambda_i) - (Ac)(\lambda_i)$, en kPa.
3. Se toma el mayor residuo en valor absoluto y se lo divide por el rango de la curva:

$$e(y;k) = \frac{\max_i |r(\lambda_i)|}{\max_i y(\lambda_i) - \min_i y(\lambda_i)} \times 100 \quad [\,\%].$$

**Ejemplo numérico** (Fig. 6, arriba). El residuo máximo de Mean HT es 0,377 kPa, en $\lambda \approx 1{,}127$, sobre el nudo 4. La curva va de 3,52 a 32,37 kPa, un rango de 28,85 kPa. Entonces $e = 0{,}377/28{,}85 = 1{,}31$ %.

Este es exactamente el **criterio de diseño**: una curva cumple si $e \leq 3$ %. Se divide por el rango para que el criterio sea igual de exigente con una arteria blanda (rango de 10 kPa) que con una rígida (rango de 60 kPa). Medido en kPa, el ajuste quedaría dominado por las curvas rígidas.

**Otra medida de error: el NRMSE.** Además del error máximo $e$ se usa el *error cuadrático medio normalizado*:

$$\mathrm{NRMSE} = \frac{\sqrt{\frac{1}{999}\sum_{i=1}^{999} r(\lambda_i)^2}}{\max y - \min y} \times 100\ [\%].$$

$e$ mide el peor punto de la curva; el NRMSE mide el error típico a lo largo de toda la curva. Siempre NRMSE $\leq e$.

### 4.5.2. Paso 2: de una curva a la población

Los nudos no se eligen para una arteria, sino para *todas* las del espacio de trabajo. Fijados los nudos, cada curva $y_i$ tiene su error $e_i = e(y_i; k)$. Con 22 500 curvas hay 22 500 errores. La Fig. 7 muestra su histograma para los nudos adoptados:

- la mayoría de las curvas tiene error cercano a 1,2 % (media 1,22 %, mediana 1,23 %);
- el peor 1 % (225 curvas, en rojo) está entre 1,65 % y 2,06 %;
- ninguna curva supera el 3 %.

¿Qué número resume este histograma para decidir si unos nudos son mejores que otros?

- **La media no sirve**: unos nudos podrían ajustar muy bien la mayoría de las curvas y muy mal unas pocas. Esas pocas no cumplirían el criterio, y la media no lo mostraría.
- Como el criterio es "*toda* curva con $e \leq 3$ %", lo que importa es la **cola derecha** del histograma: las peores curvas. De ahí el nombre *minimax*: **mini**mizar el **máx**imo error.

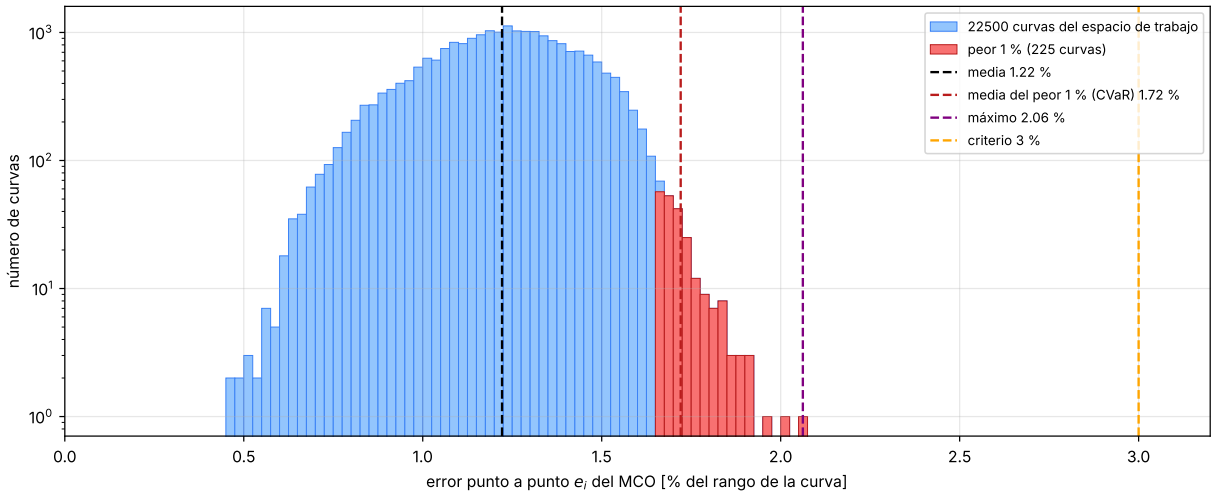



**Figura 7:** Error punto a punto del MCO con los nudos adoptados en las 22 500 curvas del espacio de trabajo (escala vertical logarítmica). En rojo, el peor 1 %. El método minimax actúa sobre esa cola.

### 4.5.3. Paso 3: por qué la media del peor 1 % y no el máximo

El paso anterior dejó establecido que, para comparar dos juegos de nudos, hay que mirar las curvas peor ajustadas. Este paso define con exactitud *qué número* se calcula a partir de esas curvas y justifica la elección.

**(a) El conjunto de curvas de optimización** Durante la búsqueda de los nudos, la función objetivo se evalúa miles de veces, y cada evaluación requiere resolver un ajuste MCO por curva. Para el error de ajuste no se usan las 22 500 curvas del espacio de trabajo sino un **conjunto de optimización** de $n = 2532$ curvas, formado por:

| Componente | Curvas |
|---|---|
| Muestra al azar del espacio de trabajo (con semilla fija, siempre la misma muestra) | 2500 |
| Sujetos de entrenamiento de Masson (los 31, todos dentro de la franja $y_1$–$y_2$) | 31 |
| Curva límite $y_2$ (la más rígida y exigente) | 1 |
| **Total** ($n$) | **2532** |

- **Semilla fija:** la *semilla* es el número con que se inicializa el generador de números aleatorios de la computadora. Con la misma semilla, el sorteo da siempre las mismas 2500 curvas, de modo que el resultado es reproducible.
- **Los sujetos reales y $y_2$ se incluyen siempre**, para que nunca queden fuera de la muestra.
- **Los 10 sujetos de test no se incluyen**: la elección de los nudos no los "ve", y por eso sirven después para evaluar el método sin sesgo.
- **Grilla:** para el error, cada curva se evalúa en 500 puntos (uno de cada dos de la grilla de 999), también por velocidad. Todos los números de este Paso 3 están calculados así.
- **No confundir con el Paso 2:** el histograma de la Fig. 7 usa las 22 500 curvas completas, y allí el peor 1 % son 225 curvas. En la optimización se usa este conjunto de 2532 curvas, y el peor 1 % son 25. El criterio es el mismo (el 1 % de mayor error); cambia solo el conjunto sobre el que se calcula.
- **El signo se evalúa en todo el espacio:** a diferencia del error, el término de signo del Paso 5 usa las 22 500 curvas en los 999 puntos, porque se exige que *ninguna* curva dé láminas negativas.
- **Verificación final:** una vez elegidos los nudos, el resultado se verifica con las 22 500 curvas completas y los 999 puntos. De ahí salen los valores de la Sección 4.10. Por eso pueden diferir levemente de los de este punto: por ejemplo, el error de $y_2$ con los nudos adoptados es 2,19 % en 500 puntos y 2,25 % en 999.

**(b) Cómo se calcula la media del peor 1 % (CVaR 99 %), paso a paso** Se parte de un juego de nudos $k = (k_1, \ldots, k_5)$ fijo; por ejemplo, los adoptados.

1. **Ajustar cada curva.** A cada una de las 2532 curvas $y_i$ se le calcula su ajuste MCO con esos nudos, $c_i = A^+ y_i$.
2. **Medir el error de cada curva.** Para cada curva se calcula su error punto a punto relativo al rango (Paso 1):

$$e_i = \frac{\max_\lambda |y_i(\lambda) - (Ac_i)(\lambda)|}{\max_\lambda y_i - \min_\lambda y_i} \times 100 \;\; [\,\%], \qquad i = 1, \ldots, 2532.$$

   El resultado es una lista de 2532 números, uno por curva.
3. **Ordenar la lista de mayor a menor.** Se reordenan los errores de modo que el primero sea el más grande:

$$e_{(1)} \;\geq\; e_{(2)} \;\geq\; \cdots \;\geq\; e_{(2532)}.$$

   El subíndice entre paréntesis indica el *puesto* en ese ranking: $e_{(1)}$ es el error de la curva peor ajustada, $e_{(2)}$ el de la segunda peor, y $e_{(2532)}$ el de la mejor ajustada.
4. **Contar cuántas curvas forman el "peor 1 %".** Es $m = \lfloor n/100 \rfloor = \lfloor 2532/100 \rfloor = 25$ curvas, donde $\lfloor \cdot \rfloor$ es la parte entera.
5. **Promediar los errores de esas $m$ curvas,** es decir, los de los puestos 1 a 25:

$$\mathrm{CVaR}_{99}(k) = \frac{1}{m} \sum_{p=1}^{m} e_{(p)} = \frac{e_{(1)} + e_{(2)} + \cdots + e_{(25)}}{25}.$$

El nombre CVaR (*conditional value at risk*, valor en riesgo condicional) proviene de la gestión de riesgo financiero. Allí mide la pérdida media en el peor 1 % de los escenarios (Rockafellar y Uryasev, 2000); aquí los "escenarios" son las curvas y la "pérdida" es el error de ajuste.

La Tabla 3 muestra el ranking real con los nudos adoptados, y la Fig. 8 lo grafica completo.

**Tabla 3:** Ranking de las 2532 curvas del conjunto de optimización según su error punto a punto, con los nudos adoptados (500 puntos). Las "sintéticas" se identifican por su índice dentro de las 22 500 del espacio de trabajo.

| Puesto $p$ | Curva | Error $e_{(p)}$ |
|---:|---|---:|
| 1 | curva límite $y_2$ | 2,19 % |
| 2 | sintética n.º 22231 | 1,80 % |
| 3 | sintética n.º 20218 | 1,80 % |
| 4 | sintética n.º 19476 | 1,78 % |
| 5 | sintética n.º 19458 | 1,78 % |
| ⋮ | ⋮ | ⋮ |
| 25 | sintética n.º 17190 | 1,65 % |
| 26 | sintética n.º 19385 | 1,64 % |
| ⋮ | ⋮ | ⋮ |
| 1267 (mitad) | sintética n.º 1798 | 1,20 % |
| ⋮ | ⋮ | ⋮ |
| 2532 (última) | sintética n.º 17465 | 0,48 % |
| **CVaR 99 %** = promedio de los puestos 1 a 25 | | **1,72 %** |
| Máximo = error del puesto 1 | | 2,19 % |
| Promedio de las 2532 curvas | | 1,19 % |

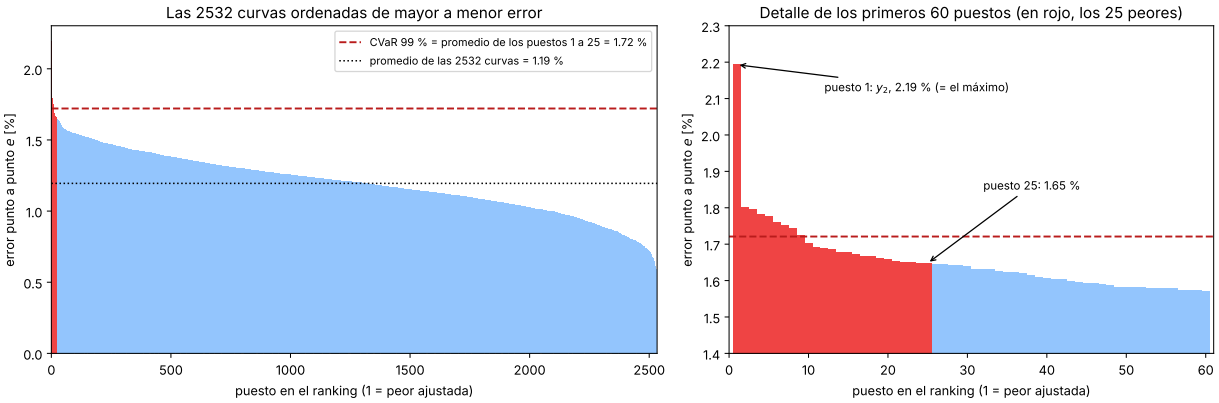



**Figura 8:** Izquierda: errores de las 2532 curvas del conjunto de optimización, ordenados de mayor a menor (una barra por curva). Derecha: detalle de los primeros 60 puestos; en rojo, los 25 que forman el peor 1 %. La línea discontinua roja es su promedio (CVaR 99 %); la punteada negra, el promedio de todas las curvas.

**Cómo se lee.**

- La curva peor ajustada es $y_2$, con 2,19 %.
- Las 25 peores tienen errores entre 1,65 y 2,19 %, y su promedio, el CVaR, es 1,72 %.
- Ninguno de los 31 sujetos reales está entre esas 25: todos ajustan mejor que la cola.
- La mitad de las curvas tiene error menor que 1,20 %.

Por construcción, $e_{(1)} \geq \text{CVaR}_{99} \geq e_{(25)}$: el CVaR nunca supera al máximo y nunca es menor que el error del puesto 25.

**(c) Las dos alternativas: el máximo o el CVaR** Ambas miden la cola de peores casos, que es lo que importa para el criterio de diseño (Paso 2):

- **El máximo** es $e_{(1)}$, el error de *una sola* curva, la peor. Minimizarlo es el minimax "puro".
- **El CVaR 99 %** es el promedio de las 25 peores. Sigue siendo una medida de peor caso, porque las 2507 curvas restantes no intervienen, pero no depende de una curva sola.

Para decidir entre las dos se hizo el siguiente experimento.

**(d) El experimento: mover un solo nudo**

1. Se fijan cuatro nudos en sus valores adoptados: $k_1 = 0{,}8291$, $k_2 = 1{,}0231$, $k_3 = 1{,}0942$ y $k_5 = 1{,}1472$.
2. El nudo 4 se prueba en 140 posiciones equiespaciadas entre $k_4 = 1{,}112$ y $k_4 = 1{,}141$.
3. En cada posición se calculan los 2532 errores $e_i$ (como en el apartado b) y se registran tres cosas:

   (I) el máximo $e_{(1)}$;

   (II) *cuál* es la curva que ocupa el puesto 1;

   (III) el CVaR 99 %.

La Fig. 9 muestra el máximo (violeta) y el CVaR (rojo) en función de $k_4$.

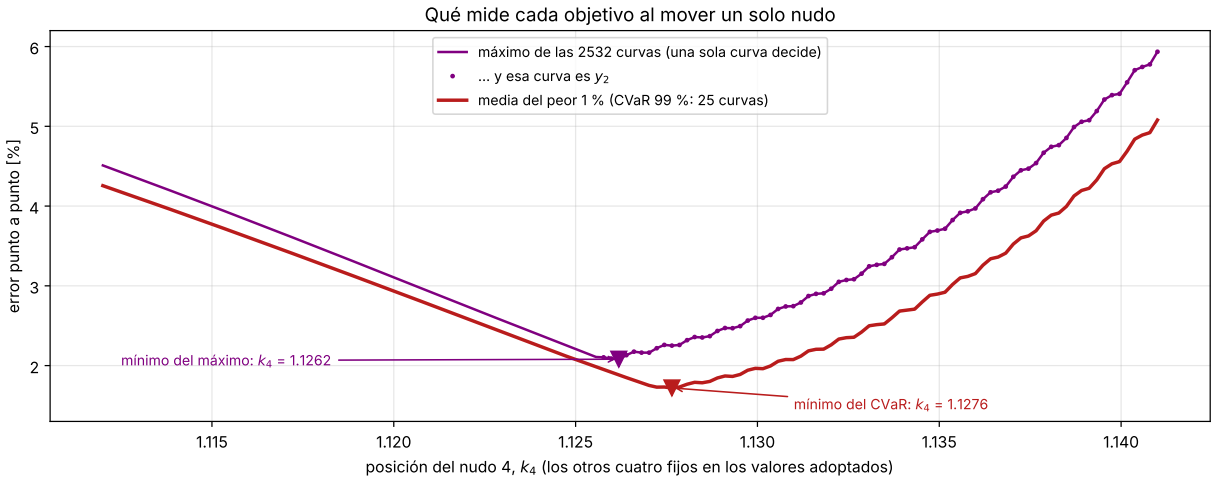



**Figura 9:** Experimento del apartado (d): al mover el nudo 4 con los demás fijos, error de la peor curva (violeta) y promedio de las 25 peores (CVaR 99 %, rojo). Los puntos violeta marcan las posiciones en que la peor curva es $y_2$. Los triángulos marcan el mínimo de cada criterio. Las pequeñas ondulaciones vienen de la discretización: cuando $k_4$ cruza un punto de la grilla, el quiebre de la poligonal pasa a otro intervalo.

**(e) Resultados del experimento** **1. En la zona del óptimo, el máximo es el error de una sola curva, $y_2$.** En 74 de las 140 posiciones (53 %), la curva del puesto 1 es $y_2$. Esto ocurre en todas las posiciones con $k_4 \geq 1{,}1258$, que es justamente la zona donde están los óptimos. Ahí el máximo de las 2532 curvas es, literalmente, el error de $y_2$: las otras 2531 curvas no influyen en ese número. Minimizar el máximo equivale, en esa zona, a elegir $k_4$ para que $y_2$ ajuste lo mejor posible.

**2. Los dos criterios eligen nudos distintos.** La Tabla 4 compara los dos óptimos del experimento y los nudos adoptados.

**Tabla 4:** Comparación de los criterios en el experimento del apartado (d) (500 puntos). La última columna son los nudos adoptados, que surgen de optimizar los cinco nudos a la vez.

| | Mínimo del máximo | Mínimo del CVaR | Nudos adoptados |
|---|---|---|---|
| $k_4$ | 1,1262 | 1,1276 | 1,1273 |
| Puesto 1: error de $y_2$ | **2,08 %** | 2,25 % | 2,19 % |
| Puesto 2: segunda peor curva | 2,00 % | 1,78 % | 1,80 % |
| Promedio de los puestos 1 a 25 (CVaR) | 1,89 % | **1,72 %** | 1,72 % |
| Promedio de las 2532 curvas | 1,21 % | 1,22 % | 1,19 % |

Con el criterio del máximo, $y_2$ baja de 2,25 % a 2,08 %, pero la segunda peor curva sube de 1,78 a 2,00 % y el promedio de las 25 peores sube de 1,72 % a 1,89 %. Es decir, **se mejora una curva a costa del resto de la cola**. El promedio de todas las curvas prácticamente no cambia: la diferencia entre los criterios está solo en la cola. El CVaR acepta que $y_2$ quede algo peor a cambio de que mejoren las 25 peores en conjunto.

**3. El máximo tiene un mínimo anguloso.** El máximo es, en cada posición de $k_4$, el mayor de 2532 errores, y cada uno de ellos varía de forma aproximadamente suave con $k_4$ (salvo las pequeñas ondulaciones de la discretización).

- A la izquierda del óptimo ($k_4 < 1{,}1258$), la peor curva es otra, cuyo error *baja* al aumentar $k_4$.
- A la derecha, la peor es $y_2$, cuyo error *sube* al aumentar $k_4$.

El mínimo del máximo cae justo donde esas dos curvas intercambian el puesto 1, y en ese punto la pendiente cambia de signo bruscamente: el gráfico tiene forma de "V", con un quiebre sin derivada. El CVaR, al promediar 25 curvas, suaviza esos quiebres.

**(f) Conclusión** Se adopta el CVaR 99 % como medida de la cola por tres razones:

1. No depende de una sola curva: reparte el criterio entre las 25 peores.
2. Sigue siendo un criterio de peor caso: solo cuentan las curvas de la cola.
3. Es más suave que el máximo, lo que facilita la búsqueda.

Con cualquiera de los dos criterios, todas las curvas quedan lejos del 3 %: la elección afecta la robustez del diseño, no su cumplimiento.

### 4.5.4. Paso 4: el número de condición, cond$(A)$

Sin ninguna restricción, la búsqueda tendería a *juntar* nudos en la zona de mayor curvatura, cerca de 1,16, porque más quiebres juntos siguen mejor la curva. Esto tiene un costo.

**Qué mide cond$(A)$.** Se normaliza cada columna de $A$ para que su máximo valga 1 y se calculan sus **valores singulares** $s_1 \geq \cdots \geq s_N \geq 0$. Toda matriz se puede escribir como $A = U\Sigma V^{\mathsf{T}}$ (descomposición en valores singulares, SVD), donde $\Sigma$ es diagonal y sus elementos son los $s_j$. Cada $s_j$ es el factor por el que la matriz estira un vector en una dirección principal: $s_1$ es el mayor estiramiento y $s_N$ el menor. Un $s_N$ muy chico indica que existe una combinación de columnas que la matriz casi anula (Trefethen y Bau, 1997, Lecturas 4, 5 y 12). Entonces

$$\text{cond}(A) = s_1/s_N.$$

Si dos columnas se parecen mucho (dos nudos muy próximos dan dos rampas casi iguales), una combinación de ellas casi se anula, $s_N$ se hace chico y cond$(A)$ crece. La normalización hace que cond$(A)$ dependa solo de los nudos, no de las pendientes ni de $C_{LAM}$.

**Por qué importa.** El MCO resuelve $c = A^{+}y$. Un error $\delta y$ en la curva (ruido de medición, o la diferencia entre la arteria real y el modelo) produce un error en las láminas acotado por

$$\frac{\|\delta c\|}{\|c\|} \lesssim \operatorname{cond}(A)\, \frac{\|\delta y\|}{\|y\|}.$$

Con $\operatorname{cond}(A)$ grande, ruidos chicos en la curva dan cambios grandes en las láminas: por ejemplo $+3$ láminas de un material y $-3$ del vecino, que casi se cancelan en la curva. Ese diseño no es confiable para fabricar. Además, a la red le cuesta aprender una función tan sensible.

La Fig. 10 lo muestra acercando $k_5$ a $k_4$:

- **cond$(A)$:** con la separación adoptada ($k_5 - k_4 = 0{,}0199$) vale 18,0. Llega al umbral 25 con una separación de 0,0121, y con 0,0005 vale 541.
- **Láminas (panel derecho):** un ruido de 0,1 kPa en la curva produce un desvío de 0,032 láminas con los nudos adoptados, y de 0,72 láminas con los nudos casi pegados.
- **El otro extremo:** separar demasiado $k_5$ también empeora. El nudo del material 5 queda tan cerca de 1,16 que casi no tiene puntos donde actuar.

**Cómo se impone en la optimización.** Se suma una penalización:

$$\mathrm{pen}_{\mathrm{cond}}(k) = 50 \cdot \max\left(0,\ \operatorname{cond}(A) - (\texttt{UMBRAL_COND} - 1)\right).$$

Vale cero mientras $\operatorname{cond}(A) < 24$ (con el umbral por defecto, 25). Pasado 24, cada décima de $\operatorname{cond}(A)$ suma 5 puntos al objetivo, mucho más que cualquier mejora posible del error, que es del orden de 0,1 puntos. En la práctica funciona como una **restricción**: el óptimo nunca pasa de 24. El margen de una unidad garantiza que $\operatorname{cond}(A) < 25$ estrictamente, que es lo que verifica la Celda 3. Con 6 bases la restricción queda *activa*: el óptimo sin restricción juntaría más los nudos, y queda exactamente en $\operatorname{cond}(A) = 24{,}0$.

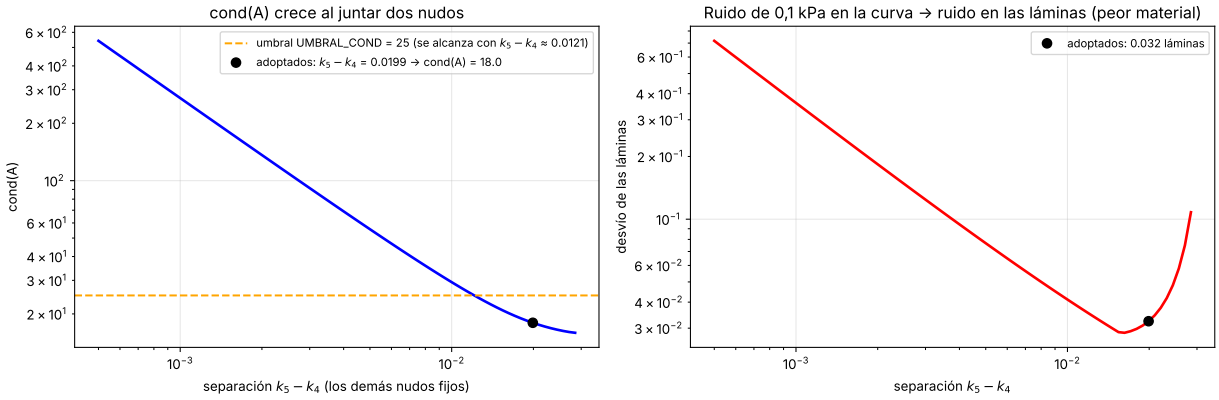



**Figura 10:** Izquierda: $\operatorname{cond}(A)$ al acercar el nudo 5 al 4 (escalas logarítmicas). Derecha: desvío de las láminas del peor material ante un ruido blanco de 0,1 kPa en la curva ($\sigma\, \|A_j^{+}\|$, con $C_{LAM} = 10$). El punto negro marca los nudos adoptados.

### 4.5.5. Paso 5: el signo de las láminas

**El problema.** El MCO libre minimiza el error sin mirar el signo de $c$. Si una curva es muy plana al comienzo en relación con su crecimiento posterior, la mejor poligonal puede necesitar una pendiente inicial *menor* que la que da una lámina del material 1, y el MCO la obtiene restando láminas: $c_1 < 0$. Una lámina negativa no se puede fabricar.

Imponer $c \geq 0$ en el ajuste (mínimos cuadrados no negativos) resolvería el problema, pero es exactamente una *condición en el ajuste*, que es lo que se quiere evitar: el ajuste dejaría de ser la fórmula cerrada $c = A^{+}y$. La alternativa coherente con el objetivo actúa en dos lugares:

1. **En el espacio de trabajo:** la curva límite inferior parte de la menor presión medida en $\lambda = 1{,}02$ (Sección 3). Quedan fuera las curvas que arrancan casi sin presión, que son las que fuerzan $c_1 \leq 0$ y que ninguna arteria medida presenta.
2. **En la base:** se eligen nudos con los que el MCO libre *ya* dé láminas no negativas en todo el espacio de trabajo.

**Cómo se mide.** Para un juego de nudos se calculan las láminas MCO $c_i$ de **todas** las curvas del espacio de trabajo (22 500), de los 31 sujetos de entrenamiento y de las dos curvas límite, en los 999 puntos. Para que la medida no dependa de las unidades, las láminas de cada material se reescalan de modo que su máximo sobre ese conjunto valga $C_{LAM} = 10$ (la misma escala que usa el cuaderno). Luego se calcula, para cada curva, la suma de la parte negativa de sus láminas,

$$\mathrm{neg}_i = \sum_{j=1}^{N} \max\left(0,\, -c_{ij}\right) \quad \text{[láminas]},$$

que vale cero si y solo si todas sus láminas son $\geq 0$. Por ejemplo, una curva con $c_1 = -0{,}5$ y las demás positivas tiene $\mathrm{neg}_i = 0{,}5$. Con esos valores se arman dos términos:

- **el promedio,** $\overline{\mathrm{neg}} = \frac{1}{n}\sum_i \mathrm{neg}_i$, que mide cuánto negativo hay en total;
- **el peor caso,** $\max_i \mathrm{neg}_i$, la curva más negativa.

**Cómo se impone.** Se suma a $J$

$$\mathrm{pen}_{\mathrm{signo}}(k) = \texttt{PESO_NEG} \cdot 100 \cdot \overline{\mathrm{neg}} \;+\; 100 \cdot \max_i \mathrm{neg}_i,$$

con $\texttt{PESO_NEG} = 10$. El factor 100 lleva las láminas a la escala de los errores (en %).

- **Por qué el término de peor caso.** Con 22 500 curvas, una sola curva con una lámina de $-0{,}06$ cambia el promedio en $0{,}06/22\,500 \approx 3 \times 10^{-6}$ láminas: su peso en $J$ sería despreciable, y la búsqueda podría aceptarla a cambio de una mínima mejora del error. Con el término de peor caso, esa curva suma $100 \times 0{,}06 = 6$ puntos a $J$, mucho más que cualquier mejora posible del error. Es lo que convierte la exigencia en "*ninguna* curva con láminas negativas".
- **Por qué el promedio.** Cuando hay muchas curvas negativas, guía a la búsqueda hacia la zona donde son menos, aunque la peor todavía no haya mejorado.
- Ambos términos valen exactamente cero en cualquier juego de nudos que cumpla el signo: entre esos juegos, la búsqueda elige solo por precisión.

**Efecto de cada medida.** La Tabla 5 separa el aporte de la nueva curva límite y el del término de signo en la base (5 bases, verificado en todo el espacio de trabajo y en los 41 sujetos).

**Tabla 5:** Efecto de las dos medidas sobre el signo de las láminas (5 bases). "Curvas con todas $\geq 0$": porcentaje de las 22 500 curvas del espacio de trabajo cuyas 5 láminas MCO son no negativas. Las dos primeras filas corresponden a una franja cuya curva límite inferior parte de 0 en $\lambda = 1{,}02$ (NT08 desplazada), con su propio espacio de trabajo.

| Curva límite inferior | Término de signo en la base | Curvas con todas $\geq 0$ | Sujetos con todas $\geq 0$ | CVaR 99 % | $k_1$ |
|---|---|---|---|---|---|
| parte de 0 | no | 96,1 % | 35/41 | 1,74 % | 0,867 |
| parte de 0 | sí (solo promedio) | 99,98 % | 41/41 | 1,77 % | 0,793 |
| parte del mínimo medido | no | 96,97 % | 39/41 | 1,74 % | 0,922 |
| **parte del mínimo medido** | **sí (promedio y peor caso)** | **100 %** | **41/41** | **1,72 %** | **0,829** |

**Las dos medidas son necesarias.**

- **Solo la nueva curva límite** (tercera fila) no alcanza: con la base elegida sin término de signo, 681 curvas (3 %) y 2 sujetos siguen dando láminas negativas.
- **Solo el término de signo** (segunda fila) deja unas pocas curvas negativas (5 de 22 500), todas con presión casi nula en $\lambda = 1{,}02$, exactamente las que la nueva curva límite excluye.

- **Con las dos** (última fila), ninguna curva ni ningún sujeto da láminas negativas, sin costo en precisión.

**Qué cambia en los nudos.** El término de signo actúa sobre todo en el *primer nudo*: sin él, el óptimo tiene $k_1 \approx 0{,}92$; con él, $k_1 \approx 0{,}83$. Con el nudo más lejos del dominio, la lámina del material 1 es más "tendida" en relación con los demás materiales y el MCO ya no necesita restarla para seguir curvas planas al comienzo. Los nudos dentro del dominio, que deciden la precisión, casi no se mueven, y por eso el costo en precisión es nulo. El precio es mecánico: con $k_1$ más bajo, el material 1 trabaja más estirado (Sección 4.11).

### 4.5.6. Paso 6: la función objetivo completa $J$

Juntando los pasos, los nudos minimizan

$$J(k) = \underbrace{\mathrm{CVaR}_{99}}_{\text{peor 1 \%}} + \underbrace{0{,}25 \cdot \overline{\mathrm{NRMSE}}}_{\text{desempate}} + \underbrace{50 \cdot \max\left(0, \mathrm{cond}(A) - 24\right)}_{\text{restricción de cond}(A)} + \underbrace{10 \cdot 100 \cdot \overline{\mathrm{neg}} + 100 \cdot \max_i \mathrm{neg}_i}_{\text{signo}}$$

**Tabla 6:** Los términos de $J$.

| Término | Qué mide | Por qué ese peso |
|---|---|---|
| $\mathrm{CVaR}_{99}$ | Media de los errores punto a punto de las 25 peores curvas del conjunto de optimización (%) | Es el objetivo principal: la cola del criterio de diseño. Peso 1. |
| $0{,}25 \cdot \overline{\mathrm{NRMSE}}$ | Error cuadrático medio relativo al rango, promediado sobre el conjunto de optimización (%) | Desempata: entre dos juegos con cola parecida, prefiere el que ajusta mejor en promedio. Es chico (el NRMSE medio ronda 0,45 %) para no competir con la cola. |
| $50 \cdot \max(0, \mathrm{cond} - 24)$ | Exceso de cond($A$) sobre 24 | Hace de restricción dura (Paso 4). |
| $10 \cdot 100 \cdot \overline{\mathrm{neg}} + 100 \cdot \max \mathrm{neg}$ | Láminas negativas, en promedio y en la peor curva, sobre todo el espacio de trabajo | Hace de restricción: cualquier lámina negativa pesa más que cualquier mejora del error (Paso 5). |

**Restricciones geométricas.** Además de cond($A$):

- nudos separados al menos 0,004;
- el último a 0,004 o más de $\lambda_{max} = 1{,}16$ (si no, ese material no actúa en el dominio);
- el primero por encima de 0,6.

Si un punto las viola, $J = 10^9$, un valor que la búsqueda siempre descarta.

## 4.6. El método de búsqueda: evolución diferencial y refinamiento con Nelder–Mead

Los dos métodos que siguen son de **optimización numérica**: buscan el mínimo de una función de varias variables, aquí $J(k_1, \ldots, k_N)$. Ambos solo necesitan poder *evaluar* $J$ en un punto: no usan derivadas ni gradientes, y no suponen ninguna forma particular de la función. Ninguno es un método de mínimos cuadrados: cumplen el papel de lazo exterior (recuadro al comienzo de esta sección), y en cada evaluación de $J$ se hacen los ajustes MCO.

### 4.6.1. Etapa 1: búsqueda global con evolución diferencial

**Qué es.** La **evolución diferencial** (Storn y Price, 1997) es un método de búsqueda *global* basado en una *población*: en lugar de mover un único juego de nudos, mantiene muchos a la vez,

repartidos por todo el rango, y los mejora generación tras generación combinándolos entre sí. Una descripción accesible está en Price, Storn y Lampinen (2005), cap. 2. Se usa la implementación de la biblioteca SciPy (`scipy.optimize.differential_evolution`; Virtanen et al., 2020).

**Cómo funciona,** con los valores que usa el cuaderno:

1. **Población inicial.** Se sortean $15N$ juegos de nudos dentro del rango (75 con 5 bases). El sorteo es por *hipercubo latino*: se divide el rango de cada nudo en 75 franjas y se pone exactamente un juego en cada franja, para que la población cubra todo el rango de forma pareja. Se calcula $J$ de cada uno.

2. **Mutación.** Para cada miembro de la población, el "blanco" $x$, se arma un *mutante* partiendo del mejor juego de la población, $x_{mejor}$, y sumándole la diferencia entre otros dos miembros elegidos al azar, $x_a$ y $x_b$:
$$v = x_{mejor} + F\,(x_a - x_b),$$
con $F$ sorteado entre 0,5 y 1 en cada generación. La diferencia $x_a - x_b$ da el tamaño y la dirección del paso: cuando la población está dispersa, los pasos son grandes (exploración); cuando se concentra alrededor del óptimo, los pasos se achican solos (refinamiento). De ahí el nombre "diferencial".

3. **Cruza.** Se arma un *candidato* tomando cada nudo del mutante con probabilidad 0,7 y del blanco en caso contrario (al menos un nudo siempre del mutante).

4. **Selección.** Se calcula $J$ del candidato. Si es menor o igual que el del blanco, lo reemplaza; si no, el blanco se queda. Así la población nunca empeora.

5. **Repetición.** Los pasos 2 a 4 se repiten para todos los miembros: eso es una *generación*. Se termina cuando los $J$ de la población son prácticamente iguales entre sí (desvío estándar menor que $10^{-6}$ veces su media), o tras 300 generaciones.

Con 5 bases la búsqueda converge en unas 130 a 150 generaciones, es decir, entre 10 000 y 11 300 evaluaciones de $J$. Como cada evaluación calcula el signo sobre las 22 500 curvas, tarda entre 10 y 20 minutos según la computadora.

**Semilla.** El sorteo de la población inicial y los sorteos de cada generación usan la semilla fija del cuaderno (`SEED`), de modo que la búsqueda es reproducible. La Sección 4.8 muestra que con otras semillas se llega al mismo resultado.

### 4.6.2. Etapa 2: refinamiento local con Nelder–Mead

**Qué es.** El método de **Nelder–Mead** (Nelder y Mead, 1965), también llamado *simplex descendente*, es un método de búsqueda *local*: parte de un punto y va cuesta abajo hasta el mínimo más cercano. Hay una descripción accesible en Press et al. (2007, Sec. 10.5); sus propiedades de convergencia están en Lagarias et al. (1998).

**Para qué se usa aquí.** La evolución diferencial termina cuando su población se concentró alrededor del mínimo, pero su mejor miembro puede estar todavía a una distancia del orden de $10^{-4}$ del fondo. Nelder–Mead parte de ese punto y lo lleva al fondo con precisión de $10^{-5}$ en los nudos. No cambia la región del óptimo, que ya eligió la búsqueda global; solo afina la posición dentro de ella.

**Cómo funciona.** Con $N$ nudos, trabaja con un *simplex* de $N + 1$ puntos: un triángulo si $N = 2$, un tetraedro si $N = 3$. El simplex inicial lo arma SciPy con el punto de partida y $N$ puntos más, cada uno con un nudo aumentado un 5 %. En cada iteración:

1. Ordena los vértices por su valor de $J$: el mejor ($M$), el segundo peor ($S$) y el peor ($P$).

2. Calcula el centro de todos los vértices salvo el peor, y **refleja** el peor a través de ese centro: el punto $R$, el "espejo" de $P$.

3. Si $R$ es el mejor de todos, prueba ir el doble de lejos: **expansión** ($E$).

4. Si $R$ no mejora lo suficiente, prueba un punto intermedio: **contracción** ($C_e$ por fuera o $C_i$ por dentro).
5. Si nada mejora, achica todo el simplex hacia el mejor vértice.
6. Reemplaza el peor vértice por el punto nuevo y repite, hasta que el simplex se achica por debajo de $10^{-5}$ en $\lambda$ y $10^{-6}$ en $J$.

El simplex "rueda" cuesta abajo por el paisaje de $J$, se estira en las direcciones buenas y se encoge al llegar al fondo.

La Fig. 11 lo muestra en dos dimensiones, moviendo solo $k_3$ y $k_4$ con los demás nudos fijos:

- parte de un triángulo en (1,076; 1,106), donde $J = 67{,}9$;
- en 49 iteraciones (91 evaluaciones de $J$) llega a (1,0945; 1,1276), con $J = 1{,}815$;
- ese punto prácticamente coincide con los nudos adoptados, (1,0942; 1,1273).

En este corte de dos dimensiones el paisaje tiene un solo valle y Nelder–Mead lo encuentra desde lejos. En las $N$ dimensiones, con el término de signo, el paisaje tiene muchos valles (Sección 4.7), y por eso Nelder–Mead se usa solo para refinar, después de la búsqueda global.

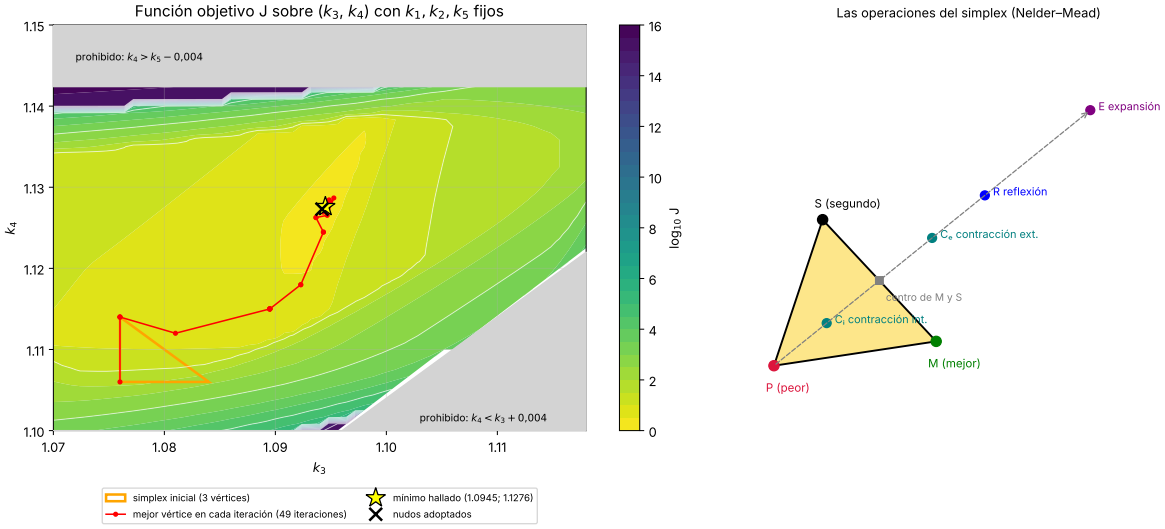



**Figura 11:** Izquierda: mapa de $\log_{10} J$ sobre $(k_3, k_4)$ con $k_1, k_2, k_5$ fijos en los valores adoptados; en gris, las regiones prohibidas. Naranja, el simplex inicial; rojo, el mejor vértice en cada iteración; estrella, el mínimo hallado; cruz, los nudos adoptados. Derecha: las operaciones de una iteración sobre un triángulo.

## 4.7. Por qué este optimizador y no otro

Elegir un optimizador depende de las características del problema. Esta sección describe esas características, revisa las familias de métodos disponibles y compara seis de ellos sobre la misma función objetivo, con y sin el término de signo. La comparación muestra un hecho importante: **sin el término de signo, un método local con varios puntos de partida (Nelder–Mead) alcanza; con el término de signo ya no**, y hace falta una búsqueda global.

**(a) Características del problema.** Se busca el mínimo de $J(k)$, donde $k = (k_1, \ldots, k_N)$ son los nudos:

1. **Pocas variables:** de 4 a 6 nudos.
2. **No hay fórmula para las derivadas de $J$,** y además $J$ no es derivable en muchos puntos:
   - el error de cada curva es un *máximo* sobre los puntos de la grilla;
   - el CVaR depende de un *ordenamiento* de las curvas;

- las bases usan $\max(0, \lambda - k)$, y las penalizaciones usan $\max(0, \cdot)$ y el máximo sobre las curvas.

Cada una de esas operaciones introduce quiebres.

3. **Pequeñas ondulaciones** por la discretización: cuando un nudo cruza un punto de la grilla, $J$ cambia levemente (Fig. 9). Una derivada aproximada numéricamente sobre esas ondulaciones da direcciones engañosas.
4. $J$ **no es una suma de cuadrados.** Es un criterio de peor caso (el CVaR) más penalizaciones.
5. **Muchos mínimos locales.** El término de signo depende sobre todo de $k_1$, una dirección en la que el error es casi plano, y se activa y desactiva bruscamente según qué curva sea la más negativa. El paisaje queda lleno de valles separados: un método local termina en el valle donde arranca (apartado c).
6. **Restricciones simples:** rango de cada nudo y separación mínima, tratadas como penalización.
7. **Evaluación barata:** unas decenas de milisegundos por evaluación de $J$, de modo que se pueden hacer decenas de miles de evaluaciones.

**(b) Familias de optimizadores.** La Tabla 7 resume las familias de métodos disponibles, qué requiere cada una y si sirve para este problema.

**Tabla 7:** Familias de métodos de optimización y su aplicabilidad a la elección de los nudos.

| Familia (ejemplos) | Qué requiere | Aplicabilidad aquí |
|---|---|---|
| Mínimos cuadrados lineales (MCO) | Incógnitas que entren en forma lineal | Sirve para las láminas (lazo interior), no para los nudos, que entran en forma no lineal. |
| Mínimos cuadrados no lineales (Gauss–Newton, Levenberg–Marquardt; nudos libres: Jupp, 1978; Golub y Pereyra, 1973) | Objetivo = suma de cuadrados de residuos derivables | No aplica: $J$ es un criterio de peor caso, no una suma de cuadrados. Además, minimizaría el error *promedio*, no la cola, y no tendría en cuenta el signo. |
| Programación lineal o convexa (minimax como problema lineal) | Problema convexo en las incógnitas | Es convexo en las láminas con los nudos fijos, pero no en los nudos. |
| Métodos con gradiente (descenso por gradiente, Newton, BFGS, L-BFGS-B; Nocedal y Wright, 2006) | Derivadas de $J$, o una aproximación por diferencias finitas | Poco confiables: $J$ tiene quiebres y ondulaciones, y el gradiente aproximado engaña. Además son locales. |
| Locales sin derivadas (Nelder–Mead, 1965; Powell, 1964; búsqueda por patrones, Hooke y Jeeves, 1961) | Solo evaluar $J$ | Toleran quiebres y funcionan bien con pocas variables, pero encuentran el mínimo local más cercano al punto de partida. |
| **Globales sin derivadas** (**evolución diferencial**, Storn y Price, 1997; recocido simulado; algoritmos genéticos) | Solo evaluar $J$, pero muchas más veces | **Adecuados**: toleran quiebres y exploran todo el rango, por lo que no quedan atrapados en un valle. Su costo, miles de evaluaciones, es aceptable porque $J$ es barata. |

**(c) Comparación empírica.** Se minimizó la misma $J$ (5 bases) con seis métodos, en dos variantes del criterio: sin el término de signo (Tabla 8) y con él, que es el criterio adoptado (Tabla 9).

- Los métodos locales parten de los nudos de la regla geométrica $k = (0{,}86;\ 1{,}010;\ 1{,}090;\ 1{,}128;\ 1{,}145)$: el primer nudo antes del dominio y los demás cada vez más juntos hacia 1,16, como sugiere la Sección 4.4.
- Nelder–Mead se corrió además desde 5 puntos de partida distintos (el anterior y cuatro sorteados en el rango), quedándose con el mejor resultado.
- La evolución diferencial busca en todo el rango permitido, sin punto de partida.

El costo se mide en *evaluaciones de* $J$, que no depende de la computadora. Los métodos con gradiente (BFGS, L-BFGS-B) lo aproximan por diferencias finitas: cada gradiente cuesta $N + 1$ evaluaciones. Cada resultado se verificó sobre las 22 500 curvas y los 999 puntos.

**Tabla 8:** Comparación de optimizadores **sin el término de signo** (5 bases). Verificación sobre las 22 500 curvas del espacio de trabajo.

| Método | Evaluaciones de $J$ | $J$ final | CVaR 99 % | Error máx. | Curvas con lámina $< 0$ | Nudos obtenidos |
|---|---|---|---|---|---|---|
| Evolución diferencial (global) | 10 345 | 1,813 | 1,74 % | 2,15 % | 681 (-1,78) | 0,9220; 1,0234; 1,0939; 1,1270; 1,1470 |
| Nelder–Mead, 5 puntos de partida | 1 902 | 1,822 | 1,73 % | 2,06 % | 541 (-1,50) | 0,8658; 1,0151; 1,0948; 1,1276; 1,1472 |
| Powell | 906 | 2,161 | 2,10 % | 2,66 % | 243 (-1,11) | 0,8991; 1,0240; 1,0911; 1,1231; 1,1453 |
| Nelder–Mead, 1 punto de partida | 242 | 1,822 | 1,73 % | 2,06 % | 541 (-1,50) | 0,8658; 1,0151; 1,0948; 1,1276; 1,1472 |
| BFGS (gradiente por diferencias finitas) | 834 | 1,972 | 1,88 % | 2,08 % | 1427 (-3,14) | 0,8600; 1,0100; 1,0979; 1,1284; 1,1484 |
| L-BFGS-B (gradiente por diferencias finitas) | 366 | 2,099 | 2,04 % | 2,58 % | 1258 (-2,91) | 0,8600; 1,0100; 1,0923; 1,1240; 1,1456 |

**Tabla 9:** Comparación de optimizadores **con el término de signo** (criterio adoptado; 5 bases). CVaR, error máximo y curvas con láminas negativas, verificados sobre las 22 500 curvas del espacio de trabajo. Entre paréntesis, la lámina más negativa.

| Método | Evaluaciones de $J$ | $J$ final | CVaR 99 % | Error máx. | Curvas con lámina $< 0$ | Nudos obtenidos |
|---|---|---|---|---|---|---|
| **Evolución diferencial (global), 3 semillas** | **9 984 a 11 331** | **1,808 a 1,814** | **1,72 %** | **2,06 %** | **0** | **0,8292; 1,0229; 1,0945; 1,1276; 1,1472** |
| Powell | 592 | 1,869 | 1,80 % | 2,24 % | 0 | 0,8298; 1,0234; 1,0956; 1,1268; 1,1467 |
| Nelder–Mead, 5 puntos de partida | 3 443 | 1,974 | 1,89 % | 2,41 % | 0 | 0,7778; 1,0231; 1,0952; 1,1259; 1,1462 |
| Nelder–Mead, 1 punto de partida | 413 | 2,264 | 2,19 % | 2,60 % | 0 | 0,8033; 1,0196; 1,0788; 1,1209; 1,1453 |
| L-BFGS-B (gradiente por diferencias finitas) | 498 | 7,993 | 4,84 % | 5,61 % | 2 (-0,03) | 0,8276; 1,0321; 1,0840; 1,1259; 1,1385 |
| BFGS (gradiente por diferencias finitas) | 456 | 19,008 | 4,76 % | 6,73 % | 9 (-0,14) | 0,8544; 1,0358; 1,1189; 1,1469; 1,1555 |

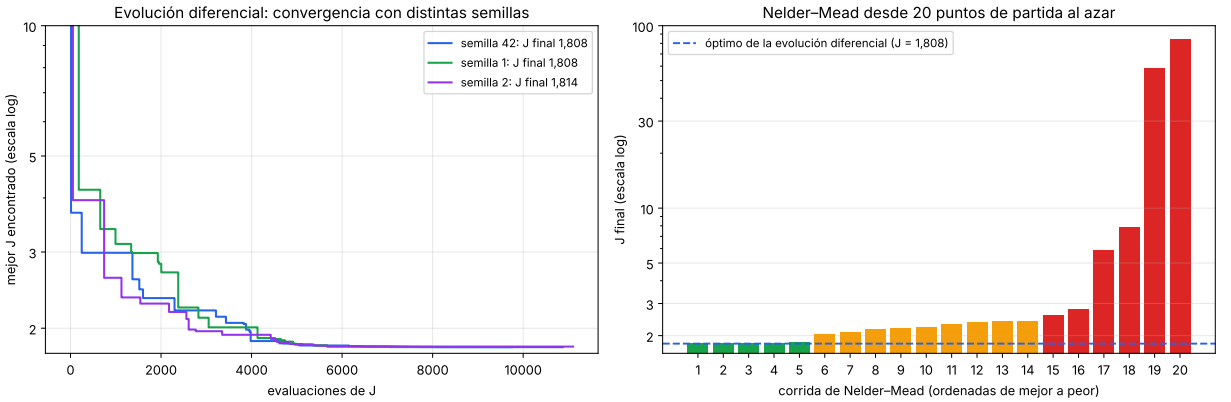



**Figura 12:** Criterio adoptado (con término de signo), 5 bases. Izquierda: mejor $J$ encontrado por la evolución diferencial en función del número de evaluaciones, con tres semillas distintas. Derecha: $J$ final de Nelder–Mead corrido desde 20 puntos de partida sorteados en el rango (ordenados de mejor a peor); la línea discontinua es el óptimo de la evolución diferencial. Verde: a menos del 5 % del óptimo; naranja: $J$ hasta 2,5; rojo: peor.

**(d) Qué muestra la comparación.**

1. **Sin el término de signo, el paisaje es benigno, pero la base no sirve.** Nelder–Mead desde un solo punto de partida queda a 0,5 % del óptimo global ($J = 1{,}822$ frente a 1,813)

con 40 veces menos evaluaciones; para ese criterio, un método local alcanzaba. Pero *todos* los resultados dan láminas negativas: entre 243 y 1 427 curvas del espacio de trabajo, y hasta 5 sujetos reales. Sin el término de signo, la base no es fabricable.

2. **Con el término de signo, el paisaje tiene muchos valles.** Ningún método local llega al óptimo de forma confiable:
   - Nelder–Mead desde 1 punto de partida queda en $J = 2{,}265$ (25 % por encima del óptimo), y desde 5 puntos, en 1,974 (9 % por encima);
   - desde 20 puntos de partida al azar (Fig. 12, derecha) los resultados van de 1,814 a 84,1: solo 5 de las 20 corridas llegan a menos del 5 % del óptimo. El resultado depende del punto de partida, que es justamente lo que no se quiere;
   - Powell, desde el punto de partida de la regla geométrica, llega a 1,870 (3 % por encima). Es un buen resultado, pero, como todo método local, depende de dónde arranca.
3. **Los métodos con gradiente fallan.** Sin el término de signo, BFGS y L-BFGS-B prácticamente no mueven $k_1$ ni $k_2$ desde el punto de partida (0,86 y 1,01): su gradiente, aproximado por diferencias finitas, es nulo o engañoso en las zonas planas y con quiebres de $J$. Con el término de signo terminan con $J = 19{,}0$ y 8,0, errores máximos de 6,7 y 5,6 % y curvas con láminas negativas: ni siquiera cumplen las restricciones.
4. **La evolución diferencial es reproducible.** Con tres semillas distintas llega a $J$ entre 1,808 y 1,814, con nudos que difieren en menos de 0,0006 y, en los tres casos, sin ninguna lámina negativa (Fig. 12, izquierda, y Sección 4.8). Su costo, unas 10 000 evaluaciones (entre 10 y 20 minutos), es irrelevante para un cálculo que se hace una sola vez.

**(e) Conclusión.** Se adopta la **evolución diferencial seguida de un refinamiento con Nelder–Mead** por cinco razones:

1. **No necesita derivadas** y tolera los quiebres y ondulaciones de $J$, donde los métodos con gradiente fallan.
2. **Es global:** explora todo el rango con una población, y no queda atrapada en el valle donde arranca. Con el término de signo, que llena el paisaje de valles, es lo que decide el resultado.
3. **Es reproducible:** da el mismo óptimo, o uno equivalente, con distintas semillas, y no requiere elegir puntos de partida a mano. El resultado depende solo del criterio $J$ y del rango.
4. **Su costo es aceptable:** unos minutos, una sola vez, porque $J$ es barata y hay pocas variables.
5. **Nelder–Mead completa la precisión:** la búsqueda global ubica el valle correcto y Nelder–Mead, que es eficaz con pocas variables, lleva el resultado al fondo con pocas evaluaciones.

**Limitaciones.** Ningún método sin derivadas garantiza en general el óptimo global. La garantía práctica es la que se mostró: tres semillas distintas llegan a la misma región, y ninguno de los otros métodos encontró un $J$ menor. Nelder–Mead, por su parte, no tiene garantía general de convergencia (McKinnon, 1998), pero aquí solo se lo usa dentro del valle ya ubicado, donde el paisaje es simple.

## 4.8. Robustez del resultado

**Respecto del azar de la búsqueda.** La evolución diferencial usa sorteos. Para verificar que el resultado no depende de ellos, la búsqueda (5 bases, criterio adoptado) se repitió con tres semillas distintas (Tabla 10).

**Tabla 10:** Evolución diferencial + Nelder–Mead con tres semillas (5 bases), verificada en las 22 500 curvas y los 41 sujetos. Última fila: los nudos con los que se entrenó la red.

| Semilla | Nudos | Evaluaciones | $J$ | CVaR 99 % | Error máx. | Curvas / sujetos con lámina $< 0$ |
|---|---|---|---|---|---|---|
| 42 | 0,8292; 1,0229; 1,0945; 1,1276; 1,1472 | 11 109 | 1,808 | 1,72 % | 2,06 % | 0 / 0 |
| 1 | 0,8291; 1,0229; 1,0945; 1,1276; 1,1472 | 9 984 | 1,808 | 1,72 % | 2,06 % | 0 / 0 |
| 2 | 0,8290; 1,0229; 1,0939; 1,1270; 1,1470 | 11 331 | 1,814 | 1,74 % | 2,15 % | 0 / 0 |
| Nudos adoptados | 0,8291; 1,0231; 1,0942; 1,1273; 1,1472 | – | 1,831 | 1,72 % | 2,06 % | 0 / 0 |

- Dos semillas llegan exactamente al mismo óptimo ($J = 1{,}808$) y a los mismos nudos, salvo una diezmilésima en $k_1$.
- La tercera queda en un punto vecino, con $J$ un 0,3 % mayor: los nudos difieren en menos de 0,0006 y el resultado sobre el espacio completo es prácticamente el mismo.
- En las tres, ninguna curva ni ningún sujeto da láminas negativas.

La evolución diferencial no garantiza el óptimo exacto en cada corrida, pero llega siempre a la misma región, y las diferencias que quedan no tienen efecto práctico.

**Los nudos adoptados.** La red se entrenó con los nudos (0,8291; 1,0231; 1,0942; 1,1273; 1,1472), hallados con la misma búsqueda cuando el término de signo era solo el promedio (sin el término de peor caso, que en ellos vale cero porque no tienen láminas negativas). Difieren del óptimo en menos de 0,0004 y su $J$ es un 1,3 % mayor, por las pequeñas ondulaciones de la discretización. Sobre el espacio completo son equivalentes (Tabla 10). Por eso se conservan: cambiarlos obligaría a reentrenar la red sin ganancia apreciable. Si se fuerza la re-optimización, la Celda 3 obtiene el óptimo de la evolución diferencial.

**Respecto del número de bases.** Con 4 y 6 bases la búsqueda converge igual (Tabla 2), y en ambos casos ninguna curva ni ningún sujeto da láminas negativas.

## 4.9. Las pendientes: cuánto aporta una lámina

Con los nudos fijos, falta la pendiente $S_j$ de cada base, es decir, cuánta presión aporta *una* lámina del material $j$ por unidad de estiramiento. Esta sección explica cómo se calcula, por qué no afecta al ajuste y qué significa físicamente.

**(a) La pendiente que pide cada curva.** Se toman las líneas truncadas *sin escalar*, $G_j(\lambda) = \max(0, \lambda - k_j)$, y se ajusta por MCO cada curva $y$ con ellas: $g = G^{+}y$. El coeficiente $g_j$ [kPa por unidad de $\lambda$] es la pendiente total que la curva $y$ le pide a la capa del material $j$. Por ejemplo, para Mean HT resulta $g = (18{,}33;\ 76{,}77;\ 96{,}31;\ 180{,}04;\ 256{,}66)$ kPa.

**(b) La pendiente máxima.** La capa más exigida de cada material aparece en alguna curva del espacio de trabajo. Se define

$$\texttt{PEND_MAX}_j = \max\Big\{ \max_{y \in \text{espacio}} (G^{+}y)_j,\ \max_{\text{sujetos en la franja}} (G^{+}y)_j,\ (G^{+}y_2)_j \Big\},$$

es decir, el mayor $g_j$ entre las 22 500 curvas del espacio de trabajo, los 41 sujetos y la curva límite $y_2$. La Tabla 11 muestra qué curva fija cada máximo.

**Tabla 11:** Pendiente máxima de cada capa y curva que la fija (kPa por unidad de $\lambda$).

| Material | Máx. espacio | Máx. sujetos | $y_2$ | PEND_MAX | Lo fija |
|---|---|---|---|---|---|
| 1 | 38,5 | 37,6 | 38,1 | 38,5 | una curva del espacio de trabajo |
| 2 | 186,5 | 139,0 | 79,6 | 186,5 | una curva del espacio de trabajo |
| 3 | 241,1 | 219,9 | 208,7 | 241,1 | una curva del espacio de trabajo |
| 4 | 485,8 | 426,1 | 495,6 | 495,6 | la curva límite $y_2$ |
| 5 | 814,5 | 624,7 | 472,4 | 814,5 | una curva del espacio de trabajo |

**(c) La pendiente de una lámina.** Se elige cuántas láminas, como máximo, se quieren usar de cada material, $C_{LAM,j}$ (por defecto 10), y se define

$$S_j = \frac{\texttt{PEND_MAX}_j}{C_{LAM,j}}.$$

Así, la curva más exigente del espacio de trabajo usa exactamente $C_{LAM,j}$ láminas del material $j$, y cualquier otra usa menos. Por ejemplo, $S_4 = 495{,}6/10 = 49{,}56\,\text{kPa}$: $y_2$ usa 10,00 láminas del material 4. Con $C_{LAM} = 10$ resultan las bases de la Tabla 12.

**(d) Rigidez de una lámina.** Para el fabricante interesa la rigidez de membrana de una lámina. Por la ley de Laplace para un tubo de pared delgada, la tensión de membrana es $T = P\,r$. Una lámina aporta $P = S_j(\lambda - k_j)$ con radio $r = \lambda R_{ref}$, y la deformación de sus fibras es $\varepsilon = (\lambda - k_j)/k_j$. La rigidez al comenzar a trabajar ($\lambda = k_j$) es

$$K_j = \frac{dT}{d\varepsilon}\Big|_{\lambda=k_j} = S_j\, R_{ref}\, k_j^2 \quad [\text{kPa} \cdot \text{mm} = \text{N/m}],$$

con $R_{ref} = 3{,}42\,\text{mm}$, la mediana poblacional. El módulo equivalente es $E_j = K_j/t$, con $t = 0{,}1\,\text{mm}$ el espesor de referencia de una lámina.

**Tabla 12:** Bases con $C_{LAM} = 10$. Las dos últimas columnas son las láminas MCO de las curvas límite.

| Material | $k_j$ | PEND_MAX [kPa] | $A_j(\lambda)$ [kPa] | $K$ [N/m] | $E$ [MPa] | $y_1$ | $y_2$ |
|---|---|---|---|---|---|---|---|
| 1 | 0,8291 | 38,5 | $3{,}85\,\text{máx}(0, \lambda - 0{,}8291)$ | 9,1 | 0,09 | 0,43 | 9,89 |
| 2 | 1,0231 | 186,5 | $18{,}65\,\text{máx}(0, \lambda - 1{,}0231)$ | 66,8 | 0,67 | 2,98 | 4,27 |
| 3 | 1,0942 | 241,1 | $24{,}11\,\text{máx}(0, \lambda - 1{,}0942)$ | 98,8 | 0,99 | 0,48 | 8,65 |
| 4 | 1,1273 | 495,6 | $49{,}56\,\text{máx}(0, \lambda - 1{,}1273)$ | 215,5 | 2,15 | 0,48 | 10,00 |
| 5 | 1,1472 | 814,5 | $81{,}45\,\text{máx}(0, \lambda - 1{,}1472)$ | 366,7 | 3,67 | 0,35 | 5,80 |

$\text{cond}(A) = 17{,}97$ (umbral 25). MCO: $e(y_1) = 1{,}49$ %, $e(y_2) = 2{,}25$ %. Las dos curvas límite dan todas sus láminas positivas.

**(e) Las pendientes no cambian el ajuste ni el signo.** Si se multiplica una base por un factor $\alpha > 0$, el MCO divide su coeficiente por el mismo $\alpha$: la poligonal ajustada es la misma, con el mismo error, y el signo de cada lámina no cambia. Por eso:

- la precisión, la estabilidad y el signo dependen solo de los nudos ($\text{cond}(A)$ se calcula con las columnas normalizadas);
- $C_{LAM}$ es una **elección de unidades**: cambia la rigidez de una lámina y, en proporción inversa, el número de láminas, pero no la pendiente de cada capa ($c_j S_j$), ni la curva, ni la rigidez total de cada capa;
- se puede elegir un $C_{LAM}$ distinto para cada material, sin reentrenar: las salidas de la red se multiplican por $C_{LAM,j}/10$.

La Tabla 13 lo comprueba con la curva media de los hipertensos.

**Tabla 13:** Injerto MCO para Mean HT con dos elecciones de $C_{LAM}$. Cambian las láminas y la rigidez de una lámina; la rigidez total de cada capa y el error máximo (0,377 kPa) son idénticos.

| | $C_{LAM} = [10, 10, 10, 10, 10]$ | | | $C_{LAM} = [8, 10, 10, 12, 15]$ | | |
|---|---|---|---|---|---|---|
| Material | Láminas | $K$ 1 lámina | $K$ total | Láminas | $K$ 1 lámina | $K$ total |
| 1 | 4,76 | 9,1 | 43,1 | 3,81 | 11,3 | 43,1 |
| 2 | 4,12 | 66,8 | 274,9 | 4,12 | 66,8 | 274,9 |
| 3 | 3,99 | 98,8 | 394,5 | 3,99 | 98,8 | 394,5 |
| 4 | 3,63 | 215,5 | 782,8 | 4,36 | 179,6 | 782,8 |
| 5 | 3,15 | 366,7 | 1155,6 | 4,73 | 244,5 | 1155,6 |
| Total | 19,66 | | | 21,01 | | |

## 4.10. Resultados: 4, 5 o 6 bases

**Tabla 14:** MCO con los nudos de la Tabla 2, evaluado en las 22 500 curvas del espacio de trabajo y en los 41 sujetos (999 puntos). Errores en % del rango. En los tres casos, ninguna curva ni ningún sujeto da láminas negativas.

| Bases | cond($A$) | Media | CVaR 99 | Máx. | Cumplen 3 % | Sujetos | $e(y_2)$ |
|---|---|---|---|---|---|---|---|
| 4 | 11,6 | 2,20 | 3,10 | 3,75 | 99,02 % | 40/41 | 2,99 |
| **5** | **18,0** | **1,22** | **1,72** | **2,06** | **100 %** | **41/41** | **2,25** |
| 6 | 24,0 | 0,88 | 1,23 | 1,38 | 100 % | 41/41 | 1,68 |

- **4 bases no alcanzan**: aun con los mejores nudos, el 1 % de las curvas queda por encima del 3 % (máximo 3,75 %), y un sujeto real tampoco cumple. La franja, que llega a 60 kPa, exige más quiebres.
- **5 bases** cumplen con margen: el máximo es 2,06 %, a casi un punto del criterio. Es la configuración adoptada.
- **6 bases** bajan el máximo a 1,38 %, pero con cond($A$) en el límite: el sexto quiebre solo se puede poner muy cerca de otro. La ganancia (0,7 puntos de error máximo) se paga con un material más y con láminas más sensibles al ruido.

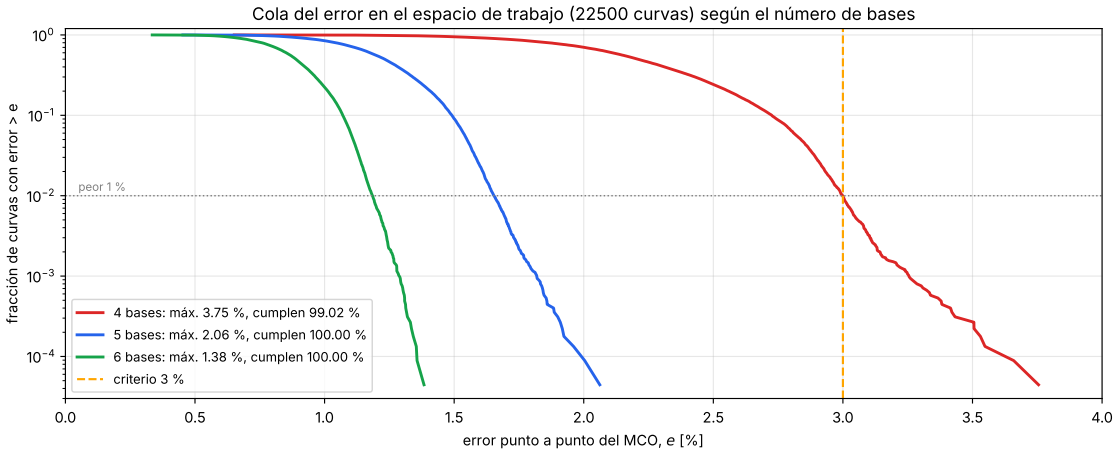



**Figura 13:** Fracción de curvas del espacio de trabajo con error mayor que $e$, para 4, 5 y 6 bases (escala logarítmica). La línea gris marca el peor 1 %; la naranja, el criterio de diseño.

## 4.11. Qué garantiza la base elegida y qué no

Con 5 bases y los nudos adoptados, el ajuste MCO *sin condiciones*, $c = A^{+}y$, cumple las tres propiedades buscadas:

- **Precisión:** el 100 % de las 22 500 curvas y los 41 sujetos cumplen el criterio del 3 %, con un máximo de 2,06 % (Tabla 14).
- **Estabilidad:** cond($A$) = 18,0 < 25. Un ruido de 0,1 kPa en la curva produce un desvío de 0,032 láminas (Paso 4).
- **Signo:** ninguna de las 22 500 curvas del espacio de trabajo y ninguno de los 41 sujetos da láminas negativas. La menor lámina de los sujetos es +0,305 (NT04).

**Margen de signo.** La búsqueda lleva el primer nudo hasta el borde de la condición de signo, porque allí la precisión es mejor. Por eso, en una curva del espacio de trabajo, la lámina del material 2 queda en +0,0004: no es negativa, pero está prácticamente en cero, y solo 2 curvas de 22 500

tienen alguna lámina menor que 0,05. Si se prefiere un margen (por ejemplo, láminas $\geq 0{,}05$), se puede exigir en el término de signo, a cambio de un primer nudo algo más bajo.

**Lo que la base no garantiza.**

- **Curvas fuera de la franja $y_1$–$y_2$.** Las garantías valen para el espacio de trabajo. Una curva más rígida que $y_2$ o más distensible que $y_1$ (por ejemplo, una que arranque con menos de 0,17 kPa en $\lambda = 1{,}02$) puede ajustar peor o dar láminas negativas; el cuaderno lo informa sin corregirlo.
- **Curvas de otras leyes dentro de la franja.** El espacio de trabajo está formado por curvas de la ley de Masson. Con otra ley (la exponencial del dataset), 2 de 4 535 curvas dentro de la franja superan levemente el 3 % (máximo 3,12 %), y ninguna da láminas negativas.
- **El signo de lo que da la red.** La propiedad de signo es del MCO; la red lo reproduce con un error del orden de 0,01 láminas, y una lámina MCO cercana a cero podría salir levemente negativa en la red. Si eso ocurre, el pulido MCO de la salida de la red da el valor exacto.
- **La deformación de los materiales.** Con $k_1 = 0{,}8291$, el material 1 está estirado un 40 % respecto de su largo sin carga cuando $\lambda = 1{,}16$ (Sección 7). La base no impone límites de deformación; que el material los soporte es una condición de fabricación que hay que verificar aparte.

## 4.12. Cómo se usa en el cuaderno

En la Celda 0:

- `N_BASES` (4, 5 o 6): el número de materiales. Cambiarlo requiere reentrenar.
- `NUDOS_REF`: los nudos de referencia por número de bases (los de la Tabla 2).
- `UMBRAL_COND` (25 por defecto): la cota de cond($A$).
- `PESO_NEG` (10 por defecto): el peso del término de signo promedio (Paso 5).
- `SIGNO_ESTRICTO` (`True` por defecto): agrega el término de peor caso y exige 0 curvas y 0 sujetos con láminas negativas.
- `PARAM_Y1`: los cinco parámetros de la curva límite inferior (Sección 3).
- `OPTIMIZAR_NUDOS` (`False` por defecto): `True` fuerza la re-optimización.

La Celda 1 calcula las 41 curvas y las curvas límite, y verifica que $y_1(1{,}02)$ sea la menor presión medida, que $y_1$ quede por debajo de los 41 sujetos y que tenga forma J. La Celda 3 sigue esta lógica:

1. Toma `NUDOS_REF[N_BASES]`, calcula cond($A$) y cuenta las curvas y sujetos con láminas negativas.
2. Si cond($A$) $\geq$ `UMBRAL_COND`, si no hay nudos para ese número de bases, si hay láminas negativas (con `SIGNO_ESTRICTO`) o si `OPTIMIZAR_NUDOS = True`, corre el método de esta sección: evolución diferencial y refinamiento con Nelder–Mead. Tarda entre 10 y 20 minutos.
3. Imprime la línea `NUDOS_REF[N] = [...]` para copiar en la Celda 0. Conviene copiarla: así la próxima corrida no re-optimiza y, al cargar una red entrenada (`ENTRENAR = False`), los nudos coinciden. La Celda 8 lo verifica.
4. Verifica cond($A$) $<$ `UMBRAL_COND` y, con `SIGNO_ESTRICTO`, que no haya láminas negativas; si no se cumple, se detiene con un mensaje.
5. Calcula las pendientes máximas `PEND_MAX` con los nudos finales (Sección 4.9) e informa el signo.

**Resumen de la construcción de la base**

1. Fijar el rango de cada nudo: $k_1 \in [0{,}60;\ 0{,}98]$, los demás en $[1{,}00;\ 1{,}156]$.
2. Para un juego de nudos, ajustar por MCO cada curva del conjunto de optimización (2500 del espacio de trabajo, 31 sujetos de entrenamiento e $y_2$).
3. Medir el error de cada curva (residuo máximo dividido por su rango) y promediar los de las 25 peores: eso es el CVaR.
4. Sumar 0,25× el NRMSE medio, la penalización si $\mathrm{cond}(A) > 24$ y la penalización por láminas negativas en todo el espacio de trabajo: eso es $J$, la calificación de esos nudos.
5. La evolución diferencial sortea una población de juegos de nudos en todo el rango y la mejora generación tras generación (mutación, cruza y selección) hasta que todos tienen el mismo $J$; Nelder–Mead refina el mejor.
6. Con los nudos fijos, calcular la pendiente máxima de cada capa en el espacio de trabajo, $\texttt{PEND_MAX}_j$, y la de una lámina, $S_j = \texttt{PEND_MAX}_j / C_{LAM,j}$.
7. Verificar el resultado en las 22 500 curvas y los 41 sujetos: precisión, estabilidad y signo.

# 5. Dataset sintético y red neuronal

## 5.1. Dataset

Se generan 50 000 curvas en siete familias (Tabla 15). Las familias se agrupan en dos clases, que conviene distinguir al leer los resultados:

**Familias del dataset: “de bases” y “fisiológicas”**

Las siete familias de curvas del dataset se agrupan en dos clases:

- **Familias de bases** (pura y combinada): curvas armadas sumando láminas de las propias bases, es decir, rampas y poligonales con quiebres en los nudos. No se parecen a una arteria. Le enseñan a la red qué hace cada material por separado y a no mezclarlos (crosstalk). Como son combinaciones exactas de las bases, su óptimo MCO es casi perfecto, y un error pequeño de la red da un exceso relativo alto.
- **Familias fisiológicas** (constitutiva, amplia, uniforme, exponencial y pacientes): curvas suaves con forma J, como las de una arteria. Salen de la ley constitutiva de Masson con parámetros derivados de los sujetos de entrenamiento (mezclados, perturbados o sorteados), de otra ley exponencial ajustada a esos sujetos, o directamente de los 31 sujetos de entrenamiento con ruido. Representan lo que la red recibe al diseñar un injerto, y por eso con ellas se juzga su desempeño.

“Fisiológica” indica que la curva proviene de un modelo de arteria, no de las bases. No significa que cada curva corresponda a una arteria medida: la familia amplia extrapola parámetros y la exponencial no se filtra por la franja $y_1$–$y_2$.

Una curva fisiológica se acepta solo si cumple todas estas condiciones:

- es positiva;
- es monótona;
- es convexa desde $\lambda = 1{,}05$ (forma J);
- no supera 1,5 veces la presión máxima de los sujetos;
- salvo en la familia exponencial, queda dentro de $y_1$–$y_2$.

**Tabla 15:** Familias del dataset (50 000 curvas).

| Familia | % | Cómo se genera |
|---|---|---|
| pura | 20 | Un solo material, con láminas log-uniformes entre 0,1 y 10 (el logaritmo es uniforme: hay tantas curvas entre 0,1 y 1 lámina como entre 1 y 10). Ruido del 0,5 %. |
| combinada | 20 | De 2 a $N$ materiales al azar, con láminas uniformes entre 0 y 10. Se reduce la escala si supera el techo de presión. Ruido del 0,5 %. |
| constitutiva | 20 | Ley de Masson con una mezcla convexa de 2–3 sujetos (promedio ponderado con pesos aleatorios positivos que suman 1, sorteados con una distribución de Dirichlet), perturbación moderada de los parámetros y amplitud entre 0,85 y 1,20. Ruido del 1 %. |
| amplia | 15 | Igual, con 2–4 sujetos, perturbaciones mayores, extrapolación desde el centro de la población ($\gamma$ hasta 1,35) y amplitud entre 0,65 y 1,50. |
| exponencial | 10 | Otra ley: $C + \mu E + k_1 E e^{k_2 E^2}$ con $E = \lambda^2 - 1$, media geométrica de los ajustes de 2–3 sujetos. No se filtra por la franja. |
| uniforme | 10 | Ley de Masson con cada parámetro independiente, uniforme entre el mínimo y el máximo de los sujetos de entrenamiento. |
| pacientes | 5 | Los 31 sujetos de entrenamiento, repetidos, con ruido del 1 %. |

**Ruido.** Para imitar los errores de medición, a cada punto de la curva se le suma un valor aleatorio con distribución normal, de media 0 y desvío igual al 0,5 % o al 1 % del valor de la curva en ese punto, según la familia.

**Etiquetas.** La *etiqueta* de cada curva es la respuesta que la red debe aprender: su ajuste MCO *con la misma curva ruidosa que ve la red*, expresado en láminas con $C_{LAM} = 10$.

**Partición.** Las 50 000 curvas se dividen en tres conjuntos disjuntos, *estratificados* por familia (cada uno conserva las proporciones de familias de la Tabla 15):

- **entrenamiento** (35 000): las curvas con las que la red ajusta sus parámetros;
- **validación** (5 000): la red no aprende de ellas; sirven para decidir cuándo reducir el paso de aprendizaje y cuándo detener el entrenamiento;
- **test** (10 000): se usan solo al final, para evaluar la red con curvas que nunca intervinieron en el entrenamiento.

## 5.2. Red y entrenamiento

**Qué es la red.** Una **red neuronal densa** (perceptrón multicapa) es una función con muchos coeficientes ajustables, llamados *pesos* o *parámetros*. Transforma la entrada (999 números) en la salida (5 láminas) mediante capas sucesivas. Cada *neurona* calcula una suma ponderada de las salidas de la capa anterior más una constante, y le aplica una función no lineal. **Entrenar** la red es ajustar sus pesos para que su salida se acerque a las etiquetas, minimizando una función de pérdida sobre las curvas de entrenamiento (Goodfellow et al., 2016).

- **Entrada:** la curva en los 999 puntos de la grilla, transformada como $\log(y+5)$, que comprime el rango de presiones, y *estandarizada*: a cada uno de los 999 valores se le resta su media y se lo divide por su desvío estándar, ambos calculados sobre el conjunto de entrenamiento.
- **Arquitectura:** tres capas densas de 256, 128 y 64 neuronas.
  - Cada capa usa la función no lineal **ReLU**, $\max(0, x)$.
  - Cada capa usa **normalización de capa**, que reescala sus salidas a media 0 y desvío 1 y estabiliza el entrenamiento (Ba et al., 2016).
  - La salida es lineal, con las 5 láminas estandarizadas.
  - En total, 298 373 parámetros.

- **Pérdida:** la función que el entrenamiento minimiza. MSE es el error cuadrático medio (*mean squared error*).

$$L = \underbrace{\mathrm{MSE}(\hat{c}_{std}, c_{std})}_{\text{láminas}} + 5 \cdot \underbrace{\mathrm{media}\left(\frac{A(\hat{c}-c)}{\max Ac}\right)^2}_{\text{curva reconstruida}} + 5 \cdot \underbrace{\mathrm{media}\left(m \odot \hat{c}^{\,2}\right)}_{\text{crosstalk}}.$$

  - El primer término compara las láminas estandarizadas.
  - El segundo compara las curvas que esas láminas reconstruyen, relativas al máximo de cada curva.
  - El tercero penaliza las láminas que la red asigna a materiales que el generador dejó en cero ($m = 1$ en las familias pura y combinada). Se llama *crosstalk*: la fuga de un material a otro.

- **Entrenamiento:** con el algoritmo **Adam** (Kingma y Ba, 2015), una variante del descenso por gradiente que adapta el tamaño del paso de cada peso.

  - **Época y lote.** Una *época* es una pasada completa por las 35 000 curvas de entrenamiento. Dentro de cada época, las curvas se procesan en *lotes* de 64, y los pesos se corrigen después de cada lote (547 correcciones por época).
  - **Learning rate** (tasa de aprendizaje): el tamaño de cada corrección. Empieza en $10^{-3}$ y se reduce a la mitad cada vez que la pérdida de validación no mejora durante 30 épocas, hasta $10^{-6}$.
  - **Parada temprana** (*early stopping*): si la pérdida de validación no mejora durante 80 épocas, el entrenamiento se detiene y se restauran los pesos de la mejor época.

**Pulido.** Para un diseño final, la red puede completarse con un paso MCO, $c = A^{+}y$. Las *ecuaciones normales*, $A^{\mathsf{T}}Ac = A^{\mathsf{T}}y$, son la condición que caracteriza al mínimo de MCO; se cumplen con un residuo relativo $\leq 2{,}4\times10^{-15}$, de modo que red + pulido da el óptimo exacto. Los resultados que siguen son de *la red sola*, sin pulido.

**Control de clase.** Antes de usar la red, se verifica que la curva de entrada sea de la clase aprendida. Se acepta si una combinación no negativa de 40 líneas truncadas (nudos entre 0,85 y 1,16) la aproxima con NRMSE $\leq 2$ %. Esa combinación se calcula con *mínimos cuadrados no negativos* (NNLS, Lawson y Hanson, 1974), es decir, MCO con la restricción de que todos los coeficientes sean $\geq 0$. Se usa solo para este control, no para el diseño. Una curva que no admite esa aproximación no tiene forma J y no se puede reproducir con láminas.

# 6. Resultados de la red

## 6.1. Entrenamiento

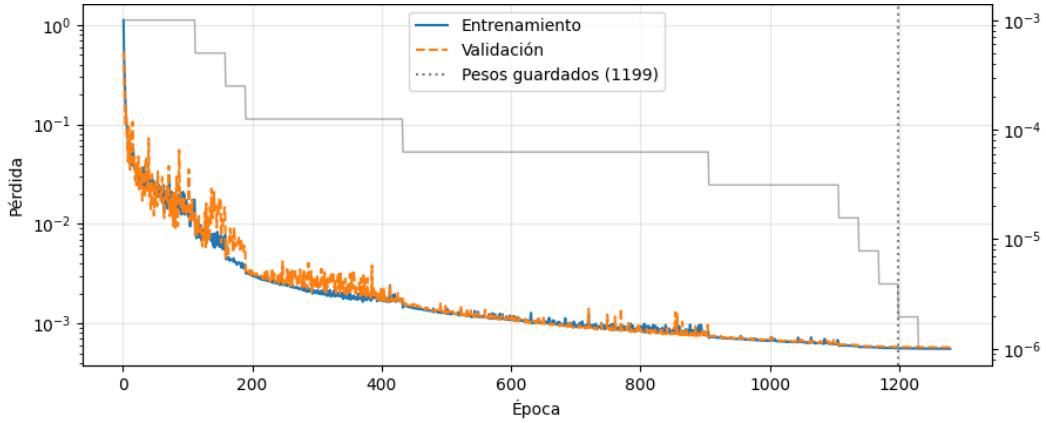



**Figura 14:** Pérdida de entrenamiento y de validación (gris, eje derecho: learning rate). Se guardan los pesos de la época 1199.

El entrenamiento duró 1279 épocas (85 min en CPU), y se guardaron los pesos de la época 1199. Las pérdidas de entrenamiento (0,000562) y de validación (0,000580) terminan juntas, sin *sobreajuste* (el sobreajuste ocurre cuando la red memoriza las curvas de entrenamiento y empeora en las de validación). Cada escalón del learning rate produce una bajada de la pérdida.

**Tiempo y signo en el test.** Sobre las 10 000 curvas de test, la red tarda 0,07 ms por curva, lo mismo que el MCO. La red da alguna lámina negativa en el 29,9 % de las curvas de test (la más negativa, −0,024), frente al 30,9 % del MCO (la más negativa, −0,157). Esto no contradice las garantías de la base:

- **Todas esas curvas son de las familias de bases** (pura y combinada, el 40 % del test). En ellas varios materiales valen exactamente 0, y el ruido agregado (0,5 %) los mueve apenas por debajo o por encima de cero.
- **En las familias fisiológicas, el MCO no da ninguna lámina negativa,** ni siquiera sobre las curvas con ruido, salvo 2 curvas de la familia exponencial que están fuera de la franja $y_1$–$y_2$ (mínimo −0,18).

## 6.2. Los 41 sujetos y las curvas medias

Medidas usadas en los resultados:

- **Óptimo:** el ajuste MCO, que es el mejor ajuste posible con las bases, en el sentido de los cuadrados mínimos.
- **Exceso:** cuánto peor ajusta la red que el óptimo, exceso = $\mathrm{NRMSE}_{red}/\mathrm{NRMSE}_{óptimo} - 1$. Un exceso de +1,5 % significa que el error típico de la red es 1,015 veces el del óptimo.
- $\mathbf{R^2}$ (coeficiente de determinación): $R^2 = 1 - \sum r_i^2 / \sum (y_i - \bar{y})^2$. Vale 1 para un ajuste perfecto.
- $|\Delta c|$**:** diferencia, en láminas, entre la red y el óptimo.
- **Mediana:** el valor que deja por debajo a la mitad de los casos.

**Tabla 16:** Red sola frente al óptimo MCO en los sujetos de Masson.

| Grupo | $n$ | NRMSE óptimo | NRMSE red | Exceso | Error pto. máx. red | Cumplen $\leq 3$ % | máx $\lvert\Delta c\rvert$ |
|---|---|---|---|---|---|---|---|
| Test | 10 | 0,489 % | 0,501 % | +2,32 % | 1,58 % | 10/10 | 0,032 |
| Entrenamiento | 31 | 0,453 % | 0,455 % | +0,54 % | 1,56 % | 31/31 | 0,022 |
| Normotensos | 16 | 0,433 % | 0,440 % | +1,55 % | 1,58 % | 16/16 | 0,017 |
| Hipertensos | 25 | 0,480 % | 0,483 % | +0,68 % | 1,56 % | 25/25 | 0,032 |
| **Todos** | **41** | 0,462 % | 0,466 % | **+1,00** % | 1,58 % | **41/41** | 0,032 |

- En los 10 sujetos de test, la mediana del exceso es +0,6 %.
- El máximo es NT08, con +13,4 %, que equivale a menos de 0,03 láminas.
- El peor error punto a punto de la red (1,58 %) queda muy por debajo del criterio.
- El MCO da todas las láminas $\geq 0$ en los 41 sujetos (Sección 4.11): el diseño de cualquiera de ellos es fabricable tal como sale.

**Tabla 17:** Curvas medias de los grupos de Masson.

| Curva | $n$ | Láminas MCO (total) | Exceso de NRMSE | Error pto. red | Error pto. óptimo |
|---|---|---|---|---|---|
| Mean Young | 7 | 13,00 | +0,83 % | 1,07 % | 1,03 % |
| Mean Old | 9 | 17,84 | +0,01 % | 1,36 % | 1,36 % |
| Mean NT | 11 | 17,65 | +0,88 % | 1,26 % | 1,34 % |
| Mean HT | 25 | 19,66 | +0,46 % | 1,27 % | 1,31 % |

En las cuatro curvas medias la red coincide con el MCO en 0,02 láminas como máximo, y todas las láminas son positivas.

## 6.3. Test por familia

**Tabla 18:** Test por familia (10 000 curvas). Criterio evaluado contra la curva sin ruido.

| Familia | $n$ | NRMSE óptimo | NRMSE red | Exceso | $R^2$ red mín. | Red cumple 3 % | Red máx. | MCO máx. |
|---|---|---|---|---|---|---|---|---|
| pura | 2000 | 0,320 | 0,402 | +25,6 % | 0,992 | 99,45 % | 3,57 % | 0,74 % |
| combinada | 2000 | 0,242 | 0,333 | +37,7 % | 0,912 | 99,15 % | 15,02 % | 0,57 % |
| constitutiva | 2000 | 0,717 | 0,720 | +0,44 % | 0,997 | 100 % | 1,93 % | 1,81 % |
| amplia | 1500 | 0,721 | 0,726 | +0,70 % | 0,996 | 99,93 % | 3,18 % | 2,22 % |
| exponencial | 1000 | 0,732 | 0,741 | +1,18 % | 0,994 | 99,70 % | 8,25 % | 3,54 % |
| uniforme | 1000 | 0,740 | 0,745 | +0,65 % | 0,998 | 100 % | 2,32 % | 2,10 % |
| pacientes | 500 | 0,721 | 0,724 | +0,36 % | 0,997 | 100 % | 1,70 % | 1,66 % |

- **Familias fisiológicas** (constitutiva, amplia, exponencial, uniforme y pacientes: las de forma arterial). El exceso queda entre +0,4 y +1,2 %: la red está prácticamente sobre el óptimo.
  - Constitutiva, uniforme y pacientes: el 100 % cumple el 3 %.
  - Amplia: 1 curva de 1500 supera el 3 % con la red (3,18 %); el MCO da en ella 2,2 %.
  - Exponencial: 3 curvas de 1000 superan el 3 % con la red, la peor con 8,2 %. Esta familia no se filtra por la franja, y la peor curva sube a unos 70 kPa en $\lambda = 1{,}16$, por encima de $y_2$: está *fuera del espacio de trabajo*, y el propio MCO no cumple (3,5 %).
- **Familias de bases** (pura y combinada). El exceso relativo es mayor (26 a 38 %), pero sobre óptimos muy chicos (NRMSE de 0,24–0,32 %). La causa es el ruido de la curva:
  - el MCO reparte ese ruido como láminas chicas, de ambos signos, en los materiales ausentes;

- la red, entrenada para no producir crosstalk, las deja casi en cero.

Entre el 0,5 y el 0,9 % de estas curvas no cumple el 3 % con la red. Son poligonales de muy poca presión. El peor caso (15 %, Fig. 15) es una curva que va de 0,03 a 0,6 kPa, armada con unas 0,04 láminas del material 1 y 0,35 del material 3. La red pone en cero el material 1 (no lo distingue de un material ausente con ruido) y su curva queda hasta 0,09 kPa por debajo: un error absoluto menor que el de las curvas fisiológicas, pero enorme frente a un rango de 0,6 kPa. No representa ninguna arteria, está muy por debajo de $y_1$, y el pulido MCO la lleva al óptimo exacto.

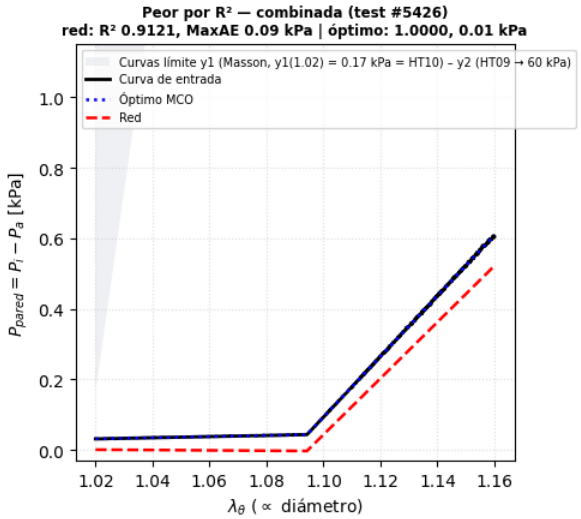



**Figura 15:** Peor caso de la familia combinada: una poligonal de menos de 1 kPa. El MCO (azul) la ajusta exactamente; la red (rojo) anula las 0,04 láminas del material 1.

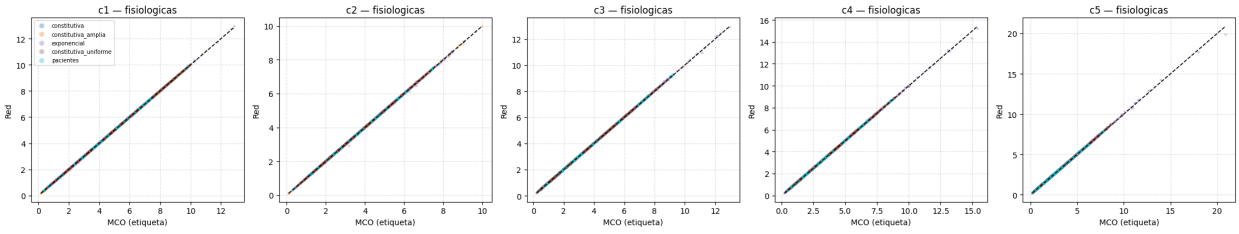



**Figura 16:** Láminas de la red frente a las del MCO en las familias fisiológicas de test (6000 curvas). $R^2 \geq 0{,}99969$ en los cinco materiales; error medio absoluto de 0,007 a 0,019 láminas.

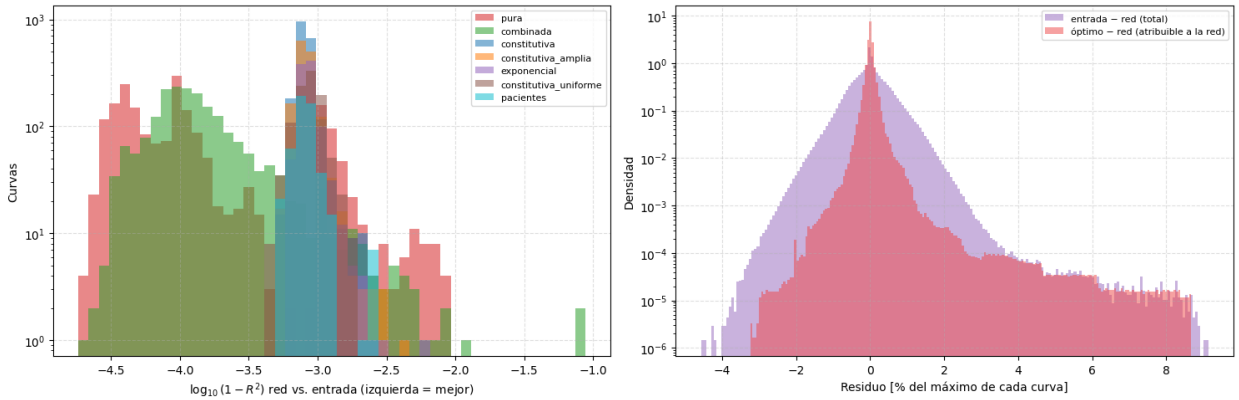



**Figura 17:** Izquierda: $\log_{10}(1 - R^2)$ de la red por familia. Derecha: residuo total (violeta) y la parte atribuible a la red (óptimo − red, rojo), en % del máximo de cada curva. El cuerpo de la parte atribuible a la red está dentro de ±2 %.

## 6.4. Generalización a una ley nunca vista y control de clase

Se generaron 300 curvas con una *ley tipo Fung*, una exponencial pura $P(\lambda) = C + a(e^{\,b(\lambda-1{,}02)} - 1)$ (Fung, 1993), con parámetros obtenidos de los sujetos de entrenamiento. No forma parte del dataset de entrenamiento (con ruido del 1 %; el 0,8 % de sus puntos queda fuera de $y_1$–$y_2$).

- El NRMSE de la red es 1,125 % y el del óptimo 1,110 %: un exceso de +1,3 %.
- El peor $R^2$ de la red es 0,9969, frente a un óptimo de 0,9970.
- El MCO da todas las láminas $\geq 0$ en las 300 curvas.

La red generaliza a una forma funcional que no vio, casi sin costo frente al óptimo.

El control de clase acepta todas las curvas de Fung y los 41 sujetos. Rechaza el 95,7 % de las curvas moduladas que dejan de tener forma J, y acepta el 73,9 % de las que la conservan.

## 6.5. Reproducción de láminas aisladas

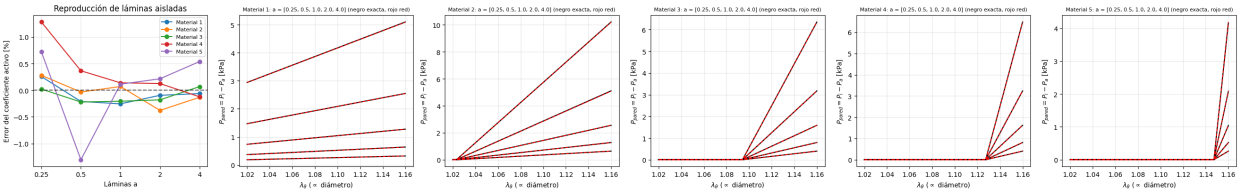



**Figura 18:** Entrada $y = a\,A_j$ (una sola base, $a = 0{,}25$ a 4 láminas); la respuesta exacta es $c = a\,e_j$. Izquierda: error del coeficiente activo; resto: curvas exactas (negro) y de la red (rojo).

- **Crosstalk:** la mayor lámina asignada a un material ausente es 0,004.
- **Coeficiente activo:** el peor error es 1,30 %, en el material 5 con 0,5 láminas (0,007 láminas en valor absoluto). Con 1 lámina o más, el error es como mucho 0,54 %.
- **$R^2$:** $\geq 0{,}9995$ en todos los casos.

# 7. Diseño: la curva media de los hipertensos

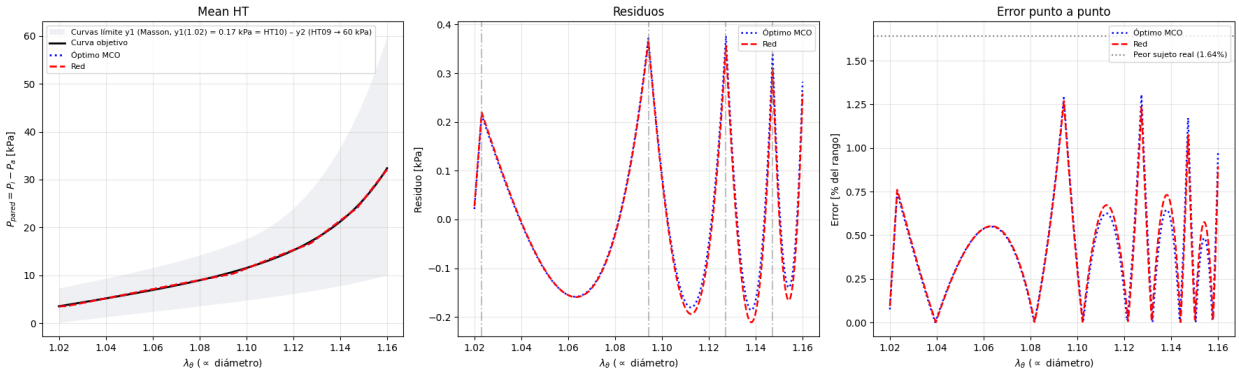



**Figura 19:** Mean HT: curva, ajuste MCO y red (izquierda), residuos (centro; líneas verticales en los nudos) y error punto a punto (derecha).

**Tabla 19:** Injerto para Mean HT ($C_{LAM} = 10$): láminas del MCO y de la red, y rigidez de cada capa. Holgura de fibra: $k_j/k_1 - 1$. Deformación máxima: estiramiento del material en $\lambda = 1{,}16$ respecto de su largo sin carga, $1{,}16/k_j - 1$.

| Material | Nudo | Holgura de fibra | Láminas MCO | Láminas red | $K$ 1 lámina [N/m] | $K$ total [N/m] | Aporte a $P(1{,}16)$ [kPa] | Deform. máx. |
|---|---|---|---|---|---|---|---|---|
| 1 | 0,8291 | 0 % | 4,761 | 4,753 | 9,1 | 43,1 | 6,06 | **39,9 %** |
| 2 | 1,0231 | 23,4 % | 4,117 | 4,126 | 66,8 | 274,9 | 10,51 | 13,4 % |
| 3 | 1,0942 | 32,0 % | 3,994 | 4,006 | 98,8 | 394,5 | 6,34 | 6,0 % |
| 4 | 1,1273 | 36,0 % | 3,633 | 3,632 | 215,5 | 782,8 | 5,89 | 2,9 % |
| 5 | 1,1472 | 38,4 % | 3,151 | 3,142 | 366,7 | 1155,6 | 3,29 | 1,1 % |
| Total | | | 19,655 | 19,660 | | | 32,08 | |

- **Láminas:** la red difiere del MCO en 0,012 láminas como máximo. Todas son positivas.
- **Error:** el punto a punto de la red es menor que el del MCO (1,27 % contra 1,31 %), y el NRMSE prácticamente igual (0,511 contra 0,509 %). Los picos del residuo caen en los nudos: es el piso de error de las bases, no de la red.
- **Injerto resultante:**
  - radio de reposo de 0,8291 $R_{ref} = 2{,}84$ mm, sin pretensado;
  - presión de pared en $\lambda = 1{,}16$ de 32,1 kPa (241 mmHg);
  - cada material entra en carga con la holgura de fibra indicada en la tabla.
- **A verificar en la fabricación:** el material 1 trabaja estirado hasta un 40 % en $\lambda = 1{,}16$, consecuencia de su nudo bajo, que es parte de lo que asegura el signo de las láminas (Paso 5). El material elegido para esa capa debe admitir esa deformación en régimen elástico; los demás trabajan por debajo del 14 %.

# 8. Conclusiones

1. **Curvas objetivo.** Se calculan con la ley constitutiva y los parámetros publicados por Masson et al. (2011), integrando el equilibrio radial sobre un espesor íntima–media supuesto de 0,6 mm, y se validan contra las curvas medias publicadas (error de 1,2 a 1,7 %).
2. **Espacio de trabajo.** Se definió entre dos curvas límite que contienen a las 41 carótidas y llegan a 60 kPa. La inferior es una curva de la ley de Masson, con parámetros dentro del rango de los sujetos, que parte de la menor presión medida en $\lambda = 1{,}02$. El ajuste se hace en [1,02; 1,16], el rango respaldado por las mediciones.

3. **Elección de las bases.** El objetivo fue elegir la base de modo que el ajuste sea MCO sin condiciones. El método minimax califica cada juego de nudos con el CVaR 99 % del error punto a punto, un desempate por NRMSE, la restricción $\mathrm{cond}(A) < 25$ y una penalización por láminas negativas en todo el espacio de trabajo (promedio y peor caso), y lo minimiza con evolución diferencial y un refinamiento con Nelder–Mead. Las pendientes se fijan después, con la pendiente máxima de cada capa en el espacio de trabajo. Con 5 materiales, el MCO libre $c = A^{+}y$:

   - cumple el criterio del 3 % en las 22 500 curvas del espacio de trabajo (máximo 2,06 %) y en los 41 sujetos;
   - es estable: $\mathrm{cond}(A) = 18{,}0$;
   - no da ninguna lámina negativa en el espacio de trabajo ni en los 41 sujetos.

   Con 4 materiales no alcanza; con 6 la mejora es moderada y $\mathrm{cond}(A)$ queda en el límite.

4. **Signo sin condiciones.** El 0 % de láminas negativas se logra combinando dos medidas: la curva límite inferior que parte del mínimo medido, que deja fuera las curvas que arrancan casi sin presión, y el término de signo en la elección de los nudos. Ninguna de las dos impone condiciones al ajuste.

5. **Optimizador.** Con el término de signo, la función objetivo tiene muchos mínimos locales: un método local depende del punto de partida. La evolución diferencial llega al mismo óptimo con distintas semillas, por lo que la base resulta reproducible y no depende de elecciones manuales.

6. **Red neuronal.**

   - Reproduce el óptimo: +1,0 % en los 41 sujetos, todos dentro del criterio, y entre +0,4 y +1,2 % en las familias fisiológicas.
   - Generaliza a una ley nunca vista con un exceso de +1,3 %.
   - Su diseño para la curva media de los hipertensos coincide con el óptimo en 0,012 láminas.

7. **Número de láminas.** $C_{LAM}$ es una elección de unidades: puede fijarse por material según los materiales disponibles, sin reentrenar y sin cambiar el injerto.

8. **Trabajo futuro.**

   - Redondear las láminas a números enteros, buscando la combinación entera que mejor reproduce la curva.
   - Verificar que el material de la capa 1 admita deformaciones del orden del 40 %; si no, incorporar a la elección de la base una cota para el primer nudo.
   - Si se dispone de los espesores íntima–media medidos, reemplazar el espesor supuesto de 0,6 mm.
   - Si interesa un tope de dilatación ante sobrepresiones, estudiar un material “freno” con nudo cerca de 1,16.

# A. El cuaderno

| Celda | Contenido |
|---|---|
| 0 | Configuración: `N_BASES`, `NUDOS_REF`, `OPTIMIZAR_NUDOS`, `UMBRAL_COND`, `PESO_NEG`, `SIGNO_ESTRICTO`, `PARAM_Y1`, `C_LAM`, `ENTRENAR` |
| 1 | Modelo de Masson, 41 sujetos y curvas límite (con sus verificaciones) |
| 2 | Espacio de trabajo: curvas fisiológicas sintéticas |
| 3 | Bases: cond($A$), nudos (minimax si hace falta), `PEND_MAX` y signo de las láminas |
| 4 | Verificación de las bases sobre los 41 sujetos |
| 5 | Figura: láminas de las curvas límite y error de los 41 sujetos |
| 6 | Librerías, entrada logarítmica, métricas y predicción |
| 7 | Dataset: familias pura y combinada + fisiológicas |
| 8 | Partición y normalización (verifica los nudos al cargar una red) |
| 9–11 | Pérdida y arquitectura, integridad de los datos, entrenamiento o carga de la red |
| 12–18 | Evaluación en test, reconstrucción, 41 sujetos, figuras, familias, ley de Fung, muestras |
| 19 | Diseñador de injerto |
| 20 | Reproducción de láminas aisladas |
| 21 | Las bases con su fórmula |
| 22 | Extrapolación fuera del dominio de ajuste |

- Con `ENTRENAR = True` el cuaderno genera el dataset y entrena la red; con `False`, carga una red ya entrenada.
- Los archivos de la red llevan en el nombre el número de bases, de modo que redes con 4, 5 o 6 materiales no se pisan entre sí.
- Las tablas de Masson (`tabla2_masson_NT.csv`, `tabla4_masson_HT.csv`) van en la misma carpeta que el cuaderno.

# B. Datos de partida: Masson et al. (2011)

Este apéndice reúne la información del artículo de Masson et al. (2011) que usa el método, para que el documento sea autocontenido. Los autores midieron in vivo, a lo largo del ciclo cardíaco, el diámetro, el espesor íntima–media y la presión de la carótida común de 16 sujetos normotensos y 25 hipertensos tratados. A cada sujeto le ajustaron un modelo constitutivo de la pared arterial, y publicaron los parámetros en las Tablas 2 y 4 del artículo (Tablas 20 y 21 de este informe). La ley constitutiva, la cinemática y el cálculo de la presión de pared a partir de esos parámetros están en la Sección 2.

## B.1. Figuras 5a y 7a: de la tensión a la presión de pared

Las Figs. 20 y 21 muestran el contenido de las Figs. 5a y 7a del artículo, recalculado con la ley constitutiva y los parámetros de las Tablas 20 y 21: la tensión circunferencial $\sigma_{\theta\theta}$ en $r_m$ de cada sujeto y las curvas medias, junto con las curvas medias publicadas (digitalizadas). Las presiones de pared de los mismos sujetos, que son las curvas objetivo de este trabajo, están en la Fig. 2. La presión es del orden de la tensión por $h/r$ ($\approx 0{,}16$, con el espesor supuesto $h = 0{,}6\,\mathrm{mm}$), por eso sus valores son unas seis veces menores. Las curvas publicadas cubren solo el rango de $\lambda$ medido en cada sujeto; las recalculadas se muestran en todo el dominio [1,02; 1,16].

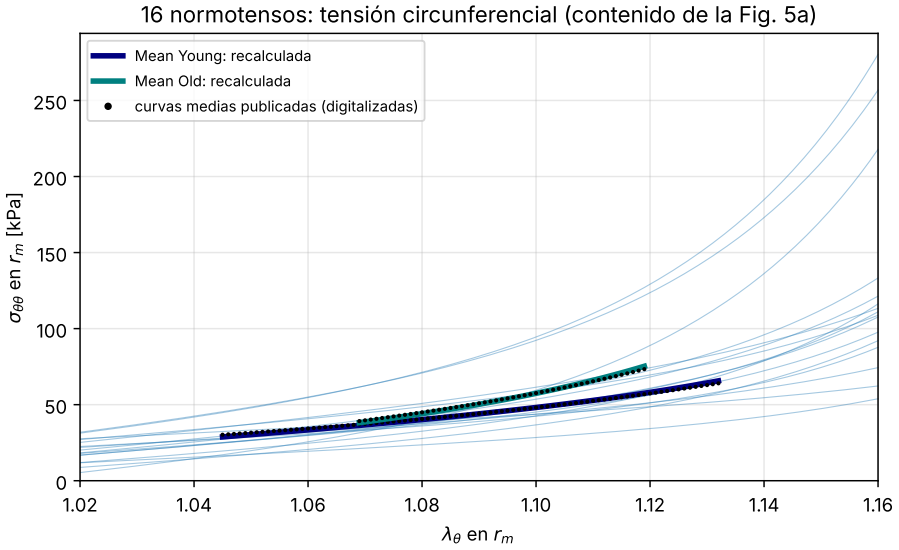



**Figura 20:** Contenido de la Fig. 5a de Masson et al. (2011), recalculado: tensión circunferencial de los 16 normotensos (finas) y medias de jóvenes (edad $\leq 42$) y mayores (edad $\geq 53$). Puntos: curvas medias publicadas, digitalizadas.

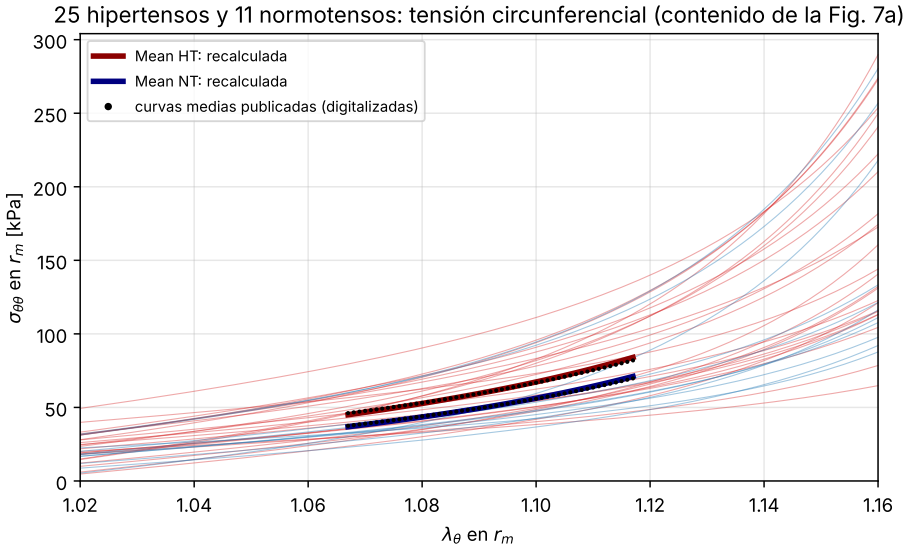



**Figura 21:** Contenido de la Fig. 7a de Masson et al. (2011), recalculado: 25 hipertensos (rojo) y 11 normotensos de edad comparable (azul), con sus medias. Puntos: curvas medias publicadas, digitalizadas.

## B.2. Tablas 2 y 4: parámetros de los 41 sujetos

Las Tablas 20 y 21 reproducen los parámetros publicados:

- **Geometría:** $R_m$ y $\Theta_0$ son el radio medial (interfaz media–adventicia) y el ángulo de apertura de la configuración libre de tensiones, y $\lambda_z$ es el estiramiento axial in vivo.
- **Elastina:** $c$.
- **Colágeno:** $c_1$ y $c_2$ (fibras axiales y diagonales), $c_1^{circ}$ y $c_2^{circ}$ (fibras circunferenciales), y $\alpha$, el ángulo de las fibras diagonales.
- **Tono activo:** $T_m$, $\lambda_0$ y $\lambda_m$.
- **Presión perivascular:** $a$ y $b$.

Los sujetos marcados con † son los 10 reservados para test.

**Tabla 20:** Tabla 2 de Masson et al. (2011): parámetros de los 16 sujetos normotensos. †: sujeto reservado para test. RMSE: error del ajuste del modelo a los datos, informado por los autores.

| Sujeto | Edad [años] | Sexo | $R_m$ [mm] | $\Theta_0$ [°] | $\lambda_z$ | $c$ [kPa] | $c_1$ [kPa] | $c_2$ | $c_1^{circ}$ [kPa] | $c_2^{circ}$ | $\alpha$ [°] | $T_m$ [kPa] | $\lambda_0$ | $\lambda_m$ | $a$ [kPa] | $b$ | RMSE [kPa] |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| NT01 | 62 | F | 4,261 | 128,7 | 1,11 | 29,82 | 9,44 | 14,14 | 16,13 | 15,11 | 65,74 | 39,73 | 0,96 | 1,70 | 0,122 | 3,52 | 0,174 |
| NT02† | 60 | M | 4,691 | 128,9 | 1,08 | 20,42 | 8,47 | 13,10 | 14,16 | 15,12 | 44,46 | 41,84 | 0,68 | 1,92 | 0,126 | 3,40 | 0,288 |
| NT03 | 31 | M | 4,305 | 132,2 | 1,09 | 27,23 | 10,34 | 13,10 | 7,01 | 12,82 | 48,62 | 43,37 | 0,82 | 1,65 | 0,139 | 3,57 | 0,131 |
| NT04 | 31 | M | 4,672 | 133,9 | 1,10 | 23,59 | 6,58 | 11,77 | 6,38 | 10,69 | 32,04 | 39,81 | 0,68 | 1,59 | 0,118 | 3,53 | 0,146 |
| NT05 | 34 | F | 4,203 | 130,1 | 1,10 | 35,68 | 13,62 | 13,18 | 13,38 | 13,17 | 50,72 | 50,07 | 0,86 | 1,62 | 0,103 | 3,58 | 0,123 |
| NT06 | 53 | F | 3,957 | 130,1 | 1,11 | 33,37 | 11,38 | 13,63 | 13,30 | 14,26 | 57,14 | 46,59 | 0,95 | 1,69 | 0,093 | 3,44 | 0,269 |
| NT07 | 21 | F | 3,827 | 132,0 | 1,10 | 44,28 | 21,79 | 13,17 | 8,27 | 12,73 | 51,15 | 53,58 | 0,92 | 1,62 | 0,111 | 3,58 | 0,215 |
| NT08† | 25 | M | 4,856 | 133,2 | 1,07 | 23,25 | 6,34 | 12,93 | 8,11 | 13,17 | 42,93 | 31,90 | 0,82 | 1,77 | 0,173 | 3,57 | 0,367 |
| NT09 | 42 | F | 4,506 | 129,5 | 1,10 | 34,90 | 16,14 | 13,58 | 19,64 | 13,89 | 57,21 | 47,01 | 0,93 | 1,65 | 0,084 | 3,55 | 0,209 |
| NT10† | 55 | M | 4,770 | 129,1 | 1,10 | 38,57 | 36,31 | 13,31 | 56,88 | 13,61 | 54,22 | 46,36 | 0,89 | 1,66 | 0,006 | 3,75 | 0,652 |
| NT11† | 64 | M | 5,566 | 129,5 | 1,10 | 34,89 | 40,16 | 13,45 | 66,88 | 13,53 | 54,54 | 41,12 | 0,85 | 1,79 | 0,005 | 3,23 | 0,375 |
| NT12 | 60 | F | 4,876 | 130,1 | 1,09 | 33,94 | 10,78 | 13,95 | 12,79 | 15,42 | 60,97 | 45,77 | 0,93 | 1,73 | 0,099 | 3,37 | 0,362 |
| NT13 | 61 | F | 4,924 | 130,6 | 1,09 | 35,15 | 17,69 | 13,43 | 18,40 | 13,22 | 55,04 | 45,59 | 0,94 | 1,66 | 0,085 | 3,51 | 0,240 |
| NT14 | 39 | F | 3,539 | 131,5 | 1,09 | 28,97 | 8,22 | 13,13 | 19,02 | 13,16 | 50,22 | 41,30 | 0,89 | 1,67 | 0,105 | 3,53 | 0,262 |
| NT15 | 58 | F | 3,922 | 132,4 | 1,08 | 26,71 | 15,79 | 13,36 | 16,68 | 13,11 | 53,60 | 35,32 | 0,95 | 1,71 | 0,166 | 3,60 | 0,302 |
| NT16 | 60 | M | 5,718 | 129,7 | 1,10 | 27,79 | 28,23 | 13,46 | 57,77 | 13,63 | 55,73 | 36,50 | 1,05 | 1,77 | 0,141 | 3,58 | 0,283 |

**Tabla 21:** Tabla 4 de Masson et al. (2011): parámetros de los 25 sujetos hipertensos tratados. †: sujeto reservado para test. RMSE: error del ajuste del modelo a los datos, informado por los autores.

| Sujeto | Edad [años] | Sexo | $R_m$ [mm] | $\Theta_0$ [°] | $\lambda_z$ | $c$ [kPa] | $c_1$ [kPa] | $c_2$ | $c_1^{circ}$ [kPa] | $c_2^{circ}$ | $\alpha$ [°] | $T_m$ [kPa] | $\lambda_0$ | $\lambda_m$ | $a$ [kPa] | $b$ | RMSE [kPa] |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| HT01 | 68 | M | 4,965 | 130,9 | 1,10 | 35,91 | 12,57 | 14,08 | 15,52 | 14,91 | 67,18 | 48,42 | 0,99 | 1,66 | 0,098 | 3,50 | 0,300 |
| HT02 | 54 | M | 4,927 | 129,8 | 1,10 | 38,20 | 16,40 | 13,20 | 16,44 | 13,20 | 51,11 | 52,44 | 0,86 | 1,62 | 0,137 | 3,58 | 0,213 |
| HT03† | 64 | F | 4,869 | 129,5 | 1,10 | 36,01 | 14,55 | 13,96 | 18,35 | 14,48 | 62,66 | 47,02 | 1,00 | 1,74 | 0,113 | 3,62 | 0,419 |
| HT04 | 58 | F | 4,574 | 131,2 | 1,09 | 22,42 | 8,57 | 13,03 | 6,43 | 13,36 | 46,38 | 38,53 | 0,81 | 1,68 | 0,099 | 3,51 | 0,346 |
| HT05† | 62 | F | 4,779 | 130,1 | 1,10 | 48,19 | 35,06 | 13,23 | 43,19 | 13,03 | 53,24 | 52,86 | 0,91 | 1,63 | 0,033 | 3,56 | 0,218 |
| HT06 | 66 | F | 5,062 | 129,1 | 1,10 | 39,78 | 37,75 | 13,35 | 60,89 | 13,45 | 56,01 | 46,44 | 0,91 | 1,64 | 0,004 | 3,54 | 0,349 |
| HT07 | 54 | F | 4,298 | 129,6 | 1,11 | 50,45 | 25,51 | 13,32 | 39,43 | 13,24 | 53,47 | 64,91 | 0,93 | 1,66 | 0,078 | 3,72 | 0,341 |
| HT08 | 63 | F | 4,436 | 129,0 | 1,10 | 34,44 | 30,62 | 13,29 | 60,33 | 13,21 | 54,67 | 44,94 | 0,93 | 1,65 | 0,084 | 3,56 | 0,518 |
| HT09 | 68 | M | 5,090 | 128,2 | 1,12 | 51,48 | 33,77 | 13,17 | 44,26 | 13,49 | 51,83 | 66,41 | 0,84 | 1,62 | 0,023 | 3,55 | 0,277 |
| HT10 | 55 | F | 4,300 | 129,0 | 1,10 | 37,04 | 12,32 | 14,13 | 15,04 | 14,93 | 65,14 | 48,19 | 1,04 | 1,71 | 0,114 | 3,47 | 0,270 |
| HT11 | 69 | M | 5,545 | 131,2 | 1,08 | 29,64 | 9,76 | 13,23 | 9,10 | 15,12 | 48,16 | 37,83 | 0,83 | 1,74 | 0,115 | 3,59 | 0,263 |
| HT12 | 54 | M | 5,426 | 131,8 | 1,09 | 32,23 | 17,81 | 13,35 | 14,03 | 12,15 | 53,73 | 44,93 | 0,92 | 1,65 | 0,090 | 3,58 | 0,185 |
| HT13† | 61 | M | 5,169 | 128,4 | 1,11 | 30,45 | 15,87 | 13,08 | 23,03 | 13,84 | 47,86 | 52,58 | 0,75 | 1,61 | 0,009 | 3,49 | 0,315 |
| HT14† | 60 | M | 4,640 | 129,9 | 1,10 | 30,43 | 13,74 | 13,45 | 18,01 | 13,35 | 54,90 | 42,43 | 0,91 | 1,66 | 0,088 | 3,52 | 0,158 |
| HT15 | 53 | M | 4,649 | 130,4 | 1,10 | 40,83 | 28,98 | 13,36 | 31,16 | 12,62 | 54,44 | 49,57 | 0,93 | 1,65 | 0,085 | 3,63 | 0,311 |
| HT16 | 54 | M | 4,713 | 129,6 | 1,10 | 45,26 | 29,27 | 14,00 | 33,48 | 14,82 | 67,16 | 67,68 | 1,02 | 1,65 | 0,039 | 3,52 | 0,194 |
| HT17 | 53 | M | 5,043 | 130,0 | 1,10 | 37,25 | 39,18 | 13,24 | 66,29 | 13,15 | 54,90 | 48,26 | 0,91 | 1,64 | 0,099 | 3,60 | 0,252 |
| HT18 | 52 | M | 4,922 | 129,7 | 1,10 | 29,28 | 10,50 | 13,21 | 19,76 | 13,39 | 50,96 | 46,42 | 0,85 | 1,63 | 0,094 | 3,56 | 0,200 |
| HT19† | 57 | F | 4,270 | 130,3 | 1,10 | 33,49 | 14,47 | 13,22 | 17,35 | 13,27 | 53,18 | 46,18 | 0,90 | 1,64 | 0,097 | 3,55 | 0,228 |
| HT20 | 61 | F | 5,143 | 129,2 | 1,10 | 40,09 | 15,72 | 14,09 | 16,78 | 14,83 | 65,17 | 53,40 | 1,04 | 1,70 | 0,100 | 3,47 | 0,265 |
| HT21 | 57 | F | 4,881 | 129,9 | 1,10 | 35,31 | 14,57 | 13,26 | 15,58 | 13,30 | 52,07 | 48,97 | 0,87 | 1,63 | 0,094 | 3,57 | 0,442 |
| HT22 | 44 | F | 4,170 | 131,0 | 1,10 | 55,25 | 35,78 | 13,23 | 19,51 | 12,55 | 52,36 | 59,58 | 0,93 | 1,61 | 0,097 | 3,61 | 0,335 |
| HT23 | 51 | M | 4,827 | 130,6 | 1,08 | 30,77 | 12,80 | 13,60 | 41,10 | 14,20 | 49,79 | 41,06 | 0,87 | 1,90 | 0,094 | 3,56 | 0,337 |
| HT24† | 65 | M | 4,565 | 129,6 | 1,10 | 38,91 | 25,76 | 13,20 | 35,01 | 13,20 | 51,94 | 50,28 | 0,87 | 1,62 | 0,043 | 3,58 | 0,212 |
| HT25 | 67 | F | 4,718 | 129,2 | 1,10 | 40,29 | 31,78 | 13,75 | 60,40 | 14,29 | 63,50 | 46,06 | 1,03 | 1,72 | 0,025 | 3,46 | 0,412 |

# C. Glosario

Términos técnicos usados en el informe, en orden alfabético. La columna de la derecha indica dónde se desarrollan o una referencia que los explica en detalle.

| Término | Definición | Dónde / referencia |
|---|---|---|
| Adam | Algoritmo de entrenamiento de redes neuronales: una variante del descenso por gradiente que adapta el tamaño del paso de cada peso. | Kingma y Ba (2015) |
| Ángulo de apertura $\Theta_0$ | Ángulo del sector que forma la arteria al cortarla longitudinalmente; representa las tensiones residuales de la pared. | Secc. 2; Masson et al. (2011) |
| BFGS / L-BFGS-B | Métodos de optimización que usan el gradiente de la función (aquí aproximado por diferencias finitas) para elegir la dirección de descenso. | Nocedal y Wright (2006) |
| Diferencias finitas | Aproximación numérica de una derivada: $[J(k+h) - J(k)]/h$ con $h$ pequeño. Falla si la función tiene quiebres u ondulaciones. | Nocedal y Wright (2006) |
| Evolución diferencial | Método de optimización global sin derivadas. Mantiene una población de juegos de nudos repartida por todo el rango y la mejora generación tras generación (mutación, cruza y selección). Aquí es la búsqueda principal de los nudos. | Secc. 4.6; Storn y Price (1997); Price et al. (2005) |
| $C_{LAM}$ | Número de láminas con que la curva más exigente del espacio de trabajo usa cada material. Fija la rigidez de una lámina: es una elección de unidades. | Secc. 4.9 |
| cond($A$) | Número de condición: cociente entre el mayor y el menor valor singular de la matriz de bases normalizada. Si es grande, pequeños errores en la curva producen grandes cambios en las láminas. | Paso 4; Trefethen y Bau (1997) |
| Crosstalk | Láminas que la red asigna a un material que no está presente en la curva ("fuga" de un material a otro). Se penaliza en la pérdida. | Secc. de la red |
| CVaR 99 % | Promedio de los errores del 1 % de curvas peor ajustadas. Es la medida de la cola de errores que minimiza el método minimax. | Paso 3; Rockafellar y Uryasev (2000) |
| Curvas límite $y_1$, $y_2$ | Curvas inferior y superior que definen la franja del espacio de trabajo. | Secc. 3 |
| Ecuaciones normales | $A^\mathsf{T}Ac = A^\mathsf{T}y$: la condición que cumple la solución de MCO. | Lawson y Hanson (1974) |
| Época | Una pasada completa del entrenamiento por todas las curvas de entrenamiento. | Goodfellow et al. (2016) |
| Error punto a punto $e$ | Mayor diferencia, en valor absoluto, entre la curva y su ajuste en los puntos de la grilla, dividida por el rango de la curva (en %). El criterio de diseño exige $e \leq 3$ %. | Paso 1 |
| Envolvente inferior | Para cada $\lambda$, la menor presión entre los 41 sujetos. La curva límite $y_1$ queda por debajo de ella. | Secc. 3 |
| Espacio de trabajo | Conjunto de curvas generadas con la ley de Masson que quedan entre $y_1$ e $y_2$. | Secc. 3 |
| Estandarizar | Restar la media y dividir por el desvío estándar, para que todas las variables tengan escala comparable. | |
| Exceso | Cuánto peor ajusta la red que el óptimo MCO: NRMSE de la red / NRMSE óptimo − 1. | Resultados |
| Familias de bases / fisiológicas | Grupos de curvas del dataset: poligonales armadas con las bases, o curvas con forma de arteria generadas con leyes constitutivas o tomadas de pacientes. | Secc. del dataset |
| Grilla | Los 999 valores equiespaciados de $\lambda$ entre 1,02 y 1,16 en los que se evalúan todas las curvas (paso $\approx$ 0,00014). | Secc. 1 |

| Término | Definición | Dónde / referencia |
|---|---|---|
| Hipercubo latino | Forma de sortear una población: se divide el rango de cada variable en tantas franjas como miembros y se pone exactamente uno en cada franja, para cubrir el rango de forma pareja. | Secc. 4.6 |
| $J(k)$ | Función objetivo que califica un juego de nudos $k$: $J = \mathrm{CVaR}_{99} + 0{,}25\,\overline{\mathrm{NRMSE}} + 50\,\mathrm{máx}(0, \mathrm{cond}(A) - 24) + 1000\,\overline{\mathrm{neg}} + 100\,\mathrm{máx}_i\,\mathrm{neg}_i$. El primer término mide la cola de errores, el segundo desempata, y los demás actúan como restricciones de estabilidad y de signo. Se minimiza con evolución diferencial y Nelder–Mead. | Paso 6 |
| Learning rate | Tasa de aprendizaje: tamaño de cada corrección de los pesos de la red durante el entrenamiento. | Goodfellow et al. (2016) |
| Ley de Laplace | En un tubo de pared delgada, la tensión de membrana es igual a la presión por el radio. | |
| Ley de Masson | Ley constitutiva de la pared de la carótida: elastina neo-Hookeana, cuatro familias de fibras de colágeno y tono muscular activo, con parámetros ajustados a 41 sujetos medidos in vivo. | Secc. 2; Ap. B; Masson et al. (2011) |
| Línea truncada | Función $S\,\mathrm{máx}(0, \lambda - k)$: vale cero hasta el nudo $k$ y crece con pendiente $S$ desde allí. Representa una lámina de un material. | Secc. 4.1 |
| Lote | Grupo de curvas (aquí 64) que la red procesa antes de cada corrección de sus pesos. | Goodfellow et al. (2016) |
| MCO | Mínimos cuadrados ordinarios: se eligen las láminas que minimizan la suma de los cuadrados de las diferencias entre la curva y el ajuste. Tiene solución exacta, $c = A^{+}y$. | Secc. 4.2; Lawson y Hanson (1974) |
| Mediana / percentil | La mediana deja la mitad de los casos por debajo; el percentil $p$ deja el $p$ % por debajo. | |
| Minimax | Criterio que elige los nudos para minimizar los errores de las curvas *peor* ajustadas, no el promedio. | Secc. 4.5 |
| Mínimo local | Punto donde la función es menor que en sus alrededores, pero no necesariamente el menor de todos (mínimo global). Un método local termina en el mínimo local más cercano a su punto de partida. | Secc. 4.7 |
| Nelder–Mead | Método de optimización numérica local sin derivadas (*simplex descendente*). Aquí refina el mejor juego de nudos hallado por la evolución diferencial. No es un método de mínimos cuadrados. | Secc. 4.6; Nelder y Mead (1965); Press et al. (2007) |
| NNLS | Mínimos cuadrados no negativos: MCO con la restricción de que todos los coeficientes sean $\geq 0$. | Lawson y Hanson (1974) |
| Normalización de capa | Operación de la red que reescala las salidas de cada capa a media 0 y desvío 1, y estabiliza el entrenamiento. | Ba et al. (2016) |
| NRMSE | Raíz del error cuadrático medio dividida por el rango de la curva (%). Mide el error típico a lo largo de la curva. | Paso 1 |
| Nudo (*knot*) | Valor de $\lambda$ en el que una lámina empieza a aportar presión: es el quiebre de la línea truncada. | Secc. 4.1 |
| Óptimo local / global | Un óptimo local es el mejor punto de su entorno; el global, el mejor de todo el rango permitido. | |
| Powell (método de) | Método local sin derivadas que minimiza a lo largo de direcciones sucesivas. | Powell (1964) |
| Parada temprana | Detener el entrenamiento cuando la pérdida de validación deja de mejorar y quedarse con los mejores pesos. | Goodfellow et al. (2016) |
| `PEND_MAX` | Pendiente máxima que exige el espacio de trabajo a cada capa; dividida por $C_{LAM}$ da la pendiente de una lámina. | Secc. 4.9 |
| Presión de pared $P_{pared}$ | Presión interna menos la presión que ejercen la adventicia y el tejido perivascular sobre la capa íntima–media: $P_i - P_a$. Es la curva objetivo. | Secc. 2 |

| Término | Definición | Dónde / referencia |
|---|---|---|
| Pseudoinversa $A^+$ | $(A^\mathsf{T}A)^{-1}A^\mathsf{T}$ cuando las columnas de $A$ son independientes. Da la solución de MCO. | Trefethen y Bau (1997) |
| Pulido | Paso MCO aplicado a una curva para obtener el óptimo exacto, en lugar de usar la salida de la red. | Secc. de la red |
| Radio medial $r_m$ | Radio de la interfaz media–adventicia. El estiramiento circunferencial en ese radio, $\lambda_\theta = r_m/R_{ref}$, es la abscisa de todas las curvas. | Secc. 2 |
| $R^2$ | Coeficiente de determinación, $1 - \sum r_i^2 / \sum (y_i - \bar{y})^2$. Vale 1 para un ajuste perfecto. | Resultados |
| Red neuronal densa | Función con muchos parámetros, organizada en capas de neuronas, que transforma la entrada en la salida. Se ajusta (entrena) con datos. | Goodfellow et al. (2016) |
| ReLU | Función no lineal máx$(0, x)$ que aplica cada neurona. | Goodfellow et al. (2016) |
| Semilla | Número que inicializa el generador de números aleatorios. Con la misma semilla, los sorteos se repiten, y el resultado es reproducible. | |
| Simplex | Figura de $N + 1$ vértices en $N$ dimensiones (triángulo en 2D, tetraedro en 3D) con la que trabaja Nelder–Mead. | Secc. 4.6 |
| Sobreajuste | Situación en que la red memoriza las curvas de entrenamiento y empeora en curvas nuevas. | Goodfellow et al. (2016) |
| Test / validación / entrenamiento | Conjuntos disjuntos de curvas:<br>▪ entrenamiento: para ajustar los pesos;<br>▪ validación: para controlar el entrenamiento;<br>▪ test: solo para la evaluación final. | Secc. del dataset |
| Valores singulares (SVD) | Factores de estiramiento de una matriz en sus direcciones principales, $A = U\Sigma V^\mathsf{T}$. | Trefethen y Bau (1997) |

# Referencias


Ba, J. L., Kiros, J. R., Hinton, G. E. (2016). Layer normalization. *arXiv:1607.06450*. https://arxiv.org/abs/1607.06450

Fung, Y. C. (1993). *Biomechanics: Mechanical Properties of Living Tissues* (2.ª ed.). Springer, Nueva York. https://doi.org/10.1007/978-1-4757-2257-4

Golub, G. H., Pereyra, V. (1973). The differentiation of pseudo-inverses and nonlinear least squares problems whose variables separate. *SIAM Journal on Numerical Analysis*, 10(2), 413–432. https://doi.org/10.1137/0710036

Goodfellow, I., Bengio, Y., Courville, A. (2016). *Deep Learning*. MIT Press. https://www.deeplearningbook.org

Holzapfel, G. A., Gasser, T. C., Ogden, R. W. (2000). A new constitutive framework for arterial wall mechanics and a comparative study of material models. *Journal of Elasticity*, 61, 1–48. https://doi.org/10.1023/A:1010835316564

Hooke, R., Jeeves, T. A. (1961). "Direct search" solution of numerical and statistical problems. *Journal of the ACM*, 8(2), 212–229. https://doi.org/10.1145/321062.321069

Jupp, D. L. B. (1978). Approximation to data by splines with free knots. *SIAM Journal on Numerical Analysis*, 15(2), 328–343. https://doi.org/10.1137/0715022

Kingma, D. P., Ba, J. (2015). Adam: A method for stochastic optimization. *3rd International Conference on Learning Representations (ICLR)*. arXiv:1412.6980. https://arxiv.org/abs/1412.6980

Lagarias, J. C., Reeds, J. A., Wright, M. H., Wright, P. E. (1998). Convergence properties of the Nelder–Mead simplex method in low dimensions. *SIAM Journal on Optimization*, 9(1), 112–147. https://doi.org/10.1137/S1052623496303470

Lawson, C. L., Hanson, R. J. (1974). *Solving Least Squares Problems*. Prentice-Hall (reeditado por SIAM, 1995). https://doi.org/10.1137/1.9781611971217

Masson, I., Beaussier, H., Boutouyrie, P., Laurent, S., Humphrey, J. D., Zidi, M. (2011). Carotid artery mechanical properties and stresses quantified using in vivo data from normotensive and hypertensive humans. *Biomechanics and Modeling in Mechanobiology*, 10, 867–882. https://doi.org/10.1007/s10237-010-0279-6

McKinnon, K. I. M. (1998). Convergence of the Nelder–Mead simplex method to a nonstationary point. *SIAM Journal on Optimization*, 9(1), 148–158. https://doi.org/10.1137/S1052623496303482

Nelder, J. A., Mead, R. (1965). A simplex method for function minimization. *The Computer Journal*, 7(4), 308–313. https://doi.org/10.1093/comjnl/7.4.308

Nocedal, J., Wright, S. J. (2006). *Numerical Optimization* (2.ª ed.). Springer. https://doi.org/10.1007/978-0-387-40065-5

Powell, M. J. D. (1964). An efficient method for finding the minimum of a function of several variables without calculating derivatives. *The Computer Journal*, 7(2), 155–162. https://doi.org/10.1093/comjnl/7.2.155

Price, K. V., Storn, R. M., Lampinen, J. A. (2005). *Differential Evolution: A Practical Approach to Global Optimization*. Springer. https://doi.org/10.1007/3-540-31306-0

Press, W. H., Teukolsky, S. A., Vetterling, W. T., Flannery, B. P. (2007). *Numerical Recipes: The Art of Scientific Computing* (3.ª ed.). Cambridge University Press. Sec. 10.5: *Downhill simplex method in multidimensions*. https://numerical.recipes

Rachev, A., Hayashi, K. (1999). Theoretical study of the effects of vascular smooth muscle contraction on strain and stress distributions in arteries. *Annals of Biomedical Engineering*, 27(4), 459–468. https://doi.org/10.1114/1.191

Rockafellar, R. T., Uryasev, S. (2000). Optimization of conditional value-at-risk. *Journal of Risk*, 2(3), 21–41. https://doi.org/10.21314/JOR.2000.038

Storn, R., Price, K. (1997). Differential evolution: a simple and efficient heuristic for global optimization over continuous spaces. *Journal of Global Optimization*, 11, 341–359. https://doi.org/10.1023/A:1008202821328

Trefethen, L. N., Bau, D. (1997). *Numerical Linear Algebra*. SIAM. https://doi.org/10.1137/1.9780898719574

Virtanen, P., Gommers, R., Oliphant, T. E., et al. (2020). SciPy 1.0: fundamental algorithms for scientific computing in Python. *Nature Methods*, 17, 261–272. https://doi.org/10.1038/s41592-019-0686-2