Diseño de injertos vasculares biomiméticos con láminas de materiales mediante una red neuronal: método minimax de las bases y validación con 41 carótidas humanas

Pablo

19 de octubre de 2026

Resumen

Se presenta un método para diseñar injertos vasculares multicapa a partir de la curva presión–diámetro de una arteria. Cada función base es la curva de *una lámina* de un material, idealizada como una línea truncada $A_j(\lambda) = S_j\,\mathrm{máx}(0, \lambda - k_j)$. Cada coeficiente es el *número de láminas* de ese material, y se obtiene por mínimos cuadrados ordinarios (MCO). Una red neuronal aprende a dar esas láminas directamente a partir de la curva. El criterio de diseño es un error punto a punto de a lo sumo el 3 % del rango de la curva.

Espacio de trabajo. Las curvas objetivo son las presiones de pared de 41 carótidas humanas (Masson et al., 2011), en $\lambda_\theta \in [1{,}02;\ 1{,}16]$, el rango respaldado por las mediciones. El espacio de trabajo es la franja entre dos curvas límite que contienen a los 41 sujetos y llegan hasta 60 kPa.

Bases. El objetivo es elegir la base de modo que el ajuste sea MCO *sin condiciones* (sin cotas ni restricciones sobre las láminas): $c = A^{+}y$. Toda la exigencia se traslada a la elección de los nudos k_j, que se hace con un método minimax: se minimiza la media del peor 1 % de los errores punto a punto del MCO (CVaR 99 %), con la restricción $\mathrm{cond}(A) < 25$ y una penalización por láminas negativas. La búsqueda se hace con evolución diferencial, un método global que da el mismo resultado con distintas semillas, y un refinamiento con Nelder–Mead. Con 5 materiales, el MCO libre cumple el criterio en las 22 500 curvas del espacio de trabajo (máximo 2,04 %) y en los 41 sujetos, con $\mathrm{cond}(A) = 17{,}8$, y da todas las láminas ≥ 0 en los 41 sujetos y en el 99,98 % del espacio de trabajo. Con 4 materiales no alcanza; con 6 mejora moderadamente, con $\mathrm{cond}(A)$ en el límite.

Red neuronal. Entrenada con 50 000 curvas sintéticas, la red sola cumple el 3 % en los 41 sujetos y queda a +0,75 % del NRMSE óptimo, con mediana de +0,3 % en los sujetos de test. En las familias fisiológicas del dataset de test (curvas con forma de arteria, generadas con leyes constitutivas o tomadas de los pacientes) el exceso queda entre +0,3 y +1,0 %, y las 6 000 curvas cumplen el criterio. En una ley constitutiva nunca vista (tipo Fung) el exceso es de +1,5 %. Reproduce láminas aisladas con un crosstalk de 0,001 láminas, y su diseño para la curva media de los hipertensos coincide con el óptimo en 0,01 láminas. *Los términos técnicos se definen en su primera aparición y se reúnen en el Glosario (Apéndice C).*

Palabras clave— Mínimos cuadrados ordinarios, Líneas truncadas, Aproximación minimax, CVaR, Número de condición, Evolución diferencial, Nelder–Mead, Red neuronal, Injerto vascular biomimético, Curva presión–diámetro.

Índice

1. Planteo del problema **3**

1.1. Variable objetivo y dominio 3

1.2. Curvas límite y espacio de trabajo 3

1.3. Dominio de validez 4

1.4. Bases: una lámina de cada material 5

2. Elección óptima de la base: el método minimax **5**
2.1. El problema: qué es un nudo y por qué importa . . . 6
2.2. Visión general del procedimiento . . . 7
2.3. Rango de búsqueda y ubicación típica de los nudos . . . 8
2.4. El criterio minimax: cómo se califica un juego de nudos . . . 8
2.4.1. Paso 1: el error de *una* curva . . . 8
2.4.2. Paso 2: de una curva a la población . . . 9
2.4.3. Paso 3: por qué la media del peor 1 % y no el máximo . . . 10
2.4.4. Paso 4: el número de condición, cond(A) . . . 13
2.4.5. Paso 5: el signo de las láminas . . . 15
2.4.6. Paso 6: la función objetivo completa J . . . 15
2.5. El método de búsqueda: evolución diferencial y refinamiento con Nelder–Mead . . . 16
2.5.1. Etapa 1: búsqueda global con evolución diferencial . . . 16
2.5.2. Etapa 2: refinamiento local con Nelder–Mead . . . 17
2.6. Por qué este optimizador y no otro . . . 18
2.7. Robustez del resultado . . . 21
2.8. Resultados: 4, 5 o 6 bases . . . 22
2.9. Qué garantiza la base elegida y qué no . . . 22
2.10. Cómo se usa en el cuaderno . . . 23

3. Pendientes máximas y escala de las láminas **24**

4. Dataset sintético y red neuronal **25**
4.1. Dataset . . . 25
4.2. Red y entrenamiento . . . 27

5. Resultados de la red **28**
5.1. Entrenamiento . . . 28
5.2. Los 41 sujetos y las curvas medias . . . 28
5.3. Test por familia . . . 29
5.4. Generalización a una ley nunca vista y control de clase . . . 30
5.5. Reproducción de láminas aisladas . . . 31

6. Diseño: la curva media de los hipertensos **31**

7. Conclusiones **32**

A. El cuaderno **33**

B. Datos de partida: Masson et al. (2011) **33**
B.1. Ley constitutiva . . . 33
B.2. Cinemática y presión de pared . . . 34
B.3. Figuras 5a y 7a: de la tensión a la presión de pared . . . 34
B.4. Tablas 2 y 4: parámetros de los 41 sujetos . . . 35

C. Glosario **38**

1. Planteo del problema

1.1. Variable objetivo y dominio

La curva objetivo es la presión transmural de pared en función del estiramiento circunferencial en el radio medio, $\lambda_\theta = r_m/R_{ref}$, proporcional al diámetro:

$$P_{pared}(\lambda_\theta) = P_i - P_a = \int_{r_i}^{r_m} \frac{\sigma_{\theta\theta} - \sigma_{rr}}{r}\, dr.$$

Se calcula con el modelo constitutivo y los parámetros publicados de 41 sujetos (16 normotensos y 25 hipertensos tratados; Masson et al. 2011): elastina neo-Hookeana, cuatro familias de fibras de colágeno y tono muscular activo, con espesor $h = 0{,}6\,\text{mm}$. La ley constitutiva completa, las tablas de parámetros (Tablas 2 y 4 del artículo) y sus figuras originales 5a y 7a están en el Apéndice B.

El dominio es $\lambda_\theta \in [1{,}02;\ 1{,}16]$.

La grilla. Una computadora no maneja funciones continuas sino listas de números. Por eso el dominio se *discretiza*: se lo representa con una **grilla** de 999 valores de λ equiespaciados,

$$\lambda_1 = 1{,}02, \quad \lambda_2 = 1{,}02014, \quad \ldots, \quad \lambda_{999} = 1{,}16,$$

con paso $(1{,}16 - 1{,}02)/998 \approx 0{,}00014$. Cada curva queda representada por el vector de sus 999 valores, $P(\lambda_1), \ldots, P(\lambda_{999})$. Todas las sumas, máximos y errores de este informe se calculan sobre esos 999 puntos, y ese mismo vector es la entrada de la red. En todo el dominio, los 41 sujetos tienen $P_{pared} > 0$. Se reservan 10 sujetos para test (NT02, NT08, NT10, NT11, HT03, HT05, HT13, HT14, HT19, HT24). No participan ni en la elección de las bases ni en el generador de datos.

1.2. Curvas límite y espacio de trabajo

El *espacio de trabajo* son las curvas generadas con la ley de Masson que quedan entre dos curvas límite, $y_1(\lambda) \le y(\lambda) \le y_2(\lambda)$, en todo el dominio. Las curvas límite se construyen a partir de los sujetos extremos de la población:

$$y_1(\lambda) = P_{NT08}(\lambda) - P_{NT08}(1{,}02) \qquad \text{(la más distensible, desplazada a 0 en } \lambda = 1{,}02),$$
$$y_2(\lambda) = P_{HT09}(\lambda) + a\left(e^{\,b\,E^2} - 1\right), \qquad E = \text{máx}\Big(0,\ (\lambda/1{,}10)^2 - 1\Big).$$

y_2 coincide con la del sujeto más rígido (HT09) hasta $\lambda = 1{,}10$. Desde allí suma un término con la forma exponencial del colágeno circunferencial de Masson, con $b = c_2^{circ}$ de HT09 (13,49) y $a = 80{,}2\,\text{kPa}$, elegido para que $y_2(1{,}16) = 60\,\text{kPa}$.

Los 41 sujetos quedan dentro de la franja (Fig. 1). El espacio de trabajo se genera mezclando y perturbando los parámetros de los 31 sujetos de entrenamiento (Sección 4). Tiene 22 500 curvas. En $\lambda = 1{,}16$ sus presiones van de 10,0 kPa (*percentil 1*: el 1 % de las curvas queda por debajo de ese valor) a 60,0 kPa, con mediana de 25,9 kPa (la mitad de las curvas queda por debajo).

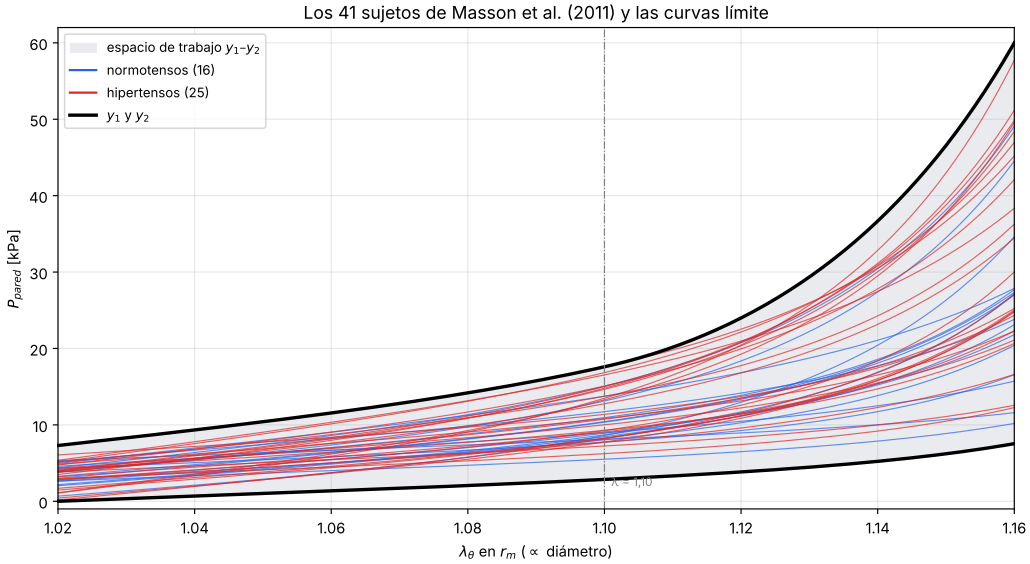


Figura 1: Presión de pared de los 41 sujetos de Masson et al. (2011) y curvas límite y_1, y_2 del espacio de trabajo.

1.3. Dominio de validez

El modelo constitutivo de cada sujeto se ajustó en el rango de λ medido durante su ciclo cardíaco: aproximadamente 1,085–1,122 para HT09 y hasta $\approx$ 1,16 en los más distensibles. Fuera de ese rango la ley es una extrapolación sin datos:

- por debajo de $\lambda \approx 0{,}95$ el término activo vuelve negativa la presión;
- por encima de 1,16 el colágeno crece sin límite.

Por eso **el ajuste se hace solo en** [1,02; 1,16]. La extrapolación del injerto (Fig. 2) se muestra solo como información.

Más allá de 1,16 el injerto es lineal, y en $\lambda = 1{,}20$ da entre la mitad y el 60 % de la presión que predice la ley (NT08: 15,4 frente a 25,6 kPa; Mean HT: 57,8 frente a 114,8 kPa; HT09: 78,6 frente a 149,1 kPa). Hacia λ bajo, el injerto tiende a cero sin volverse negativo, mientras que la ley da presiones negativas. Si se quisiera un tope de dilatación ante sobrepresiones, la alternativa que no depende de extrapolar la ley es un material "freno" con nudo cerca de 1,16. Su número de láminas se fijaría con un criterio de seguridad explícito.

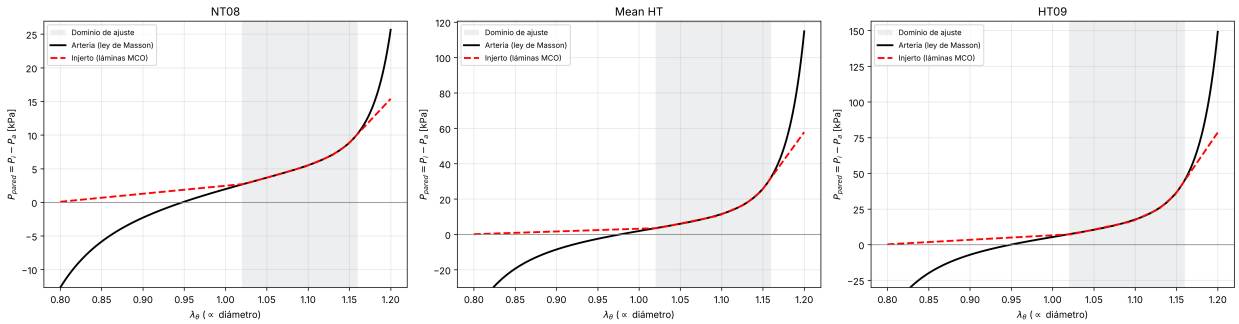


Figura 2: Injerto (láminas MCO ajustadas en [1,02; 1,16], sombreado) frente a la ley de Masson fuera del dominio de ajuste, para NT08, la media de los hipertensos y HT09.

1.4. Bases: una lámina de cada material

Cada base es la curva de presión de *una lámina* del material j:

$$A_j(\lambda) = S_j \ \text{máx}(0, \lambda - k_j), \qquad j = 1, \ldots, N.$$

La lámina no aporta presión hasta que sus fibras se tensan ($\lambda = k_j$, el *nudo*, *knot* en inglés). Desde ahí aporta presión proporcional al estiramiento adicional, con pendiente S_j. El injerto es $y \approx \sum_j c_j A_j$, donde c_j es el número de láminas del material j, un número real porque el espesor puede variar en forma continua. Los nudos se eligen con el método de la Sección 2, y las pendientes como se describe en la Sección 3.

2. Elección óptima de la base: el método minimax

Objetivo. Elegir la base apropiada, es decir, la posición de los nudos $k_1, \ldots, k_N$, para que el ajuste de cualquier curva del espacio de trabajo pueda hacerse por MCO **sin condiciones**: sin cotas ni restricciones sobre las láminas y sin regularización.

- Con una base así, el ajuste es la fórmula cerrada $c = A^+ y$: exacta, única e instantánea, y es lo que la red aprende a reproducir.
- Toda la exigencia se traslada a la elección de la base, que se hace una sola vez.

Para que el ajuste libre sea aceptable, la base debe garantizar tres propiedades en todo el espacio de trabajo:

1. **Precisión:** toda curva se ajusta con error punto a punto ≤ 3 %.
2. **Estabilidad:** cond(A) acotado, para que pequeños errores en la curva no produzcan grandes cambios en las láminas.
3. **Signo:** las láminas que da el MCO libre resultan ≥ 0, es decir, fabricables. El MCO no impone el signo; es la base la que debe hacer que salga positivo.

Las tres se incorporan a una única calificación $J(k)$ de cada juego de nudos, y los nudos se eligen minimizando J. Esta sección explica, desde cero y paso a paso, cómo; es lo que hace la Celda 3 del cuaderno cuando hace falta.

Dos problemas distintos: las láminas (MCO) y los nudos (búsqueda numérica)

El diseño tiene dos tipos de incógnitas, que se resuelven con métodos distintos:

1. **Las láminas c_j, con los nudos fijos.** La curva del injerto depende de las láminas en forma *lineal*. Por eso el mejor ajuste se obtiene con **mínimos cuadrados ordinarios (MCO)**, que dan una solución exacta mediante una fórmula cerrada (Sección 2.1). Se resuelve una vez por cada curva arterial, y es lo que la red aprende a reproducir.
2. **Los nudos k_j.** La curva depende de los nudos en forma *no lineal* (a través de $\text{máx}(0, \lambda - k_j)$), y no hay fórmula para el mejor juego de nudos. Se busca numéricamente en dos etapas (Sección 2.5):
   - una **búsqueda global** con el método de **evolución diferencial**, que explora todo el rango permitido con una población de juegos de nudos;
   - un **refinamiento local** con el método de **Nelder–Mead**, que parte del mejor juego hallado y lo ajusta fino.

   Se resuelve una sola vez, al construir las bases.

Los métodos trabajan anidados. La búsqueda de nudos es el *lazo exterior*: propone un juego de nudos. El MCO es el *lazo interior*: con esos nudos, ajusta todas las curvas y devuelve sus errores y sus láminas, con los que se calcula J y la búsqueda decide qué probar después. **Ni la evolución diferencial ni Nelder–Mead son métodos de mínimos cuadrados**: son métodos para buscar el mínimo de una función que solo se sabe evaluar.

2.1. El problema: qué es un nudo y por qué importa

Cada material se representa con una *línea truncada*:

$$A_j(\lambda) = S_j \ \text{máx}(0,\ \lambda - k_j).$$

Vale cero mientras $\lambda < k_j$: las fibras de esa lámina todavía están flojas. A partir de $\lambda = k_j$ (el **nudo**, *knot* en inglés) crece con pendiente S_j. La curva del injerto es la suma de las láminas:

$$P_{injerto}(\lambda) = \sum_{j=1}^{N} c_j \, A_j(\lambda),$$

que es una *poligonal*: una sucesión de tramos rectos que se quiebran en cada nudo. En cada quiebre la pendiente aumenta, porque entra en carga un material nuevo.

Dada una curva arterial $y(\lambda)$, el número de láminas $c = (c_1, \ldots, c_N)$ se obtiene por mínimos cuadrados ordinarios:

$$c = A^{+}y = \arg\min_{c} \ \sum_{i=1}^{999} \big(y(\lambda_i) - (Ac)(\lambda_i)\big)^2,$$

donde A es la matriz de $999 \times N$ cuyas columnas son las bases evaluadas en los 999 puntos de la grilla.

Qué son los mínimos cuadrados ordinarios (MCO). Se eligen las láminas c que hacen mínima la suma de los cuadrados de las diferencias entre la curva arterial y la del injerto, punto por punto de la grilla. Como la curva del injerto es lineal en c y las columnas de A son linealmente independientes, el mínimo es único y tiene solución exacta:

$$c = (A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}y \equiv A^{+}y.$$

A^{+} es la **pseudoinversa** (de Moore–Penrose) de A. En la práctica se calcula con la descomposición en valores singulares, que es numéricamente más estable (Trefethen y Bau, 1997, Lecturas 11–12; Lawson y Hanson, 1974).

El MCO elige las láminas; los nudos se eligen antes, una sola vez, para todas las curvas. Eso es lo que resuelve esta sección.

¿Por qué importa dónde están los nudos? Una poligonal solo puede doblarse donde tiene quiebres. La curva J arterial es suave y se curva cada vez más hacia λ alto. Si los quiebres están mal ubicados (por ejemplo, equiespaciados), la poligonal no puede seguir la curvatura del final. La Fig. 3 lo muestra con la curva media de los hipertensos (Mean HT):

- **Con los nudos minimax**, el error máximo es 1,37 % del rango.
- **Con 5 nudos equiespaciados** es 7,93 %. Sobre las 22 500 curvas del espacio de trabajo, el peor 1 % pasa de 1,77 % a 11,67 %, y solo el 0,21 % de las curvas cumple el 3 %.

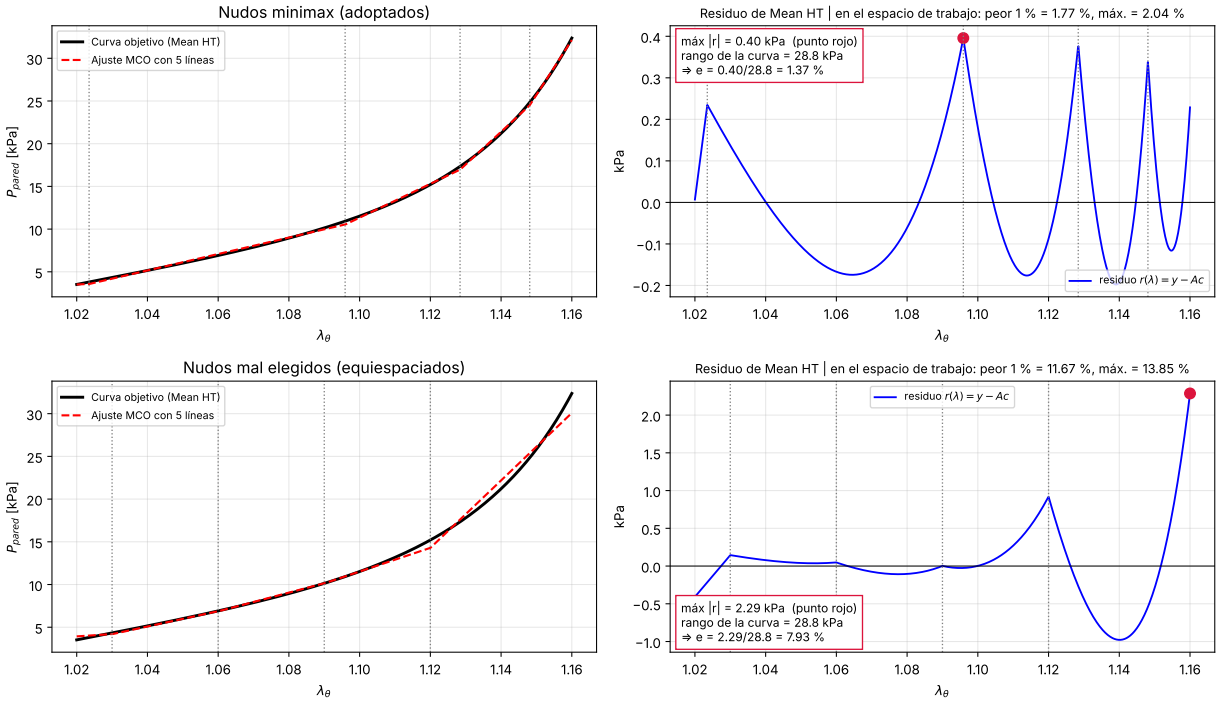


Figura 3: La misma curva (Mean HT) ajustada con 5 líneas truncadas por MCO, con dos juegos de nudos (líneas punteadas verticales). Arriba, los nudos minimax adoptados; abajo, nudos equiespaciados. A la derecha, el residuo y su máximo (punto rojo). Con los mismos 5 materiales, el error cambia por un factor 6 según dónde se quiebre la poligonal.

2.2. Visión general del procedimiento

Elegir los nudos es un proceso en cuatro etapas:

1. **Rango de búsqueda** (Sección 2.3): se fija entre qué valores puede estar cada nudo.
2. **Calificación** (Sección 2.4): para un juego de nudos se calcula un único número, $J(k)$. Mide qué tan bien ajusta el MCO a las *peores* curvas del espacio de trabajo, y penaliza si cond(A) es grande o si aparecen láminas negativas. Cuanto menor es J, mejor es la base. Este es el **criterio minimax**: *qué* se considera una buena base.
3. **Búsqueda** (Sección 2.5): la evolución diferencial prueba miles de juegos de nudos en todo el rango, quedándose siempre con los mejores, hasta que la población deja de mejorar; Nelder–Mead refina el mejor. Este es el **método**: *cómo* se encuentra la mejor base. La Sección 2.6 justifica la elección de este método frente a otros.
4. **Verificación** (Secciones 2.7 a 2.9):
   - que el resultado no dependa del azar de la búsqueda;

- que la base final cumpla precisión, estabilidad y signo en las 22 500 curvas completas y en los 41 sujetos.

2.3. Rango de búsqueda y ubicación típica de los nudos

La evolución diferencial (Sección 2.5) no necesita un punto de partida elegido a mano: solo necesita el **rango** en que puede estar cada nudo, y dentro de él sortea su población inicial. El rango es:

- **primer nudo:** $k_1 \in [0{,}60;\ 0{,}98]$, es decir, *antes* del dominio [1,02; 1,16]. Así, el primer material ya está en carga en todo el dominio y aporta la pendiente inicial de la curva. El límite inferior 0,60 evita nudos absurdos (fibras que se tensan con el vaso reducido a menos de dos tercios de su radio de referencia);
- **demás nudos:** $k_j \in [1{,}00;\ 1{,}156]$, $j = 2, \ldots, N$. El tope $1{,}156 = 1{,}16 - 0{,}004$ asegura que cada material tenga al menos unos 28 puntos de la grilla donde actuar.

Además se exige que dos nudos consecutivos estén separados al menos 0,004 (Paso 6).

Dónde terminan los nudos, y por qué. La Tabla 1 muestra los nudos que resultan de la búsqueda. En los tres casos siguen el mismo patrón:

- **Los nudos se juntan hacia λ alto.** La curva J arterial es casi recta al comienzo del dominio y se curva cada vez más hacia $\lambda = 1{,}16$. Una poligonal solo puede doblarse en sus nudos, así que necesita más quiebres, y más próximos entre sí, donde la curvatura es mayor. Con 5 bases las separaciones entre nudos consecutivos dentro del dominio son 0,072; 0,033 y 0,020: cada una es aproximadamente la mitad de la anterior.
- **El primer nudo queda cerca de 0,79**, bien antes del dominio. Su posición casi no influye en el error de ajuste, pero sí en el signo de las láminas (Paso 5): un k_1 más bajo hace que el primer material tenga pendiente más suave, y el MCO ya no necesita restarle láminas para seguir curvas muy planas al comienzo.

Este patrón sirve como intuición y para controlar el resultado, pero el método no lo usa: la búsqueda lo encuentra sola desde un sorteo en todo el rango.

Tabla 1: Rango de búsqueda y nudos que resultan del método, para 4, 5 y 6 bases. Con 5 bases se indican los nudos adoptados (con los que se entrenó la red); la Sección 2.7 explica su relación con el óptimo de la evolución diferencial.

Bases	Nudos
4	0,7978; 1,0259; 1,1077; 1,1416
5	0,7931; 1,0235; 1,0959; 1,1284; 1,1481
6	0,7903; 1,0219; 1,0872; 1,1203; 1,1397; 1,1533
Rango	$k_1 \in [0{,}60;\ 0{,}98];\ \ k_2, \ldots, k_N \in [1{,}00;\ 1{,}156]$

2.4. El criterio minimax: cómo se califica un juego de nudos

Los Pasos 1 a 6 definen cómo se calcula $J(k)$ para un juego de nudos k *cualquiera*: cualquiera de los que propone la búsqueda. En los ejemplos se usan los nudos adoptados, $k = (0{,}7931;\ 1{,}0235;\ 1{,}0959;\ 1{,}1284;\ 1{,}1481)$, que son el resultado final del procedimiento, para mostrar números concretos.

2.4.1. Paso 1: el error de *una* curva

Para unos nudos k dados y una curva y:

1. Se calculan las láminas por MCO: $c = A^{+}y$.

2. Se calcula el residuo en cada punto: $r(\lambda_i) = y(\lambda_i) - (Ac)(\lambda_i)$, en kPa.

3. Se toma el mayor residuo en valor absoluto y se lo divide por el rango de la curva:

$$e(y;k) = \frac{\max_i |r(\lambda_i)|}{\max_i y(\lambda_i) - \min_i y(\lambda_i)} \times 100 \quad [\,\%].$$

Ejemplo numérico (Fig. 3, arriba). El residuo máximo de Mean HT es 0,396 kPa, en $\lambda \approx 1{,}096$. La curva va de 3,52 a 32,37 kPa, un rango de 28,85 kPa. Entonces $e = 0{,}396/28{,}85 = 1{,}37$ %.

Este es exactamente el **criterio de diseño**: una curva cumple si $e \leq 3$ %. Se divide por el rango para que el criterio sea igual de exigente con una arteria blanda (rango de 10 kPa) que con una rígida (rango de 60 kPa). Medido en kPa, el ajuste quedaría dominado por las curvas rígidas.

Otra medida de error: el NRMSE. Además del error máximo e se usa el *error cuadrático medio normalizado*:

$$\text{NRMSE} = \frac{\sqrt{\frac{1}{999}\sum_{i=1}^{999} r(\lambda_i)^2}}{\max y - \min y} \times 100 \;[\,\%].$$

e mide el peor punto de la curva; el NRMSE mide el error típico a lo largo de toda la curva. Siempre NRMSE $\leq e$.

2.4.2. Paso 2: de una curva a la población

Los nudos no se eligen para una arteria, sino para *todas* las del espacio de trabajo. Fijados los nudos, cada curva y_i tiene su error $e_i = e(y_i;k)$. Con 22 500 curvas hay 22 500 errores. La Fig. 4 muestra su histograma para los nudos adoptados:

- la mayoría de las curvas tiene error cercano a 1,26 % (media 1,26 %, mediana 1,26 %);
- el peor 1 % (225 curvas, en rojo) está entre 1,72 % y 2,04 %;
- ninguna curva supera el 3 %.

¿Qué número resume este histograma para decidir si unos nudos son mejores que otros?

- **La media no sirve**: unos nudos podrían ajustar muy bien la mayoría de las curvas y muy mal unas pocas. Esas pocas no cumplirían el criterio, y la media no lo mostraría.
- Como el criterio es "*toda* curva con $e \leq 3$ %", lo que importa es la **cola derecha** del histograma: las peores curvas. De ahí el nombre *minimax*: **mini**mizar el **máx**imo error.

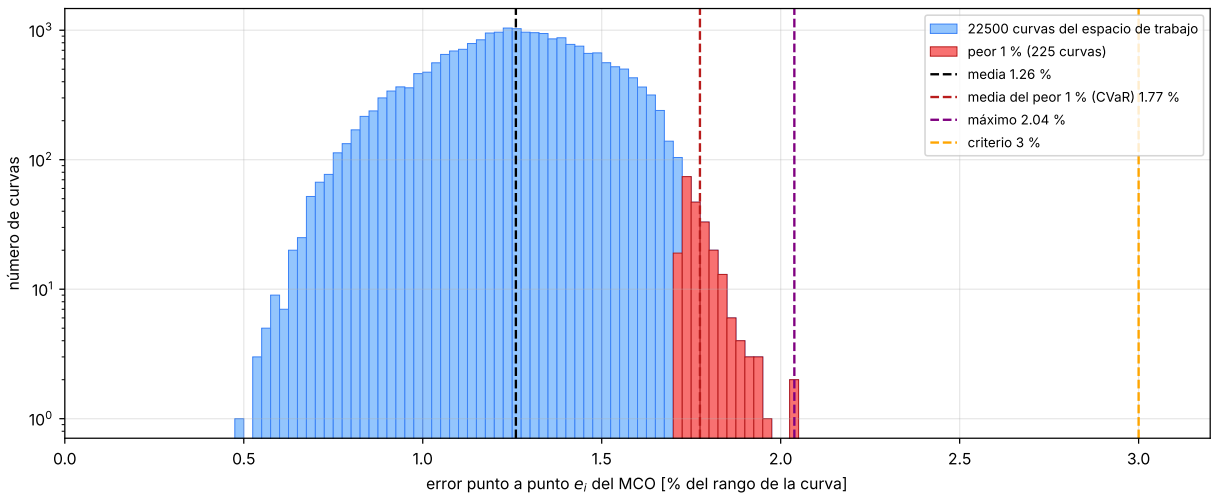


Figura 4: Error punto a punto del MCO con los nudos adoptados en las 22 500 curvas del espacio de trabajo (escala vertical logarítmica). En rojo, el peor 1 %. El método minimax actúa sobre esa cola.

2.4.3. Paso 3: por qué la media del peor 1 % y no el máximo

El paso anterior dejó establecido que, para comparar dos juegos de nudos, hay que mirar las curvas peor ajustadas. Este paso define con exactitud *qué número* se calcula a partir de esas curvas y justifica la elección.

(a) El conjunto de curvas de optimización Durante la búsqueda de los nudos, la función objetivo se evalúa miles de veces, y cada evaluación requiere resolver un ajuste MCO por curva. Para que la búsqueda tarde minutos y no horas, no se usan las 22 500 curvas del espacio de trabajo sino un **conjunto de optimización** de $n = 2532$ curvas, formado por:

Componente	Curvas
Muestra al azar del espacio de trabajo (con semilla fija, siempre la misma muestra)	2500
Sujetos de entrenamiento de Masson (los 31, todos dentro de la franja y_1–y_2)	31
Curva límite y_2 (la más rígida y exigente)	1
Total (n)	**2532**

- **Semilla fija:** la *semilla* es el número con que se inicializa el generador de números aleatorios de la computadora. Con la misma semilla, el sorteo da siempre las mismas 2500 curvas, de modo que el resultado es reproducible.
- **Los sujetos reales y y_2 se incluyen siempre**, para que nunca queden fuera de la muestra.
- **Los 10 sujetos de test no se incluyen**: la elección de los nudos no los "ve", y por eso sirven después para evaluar el método sin sesgo.
- **Grilla:** en la optimización cada curva se evalúa en 500 puntos (uno de cada dos de la grilla de 999), también por velocidad. Todos los números de este Paso 3 están calculados así.
- **No confundir con el Paso 2:** el histograma de la Fig. 4 usa las 22 500 curvas completas, y allí el peor 1 % son 225 curvas. En la optimización se usa este conjunto de 2532 curvas, y el peor 1 % son 25. El criterio es el mismo (el 1 % de mayor error); cambia solo el conjunto sobre el que se calcula.
- **Verificación final:** una vez elegidos los nudos, el resultado se verifica con las 22 500 curvas completas y los 999 puntos. De ahí salen los valores de la Sección 2.8. Por eso pueden diferir levemente de los de este punto: por ejemplo, el error de y_2 con los nudos adoptados es 2,20 % en 500 puntos y 2,23 % en 999.

(b) Cómo se calcula la media del peor 1 % (CVaR 99 %), paso a paso Se parte de un juego de nudos $k = (k_1, \ldots, k_5)$ fijo; por ejemplo, los adoptados.

1. **Ajustar cada curva.** A cada una de las 2532 curvas y_i se le calcula su ajuste MCO con esos nudos, $c_i = A^+ y_i$.
2. **Medir el error de cada curva.** Para cada curva se calcula su error punto a punto relativo al rango (Paso 1):

$$e_i = \frac{\max_\lambda |y_i(\lambda) - (Ac_i)(\lambda)|}{\max_\lambda y_i - \min_\lambda y_i} \times 100 \;\; [\,\%], \qquad i = 1, \ldots, 2532.$$

   El resultado es una lista de 2532 números, uno por curva.
3. **Ordenar la lista de mayor a menor.** Se reordenan los errores de modo que el primero sea el más grande:

$$e_{(1)} \;\geq\; e_{(2)} \;\geq\; \cdots \;\geq\; e_{(2532)}.$$

   El subíndice entre paréntesis indica el *puesto* en ese ranking: $e_{(1)}$ es el error de la curva peor ajustada, $e_{(2)}$ el de la segunda peor, y $e_{(2532)}$ el de la mejor ajustada.

4. **Contar cuántas curvas forman el "peor 1 %".** Es $m = \lfloor n/100 \rfloor = \lfloor 2532/100 \rfloor = 25$ curvas, donde $\lfloor \cdot \rfloor$ es la parte entera.

5. **Promediar los errores de esas m curvas,** es decir, los de los puestos 1 a 25:

$$\mathrm{CVaR}_{99}(k) = \frac{1}{m} \sum_{p=1}^{m} e_{(p)} = \frac{e_{(1)} + e_{(2)} + \cdots + e_{(25)}}{25}.$$

El nombre CVaR (*conditional value at risk*, valor en riesgo condicional) proviene de la gestión de riesgo financiero. Allí mide la pérdida media en el peor 1 % de los escenarios (Rockafellar y Uryasev, 2000); aquí los "escenarios" son las curvas y la "pérdida" es el error de ajuste.

La Tabla 2 muestra el ranking real con los nudos adoptados, y la Fig. 5 lo grafica completo.

Tabla 2: Ranking de las 2532 curvas del conjunto de optimización según su error punto a punto, con los nudos adoptados (500 puntos). Las "sintéticas" se identifican por su índice dentro de las 22 500 del espacio de trabajo.

Puesto p	Curva	Error $e_{(p)}$
1	curva límite y_2	2,20 %
2	sintética n.º 18473	1,91 %
3	sintética n.º 15379	1,80 %
4	sintética n.º 17440	1,79 %
5	sintética n.º 20028	1,78 %
⋮	⋮	⋮
25	sintética n.º 13411	1,69 %
26	sintética n.º 6068	1,69 %
⋮	⋮	⋮
1267 (mitad)	sintética n.º 4966	1,25 %
⋮	⋮	⋮
2532 (última)	sintética n.º 333	0,57 %
CVaR 99 % = promedio de los puestos 1 a 25		**1,75 %**
Máximo = error del puesto 1		2,20 %
Promedio de las 2532 curvas		1,25 %

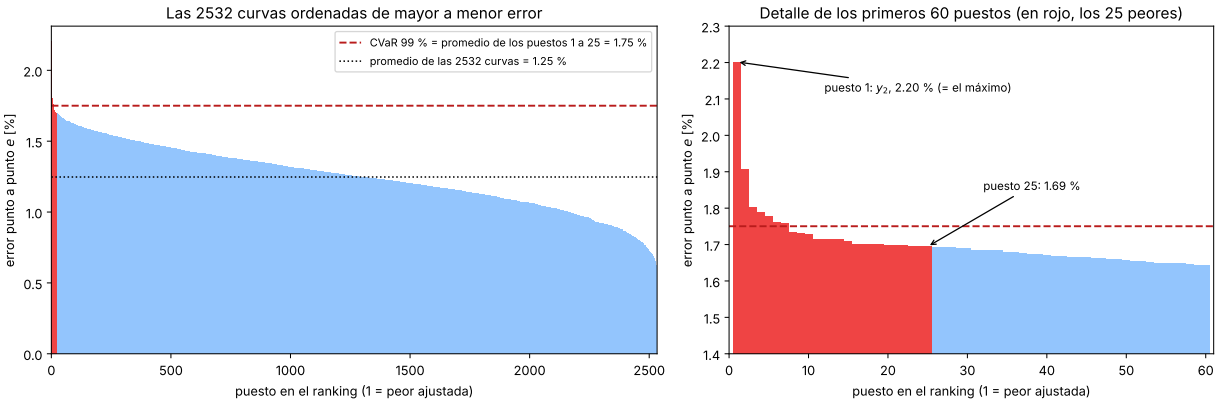


Figura 5: Izquierda: errores de las 2532 curvas del conjunto de optimización, ordenados de mayor a menor (una barra por curva). Derecha: detalle de los primeros 60 puestos; en rojo, los 25 que forman el peor 1 %. La línea discontinua roja es su promedio (CVaR 99 %); la punteada negra, el promedio de todas las curvas.

Cómo se lee.

- La curva peor ajustada es y_2, con 2,20 %.
- Las 25 peores tienen errores entre 1,69 y 2,20 %, y su promedio, el CVaR, es 1,75 %.
- Ninguno de los 31 sujetos reales está entre esas 25: todos ajustan mejor que la cola.
- La mitad de las curvas tiene error menor que 1,25 %.

Por construcción, $e_{(1)} \geq \text{CVaR}_{99} \geq e_{(25)}$: el CVaR nunca supera al máximo y nunca es menor que el error del puesto 25.

(c) Las dos alternativas: el máximo o el CVaR Ambas miden la cola de peores casos, que es lo que importa para el criterio de diseño (Paso 2):

- **El máximo** es $e_{(1)}$, el error de *una sola* curva, la peor. Minimizarlo es el minimax "puro".
- **El CVaR 99 %** es el promedio de las 25 peores. Sigue siendo una medida de peor caso, porque las 2507 curvas restantes no intervienen, pero no depende de una curva sola.

Para decidir entre las dos se hizo el siguiente experimento.

(d) El experimento: mover un solo nudo

1. Se fijan cuatro nudos en sus valores adoptados: $k_1 = 0{,}7931$, $k_2 = 1{,}0235$, $k_3 = 1{,}0959$ y $k_5 = 1{,}1481$.
2. El nudo 4 se prueba en 140 posiciones equiespaciadas entre $k_4 = 1{,}112$ y $k_4 = 1{,}141$.
3. En cada posición se calculan los 2532 errores e_i (como en el apartado b) y se registran tres cosas:

   (I) el máximo $e_{(1)}$;

   (II) *cuál* es la curva que ocupa el puesto 1;

   (III) el CVaR 99 %.

La Fig. 6 muestra el máximo (violeta) y el CVaR (rojo) en función de k_4.

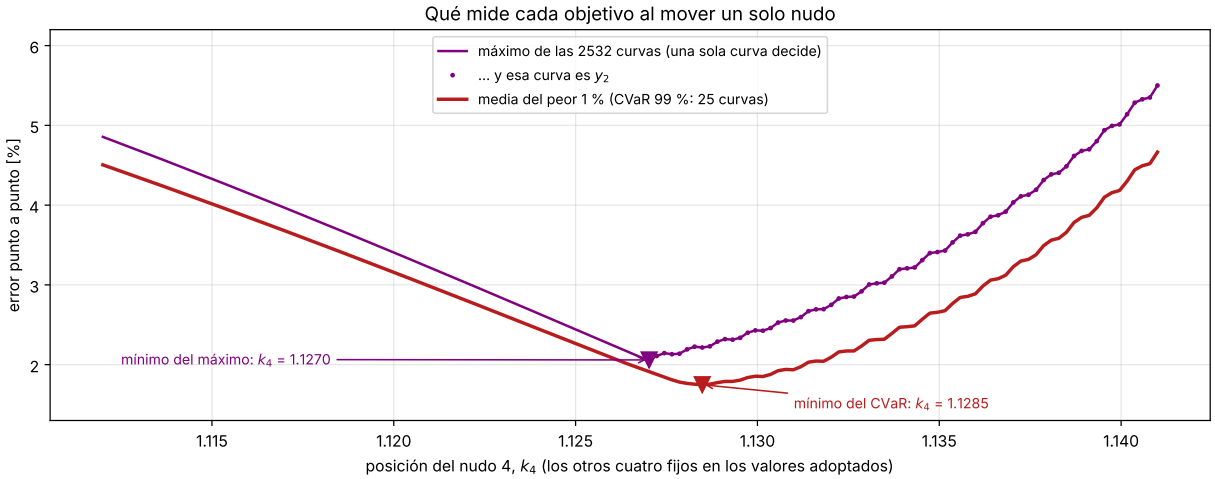


Figura 6: Experimento del apartado (d): al mover el nudo 4 con los demás fijos, error de la peor curva (violeta) y promedio de las 25 peores (CVaR 99 %, rojo). Los puntos violeta marcan las posiciones en que la peor curva es y_2. Los triángulos marcan el mínimo de cada criterio. Las pequeñas ondulaciones vienen de la discretización: cuando k_4 cruza un punto de la grilla, el quiebre de la poligonal pasa a otro intervalo.

(e) Resultados del experimento **1. En la zona del óptimo, el máximo es el error de una sola curva, y_2.** En 68 de las 140 posiciones (49 %), la curva del puesto 1 es y_2. Esto ocurre en todas las posiciones con $k_4 \geq 1{,}127$, que es justamente la zona donde están los óptimos. Ahí el máximo de las 2532 curvas es, literalmente, el error de y_2: las otras 2531 curvas no influyen en ese número. Minimizar el máximo equivale, en esa zona, a elegir k_4 para que y_2 ajuste lo mejor posible.

2. Los dos criterios eligen nudos distintos. La Tabla 3 compara los dos óptimos del experimento y los nudos adoptados.

Tabla 3: Comparación de los criterios en el experimento del apartado (d) (500 puntos). La última columna son los nudos adoptados, que surgen de optimizar los cinco nudos a la vez.

	Mínimo del máximo	Mínimo del CVaR	Nudos adoptados
k_4	1,1270	1,1285	1,1284
Puesto 1: error de y_2	**2,06 %**	2,22 %	2,20 %
Puesto 2: segunda peor curva	2,05 %	1,91 %	1,91 %
Promedio de los puestos 1 a 25 (CVaR)	1,92 %	**1,75 %**	1,75 %
Promedio de las 2532 curvas	1,257 %	1,249 %	1,247 %

Con el criterio del máximo, y_2 baja de 2,22 % a 2,06 %, pero la segunda peor curva sube de 1,91 a 2,05 % y el promedio de las 25 peores sube de 1,75 % a 1,92 %. Es decir, **se mejora una curva a costa del resto de la cola**. El promedio de todas las curvas prácticamente no cambia (1,257 frente a 1,249 %): la diferencia entre los criterios está solo en la cola. El CVaR acepta que y_2 quede algo peor a cambio de que mejoren las 25 peores en conjunto.

3. El máximo tiene un mínimo anguloso. El máximo es, en cada posición de k_4, el mayor de 2532 errores, y cada uno de ellos varía de forma aproximadamente suave con k_4 (salvo las pequeñas ondulaciones de la discretización).

- A la izquierda del óptimo ($k_4 < 1{,}127$), la peor curva es otra, cuyo error *baja* al aumentar k_4.
- A la derecha, la peor es y_2, cuyo error *sube* al aumentar k_4.

El mínimo del máximo cae justo donde esas dos curvas intercambian el puesto 1 (por eso, en la primera columna de la tabla, los puestos 1 y 2 casi empatan), y en ese punto la pendiente cambia de signo bruscamente: el gráfico tiene forma de "V", con un quiebre sin derivada. El CVaR, al promediar 25 curvas, suaviza esos quiebres.

(f) Conclusión Se adopta el CVaR 99 % como medida de la cola por tres razones:

1. No depende de una sola curva: reparte el criterio entre las 25 peores.
2. Sigue siendo un criterio de peor caso: solo cuentan las curvas de la cola.
3. Es más suave que el máximo, lo que facilita la búsqueda.

Con cualquiera de los dos criterios, todas las curvas quedan lejos del 3 %: la elección afecta la robustez del diseño, no su cumplimiento.

2.4.4. Paso 4: el número de condición, cond(A)

Sin ninguna restricción, la búsqueda tendería a *juntar* nudos en la zona de mayor curvatura, cerca de 1,16, porque más quiebres juntos siguen mejor la curva. Esto tiene un costo.

Qué mide cond(A). Se normaliza cada columna de A para que su máximo valga 1 y se calculan sus **valores singulares** $s_1 \geq \cdots \geq s_N \geq 0$. Toda matriz se puede escribir como $A = U\Sigma V^{\mathsf{T}}$ (descomposición en valores singulares, SVD), donde Σ es diagonal y sus elementos son los s_j. Cada s_j es el factor por el que la matriz estira un vector en una dirección principal: s_1 es el mayor

estiramiento y s_N el menor. Un s_N muy chico indica que existe una combinación de columnas que la matriz casi anula (Trefethen y Bau, 1997, Lecturas 4, 5 y 12). Entonces

$$\mathrm{cond}(A) = s_1/s_N.$$

Si dos columnas se parecen mucho (dos nudos muy próximos dan dos rampas casi iguales), una combinación de ellas casi se anula, s_N se hace chico y $\mathrm{cond}(A)$ crece. La normalización hace que $\mathrm{cond}(A)$ dependa solo de los nudos, no de las pendientes ni de C_{LAM}.

Por qué importa. El MCO resuelve $c = A^{+}y$. Un error δy en la curva (ruido de medición, o la diferencia entre la arteria real y el modelo) produce un error en las láminas acotado por

$$\frac{\|\delta c\|}{\|c\|} \lesssim \mathrm{cond}(A)\,\frac{\|\delta y\|}{\|y\|}.$$

Con $\mathrm{cond}(A)$ grande, ruidos chicos en la curva dan cambios grandes en las láminas: por ejemplo $+3$ láminas de un material y -3 del vecino, que casi se cancelan en la curva. Ese diseño no es confiable para fabricar. Además, a la red le cuesta aprender una función tan sensible.

La Fig. 7 lo muestra acercando k_5 a k_4:

- **cond(A):** con la separación adoptada ($k_5 - k_4 = 0{,}0197$) vale 17,8. Llega al umbral 25 con una separación de 0,0118, y con 0,0005 vale 533.
- **Láminas (panel derecho):** un ruido de 0,1 kPa en la curva produce un desvío de 0,034 láminas con los nudos adoptados, y de 0,72 láminas con los nudos casi pegados.
- **El otro extremo:** separar demasiado k_5 también empeora. El nudo del material 5 queda tan cerca de 1,16 que casi no tiene puntos donde actuar.

Cómo se impone en la optimización. Se suma una penalización:

$$\mathrm{pen}_{\mathrm{cond}}(k) = 50 \cdot \max\left(0,\ \mathrm{cond}(A) - (\texttt{UMBRAL_COND} - 1)\right).$$

Vale cero mientras $\mathrm{cond}(A) < 24$ (con el umbral por defecto, 25). Pasado 24, cada décima de $\mathrm{cond}(A)$ suma 5 puntos al objetivo, mucho más que cualquier mejora posible del error, que es del orden de 0,1 puntos. En la práctica funciona como una **restricción**: el óptimo nunca pasa de 24. El margen de una unidad garantiza que $\mathrm{cond}(A) < 25$ estrictamente, que es lo que verifica la Celda 3. Con 6 bases la restricción queda *activa*: el óptimo sin restricción juntaría más los nudos, y queda exactamente en $\mathrm{cond}(A) = 24{,}0$.

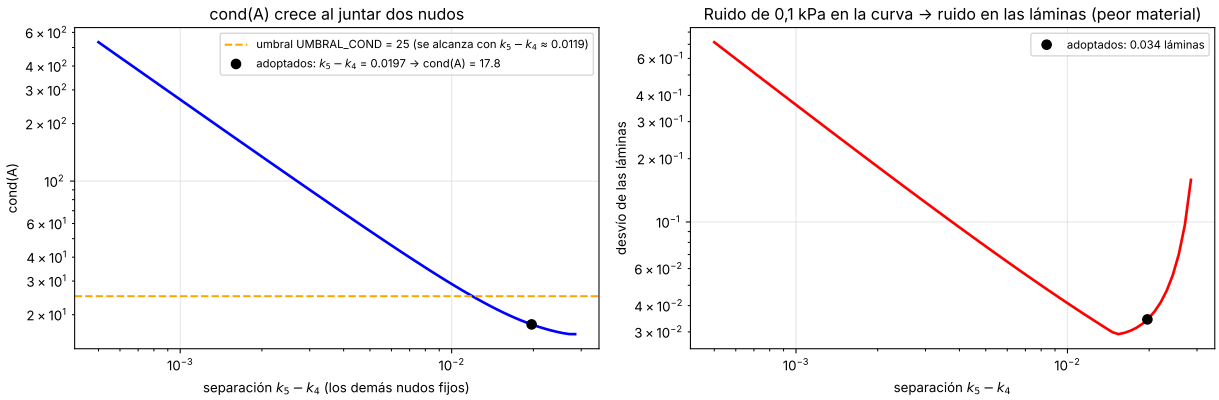


Figura 7: Izquierda: $\mathrm{cond}(A)$ al acercar el nudo 5 al 4 (escalas logarítmicas). Derecha: desvío de las láminas del peor material ante un ruido blanco de 0,1 kPa en la curva ($\sigma\,\|A_j^{+}\|$, con $C_{LAM} = 10$). El punto negro marca los nudos adoptados.

2.4.5. Paso 5: el signo de las láminas

El problema. El MCO libre minimiza el error sin mirar el signo de c. Si una curva es muy plana al comienzo en relación con su crecimiento posterior, la mejor poligonal puede necesitar una pendiente inicial *menor* que la que da una lámina del material 1, y el MCO la obtiene restando láminas: $c_1 < 0$. Una lámina negativa no se puede fabricar.

Imponer $c \geq 0$ en el ajuste (mínimos cuadrados no negativos) resolvería el problema, pero es exactamente una *condición en el ajuste*, que es lo que se quiere evitar: el ajuste dejaría de ser la fórmula cerrada $c = A^{+}y$. La alternativa coherente con el objetivo es trasladar la exigencia a la base: elegir nudos con los que el MCO libre *ya* dé láminas no negativas.

Cómo se mide. Para un juego de nudos se calculan las láminas MCO c_i de las 2532 curvas del conjunto de optimización. Para que la medida no dependa de las unidades, las láminas de cada material se reescalan de modo que su máximo sobre el conjunto valga $C_{LAM} = 10$ (la misma escala que usa el cuaderno). Luego se suma, en cada curva, la parte negativa de sus láminas, y se promedia sobre las curvas:

$$\mathrm{neg}(k) = \frac{1}{n}\sum_{i=1}^{n}\sum_{j=1}^{N} \mathrm{máx}\,(0,\, -c_{ij}) \quad \text{[láminas]}.$$

Vale cero si y solo si ninguna curva tiene láminas negativas. Una curva con $c_1 = -0{,}5$ aporta 0,5.

Cómo se impone. Se suma a J el término $\texttt{PESO_NEG} \cdot 100 \cdot \mathrm{neg}(k)$. El factor 100 lo lleva a la escala de los errores (en %), y el peso `PESO_NEG` regula cuánto se privilegia el signo frente a la precisión. La Tabla 4 muestra el efecto del peso con 5 bases, verificado sobre las 22 500 curvas y los 41 sujetos.

Tabla 4: Efecto del peso del término de signo (5 bases). "Todas ≥ 0": porcentaje de curvas del espacio de trabajo cuyas 5 láminas MCO son no negativas.

`PESO_NEG`	Todas ≥ 0 (espacio de trabajo)	Sujetos con todas ≥ 0	CVaR 99 %
0 (sin término de signo)	96,1 %	35/41	1,74 %
2	99,94 %	41/41	1,76 %
10 (adoptado)	**99,98 %**	**41/41**	1,77 %

Qué cambia en los nudos. Lo que hace el término de signo es, sobre todo, *bajar el primer nudo*: sin él, el óptimo tiene $k_1 \approx 0{,}87$; con él, $k_1 \approx 0{,}79$. Con el nudo más lejos del dominio, la lámina del material 1 es más "tendida" en relación con los demás materiales y el MCO ya no necesita restarla. Los nudos dentro del dominio, que deciden la precisión, casi no se mueven, y por eso el costo en precisión es mínimo: el CVaR pasa de 1,74 a 1,77 %.

Por qué `PESO_NEG` = 10. Con peso 2 ya se logra el 99,94 % y los 41 sujetos; con 10 se llega al 99,98 % por un costo adicional de 0,01 puntos de CVaR. Pesos mayores no mejoran el signo de forma apreciable y empiezan a sacrificar precisión.

2.4.6. Paso 6: la función objetivo completa J

Juntando los pasos, los nudos minimizan

$$J(k) = \underbrace{\mathrm{CVaR}_{99}(e_1,\ldots,e_n)}_{\text{peor 1 \%}} + \underbrace{0{,}25\cdot\overline{\mathrm{NRMSE}}}_{\text{desempate}} + \underbrace{50\cdot \mathrm{máx}\,(0, \mathrm{cond}(A) - 24)}_{\text{restricción de cond}(A)} + \underbrace{10\cdot 100\cdot \mathrm{neg}(k)}_{\text{signo}}$$

Tabla 5: Los cuatro términos de J.

Término	Qué mide	Por qué ese peso
CVaR_{99}	Media de los errores punto a punto de las 25 peores curvas (%)	Es el objetivo principal: la cola del criterio de diseño. Peso 1.
$0{,}25 \cdot \overline{\mathrm{NRMSE}}$	Error cuadrático medio relativo al rango, promediado sobre todas las curvas (%)	Desempata: entre dos juegos con cola parecida, prefiere el que ajusta mejor en promedio. Es chico (el NRMSE medio ronda 0,45 %) para no competir con la cola.
$50 \cdot \max(0, \mathrm{cond} - 24)$	Exceso de cond(A) sobre 24	Hace de restricción dura (Paso 4).
$10 \cdot 100 \cdot \mathrm{neg}$	Láminas negativas promedio por curva	Lleva el signo a la escala del error; peso 10 (Paso 5).

Conjunto de curvas sobre el que se evalúa J: el conjunto de optimización de $n = 2532$ curvas definido en el Paso 3, apartado (a): 2500 del espacio de trabajo, los 31 sujetos de entrenamiento e y_2, en 500 puntos. El resultado final se verifica con las 22 500 curvas y los 999 puntos.

Restricciones geométricas. Además de cond(A):

- nudos separados al menos 0,004;
- el último a 0,004 o más de $\lambda_{max} = 1{,}16$ (si no, ese material no actúa en el dominio);
- el primero por encima de 0,6.

Si un punto las viola, $J = 10^9$, un valor que la búsqueda siempre descarta.

2.5. El método de búsqueda: evolución diferencial y refinamiento con Nelder–Mead

Los dos métodos que siguen son de **optimización numérica**: buscan el mínimo de una función de varias variables, aquí $J(k_1, \ldots, k_N)$. Ambos solo necesitan poder *evaluar* J en un punto: no usan derivadas ni gradientes, y no suponen ninguna forma particular de la función. Ninguno es un método de mínimos cuadrados: cumplen el papel de lazo exterior (recuadro al comienzo de esta sección), y en cada evaluación de J se hacen los 2532 ajustes MCO.

2.5.1. Etapa 1: búsqueda global con evolución diferencial

Qué es. La **evolución diferencial** (Storn y Price, 1997) es un método de búsqueda *global* basado en una *población*: en lugar de mover un único juego de nudos, mantiene muchos a la vez, repartidos por todo el rango, y los mejora generación tras generación combinándolos entre sí. Una descripción accesible está en Price, Storn y Lampinen (2005), cap. 2. Se usa la implementación de la biblioteca SciPy (`scipy.optimize.differential_evolution`; Virtanen et al., 2020).

Cómo funciona, con los valores que usa el cuaderno:

1. **Población inicial.** Se sortean $15N$ juegos de nudos dentro del rango (75 con 5 bases). El sorteo es por *hipercubo latino*: se divide el rango de cada nudo en 75 franjas y se pone exactamente un juego en cada franja, para que la población cubra todo el rango de forma pareja. Se calcula J de cada uno.

2. **Mutación.** Para cada miembro de la población, el "blanco" x, se arma un *mutante* partiendo del mejor juego de la población, x_{mejor}, y sumándole la diferencia entre otros dos miembros elegidos al azar, x_a y x_b:

$$v = x_{mejor} + F\,(x_a - x_b),$$

   con F sorteado entre 0,5 y 1 en cada generación. La diferencia $x_a - x_b$ da el tamaño y la dirección del paso: cuando la población está dispersa, los pasos son grandes (exploración);

cuando se concentra alrededor del óptimo, los pasos se achican solos (refinamiento). De ahí el nombre "diferencial".

3. **Cruza.** Se arma un *candidato* tomando cada nudo del mutante con probabilidad 0,7 y del blanco en caso contrario (al menos un nudo siempre del mutante).
4. **Selección.** Se calcula J del candidato. Si es menor o igual que el del blanco, lo reemplaza; si no, el blanco se queda. Así la población nunca empeora.
5. **Repetición.** Los pasos 2 a 4 se repiten para todos los miembros: eso es una *generación*. Se termina cuando los J de la población son prácticamente iguales entre sí (desvío estándar menor que 10^{-6} veces su media), o tras 300 generaciones.

Con 5 bases la búsqueda converge en unas 100 a 130 generaciones, es decir, entre 7 400 y 9 600 evaluaciones de J. A unos 13 ms por evaluación, tarda unos 2 minutos (entre 5 y 10 minutos en el cuaderno, según la computadora).

Semilla. El sorteo de la población inicial y los sorteos de cada generación usan la semilla fija del cuaderno (`SEED`), de modo que la búsqueda es reproducible. La Sección 2.7 muestra que con otras semillas se llega al mismo resultado.

2.5.2. Etapa 2: refinamiento local con Nelder–Mead

Qué es. El método de **Nelder–Mead** (Nelder y Mead, 1965), también llamado *simplex descendente*, es un método de búsqueda *local*: parte de un punto y va cuesta abajo hasta el mínimo más cercano. Hay una descripción accesible en Press et al. (2007, Sec. 10.5); sus propiedades de convergencia están en Lagarias et al. (1998).

Para qué se usa aquí. La evolución diferencial termina cuando su población se concentró alrededor del mínimo, pero su mejor miembro puede estar todavía a una distancia del orden de 10^{-4} del fondo. Nelder–Mead parte de ese punto y lo lleva al fondo con precisión de 10^{-5} en los nudos, con unas pocas centenas de evaluaciones más. No cambia la región del óptimo, que ya eligió la búsqueda global; solo afina la posición dentro de ella.

Cómo funciona. Con N nudos, trabaja con un *simplex* de $N + 1$ puntos: un triángulo si $N = 2$, un tetraedro si $N = 3$. El simplex inicial lo arma SciPy con el punto de partida y N puntos más, cada uno con un nudo aumentado un 5 %. En cada iteración:

1. Ordena los vértices por su valor de J: el mejor (M), el segundo peor (S) y el peor (P).
2. Calcula el centro de todos los vértices salvo el peor, y **refleja** el peor a través de ese centro: el punto R, el "espejo" de P.
3. Si R es el mejor de todos, prueba ir el doble de lejos: **expansión** (E).
4. Si R no mejora lo suficiente, prueba un punto intermedio: **contracción** (C_e por fuera o C_i por dentro).
5. Si nada mejora, achica todo el simplex hacia el mejor vértice.
6. Reemplaza el peor vértice por el punto nuevo y repite, hasta que el simplex se achica por debajo de 10^{-5} en λ y 10^{-6} en J.

El simplex "rueda" cuesta abajo por el paisaje de J, se estira en las direcciones buenas y se encoge al llegar al fondo.

La Fig. 8 lo muestra en dos dimensiones, moviendo solo k_3 y k_4 con los demás nudos fijos:

- parte de un triángulo en (1,076; 1,106), donde $J = 19{,}6$;
- en 42 iteraciones (83 evaluaciones de J) llega a (1,0953; 1,1282), con $J = 1{,}862$;
- ese punto prácticamente coincide con los nudos adoptados, (1,0959; 1,1284).

En este corte de dos dimensiones el paisaje tiene un solo valle y Nelder–Mead lo encuentra desde lejos. En las N dimensiones, con el término de signo, el paisaje tiene muchos valles (Sección 2.6), y por eso Nelder–Mead se usa solo para refinar, después de la búsqueda global.

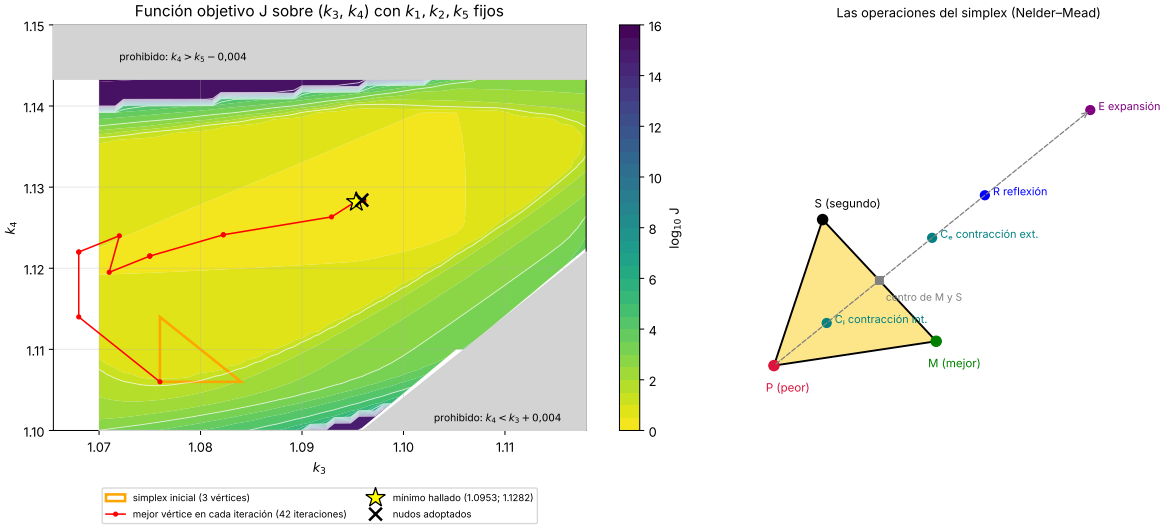


Figura 8: Izquierda: mapa de $\log_{10} J$ sobre (k_3, k_4) con k_1, k_2, k_5 fijos en los valores adoptados; en gris, las regiones prohibidas. Naranja, el simplex inicial; rojo, el mejor vértice en cada iteración; estrella, el mínimo hallado; cruz, los nudos adoptados. Derecha: las operaciones de una iteración sobre un triángulo.

2.6. Por qué este optimizador y no otro

Elegir un optimizador depende de las características del problema. Esta sección describe esas características, revisa las familias de métodos disponibles y compara seis de ellos sobre la misma función objetivo, con y sin el término de signo. La comparación muestra un hecho importante: **sin el término de signo, un método local con varios puntos de partida (Nelder–Mead) alcanzaba; con el término de signo ya no**, y hace falta una búsqueda global.

(a) Características del problema. Se busca el mínimo de $J(k)$, donde $k = (k_1, \ldots, k_N)$ son los nudos:

1. **Pocas variables:** de 4 a 6 nudos.
2. **No hay fórmula para las derivadas de J,** y además J no es derivable en muchos puntos:
   - el error de cada curva es un *máximo* sobre los puntos de la grilla;
   - el CVaR depende de un *ordenamiento* de las curvas;
   - las bases usan $\max(0, \lambda - k)$, y las penalizaciones usan $\max(0, \cdot)$.

   Cada una de esas operaciones introduce quiebres.
3. **Pequeñas ondulaciones** por la discretización: cuando un nudo cruza un punto de la grilla, J cambia levemente (Fig. 6). Una derivada aproximada numéricamente sobre esas ondulaciones da direcciones engañosas.
4. **J no es una suma de cuadrados.** Es un criterio de peor caso (el CVaR) más penalizaciones.
5. **Muchos mínimos locales.** El término de signo depende sobre todo de k_1, una dirección en la que el error es casi plano. Combinado con las penalizaciones, el paisaje queda lleno de valles separados: un método local termina en el valle donde arranca (apartado c).
6. **Restricciones simples:** rango de cada nudo y separación mínima, tratadas como penalización.

7. **Evaluación barata:** unos 13 ms por evaluación de J, de modo que se pueden hacer decenas de miles de evaluaciones.

(b) Familias de optimizadores. La Tabla 6 resume las familias de métodos disponibles, qué requiere cada una y si sirve para este problema.

Tabla 6: Familias de métodos de optimización y su aplicabilidad a la elección de los nudos.

Familia (ejemplos)	Qué requiere	Aplicabilidad aquí
Mínimos cuadrados lineales (MCO)	Incógnitas que entren en forma lineal	Sirve para las láminas (lazo interior), no para los nudos, que entran en forma no lineal.
Mínimos cuadrados no lineales (Gauss–Newton, Levenberg–Marquardt; nudos libres: Jupp, 1978; Golub y Pereyra, 1973)	Objetivo = suma de cuadrados de residuos derivables	No aplica: J es un criterio de peor caso, no una suma de cuadrados. Además, minimizaría el error *promedio*, no la cola, y no tendría en cuenta el signo.
Programación lineal o convexa (minimax como problema lineal)	Problema convexo en las incógnitas	Es convexo en las láminas con los nudos fijos, pero no en los nudos.
Métodos con gradiente (descenso por gradiente, Newton, BFGS, L-BFGS-B; Nocedal y Wright, 2006)	Derivadas de J, o una aproximación por diferencias finitas	Poco confiables: J tiene quiebres y ondulaciones, y el gradiente aproximado engaña. Además son locales.
Locales sin derivadas (Nelder–Mead, 1965; Powell, 1964; búsqueda por patrones, Hooke y Jeeves, 1961)	Solo evaluar J	Toleran quiebres y funcionan bien con pocas variables, pero encuentran el mínimo local más cercano al punto de partida.
Globales sin derivadas (**evolución diferencial**, Storn y Price, 1997; recocido simulado; algoritmos genéticos)	Solo evaluar J, pero muchas más veces	**Adecuados**: toleran quiebres y exploran todo el rango, por lo que no quedan atrapados en un valle. Su costo, miles de evaluaciones, es aceptable porque J es barata.

(c) Comparación empírica. Se minimizó la misma J (5 bases) con seis métodos, en dos variantes del criterio: sin el término de signo (Tabla 7) y con él, que es el criterio adoptado (Tabla 8).

- Los métodos locales parten de los nudos de la regla geométrica $k = (0{,}86;\ 1{,}010;\ 1{,}090;\ 1{,}128;\ 1{,}145)$: el primer nudo antes del dominio y los demás cada vez más juntos hacia 1,16, como sugiere la Sección 2.3.
- Nelder–Mead se corrió además desde 5 puntos de partida distintos, quedándose con el mejor resultado.
- La evolución diferencial busca en todo el rango permitido, sin punto de partida.

El costo se mide en *evaluaciones de* J, que no depende de la computadora. Los métodos con gradiente (BFGS, L-BFGS-B) lo aproximan por diferencias finitas: cada gradiente cuesta $N + 1$ evaluaciones.

Tabla 7: Comparación de optimizadores **sin el término de signo** (5 bases). CVaR y error máximo, verificados sobre las 22 500 curvas del espacio de trabajo.

Método	Evaluaciones de J	J final	CVaR 99 %	Error máx.	Nudos obtenidos
Evolución diferencial (global)	10 350	**1,810**	1,73 %	2,08 %	0,8588; 1,0229; 1,0945; 1,1276; 1,1472
Nelder–Mead, 5 puntos de partida	1 680	1,823	1,75 %	2,06 %	0,8679; 1,0135; 1,0942; 1,1273; 1,1472
Powell	3 025	1,824	1,76 %	2,05 %	0,9070; 1,0230; 1,0945; 1,1276; 1,1475
Nelder–Mead, 1 punto de partida	277	1,873	1,81 %	2,26 %	0,8712; 1,0150; 1,0934; 1,1265; 1,1467
BFGS (gradiente por diferencias finitas)	504	1,952	1,91 %	2,25 %	0,8600; 1,0100; 1,0937; 1,1271; 1,1481
L-BFGS-B (gradiente por diferencias finitas)	978	1,992	1,94 %	2,43 %	0,8600; 1,0100; 1,0926; 1,1251; 1,1461

Tabla 8: Comparación de optimizadores **con el término de signo** (criterio adoptado, `PESO_NEG` = 10; 5 bases).

Método	Evaluaciones de J	J final	Nudos obtenidos
Evolución diferencial (global), 3 semillas	**7 425 a 9 600**	**1,810 (las 3)**	0,7925; 1,0229; 1,0945; 1,1276; 1,1472
Nelder–Mead, 5 puntos de partida	2 150 a 2 320	1,86 a 1,94	según los puntos de partida
BFGS (gradiente por diferencias finitas)	1 055	1,962	0,7696; 1,0236; 1,0979; 1,1293; 1,1489
Nelder–Mead, 1 punto de partida	602	1,993	0,8442; 1,0229; 1,0945; 1,1274; 1,1470
L-BFGS-B (gradiente por diferencias finitas)	1 482	2,011	0,7944; 1,0238; 1,0987; 1,1295; 1,1492
Powell	1 365	2,244	0,7911; 1,0225; 1,0892; 1,1220; 1,1450

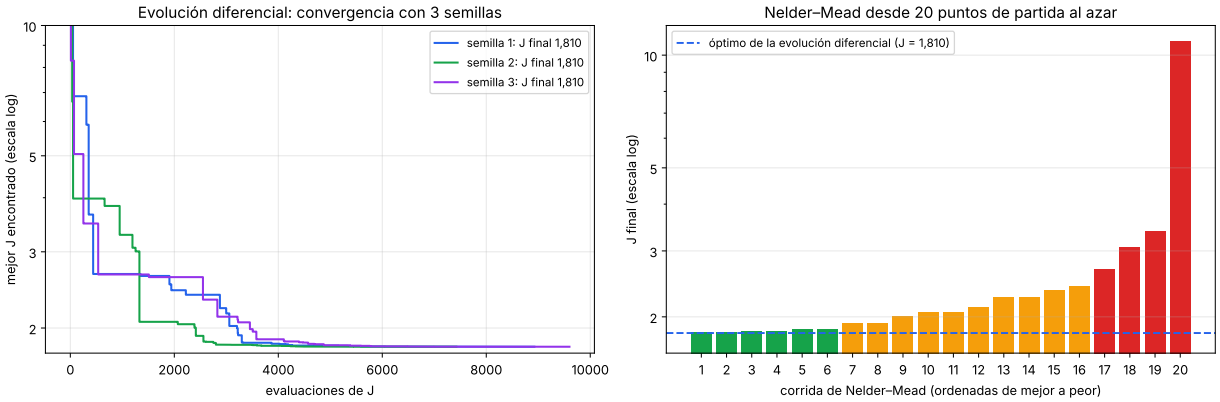


Figura 9: Criterio adoptado (con término de signo), 5 bases. Izquierda: mejor J encontrado por la evolución diferencial en función del número de evaluaciones, con tres semillas distintas; las tres llegan al mismo valor. Derecha: J final de Nelder–Mead corrido desde 20 puntos de partida sorteados en el rango (ordenados de mejor a peor); la línea discontinua es el óptimo de la evolución diferencial. Verde: a menos del 5 % del óptimo; naranja: J hasta 2,5; rojo: peor.

(d) Qué muestra la comparación.

1. **Sin el término de signo, el paisaje es benigno.** Nelder–Mead con 5 puntos de partida queda a 0,7 % del óptimo global ($J = 1{,}823$ frente a 1,810), con 6 veces menos evaluaciones, y sobre el espacio completo la diferencia es despreciable (CVaR 1,75 frente a 1,73 %). Para ese criterio, un método local con varios arranques alcanzaba.

2. **Con el término de signo, el paisaje tiene muchos valles.** Ningún método local llega al óptimo. Nelder–Mead con 5 puntos de partida queda entre 1,86 y 1,94 según cuáles sean esos puntos, y desde 20 puntos de partida al azar (Fig. 9, derecha) los resultados van de 1,82 a 10,9: solo 6 de las 20 corridas llegan a menos del 5 % del óptimo. El resultado depende del punto de partida, que es justamente lo que no se quiere.

3. **La evolución diferencial es reproducible.** Con tres semillas distintas llega al mismo $J = 1{,}8104$ y a los mismos nudos, con cuatro decimales (Fig. 9, izquierda). Su costo es de 4 a 5 veces el de Nelder–Mead con 5 arranques, unos 2 minutos, que es irrelevante para un cálculo que se hace una sola vez.

4. **Los métodos con gradiente fallan como se esperaba.** Sin el término de signo, BFGS y L-BFGS-B prácticamente no mueven k_1 ni k_2 desde el punto de partida (0,86 y 1,01): su gradiente, aproximado por diferencias finitas, es nulo o engañoso en las zonas planas y con quiebres de J. Con el término de signo mueven k_1, pero se quedan en mínimos locales.
5. **Powell** empata con Nelder–Mead en el criterio sin signo, pero con el término de signo queda último ($J = 2{,}24$): se detiene en un valle lejano.

(e) Conclusión. Se adopta la **evolución diferencial seguida de un refinamiento con Nelder–Mead** por cinco razones:

1. **No necesita derivadas** y tolera los quiebres y ondulaciones de J, donde los métodos con gradiente fallan.
2. **Es global:** explora todo el rango con una población, y no queda atrapada en el valle donde arranca. Con el término de signo, que llena el paisaje de valles, es lo que decide el resultado.
3. **Es reproducible:** da el mismo óptimo con distintas semillas, y no requiere elegir puntos de partida a mano. El resultado depende solo del criterio J y del rango.
4. **Su costo es aceptable:** unos 2 minutos, una sola vez, porque J es barata y hay pocas variables.
5. **Nelder–Mead completa la precisión:** la búsqueda global ubica el valle correcto y Nelder–Mead, que es eficaz con pocas variables, lleva el resultado al fondo con pocas evaluaciones.

Limitaciones. Ningún método sin derivadas garantiza en general el óptimo global. La garantía práctica es la que se mostró: tres semillas distintas llegan al mismo punto, y ninguno de los otros cinco métodos encontró un J menor. Nelder–Mead, por su parte, no tiene garantía general de convergencia (McKinnon, 1998), pero aquí solo se lo usa dentro del valle ya ubicado, donde el paisaje es simple.

2.7. Robustez del resultado

Respecto del azar de la búsqueda. La evolución diferencial usa sorteos. Para verificar que el resultado no depende de ellos, la búsqueda (5 bases) se repitió con tres semillas distintas: las tres llegaron a $J = 1{,}8104$ y a los mismos nudos, (0,7925; 1,0229; 1,0945; 1,1276; 1,1472), con 7 425 a 9 600 evaluaciones.

Los nudos adoptados y el óptimo. La red se entrenó con los nudos (0,7931; 1,0235; 1,0959; 1,1284; 1,1481), obtenidos con Nelder–Mead desde varios puntos de partida con este mismo criterio J. Su J es 1,866, un 3 % por encima del óptimo de la evolución diferencial. Sobre el espacio de trabajo completo, sin embargo, las dos bases son equivalentes:

Tabla 9: Nudos adoptados frente al óptimo de la evolución diferencial (5 bases), verificados en las 22 500 curvas y los 41 sujetos (999 puntos).

	Nudos adoptados	Óptimo de la evol. diferencial
Nudos	0,7931; 1,0235; 1,0959; 1,1284; 1,1481	0,7925; 1,0229; 1,0945; 1,1276; 1,1472
J (conjunto de optimización)	1,866	1,810
CVaR 99 %	1,77 %	1,73 %
Error máximo	2,04 %	2,08 %
Láminas ≥ 0 (espacio de trabajo)	99,98 %	99,95 %
Sujetos (3 % y láminas ≥ 0)	41/41	41/41
cond(A)	17,8	18,1

Los nudos difieren en menos de 0,0015 y los indicadores se reparten: el óptimo tiene algo menos de CVaR, los adoptados algo menos de error máximo y más curvas con signo correcto. Por eso se conservan los nudos adoptados, con los que la red ya está entrenada: cambiarlos obligaría a

reentrenar sin ganancia apreciable. El cuaderno los trae como referencia (`NUDOS_REF`); si se fuerza la re-optimización, la Celda 3 obtiene el óptimo de la evolución diferencial.

Respecto del número de bases. Con 4 y 6 bases la evolución diferencial converge igual (Tabla 1), en 6 a 10 minutos en el cuaderno, y da todas las láminas ≥ 0 en el 99,96 % del espacio de trabajo en ambos casos.

2.8. Resultados: 4, 5 o 6 bases

Tabla 10: MCO con los nudos de la Tabla 1, evaluado en las 22 500 curvas del espacio de trabajo y en los 41 sujetos (999 puntos). Errores en % del rango.

Bases	cond(A)	Media	CVaR 99	Máx.	Cumplen 3 %	Sujetos	$e(y_2)$
4	11,7	2,20	3,13	3,81	98,89 %	40/41	3,05
5	**17,8**	**1,26**	**1,77**	**2,04**	**100 %**	**41/41**	**2,23**
6	24,0	0,91	1,25	1,38	100 %	41/41	1,75

- **4 bases no alcanzan**: aun con los mejores nudos, el 1,1 % de las curvas queda por encima del 3 % (máximo 3,81 %), y un sujeto real tampoco cumple. La franja, que llega a 60 kPa, exige más quiebres.
- **5 bases** cumplen con margen: el máximo es 2,04 %, a casi un punto del criterio. Es la configuración adoptada.
- **6 bases** bajan el máximo a 1,38 %, pero con cond(A) en el límite: el sexto quiebre solo se puede poner muy cerca de otro. La ganancia (0,7 puntos de error máximo) se paga con un material más y con láminas más sensibles al ruido.

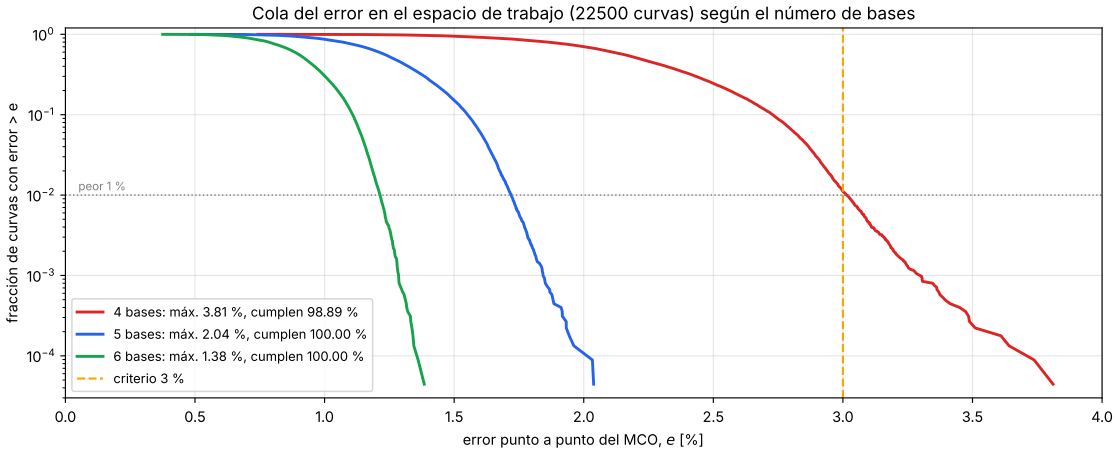


Figura 10: Fracción de curvas del espacio de trabajo con error mayor que e, para 4, 5 y 6 bases (escala logarítmica). La línea gris marca el peor 1 %; la naranja, el criterio de diseño.

2.9. Qué garantiza la base elegida y qué no

Con 5 bases y los nudos adoptados, el ajuste MCO *sin condiciones*, $c = A^{+}y$, cumple las tres propiedades buscadas:

- **Precisión:** el 100 % de las 22 500 curvas y los 41 sujetos cumplen el criterio del 3 %, con un máximo de 2,04 % (Tabla 10).
- **Estabilidad:** cond(A) = 17,8 < 25. Un ruido de 0,1 kPa en la curva produce un desvío de 0,034 láminas (Paso 4).

- **Signo:** los 41 sujetos tienen todas sus láminas ≥ 0; la menor de todas es $+0{,}30$ láminas. En el espacio de trabajo, 22 495 de las 22 500 curvas (99,98 %) tienen todas las láminas ≥ 0. Las 5 restantes tienen un único valor negativo pequeño (el más negativo es $-0{,}10$ láminas, con $C_{LAM} = 10$): 4 en el material 1 y 1 en el material 2. Son curvas sintéticas en el borde de la franja, no arterias medidas.

El costo. Exigir el signo desde la base cuesta poca precisión: el CVaR del espacio de trabajo pasa de 1,74 a 1,77 % respecto de la base optimizada sin término de signo (Tabla 4), y el NRMSE óptimo de los sujetos sube del orden de un 2 % relativo. Todas las curvas siguen lejos del 3 %.

Lo que la base no garantiza.

- **Curvas fuera de la franja y_1–y_2.** Las garantías valen para el espacio de trabajo. Una curva más rígida que y_2 o más distensible que y_1 puede ajustar peor o dar láminas negativas; el cuaderno lo informa.
- **El signo de lo que da la red.** La propiedad de signo es del MCO; la red lo reproduce con un error del orden de 0,01 láminas, por lo que una lámina MCO cercana a cero puede salir levemente negativa en la red (Sección 5).
- **La deformación de los materiales.** Con $k_1 = 0{,}7931$, el material 1 está estirado un 46 % respecto de su largo sin carga cuando $\lambda = 1{,}16$ (Sección 6). La base no impone límites de deformación; que el material los soporte es una condición de fabricación que hay que verificar aparte.

2.10. Cómo se usa en el cuaderno

En la Celda 0:

- `N_BASES` (4, 5 o 6): el número de materiales. Cambiarlo requiere reentrenar.
- `NUDOS_REF`: los nudos de referencia por número de bases (los de la Tabla 1).
- `UMBRAL_COND` (25 por defecto): la cota de cond(A).
- `PESO_NEG` (10 por defecto): el peso del término de signo (Paso 5); 0 lo desactiva.
- `OPTIMIZAR_NUDOS` (`False` por defecto): `True` fuerza la re-optimización.

La Celda 3 sigue esta lógica:

1. Toma `NUDOS_REF[N_BASES]` y calcula cond(A).
2. Si cond(A) $\geq$ `UMBRAL_COND`, si no hay nudos para ese número de bases, o si `OPTIMIZAR_NUDOS = True`, imprime "`Optimizando N nudos...`" y corre el método de esta sección: evolución diferencial y refinamiento con Nelder–Mead. Tarda entre 5 y 10 minutos.
3. Imprime la línea `NUDOS_REF[N] = [...]` para copiar en la Celda 0. Conviene copiarla: así la próxima corrida no re-optimiza y, al cargar una red entrenada (`ENTRENAR = False`), los nudos coinciden. La Celda 8 lo verifica.
4. Verifica cond(A) $<$ `UMBRAL_COND`; si no se cumple, se detiene con un mensaje.
5. Calcula las pendientes máximas `PEND_MAX` con los nudos finales (Sección 3).
6. Informa el signo: el porcentaje de curvas del espacio de trabajo con todas las láminas MCO ≥ 0 y cuántos de los 41 sujetos lo cumplen.

Resumen del método en siete líneas

1. Fijar el rango de cada nudo: $k_1 \in [0{,}60;\ 0{,}98]$, los demás en $[1{,}00;\ 1{,}156]$.
2. Para un juego de nudos, ajustar por MCO cada curva del conjunto de optimización (2500 del espacio de trabajo, 31 sujetos de entrenamiento e y_2).
3. Medir el error de cada curva (residuo máximo dividido por su rango) y promediar los de las 25 peores: eso es el CVaR.
4. Sumar 0,25× el NRMSE medio, la penalización si $\mathrm{cond}(A) > 24$ y la penalización por láminas negativas: eso es J, la calificación de esos nudos.
5. La evolución diferencial sortea una población de juegos de nudos en todo el rango y la mejora generación tras generación (mutación, cruza y selección) hasta que todos tienen el mismo J.
6. Nelder–Mead refina el mejor juego hasta el fondo del valle.
7. Se verifica el resultado en las 22 500 curvas y los 41 sujetos: precisión, estabilidad y signo.

3. Pendientes máximas y escala de las láminas

Una vez fijados los nudos, la pendiente de cada lámina se elige para que la curva más exigente del espacio de trabajo use exactamente C_{LAM} láminas de cada material. Con las líneas sin escalar $G_j(\lambda) = \mathrm{máx}(0, \lambda - k_j)$:

$$\texttt{PEND_MAX}_j = \mathrm{máx}\Big\{ \max_{y \in \text{espacio}} (G^+ y)_j,\ \max_{\text{sujetos en la franja}} (G^+ y)_j,\ (G^+ y_2)_j \Big\},$$

y la pendiente de una lámina es $S_j = \texttt{PEND_MAX}_j / C_{LAM,j}$. Con $C_{LAM} = 10$ resultan las bases de la Tabla 11. La curva y_2 es la que fija el máximo del material 4: usa exactamente 10,0 láminas. Las dos curvas límite dan todas sus láminas positivas.

Tabla 11: Bases con $C_{LAM} = 10$. $K = S_j R_{ref} k_j^2$ es la rigidez de membrana de una lámina según la ley de Laplace para un tubo de pared delgada (tensión de membrana = presión × radio) ($R_{ref} = \Theta_0 R_m/\pi = 3{,}42$ mm, mediana poblacional); $E = K/t$ con $t = 0{,}1$ mm. Las dos últimas columnas son las láminas MCO de las curvas límite.

Material	k_j	PEND_MAX [kPa]	$A_j(\lambda)$ [kPa]	K [N/m]	E [MPa]	y_1	y_2
1	0,7931	32,6	$3{,}26\,\mathrm{máx}(0, \lambda - 0{,}7931)$	7,0	0,07	0,12	9,85
2	1,0235	194,9	$19{,}49\,\mathrm{máx}(0, \lambda - 1{,}0235)$	69,8	0,70	1,78	4,47
3	1,0959	254,3	$25{,}43\,\mathrm{máx}(0, \lambda - 1{,}0959)$	104,5	1,04	0,62	8,83
4	1,1284	503,2	$50{,}32\,\mathrm{máx}(0, \lambda - 1{,}1284)$	219,2	2,19	0,67	10,00
5	1,1481	830,3	$83{,}03\,\mathrm{máx}(0, \lambda - 1{,}1481)$	374,4	3,74	0,56	5,68
$\mathrm{cond}(A) = 17{,}79$ (umbral 25). MCO: $e(y_1) = 1{,}13$ %, $e(y_2) = 2{,}23$ %.							

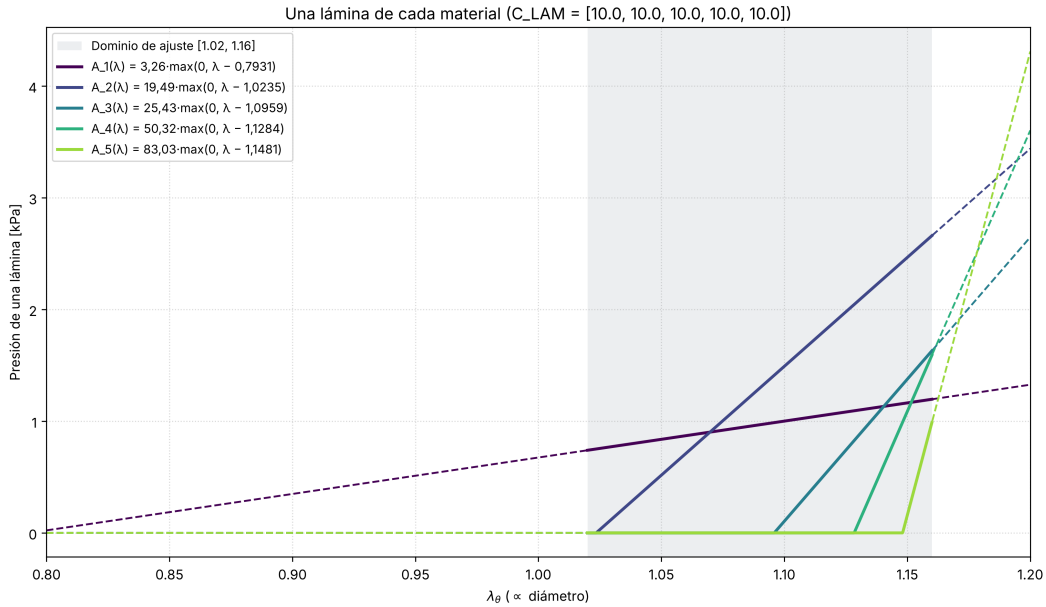


Figura 11: Una lámina de cada material ($C_{LAM} = 10$). Continua: dominio de ajuste; punteada: la misma fórmula fuera de él.

C_{LAM} es una elección de unidades. Si se cambia la escala de una base, el MCO divide su coeficiente por el mismo factor. Por eso cambiar $C_{LAM,j}$ cambia la rigidez de una lámina y, en proporción inversa, el número de láminas. El producto $c_j S_j$ (la pendiente de la capa) no cambia, y tampoco la curva, el error, el signo de las láminas ni la rigidez total de cada capa.

- Se puede elegir un C_{LAM} distinto para cada material, sin reentrenar: las salidas de la red se multiplican por $C_{LAM,j}/10$.
- La Tabla 12 lo comprueba con la curva media de los hipertensos y dos elecciones de C_{LAM}.

Tabla 12: Injerto MCO para Mean HT con dos elecciones de C_{LAM}. Cambian las láminas y la rigidez de una lámina; la rigidez total de cada capa y el error máximo (0,396 kPa) son idénticos.

	$C_{LAM} = [10, 10, 10, 10, 10]$			$C_{LAM} = [8, 10, 10, 12, 15]$		
Material	Láminas	K 1 lámina	K total	Láminas	K 1 lámina	K total
1	4,75	7,0	33,3	3,80	8,8	33,3
2	4,14	69,8	289,1	4,14	69,8	289,1
3	4,00	104,5	417,7	4,00	104,5	417,7
4	3,68	219,2	806,1	4,41	182,7	806,1
5	3,12	374,4	1168,3	4,68	249,6	1168,3
Total	19,68			21,03		

4. Dataset sintético y red neuronal

4.1. Dataset

Se generan 50 000 curvas en siete familias (Tabla 13). Las familias se agrupan en dos clases, que conviene distinguir al leer los resultados:

Familias del dataset: "de bases" y "fisiológicas"

Las siete familias de curvas del dataset se agrupan en dos clases:

- **Familias de bases** (pura y combinada): curvas armadas sumando láminas de las propias bases, es decir, rampas y poligonales con quiebres en los nudos. No se parecen a una arteria. Le enseñan a la red qué hace cada material por separado y a no mezclarlos (crosstalk). Como son combinaciones exactas de las bases, su óptimo MCO es casi perfecto, y un error pequeño de la red da un exceso relativo alto.
- **Familias fisiológicas** (constitutiva, amplia, uniforme, exponencial y pacientes): curvas suaves con forma J, como las de una arteria. Salen de la ley constitutiva de Masson con parámetros derivados de los sujetos de entrenamiento (mezclados, perturbados o sorteados), de otra ley exponencial ajustada a esos sujetos, o directamente de los 31 sujetos de entrenamiento con ruido. Representan lo que la red recibe al diseñar un injerto, y por eso con ellas se juzga su desempeño.

"Fisiológica" indica que la curva proviene de un modelo de arteria, no de las bases. No significa que cada curva corresponda a una arteria medida: la familia amplia extrapola parámetros y la exponencial no se filtra por la franja y_1–y_2.

Una curva fisiológica se acepta solo si cumple todas estas condiciones:

- es positiva;
- es monótona;
- es convexa desde $\lambda = 1{,}05$ (forma J);
- no supera 1,5 veces la presión máxima de los sujetos;
- salvo en la familia exponencial, queda dentro de y_1–y_2.

Tabla 13: Familias del dataset (50 000 curvas).

Familia	%	Cómo se genera
pura	20	Un solo material, con láminas log-uniformes entre 0,1 y 10 (el logaritmo es uniforme: hay tantas curvas entre 0,1 y 1 lámina como entre 1 y 10). Ruido del 0,5 %.
combinada	20	De 2 a N materiales al azar, con láminas uniformes entre 0 y 10. Se reduce la escala si supera el techo de presión. Ruido del 0,5 %.
constitutiva	20	Ley de Masson con una mezcla convexa de 2–3 sujetos (promedio ponderado con pesos aleatorios positivos que suman 1, sorteados con una distribución de Dirichlet), perturbación moderada de los parámetros y amplitud entre 0,85 y 1,20. Ruido del 1 %.
amplia	15	Igual, con 2–4 sujetos, perturbaciones mayores, extrapolación desde el centro de la población (γ hasta 1,35) y amplitud entre 0,65 y 1,50.
exponencial	10	Otra ley: $C + \mu E + k_1 E e^{k_2 E^2}$ con $E = \lambda^2 - 1$, media geométrica de los ajustes de 2–3 sujetos. No se filtra por la franja.
uniforme	10	Ley de Masson con cada parámetro independiente, uniforme entre el mínimo y el máximo de los sujetos de entrenamiento.
pacientes	5	Los 31 sujetos de entrenamiento, repetidos, con ruido del 1 %.

Ruido. Para imitar los errores de medición, a cada punto de la curva se le suma un valor aleatorio con distribución normal, de media 0 y desvío igual al 0,5 % o al 1 % del valor de la curva en ese punto, según la familia.

Etiquetas. La *etiqueta* de cada curva es la respuesta que la red debe aprender: su ajuste MCO *con la misma curva ruidosa que ve la red*, expresado en láminas con $C_{LAM} = 10$.

Partición. Las 50 000 curvas se dividen en tres conjuntos disjuntos, *estratificados* por familia (cada uno conserva las proporciones de familias de la Tabla 13):

- **entrenamiento** (35 000): las curvas con las que la red ajusta sus parámetros;
- **validación** (5 000): la red no aprende de ellas; sirven para decidir cuándo reducir el paso de aprendizaje y cuándo detener el entrenamiento;
- **test** (10 000): se usan solo al final, para evaluar la red con curvas que nunca intervinieron en el entrenamiento.

4.2. Red y entrenamiento

Qué es la red. Una **red neuronal densa** (perceptrón multicapa) es una función con muchos coeficientes ajustables, llamados *pesos* o *parámetros*. Transforma la entrada (999 números) en la salida (5 láminas) mediante capas sucesivas. Cada *neurona* calcula una suma ponderada de las salidas de la capa anterior más una constante, y le aplica una función no lineal. **Entrenar** la red es ajustar sus pesos para que su salida se acerque a las etiquetas, minimizando una función de pérdida sobre las curvas de entrenamiento (Goodfellow et al., 2016).

- **Entrada:** la curva en los 999 puntos de la grilla, transformada como $\log(y+5)$, que comprime el rango de presiones, y *estandarizada*: a cada uno de los 999 valores se le resta su media y se lo divide por su desvío estándar, ambos calculados sobre el conjunto de entrenamiento.
- **Arquitectura:** tres capas densas de 256, 128 y 64 neuronas.
  - Cada capa usa la función no lineal **ReLU**, $\max(0, x)$.
  - Cada capa usa **normalización de capa**, que reescala sus salidas a media 0 y desvío 1 y estabiliza el entrenamiento (Ba et al., 2016).
  - La salida es lineal, con las 5 láminas estandarizadas.
  - En total, 298 373 parámetros.
- **Pérdida:** la función que el entrenamiento minimiza. MSE es el error cuadrático medio (*mean squared error*).

$$L = \underbrace{\mathrm{MSE}(\hat{c}_{std}, c_{std})}_{\text{láminas}} + 5 \cdot \underbrace{\mathrm{media}\left(\frac{A(\hat{c}-c)}{\max Ac}\right)^2}_{\text{curva reconstruida}} + 5 \cdot \underbrace{\mathrm{media}\left(m \odot \hat{c}^{\,2}\right)}_{\text{crosstalk}}.$$

  - El primer término compara las láminas estandarizadas.
  - El segundo compara las curvas que esas láminas reconstruyen, relativas al máximo de cada curva.
  - El tercero penaliza las láminas que la red asigna a materiales que el generador dejó en cero ($m = 1$ en las familias pura y combinada). Se llama *crosstalk*: la fuga de un material a otro.
- **Entrenamiento:** con el algoritmo **Adam** (Kingma y Ba, 2015), una variante del descenso por gradiente que adapta el tamaño del paso de cada peso.
  - **Época y lote.** Una *época* es una pasada completa por las 35 000 curvas de entrenamiento. Dentro de cada época, las curvas se procesan en *lotes* de 64, y los pesos se corrigen después de cada lote (547 correcciones por época).
  - **Learning rate** (tasa de aprendizaje): el tamaño de cada corrección. Empieza en 10^{-3} y se reduce a la mitad cada vez que la pérdida de validación no mejora durante 30 épocas, hasta 10^{-6}.

- **Parada temprana** (*early stopping*): si la pérdida de validación no mejora durante 80 épocas, el entrenamiento se detiene y se restauran los pesos de la mejor época.

Pulido. Para un diseño final, la red puede completarse con un paso MCO, $c = A^{+}y$. Las *ecuaciones normales*, $A^{\mathsf{T}}Ac = A^{\mathsf{T}}y$, son la condición que caracteriza al mínimo de MCO; se cumplen con un residuo relativo $\leq 2{,}5\times10^{-15}$, de modo que red + pulido da el óptimo exacto. Los resultados que siguen son de *la red sola*, sin pulido.

Control de clase. Antes de usar la red, se verifica que la curva de entrada sea de la clase aprendida. Se acepta si una combinación no negativa de 40 líneas truncadas (nudos entre 0,85 y 1,16) la aproxima con NRMSE ≤ 2 %. Esa combinación se calcula con *mínimos cuadrados no negativos* (NNLS, Lawson y Hanson, 1974), es decir, MCO con la restricción de que todos los coeficientes sean ≥ 0. Se usa solo para este control, no para el diseño. Una curva que no admite esa aproximación no tiene forma J y no se puede reproducir con láminas.

5. Resultados de la red

5.1. Entrenamiento

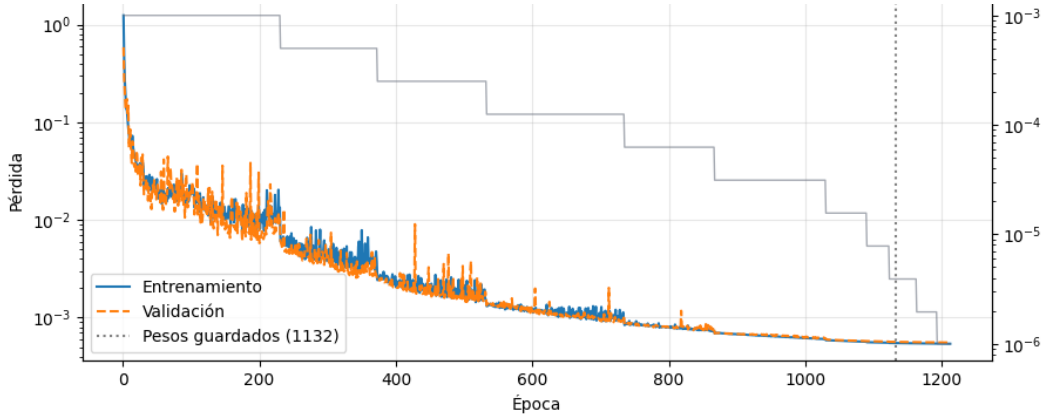


Figura 12: Pérdida de entrenamiento y de validación (gris, eje derecho: learning rate). Se guardan los pesos de la época 1132.

El entrenamiento duró 1212 épocas (73 min en CPU), y se guardaron los pesos de la época 1132. Las pérdidas de entrenamiento (0,000550) y de validación (0,000564) terminan juntas, sin *sobreajuste* (el sobreajuste ocurre cuando la red memoriza las curvas de entrenamiento y empeora en las de validación). Cada escalón del learning rate produce una bajada de la pérdida; desde la época 1155 la mejora es despreciable.

Tiempo y signo en el test. Sobre las 10 000 curvas de test, la red tarda 0,10 ms por curva, frente a 0,14 ms del MCO en la misma computadora. La red da alguna lámina negativa en el 26,4 % de las curvas de test (la más negativa, −0,015), frente al 31,0 % del MCO (la más negativa, −0,157). Casi todas son curvas de las familias de bases, que tienen materiales ausentes (láminas exactamente 0) a los que el ruido de la curva hace oscilar alrededor de cero (Sección 5.3).

5.2. Los 41 sujetos y las curvas medias

Medidas usadas en los resultados:

- **Óptimo:** el ajuste MCO, que es el mejor ajuste posible con las bases, en el sentido de los cuadrados mínimos.
- **Exceso:** cuánto peor ajusta la red que el óptimo, exceso = $\mathrm{NRMSE}_{red}/\mathrm{NRMSE}_{óptimo} - 1$. Un exceso de +1,5 % significa que el error típico de la red es 1,015 veces el del óptimo.

- **R^2** (coeficiente de determinación): $R^2 = 1 - \sum r_i^2 / \sum (y_i - \bar{y})^2$. Vale 1 para un ajuste perfecto.
- **$|\Delta c|$:** diferencia, en láminas, entre la red y el óptimo.
- **Mediana:** el valor que deja por debajo a la mitad de los casos.

Tabla 14: Red sola frente al óptimo MCO en los sujetos de Masson.

Grupo	n	NRMSE óptimo	NRMSE red	Exceso	Error pto. máx. red	Cumplen ≤ 3 %	máx $\lvert\Delta c\rvert$
Test	10	0,509 %	0,514 %	+0,81 %	1,73 %	10/10	0,017
Entrenamiento	31	0,471 %	0,474 %	+0,73 %	1,66 %	31/31	0,023
Normotensos	16	0,449 %	0,455 %	+1,28 %	≤1,73 %	16/16	≤0,023
Hipertensos	25	0,500 %	0,502 %	+0,45 %	≤1,73 %	25/25	≤0,023
Todos	**41**	0,480 %	0,484 %	**+0,75** %	1,73 %	**41/41**	0,023

- En los 10 sujetos de test, la mediana del exceso es +0,3 %.
- El máximo es NT02, con +4,9 %, que equivale a menos de 0,02 láminas.
- El peor error punto a punto de la red (1,73 %) queda muy por debajo del criterio.
- Además, el MCO da todas las láminas ≥ 0 en los 41 sujetos (Sección 2.9), de modo que el diseño de cualquiera de ellos es fabricable tal como sale.

Tabla 15: Curvas medias de los grupos de Masson.

Curva	n	Láminas MCO (total)	Exceso de NRMSE	Error pto. red	Error pto. óptimo
Mean Young	7	13,10	+0,59 %	1,01 %	1,03 %
Mean Old	9	17,86	+1,04 %	1,49 %	1,42 %
Mean NT	11	17,68	+2,19 %	1,50 %	1,37 %
Mean HT	25	19,68	+0,37 %	1,31 %	1,37 %

5.3. Test por familia

Tabla 16: Test por familia (10 000 curvas). Criterio evaluado contra la curva sin ruido.

Familia	n	NRMSE óptimo	NRMSE red	Exceso	R^2 red mín.	Red cumple 3 %	Red máx.	MCO máx.
pura	2000	0,342	0,423	+23,9 %	0,980	98,75 %	5,78 %	0,80 %
combinada	2000	0,243	0,335	+37,8 %	0,961	98,65 %	9,16 %	0,64 %
constitutiva	2000	0,731	0,734	+0,43 %	0,997	100 %	2,02 %	1,76 %
amplia	1500	0,738	0,743	+0,70 %	0,997	100 %	2,18 %	1,91 %
exponencial	1000	0,749	0,756	+0,97 %	0,998	100 %	2,90 %	2,50 %
uniforme	1000	0,748	0,753	+0,65 %	0,998	100 %	2,24 %	1,97 %
pacientes	500	0,733	0,736	+0,33 %	0,997	100 %	1,72 %	1,71 %

- **Familias fisiológicas** (constitutiva, amplia, exponencial, uniforme y pacientes: las de forma arterial). El exceso queda entre +0,3 y +1,0 %: la red está prácticamente sobre el óptimo. **Las 6 000 curvas cumplen el criterio del 3 %**; el peor caso (2,90 %, en la familia exponencial, que no se filtra por la franja) es una curva en la que el MCO ya da 2,50 %.
- **Familias de bases** (pura y combinada). El exceso relativo es mayor (24 a 38 %), pero sobre óptimos muy chicos (NRMSE de 0,24–0,34 %). La causa es el ruido de la curva:
  - el MCO reparte ese ruido como láminas chicas, de ambos signos, en los materiales ausentes;
  - la red, entrenada para no producir crosstalk, las deja casi en cero.

El 1,3 % de estas curvas no cumple el 3 % con la red (máximo 9,2 %). Son poligonales de muy poca presión, con tramos casi planos, sin sentido fisiológico; en ellas el error relativo al rango amplifica diferencias absolutas mínimas. No representan arterias, y si hiciera falta, el pulido MCO las lleva al óptimo exacto.

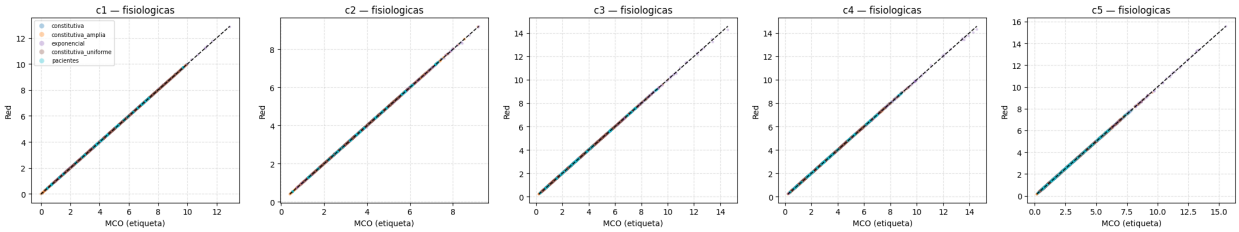


Figura 13: Láminas de la red frente a las del MCO en las familias fisiológicas de test (6000 curvas). $R^2 \geq 0{,}99982$ en los cinco materiales; error medio absoluto de 0,007 a 0,017 láminas.

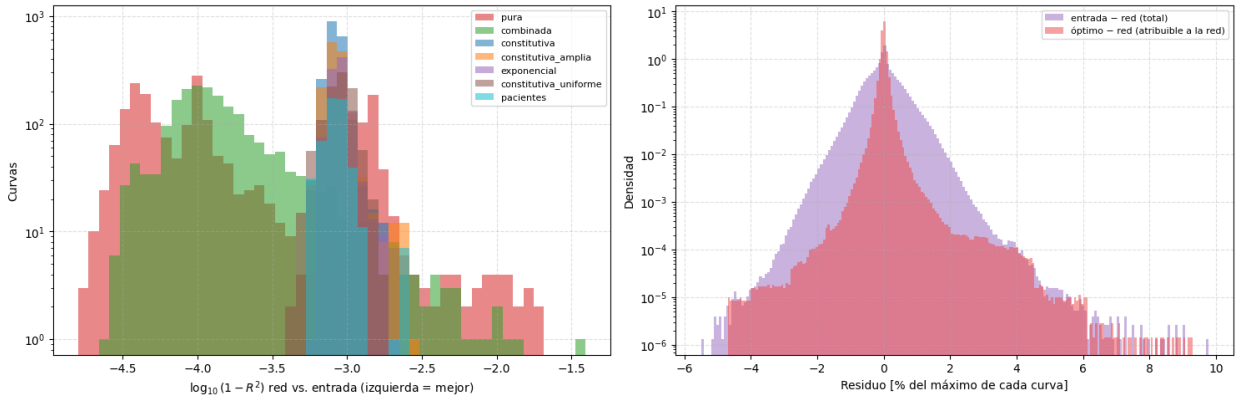


Figura 14: Izquierda: $\log_{10}(1 - R^2)$ de la red por familia. Derecha: residuo total (violeta) y la parte atribuible a la red (óptimo − red, rojo), en % del máximo de cada curva. El cuerpo de la parte atribuible a la red está dentro de ±2 %.

5.4. Generalización a una ley nunca vista y control de clase

Se generaron 300 curvas con una *ley tipo Fung*, una exponencial pura $P(\lambda) = C + a(e^{\,b(\lambda - 1{,}02)} - 1)$ (Fung, 1993), con parámetros obtenidos de los sujetos de entrenamiento. No forma parte del dataset de entrenamiento (con ruido del 1 %; el 0,8 % de sus puntos queda fuera de y_1–y_2).

- El NRMSE de la red es 1,179 % y el del óptimo 1,161 %: un exceso de +1,5 %.
- El peor R^2 de la red es 0,9968, frente a un óptimo de 0,9971.
- El MCO da todas las láminas ≥ 0 en las 300 curvas.

La red generaliza a una forma funcional que no vio, casi sin costo frente al óptimo.

El control de clase acepta todas las curvas de Fung y los 41 sujetos. Rechaza el 95,7 % de las curvas moduladas que dejan de tener forma J, y acepta el 73,9 % de las que la conservan.

5.5. Reproducción de láminas aisladas

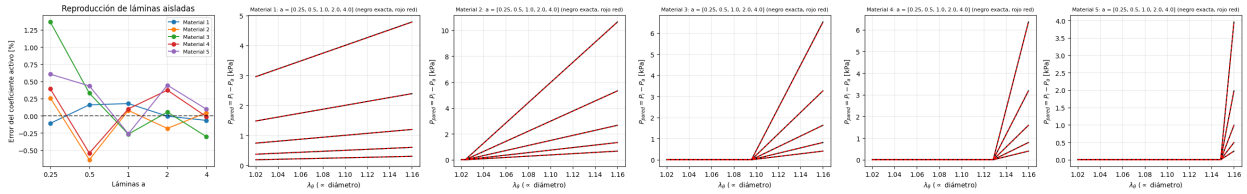


Figura 15: Entrada $y = a\,A_j$ (una sola base, $a = 0{,}25$ a 4 láminas); la respuesta exacta es $c = a\,e_j$. Izquierda: error del coeficiente activo; resto: curvas exactas (negro) y de la red (rojo).

- **Crosstalk:** el máximo en los materiales ausentes es 0,001 láminas.
- **Coeficiente activo:** el error es como mucho ±0,65 % en todos los casos salvo uno: el material 3 con 0,25 láminas, con 1,36 %, que en valor absoluto son 0,003 láminas.
- **Material 5:** el error es $\leq$ 0,6 % en todas las amplitudes, aunque esa base solo actúa en el último 8 % del dominio.

6. Diseño: la curva media de los hipertensos

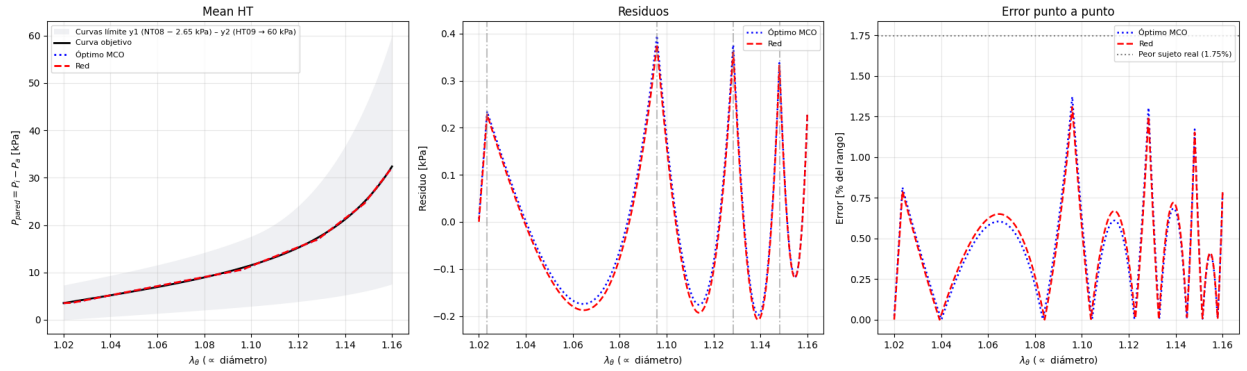


Figura 16: Mean HT: curva, ajuste MCO y red (izquierda), residuos (centro; líneas verticales en los nudos) y error punto a punto (derecha).

Tabla 17: Injerto para Mean HT ($C_{LAM} = 10$): láminas del MCO y de la red, y rigidez de cada capa. Holgura de fibra: $k_j/k_1 - 1$. Deformación máxima: estiramiento del material en $\lambda = 1{,}16$ respecto de su largo sin carga, $1{,}16/k_j - 1$.

Material	Nudo	Holgura de fibra	Láminas MCO	Láminas red	K 1 lámina [N/m]	K total [N/m]	Aporte a $P(1{,}16)$ [kPa]	Deform. máx.
1	0,7931	0 %	4,750	4,759	7,0	33,3	5,68	**46,3 %**
2	1,0235	29,1 %	4,138	4,145	69,8	289,1	11,01	13,3 %
3	1,0959	38,2 %	3,997	3,988	104,5	417,7	6,52	5,9 %
4	1,1284	42,3 %	3,678	3,669	219,2	806,1	5,85	2,8 %
5	1,1481	44,8 %	3,120	3,121	374,4	1168,3	3,08	1,0 %
Total			19,684	19,682			32,14	

- **Láminas:** la red difiere del MCO en 0,009 láminas como máximo. Todas son positivas.
- **Error:** el punto a punto de la red es menor que el del MCO (1,31 % contra 1,37 %), y el NRMSE prácticamente igual (0,532 contra 0,530 %). Los picos del residuo caen en los nudos 3, 4 y 5: es el piso de error de las bases, no de la red.
- **Injerto resultante:**

- radio de reposo de 0,7931 $R_{ref} = 2{,}71$ mm, sin pretensado;
- presión de pared en $\lambda = 1{,}16$ de 32,1 kPa (241 mmHg);
- cada material entra en carga con la holgura de fibra indicada en la tabla.

- **A verificar en la fabricación:** el material 1 trabaja estirado hasta un 46 % en $\lambda = 1{,}16$. Es consecuencia de su nudo bajo, que es lo que asegura el signo de las láminas (Paso 5 de la Sección 2.4). El material elegido para esa capa debe admitir esa deformación en régimen elástico; los demás trabajan por debajo del 14 %.

7. Conclusiones

1. **Espacio de trabajo.** Se definió entre dos curvas límite que contienen a las 41 carótidas de Masson et al. (2011) y llegan a 60 kPa. El ajuste se hace en [1,02; 1,16], el rango respaldado por las mediciones.
2. **Elección de las bases.** El objetivo fue elegir la base de modo que el ajuste sea MCO sin condiciones. El método minimax califica cada juego de nudos con el CVaR 99 % del error punto a punto, un desempate por NRMSE, la restricción $\mathrm{cond}(A) < 25$ y una penalización por láminas negativas, y lo minimiza con evolución diferencial y un refinamiento con Nelder–Mead. Con 5 materiales, el MCO libre $c = A^{+}y$:

   - cumple el criterio del 3 % en las 22 500 curvas del espacio de trabajo (máximo 2,04 %) y en los 41 sujetos;
   - es estable: $\mathrm{cond}(A) = 17{,}8$;
   - da todas las láminas ≥ 0 en los 41 sujetos y en el 99,98 % del espacio de trabajo.

   Con 4 materiales no alcanza; con 6 la mejora es moderada y $\mathrm{cond}(A)$ queda en el límite.
3. **Optimizador.** Con el término de signo, la función objetivo tiene muchos mínimos locales: un método local depende del punto de partida. La evolución diferencial llega al mismo óptimo con distintas semillas, por lo que la base resulta reproducible y no depende de elecciones manuales.
4. **Red neuronal.**

   - Reproduce el óptimo: +0,75 % en los 41 sujetos, todos dentro del criterio, y entre +0,3 y +1,0 % en las familias fisiológicas, donde las 6 000 curvas de test cumplen el 3 %.
   - Generaliza a una ley nunca vista con un exceso de +1,5 %.
   - Su diseño para la curva media de los hipertensos coincide con el óptimo en 0,01 láminas.
5. **Número de láminas.** C_{LAM} es una elección de unidades: puede fijarse por material según los materiales disponibles, sin reentrenar y sin cambiar el injerto.
6. **Trabajo futuro.**

   - Verificar que el material de la capa 1 admita deformaciones del orden del 46 %; si no, incorporar a la elección de la base una cota para el primer nudo.
   - Si interesa un tope de dilatación ante sobrepresiones, estudiar un material “freno” con nudo cerca de 1,16.

A. El cuaderno

Celda	Contenido
0	Configuración: `N_BASES`, `NUDOS_REF`, `OPTIMIZAR_NUDOS`, `UMBRAL_COND`, `PESO_NEG`, `C_LAM`, `ENTRENAR`
1	Modelo de Masson, 41 sujetos y curvas límite
2	Espacio de trabajo: curvas fisiológicas sintéticas
3	Bases: cond(A), nudos (minimax si hace falta), `PEND_MAX` y signo de las láminas
4	Verificación de las bases sobre los 41 sujetos
5	Figura: láminas de las curvas límite y error de los 41 sujetos
6	Librerías, entrada logarítmica, métricas y predicción
7	Dataset: familias pura y combinada + fisiológicas
8	Partición y normalización (verifica los nudos al cargar una red)
9–11	Pérdida y arquitectura, integridad de los datos, entrenamiento o carga de la red
12–18	Evaluación en test, reconstrucción, 41 sujetos, figuras, familias, ley de Fung, muestras
19	Diseñador de injerto
20	Reproducción de láminas aisladas
21	Las bases con su fórmula
22	Extrapolación fuera del dominio de ajuste

- Con `ENTRENAR = True` el cuaderno genera el dataset y entrena la red; con `False`, carga una red ya entrenada.
- Los archivos de la red llevan en el nombre el número de bases, de modo que redes con 4, 5 o 6 materiales no se pisan entre sí.
- Las tablas de Masson (`tabla2_masson_NT.csv`, `tabla4_masson_HT.csv`) van en la misma carpeta que el cuaderno.

B. Datos de partida: Masson et al. (2011)

Este apéndice reúne la información del artículo de Masson et al. (2011) que usa el método, para que el documento sea autocontenido. Los autores midieron in vivo, a lo largo del ciclo cardíaco, el diámetro y la presión de la carótida común de 16 sujetos normotensos y 25 hipertensos tratados. A cada sujeto le ajustaron un modelo constitutivo de la pared arterial, y publicaron los parámetros en las Tablas 2 y 4 del artículo (Tablas 18 y 19 de este informe). Las curvas de presión de pared de este trabajo se calculan con esos parámetros y con las ecuaciones que siguen.

B.1. Ley constitutiva

La pared se modela como un material incompresible, con una energía de deformación formada por tres contribuciones:

- **Elastina**, neo-Hookeana (el modelo elástico isótropo más simple, cuya energía es proporcional a $I_1 - 3$, con I_1 el primer invariante de la deformación), con módulo c.
- **Colágeno**, en cuatro familias de fibras con respuesta exponencial, con la estructura introducida por Holzapfel et al. (2000): una axial, una circunferencial y dos diagonales a $\pm\alpha$ respecto del eje. Las fibras axiales y diagonales comparten los parámetros (c_1, c_2); las circunferenciales tienen los suyos, (c_1^{circ}, c_2^{circ}).
- **Tono muscular activo**, con tensión máxima T_m y estiramientos característicos λ_0 (sin tensión activa) y λ_m (tensión máxima).

Con estiramiento axial fijo λ_z e incompresibilidad ($\lambda_r = 1/(\lambda_\theta \lambda_z)$), la diferencia de tensiones circunferencial y radial en función del estiramiento circunferencial local λ_θ es

$$\sigma_{\theta\theta} - \sigma_{rr} = c\left(\lambda_\theta^2 - \lambda_r^2\right) + \lambda_\theta^2 \sum_{k=1}^{4} c_{1,k}\, E_k\, e^{\,c_{2,k} E_k^2}\, \sin^2 \varphi_k + T_m\, \lambda_\theta \left[1 - \left(\frac{\lambda_m - \lambda_\theta}{\lambda_m - \lambda_0}\right)^2\right],$$

donde $E_k = \lambda_k^2 - 1$, y para cada familia de fibras:

Familia	Ángulo φ_k (desde el eje)	Estiramiento λ_k	$c_{1,k}$	$c_{2,k}$
axial	0	λ_z	c_1	c_2
circunferencial	90°	λ_θ	c_1^{circ}	c_2^{circ}
diagonales	$\pm\alpha$	$\sqrt{\lambda_\theta^2 \sin^2\alpha + \lambda_z^2 \cos^2\alpha}$	c_1	c_2

La familia axial no contribuye a la dirección circunferencial, porque $\sin^2 0 = 0$.

B.2. Cinemática y presión de pared

La configuración de referencia libre de tensiones es un sector anular con ángulo de apertura Θ_0 y radio medio R_m. Un punto de radio R en la referencia pasa al radio r en la arteria cerrada y estirada. Por incompresibilidad,

$$R^2 = R_m^2 - \frac{\pi \lambda_z}{\Theta_0}\left(r_m^2 - r^2\right), \qquad \lambda_\theta(r) = \frac{\pi\, r}{\Theta_0\, R}, \qquad r_m = \lambda_\theta\, \frac{\Theta_0 R_m}{\pi}.$$

La abscisa de todas las curvas es el estiramiento en el radio medio, $\lambda_\theta = r_m / R_{ref}$ con $R_{ref} = \Theta_0 R_m / \pi$, proporcional al diámetro.

Del equilibrio radial resulta la presión de pared

$$P_{pared} = P_i - P_a = \int_{r_m - h}^{r_m} \frac{\sigma_{\theta\theta} - \sigma_{rr}}{r}\, dr,$$

con $h = 0{,}6\,\text{mm}$, calculada con la regla del trapecio (integración numérica que aproxima el área bajo la curva por trapecios) sobre 60 puntos radiales. P_{pared} no depende de la presión perivascular P_a.

Validación. Las Figs. 5a y 7a de Masson grafican la tensión circunferencial $\sigma_{\theta\theta}$ en r_m, de la que se descuenta el término perivascular $a\, e^b$ con los parámetros a, b de las tablas. Reconstruida así con las ecuaciones de arriba, reproduce las curvas medias publicadas con un RMSE de 0,6 a 0,9 kPa (1,2 a 1,7 % de su valor medio): Mean Young 1,7 %, Mean Old 1,5 %, Mean NT 1,2 % y Mean HT 1,4 %.

B.3. Figuras 5a y 7a: de la tensión a la presión de pared

Las Figs. 17 y 18 muestran, a la izquierda, las figuras originales del artículo, con la tensión circunferencial (90–150 kPa en los sujetos más rígidos). A la derecha están las presiones de pared de los mismos sujetos calculadas con la ley constitutiva, que son las curvas objetivo de este trabajo. La presión es del orden de la tensión por h/r ($\approx 0{,}16$), por eso sus valores son unas seis veces menores. Las curvas originales cubren solo el rango de λ medido en cada sujeto; las de la derecha se evalúan en todo el dominio [1,02; 1,16].

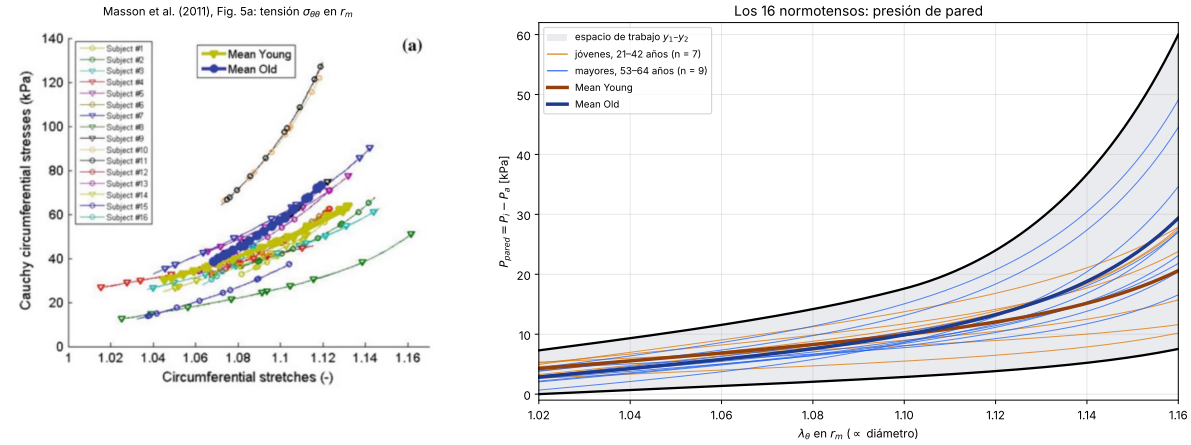


Figura 17: Izquierda: Fig. 5a de Masson et al. (2011), tensión circunferencial de los 16 normotensos y medias de jóvenes y mayores (reproducida del artículo). Derecha: presión de pared de los mismos sujetos con la ley constitutiva y el espacio de trabajo y_1–y_2.

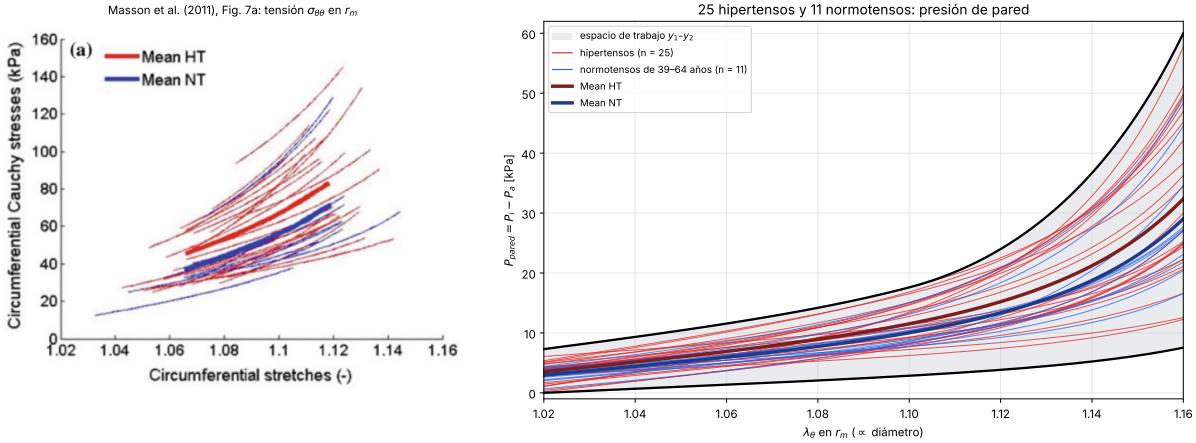


Figura 18: Izquierda: Fig. 7a de Masson et al. (2011), tensión circunferencial de los 25 hipertensos y de los 11 normotensos de edad comparable, con sus medias (reproducida del artículo). Derecha: presión de pared de los mismos sujetos con la ley constitutiva y el espacio de trabajo y_1–y_2.

B.4. Tablas 2 y 4: parámetros de los 41 sujetos

Las Tablas 18 y 19 reproducen los parámetros publicados:

- **Geometría:** R_m y Θ_0 son el radio medio y el ángulo de apertura de la configuración libre de tensiones, y λ_z es el estiramiento axial in vivo.
- **Elastina:** c.
- **Colágeno:** c_1 y c_2 (fibras axiales y diagonales), c_1^{circ} y c_2^{circ} (fibras circunferenciales), y α, el ángulo de las fibras diagonales.
- **Tono activo:** T_m, λ_0 y λ_m.
- **Presión perivascular:** a y b.

Los sujetos marcados con † son los 10 reservados para test.

Tabla 18: Tabla 2 de Masson et al. (2011): parámetros de los 16 sujetos normotensos. †: sujeto reservado para test. RMSE: error del ajuste del modelo a los datos, informado por los autores.

Sujeto	Edad [años]	Sexo	R_m [mm]	Θ_0 [°]	λ_z	c [kPa]	c_1 [kPa]	c_2	c_1^{circ} [kPa]	c_2^{circ}	α [°]	T_m [kPa]	λ_0	λ_m	a [kPa]	b	RMSE [kPa]
NT01	62	F	4,261	128,7	1,11	29,82	9,44	14,14	16,13	15,11	65,74	39,73	0,96	1,70	0,122	3,52	0,174
NT02†	60	M	4,691	128,9	1,08	20,42	8,47	13,10	14,16	15,12	44,46	41,84	0,68	1,92	0,126	3,40	0,288
NT03	31	M	4,305	132,2	1,09	27,23	10,34	13,10	7,01	12,82	48,62	43,37	0,82	1,65	0,139	3,57	0,131
NT04	31	M	4,672	133,9	1,10	23,59	6,58	11,77	6,38	10,69	32,04	39,81	0,68	1,59	0,118	3,53	0,146
NT05	34	F	4,203	130,1	1,10	35,68	13,62	13,18	13,38	13,17	50,72	50,07	0,86	1,62	0,103	3,58	0,123
NT06	53	F	3,957	130,1	1,11	33,37	11,38	13,63	13,30	14,26	57,14	46,59	0,95	1,69	0,093	3,44	0,269
NT07	21	F	3,827	132,0	1,10	44,28	21,79	13,17	8,27	12,73	51,15	53,58	0,92	1,62	0,111	3,58	0,215
NT08†	25	M	4,856	133,2	1,07	23,25	6,34	12,93	8,11	13,17	42,93	31,90	0,82	1,77	0,173	3,57	0,367
NT09	42	F	4,506	129,5	1,10	34,90	16,14	13,58	19,64	13,89	57,21	47,01	0,93	1,65	0,084	3,55	0,209
NT10†	55	M	4,770	129,1	1,10	38,57	36,31	13,31	56,88	13,61	54,22	46,36	0,89	1,66	0,006	3,75	0,652
NT11†	64	M	5,566	129,5	1,10	34,89	40,16	13,45	66,88	13,53	54,54	41,12	0,85	1,79	0,005	3,23	0,375
NT12	60	F	4,876	130,1	1,09	33,94	10,78	13,95	12,79	15,42	60,97	45,77	0,93	1,73	0,099	3,37	0,362
NT13	61	F	4,924	130,6	1,09	35,15	17,69	13,43	18,40	13,22	55,04	45,59	0,94	1,66	0,085	3,51	0,240
NT14	39	F	3,539	131,5	1,09	28,97	8,22	13,13	19,02	13,16	50,22	41,30	0,89	1,67	0,105	3,53	0,262
NT15	58	F	3,922	132,4	1,08	26,71	15,79	13,36	16,68	13,11	53,60	35,32	0,95	1,71	0,166	3,60	0,302
NT16	60	M	5,718	129,7	1,10	27,79	28,23	13,46	57,77	13,63	55,73	36,50	1,05	1,77	0,141	3,58	0,283

Tabla 19: Tabla 4 de Masson et al. (2011): parámetros de los 25 sujetos hipertensos tratados. †: sujeto reservado para test. RMSE: error del ajuste del modelo a los datos, informado por los autores.

Sujeto	Edad [años]	Sexo	R_m [mm]	Θ_0 [°]	λ_z	c [kPa]	c_1 [kPa]	c_2	c_1^{circ} [kPa]	c_2^{circ}	α [°]	T_m [kPa]	λ_0	λ_m	a [kPa]	b	RMSE [kPa]
HT01	68	M	4,965	130,9	1,10	35,91	12,57	14,08	15,52	14,91	67,18	48,42	0,99	1,66	0,098	3,50	0,300
HT02	54	M	4,927	129,8	1,10	38,20	16,40	13,20	16,44	13,20	51,11	52,44	0,86	1,62	0,137	3,58	0,213
HT03†	64	F	4,869	129,5	1,10	36,01	14,55	13,96	18,35	14,48	62,66	47,02	1,00	1,74	0,113	3,62	0,419
HT04	58	F	4,574	131,2	1,09	22,42	8,57	13,03	6,43	13,36	46,38	38,53	0,81	1,68	0,099	3,51	0,346
HT05†	62	F	4,779	130,1	1,10	48,19	35,06	13,23	43,19	13,03	53,24	52,86	0,91	1,63	0,033	3,56	0,218
HT06	66	F	5,062	129,1	1,10	39,78	37,75	13,35	60,89	13,45	56,01	46,44	0,91	1,64	0,004	3,54	0,349
HT07	54	F	4,298	129,6	1,11	50,45	25,51	13,32	39,43	13,24	53,47	64,91	0,93	1,66	0,078	3,72	0,341
HT08	63	F	4,436	129,0	1,10	34,44	30,62	13,29	60,33	13,21	54,67	44,94	0,93	1,65	0,084	3,56	0,518
HT09	68	M	5,090	128,2	1,12	51,48	33,77	13,17	44,26	13,49	51,83	66,41	0,84	1,62	0,023	3,55	0,277
HT10	55	F	4,300	129,0	1,10	37,04	12,32	14,13	15,04	14,93	65,14	48,19	1,04	1,71	0,114	3,47	0,270
HT11	69	M	5,545	131,2	1,08	29,64	9,76	13,23	9,10	15,12	48,16	37,83	0,83	1,74	0,115	3,59	0,263
HT12	54	M	5,426	131,8	1,09	32,23	17,81	13,35	14,03	12,15	53,73	44,93	0,92	1,65	0,090	3,58	0,185
HT13†	61	M	5,169	128,4	1,11	30,45	15,87	13,08	23,03	13,84	47,86	52,58	0,75	1,61	0,009	3,49	0,315
HT14†	60	M	4,640	129,9	1,10	30,43	13,74	13,45	18,01	13,35	54,90	42,43	0,91	1,66	0,088	3,52	0,158
HT15	53	M	4,649	130,4	1,10	40,83	28,98	13,36	31,16	12,62	54,44	49,57	0,93	1,65	0,085	3,63	0,311
HT16	54	M	4,713	129,6	1,10	45,26	29,27	14,00	33,48	14,82	67,16	67,68	1,02	1,65	0,039	3,52	0,194
HT17	53	M	5,043	130,0	1,10	37,25	39,18	13,24	66,29	13,15	54,90	48,26	0,91	1,64	0,099	3,60	0,252
HT18	52	M	4,922	129,7	1,10	29,28	10,50	13,21	19,76	13,39	50,96	46,42	0,85	1,63	0,094	3,56	0,200
HT19†	57	F	4,270	130,3	1,10	33,49	14,47	13,22	17,35	13,27	53,18	46,18	0,90	1,64	0,097	3,55	0,228
HT20	61	F	5,143	129,2	1,10	40,09	15,72	14,09	16,78	14,83	65,17	53,40	1,04	1,70	0,100	3,47	0,265
HT21	57	F	4,881	129,9	1,10	35,31	14,57	13,26	15,58	13,30	52,07	48,97	0,87	1,63	0,094	3,57	0,442
HT22	44	F	4,170	131,0	1,10	55,25	35,78	13,23	19,51	12,55	52,36	59,58	0,93	1,61	0,097	3,61	0,335
HT23	51	M	4,827	130,6	1,08	30,77	12,80	13,60	41,10	14,20	49,79	41,06	0,87	1,90	0,094	3,56	0,337
HT24†	65	M	4,565	129,6	1,10	38,91	25,76	13,20	35,01	13,20	51,94	50,28	0,87	1,62	0,043	3,58	0,212
HT25	67	F	4,718	129,2	1,10	40,29	31,78	13,75	60,40	14,29	63,50	46,06	1,03	1,72	0,025	3,46	0,412

C. Glosario

Términos técnicos usados en el informe, en orden alfabético. La columna de la derecha indica dónde se desarrollan o una referencia que los explica en detalle.

Término	Definición	Dónde / referencia
Adam	Algoritmo de entrenamiento de redes neuronales: una variante del descenso por gradiente que adapta el tamaño del paso de cada peso.	Kingma y Ba (2015)
BFGS / L-BFGS-B	Métodos de optimización que usan el gradiente de la función (aquí aproximado por diferencias finitas) para elegir la dirección de descenso.	Nocedal y Wright (2006)
Diferencias finitas	Aproximación numérica de una derivada: $[J(k+h) - J(k)]/h$ con h pequeño. Falla si la función tiene quiebres u ondulaciones.	Nocedal y Wright (2006)
Evolución diferencial	Método de optimización global sin derivadas. Mantiene una población de juegos de nudos repartida por todo el rango y la mejora generación tras generación (mutación, cruza y selección). Aquí es la búsqueda principal de los nudos.	Secc. 2.5; Storn y Price (1997); Price et al. (2005)
C_{LAM}	Número de láminas con que la curva más exigente del espacio de trabajo usa cada material. Fija la rigidez de una lámina: es una elección de unidades.	Secc. de pendientes
cond(A)	Número de condición: cociente entre el mayor y el menor valor singular de la matriz de bases normalizada. Si es grande, pequeños errores en la curva producen grandes cambios en las láminas.	Paso 4; Trefethen y Bau (1997)
Crosstalk	Láminas que la red asigna a un material que no está presente en la curva ("fuga" de un material a otro). Se penaliza en la pérdida.	Secc. de la red
CVaR 99 %	Promedio de los errores del 1 % de curvas peor ajustadas. Es la medida de la cola de errores que minimiza el método minimax.	Paso 3; Rockafellar y Uryasev (2000)
Curvas límite y_1, y_2	Curvas inferior y superior que definen la franja del espacio de trabajo.	Secc. 1
Ecuaciones normales	$A^{\mathsf{T}}Ac = A^{\mathsf{T}}y$: la condición que cumple la solución de MCO.	Lawson y Hanson (1974)
Época	Una pasada completa del entrenamiento por todas las curvas de entrenamiento.	Goodfellow et al. (2016)
Error punto a punto e	Mayor diferencia, en valor absoluto, entre la curva y su ajuste en los puntos de la grilla, dividida por el rango de la curva (en %). El criterio de diseño exige $e \leq 3$ %.	Paso 1
Espacio de trabajo	Conjunto de curvas generadas con la ley de Masson que quedan entre y_1 e y_2.	Secc. 1
Estandarizar	Restar la media y dividir por el desvío estándar, para que todas las variables tengan escala comparable.	
Exceso	Cuánto peor ajusta la red que el óptimo MCO: NRMSE de la red / NRMSE óptimo − 1.	Resultados
Familias de bases / fisiológicas	Grupos de curvas del dataset: poligonales armadas con las bases, o curvas con forma de arteria generadas con leyes constitutivas o tomadas de pacientes.	Secc. del dataset
Grilla	Los 999 valores equiespaciados de λ entre 1,02 y 1,16 en los que se evalúan todas las curvas (paso $\approx$ 0,00014).	Secc. 1
Hipercubo latino	Forma de sortear una población: se divide el rango de cada variable en tantas franjas como miembros y se pone exactamente uno en cada franja, para cubrir el rango de forma pareja.	Secc. 2.5
Learning rate	Tasa de aprendizaje: tamaño de cada corrección de los pesos de la red durante el entrenamiento.	Goodfellow et al. (2016)

Término	Definición	Dónde / referencia
Ley de Laplace	En un tubo de pared delgada, la tensión de membrana es igual a la presión por el radio.	
Línea truncada	Función $S\,\max(0, \lambda - k)$: vale cero hasta el nudo k y crece con pendiente S desde allí. Representa una lámina de un material.	Secc. 1
Lote	Grupo de curvas (aquí 64) que la red procesa antes de cada corrección de sus pesos.	Goodfellow et al. (2016)
MCO	Mínimos cuadrados ordinarios: se eligen las láminas que minimizan la suma de los cuadrados de las diferencias entre la curva y el ajuste. Tiene solución exacta, $c = A^{+}y$.	Secc. 2; Lawson y Hanson (1974)
Mediana / percentil	La mediana deja la mitad de los casos por debajo; el percentil p deja el p % por debajo.	
Minimax	Criterio que elige los nudos para minimizar los errores de las curvas *peor* ajustadas, no el promedio.	Secc. 2
Mínimo local	Punto donde la función es menor que en sus alrededores, pero no necesariamente el menor de todos (mínimo global). Un método local termina en el mínimo local más cercano a su punto de partida.	Secc. 2.6
Nelder–Mead	Método de optimización numérica local sin derivadas (*simplex descendente*). Aquí refina el mejor juego de nudos hallado por la evolución diferencial. No es un método de mínimos cuadrados.	Secc. 2.5; Nelder y Mead (1965); Press et al. (2007)
NNLS	Mínimos cuadrados no negativos: MCO con la restricción de que todos los coeficientes sean ≥ 0.	Lawson y Hanson (1974)
Normalización de capa	Operación de la red que reescala las salidas de cada capa a media 0 y desvío 1, y estabiliza el entrenamiento.	Ba et al. (2016)
NRMSE	Raíz del error cuadrático medio dividida por el rango de la curva (%). Mide el error típico a lo largo de la curva.	Paso 1
Nudo (*knot*)	Valor de λ en el que una lámina empieza a aportar presión: es el quiebre de la línea truncada.	Secc. 2
Óptimo local / global	Un óptimo local es el mejor punto de su entorno; el global, el mejor de todo el rango permitido.	
Powell (método de)	Método local sin derivadas que minimiza a lo largo de direcciones sucesivas.	Powell (1964)
Parada temprana	Detener el entrenamiento cuando la pérdida de validación deja de mejorar y quedarse con los mejores pesos.	Goodfellow et al. (2016)
`PEND_MAX`	Pendiente máxima que exige el espacio de trabajo a cada capa; dividida por C_{LAM} da la pendiente de una lámina.	Secc. de pendientes
Pseudoinversa A^{+}	$(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}$ cuando las columnas de A son independientes. Da la solución de MCO.	Trefethen y Bau (1997)
Pulido	Paso MCO aplicado a una curva para obtener el óptimo exacto, en lugar de usar la salida de la red.	Secc. de la red
R^2	Coeficiente de determinación, $1 - \sum r_i^2 / \sum (y_i - \bar{y})^2$. Vale 1 para un ajuste perfecto.	Resultados
Red neuronal densa	Función con muchos parámetros, organizada en capas de neuronas, que transforma la entrada en la salida. Se ajusta (entrena) con datos.	Goodfellow et al. (2016)
ReLU	Función no lineal $\max(0, x)$ que aplica cada neurona.	Goodfellow et al. (2016)
Semilla	Número que inicializa el generador de números aleatorios. Con la misma semilla, los sorteos se repiten, y el resultado es reproducible.	
Simplex	Figura de $N + 1$ vértices en N dimensiones (triángulo en 2D, tetraedro en 3D) con la que trabaja Nelder–Mead.	Secc. 2
Sobreajuste	Situación en que la red memoriza las curvas de entrenamiento y empeora en curvas nuevas.	Goodfellow et al. (2016)

Término	Definición	Dónde / referencia
Test / validación / entrenamiento	Conjuntos disjuntos de curvas: ▪ entrenamiento: para ajustar los pesos; ▪ validación: para controlar el entrenamiento; ▪ test: solo para la evaluación final.	Secc. del dataset
Valores singulares (SVD)	Factores de estiramiento de una matriz en sus direcciones principales, $A = U\Sigma V^{\mathsf{T}}$.	Trefethen y Bau (1997)

Referencias

Ba, J. L., Kiros, J. R., Hinton, G. E. (2016). Layer normalization. *arXiv:1607.06450*.

Fung, Y. C. (1993). *Biomechanics: Mechanical Properties of Living Tissues* (2.ª ed.). Springer, Nueva York.

Golub, G. H., Pereyra, V. (1973). The differentiation of pseudo-inverses and nonlinear least squares problems whose variables separate. *SIAM Journal on Numerical Analysis*, 10(2), 413–432.

Goodfellow, I., Bengio, Y., Courville, A. (2016). *Deep Learning*. MIT Press.

Holzapfel, G. A., Gasser, T. C., Ogden, R. W. (2000). A new constitutive framework for arterial wall mechanics and a comparative study of material models. *Journal of Elasticity*, 61, 1–48.

Hooke, R., Jeeves, T. A. (1961). "Direct search" solution of numerical and statistical problems. *Journal of the ACM*, 8(2), 212–229.

Jupp, D. L. B. (1978). Approximation to data by splines with free knots. *SIAM Journal on Numerical Analysis*, 15(2), 328–343.

Kingma, D. P., Ba, J. (2015). Adam: A method for stochastic optimization. *3rd International Conference on Learning Representations (ICLR)*. arXiv:1412.6980.

Lagarias, J. C., Reeds, J. A., Wright, M. H., Wright, P. E. (1998). Convergence properties of the Nelder–Mead simplex method in low dimensions. *SIAM Journal on Optimization*, 9(1), 112–147.

Lawson, C. L., Hanson, R. J. (1974). *Solving Least Squares Problems*. Prentice-Hall (reeditado por SIAM, 1995).

Masson, I., Beaussier, H., Boutouyrie, P., Laurent, S., Humphrey, J. D., Zidi, M. (2011). Carotid artery mechanical properties and stresses quantified using in vivo data from normotensive and hypertensive humans. *Biomechanics and Modeling in Mechanobiology*, 10, 867–882.

McKinnon, K. I. M. (1998). Convergence of the Nelder–Mead simplex method to a nonstationary point. *SIAM Journal on Optimization*, 9(1), 148–158.

Nelder, J. A., Mead, R. (1965). A simplex method for function minimization. *The Computer Journal*, 7(4), 308–313.

Nocedal, J., Wright, S. J. (2006). *Numerical Optimization* (2.ª ed.). Springer.

Powell, M. J. D. (1964). An efficient method for finding the minimum of a function of several variables without calculating derivatives. *The Computer Journal*, 7(2), 155–162.

Price, K. V., Storn, R. M., Lampinen, J. A. (2005). *Differential Evolution: A Practical Approach to Global Optimization*. Springer.

Press, W. H., Teukolsky, S. A., Vetterling, W. T., Flannery, B. P. (2007). *Numerical Recipes: The Art of Scientific Computing* (3.ª ed.). Cambridge University Press. Sec. 10.5: *Downhill simplex method in multidimensions*.

Rockafellar, R. T., Uryasev, S. (2000). Optimization of conditional value-at-risk. *Journal of Risk*, 2(3), 21–41.

Storn, R., Price, K. (1997). Differential evolution: a simple and efficient heuristic for global optimization over continuous spaces. *Journal of Global Optimization*, 11, 341–359.

Trefethen, L. N., Bau, D. (1997). *Numerical Linear Algebra*. SIAM.

Virtanen, P., Gommers, R., Oliphant, T. E., et al. (2020). SciPy 1.0: fundamental algorithms for scientific computing in Python. *Nature Methods*, 17, 261–272.