Diseño de injertos vasculares biomiméticos con láminas de materiales mediante una red neuronal: método minimax de las bases y validación con 41 carótidas humanas

Pablo

13 de octubre de 2026

Resumen

Se presenta un método para diseñar injertos vasculares multicapa a partir de la curva presión–diámetro de una arteria. Cada función base es la curva de *una lámina* de un material, idealizada como una línea truncada $A_j(\lambda) = S_j\,\max(0, \lambda - k_j)$. Cada coeficiente es el *número de láminas* de ese material, y se obtiene por mínimos cuadrados ordinarios (MCO). Una red neuronal aprende a dar esas láminas directamente a partir de la curva. El criterio de diseño es un error punto a punto de a lo sumo el 3 % del rango de la curva.

Espacio de trabajo. Las curvas objetivo son las presiones de pared de 41 carótidas humanas (Masson et al., 2011), en $\lambda_\theta \in [1{,}02;\ 1{,}16]$, el rango respaldado por las mediciones. El espacio de trabajo es la franja entre dos curvas límite que contienen a los 41 sujetos y llegan hasta 60 kPa.

Bases. Los nudos k_j se eligen con un método minimax: se minimiza la media del peor 1 % de los errores punto a punto del MCO (CVaR 99 %) con la restricción $\mathrm{cond}(A) < 25$, usando Nelder–Mead. Con 5 materiales, el MCO cumple el criterio en las 22 500 curvas del espacio de trabajo (máximo 2,07 %) y en los 41 sujetos. Con 4 materiales no alcanza; con 6 mejora poco, con $\mathrm{cond}(A)$ en el límite.

Red neuronal. Entrenada con 50 000 curvas sintéticas, la red sola cumple el 3 % en los 41 sujetos y queda a +1,48 % del NRMSE óptimo, con mediana de +0,1 % en los sujetos de test. En las familias fisiológicas del dataset de test (curvas con forma de arteria, generadas con leyes constitutivas o tomadas de los pacientes) el exceso queda entre +0,3 y +1,1 %. En una ley constitutiva nunca vista (tipo Fung) es de +4,2 %. Reproduce láminas aisladas con un crosstalk de 0,0024 láminas, y su diseño para la curva media de los hipertensos coincide con el óptimo en 0,02 láminas.

Palabras clave— Mínimos cuadrados ordinarios, Líneas truncadas, Aproximación minimax, CVaR, Número de condición, Nelder–Mead, Red neuronal, Injerto vascular biomimético, Curva presión–diámetro.

Índice

1. Planteo del problema **2**
- 1.1. Variable objetivo y dominio . . . 2
- 1.2. Curvas límite y espacio de trabajo . . . 2
- 1.3. Dominio de validez . . . 3
- 1.4. Bases: una lámina de cada material . . . 4

2. El método minimax para elegir los nudos **4**
- 2.1. El problema: qué es un nudo y por qué importa . . . 4
- 2.2. Paso 1: el error de *una* curva . . . 5
- 2.3. Paso 2: de una curva a la población . . . 5

2.4. Paso 3: por qué la media del peor 1 % y no el máximo 6
2.5. Paso 4: el número de condición, cond(A) 7
2.6. La función objetivo completa 8
2.7. El optimizador: Nelder–Mead 9
2.8. Resultados: 4, 5 o 6 bases 10
2.9. Cómo se usa en el cuaderno 10

3. Pendientes máximas y escala de las láminas **11**

4. Dataset sintético y red neuronal **12**
4.1. Dataset 12
4.2. Red y entrenamiento 13

5. Resultados de la red **14**
5.1. Entrenamiento 14
5.2. Los 41 sujetos y las curvas medias 15
5.3. Test por familia 15
5.4. Generalización a una ley nunca vista y control de clase 16
5.5. Reproducción de láminas aisladas 17

6. Diseño: la curva media de los hipertensos **17**

7. Conclusiones **18**

A. El cuaderno **18**

1. Planteo del problema

1.1. Variable objetivo y dominio

La curva objetivo es la presión transmural de pared en función del estiramiento circunferencial en el radio medio, $\lambda_\theta = r_m/R_{ref}$, proporcional al diámetro:

$$P_{pared}(\lambda_\theta) = P_i - P_a = \int_{r_i}^{r_m} \frac{\sigma_{\theta\theta} - \sigma_{rr}}{r}\, dr.$$

Se calcula con el modelo constitutivo y los parámetros publicados de 41 sujetos (16 normotensos y 25 hipertensos tratados; Masson et al. 2011): elastina neo-Hookeana, cuatro familias de fibras de colágeno y tono muscular activo, con espesor $h = 0{,}6\,\text{mm}$.

El dominio es $\lambda_\theta \in [1{,}02;\ 1{,}16]$, discretizado en 999 puntos, y en él los 41 sujetos tienen $P_{pared} > 0$. Se reservan 10 sujetos para test (NT02, NT08, NT10, NT11, HT03, HT05, HT13, HT14, HT19, HT24). No participan ni en la elección de las bases ni en el generador de datos.

1.2. Curvas límite y espacio de trabajo

El *espacio de trabajo* son las curvas generadas con la ley de Masson que quedan entre dos curvas límite, $y_1(\lambda) \le y(\lambda) \le y_2(\lambda)$, en todo el dominio. Las curvas límite se construyen a partir de los sujetos extremos de la población:

$$y_1(\lambda) = P_{NT08}(\lambda) - P_{NT08}(1{,}02) \qquad \text{(la más distensible, desplazada a 0 en } \lambda = 1{,}02),$$
$$y_2(\lambda) = P_{HT09}(\lambda) + a\left(e^{\,b\,E^2} - 1\right), \qquad E = \text{máx}\Big(0,\ (\lambda/1{,}10)^2 - 1\Big).$$

y_2 coincide con la del sujeto más rígido (HT09) hasta $\lambda = 1{,}10$. Desde allí suma un término con la forma exponencial del colágeno circunferencial de Masson, con $b = c_2^{circ}$ de HT09 (13,49) y $a = 80{,}2\,\text{kPa}$, elegido para que $y_2(1{,}16) = 60\,\text{kPa}$.

Los 41 sujetos quedan dentro de la franja (Fig. 1). El espacio de trabajo se genera mezclando y perturbando los parámetros de los 31 sujetos de entrenamiento (Sección 4). Tiene 22 500 curvas, con presiones en $\lambda = 1{,}16$ entre 10,0 kPa (percentil 1) y 60,0 kPa, y mediana de 25,9 kPa.

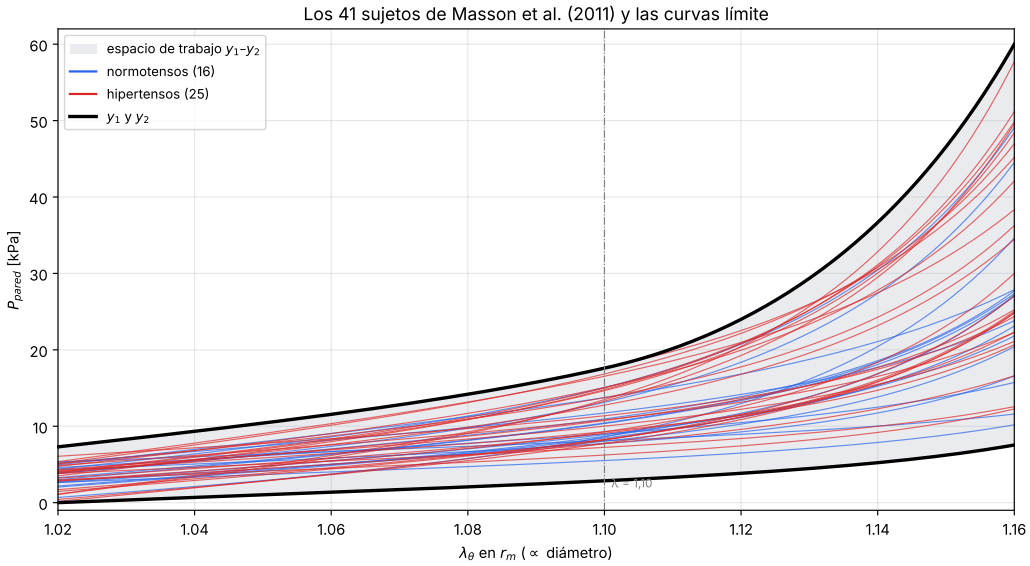


Figura 1: Presión de pared de los 41 sujetos de Masson et al. (2011) y curvas límite y_1, y_2 del espacio de trabajo.

1.3. Dominio de validez

El modelo constitutivo de cada sujeto se ajustó en el rango de λ medido durante su ciclo cardíaco: aproximadamente 1,085–1,122 para HT09 y hasta $\approx 1{,}16$ en los más distensibles. Fuera de ese rango la ley es una extrapolación sin datos:

- por debajo de $\lambda \approx 0{,}95$ el término activo vuelve negativa la presión;
- por encima de 1,16 el colágeno crece sin límite.

Por eso **el ajuste se hace solo en** [1,02; 1,16]. La extrapolación del injerto (Fig. 2) se muestra solo como información.

Más allá de 1,16 el injerto es lineal, y en $\lambda = 1{,}20$ da la mitad de la presión que predice la ley. Si se quisiera un tope de dilatación ante sobrepresiones, la alternativa que no depende de extrapolar la ley es un material "freno" con nudo cerca de 1,16. Su número de láminas se fijaría con un criterio de seguridad explícito.

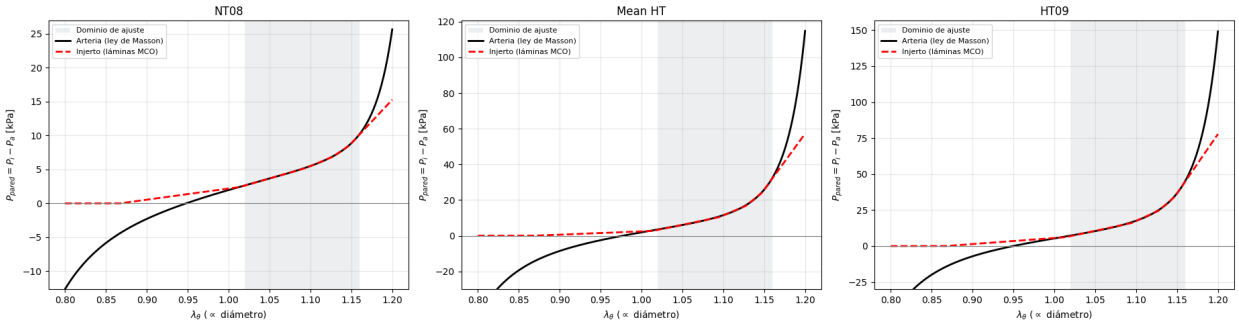


Figura 2: Injerto (láminas MCO ajustadas en [1,02; 1,16], sombreado) frente a la ley de Masson fuera del dominio de ajuste, para NT08, la media de los hipertensos y HT09.

1.4. Bases: una lámina de cada material

Cada base es la curva de presión de *una lámina* del material j:

$$A_j(\lambda) = S_j \ \text{máx}(0, \lambda - k_j), \qquad j = 1, \ldots, N.$$

La lámina no aporta presión hasta que sus fibras se tensan ($\lambda = k_j$, el *nudo*, *knot* en inglés). Desde ahí aporta presión proporcional al estiramiento adicional, con pendiente S_j. El injerto es $y \approx \sum_j c_j A_j$, donde c_j es el número de láminas del material j, un número real porque el espesor puede variar en forma continua. Los nudos se eligen con el método de la Sección 2, y las pendientes como se describe en la Sección 3.

2. El método minimax para elegir los nudos

Esta sección explica, desde cero y paso a paso, cómo se eligen los nudos $k_1, \ldots, k_N$ de las bases. Es lo que hace la Celda 3 del cuaderno cuando hace falta.

2.1. El problema: qué es un nudo y por qué importa

Cada material se representa con una *línea truncada*:

$$A_j(\lambda) = S_j \ \text{máx}(0, \ \lambda - k_j).$$

Vale cero mientras $\lambda < k_j$: las fibras de esa lámina todavía están flojas. A partir de $\lambda = k_j$ (el **nudo**, *knot* en inglés) crece con pendiente S_j. La curva del injerto es la suma de las láminas:

$$P_{injerto}(\lambda) = \sum_{j=1}^{N} c_j \, A_j(\lambda),$$

que es una *poligonal*: una sucesión de tramos rectos que se quiebran en cada nudo. En cada quiebre la pendiente aumenta, porque entra en carga un material nuevo.

Dada una curva arterial $y(\lambda)$, el número de láminas $c = (c_1, \ldots, c_N)$ se obtiene por mínimos cuadrados ordinarios:

$$c = A^{+} y = \arg\min_{c} \ \sum_{i=1}^{999} \big(y(\lambda_i) - (Ac)(\lambda_i)\big)^2,$$

donde A es la matriz de $999 \times N$ cuyas columnas son las bases evaluadas en la grilla. **El MCO elige las láminas; los nudos los elegimos antes, una sola vez, para todas las curvas.** Eso es lo que resuelve esta sección.

¿Por qué importa dónde están los nudos? Una poligonal solo puede doblarse donde tiene quiebres. La curva J arterial es suave y se curva cada vez más hacia λ alto. Si los quiebres están mal ubicados (por ejemplo, equiespaciados), la poligonal no puede seguir la curvatura del final. La Fig. 3 lo muestra con la curva media de los hipertensos (Mean HT):

- **Con los nudos minimax**, el error máximo es 1,31 % del rango.
- **Con 5 nudos equiespaciados** es 7,93 %. Sobre las 22 500 curvas del espacio de trabajo, el peor 1 % pasa de 1,74 % a 11,67 %, y solo el 0,21 % de las curvas cumple el 3 %.

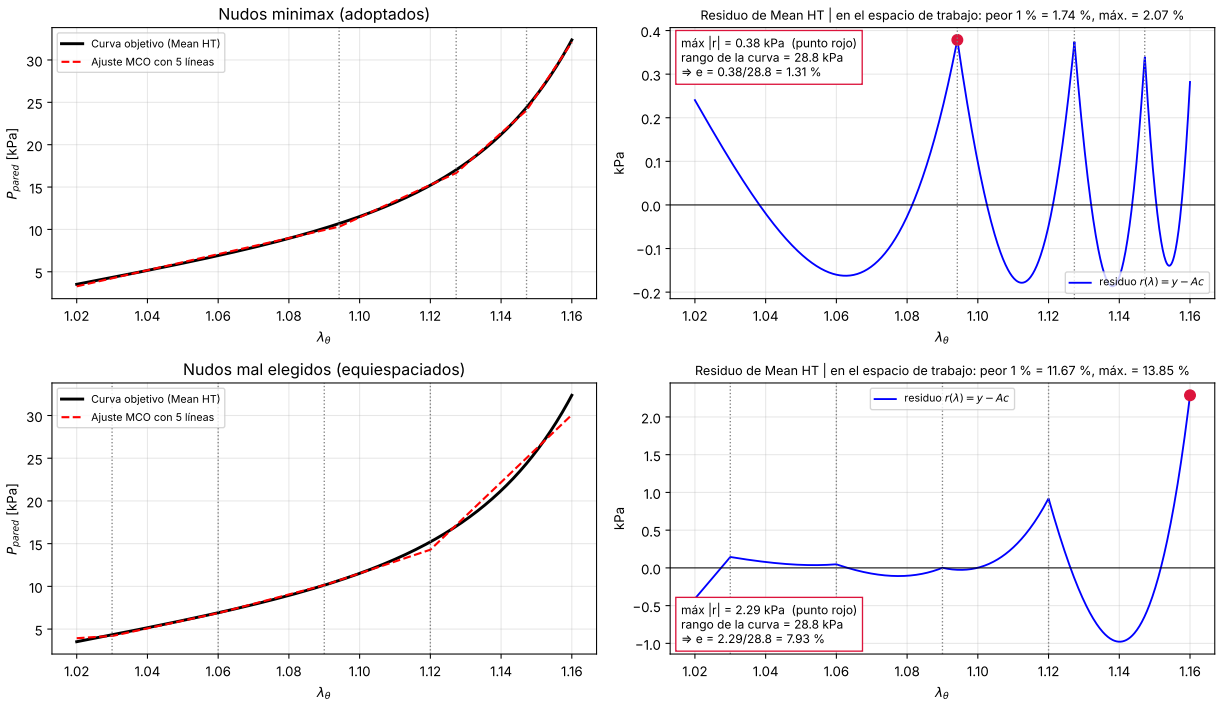


Figura 3: La misma curva (Mean HT) ajustada con 5 líneas truncadas por MCO, con dos juegos de nudos (líneas punteadas verticales). Arriba, los nudos minimax adoptados; abajo, nudos equiespaciados. A la derecha, el residuo y su máximo (punto rojo). Con los mismos 5 materiales, el error cambia por un factor 6 según dónde se quiebre la poligonal.

2.2. Paso 1: el error de *una* curva

Para unos nudos k dados y una curva y:

1. Se calculan las láminas por MCO: $c = A^{+}y$.
2. Se calcula el residuo en cada punto: $r(\lambda_i) = y(\lambda_i) - (Ac)(\lambda_i)$, en kPa.
3. Se toma el mayor residuo en valor absoluto y se lo divide por el rango de la curva:

$$e(y;k) = \frac{\max_i |r(\lambda_i)|}{\max_i y(\lambda_i) - \min_i y(\lambda_i)} \times 100 \quad [\,\%].$$

Ejemplo numérico (Fig. 3, arriba). El residuo máximo de Mean HT es 0,38 kPa, en $\lambda \approx 1{,}094$. La curva va de 3,5 a 32,3 kPa, un rango de 28,8 kPa. Entonces $e = 0{,}38/28{,}8 = 1{,}31$ %.

Este es exactamente el **criterio de diseño**: una curva cumple si $e \leq 3$ %. Se divide por el rango para que el criterio sea igual de exigente con una arteria blanda (rango de 10 kPa) que con una rígida (rango de 60 kPa). Medido en kPa, el ajuste quedaría dominado por las curvas rígidas.

2.3. Paso 2: de una curva a la población

Los nudos no se eligen para una arteria, sino para *todas* las del espacio de trabajo. Fijados los nudos, cada curva y_i tiene su error $e_i = e(y_i;k)$. Con 22 500 curvas hay 22 500 errores. La Fig. 4 muestra su histograma para los nudos adoptados:

- la mayoría de las curvas tiene error cercano a 1,2 % (media 1,22 %, mediana 1,23 %);
- el peor 1 % (225 curvas, en rojo) está entre 1,66 % y 2,07 %;
- ninguna curva supera el 3 %.

¿Qué número resume este histograma para decidir si unos nudos son mejores que otros?

- **La media no sirve**: unos nudos podrían ajustar muy bien la mayoría de las curvas y muy mal unas pocas. Esas pocas no cumplirían el criterio, y la media no lo mostraría.
- Como el criterio es "*toda* curva con $e \leq 3\ \%$", lo que importa es la **cola derecha** del histograma: las peores curvas. De ahí el nombre *minimax*: **mini**mizar el **máx**imo error.

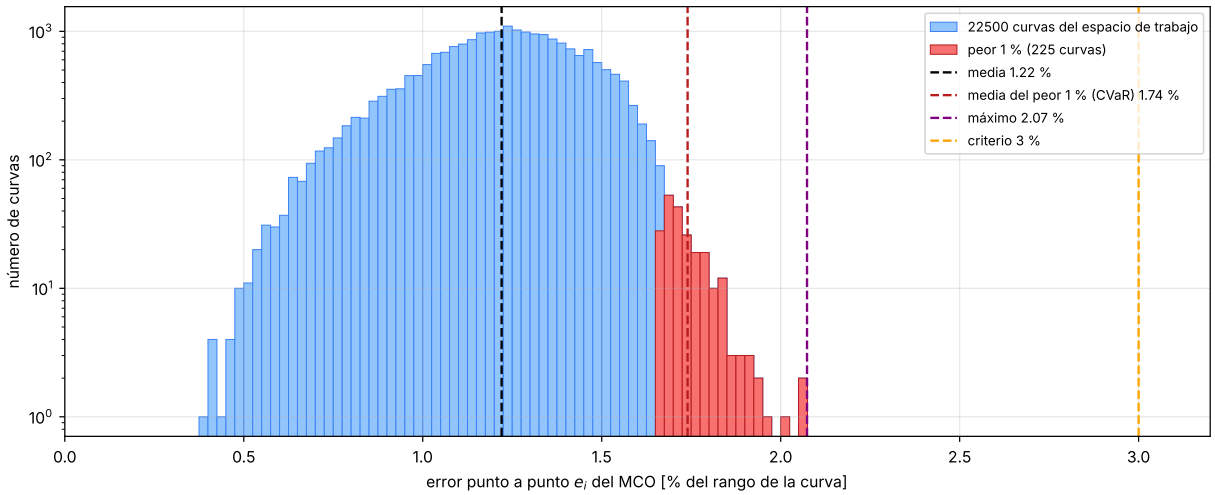


Figura 4: Error punto a punto del MCO con los nudos adoptados en las 22 500 curvas del espacio de trabajo (escala vertical logarítmica). En rojo, el peor 1 %. El método minimax actúa sobre esa cola.

2.4. Paso 3: por qué la media del peor 1 % y no el máximo

El minimax "puro" minimizaría $\max_i e_i$, el error de la peor curva. En su lugar se usa la **media del peor 1 %**, que en estadística se llama CVaR al 99 % (*conditional value at risk*):

$$\mathrm{CVaR}_{99}(k) = \frac{1}{m} \sum_{\text{las } m \text{ curvas de mayor } e_i} e_i, \qquad m = \lfloor n/100 \rfloor .$$

Ejemplo. En el conjunto de optimización hay $n = 2532$ curvas. Se ordenan sus errores de mayor a menor y se promedian los primeros $m = 25$.

La Fig. 5 muestra la diferencia moviendo un solo nudo (k_4) y dejando fijos los otros cuatro:

1. **El máximo lo decide una sola curva.** En el 53 % de las posiciones de k_4 probadas, la peor curva es y_2 (puntos violeta). Minimizar el máximo es, en la práctica, ajustar los nudos a *una* curva. El óptimo del máximo cae en $k_4 = 1{,}1262$, buscando solo que y_2 mejore, aunque las demás empeoren.
2. **El máximo tiene un mínimo anguloso**, en forma de V. A cada lado manda una curva distinta, y donde se cruzan hay un pico sin derivada. Los optimizadores convergen peor en esos "valles con quiebre".
3. **El CVaR promedia las 25 peores.** Su mínimo ($k_4 = 1{,}1276$) reparte el esfuerzo entre toda la cola. Sigue siendo un criterio de peor caso: no le importan las curvas que ajustan bien.

En los dos casos el valor óptimo queda muy por debajo del 3 %. El CVaR elige nudos *robustos*, que no dependen de una curva particular.

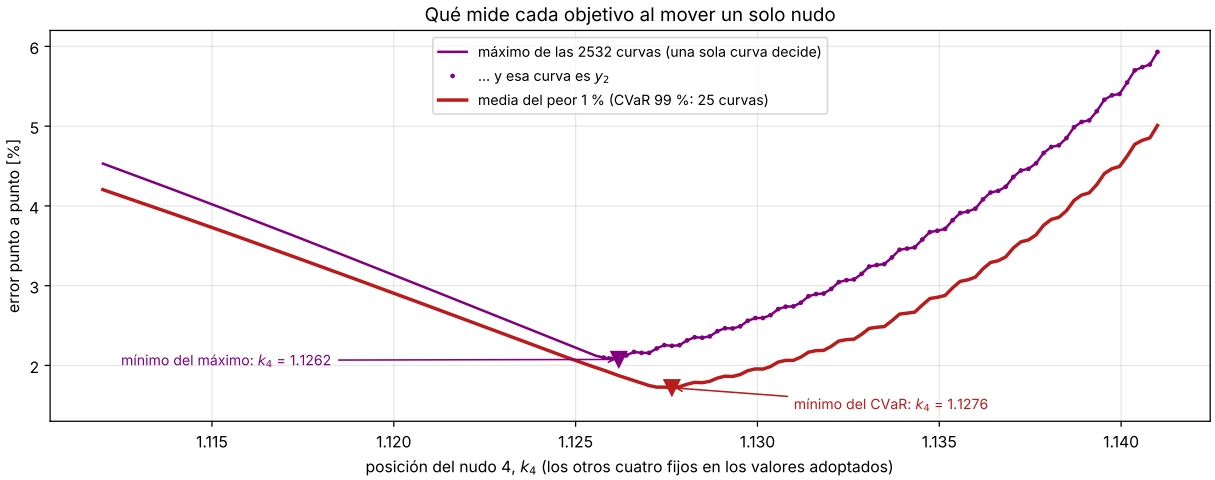


Figura 5: Al mover el nudo 4 (los demás fijos en los valores adoptados): violeta, el error de la peor curva; rojo, la media de las 25 peores (CVaR 99 %). El máximo lo define muchas veces y_2 (puntos) y tiene un mínimo anguloso; el CVaR es más suave. Las pequeñas ondulaciones vienen de la discretización: cuando k_4 cruza un punto de la grilla, el quiebre cambia de intervalo.

2.5. Paso 4: el número de condición, cond(A)

Sin ninguna restricción, el optimizador tendería a *juntar* nudos en la zona de mayor curvatura, cerca de 1,16, porque más quiebres juntos siguen mejor la curva. Esto tiene un costo.

Qué mide cond(A). Se normaliza cada columna de A para que su máximo valga 1 y se calculan sus valores singulares $s_1 \geq \cdots \geq s_N$. Entonces

$$\text{cond}(A) = s_1/s_N.$$

Si dos columnas se parecen mucho (dos nudos muy próximos dan dos rampas casi iguales), una combinación de ellas casi se anula, s_N se hace chico y cond(A) crece. La normalización hace que cond(A) dependa solo de los nudos, no de las pendientes ni de C_{LAM}.

Por qué importa. El MCO resuelve $c = A^{+}y$. Un error δy en la curva (ruido de medición, o la diferencia entre la arteria real y el modelo) produce un error en las láminas acotado por

$$\frac{\|\delta c\|}{\|c\|} \lesssim \text{cond}(A)\, \frac{\|\delta y\|}{\|y\|}.$$

Con cond(A) grande, ruidos chicos en la curva dan cambios grandes en las láminas: por ejemplo $+3$ láminas de un material y -3 del vecino, que casi se cancelan en la curva. Ese diseño no es confiable para fabricar. Además, a la red le cuesta aprender una función tan sensible.

La Fig. 6 lo muestra acercando k_5 a k_4:

- **cond(A):** con la separación adoptada ($k_5 - k_4 = 0{,}0199$) vale 18,5. Llega al umbral 25 con una separación de 0,0122, y con 0,0005 vale 541.
- **Láminas (panel derecho):** un ruido de 0,1 kPa en la curva produce un desvío de 0,032 láminas con los nudos adoptados, y de 0,72 láminas con los nudos casi pegados.
- **El otro extremo:** separar demasiado k_5 también empeora. El nudo del material 5 queda tan cerca de 1,16 que casi no tiene puntos donde actuar.

Cómo se impone en la optimización. Se suma una penalización:

$$\text{pen}(k) = 50 \cdot \text{máx}\,(0,\ \text{cond}(A) - (\texttt{UMBRAL_COND} - 1)).$$

Vale cero mientras cond$(A) < 24$ (con el umbral por defecto, 25). Pasado 24, cada décima de cond(A) suma 5 puntos al objetivo, mucho más que cualquier mejora posible del error, que es del

orden de 0,1 puntos. En la práctica funciona como una **restricción**: el óptimo nunca pasa de 24. El margen de una unidad garantiza que $\mathrm{cond}(A) < 25$ estrictamente, que es lo que verifica la Celda 3. Con 6 bases la restricción queda *activa*: el óptimo sin restricción juntaría más los nudos, y queda exactamente en $\mathrm{cond}(A) = 24{,}0$.

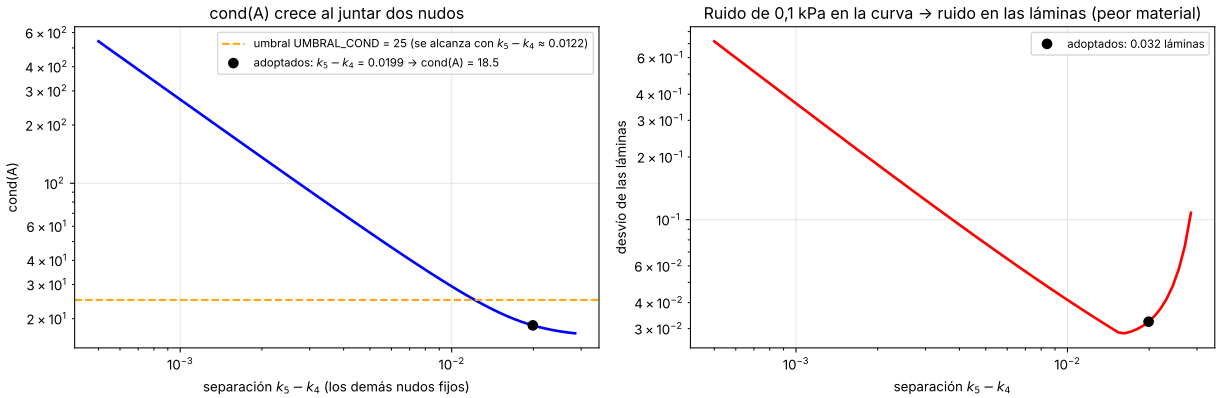


Figura 6: Izquierda: $\mathrm{cond}(A)$ al acercar el nudo 5 al 4 (escalas logarítmicas). Derecha: desvío de las láminas del peor material ante un ruido blanco de 0,1 kPa en la curva ($\sigma \, \|A_j^+\|$, con $C_{LAM} = 10$). El punto negro marca los nudos adoptados.

2.6. La función objetivo completa

Juntando los pasos, los nudos minimizan

$$J(k) = \underbrace{\mathrm{CVaR}_{99}(e_1, \ldots, e_n)}_{\text{peor 1 \%}} + \underbrace{0{,}25 \cdot \overline{\mathrm{NRMSE}}}_{\text{desempate}} + \underbrace{50 \cdot \max\left(0, \mathrm{cond}(A) - 24\right)}_{\text{restricción de cond}(A)}$$

Tabla 1: Los tres términos de J.

Término	Qué mide	Por qué ese peso
CVaR_{99}	Media de los errores punto a punto de las 25 peores curvas (%)	Es el objetivo principal: la cola del criterio de diseño. Peso 1.
$0{,}25 \cdot \overline{\mathrm{NRMSE}}$	Error cuadrático medio relativo al rango, promediado sobre todas las curvas (%)	Desempata: entre dos juegos con cola parecida, prefiere el que ajusta mejor en promedio. Es chico (el NRMSE medio ronda 0,45 %) para no competir con la cola.
$50 \cdot \max(0, \mathrm{cond} - 24)$	Exceso de $\mathrm{cond}(A)$ sobre 24	Hace de restricción dura (ver Paso 4).

Conjunto de curvas sobre el que se evalúa J ($n = 2532$):

- 2500 curvas elegidas al azar (con semilla fija) entre las 22 500 del espacio de trabajo;
- los 31 sujetos de entrenamiento, que hoy están todos dentro de la franja;
- la curva límite y_2, la más exigente.

No se usan los sujetos de test, así que la elección de nudos no los "ve". Para acelerar, en la optimización se usa un punto de cada dos de la grilla (500 puntos). El resultado final se verifica con los 999 puntos y las 22 500 curvas.

Restricciones geométricas. Además de $\mathrm{cond}(A)$:

- nudos separados al menos 0,004;
- el último a 0,004 o más de $\lambda_{max} = 1{,}16$ (si no, ese material no actúa en el dominio);

- el primero por encima de 0,6.

Si un punto las viola, $J = 1000$, un valor que el optimizador descarta.

2.7. El optimizador: Nelder–Mead

$J(k)$ no tiene derivadas útiles: cada evaluación resuelve 2532 problemas de MCO y ordena sus errores, y el máximo y el ordenamiento producen quiebres. Por eso se usa **Nelder–Mead**, un método que solo compara valores de J, sin derivadas.

Cómo funciona. Con N nudos, trabaja con un *simplex* de $N + 1$ puntos: un triángulo si $N = 2$, un tetraedro si $N = 3$. En cada iteración:

1. Ordena los vértices por su valor de J: el mejor (M), el segundo peor (S) y el peor (P).
2. Calcula el centro de todos los vértices salvo el peor, y **refleja** el peor a través de ese centro: el punto R, el "espejo" de P.
3. Si R es el mejor de todos, prueba ir el doble de lejos: **expansión** (E).
4. Si R no mejora lo suficiente, prueba un punto intermedio: **contracción** (C_e por fuera o C_i por dentro).
5. Si nada mejora, achica todo el simplex hacia el mejor vértice.
6. Reemplaza el peor vértice por el punto nuevo y repite, hasta que el simplex se achica por debajo de 10^{-5} en λ y en J.

El simplex "rueda" cuesta abajo por el paisaje de J, se estira en las direcciones buenas y se encoge al llegar al fondo.

La Fig. 7 lo muestra en dos dimensiones, moviendo solo k_3 y k_4:

- parte de un triángulo en (1,076; 1,106), donde $J = 85{,}2$;
- en 38 iteraciones (75 evaluaciones de J) llega a (1,0939; 1,1273), con $J = 1{,}83$;
- ese punto prácticamente coincide con los nudos adoptados, (1,0942; 1,1273).

En la Celda 3 se hace lo mismo en las N dimensiones a la vez.

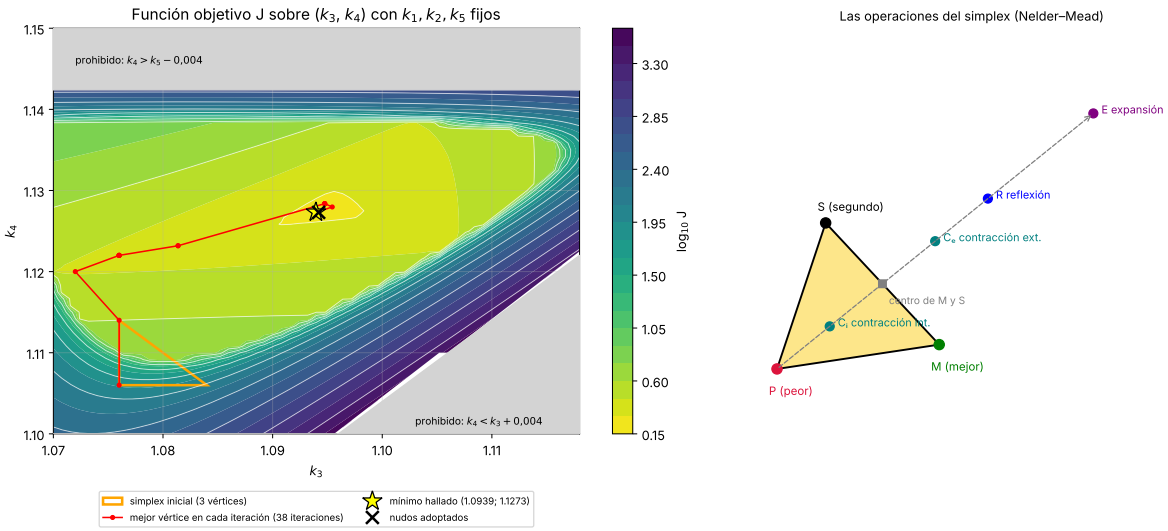


Figura 7: Izquierda: mapa de $\log_{10} J$ sobre (k_3, k_4) con k_1, k_2, k_5 fijos en los valores adoptados; en gris, las regiones prohibidas. Naranja, el simplex inicial; rojo, el mejor vértice en cada iteración; estrella, el mínimo hallado; cruz, los nudos adoptados. Derecha: las operaciones de una iteración sobre un triángulo.

Puntos de partida. Nelder–Mead encuentra un mínimo *local*, así que el punto de partida importa. La Celda 3 arranca desde dos puntos y se queda con el mejor:

1. un reparto geométrico que junta los nudos hacia λ alto, donde la J se dobla más: $k_1 = 0{,}86$ y $k_2, \ldots, k_N = 1{,}16 - 0{,}15 \cdot g$, con g de 1 a 0,1 en progresión geométrica. Para 5 bases da (0,86; 1,010; 1,090; 1,128; 1,145), ya muy cerca del óptimo;
2. los nudos que figuran en la Celda 0 para ese número de bases, si existen.

Se verificó la robustez desde 6 puntos de partida al azar para cada número de bases: los resultados difieren en menos de 0,05 puntos de error. El paisaje es plano en k_1: valores entre 0,87 y 0,91 dan el mismo error. Cada optimización tarda unos segundos.

2.8. Resultados: 4, 5 o 6 bases

Tabla 2: MCO con los nudos de referencia del cuaderno, evaluado en las 22 500 curvas del espacio de trabajo y en los 41 sujetos (999 puntos).

Bases	Nudos	cond(A)	Media	CVaR 99	Máx.	Cumplen 3 %	Sujetos	$e(y_2)$
4	0,8835; 1,0269; 1,1080; 1,1416	11,6	2,20	3,13	3,83	98,96 %	40/41	2,99
5	0,8669; 1,0135; 1,0942; 1,1273; 1,1472	18,5	1,22	1,74	2,07	100 %	41/41	2,24
6	0,8669; 1,0210; 1,0758; 1,1139; 1,1380; 1,1518	24,0	1,07	1,51	1,67	100 %	41/41	1,70

- **4 bases no alcanzan**: aun con los mejores nudos, el 1 % de las curvas queda por encima del 3 % (máximo 3,83 %), y un sujeto real tampoco cumple. La franja nueva, que llega a 60 kPa, exige más quiebres.
- **5 bases** cumplen con margen: el máximo es 2,07 %, a casi un punto del criterio. Es la configuración adoptada.
- **6 bases** bajan el máximo a 1,67 %, pero con cond(A) en el límite: el sexto quiebre solo se puede poner muy cerca de otro. La ganancia (0,4 puntos) probablemente no justifica un material más.

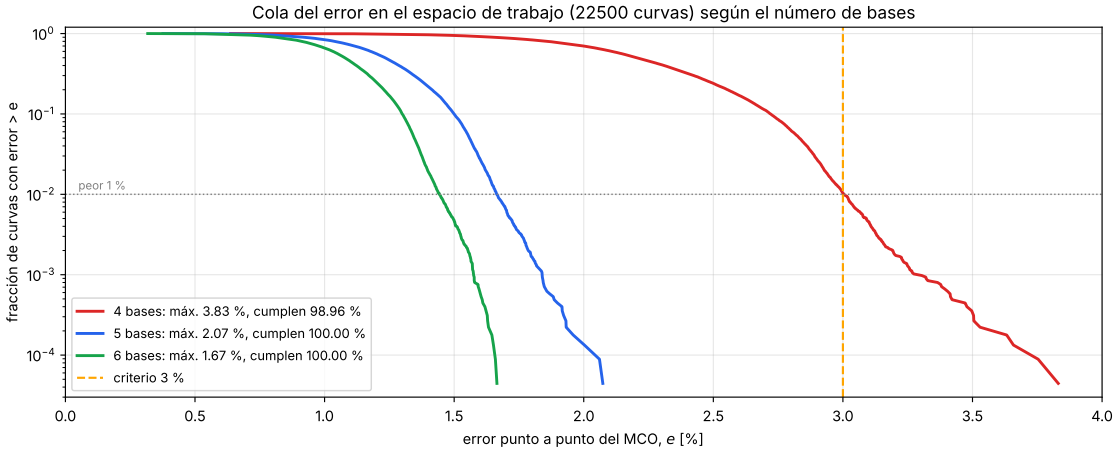


Figura 8: Fracción de curvas del espacio de trabajo con error mayor que e, para 4, 5 y 6 bases (escala logarítmica). La línea gris marca el peor 1 %; la naranja, el criterio de diseño.

2.9. Cómo se usa en el cuaderno

En la Celda 0:

- `N_BASES` (4, 5 o 6): el número de materiales. Cambiarlo requiere reentrenar.
- `NUDOS_REF`: los nudos de referencia por número de bases (los de la Tabla 2).
- `UMBRAL_COND` (25 por defecto): la cota de cond(A).

- `OPTIMIZAR_NUDOS` (`False` por defecto): `True` fuerza la re-optimización.

La Celda 3 sigue esta lógica:

1. Toma `NUDOS_REF[N_BASES]` y calcula $\mathrm{cond}(A)$.
2. Si $\mathrm{cond}(A) \geq$ `UMBRAL_COND`, si no hay nudos para ese número de bases, o si `OPTIMIZAR_NUDOS = True`, imprime "`Optimizando N nudos...`" y corre el método de esta sección.
3. Imprime la línea `NUDOS_REF[N] = [...]` para copiar en la Celda 0. Conviene copiarla: así la próxima corrida no re-optimiza y, al cargar una red entrenada (`ENTRENAR = False`), los nudos coinciden. La Celda 8 lo verifica.
4. Verifica $\mathrm{cond}(A) <$ `UMBRAL_COND`; si no se cumple, se detiene con un mensaje.
5. Calcula las pendientes máximas `PEND_MAX` con los nudos finales (Sección 3).

Ejemplo verificado: con `UMBRAL_COND = 15` y 5 bases, los nudos de referencia (cond 18,5) no cumplen. La Celda 3 los re-optimiza sola y propone (0,9479; 1,0409; 1,1009; 1,1376; 1,1560), con $\mathrm{cond}(A) < 15$.

Resumen del método en cinco líneas

1. Para unos nudos, ajustar por MCO cada curva del conjunto (2500 del espacio de trabajo, 31 sujetos de entrenamiento e y_2).
2. Medir el error de cada curva: residuo máximo dividido por su rango.
3. Promediar los errores del peor 1 % (25 curvas): eso es el CVaR.
4. Sumar 0,25× el NRMSE medio y la penalización si $\mathrm{cond}(A) > 24$: eso es J.
5. Mover los nudos con Nelder–Mead hasta que J no baje más.

3. Pendientes máximas y escala de las láminas

Una vez fijados los nudos, la pendiente de cada lámina se elige para que la curva más exigente del espacio de trabajo use exactamente C_{LAM} láminas de cada material. Con las líneas sin escalar $G_j(\lambda) = \mathrm{máx}(0, \lambda - k_j)$:

$$\texttt{PEND_MAX}_j = \mathrm{máx}\Big\{ \max_{y \in \text{espacio}} (G^{+}y)_j,\ \max_{\text{sujetos en la franja}} (G^{+}y)_j,\ (G^{+}y_2)_j \Big\},$$

y la pendiente de una lámina es $S_j = \texttt{PEND_MAX}_j / C_{LAM,j}$. Con $C_{LAM} = 10$ resultan las bases de la Tabla 3. La curva y_2 es la que fija el máximo del material 4: usa exactamente 10,0 láminas.

Tabla 3: Bases con $C_{LAM} = 10$. $K = S_j R_{ref} k_j^2$ es la rigidez de membrana de una lámina por la ley de Laplace ($R_{ref} = \Theta_0 R_m/\pi = 3{,}42\,\mathrm{mm}$, mediana poblacional); $E = K/t$ con $t = 0{,}1\,\mathrm{mm}$. Las dos últimas columnas son las láminas MCO de las curvas límite.

Material	k_j	`PEND_MAX` [kPa]	$A_j(\lambda)$ [kPa]	K [N/m]	E [MPa]	y_1	y_2
1	0,8669	47,5	$4{,}75\,\mathrm{máx}(0, \lambda - 0{,}8669)$	12,2	0,12	−0,36	9,01
2	1,0135	204,1	$20{,}41\,\mathrm{máx}(0, \lambda - 1{,}0135)$	71,7	0,72	1,79	3,65
3	1,0942	242,0	$24{,}20\,\mathrm{máx}(0, \lambda - 1{,}0942)$	99,1	0,99	0,63	8,65
4	1,1273	495,1	$49{,}51\,\mathrm{máx}(0, \lambda - 1{,}1273)$	215,3	2,15	0,65	10,00
5	1,1472	815,0	$81{,}50\,\mathrm{máx}(0, \lambda - 1{,}1472)$	367,0	3,67	0,57	5,80
$\mathrm{cond}(A) = 18{,}47$ (umbral 25). MCO: $e(y_1) = 0{,}91$ %, $e(y_2) = 2{,}24$ %.							

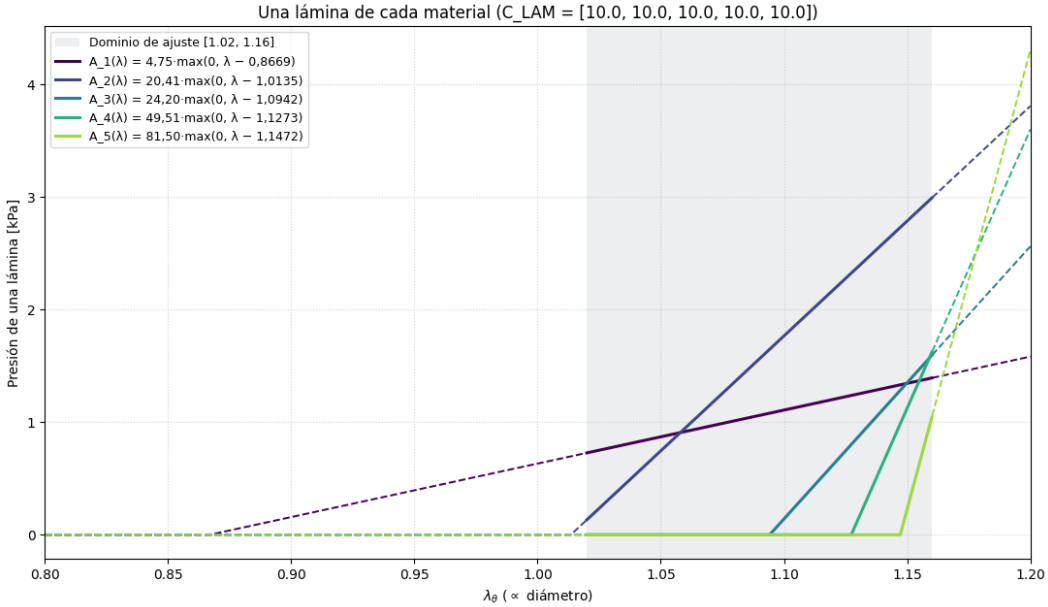


Figura 9: Una lámina de cada material ($C_{LAM} = 10$). Continua: dominio de ajuste; punteada: la misma fórmula fuera de él.

C_{LAM} es una elección de unidades. Si se cambia la escala de una base, el MCO divide su coeficiente por el mismo factor. Por eso cambiar $C_{LAM,j}$ cambia la rigidez de una lámina y, en proporción inversa, el número de láminas. El producto $c_j S_j$ (la pendiente de la capa) no cambia, y tampoco la curva, el error ni la rigidez total de cada capa.

- Se puede elegir un C_{LAM} distinto para cada material, sin reentrenar: las salidas de la red se multiplican por $C_{LAM,j}/10$.
- La Tabla 4 lo comprueba con la curva media de los hipertensos y dos elecciones de C_{LAM}.

Tabla 4: Injerto MCO para Mean HT con dos elecciones de C_{LAM}. Cambian las láminas y la rigidez de una lámina; la rigidez total de cada capa y el error máximo (0,379 kPa) son idénticos.

	$C_{LAM} = [10, 10, 10, 10, 10]$			$C_{LAM} = [8, 10, 10, 12, 15]$		
Material	Láminas	K 1 lámina	K total	Láminas	K 1 lámina	K total
1	3,83	12,2	46,7	3,06	15,3	46,7
2	3,75	71,7	269,1	3,75	71,7	269,1
3	4,01	99,1	397,0	4,01	99,1	397,0
4	3,63	215,3	780,9	4,35	179,4	780,9
5	3,15	367,0	1156,7	4,73	244,6	1156,7
Total	18,36			19,90		

4. Dataset sintético y red neuronal

4.1. Dataset

Se generan 50 000 curvas en siete familias (Tabla 5). Las familias se agrupan en dos clases, que conviene distinguir al leer los resultados:

Familias del dataset: "de bases" y "fisiológicas"

Las siete familias de curvas del dataset se agrupan en dos clases:

- **Familias de bases** (pura y combinada): curvas armadas sumando láminas de las propias bases, es decir, rampas y poligonales con quiebres en los nudos. No se parecen a una arteria. Le enseñan a la red qué hace cada material por separado y a no mezclarlos (crosstalk). Como son combinaciones exactas de las bases, su óptimo MCO es casi perfecto, y un error pequeño de la red da un exceso relativo alto.
- **Familias fisiológicas** (constitutiva, amplia, uniforme, exponencial y pacientes): curvas suaves con forma J, como las de una arteria. Salen de la ley constitutiva de Masson con parámetros derivados de los sujetos de entrenamiento (mezclados, perturbados o sorteados), de otra ley exponencial ajustada a esos sujetos, o directamente de los 31 sujetos de entrenamiento con ruido. Representan lo que la red recibe al diseñar un injerto, y por eso con ellas se juzga su desempeño.

"Fisiológica" indica que la curva proviene de un modelo de arteria, no de las bases. No significa que cada curva corresponda a una arteria medida: la familia amplia extrapola parámetros y la exponencial no se filtra por la franja y_1–y_2.

Una curva fisiológica se acepta solo si cumple todas estas condiciones:

- es positiva;
- es monótona;
- es convexa desde $\lambda = 1{,}05$ (forma J);
- no supera 1,5 veces la presión máxima de los sujetos;
- salvo en la familia exponencial, queda dentro de y_1–y_2.

Tabla 5: Familias del dataset (50 000 curvas).

Familia	%	Cómo se genera
pura	20	Un solo material, con láminas log-uniformes entre 0,1 y 10. Ruido del 0,5 %.
combinada	20	De 2 a N materiales al azar, con láminas uniformes entre 0 y 10. Se reduce la escala si supera el techo de presión. Ruido del 0,5 %.
constitutiva	20	Ley de Masson con una mezcla convexa (pesos de Dirichlet) de 2–3 sujetos, perturbación moderada de los parámetros y amplitud entre 0,85 y 1,20. Ruido del 1 %.
amplia	15	Igual, con 2–4 sujetos, perturbaciones mayores, extrapolación desde el centro de la población (γ hasta 1,35) y amplitud entre 0,65 y 1,50.
exponencial	10	Otra ley: $C + \mu E + k_1 E e^{k_2 E^2}$ con $E = \lambda^2 - 1$, media geométrica de los ajustes de 2–3 sujetos. No se filtra por la franja.
uniforme	10	Ley de Masson con cada parámetro independiente, uniforme entre el mínimo y el máximo de los sujetos de entrenamiento.
pacientes	5	Los 31 sujetos de entrenamiento, repetidos, con ruido del 1 %.

La etiqueta de cada curva es su ajuste MCO *con la misma curva ruidosa que ve la red*, expresado en láminas con $C_{LAM} = 10$. Se separan 35 000 curvas para entrenamiento, 5 000 para validación y 10 000 para test, estratificadas por familia.

4.2. Red y entrenamiento

- **Entrada:** la curva en 999 puntos, transformada como $\log(y + 5)$ y estandarizada.

- **Arquitectura:** tres capas densas de 256, 128 y 64 neuronas, cada una con ReLU y normalización de capa, y una salida lineal de 5 láminas estandarizadas. En total, 298 373 parámetros.
- **Pérdida:**

$$L = \underbrace{\mathrm{MSE}(\hat{c}_{std}, c_{std})}_{\text{láminas}} + 5 \cdot \underbrace{\mathrm{media}\left(\frac{A(\hat{c}-c)}{\max Ac}\right)^2}_{\text{curva reconstruida}} + 5 \cdot \underbrace{\mathrm{media}\left(m \odot \hat{c}^{\,2}\right)}_{\text{crosstalk}}.$$

  - El primer término compara las láminas estandarizadas.
  - El segundo compara las curvas que esas láminas reconstruyen, relativas al máximo de cada curva.
  - El tercero penaliza las láminas que la red asigna a materiales que el generador dejó en cero ($m = 1$ en las familias pura y combinada). Se llama *crosstalk*: la fuga de un material a otro.
- **Entrenamiento:** Adam con learning rate inicial 10^{-3}, que se reduce a la mitad tras 30 épocas sin mejora, hasta 10^{-6}. Lotes de 64 curvas. Parada temprana tras 80 épocas sin mejora, restaurando los mejores pesos.

Pulido. Para un diseño final, la red puede completarse con un paso MCO, $c = A^{+}y$. Las ecuaciones normales se cumplen con un residuo relativo $\leq 1{,}7 \times 10^{-15}$, de modo que red + pulido da el óptimo exacto. Los resultados que siguen son de *la red sola*, sin pulido.

Control de clase. Antes de usar la red, se verifica que la curva de entrada sea de la clase aprendida. Se acepta si una combinación no negativa de 40 líneas truncadas (nudos entre 0,85 y 1,16) la aproxima con NRMSE ≤ 2 %.

5. Resultados de la red

5.1. Entrenamiento

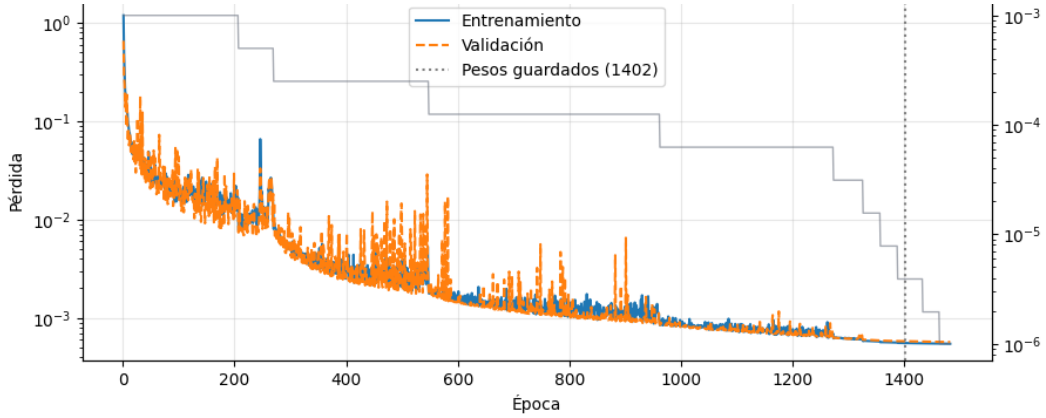


Figura 10: Pérdida de entrenamiento y de validación (gris: learning rate). Se guardan los pesos de la época 1402.

El entrenamiento duró 1482 épocas (94 min en CPU), y se guardaron los pesos de la época 1402. Las pérdidas de entrenamiento (0,000556) y de validación (0,000579) terminan juntas, sin sobreajuste. Los picos de validación entre las épocas 550 y 900 son el ruido propio de un learning rate de 10^{-4} y desaparecen al reducirlo.

5.2. Los 41 sujetos y las curvas medias

El *exceso* mide cuánto peor ajusta la red que el óptimo MCO: NRMSE de la red / NRMSE óptimo − 1.

Tabla 6: Red sola frente al óptimo MCO en los sujetos de Masson.

Grupo	n	NRMSE óptimo	NRMSE red	Exceso	Error pto. máx. red	Cumplen ≤ 3 %	máx $\lvert\Delta c\rvert$
Test	10	0,498 %	0,505 %	+1,50 %	1,69 %	10/10	0,029
Entrenamiento	31	0,461 %	0,467 %	+1,47 %	1,59 %	31/31	0,029
Normotensos	16	0,439 %	0,454 %	+3,31 %	1,69 %	16/16	0,029
Hipertensos	25	0,489 %	0,491 %	+0,42 %	1,57 %	25/25	0,029
Todos	**41**	0,470 %	0,477 %	**+1,48** %	1,69 %	**41/41**	0,029

- En los 10 sujetos de test, la mediana del exceso es +0,1 %: la mitad de ellos sale prácticamente igual al óptimo.
- El máximo es NT02, con +10,0 %. Equivale a 0,03 láminas y a un error punto a punto menor al 1,7 %.
- El peor error punto a punto de la red (1,69 %) queda muy por debajo del criterio.

Tabla 7: Curvas medias de los grupos de Masson.

Curva	n	Láminas MCO (total)	Exceso de RMSE	Error pto. red	Error pto. óptimo
Mean Young	7	12,14	+0,67 %	0,98 %	1,02 %
Mean Old	9	16,70	+0,25 %	1,39 %	1,36 %
Mean NT	11	16,51	+0,15 %	1,36 %	1,33 %
Mean HT	25	18,36	+2,04 %	1,22 %	1,31 %

5.3. Test por familia

Tabla 8: Test por familia (10 000 curvas). Criterio evaluado contra la curva sin ruido.

Familia	n	NRMSE óptimo	NRMSE red	Exceso	R^2 red mín.	Red cumple 3 %	Red máx.	MCO máx.
pura	2000	0,300	0,388	+29,3 %	0,993	99,30 %	4,25 %	0,66 %
combinada	2000	0,248	0,323	+30,1 %	0,937	99,45 %	10,57 %	0,51 %
constitutiva	2000	0,724	0,728	+0,59 %	0,995	99,95 %	3,16 %	1,74 %
amplia	1500	0,731	0,739	+1,14 %	0,990	99,80 %	3,96 %	2,12 %
exponencial	1000	0,743	0,749	+0,80 %	0,998	99,90 %	3,35 %	2,53 %
uniforme	1000	0,741	0,746	+0,70 %	0,998	100 %	2,08 %	2,13 %
pacientes	500	0,726	0,728	+0,27 %	0,997	100 %	1,64 %	1,66 %

- **Familias fisiológicas** (constitutiva, amplia, exponencial, uniforme y pacientes: las de forma arterial). El exceso queda entre +0,3 y +1,1 %: la red está prácticamente sobre el óptimo.
  - Las pocas curvas que superan el 3 % (1 de 2000 en la constitutiva, 3 de 1500 en la amplia y 1 de 1000 en la exponencial) son casos donde el MCO ya da entre 2,1 y 2,5 %.
  - Todas quedan cerca del límite.
- **Familias de bases** (pura y combinada). El exceso relativo es mayor (≈ 30 %), pero sobre óptimos muy chicos (NRMSE de 0,25–0,30 %). La causa es el ruido de la curva:
  - el MCO reparte ese ruido como láminas chicas, de ambos signos, en los materiales ausentes;
  - la red, entrenada para no producir crosstalk, las deja casi en cero.

Por eso da láminas negativas en el 22,4 % de las curvas de test, frente al 33,8 % del MCO. Los negativos grandes (mínimo −1,76 contra −1,74 del MCO) son reales y la red los respeta.

- **El peor caso de la combinada** (10,6 %) es una curva casi plana de 0,03 kPa hasta el nudo 3. La red pone en cero ese tramo. Es una curva sin sentido físico, de menos de 1 kPa en total.

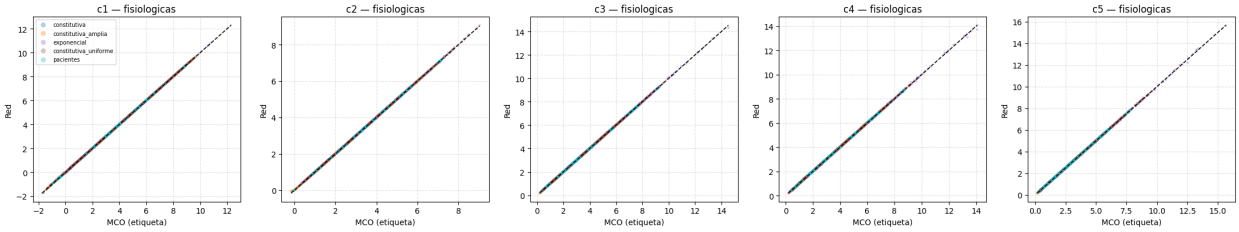


Figura 11: Láminas de la red frente a las del MCO en las familias fisiológicas de test (6000 curvas). $R^2 \geq 0{,}99987$ en los cinco materiales; error medio de 0,006 a 0,015 láminas.

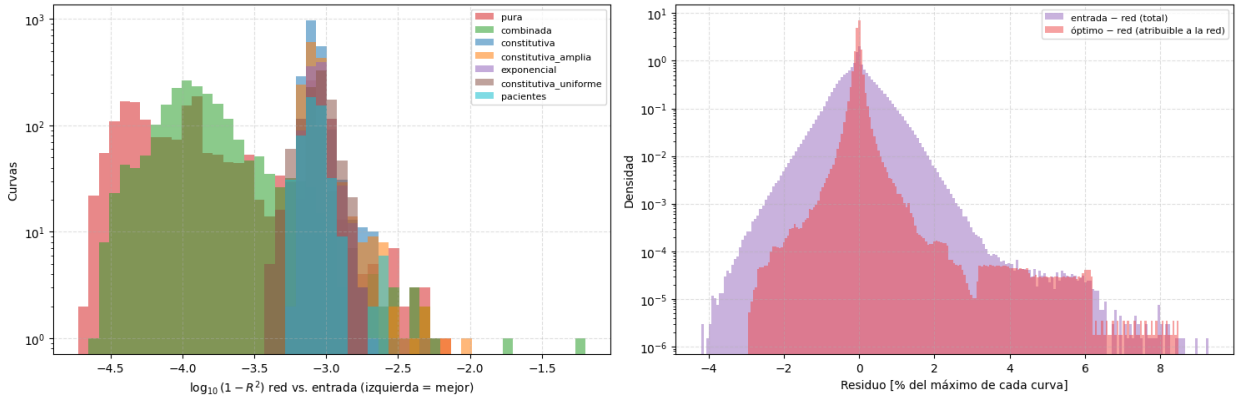


Figura 12: Izquierda: $\log_{10}(1 - R^2)$ de la red por familia. Derecha: residuo total (violeta) y la parte atribuible a la red (óptimo − red, rojo), en % del máximo de cada curva. El cuerpo de la parte atribuible a la red está dentro de ±2 %.

5.4. Generalización a una ley nunca vista y control de clase

Se generaron 300 curvas con una ley tipo Fung, que no forma parte del dataset de entrenamiento (con ruido del 1 %; el 0,8 % de sus puntos queda fuera de y_1–y_2).

- El NRMSE de la red es 1,17 % y el del óptimo 1,13 %: un exceso de +4,2 %.
- El peor R^2 de la red es 0,978, frente a un óptimo de 0,997.

La red generaliza a una forma funcional que no vio, con un costo pequeño frente al óptimo.

El control de clase acepta todas las curvas de Fung y los 41 sujetos. Rechaza el 95,7 % de las curvas moduladas que dejan de tener forma J, y acepta el 73,9 % de las que la conservan.

5.5. Reproducción de láminas aisladas

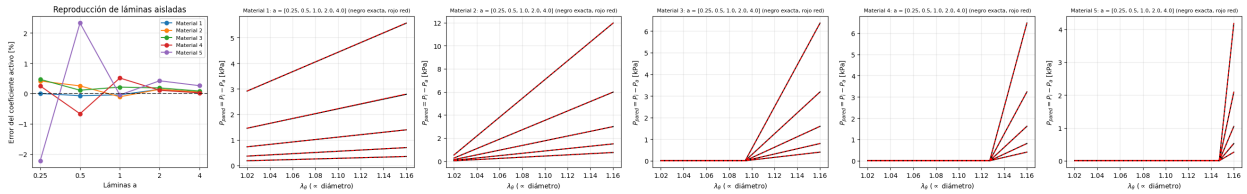


Figura 13: Entrada $y = a\,A_j$ (una sola base, $a = 0{,}25$ a 4 láminas); la respuesta exacta es $c = a\,e_j$. Izquierda: error del coeficiente activo; resto: curvas exactas (negro) y de la red (rojo).

- **Crosstalk:** el máximo en los materiales ausentes es 0,0024 láminas.
- **Coeficiente activo, materiales 1 a 4:** el error es como mucho ±0,67 %.
- **Material 5:** con 0,25 y 0,5 láminas el error llega a ±2,3 %, sin sesgo. Esa base solo actúa en el último 9 % del dominio, y con 0,25 láminas su señal es una rampa de apenas 0,26 kPa. En valor absoluto son 0,012 láminas; desde 1 lámina el error es $\leq 0{,}4$ %.

6. Diseño: la curva media de los hipertensos

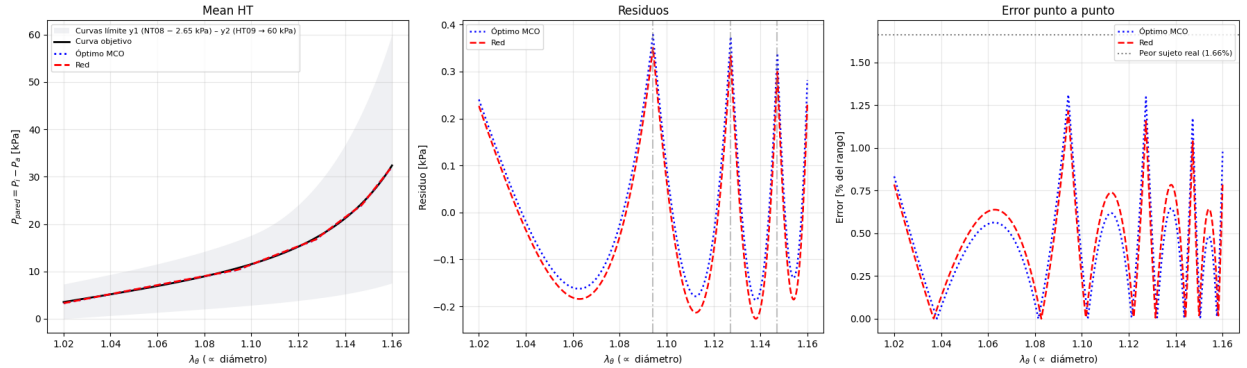


Figura 14: Mean HT: curva, ajuste MCO y red (izquierda), residuos (centro; líneas verticales en los nudos) y error punto a punto (derecha).

Tabla 9: Injerto para Mean HT ($C_{LAM} = 10$): láminas del MCO y de la red, y rigidez de cada capa.

Material	Nudo	Holgura de fibra	Láminas MCO	Láminas red	K 1 lámina [N/m]	K total [N/m]	Aporte a $P(1,16)$ [kPa]	Deform. máx.
1	0,8669	0 %	3,826	3,844	12,2	46,7	5,33	33,8 %
2	1,0135	16,9 %	3,752	3,757	71,7	269,1	11,22	14,5 %
3	1,0942	26,2 %	4,006	4,013	99,1	397,0	6,38	6,0 %
4	1,1273	30,0 %	3,628	3,619	215,3	780,9	5,87	2,9 %
5	1,1472	32,3 %	3,152	3,165	367,0	1156,7	3,29	1,1 %
Total			18,363	18,398			32,08	

- **Láminas:** la red difiere del MCO en 0,018 láminas como máximo.
- **Error:** el punto a punto de la red es menor que el del MCO (1,22 % contra 1,31 %), y el NRMSE apenas mayor (0,530 contra 0,519 %). Los picos del residuo caen en los nudos 3, 4 y 5: es el piso de error de las bases, no de la red.
- **Injerto resultante:**
  - radio de reposo de $0{,}8669\,R_{ref} = 2{,}97$ mm, sin pretensado;
  - presión de pared en $\lambda = 1{,}16$ de 32,1 kPa (241 mmHg);

- cada material entra en carga con la holgura de fibra indicada en la tabla.

7. Conclusiones

1. **Espacio de trabajo.** Se definió entre dos curvas límite que contienen a las 41 carótidas de Masson et al. (2011) y llegan a 60 kPa. El ajuste se hace en [1,02; 1,16], el rango respaldado por las mediciones.
2. **Elección de las bases.** El método minimax (CVaR 99 % del error punto a punto, desempate por NRMSE y restricción $\mathrm{cond}(A) < 25$, con Nelder–Mead) elige nudos con los que el MCO cumple el criterio del 3 % en todo el espacio de trabajo con 5 materiales (máximo 2,07 %). Con 4 materiales no alcanza; con 6 la mejora es pequeña y $\mathrm{cond}(A)$ queda en el límite.
3. **Red neuronal.**
   - Reproduce el óptimo: +1,48 % en los 41 sujetos, todos dentro del criterio, y entre +0,3 y +1,1 % en las familias fisiológicas.
   - Generaliza a una ley nunca vista con un exceso de +4,2 %.
   - Su diseño para la curva media de los hipertensos coincide con el óptimo en 0,02 láminas.
4. **Número de láminas.** C_{LAM} es una elección de unidades: puede fijarse por material según los materiales disponibles, sin reentrenar y sin cambiar el injerto.
5. **Trabajo futuro.**
   - Mejorar la generalización a leyes no vistas: más capacidad de la red o más variedad en las leyes sintéticas.
   - Si interesa un tope de dilatación ante sobrepresiones, estudiar un material "freno" con nudo cerca de 1,16.

A. El cuaderno

Celda	Contenido
0	Configuración: `N_BASES`, `NUDOS_REF`, `OPTIMIZAR_NUDOS`, `UMBRAL_COND`, `C_LAM`, `ENTRENAR`
1	Modelo de Masson, 41 sujetos y curvas límite
2	Espacio de trabajo: curvas fisiológicas sintéticas
3	Bases: $\mathrm{cond}(A)$, nudos (minimax si hace falta) y `PEND_MAX`
4	Verificación de las bases sobre los 41 sujetos
5	Figura: láminas de las curvas límite y error de los 41 sujetos
6	Librerías, entrada logarítmica, métricas y predicción
7	Dataset: familias pura y combinada + fisiológicas
8	Partición y normalización (verifica los nudos al cargar una red)
9–11	Pérdida y arquitectura, integridad de los datos, entrenamiento o carga de la red
12–18	Evaluación en test, reconstrucción, 41 sujetos, figuras, familias, ley de Fung, muestras
19	Diseñador de injerto
20	Reproducción de láminas aisladas
21	Las bases con su fórmula
22	Extrapolación fuera del dominio de ajuste

- Con `ENTRENAR = True` el cuaderno genera el dataset y entrena la red; con `False`, carga una red ya entrenada.
- Los archivos de la red llevan en el nombre el número de bases, de modo que redes con 4, 5 o 6 materiales no se pisan entre sí.

- Las tablas de Masson (`tabla2_masson_NT.csv`, `tabla4_masson_HT.csv`) van en la misma carpeta que el cuaderno.

Referencia

Masson, I., Beaussier, H., Boutouyrie, P., Laurent, S., Humphrey, J. D., Zidi, M. (2011). Carotid artery mechanical properties and stresses quantified using in vivo data from normotensive and hypertensive humans. *Biomechanics and Modeling in Mechanobiology*, 10, 867–882.