Diseño de injertos vasculares biomiméticos con láminas de materiales: curvas límite sintetizadas, método minimax de los nudos y red entrenada con 50 000 curvas (versión V25)

Pablo

13 de octubre de 2026

Resumen

Se presenta la versión V25 del método de diseño de injertos vasculares multicapa a partir de la curva presión–diámetro de una arteria. Cada función base es la curva de *una lámina* de un material, idealizada como una línea truncada $A_j(\lambda) = S_j\,\mathrm{máx}(0, \lambda - k_j)$, y cada coeficiente es el *número de láminas* de ese material.

Curvas límite (V24). Las 41 curvas de Masson et al. (2011) no cambian; cambian solo las curvas límite del espacio de trabajo. Ahora y_1 es NT08 desplazada a 0 en $\lambda = 1{,}02$, e y_2 coincide con HT09 hasta $\lambda = 1{,}10$ y desde allí sube exponencialmente hasta 60 kPa en $\lambda = 1{,}16$. Con esta franja quedan dentro los 41 sujetos (antes 26). El dominio de ajuste se mantiene en [1,02; 1,16], donde el modelo constitutivo está respaldado por mediciones.

Método minimax. Los nudos k_j se eligen para que el *peor* ajuste por mínimos cuadrados (MCO) sobre todo el espacio de trabajo sea lo más chico posible. El objetivo es la media del peor 1 % de los errores punto a punto (CVaR 99 %), con la restricción $\mathrm{cond}(A) < 25$, y se minimiza con Nelder–Mead. Se explica en detalle en la Sección 3. Con 5 bases, el MCO cumple el criterio del 3 % en las 22 500 curvas del espacio de trabajo, con un máximo de 2,07 %. Con 4 bases no alcanza (98,96 % de las curvas). Con 6 mejora poco (máximo 1,67 %), con $\mathrm{cond}(A)$ en el límite.

Red V25. Con el dataset ampliado de 30 000 a 50 000 curvas, la red sola cumple el 3 % en los 41 sujetos y queda a +1,48 % del óptimo (V24: +2,12 %; V22: +2,66 %), con mediana +0,1 % en test. Mejora en todas las familias del dataset: la combinada pasa de +70,8 % a +30,1 % y las fisiológicas (curvas con forma de arteria, generadas con la ley de Masson u otra ley exponencial o tomadas de los pacientes) quedan entre +0,3 y +1,1 %. En una ley nunca vista (tipo Fung), el exceso baja de +9,2 % (V24) a +4,2 %. El injerto diseñado para la curva media de los hipertensos tiene exactamente la misma rigidez por capa que en V24. *Los términos técnicos se definen en su primera aparición y se reúnen en el Glosario (Apéndice C).*

Palabras clave— Mínimos cuadrados ordinarios, Líneas truncadas, Aproximación minimax, CVaR, Número de condición, Nelder–Mead, Red neuronal, Injerto vascular biomimético, Curva presión–diámetro.

Los resultados de la red provienen del cuaderno V25 con 5 bases, entrenado en CPU (1482 épocas, 94 min). Las figuras de la Sección 3 se calcularon con el mismo espacio de trabajo de V25 (las pendientes coinciden con las de la corrida).

Índice

1. Qué cambió desde V23 **3**

2. Curvas límite sintetizadas y espacio de trabajo **3**
2.1. Qué cambia y qué no . . . 3
2.2. Definición . . . 3
2.3. Consecuencias . . . 4
2.4. Dominio de ajuste: se respalda en las mediciones . . . 4

3. Elección óptima de la base: el método minimax **5**
3.1. El problema: qué es un nudo y por qué importa . . . 6
3.2. Visión general del procedimiento . . . 7
3.3. Nudos iniciales . . . 7
3.4. El criterio minimax: cómo se califica un juego de nudos . . . 8
3.4.1. Paso 1: el error de *una* curva . . . 8
3.4.2. Paso 2: de una curva a la población . . . 9
3.4.3. Paso 3: por qué la media del peor 1 % y no el máximo . . . 9
3.4.4. Paso 4: el número de condición, cond(A) . . . 13
3.4.5. Paso 5: la función objetivo completa J . . . 14
3.5. El optimizador: Nelder–Mead . . . 15
3.6. Por qué Nelder–Mead y no otro optimizador . . . 16
3.7. Robustez respecto del punto de partida . . . 18
3.8. Resultados: 4, 5 o 6 bases . . . 19
3.9. Qué garantiza la base elegida y qué no . . . 19
3.10. Cómo se usa en el cuaderno . . . 20

4. Pendientes máximas y escala de las láminas **21**

5. Resultados de la red V25 **22**
5.1. Entrenamiento . . . 22
5.2. Evaluación en test (10 000 curvas) . . . 23
5.3. Los 41 sujetos y las curvas medias . . . 23
5.4. Test por familia . . . 24
5.5. Generalización a una ley nunca vista y control de clase . . . 25
5.6. Reproducción de láminas aisladas . . . 26

6. Diseño: la curva media de los hipertensos **26**

7. Conclusiones y próximos pasos **27**

A. Celdas del cuaderno V25 **27**

B. Datos de partida: Masson et al. (2011) **28**
B.1. Ley constitutiva . . . 28
B.2. Cinemática y presión de pared . . . 28
B.3. Figuras 5a y 7a: de la tensión a la presión de pared . . . 29
B.4. Tablas 2 y 4: parámetros de los 41 sujetos . . . 30

C. Glosario **33**

1. Qué cambió desde V23

Tabla 1: Cambios de V23 a V25.

Versión	Cambio
V24	Nuevas curvas límite y_1, y_2 (Sección 2). Nuevo espacio de trabajo, nudos re-optimizados (casi iguales) y nuevas pendientes máximas. Red entrenada con $C_{LAM} = 10$ y peso del crosstalk 5 (la configuración de la mejor red de V22).
V25	Dataset de 50 000 curvas (antes 30 000), con las mismas proporciones de familias. Con 5 bases es el único cambio respecto de V24.
V25	Número de bases configurable de 4 a 6 (`N_BASES`). La red, el dataset y las figuras se adaptan solos.
V25	Control de cond(A) y re-optimización automática de los nudos con cond(A) < `UMBRAL_COND` (Sección 3).
V25	`PEND_MAX` se calcula sola a partir del espacio de trabajo; ya no se escribe a mano.
V25	C_{LAM} por material como lista de `N_BASES` valores (o un número), con control de largo.
V25	Nueva Celda 2: genera las curvas fisiológicas (las de forma arterial; ver Sección 5.4) antes de las bases. Las celdas siguientes se corren un número (Apéndice A).

2. Curvas límite sintetizadas y espacio de trabajo

2.1. Qué cambia y qué no

La curva objetivo sigue siendo la presión de pared $P_{pared}(\lambda_\theta) = P_i - P_a = \int(\sigma_{\theta\theta} - \sigma_{rr})/r\, dr$, calculada con el modelo constitutivo de Masson et al. (2011) para los 41 sujetos (16 normotensos y 25 hipertensos; la ley, las tablas de parámetros y las figuras originales están en el Apéndice B), con espesor $h = 0{,}6$ mm, en $\lambda_\theta \in [1{,}02;\ 1{,}16]$. Las curvas se evalúan en una **grilla** de 999 valores de λ equiespaciados (paso $\approx 0{,}00014$): cada curva es el vector de sus 999 valores, y todas las sumas, máximos y errores se calculan sobre esos puntos. **Las 41 curvas son siempre las mismas**; los 10 sujetos de test (NT02, NT08, NT10, NT11, HT03, HT05, HT13, HT14, HT19, HT24) tampoco cambian.

Lo único que cambia son las curvas límite y_1 e y_2, que definen el *espacio de trabajo*: las curvas generadas con la ley de Masson que cumplen $y_1(\lambda) \le y(\lambda) \le y_2(\lambda)$ en todo el dominio.

2.2. Definición

$$y_1(\lambda) = P_{NT08}(\lambda) - P_{NT08}(1{,}02) \qquad \text{(desplazamiento de 2,65 kPa; } y_1(1{,}02) = 0),$$
$$y_2(\lambda) = P_{HT09}(\lambda) + a\left(e^{\,b\,E^2} - 1\right), \qquad E = \text{máx}\Big(0,\ (\lambda/1{,}10)^2 - 1\Big).$$

El término agregado vale cero hasta $\lambda = 1{,}10$, de modo que y_2 coincide allí con HT09. Desde 1,10 tiene la misma forma exponencial del colágeno circunferencial de Masson, con $b = c_2^{circ}$ de HT09 (13,49). La amplitud $a = 80{,}2$ kPa se elige para que $y_2(1{,}16) = 60$ kPa. Resultan $y_2(1{,}10) = 17{,}6$, $y_2(1{,}13) = 29{,}4$ e $y_2(1{,}16) = 60{,}0$ kPa, e $y_1(1{,}16) = 7{,}5$ kPa.

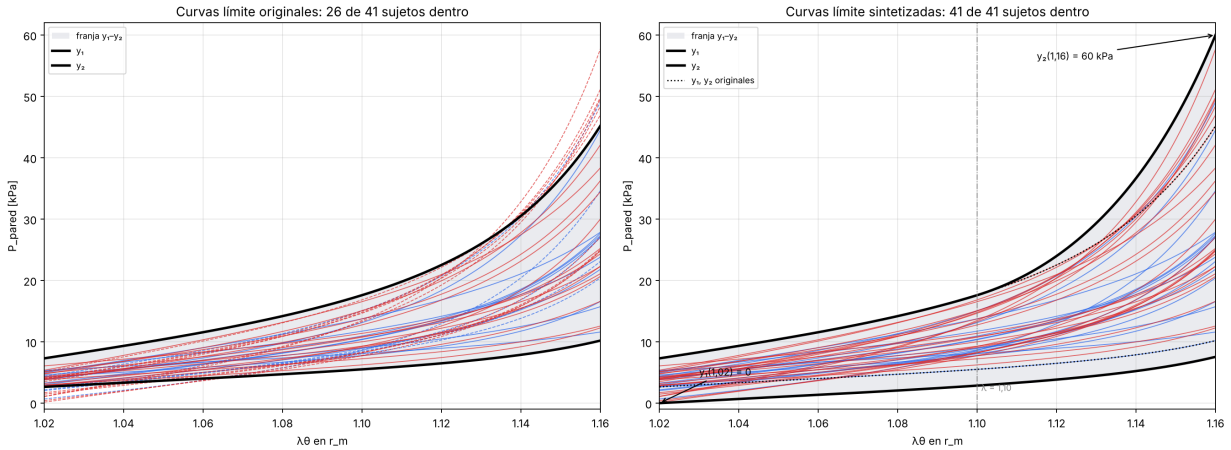


Figura 1: Izquierda: curvas límite originales (NT08 y HT09), con 26 de los 41 sujetos dentro. Derecha: curvas sintetizadas, con los 41 dentro. Azul: normotensos; rojo: hipertensos.

2.3. Consecuencias

- **Espacio de trabajo más grande.** Las familias constitutiva, amplia y uniforme aceptan ahora curvas más blandas (cerca de 0 en el pie) y más rígidas (hasta 60 kPa). En V25 son 22 500 curvas, con aceptación del 96,2 % (constitutiva), 84,7 % (amplia) y 89,8 % (uniforme). En $\lambda = 1{,}16$ su presión va de 10,0 kPa (percentil 1) a 60,0 kPa, con mediana 25,9 kPa.
- **Pendientes mayores.** Para que la curva más exigente quepa con C_{LAM} láminas, las pendientes por lámina de los materiales rígidos crecen entre 1,2 y 1,6 veces respecto de V23 (Sección 4).
- **Nudos casi iguales.** Re-optimizados en V24, se movieron menos de 0,001, salvo el primero (de 0,8322 a 0,8669), que está fuera del dominio y casi no influye.

2.4. Dominio de ajuste: se respalda en las mediciones

El modelo constitutivo de cada sujeto se ajustó en el rango de λ medido durante su ciclo cardíaco: aproximadamente 1,085–1,122 para HT09 y hasta $\approx 1{,}16$ en los más distensibles. Fuera de ese rango, la ley es una extrapolación sin datos.

- Por debajo de $\lambda \approx 0{,}95$ el término activo vuelve negativa la presión (Fig. 2).
- Por encima de 1,16 el colágeno crece sin límite: entre 1,16 y 1,20 las curvas se multiplican por 2 a 4,5, y HT25 llega a 260 kPa.

Por eso **el ajuste se hace solo en** [1,02; 1,16], y la extrapolación del injerto (Celda 22) se muestra solo como información.

Más allá de 1,16 el injerto es lineal, mientras que la ley de Masson crece de forma exponencial. En $\lambda = 1{,}20$ el injerto da la mitad de presión que la ley. Si en el futuro se quisiera un tope de dilatación ante una sobrepresión, la alternativa que no depende de extrapolar la ley es un sexto material "freno" con nudo cerca de 1,16. Su número de láminas se fijaría con un criterio de seguridad explícito, no por ajuste.

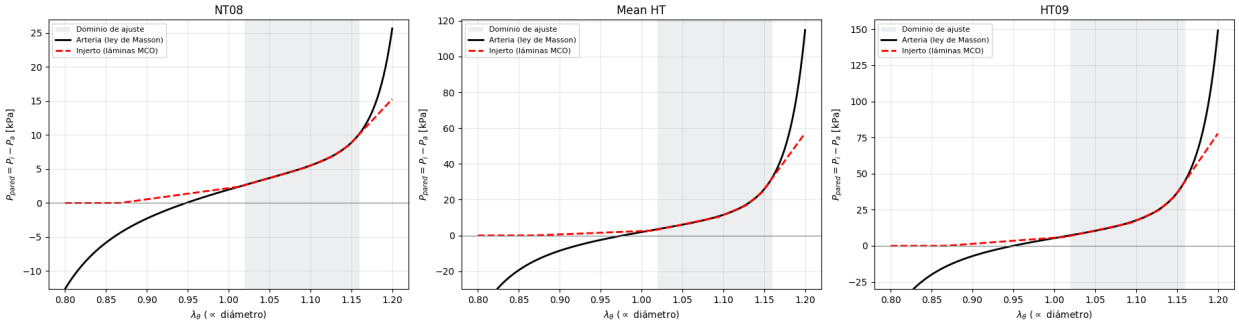


Figura 2: Extrapolación del injerto (láminas MCO ajustadas en [1,02; 1,16], sombreado) frente a la ley de Masson, para NT08, la media de los hipertensos y HT09 (cuaderno V24; los nudos son los mismos en V25).

3. Elección óptima de la base: el método minimax

Objetivo. Elegir la base apropiada, es decir, la posición de los nudos $k_1, \ldots, k_N$, para que el ajuste de cualquier curva del espacio de trabajo pueda hacerse por MCO **sin condiciones**: sin cotas ni restricciones sobre las láminas y sin regularización.

- Con una base así, el ajuste es la fórmula cerrada $c = A^+ y$: exacta, única e instantánea, y es lo que la red aprende a reproducir.
- Toda la exigencia se traslada a la elección de la base, que se hace una sola vez.

Para que el ajuste libre sea aceptable, la base debe garantizar dos propiedades en todo el espacio de trabajo:

1. **Precisión:** toda curva se ajusta con error punto a punto ≤ 3 %.
2. **Estabilidad:** cond(A) acotado, para que pequeños errores en la curva no produzcan grandes cambios en las láminas.

Una tercera propiedad deseable, que todas las láminas resulten ≥ 0, no está impuesta en el criterio. Su cumplimiento se analiza en la Sección 3.9. Esta sección explica, desde cero y paso a paso, cómo se eligen los nudos; es lo que hace la Celda 3 del cuaderno cuando hace falta.

Dos problemas distintos: las láminas (MCO) y los nudos (Nelder–Mead)

El diseño tiene dos tipos de incógnitas, que se resuelven con métodos distintos:

1. **Las láminas c_j, con los nudos fijos.** La curva del injerto depende de las láminas en forma *lineal*. Por eso el mejor ajuste se obtiene con **mínimos cuadrados ordinarios (MCO)**, que dan una solución exacta mediante una fórmula cerrada (Sección 3.1). Se resuelve una vez por cada curva arterial, y es lo que la red aprende a reproducir.
2. **Los nudos k_j.** La curva depende de los nudos en forma *no lineal* (a través de máx$(0, \lambda - k_j)$), y no hay fórmula para el mejor juego de nudos. Se busca numéricamente con el método de **Nelder–Mead**, que prueba valores de los nudos y va quedándose con los mejores (Sección 3.5). Se resuelve una sola vez, al construir las bases.

Los dos métodos trabajan anidados. Nelder–Mead es el *lazo exterior*: propone un juego de nudos. El MCO es el *lazo interior*: con esos nudos, ajusta todas las curvas y devuelve sus errores, con los que Nelder–Mead decide el siguiente juego a probar. **Nelder–Mead no es un método de mínimos cuadrados.**

3.1. El problema: qué es un nudo y por qué importa

Cada material se representa con una *línea truncada*:

$$A_j(\lambda) = S_j \ \text{máx}(0,\ \lambda - k_j).$$

Vale cero mientras $\lambda < k_j$: las fibras de esa lámina todavía están flojas. A partir de $\lambda = k_j$ (el **nudo**, *knot* en inglés) crece con pendiente S_j. La curva del injerto es la suma de las láminas:

$$P_{injerto}(\lambda) = \sum_{j=1}^{N} c_j\, A_j(\lambda),$$

que es una *poligonal*: una sucesión de tramos rectos que se quiebran en cada nudo. En cada quiebre la pendiente aumenta, porque entra en carga un material nuevo.

Dada una curva arterial $y(\lambda)$, el número de láminas $c = (c_1, \ldots, c_N)$ se obtiene por mínimos cuadrados ordinarios:

$$c = A^{+}y = \arg\min_{c} \sum_{i=1}^{999} \big(y(\lambda_i) - (Ac)(\lambda_i)\big)^2,$$

donde A es la matriz de $999 \times N$ cuyas columnas son las bases evaluadas en los 999 puntos de la grilla.

Qué son los mínimos cuadrados ordinarios (MCO). Se eligen las láminas c que hacen mínima la suma de los cuadrados de las diferencias entre la curva arterial y la del injerto, punto por punto de la grilla. Como la curva del injerto es lineal en c y las columnas de A son linealmente independientes, el mínimo es único y tiene solución exacta:

$$c = (A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}y \equiv A^{+}y.$$

A^{+} es la **pseudoinversa** (de Moore–Penrose) de A. En la práctica se calcula con la descomposición en valores singulares, que es numéricamente más estable (Trefethen y Bau, 1997, Lecturas 11–12; Lawson y Hanson, 1974).

El MCO elige las láminas; los nudos se eligen antes, una sola vez, para todas las curvas. Eso es lo que resuelve esta sección.

¿Por qué importa dónde están los nudos? Una poligonal solo puede doblarse donde tiene quiebres. La curva J arterial es suave y se curva cada vez más hacia λ alto. Si los quiebres están mal ubicados (por ejemplo, equiespaciados), la poligonal no puede seguir la curvatura del final. La Fig. 3 lo muestra con la curva media de los hipertensos (Mean HT):

- **Con los nudos minimax**, el error máximo es 1,31 % del rango.
- **Con 5 nudos equiespaciados** es 7,93 %. Sobre las 22 500 curvas del espacio de trabajo, el peor 1 % pasa de 1,74 % a 11,67 %, y solo el 0,21 % de las curvas cumple el 3 %.

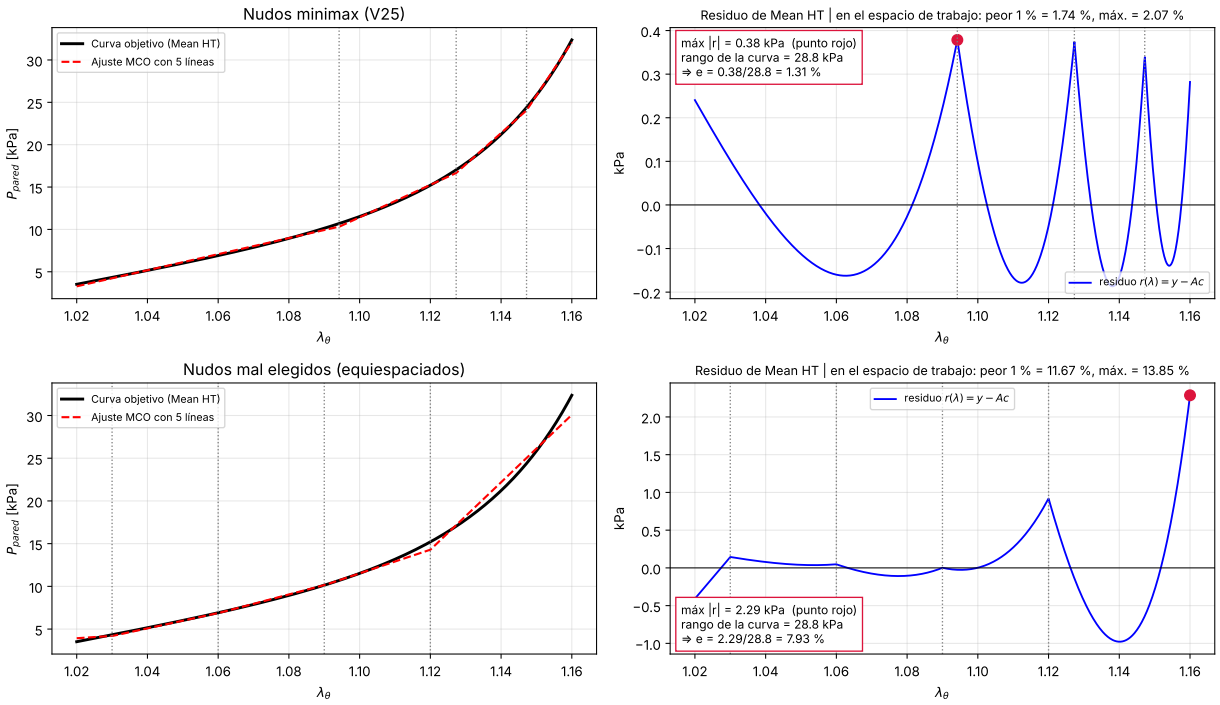


Figura 3: La misma curva (Mean HT) ajustada con 5 líneas truncadas por MCO, con dos juegos de nudos (líneas punteadas verticales). Arriba, los nudos minimax adoptados; abajo, nudos equiespaciados. A la derecha, el residuo y su máximo (punto rojo). Con los mismos 5 materiales, el error cambia por un factor 6 según dónde se quiebre la poligonal.

3.2. Visión general del procedimiento

Elegir los nudos es un proceso iterativo en cuatro etapas:

1. **Nudos iniciales** (Sección 3.3): se propone un primer juego de nudos con una regla simple.
2. **Calificación** (Sección 3.4): para un juego de nudos se calcula un único número, $J(k)$. Mide qué tan bien ajusta el MCO a las *peores* curvas del espacio de trabajo, y penaliza si $\mathrm{cond}(A)$ es grande. Cuanto menor es J, mejor es la base. Este es el **criterio minimax**: *qué* se considera una buena base.
3. **Búsqueda** (Sección 3.5): el método de Nelder–Mead propone un nuevo juego de nudos y se lo califica con J. El ciclo se repite, quedándose siempre con los mejores nudos, hasta que J deja de bajar. Este es el **método**: *cómo* se encuentra la mejor base.
4. **Verificación** (Secciones 3.7 a 3.9):
   - que el resultado no dependa del punto de partida;
   - que la base final cumpla precisión y estabilidad en las 22 500 curvas completas;
   - qué ocurre con el signo de las láminas.

3.3. Nudos iniciales

La búsqueda necesita un primer juego de nudos desde el cual partir. Se usan dos puntos de partida, y la búsqueda (Sección 3.5) se corre desde cada uno; se conserva el resultado de menor J.

(a) Regla geométrica. El primer nudo se fija en $k_1 = 0{,}86$, y los demás se calculan como

$$k_j = 1{,}16 - 0{,}15 \cdot g_j, \qquad j = 2, \ldots, N,$$

donde $g_2, \ldots, g_N$ son $N-1$ valores en progresión geométrica que van de 1 a 0,1. Por ejemplo, para 5 bases, $g = (1;\ 0{,}464;\ 0{,}215;\ 0{,}1)$, y resultan $k = (0{,}86;\ 1{,}010;\ 1{,}090;\ 1{,}128;\ 1{,}145)$.

Por qué esta regla:

- **Los nudos se juntan hacia λ alto.** La curva J arterial es casi recta al comienzo del dominio y se curva cada vez más hacia $\lambda = 1{,}16$. Una poligonal solo puede doblarse en sus nudos, así que necesita más quiebres, y más próximos entre sí, donde la curvatura es mayor. La progresión geométrica produce justamente nudos cada vez más juntos.
- **El primer nudo está fuera del dominio** ($0{,}86 < 1{,}02$). Así, el primer material ya está en carga en todo el dominio y aporta la pendiente inicial de la curva.
- **Los valores son empíricos.** Los números 0,86 y 1,01, y la razón de 1 a 0,1, se eligieron porque dejan el punto de partida cerca de donde suelen quedar los óptimos, lo que acelera la búsqueda. No hay una regla teórica detrás. El resultado final no depende de ellos (Sección 3.7).

(b) Nudos de referencia. Los que figuran en la Celda 0 del cuaderno (`NUDOS_REF`) para ese número de bases, resultado de una optimización anterior con este mismo método. Si no existen, se usa solo la regla (a).

Tabla 2: Nudos iniciales de la regla geométrica y nudos finales tras la búsqueda.

Bases	Punto de partida (regla geométrica)	Nudos finales (óptimo)
4	0,86; 1,010; 1,113; 1,145	0,8835; 1,0269; 1,1080; 1,1416
5	0,86; 1,010; 1,090; 1,128; 1,145	0,8669; 1,0135; 1,0942; 1,1273; 1,1472
6	0,86; 1,010; 1,076; 1,113; 1,133; 1,145	0,8669; 1,0210; 1,0758; 1,1139; 1,1380; 1,1518

Simplex inicial. A partir del punto de partida, la biblioteca usada (SciPy) arma el simplex inicial de Nelder–Mead (Sección 3.5) con ese punto y N puntos más. Cada uno de esos puntos aumenta un 5 % uno solo de los nudos; por ejemplo, $k_2 = 1{,}010$ pasa a 1,0605.

Hasta aquí los nudos iniciales son solo una propuesta. La sección siguiente define cómo se mide qué tan buena es.

3.4. El criterio minimax: cómo se califica un juego de nudos

Los Pasos 1 a 5 definen cómo se calcula $J(k)$ para un juego de nudos k *cualquiera*: el inicial, o cualquiera que proponga después Nelder–Mead. En los ejemplos se usan los nudos adoptados, que son el resultado final del procedimiento, para mostrar números concretos.

3.4.1. Paso 1: el error de *una* curva

Para unos nudos k dados y una curva y:

1. Se calculan las láminas por MCO: $c = A^{+}y$.
2. Se calcula el residuo en cada punto: $r(\lambda_i) = y(\lambda_i) - (Ac)(\lambda_i)$, en kPa.
3. Se toma el mayor residuo en valor absoluto y se lo divide por el rango de la curva:

$$e(y;k) = \frac{\max_i |r(\lambda_i)|}{\max_i y(\lambda_i) - \min_i y(\lambda_i)} \times 100 \;\; [\,\%].$$

Ejemplo numérico (Fig. 3, arriba). El residuo máximo de Mean HT es 0,38 kPa, en $\lambda \approx 1{,}094$. La curva va de 3,5 a 32,3 kPa, un rango de 28,8 kPa. Entonces $e = 0{,}38/28{,}8 = 1{,}31$ %.

Este es exactamente el **criterio de diseño**: una curva cumple si $e \leq 3$ %. Se divide por el rango para que el criterio sea igual de exigente con una arteria blanda (rango de 10 kPa) que con una rígida (rango de 60 kPa). Medido en kPa, el ajuste quedaría dominado por las curvas rígidas.

Otra medida de error: el NRMSE. Además del error máximo e se usa el *error cuadrático medio normalizado*:

$$\mathrm{NRMSE} = \frac{\sqrt{\frac{1}{999}\sum_{i=1}^{999} r(\lambda_i)^2}}{\max y - \min y} \times 100 \;\; [\,\%].$$

e mide el peor punto de la curva; el NRMSE mide el error típico a lo largo de toda la curva. Siempre NRMSE $\leq e$.

3.4.2. Paso 2: de una curva a la población

Los nudos no se eligen para una arteria, sino para *todas* las del espacio de trabajo. Fijados los nudos, cada curva y_i tiene su error $e_i = e(y_i; k)$. Con 22 500 curvas hay 22 500 errores. La Fig. 4 muestra su histograma para los nudos adoptados:

- la mayoría de las curvas tiene error cercano a 1,2 % (media 1,22 %, mediana 1,23 %);
- el peor 1 % (225 curvas, en rojo) está entre 1,66 % y 2,07 %;
- ninguna curva supera el 3 %.

¿Qué número resume este histograma para decidir si unos nudos son mejores que otros?

- **La media no sirve**: unos nudos podrían ajustar muy bien la mayoría de las curvas y muy mal unas pocas. Esas pocas no cumplirían el criterio, y la media no lo mostraría.
- Como el criterio es "*toda* curva con $e \leq 3$ %", lo que importa es la **cola derecha** del histograma: las peores curvas. De ahí el nombre *minimax*: **mini**mizar el **máx**imo error.

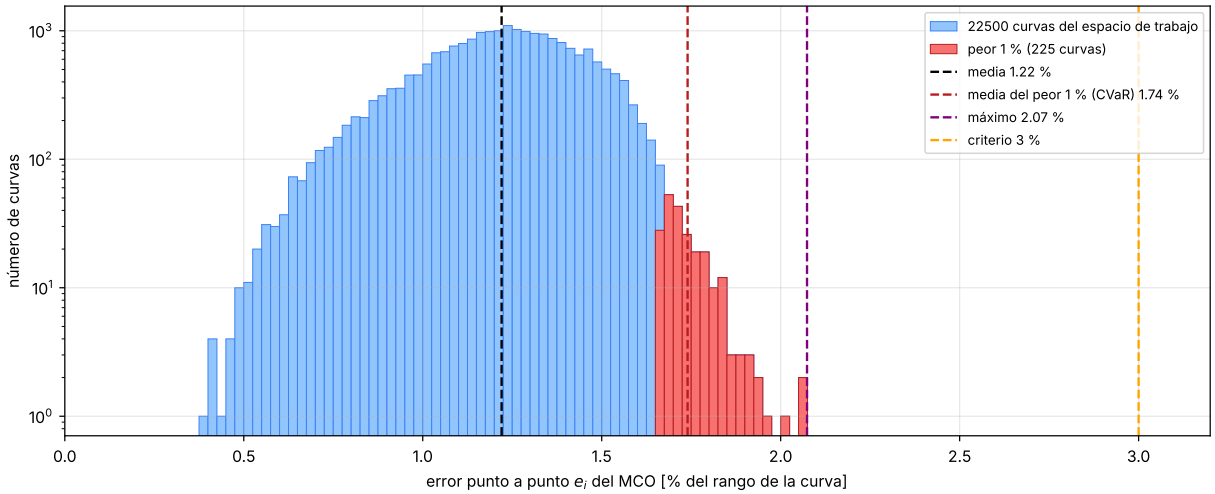


Figura 4: Error punto a punto del MCO con los nudos adoptados en las 22 500 curvas del espacio de trabajo (escala vertical logarítmica). En rojo, el peor 1 %. El método minimax actúa sobre esa cola.

3.4.3. Paso 3: por qué la media del peor 1 % y no el máximo

El paso anterior dejó establecido que, para comparar dos juegos de nudos, hay que mirar las curvas peor ajustadas. Este paso define con exactitud *qué número* se calcula a partir de esas curvas y justifica la elección.

(a) El conjunto de curvas de optimización Durante la búsqueda de los nudos, la función objetivo se evalúa cientos de veces, y cada evaluación requiere resolver un ajuste MCO por curva. Para que la búsqueda tarde segundos y no horas, no se usan las 22 500 curvas del espacio de trabajo sino un **conjunto de optimización** de $n = 2532$ curvas, formado por:

Componente	Curvas
Muestra al azar del espacio de trabajo (con semilla fija, siempre la misma muestra)	2500
Sujetos de entrenamiento de Masson (los 31, todos dentro de la franja y_1–y_2)	31
Curva límite y_2 (la más rígida y exigente)	1
Total (n)	**2532**

- **Semilla fija:** la *semilla* es el número con que se inicializa el generador de números aleatorios de la computadora. Con la misma semilla, el sorteo da siempre las mismas 2500 curvas, de modo que el resultado es reproducible.
- **Los sujetos reales y y_2 se incluyen siempre**, para que nunca queden fuera de la muestra.
- **Los 10 sujetos de test no se incluyen**: la elección de los nudos no los "ve", y por eso sirven después para evaluar el método sin sesgo.
- **Grilla:** en la optimización cada curva se evalúa en 500 puntos (uno de cada dos de la grilla de 999), también por velocidad. Todos los números de este Paso 3 están calculados así.
- **No confundir con el Paso 2:** el histograma de la Fig. 4 usa las 22 500 curvas completas, y allí el peor 1 % son 225 curvas. En la optimización se usa este conjunto de 2532 curvas, y el peor 1 % son 25. El criterio es el mismo (el 1 % de mayor error); cambia solo el conjunto sobre el que se calcula.
- **Verificación final:** una vez elegidos los nudos, el resultado se verifica con las 22 500 curvas completas y los 999 puntos. De ahí salen los valores de la Sección 3.8. Por eso pueden diferir levemente de los de este punto: por ejemplo, el error de y_2 con los nudos adoptados es 2,19 % en 500 puntos y 2,24 % en 999.

(b) Cómo se calcula la media del peor 1 % (CVaR 99 %), paso a paso Se parte de un juego de nudos $k = (k_1, \ldots, k_5)$ fijo. Se toman como ejemplo los nudos adoptados, $k = (0{,}8669;\ 1{,}0135;\ 1{,}0942;\ 1{,}1273;\ 1{,}1472)$.

1. **Ajustar cada curva.** A cada una de las 2532 curvas y_i se le calcula su ajuste MCO con esos nudos, $c_i = A^{+} y_i$.
2. **Medir el error de cada curva.** Para cada curva se calcula su error punto a punto relativo al rango (Paso 1):

$$e_i = \frac{\max_\lambda |y_i(\lambda) - (Ac_i)(\lambda)|}{\max_\lambda y_i - \min_\lambda y_i} \times 100 \ \ [\,\%], \qquad i = 1, \ldots, 2532.$$

   El resultado es una lista de 2532 números, uno por curva.
3. **Ordenar la lista de mayor a menor.** Se reordenan los errores de modo que el primero sea el más grande:

$$e_{(1)} \ \geq \ e_{(2)} \ \geq \ \cdots \ \geq \ e_{(2532)}.$$

   El subíndice entre paréntesis indica el *puesto* en ese ranking: $e_{(1)}$ es el error de la curva peor ajustada, $e_{(2)}$ el de la segunda peor, y $e_{(2532)}$ el de la mejor ajustada.
4. **Contar cuántas curvas forman el "peor 1 %".** Es $m = \lfloor n/100 \rfloor = \lfloor 2532/100 \rfloor = 25$ curvas, donde $\lfloor \cdot \rfloor$ es la parte entera.
5. **Promediar los errores de esas m curvas,** es decir, los de los puestos 1 a 25:

$$\mathrm{CVaR}_{99}(k) = \frac{1}{m} \sum_{p=1}^{m} e_{(p)} = \frac{e_{(1)} + e_{(2)} + \cdots + e_{(25)}}{25}.$$

El nombre CVaR (*conditional value at risk*, valor en riesgo condicional) proviene de la gestión de riesgo financiero. Allí mide la pérdida media en el peor 1 % de los escenarios (Rockafellar y Uryasev, 2000); aquí los "escenarios" son las curvas y la "pérdida" es el error de ajuste.

La Tabla 3 muestra el ranking real con los nudos adoptados, y la Fig. 5 lo grafica completo.

Tabla 3: Ranking de las 2532 curvas del conjunto de optimización según su error punto a punto, con los nudos adoptados (500 puntos). Las "sintéticas" se identifican por su índice dentro de las 22 500 del espacio de trabajo.

Puesto p	Curva	Error $e_{(p)}$
1	curva límite y_2	2,19 %
2	sintética n.º 17440	2,02 %
3	sintética n.º 15379	1,88 %
4	sintética n.º 20028	1,81 %
5	sintética n.º 17547	1,78 %
⋮	⋮	⋮
25	sintética n.º 11969	1,63 %
26	sintética n.º 19889	1,63 %
⋮	⋮	⋮
1267 (mitad)	sintética n.º 6958	1,22 %
⋮	⋮	⋮
2532 (última)	sintética n.º 20032	0,43 %
CVaR 99 % = promedio de los puestos 1 a 25		**1,72 %**
Máximo = error del puesto 1		2,19 %
Promedio de las 2532 curvas		1,20 %

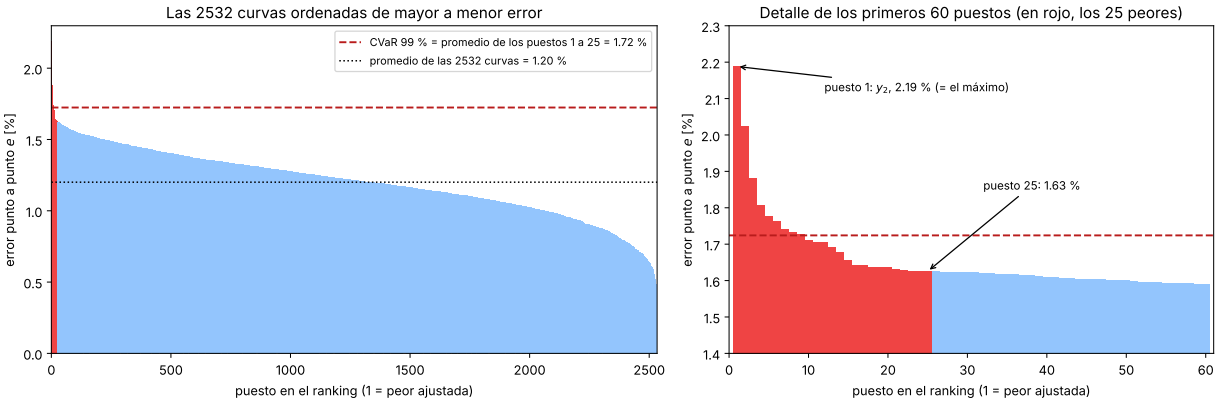


Figura 5: Izquierda: errores de las 2532 curvas del conjunto de optimización, ordenados de mayor a menor (una barra por curva). Derecha: detalle de los primeros 60 puestos; en rojo, los 25 que forman el peor 1 %. La línea discontinua roja es su promedio (CVaR 99 %); la punteada negra, el promedio de todas las curvas.

Cómo se lee.

- La curva peor ajustada es y_2, con 2,19 %.
- Las 25 peores tienen errores entre 1,63 y 2,19 %, y su promedio, el CVaR, es 1,72 %.
- Ninguno de los 31 sujetos reales está entre esas 25: todos ajustan mejor que la cola.
- La mitad de las curvas tiene error menor que 1,22 %.

Por construcción, $e_{(1)} \geq \mathrm{CVaR}_{99} \geq e_{(25)}$: el CVaR nunca supera al máximo y nunca es menor que el error del puesto 25.

(c) Las dos alternativas: el máximo o el CVaR Ambas miden la cola de peores casos, que es lo que importa para el criterio de diseño (Paso 2):

- **El máximo** es $e_{(1)}$, el error de *una sola* curva, la peor. Minimizarlo es el minimax "puro".
- **El CVaR 99 %** es el promedio de las 25 peores. Sigue siendo una medida de peor caso, porque las 2507 curvas restantes no intervienen, pero no depende de una curva sola.

Para decidir entre las dos se hizo el siguiente experimento.

(d) El experimento: mover un solo nudo

1. Se fijan cuatro nudos en sus valores adoptados: $k_1 = 0{,}8669$, $k_2 = 1{,}0135$, $k_3 = 1{,}0942$ y $k_5 = 1{,}1472$.
2. El nudo 4 se prueba en 140 posiciones equiespaciadas entre $k_4 = 1{,}112$ y $k_4 = 1{,}141$.
3. En cada posición se calculan los 2532 errores e_i (como en el apartado b) y se registran tres cosas:

   (I) el máximo $e_{(1)}$;

   (II) *cuál* es la curva que ocupa el puesto 1;

   (III) el CVaR 99 %.

La Fig. 6 muestra el máximo (violeta) y el CVaR (rojo) en función de k_4.

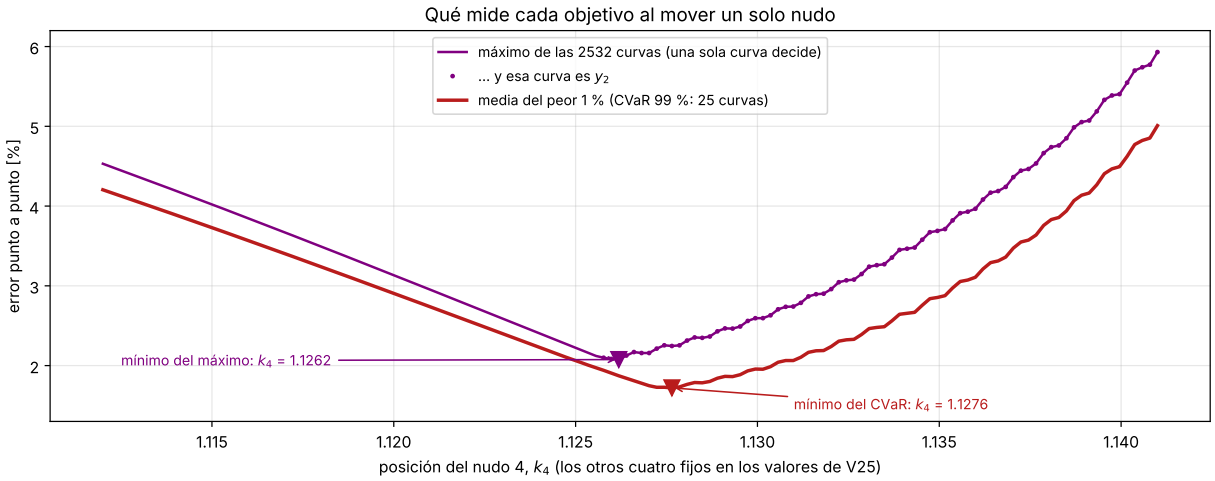


Figura 6: Experimento del apartado (d): al mover el nudo 4 con los demás fijos, error de la peor curva (violeta) y promedio de las 25 peores (CVaR 99 %, rojo). Los puntos violeta marcan las posiciones en que la peor curva es y_2. Los triángulos marcan el mínimo de cada criterio. Las pequeñas ondulaciones vienen de la discretización: cuando k_4 cruza un punto de la grilla, el quiebre de la poligonal pasa a otro intervalo.

(e) Resultados del experimento **1. En la zona del óptimo, el máximo es el error de una sola curva, y_2.** En 74 de las 140 posiciones (53 %), la curva del puesto 1 es y_2. Esto ocurre en todas las posiciones con $k_4 \geq 1{,}1258$, que es justamente la zona donde están los óptimos. Ahí el máximo de las 2532 curvas es, literalmente, el error de y_2: las otras 2531 curvas no influyen en ese número. Minimizar el máximo equivale, en esa zona, a elegir k_4 para que y_2 ajuste lo mejor posible.

2. Los dos criterios eligen nudos distintos. La Tabla 4 compara los dos óptimos del experimento y los nudos adoptados.

Tabla 4: Comparación de los criterios en el experimento del apartado (d) (500 puntos). La última columna son los nudos adoptados, que surgen de optimizar los cinco nudos a la vez con el CVaR.

	Mínimo del máximo	Mínimo del CVaR	Nudos adoptados
k_4	1,1262	1,1276	1,1273
Puesto 1: error de y_2	**2,08 %**	2,25 %	2,19 %
Puesto 2: segunda peor curva	2,02 %	2,05 %	2,02 %
Promedio de los puestos 1 a 25 (CVaR)	1,88 %	**1,72 %**	1,72 %
Promedio de las 2532 curvas	1,215 %	1,219 %	1,201 %

Con el criterio del máximo, y_2 baja de 2,25 % a 2,08 %, pero el promedio de las 25 peores curvas sube de 1,72 % a 1,88 %. Es decir, **se mejora una curva a costa del resto de la cola**. El promedio de todas las curvas prácticamente no cambia (1,215 frente a 1,219 %): la diferencia entre los criterios está solo en la cola. El CVaR acepta que y_2 quede algo peor a cambio de que mejoren las 25 peores en conjunto.

3. El máximo tiene un mínimo anguloso. El máximo es, en cada posición de k_4, el mayor de 2532 errores, y cada uno de ellos varía de forma aproximadamente suave con k_4 (salvo las pequeñas ondulaciones de la discretización).

- A la izquierda del óptimo ($k_4 < 1{,}1258$), la peor curva es otra, cuyo error *baja* al aumentar k_4.
- A la derecha, la peor es y_2, cuyo error *sube* al aumentar k_4.

El mínimo del máximo cae justo donde esas dos curvas intercambian el puesto 1, y en ese punto la pendiente cambia de signo bruscamente: el gráfico tiene forma de "V", con un quiebre sin derivada. El CVaR, al promediar 25 curvas, suaviza esos quiebres.

(f) Conclusión Se adopta el CVaR 99 % como medida de la cola por tres razones:

1. No depende de una sola curva: reparte el criterio entre las 25 peores.
2. Sigue siendo un criterio de peor caso: solo cuentan las curvas de la cola.
3. Es más suave que el máximo, lo que facilita la búsqueda.

Con cualquiera de los dos criterios, todas las curvas quedan lejos del 3 %: la elección afecta la robustez del diseño, no su cumplimiento.

3.4.4. Paso 4: el número de condición, cond(A)

Sin ninguna restricción, el optimizador tendería a *juntar* nudos en la zona de mayor curvatura, cerca de 1,16, porque más quiebres juntos siguen mejor la curva. Esto tiene un costo.

Qué mide cond(A). Se normaliza cada columna de A para que su máximo valga 1 y se calculan sus **valores singulares** $s_1 \geq \cdots \geq s_N \geq 0$. Toda matriz se puede escribir como $A = U\Sigma V^{\mathsf{T}}$ (descomposición en valores singulares, SVD), donde Σ es diagonal y sus elementos son los s_j. Cada s_j es el factor por el que la matriz estira un vector en una dirección principal: s_1 es el mayor estiramiento y s_N el menor. Un s_N muy chico indica que existe una combinación de columnas que la matriz casi anula (Trefethen y Bau, 1997, Lecturas 4, 5 y 12). Entonces

$$\text{cond}(A) = s_1/s_N.$$

Si dos columnas se parecen mucho (dos nudos muy próximos dan dos rampas casi iguales), una combinación de ellas casi se anula, s_N se hace chico y cond(A) crece. La normalización hace que cond(A) dependa solo de los nudos, no de las pendientes ni de C_{LAM}.

Por qué importa. El MCO resuelve $c = A^{+}y$. Un error δy en la curva (ruido de medición, o la diferencia entre la arteria real y el modelo) produce un error en las láminas acotado por

$$\frac{\|\delta c\|}{\|c\|} \lesssim \operatorname{cond}(A)\,\frac{\|\delta y\|}{\|y\|}.$$

Con $\operatorname{cond}(A)$ grande, ruidos chicos en la curva dan cambios grandes en las láminas: por ejemplo $+3$ láminas de un material y -3 del vecino, que casi se cancelan en la curva. Ese diseño no es confiable para fabricar. Además, a la red le cuesta aprender una función tan sensible.

La Fig. 7 lo muestra acercando k_5 a k_4:

- **cond(A):** con la separación adoptada ($k_5 - k_4 = 0{,}0199$) vale 18,5. Llega al umbral 25 con una separación de 0,0122, y con 0,0005 vale 541.
- **Láminas (panel derecho):** un ruido de 0,1 kPa en la curva produce un desvío de 0,032 láminas con los nudos adoptados, y de 0,72 láminas con los nudos casi pegados.
- **El otro extremo:** separar demasiado k_5 también empeora. El nudo del material 5 queda tan cerca de 1,16 que casi no tiene puntos donde actuar.

Cómo se impone en la optimización. Se suma una penalización:

$$\text{pen}(k) = 50 \cdot \text{máx}\,(0,\ \operatorname{cond}(A) - (\texttt{UMBRAL_COND} - 1)).$$

Vale cero mientras $\operatorname{cond}(A) < 24$ (con el umbral por defecto, 25). Pasado 24, cada décima de $\operatorname{cond}(A)$ suma 5 puntos al objetivo, mucho más que cualquier mejora posible del error, que es del orden de 0,1 puntos. En la práctica funciona como una **restricción**: el óptimo nunca pasa de 24. El margen de una unidad garantiza que $\operatorname{cond}(A) < 25$ estrictamente, que es lo que verifica la Celda 3. Con 6 bases la restricción queda *activa*: el óptimo sin restricción juntaría más los nudos, y queda exactamente en $\operatorname{cond}(A) = 24{,}0$.

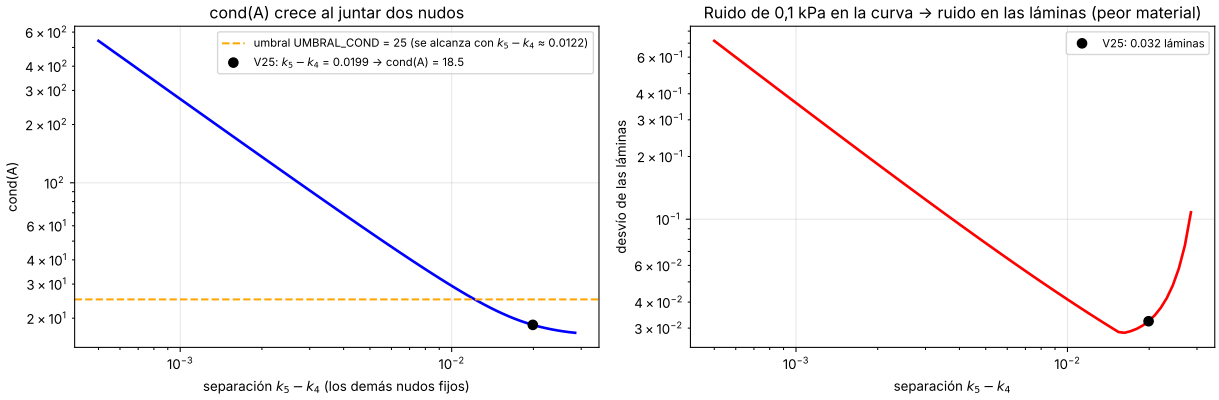


Figura 7: Izquierda: $\operatorname{cond}(A)$ al acercar el nudo 5 al 4 (escalas logarítmicas). Derecha: desvío de las láminas del peor material ante un ruido blanco de 0,1 kPa en la curva ($\sigma\,\|A_j^{+}\|$, con $C_{LAM} = 10$). El punto negro marca los nudos adoptados.

3.4.5. Paso 5: la función objetivo completa J

Juntando los pasos, los nudos minimizan

$$J(k) = \underbrace{\text{CVaR}_{99}(e_1, \ldots, e_n)}_{\text{peor 1 \%}} + \underbrace{0{,}25 \cdot \overline{\text{NRMSE}}}_{\text{desempate}} + \underbrace{50 \cdot \text{máx}\,(0, \operatorname{cond}(A) - 24)}_{\text{restricción de cond}(A)}$$

Tabla 5: Los tres términos de J.

Término	Qué mide	Por qué ese peso
CVaR_{99}	Media de los errores punto a punto de las 25 peores curvas (%)	Es el objetivo principal: la cola del criterio de diseño. Peso 1.
$0{,}25 \cdot \overline{\mathrm{NRMSE}}$	Error cuadrático medio relativo al rango, promediado sobre todas las curvas (%)	Desempata: entre dos juegos con cola parecida, prefiere el que ajusta mejor en promedio. Es chico (el NRMSE medio ronda 0,45 %) para no competir con la cola.
$50 \cdot \max(0, \mathrm{cond} - 24)$	Exceso de cond(A) sobre 24	Hace de restricción dura (ver Paso 4).

Conjunto de curvas sobre el que se evalúa J: el conjunto de optimización de $n = 2532$ curvas definido en el Paso 3, apartado (a): 2500 del espacio de trabajo, los 31 sujetos de entrenamiento e y_2, en 500 puntos. El resultado final se verifica con las 22 500 curvas y los 999 puntos.

Restricciones geométricas. Además de cond(A):

- nudos separados al menos 0,004;
- el último a 0,004 o más de $\lambda_{max} = 1{,}16$ (si no, ese material no actúa en el dominio);
- el primero por encima de 0,6.

Si un punto las viola, $J = 1000$, un valor que el optimizador descarta.

3.5. El optimizador: Nelder–Mead

Qué es. El método de **Nelder–Mead** (Nelder y Mead, 1965), también llamado *simplex descendente*, es un método de **optimización numérica**: busca el mínimo de una función de varias variables. Solo necesita poder *evaluar* la función en un punto: no usa derivadas ni gradientes, y no supone ninguna forma particular de la función.

- **No es un método de mínimos cuadrados.** Aquí cumple el papel de lazo exterior (recuadro al comienzo de esta sección), y en cada evaluación de J se hacen los ajustes MCO.
- Hay una descripción accesible en Press et al. (2007, Sec. 10.5); sus propiedades de convergencia están en Lagarias et al. (1998).

Por qué este método. En resumen: J no tiene derivadas útiles y tiene pocas variables, y Nelder–Mead solo necesita evaluarla. La justificación detallada, con la comparación frente a otros optimizadores, está en la Sección 3.6.

Cómo funciona. Con N nudos, trabaja con un *simplex* de $N + 1$ puntos: un triángulo si $N = 2$, un tetraedro si $N = 3$. En cada iteración:

1. Ordena los vértices por su valor de J: el mejor (M), el segundo peor (S) y el peor (P).
2. Calcula el centro de todos los vértices salvo el peor, y **refleja** el peor a través de ese centro: el punto R, el "espejo" de P.
3. Si R es el mejor de todos, prueba ir el doble de lejos: **expansión** (E).
4. Si R no mejora lo suficiente, prueba un punto intermedio: **contracción** (C_e por fuera o C_i por dentro).
5. Si nada mejora, achica todo el simplex hacia el mejor vértice.
6. Reemplaza el peor vértice por el punto nuevo y repite, hasta que el simplex se achica por debajo de 10^{-5} en λ y en J.

El simplex "rueda" cuesta abajo por el paisaje de J, se estira en las direcciones buenas y se encoge al llegar al fondo.

La Fig. 8 lo muestra en dos dimensiones, moviendo solo k_3 y k_4:

- parte de un triángulo en (1,076; 1,106), donde $J = 85{,}2$;
- en 38 iteraciones (75 evaluaciones de J) llega a (1,0939; 1,1273), con $J = 1{,}83$;
- ese punto prácticamente coincide con los nudos adoptados, (1,0942; 1,1273).

En la Celda 3 se hace lo mismo en las N dimensiones a la vez.

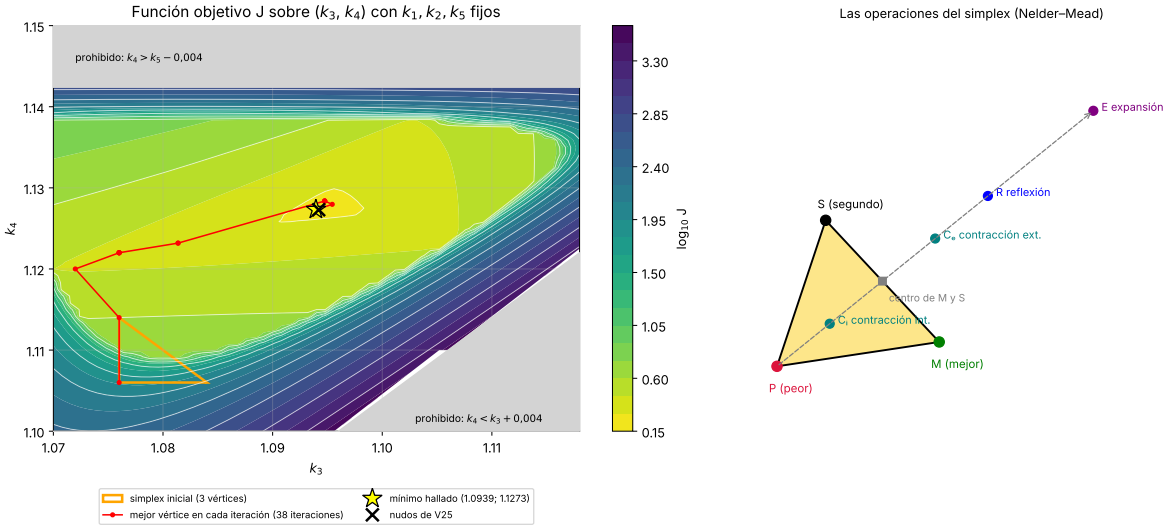


Figura 8: Izquierda: mapa de $\log_{10} J$ sobre (k_3, k_4) con k_1, k_2, k_5 fijos en los valores adoptados; en gris, las regiones prohibidas. Naranja, el simplex inicial; rojo, el mejor vértice en cada iteración; estrella, el mínimo hallado; cruz, los nudos adoptados. Derecha: las operaciones de una iteración sobre un triángulo.

Desde dónde parte. La búsqueda se corre desde cada uno de los dos puntos de partida de la Sección 3.3, y se conserva el resultado de menor J. Cada búsqueda tarda unos segundos.

3.6. Por qué Nelder–Mead y no otro optimizador

Elegir un optimizador depende de las características del problema. Esta sección describe esas características, revisa las familias de métodos disponibles y compara seis de ellos sobre la misma función objetivo.

(a) Características del problema. Se busca el mínimo de $J(k)$, donde $k = (k_1, \ldots, k_N)$ son los nudos:

1. **Pocas variables:** de 4 a 6 nudos.
2. **No hay fórmula para las derivadas de J,** y además J no es derivable en muchos puntos:
   - el error de cada curva es un *máximo* sobre los puntos de la grilla;
   - el CVaR depende de un *ordenamiento* de las curvas;
   - las bases usan $\max(0, \lambda - k)$, y las penalizaciones usan $\max(0, \cdot)$.

   Cada una de esas operaciones introduce quiebres.
3. **Pequeñas ondulaciones** por la discretización: cuando un nudo cruza un punto de la grilla, J cambia levemente (Fig. 6). Una derivada aproximada numéricamente sobre esas ondulaciones da direcciones engañosas.
4. **J no es una suma de cuadrados.** Es un criterio de peor caso (el CVaR) más penalizaciones.
5. **Restricciones simples:** separación mínima entre nudos y rango permitido, tratadas como penalización.

6. **Evaluación barata:** unos 10 ms por evaluación de J, de modo que se pueden hacer miles de evaluaciones.

(b) Familias de optimizadores. La Tabla 6 resume las familias de métodos disponibles, qué requiere cada una y si sirve para este problema.

Tabla 6: Familias de métodos de optimización y su aplicabilidad a la elección de los nudos.

Familia (ejemplos)	Qué requiere	Aplicabilidad aquí
Mínimos cuadrados lineales (MCO)	Incógnitas que entren en forma lineal	Sirve para las láminas (lazo interior), no para los nudos, que entran en forma no lineal.
Mínimos cuadrados no lineales (Gauss–Newton, Levenberg–Marquardt; nudos libres: Jupp, 1978; Golub y Pereyra, 1973)	Objetivo = suma de cuadrados de residuos derivables	No aplica: J es un criterio de peor caso, no una suma de cuadrados. Además, minimizaría el error *promedio*, no la cola.
Programación lineal o convexa (minimax como problema lineal)	Problema convexo en las incógnitas	Es convexo en las láminas con los nudos fijos, pero no en los nudos.
Métodos con gradiente (descenso por gradiente, Newton, BFGS, L-BFGS-B; Nocedal y Wright, 2006)	Derivadas de J, o una aproximación por diferencias finitas	Poco confiables: J tiene quiebres y ondulaciones, y el gradiente aproximado engaña (ver la comparación).
Locales sin derivadas (Nelder–Mead, 1965; Powell, 1964; búsqueda por patrones, Hooke y Jeeves, 1961)	Solo evaluar J	Adecuados: toleran quiebres y funcionan bien con pocas variables. Encuentran mínimos locales.
Globales sin derivadas (evolución diferencial, Storn y Price, 1997; recocido simulado; algoritmos genéticos)	Solo evaluar J, pero muchas más veces	Adecuados y más exhaustivos, a un costo de cómputo varias veces mayor.

(c) Comparación empírica. Se minimizó la misma J (5 bases), con los seis métodos de la Tabla 7:

- los métodos locales parten de los nudos iniciales de la regla geométrica (Sección 3.3);
- Nelder–Mead se corrió además desde los 5 puntos de partida que usa el cuaderno;
- la evolución diferencial, que es global, busca en todo el rango permitido: $k_1 \in [0{,}6;\ 0{,}98]$ y los demás nudos en $[1{,}00;\ 1{,}156]$.

El costo se mide en *evaluaciones de* J, que no depende de la computadora. Cada resultado se verificó después sobre las 22 500 curvas y los 999 puntos.

Tabla 7: Comparación de optimizadores sobre la misma función objetivo J (5 bases). CVaR y error máximo, verificados sobre las 22 500 curvas del espacio de trabajo.

Método	Evaluaciones de J	J final	CVaR 99 %	Error máx.	cond(A)	Nudos obtenidos
Evolución diferencial (global)	10 350	**1,810**	1,73 %	2,08 %	17,8	0,8588; 1,0229; 1,0945; 1,1276; 1,1472
Nelder–Mead, 5 puntos de partida	**1 680**	**1,823**	1,75 %	2,06 %	18,5	0,8679; 1,0135; 1,0942; 1,1273; 1,1472
Powell	3 025	1,824	1,76 %	2,05 %	17,5	0,9070; 1,0230; 1,0945; 1,1276; 1,1475
Nelder–Mead, 1 punto de partida	277	1,873	1,81 %	2,26 %	18,6	0,8712; 1,0150; 1,0934; 1,1265; 1,1467
BFGS (gradiente por diferencias finitas)	504	1,952	1,91 %	2,25 %	18,5	0,8600; 1,0100; 1,0937; 1,1271; 1,1481
L-BFGS-B (gradiente por diferencias finitas)	978	1,992	1,94 %	2,43 %	19,4	0,8600; 1,0100; 1,0926; 1,1251; 1,1461

(d) Qué muestra la comparación.

1. **La evolución diferencial encuentra el mejor** J (1,810), y sirve como referencia del óptimo global. Necesita 10 350 evaluaciones.
2. **Nelder–Mead con 5 puntos de partida** llega a $J = 1{,}823$, un 0,7 % por encima del óptimo global, con 6 veces menos evaluaciones. Sobre el espacio completo la diferencia es despreciable: CVaR de 1,75 frente a 1,73 %, y máximo de 2,06 frente a 2,08 %.
3. **Nelder–Mead desde un solo punto de partida** se queda en un mínimo local ($J = 1{,}873$). Por eso el cuaderno lo arranca desde varios puntos (Sección 3.7).
4. **Los métodos con gradiente fallan como se esperaba.** BFGS y L-BFGS-B prácticamente no mueven k_1 ni k_2 desde el punto de partida (0,86 y 1,01). Su gradiente, aproximado por diferencias finitas, es nulo o engañoso en las zonas planas y con quiebres de J. Terminan con el peor J y el mayor error máximo.
5. **Powell** llega a un J similar al de Nelder–Mead con 5 puntos de partida, pero con casi el doble de evaluaciones, y es menos confiable. Con el criterio que incluye el término de signo de las láminas, Powell queda último ($J = 2{,}24$), mientras que Nelder–Mead con 5 puntos de partida queda a menos del 1 % de la evolución diferencial (1,83 frente a 1,82).

(e) Conclusión. Se usa Nelder–Mead con varios puntos de partida por cuatro razones:

1. **No necesita derivadas** y tolera los quiebres y ondulaciones de J, donde los métodos con gradiente fallan.
2. **Funciona bien con pocas variables** (4 a 6). Su debilidad conocida, la pérdida de eficacia en problemas de muchas dimensiones, no aplica.
3. **Con 5 puntos de partida llega a menos del 1 % del óptimo global** con unas 6 veces menos evaluaciones que la evolución diferencial: unos 30 s frente a 2 min.
4. **Es simple, estándar y reproducible:** está implementado en SciPy y no tiene parámetros que ajustar.

Limitaciones. Nelder–Mead no tiene garantía general de convergencia: existen funciones en las que se detiene en un punto que no es mínimo (McKinnon, 1998). Además encuentra mínimos locales. Ambas limitaciones se controlan con los varios puntos de partida y con la verificación contra un método global, que se hizo en esta sección. Si en el futuro el problema creciera (más bases o criterios más complejos), la evolución diferencial es la alternativa natural, a un costo de cómputo mayor.

3.7. Robustez respecto del punto de partida

Como Nelder–Mead encuentra un mínimo *local*, un punto de partida distinto podría llevar a nudos distintos. Para verificar que no es así, la búsqueda se repitió desde 6 puntos de partida elegidos al azar para cada número de bases:

- k_1 al azar entre 0,80 y 0,95;

- los demás nudos al azar entre 1,00 y 1,155.

Resultados de las 6 corridas:

- **Percentil 99 del error** en el espacio de trabajo: las corridas difieren en menos de 0,03 puntos (5 bases: entre 1,683 y 1,692 %; 4 bases: entre 3,00 y 3,03 %; 6 bases: idénticas).
- **Error máximo:** varía algo más, porque depende de una sola curva. Con 5 bases queda entre 2,00 y 2,26 %, siempre por debajo del 3 %.
- **Nudos:** el que más varía es k_1, entre 0,87 y 0,91. Está fuera del dominio y casi no afecta el error, porque el paisaje de J es plano en esa dirección.

La base obtenida no depende, en la práctica, del punto de partida.

3.8. Resultados: 4, 5 o 6 bases

Tabla 8: MCO con los nudos de referencia del cuaderno, evaluado en las 22 500 curvas del espacio de trabajo y en los 41 sujetos (999 puntos).

Bases	Nudos	cond(A)	Media	CVaR 99	Máx.	Cumplen 3 %	Sujetos	$e(y_2)$
4	0,8835; 1,0269; 1,1080; 1,1416	11,6	2,20	3,13	3,83	98,96 %	40/41	2,99
5	0,8669; 1,0135; 1,0942; 1,1273; 1,1472	18,5	1,22	1,74	2,07	100 %	41/41	2,24
6	0,8669; 1,0210; 1,0758; 1,1139; 1,1380; 1,1518	24,0	1,07	1,51	1,67	100 %	41/41	1,70

- **4 bases no alcanzan**: aun con los mejores nudos, el 1 % de las curvas queda por encima del 3 % (máximo 3,83 %), y un sujeto real tampoco cumple. La franja nueva, que llega a 60 kPa, exige más quiebres.
- **5 bases** cumplen con margen: el máximo es 2,07 %, a casi un punto del criterio. Es la configuración adoptada.
- **6 bases** bajan el máximo a 1,67 %, pero con cond(A) en el límite: el sexto quiebre solo se puede poner muy cerca de otro. La ganancia (0,4 puntos) probablemente no justifica un material más.

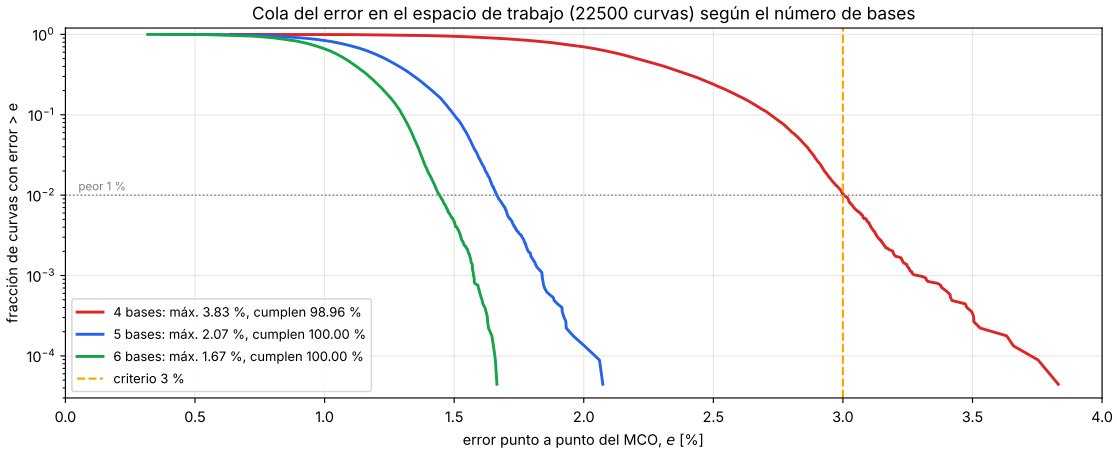


Figura 9: Fracción de curvas del espacio de trabajo con error mayor que e, para 4, 5 y 6 bases (escala logarítmica). La línea gris marca el peor 1 %; la naranja, el criterio de diseño.

3.9. Qué garantiza la base elegida y qué no

Con 5 bases y los nudos adoptados, el ajuste MCO *sin condiciones* cumple las dos propiedades buscadas en todo el espacio de trabajo:

- **Precisión:** el 100 % de las 22 500 curvas y los 41 sujetos cumplen el criterio del 3 %, con un máximo de 2,07 % (Tabla 8).
- **Estabilidad:** $\text{cond}(A) = 18{,}5 < 25$. Un ruido de 0,1 kPa en la curva produce un desvío de 0,03 láminas (Paso 4).

Lo que el criterio no impone: el signo de las láminas. El MCO libre puede dar alguna lámina negativa, que no es fabricable. Con los nudos adoptados:

- **Espacio de trabajo:** 21 631 de las 22 500 curvas (96,1 %) tienen todas las láminas ≥ 0. En las 869 restantes, el valor negativo cae en el material 1 en el 95 % de los casos y en el material 2 en el resto. La mediana del valor negativo es $-0{,}44$ láminas; el 10 % más negativo está por debajo de $-1{,}13$, y el mínimo es $-2{,}37$ (con $C_{LAM} = 10$).
- **Sujetos de Masson:** 35 de 41 tienen todas las láminas ≥ 0. Los 6 restantes tienen un valor negativo chico (Tabla 9).

Tabla 9: Sujetos con alguna lámina negativa en el MCO libre, y efecto de imponer $c \geq 0$ (mínimos cuadrados no negativos, NNLS).

Sujeto	Lámina negativa	Error máx. MCO libre	Error máx. con $c \geq 0$	NRMSE libre → con $c \geq 0$
NT04	$c_2 = -0{,}04$	0,65 %	0,74 %	0,19 → 0,25 %
NT16	$c_1 = -0{,}43$	1,60 %	1,93 %	0,63 → 0,69 %
HT10	$c_1 = -0{,}87$	1,26 %	1,88 %	0,45 → 0,88 %
HT16	$c_1 = -0{,}29$	1,44 %	1,49 %	0,54 → 0,56 %
HT20	$c_1 = -0{,}45$	1,23 %	1,61 %	0,46 → 0,63 %
HT25	$c_1 = -0{,}57$	1,56 %	1,78 %	0,61 → 0,66 %

Interpretación. Los negativos aparecen casi siempre en el material 1, cuyo nudo (0,8669) está antes del dominio y aporta la pendiente inicial. Un $c_1 < 0$ indica una curva muy plana al comienzo en relación con su crecimiento posterior: el MCO compensa restando pendiente al primer material.

- En los 6 sujetos, imponer $c \geq 0$ mantiene el criterio, con un máximo de 1,93 %.
- En el espacio de trabajo, el 99,1 % de las 869 curvas afectadas también lo mantiene.

Consecuencia para el objetivo. Con la base elegida, el ajuste sin condiciones garantiza precisión y estabilidad, y da láminas no negativas en el 96 % del espacio de trabajo y en 35 de los 41 sujetos. Para cubrir también el signo sin volver a usar condiciones en el ajuste, el paso natural es incorporarlo al criterio de la base: agregar a J una penalización por láminas negativas, de modo que la búsqueda de nudos prefiera bases en las que el MCO libre dé $c \geq 0$. El ajuste seguiría siendo $c = A^{+}y$, sin restricciones.

3.10. Cómo se usa en el cuaderno

En la Celda 0:

- `N_BASES` (4, 5 o 6): el número de materiales. Cambiarlo requiere reentrenar.
- `NUDOS_REF`: los nudos de referencia por número de bases (los de la Tabla 8).
- `UMBRAL_COND` (25 por defecto): la cota de $\text{cond}(A)$.
- `OPTIMIZAR_NUDOS` (`False` por defecto): `True` fuerza la re-optimización.

La Celda 3 sigue esta lógica:

1. Toma `NUDOS_REF[N_BASES]` y calcula $\text{cond}(A)$.
2. Si $\text{cond}(A) \geq$ `UMBRAL_COND`, si no hay nudos para ese número de bases, o si `OPTIMIZAR_NUDOS = True`, imprime "`Optimizando N nudos...`" y corre el método de esta sección.

3. Imprime la línea `NUDOS_REF[N] = [...]` para copiar en la Celda 0. Conviene copiarla: así la próxima corrida no re-optimiza y, al cargar una red entrenada (`ENTRENAR = False`), los nudos coinciden. La Celda 8 lo verifica.
4. Verifica $\text{cond}(A) <$ `UMBRAL_COND`; si no se cumple, se detiene con un mensaje.
5. Calcula las pendientes máximas `PEND_MAX` con los nudos finales (Sección 4).

Ejemplo verificado: con `UMBRAL_COND = 15` y 5 bases, los nudos de referencia (cond 18,5) no cumplen. La Celda 3 los re-optimiza sola y propone (0,9479; 1,0409; 1,1009; 1,1376; 1,1560), con $\text{cond}(A) < 15$.

Resumen del método en seis líneas

1. Proponer nudos iniciales (regla geométrica, o los de la Celda 0).
2. Con esos nudos, ajustar por MCO cada curva del conjunto de optimización (2500 del espacio de trabajo, 31 sujetos de entrenamiento e y_2).
3. Medir el error de cada curva: residuo máximo dividido por su rango.
4. Promediar los errores de las 25 curvas peor ajustadas (el peor 1 %): eso es el CVaR.
5. Sumar 0,25× el NRMSE medio y la penalización si $\text{cond}(A) > 24$: eso es J, la calificación de esos nudos.
6. Nelder–Mead propone nudos nuevos y se repiten los pasos 2 a 5, hasta que J no baja más.

4. Pendientes máximas y escala de las láminas

Una vez fijados los nudos, la pendiente de cada lámina se elige para que la curva más exigente del espacio de trabajo use exactamente C_{LAM} láminas de cada material. Con las líneas sin escalar $G_j(\lambda) = \text{máx}(0, \lambda - k_j)$:

$$\texttt{PEND_MAX}_j = \text{máx}\Big\{ \max_{y \in \text{espacio}} (G^+ y)_j,\ \max_{\text{sujetos en la franja}} (G^+ y)_j,\ (G^+ y_2)_j \Big\},$$

y la pendiente de una lámina es $S_j = \texttt{PEND_MAX}_j / C_{LAM,j}$. En V25 se calcula sola en la Celda 3. Con 50 000 curvas aparecen curvas que piden más del material 2 y algo menos del 5 (Tabla 10). La curva y_2 es la que fija el máximo del material 4: usa exactamente 10,0 láminas.

Tabla 10: Pendientes máximas [kPa] y bases de V25 con $C_{LAM} = 10$. $K = S_j R_{ref} k_j^2$ es la rigidez de membrana de una lámina ($R_{ref} = 3{,}42$ mm); $E = K/t$ con $t = 0{,}1$ mm. Las dos últimas columnas son las láminas MCO de las curvas límite.

Material	k_j	`PEND_MAX` V24	`PEND_MAX` V25	$A_j(\lambda)$ V25	K [N/m]	E [MPa]	y_1	y_2
1	0,8669	47,0	47,5	$4{,}75\,\text{máx}(0, \lambda - 0{,}8669)$	12,2	0,12	−0,36	9,01
2	1,0135	183,4	204,1	$20{,}41\,\text{máx}(0, \lambda - 1{,}0135)$	71,7	0,72	1,79	3,65
3	1,0942	243,6	242,0	$24{,}20\,\text{máx}(0, \lambda - 1{,}0942)$	99,1	0,99	0,63	8,65
4	1,1273	495,7	495,1	$49{,}51\,\text{máx}(0, \lambda - 1{,}1273)$	215,3	2,15	0,65	10,00
5	1,1472	869,2	815,0	$81{,}50\,\text{máx}(0, \lambda - 1{,}1472)$	367,0	3,67	0,57	5,80

$\text{cond}(A) = 18{,}47$ (umbral 25). MCO: $e(y_1) = 0{,}91$ %, $e(y_2) = 2{,}24$ %.

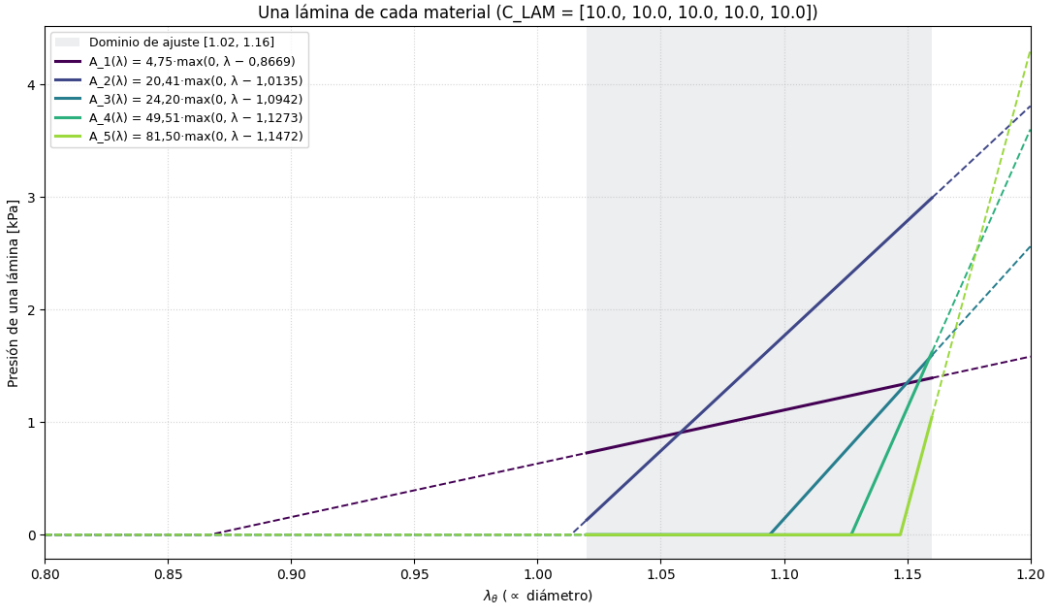


Figura 10: Una lámina de cada material en V25 ($C_{LAM} = 10$). Continua: dominio de ajuste; punteada: la misma fórmula fuera de él.

Recordatorio: C_{LAM} es una elección de unidades. Cambiar $C_{LAM,j}$ cambia la rigidez de una lámina y, en proporción inversa, el número de láminas. El producto $c_j S_j$, que es la pendiente de la capa, no cambia, y tampoco cambian la curva, el error ni la rigidez total de cada capa. No requiere reentrenar: las salidas de la red se reescalan por $C_{LAM,j}/C_{LAM,red}$. La Sección 6 lo comprueba con los resultados reales de V24 y V25.

5. Resultados de la red V25

5.1. Entrenamiento

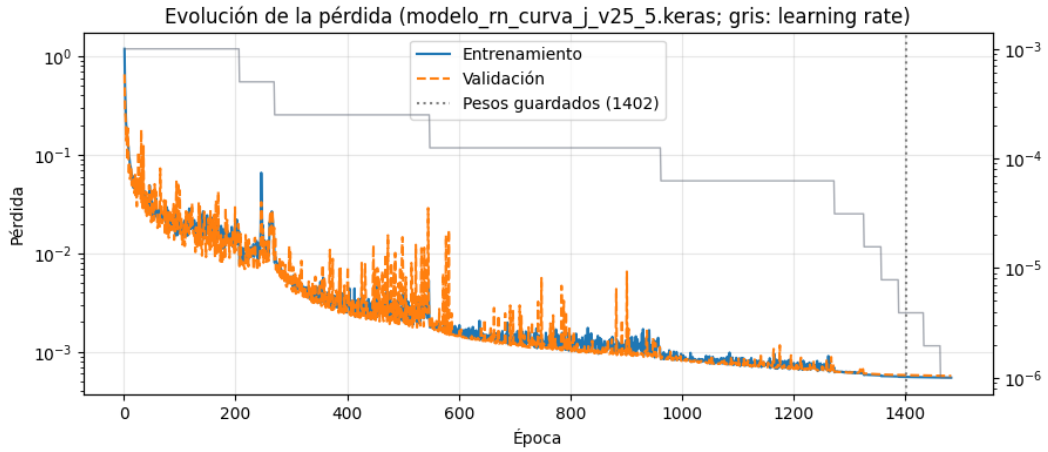


Figura 11: Pérdida de entrenamiento y validación de V25 (gris: learning rate). Se guardan los pesos de la época 1402.

Con el mismo espacio de trabajo y nudos, y solo más curvas, la pérdida de validación bajó de 0,000823 (V24) a 0,000579 (V25), un 30 % menos. Entrenamiento y validación terminan juntos (0,000556 y 0,000579), sin sobreajuste. Los picos de validación entre las épocas 550 y 900 son el ruido normal con learning rate de 10^{-4}.

5.2. Evaluación en test (10 000 curvas)

- **Láminas negativas:** la red las da en el 22,4 % de las curvas y el MCO en el 33,8 % (V24: 32,9 % y 34,5 %). La diferencia está en las familias pura y combinada. Ahí el MCO reparte el ruido de la curva entre los materiales ausentes, con valores chicos de ambos signos, y la red, empujada por el término de crosstalk, ahora los deja casi en cero. Los negativos grandes (mínimo −1,76, frente a −1,74 del MCO) son reales y la red los respeta.
- **Pulido:** red + MCO llega al óptimo exacto, con residuo de las ecuaciones normales $\leq 1{,}7 \times 10^{-15}$.

5.3. Los 41 sujetos y las curvas medias

El *exceso* mide cuánto peor ajusta la red que el óptimo MCO: exceso = $\mathrm{NRMSE}_{red}/\mathrm{NRMSE}_{óptimo} - 1$. Un exceso de +1,5 % significa que el error típico de la red es 1,015 veces el del óptimo. Las demás medidas (R^2, $|\Delta c|$, mediana) se definen en el Glosario (Apéndice C).

Tabla 11: Red sola frente al óptimo MCO en los sujetos de Masson. Exceso = NRMSE red / NRMSE óptimo − 1.

	V22 ($C_{LAM} = 10$)	V24	**V25**
Exceso, 41 sujetos	+2,66 %	+2,12 %	**+1,48 %**
Exceso en test (media / mediana)	+1,53 % / –	+3,38 / +1,8 %	**+1,50 / +0,1 %**
Peor sujeto de test	NT08, +3,6 %	NT08, +13,5 %	NT02, +10,0 %
Error punto a punto máx. de la red	1,63 %	1,74 %	1,69 %
máx $\lvert\Delta c\rvert$ red – MCO [láminas]	–	0,043	**0,029**
Cumplen ≤ 3 % con la red	40–41/41	41/41	**41/41**

Por grupo, el exceso es +3,3 % en los normotensos (casi todo por NT02) y +0,4 % en los hipertensos. El exceso de NT02, aunque alto en términos relativos, equivale a 0,03 láminas y a un error punto a punto menor al 1,7 %.

Tabla 12: Curvas medias de Masson: exceso de RMSE de la red sobre el óptimo.

	Mean Young	Mean Old	Mean NT	Mean HT
V24	+1,79 %	+0,87 %	+5,57 %	+1,33 %
V25	**+0,67 %**	**+0,25 %**	**+0,15 %**	+2,04 %

5.4. Test por familia

Familias del dataset: “de bases” y “fisiológicas”

Las siete familias de curvas del dataset se agrupan en dos clases:

- **Familias de bases** (pura y combinada): curvas armadas sumando láminas de las propias bases, es decir, rampas y poligonales con quiebres en los nudos. No se parecen a una arteria. Le enseñan a la red qué hace cada material por separado y a no mezclarlos (crosstalk). Como son combinaciones exactas de las bases, su óptimo MCO es casi perfecto, y un error pequeño de la red da un exceso relativo alto.
- **Familias fisiológicas** (constitutiva, amplia, uniforme, exponencial y pacientes): curvas suaves con forma J, como las de una arteria. Salen de la ley constitutiva de Masson con parámetros derivados de los sujetos de entrenamiento (mezclados, perturbados o sorteados), de otra ley exponencial ajustada a esos sujetos, o directamente de los 31 sujetos de entrenamiento con ruido. Representan lo que la red recibe al diseñar un injerto, y por eso con ellas se juzga su desempeño.

“Fisiológica” indica que la curva proviene de un modelo de arteria, no de las bases. No significa que cada curva corresponda a una arteria medida: la familia amplia extrapola parámetros y la exponencial no se filtra por la franja y_1–y_2.

Tabla 13: Test de V25 por familia (10 000 curvas). Criterio evaluado contra la curva sin ruido.

Familia	n	NRMSE óptimo	NRMSE red	Exceso	Exceso V24	Red cumple 3 %	Red máx.
pura	2000	0,300	0,388	+29,3 %	+33,4 %	99,30 %	4,25 %
combinada	2000	0,248	0,323	+30,1 %	+70,8 %	99,45 %	10,57 %
constitutiva	2000	0,724	0,728	+0,59 %	+1,12 %	99,95 %	3,16 %
amplia	1500	0,731	0,739	+1,14 %	+4,02 %	99,80 %	3,96 %
exponencial	1000	0,743	0,749	+0,80 %	+3,28 %	99,90 %	3,35 %
uniforme	1000	0,741	0,746	+0,70 %	+2,14 %	100 %	2,08 %
pacientes	500	0,726	0,728	+0,27 %	+0,79 %	100 %	1,64 %

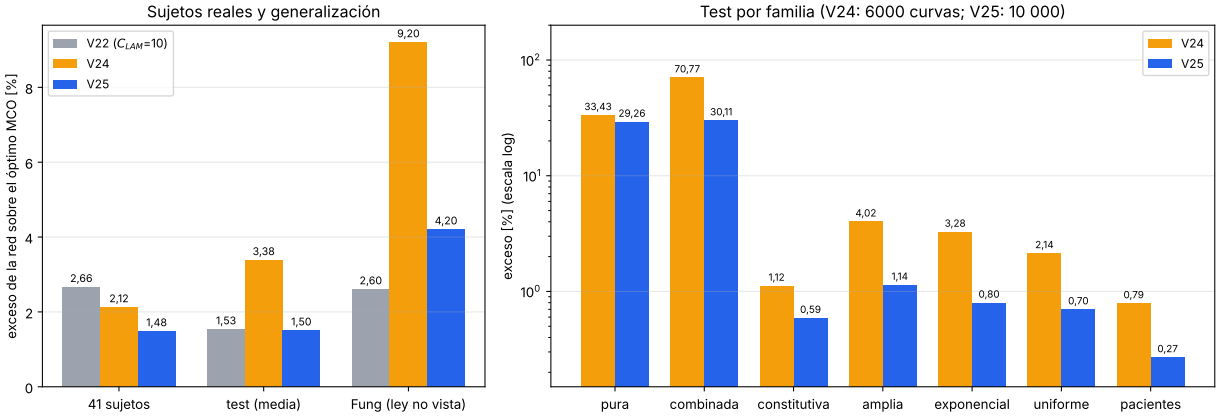


Figura 12: Izquierda: exceso de la red en los sujetos reales y en la ley de Fung, para V22, V24 y V25. Derecha: exceso por familia en test, V24 frente a V25 (escala logarítmica).

- **Todas las familias mejoran.** La combinada se reduce a menos de la mitad, y las fisiológicas quedan entre +0,3 y +1,1 %: la red está prácticamente sobre el óptimo.
- **Desapareció el fallo de V24** en una curva blanda casi lineal de la familia amplia (19,2 %). El peor caso de esa familia es ahora 3,96 %.

- **Las pocas curvas fisiológicas que superan el 3 %** (1 de 2000 en la constitutiva, 3 de 1500 en la amplia y 1 de 1000 en la exponencial) son casos donde el MCO ya da entre 2,1 y 2,5 %. Todas quedan cerca del límite.
- **El peor caso de la combinada** (10,6 %) es una curva casi plana de 0,03 kPa hasta el nudo 3. La red pone en cero ese tramo: es el mismo efecto que reduce los negativos. Es una curva sin sentido físico, de menos de 1 kPa en total.

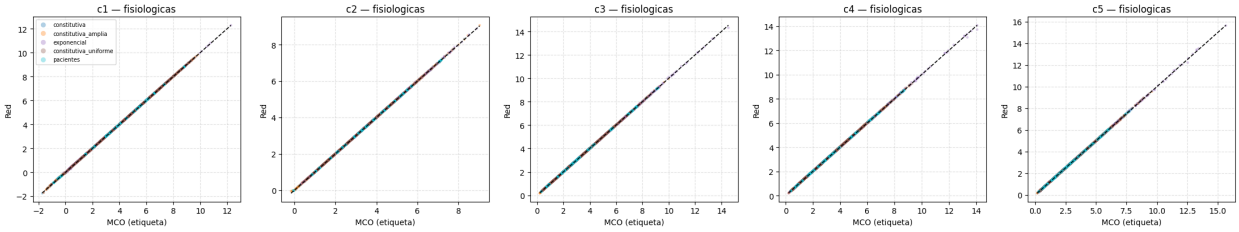


Figura 13: Láminas de la red frente a las del MCO en las familias fisiológicas de test (6000 curvas). $R^2 \geq 0{,}99987$ en los cinco materiales; error medio de 0,006 a 0,015 láminas.

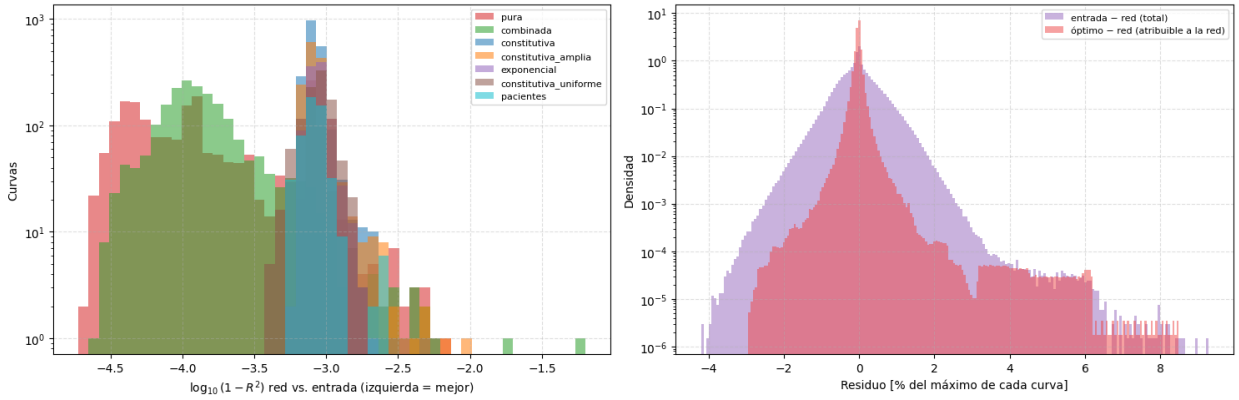


Figura 14: Izquierda: $\log_{10}(1 - R^2)$ de la red por familia. Derecha: residuo total (violeta) y la parte atribuible a la red (óptimo − red, rojo), en % del máximo de cada curva. El cuerpo de la parte atribuible a la red está dentro de ±2 % (en V24, ±4 %).

5.5. Generalización a una ley nunca vista y control de clase

Con 300 curvas tipo Fung (con ruido del 1 %; el 0,8 % de sus puntos queda fuera de y_1–y_2), el NRMSE de la red es 1,17 % y el del óptimo 1,13 %: un exceso de +4,2 %.

- El exceso era +9,2 % en V24, +2,6 % en V22 y +3,7 % en V21.
- El peor R^2 de la red sube de 0,9695 a 0,9777, frente a un óptimo de 0,9972.

Las 20 000 curvas adicionales recuperaron más de la mitad de la generalización perdida en V24. La distancia que queda con V22 es razonable: V22 trabajaba en una franja más angosta (26 sujetos, hasta ≈ 50 kPa) y V25 cubre los 41 hasta 60 kPa.

El control de clase no cambia: acepta todas las curvas de Fung y los 41 sujetos, y rechaza el 95,7 % de las curvas moduladas que dejan de ser J.

5.6. Reproducción de láminas aisladas

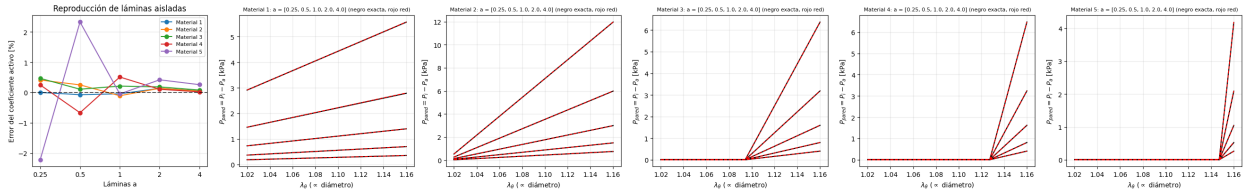


Figura 15: Entrada $y = a\,A_j$ (una sola base, $a = 0{,}25$ a 4 láminas); la respuesta exacta es $c = a\,e_j$. Izquierda: error del coeficiente activo; resto: curvas exactas (negro) y de la red (rojo).

- **Crosstalk:** el máximo en los materiales ausentes es 0,0024 láminas.
- **Coeficiente activo, materiales 1 a 4:** el error es como mucho ±0,67 %; el material 1 queda prácticamente exacto.
- **Material 5:** con 0,25 y 0,5 láminas el error es de −2,2 y +2,3 %. En V24 había un sesgo positivo; en V25 el error cambia de signo, sin sesgo, pero con algo más de amplitud. La causa es la de siempre: esa base solo actúa en el último 9 % del dominio, y con 0,25 láminas su señal es una rampa de 0,26 kPa. En valor absoluto son 0,012 láminas; desde 1 lámina el error es $\leq 0{,}4$ %.

6. Diseño: la curva media de los hipertensos

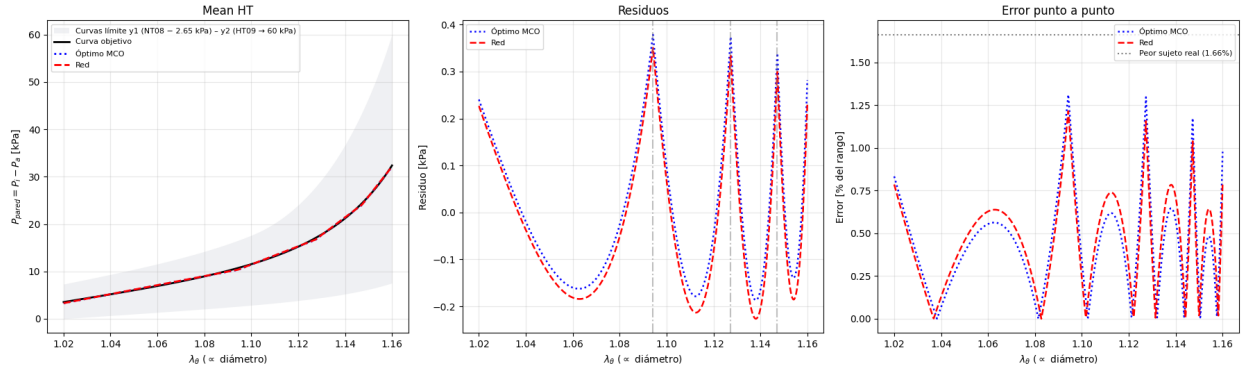


Figura 16: Mean HT: curva, ajuste MCO y red (izquierda), residuos (centro; líneas verticales en los nudos) y error punto a punto (derecha).

Para Mean HT, la red difiere del MCO en 0,018 láminas como máximo; en total da 18,40 láminas contra 18,36. Su error punto a punto es menor que el del MCO (1,22 % contra 1,31 %), y el NRMSE apenas mayor (0,530 contra 0,519 %). Los picos del residuo caen en los nudos 3, 4 y 5: es el piso de error de las bases, no de la red.

Tabla 14: Injerto para Mean HT ($C_{LAM} = 10$). Las láminas y la rigidez de una lámina cambian de V24 a V25 porque cambió `PEND_MAX`; la rigidez total de cada capa es idéntica.

Material	Láminas V24	Láminas V25	K 1 lámina V24 [N/m]	K 1 lámina V25 [N/m]	K total V24 = V25 [N/m]
1	3,87	3,83	12,1	12,2	46,72
2	4,18	3,75	64,4	71,7	269,10
3	3,98	4,01	99,8	99,1	397,05
4	3,62	3,63	215,5	215,3	780,86
5	2,96	3,15	391,4	367,0	1156,68
Total	18,60	18,36			

Esta tabla es la comprobación experimental de la invariancia de escala: el dataset más grande cambió la unidad (la lámina), pero el injerto físico es el mismo. El radio de reposo es 0,8669 R_{ref} = 2,97 mm, y la presión de pared en $\lambda = 1{,}16$ es 32,1 kPa (241 mmHg).

7. Conclusiones y próximos pasos

1. **Las nuevas curvas límite** cubren los 41 sujetos de Masson y llevan el espacio de trabajo hasta 60 kPa, sin modificar las curvas reales ni salir del dominio medido [1,02; 1,16].
2. **El método minimax** (CVaR 99 % + desempate por NRMSE + restricción de cond(A), con Nelder–Mead) elige nudos con los que el MCO cumple el 3 % en todo el espacio de trabajo con 5 bases (máximo 2,07 %). Con 4 bases no alcanza; con 6 mejora poco y con cond(A) en el límite. El cuaderno controla cond(A) y re-optimiza solo cuando hace falta.
3. **V25 es la mejor red hasta ahora:**
   - 41/41 sujetos cumplen el 3 %, con exceso de +1,48 % y mediana de +0,1 % en test;
   - todas las familias mejoran;
   - desaparece el fallo de V24 en la familia amplia;
   - Fung baja a +4,2 %;
   - el injerto de Mean HT es idéntico al de V24.
4. **Pendientes:**
   (a) recuperar el nivel de V22 en Fung (+2,6 %): más capacidad de la red o más variedad en las leyes sintéticas;
   (b) si interesa un tope de dilatación ante sobrepresiones, estudiar un sexto material "freno" con nudo cerca de 1,16 y láminas fijadas por un criterio de seguridad;
   (c) evaluar si 6 bases justifican un material más para el error del diseño.

A. Celdas del cuaderno V25

Celda	Contenido	Celda V24
0	Configuración (`N_BASES`, `NUDOS_REF`, `UMBRAL_COND`, `C_LAM`, ...)	0
1	Modelo de Masson, 41 sujetos y curvas límite sintetizadas	1
2	Espacio de trabajo: curvas fisiológicas sintéticas (nueva)	parte de 6
3	Bases: cond(A), nudos (minimax si hace falta) y `PEND_MAX`	2
4	Verificación de las bases sobre los 41 sujetos	3
5	Figura: láminas de las curvas límite y error de los 41 sujetos	4
6	Librerías, entrada logarítmica, métricas y predicción	5
7	Dataset: familias pura y combinada + fisiológicas	resto de 6
8	Partición y normalización (verifica nudos al cargar la red)	7
9–11	Pérdida y arquitectura, integridad, entrenamiento o carga	8–10
12–18	Evaluación en test, reconstrucción, 41 sujetos, figuras, familias, Fung, muestras	11–17
19	Diseñador de injerto	18
20	Reproducción de láminas aisladas	19
21	Las bases con su fórmula	20
22	Extrapolación fuera del dominio de ajuste	21

Los archivos de la red se guardan como `v25_N` según el número de bases (`v25_4`, `v25_5`, `v25_6`), de modo que no se pisan entre sí.

B. Datos de partida: Masson et al. (2011)

Este apéndice reúne la información del artículo de Masson et al. (2011) que usa el método, para que el documento sea autocontenido. Los autores midieron in vivo, a lo largo del ciclo cardíaco, el diámetro y la presión de la carótida común de 16 sujetos normotensos y 25 hipertensos tratados. A cada sujeto le ajustaron un modelo constitutivo de la pared arterial, y publicaron los parámetros en las Tablas 2 y 4 del artículo (Tablas 15 y 16 de este informe). Las curvas de presión de pared de este trabajo se calculan con esos parámetros y con las ecuaciones que siguen.

B.1. Ley constitutiva

La pared se modela como un material incompresible, con una energía de deformación formada por tres contribuciones:

- **Elastina**, neo-Hookeana (el modelo elástico isótropo más simple, cuya energía es proporcional a $I_1 - 3$, con I_1 el primer invariante de la deformación), con módulo c.
- **Colágeno**, en cuatro familias de fibras con respuesta exponencial, con la estructura introducida por Holzapfel et al. (2000): una axial, una circunferencial y dos diagonales a $\pm\alpha$ respecto del eje. Las fibras axiales y diagonales comparten los parámetros (c_1, c_2); las circunferenciales tienen los suyos, (c_1^{circ}, c_2^{circ}).
- **Tono muscular activo**, con tensión máxima T_m y estiramientos característicos λ_0 (sin tensión activa) y λ_m (tensión máxima).

Con estiramiento axial fijo λ_z e incompresibilidad ($\lambda_r = 1/(\lambda_\theta \lambda_z)$), la diferencia de tensiones circunferencial y radial en función del estiramiento circunferencial local λ_θ es

$$\sigma_{\theta\theta} - \sigma_{rr} = c\left(\lambda_\theta^2 - \lambda_r^2\right) + \lambda_\theta^2 \sum_{k=1}^{4} c_{1,k}\, E_k\, e^{\,c_{2,k} E_k^2}\, \sin^2\varphi_k + T_m\, \lambda_\theta \left[1 - \left(\frac{\lambda_m - \lambda_\theta}{\lambda_m - \lambda_0}\right)^2\right],$$

donde $E_k = \lambda_k^2 - 1$, y para cada familia de fibras:

Familia	Ángulo φ_k (desde el eje)	Estiramiento λ_k	$c_{1,k}$	$c_{2,k}$
axial	0	λ_z	c_1	c_2
circunferencial	90°	λ_θ	c_1^{circ}	c_2^{circ}
diagonales	$\pm\alpha$	$\sqrt{\lambda_\theta^2 \sin^2\alpha + \lambda_z^2 \cos^2\alpha}$	c_1	c_2

La familia axial no contribuye a la dirección circunferencial, porque $\sin^2 0 = 0$.

B.2. Cinemática y presión de pared

La configuración de referencia libre de tensiones es un sector anular con ángulo de apertura Θ_0 y radio medio R_m. Un punto de radio R en la referencia pasa al radio r en la arteria cerrada y estirada. Por incompresibilidad,

$$R^2 = R_m^2 - \frac{\pi \lambda_z}{\Theta_0}\left(r_m^2 - r^2\right), \qquad \lambda_\theta(r) = \frac{\pi\, r}{\Theta_0\, R}, \qquad r_m = \lambda_\theta\, \frac{\Theta_0 R_m}{\pi}.$$

La abscisa de todas las curvas es el estiramiento en el radio medio, $\lambda_\theta = r_m / R_{ref}$ con $R_{ref} = \Theta_0 R_m / \pi$, proporcional al diámetro.

Del equilibrio radial resulta la presión de pared

$$P_{pared} = P_i - P_a = \int_{r_m - h}^{r_m} \frac{\sigma_{\theta\theta} - \sigma_{rr}}{r}\, dr,$$

con $h = 0{,}6\,\text{mm}$, calculada con la regla del trapecio (integración numérica que aproxima el área bajo la curva por trapecios) sobre 60 puntos radiales. P_{pared} no depende de la presión perivascular P_a.

Validación. Las Figs. 5a y 7a de Masson grafican la tensión circunferencial $\sigma_{\theta\theta}$ en r_m, de la que se descuenta el término perivascular $a\,e^b$ con los parámetros a, b de las tablas. Reconstruida así con las ecuaciones de arriba, reproduce las curvas medias publicadas con un RMSE de 0,6 a 0,9 kPa (1,2 a 1,7 % de su valor medio): Mean Young 1,7 %, Mean Old 1,5 %, Mean NT 1,2 % y Mean HT 1,4 %.

B.3. Figuras 5a y 7a: de la tensión a la presión de pared

Las Figs. 17 y 18 muestran, a la izquierda, las figuras originales del artículo, con la tensión circunferencial (90–150 kPa en los sujetos más rígidos). A la derecha están las presiones de pared de los mismos sujetos calculadas con la ley constitutiva, que son las curvas objetivo de este trabajo. La presión es del orden de la tensión por h/r ($\approx 0{,}16$), por eso sus valores son unas seis veces menores. Las curvas originales cubren solo el rango de λ medido en cada sujeto; las de la derecha se evalúan en todo el dominio [1,02; 1,16].

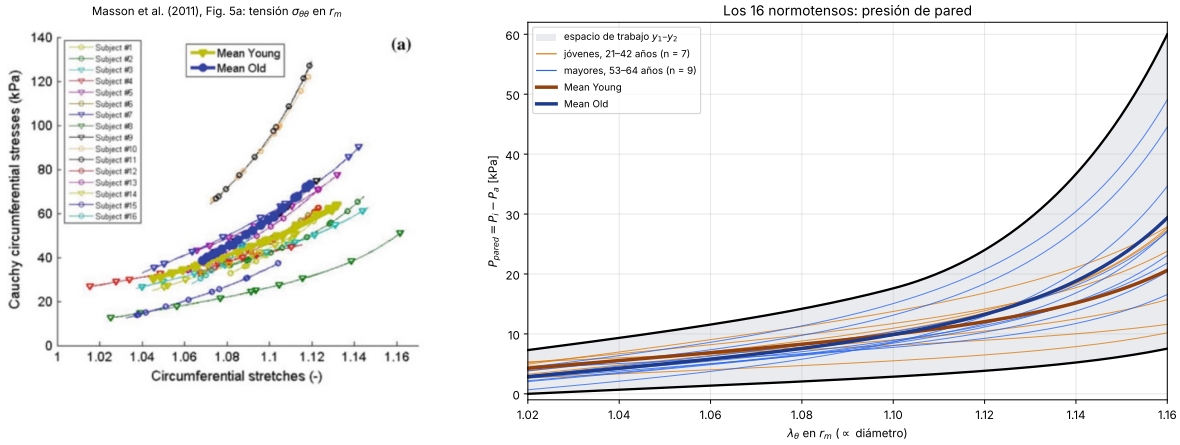


Figura 17: Izquierda: Fig. 5a de Masson et al. (2011), tensión circunferencial de los 16 normotensos y medias de jóvenes y mayores (reproducida del artículo). Derecha: presión de pared de los mismos sujetos con la ley constitutiva y el espacio de trabajo y_1–y_2.

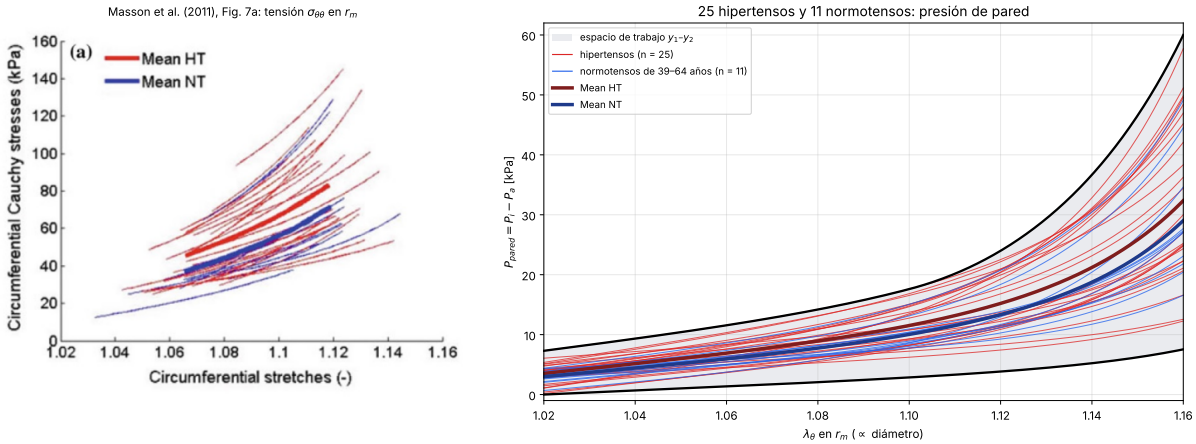


Figura 18: Izquierda: Fig. 7a de Masson et al. (2011), tensión circunferencial de los 25 hipertensos y de los 11 normotensos de edad comparable, con sus medias (reproducida del artículo). Derecha: presión de pared de los mismos sujetos con la ley constitutiva y el espacio de trabajo y_1–y_2.

B.4. Tablas 2 y 4: parámetros de los 41 sujetos

Las Tablas 15 y 16 reproducen los parámetros publicados:

- **Geometría:** R_m y Θ_0 son el radio medio y el ángulo de apertura de la configuración libre de tensiones, y λ_z es el estiramiento axial in vivo.
- **Elastina:** c.
- **Colágeno:** c_1 y c_2 (fibras axiales y diagonales), c_1^{circ} y c_2^{circ} (fibras circunferenciales), y α, el ángulo de las fibras diagonales.
- **Tono activo:** T_m, λ_0 y λ_m.
- **Presión perivascular:** a y b.

Los sujetos marcados con † son los 10 reservados para test.

Tabla 15: Tabla 2 de Masson et al. (2011): parámetros de los 16 sujetos normotensos. †: sujeto reservado para test. RMSE: error del ajuste del modelo a los datos, informado por los autores.

Sujeto	Edad [años]	Sexo	R_m [mm]	Θ_0 [°]	λ_z	c [kPa]	c_1 [kPa]	c_2	c_1^{circ} [kPa]	c_2^{circ}	α [°]	T_m [kPa]	λ_0	λ_m	a [kPa]	b	RMSE [kPa]
NT01	62	F	4,261	128,7	1,11	29,82	9,44	14,14	16,13	15,11	65,74	39,73	0,96	1,70	0,122	3,52	0,174
NT02†	60	M	4,691	128,9	1,08	20,42	8,47	13,10	14,16	15,12	44,46	41,84	0,68	1,92	0,126	3,40	0,288
NT03	31	M	4,305	132,2	1,09	27,23	10,34	13,10	7,01	12,82	48,62	43,37	0,82	1,65	0,139	3,57	0,131
NT04	31	M	4,672	133,9	1,10	23,59	6,58	11,77	6,38	10,69	32,04	39,81	0,68	1,59	0,118	3,53	0,146
NT05	34	F	4,203	130,1	1,10	35,68	13,62	13,18	13,38	13,17	50,72	50,07	0,86	1,62	0,103	3,58	0,123
NT06	53	F	3,957	130,1	1,11	33,37	11,38	13,63	13,30	14,26	57,14	46,59	0,95	1,69	0,093	3,44	0,269
NT07	21	F	3,827	132,0	1,10	44,28	21,79	13,17	8,27	12,73	51,15	53,58	0,92	1,62	0,111	3,58	0,215
NT08†	25	M	4,856	133,2	1,07	23,25	6,34	12,93	8,11	13,17	42,93	31,90	0,82	1,77	0,173	3,57	0,367
NT09	42	F	4,506	129,5	1,10	34,90	16,14	13,58	19,64	13,89	57,21	47,01	0,93	1,65	0,084	3,55	0,209
NT10†	55	M	4,770	129,1	1,10	38,57	36,31	13,31	56,88	13,61	54,22	46,36	0,89	1,66	0,006	3,75	0,652
NT11†	64	M	5,566	129,5	1,10	34,89	40,16	13,45	66,88	13,53	54,54	41,12	0,85	1,79	0,005	3,23	0,375
NT12	60	F	4,876	130,1	1,09	33,94	10,78	13,95	12,79	15,42	60,97	45,77	0,93	1,73	0,099	3,37	0,362
NT13	61	F	4,924	130,6	1,09	35,15	17,69	13,43	18,40	13,22	55,04	45,59	0,94	1,66	0,085	3,51	0,240
NT14	39	F	3,539	131,5	1,09	28,97	8,22	13,13	19,02	13,16	50,22	41,30	0,89	1,67	0,105	3,53	0,262
NT15	58	F	3,922	132,4	1,08	26,71	15,79	13,36	16,68	13,11	53,60	35,32	0,95	1,71	0,166	3,60	0,302
NT16	60	M	5,718	129,7	1,10	27,79	28,23	13,46	57,77	13,63	55,73	36,50	1,05	1,77	0,141	3,58	0,283

Tabla 16: Tabla 4 de Masson et al. (2011): parámetros de los 25 sujetos hipertensos tratados. †: sujeto reservado para test. RMSE: error del ajuste del modelo a los datos, informado por los autores.

Sujeto	Edad [años]	Sexo	R_m [mm]	Θ_0 [°]	λ_z	c [kPa]	c_1 [kPa]	c_2	c_1^{circ} [kPa]	c_2^{circ}	α [°]	T_m [kPa]	λ_0	λ_m	a [kPa]	b	RMSE [kPa]
HT01	68	M	4,965	130,9	1,10	35,91	12,57	14,08	15,52	14,91	67,18	48,42	0,99	1,66	0,098	3,50	0,300
HT02	54	M	4,927	129,8	1,10	38,20	16,40	13,20	16,44	13,20	51,11	52,44	0,86	1,62	0,137	3,58	0,213
HT03†	64	F	4,869	129,5	1,10	36,01	14,55	13,96	18,35	14,48	62,66	47,02	1,00	1,74	0,113	3,62	0,419
HT04	58	F	4,574	131,2	1,09	22,42	8,57	13,03	6,43	13,36	46,38	38,53	0,81	1,68	0,099	3,51	0,346
HT05†	62	F	4,779	130,1	1,10	48,19	35,06	13,23	43,19	13,03	53,24	52,86	0,91	1,63	0,033	3,56	0,218
HT06	66	F	5,062	129,1	1,10	39,78	37,75	13,35	60,89	13,45	56,01	46,44	0,91	1,64	0,004	3,54	0,349
HT07	54	F	4,298	129,6	1,11	50,45	25,51	13,32	39,43	13,24	53,47	64,91	0,93	1,66	0,078	3,72	0,341
HT08	63	F	4,436	129,0	1,10	34,44	30,62	13,29	60,33	13,21	54,67	44,94	0,93	1,65	0,084	3,56	0,518
HT09	68	M	5,090	128,2	1,12	51,48	33,77	13,17	44,26	13,49	51,83	66,41	0,84	1,62	0,023	3,55	0,277
HT10	55	F	4,300	129,0	1,10	37,04	12,32	14,13	15,04	14,93	65,14	48,19	1,04	1,71	0,114	3,47	0,270
HT11	69	M	5,545	131,2	1,08	29,64	9,76	13,23	9,10	15,12	48,16	37,83	0,83	1,74	0,115	3,59	0,263
HT12	54	M	5,426	131,8	1,09	32,23	17,81	13,35	14,03	12,15	53,73	44,93	0,92	1,65	0,090	3,58	0,185
HT13†	61	M	5,169	128,4	1,11	30,45	15,87	13,08	23,03	13,84	47,86	52,58	0,75	1,61	0,009	3,49	0,315
HT14†	60	M	4,640	129,9	1,10	30,43	13,74	13,45	18,01	13,35	54,90	42,43	0,91	1,66	0,088	3,52	0,158
HT15	53	M	4,649	130,4	1,10	40,83	28,98	13,36	31,16	12,62	54,44	49,57	0,93	1,65	0,085	3,63	0,311
HT16	54	M	4,713	129,6	1,10	45,26	29,27	14,00	33,48	14,82	67,16	67,68	1,02	1,65	0,039	3,52	0,194
HT17	53	M	5,043	130,0	1,10	37,25	39,18	13,24	66,29	13,15	54,90	48,26	0,91	1,64	0,099	3,60	0,252
HT18	52	M	4,922	129,7	1,10	29,28	10,50	13,21	19,76	13,39	50,96	46,42	0,85	1,63	0,094	3,56	0,200
HT19†	57	F	4,270	130,3	1,10	33,49	14,47	13,22	17,35	13,27	53,18	46,18	0,90	1,64	0,097	3,55	0,228
HT20	61	F	5,143	129,2	1,10	40,09	15,72	14,09	16,78	14,83	65,17	53,40	1,04	1,70	0,100	3,47	0,265
HT21	57	F	4,881	129,9	1,10	35,31	14,57	13,26	15,58	13,30	52,07	48,97	0,87	1,63	0,094	3,57	0,442
HT22	44	F	4,170	131,0	1,10	55,25	35,78	13,23	19,51	12,55	52,36	59,58	0,93	1,61	0,097	3,61	0,335
HT23	51	M	4,827	130,6	1,08	30,77	12,80	13,60	41,10	14,20	49,79	41,06	0,87	1,90	0,094	3,56	0,337
HT24†	65	M	4,565	129,6	1,10	38,91	25,76	13,20	35,01	13,20	51,94	50,28	0,87	1,62	0,043	3,58	0,212
HT25	67	F	4,718	129,2	1,10	40,29	31,78	13,75	60,40	14,29	63,50	46,06	1,03	1,72	0,025	3,46	0,412

C. Glosario

Términos técnicos usados en el informe, en orden alfabético. La columna de la derecha indica dónde se desarrollan o una referencia que los explica en detalle.

Término	Definición	Dónde / referencia
Adam	Algoritmo de entrenamiento de redes neuronales: una variante del descenso por gradiente que adapta el tamaño del paso de cada peso.	Kingma y Ba (2015)
BFGS / L-BFGS-B	Métodos de optimización que usan el gradiente de la función (aquí aproximado por diferencias finitas) para elegir la dirección de descenso.	Nocedal y Wright (2006)
Diferencias finitas	Aproximación numérica de una derivada: $[J(k+h) - J(k)]/h$ con h pequeño. Falla si la función tiene quiebres u ondulaciones.	Nocedal y Wright (2006)
Evolución diferencial	Método global sin derivadas que mantiene una población de candidatos y los combina para explorar todo el rango de las variables.	Storn y Price (1997)
C_{LAM}	Número de láminas con que la curva más exigente del espacio de trabajo usa cada material. Fija la rigidez de una lámina: es una elección de unidades.	Secc. de pendientes
cond(A)	Número de condición: cociente entre el mayor y el menor valor singular de la matriz de bases normalizada. Si es grande, pequeños errores en la curva producen grandes cambios en las láminas.	Paso 4; Trefethen y Bau (1997)
Crosstalk	Láminas que la red asigna a un material que no está presente en la curva ("fuga" de un material a otro). Se penaliza en la pérdida.	Resultados
CVaR 99 %	Promedio de los errores del 1 % de curvas peor ajustadas. Es la medida de la cola de errores que minimiza el método minimax.	Paso 3; Rockafellar y Uryasev (2000)
Curvas límite y_1, y_2	Curvas inferior y superior que definen la franja del espacio de trabajo.	Secc. 2
Ecuaciones normales	$A^{\mathsf{T}}Ac = A^{\mathsf{T}}y$: la condición que cumple la solución de MCO.	Lawson y Hanson (1974)
Época	Una pasada completa del entrenamiento por todas las curvas de entrenamiento.	Goodfellow et al. (2016)
Error punto a punto e	Mayor diferencia, en valor absoluto, entre la curva y su ajuste en los puntos de la grilla, dividida por el rango de la curva (en %). El criterio de diseño exige $e \leq 3$ %.	Paso 1
Espacio de trabajo	Conjunto de curvas generadas con la ley de Masson que quedan entre y_1 e y_2.	Secc. 2
Estandarizar	Restar la media y dividir por el desvío estándar, para que todas las variables tengan escala comparable.	
Exceso	Cuánto peor ajusta la red que el óptimo MCO: NRMSE de la red / NRMSE óptimo − 1.	Resultados
Familias de bases / fisiológicas	Grupos de curvas del dataset: poligonales armadas con las bases, o curvas con forma de arteria generadas con leyes constitutivas o tomadas de pacientes.	Test por familia
Grilla	Los 999 valores equiespaciados de λ entre 1,02 y 1,16 en los que se evalúan todas las curvas (paso $\approx$ 0,00014).	Secc. 2
Learning rate	Tasa de aprendizaje: tamaño de cada corrección de los pesos de la red durante el entrenamiento.	Goodfellow et al. (2016)
Ley de Laplace	En un tubo de pared delgada, la tensión de membrana es igual a la presión por el radio.	
Línea truncada	Función $S\,\mathrm{máx}(0, \lambda - k)$: vale cero hasta el nudo k y crece con pendiente S desde allí. Representa una lámina de un material.	Secc. 2

Término	Definición	Dónde / referencia
Lote	Grupo de curvas (aquí 64) que la red procesa antes de cada corrección de sus pesos.	Goodfellow et al. (2016)
MCO	Mínimos cuadrados ordinarios: se eligen las láminas que minimizan la suma de los cuadrados de las diferencias entre la curva y el ajuste. Tiene solución exacta, $c = A^{+}y$.	Secc. 3; Lawson y Hanson (1974)
Mediana / percentil	La mediana deja la mitad de los casos por debajo; el percentil p deja el p % por debajo.	
Minimax	Criterio que elige los nudos para minimizar los errores de las curvas *peor* ajustadas, no el promedio.	Secc. 3
Nelder–Mead	Método de optimización numérica sin derivadas (*simplex descendente*) que busca el mínimo de una función de varias variables. Aquí busca los nudos. No es un método de mínimos cuadrados.	Secc. 3; Nelder y Mead (1965); Press et al. (2007)
NNLS	Mínimos cuadrados no negativos: MCO con la restricción de que todos los coeficientes sean ≥ 0.	Lawson y Hanson (1974)
Normalización de capa	Operación de la red que reescala las salidas de cada capa a media 0 y desvío 1, y estabiliza el entrenamiento.	Ba et al. (2016)
NRMSE	Raíz del error cuadrático medio dividida por el rango de la curva (%). Mide el error típico a lo largo de la curva.	Paso 1
Nudo (*knot*)	Valor de λ en el que una lámina empieza a aportar presión: es el quiebre de la línea truncada.	Secc. 3
Óptimo local / global	Un óptimo local es el mejor punto de su entorno; el global, el mejor de todo el rango permitido.	
Powell (método de)	Método local sin derivadas que minimiza a lo largo de direcciones sucesivas.	Powell (1964)
Parada temprana	Detener el entrenamiento cuando la pérdida de validación deja de mejorar y quedarse con los mejores pesos.	Goodfellow et al. (2016)
`PEND_MAX`	Pendiente máxima que exige el espacio de trabajo a cada capa; dividida por C_{LAM} da la pendiente de una lámina.	Secc. de pendientes
Pseudoinversa A^{+}	$(A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}$ cuando las columnas de A son independientes. Da la solución de MCO.	Trefethen y Bau (1997)
Pulido	Paso MCO aplicado a una curva para obtener el óptimo exacto, en lugar de usar la salida de la red.	Resultados
R^2	Coeficiente de determinación, $1 - \sum r_i^2 / \sum (y_i - \bar{y})^2$. Vale 1 para un ajuste perfecto.	Resultados
Red neuronal densa	Función con muchos parámetros, organizada en capas de neuronas, que transforma la entrada en la salida. Se ajusta (entrena) con datos.	Goodfellow et al. (2016)
ReLU	Función no lineal $\max(0, x)$ que aplica cada neurona.	Goodfellow et al. (2016)
Semilla	Número que inicializa el generador de números aleatorios. Con la misma semilla, los sorteos se repiten, y el resultado es reproducible.	
Simplex	Figura de $N + 1$ vértices en N dimensiones (triángulo en 2D, tetraedro en 3D) con la que trabaja Nelder–Mead.	Secc. 3
Sobreajuste	Situación en que la red memoriza las curvas de entrenamiento y empeora en curvas nuevas.	Goodfellow et al. (2016)
Test / validación / entrenamiento	Conjuntos disjuntos de curvas: ▪ entrenamiento: para ajustar los pesos; ▪ validación: para controlar el entrenamiento; ▪ test: solo para la evaluación final.	Test por familia
Valores singulares (SVD)	Factores de estiramiento de una matriz en sus direcciones principales, $A = U\Sigma V^{\mathsf{T}}$.	Trefethen y Bau (1997)

Referencias

Ba, J. L., Kiros, J. R., Hinton, G. E. (2016). Layer normalization. *arXiv:1607.06450*.

Fung, Y. C. (1993). *Biomechanics: Mechanical Properties of Living Tissues* (2.ª ed.). Springer, Nueva York.

Golub, G. H., Pereyra, V. (1973). The differentiation of pseudo-inverses and nonlinear least squares problems whose variables separate. *SIAM Journal on Numerical Analysis*, 10(2), 413–432.

Goodfellow, I., Bengio, Y., Courville, A. (2016). *Deep Learning*. MIT Press.

Holzapfel, G. A., Gasser, T. C., Ogden, R. W. (2000). A new constitutive framework for arterial wall mechanics and a comparative study of material models. *Journal of Elasticity*, 61, 1–48.

Hooke, R., Jeeves, T. A. (1961). "Direct search" solution of numerical and statistical problems. *Journal of the ACM*, 8(2), 212–229.

Jupp, D. L. B. (1978). Approximation to data by splines with free knots. *SIAM Journal on Numerical Analysis*, 15(2), 328–343.

Kingma, D. P., Ba, J. (2015). Adam: A method for stochastic optimization. *3rd International Conference on Learning Representations (ICLR)*. arXiv:1412.6980.

Lagarias, J. C., Reeds, J. A., Wright, M. H., Wright, P. E. (1998). Convergence properties of the Nelder–Mead simplex method in low dimensions. *SIAM Journal on Optimization*, 9(1), 112–147.

Lawson, C. L., Hanson, R. J. (1974). *Solving Least Squares Problems*. Prentice-Hall (reeditado por SIAM, 1995).

Masson, I., Beaussier, H., Boutouyrie, P., Laurent, S., Humphrey, J. D., Zidi, M. (2011). Carotid artery mechanical properties and stresses quantified using in vivo data from normotensive and hypertensive humans. *Biomechanics and Modeling in Mechanobiology*, 10, 867–882.

McKinnon, K. I. M. (1998). Convergence of the Nelder–Mead simplex method to a nonstationary point. *SIAM Journal on Optimization*, 9(1), 148–158.

Nelder, J. A., Mead, R. (1965). A simplex method for function minimization. *The Computer Journal*, 7(4), 308–313.

Nocedal, J., Wright, S. J. (2006). *Numerical Optimization* (2.ª ed.). Springer.

Powell, M. J. D. (1964). An efficient method for finding the minimum of a function of several variables without calculating derivatives. *The Computer Journal*, 7(2), 155–162.

Press, W. H., Teukolsky, S. A., Vetterling, W. T., Flannery, B. P. (2007). *Numerical Recipes: The Art of Scientific Computing* (3.ª ed.). Cambridge University Press. Sec. 10.5: *Downhill simplex method in multidimensions*.

Rockafellar, R. T., Uryasev, S. (2000). Optimization of conditional value-at-risk. *Journal of Risk*, 2(3), 21–41.

Storn, R., Price, K. (1997). Differential evolution: a simple and efficient heuristic for global optimization over continuous spaces. *Journal of Global Optimization*, 11, 341–359.

Trefethen, L. N., Bau, D. (1997). *Numerical Linear Algebra*. SIAM.