

Neural Network Optimization for Convex J-Curve Prediction with Physics-Informed Loss under Biomimetic Constraints

Pablo *

Departamento de Ingeniería y Ciencias de la Computación, Data Analyst

pablo@example.com

3 de septiembre de 2026

Resumen

Este artículo presenta el desarrollo, la optimización matemática y la validación científica de un aproximador robusto basado en redes neuronales informadas por la física (PINN) para resolver el problema inverso de la regresión de coeficientes en curvas convexas de tipo J sobre una base lineal continua a trozos de 5 grados de libertad. El diseño del espacio de representación se fundamenta teóricamente utilizando la Cuadratura de Gauss-Legendre de nodos óptimos, demostrando *a priori* que $N = 5$ es la dimensión mínima requerida para garantizar un error geométrico irreducible por debajo del umbral del 2%. Antes del entrenamiento, la independencia lineal de las funciones base y su estabilidad numérica ante cancelaciones se validaron formalmente mediante Descomposición en Valores Singulares (SVD), logrando acondicionar el sistema a un número de condición $\text{cond}(A) = 29,58$. Asimismo, se formuló el ajuste inverso óptimo restringido como un problema de programación cuadrática convexo resuelto bajo las condiciones de optimalidad de Karush-Kuhn-Tucker (KKT) mediante el método de región de confianza de barrera interior (*trust-constr*). La arquitectura PINN propuesta incorpora *Normalización por Capas* (LN) en sustitución de Normalización por Lotes para prevenir el suavizado espacial de los “codos” de las bases, y una pérdida híbrida con reducción de interferencia mutua (*Dynamic Pérdida de Dispersión*). El modelo PINN propuesto logra un destacado **1,2540%** de NRMSE en la exponencial límite de peor caso (superando la barrera teórica de Gauss de 1,8753%) y un promedio global en bases puras de **1,0388%** con colapso de coeficientes inactivos a cero real, logrando un acoplamiento físico fiel con inferencia en microsegundos apto para hardware de tiempo real.

Palabras clave— Redes Neuronales Informadas por la Física (PINN), Cuadratura de Gauss, Normalización por Capas, Pérdida de Dispersión, SVD, trust-constr, KKT, SLSQP, Curva J, Tiempo Real.

*Documento compilado y estructurado mediante Gemini Notebook de forma automática.

1. Metodología de Representación Funcional

1.1. Definición del Espacio Funcional de Trabajo y Envolvente Física

Para establecer un marco de consistencia física riguroso en todo el proceso de modelado y regresión, se define formalmente el espacio funcional de trabajo $\mathcal{S}$ en el cual se inscriben todas las curvas de tipo J modeladas y aproximadas por la red neuronal. Este espacio está acotado en su dominio por el intervalo:

$$0 \leq x \leq 2$$

y en su rango o amplitud operativa por las condiciones de envolvente física dadas por:

$$-2 \leq y \leq 30 \cdot e^{3,2x}$$

Donde la cota inferior $y_{\min} = -2,0$ establece un suelo físico tolerado (esencial para absorber ruidos experimentales, perturbaciones en sistemas de medición o ligeras oscilaciones transitorias), y la cota superior $y_{\max}(x) = 30 \cdot e^{3,2x}$ delimita la curva exponencial crítica de máximo crecimiento y pendiente, cuya amplitud final alcanza un pico elevado de $y_{\max}(2,0) \approx 18,055,35$ unidades. Todas las muestras de entrenamiento, validación y testeo de la red neuronal se generan de manera estrictamente controlada para permanecer contenidas dentro de este dominio operativo biomimético $\mathcal{S}$ antes de ser normalizadas y linearizadas en escala logarítmica.

1.2. Fundamentación Teórica del Espacio de Representación (Cuadratura de Gauss)

Para determinar la dimensión mínima del espacio funcional necesario sin incurrir en una selección heurística de hiperparámetros, se evaluó *a priori* la cota de error teórico irreducible en función del número de nodos. Dado que una representación por combinación lineal de N funciones base dispone de N grados de libertad, se utilizó la Cuadratura de Gauss-Legendre sobre particiones de nodos óptimos $x_i^* \in [0, 2]$ para determinar el umbral donde el error de representación se hace admisible.

La Cuadratura de Gauss-Legendre de n puntos permite aproximar el valor de una integral definida con la máxima precisión posible mediante una suma ponderada evaluada en nodos estratégicos (raíces del polinomio de Legendre $P_n(x)$):

$$\int_{-1}^1 f(x)dx \approx \sum_{i=1}^n w_i f(x_i)$$

Para evaluar el Error Cuadrático Medio (MSE) continuo entre la función exponencial real $f(x) = 30e^{2x}$ y su aproximación lineal por tramos (polilínea) $g(x)$ en el intervalo $[0, 2]$, la integral se divide en sub-regiones delimitadas por los nodos de quiebre (puntos de quiebre):

$$MSE = \frac{1}{b-a} \int_a^b [f(x) - g(x)]^2 dx$$

Al analizar el Error Cuadrático Medio Normalizado ($NRMSE$) referido al valor máximo de la curva límite superior ($y_{\max} \approx 1637,94$ para $30e^{2x}$ y $y_{\max} \approx 18055,35$ para $30e^{3,2x}$):

- **Configuración de 3 Nodos (2 tramos óptimos):** La Cuadratura de Gauss revela que el error de representación geométrico irreducible se sitúa en un $RMSE \approx 110,5$ ($NRMSE \approx 6,75\%$). Al evaluar la exponencial de máxima pendiente $30e^{3,2x}$, el error teórico *a priori* asciende a un $NRMSE \approx 7,95\%$.

- **Configuración de 5 Nodos (4 tramos óptimos):** Al incrementar el número de puntos de control a 5, la distribución de nodos óptimos se concentra hacia la derecha del dominio (donde la curvatura explota) en $x^* = [0,0000, 0,8544, 1,3606, 1,7206, 2,0000]$. En este escenario, la Cuadratura de Gauss de 3 puntos por tramo arroja una reducción marcada del error a un $RMSE \approx 26,51$ ($NRMSE \approx 1,62\%$) para la exponencial base de $2x$, y un $NRMSE \approx 1,87\%$ para la exponencial de máxima pendiente $30e^{3,2x}$. Esto representa una reducción relativa del error de representación de un 76,01 %.

Este análisis *a priori* fundamenta de manera rigurosa la elección de $N = 5$ como la dimensión óptima del espacio de representación, estableciendo que 5 nodos óptimos de Gauss definen el límite de aproximación geométrica admisible ($NRMSE < 2\%$) por debajo del cual se garantiza la fidelidad de la aproximación matemática.

1.3. Diseño y Optimización Numérica de la Base Funcional (SVD y SLSQP)

Antes de proceder con el entrenamiento del modelo de regresión, es matemáticamente imperativo garantizar la viabilidad algebraica del espacio de representación. Una vez justificada la dimensión de la base ($N = 5$), se definieron 5 funciones base lineales a trozos (rectas con quiebre):

$$\hat{y}(x) = \sum_{i=1}^5 c_i \phi_i(x)$$

Donde cada función base $\phi_j(x)$ tiene la forma de una función bisagra (*hinge function*) o ReLU desplazada que arranca con un segmento inicial compartido con ordenada al origen $y_0 = -1,360$ y pendiente $m_0 = 6,8$:

$$\phi_j(x) = \begin{cases} y_0 + m_0(x - x_0) & \text{si } x \leq \kappa_j \\ y_{\kappa_j} + m_j(x - \kappa_j) & \text{si } x > \kappa_j \end{cases}$$

La cercanía física de los nodos de quiebre (*nudos*) puede inducir colinealidad severa entre las columnas de la matriz de diseño $A \in \mathbb{R}^{201 \times 5}$. Según la teoría de funciones continuas por tramos de Carl de Boor (1978), la proximidad geométrica de los nudos hace que las columnas se aproximen linealmente, elevando drásticamente el número de condición de la matriz, lo que se traduce en cancelaciones numéricas severas por restas destructivas de coeficientes de gran magnitud durante el ajuste inverso.

Para verificar y cuantificar formalmente la independendencia lineal de estas 5 bases continuas antes del entrenamiento de la red, se aplicó la técnica de Descomposición en Valores Singulares (SVD) sobre la matriz de diseño A , calculando el número de condición de la matriz:

$$\text{cond}(A) = \frac{\sigma_{\text{máx}}}{\sigma_{\text{mín}}}$$

Donde $\sigma_{\text{máx}}$ y $\sigma_{\text{mín}}$ son el valor singular mayor y menor de la matriz A , respectivamente. Inicialmente, debido al espaciado estrecho de los nudos, el sistema exhibía un mal condicionamiento grave.

Para resolver esta inestabilidad sin alterar la tipografía lineal a trozos de las bases, se planteó un problema de optimización con restricciones no lineales donde se perturban de forma mínima los nudos (κ_j) y las pendientes post-nudo (m_j) originales para minimizar la distorsión geométrica pero imponiendo la condición estricta de salud numérica:

$$\text{mín} \sum \left(\frac{p - p_0}{\text{escala}} \right)^2 \quad \text{Sujeto a: } \text{cond}(A) \leq 30,0$$

Este problema de optimización con restricciones no lineales se resolvió mediante el algoritmo de Programación Cuadrática Sucesiva (SLSQP) detallado en Kraft (1988). Tras la convergencia y el posterior redondeo discreto a la grilla física del dominio (paso de 0,01), la base de diseño óptima y bien condicionada consolidó un número de condición final de $\text{cond}(A) = 29,58$, permaneciendo estrictamente dentro del rango de estabilidad ≤ 30 . Los parámetros óptimos resultantes son:

- **Nudos óptimos** (κ_j): [0,05, 0,45, 0,92, 1,34, 1,69]
- **Pendientes optimizadas** (m_j): [223,4, 403,9, 510,3, 679,5, 1000,0]

La estabilidad numérica lograda ($\text{cond}(A) = 29,58$) garantiza la solubilidad robusta del problema inverso bajo restricciones y evita cancelaciones numéricas severas por aproximaciones espurias.

2. Arquitectura de la Red Neuronal PINN

2.1. Preprocesamiento de Entrada y la Formulación del Techo Óptimo bajo Condiciones KKT

Debido al crecimiento de tres órdenes de magnitud de la envolvente exponencial (desde 30 en $x = 0$ hasta más de 18,000 en $x = 2,0$), una red tradicional sufriría de inestabilidad y sesgo severo. Para mitigar esto, se lineariza el rango de entrada aplicando una transformación logarítmica con un desplazamiento de seguridad para soportar el suelo físico de $y = -2,0$:

$$X_{\log} = \ln(b(x) + 2,1)$$

Posteriormente, las características de entrada $X_{\log}$ y los coeficientes objetivo de salida Y son estandarizados mediante *escalador estándar* para normalizar la escala de gradientes durante la fase de retropropagación.

Para establecer la cota de error geométrico irreducible (techo teórico) en el espacio de coeficientes biomiméticos $\mathbf{c} \in \mathbb{R}^5$ y generar los objetivos de entrenamiento, se formula el ajuste de mínimos cuadrados continuos bajo restricciones de caja no-negativas como un problema de programación cuadrática convexo. Para una curva objetivo dada $y(x)$, el problema se define como:

$$\min_{\mathbf{c}} f(\mathbf{c}) = \frac{1}{2} \|A\mathbf{c} - \mathbf{y}\|_2^2 \quad \text{sueto a:} \quad g_i(\mathbf{c}) \leq 0, \quad h_i(\mathbf{c}) \leq 0$$

Donde las restricciones de desigualdad que delimitan el poliedro de Biomímesis están dadas por $g_i(\mathbf{c}) = -c_i \leq 0$ (cota inferior de no-negatividad) y $h_i(\mathbf{c}) = c_i - c_{\text{máx}} \leq 0$ (cota superior de saturación del espacio paramétrico, con $c_{\text{máx}} = 25,0$).

El Lagrangiano de este sistema acotado se define mediante la introducción de los vectores de multiplicadores de Lagrange $\boldsymbol{\lambda} \in \mathbb{R}^5$ y $\boldsymbol{\nu} \in \mathbb{R}^5$:

$$\mathcal{L}(\mathbf{c}, \boldsymbol{\lambda}, \boldsymbol{\nu}) = \frac{1}{2} \|A\mathbf{c} - \mathbf{y}\|_2^2 - \sum_{i=1}^5 \lambda_i c_i + \sum_{i=1}^5 \nu_i (c_i - c_{\text{máx}})$$

Donde $\lambda_i \geq 0$ y $\nu_i \geq 0$ actúan como variables duales. La solución óptima $\mathbf{c}^*$ para el techo teórico del ajuste se obtiene resolviendo el sistema mediante un método de barrera de región de confianza (*trust-constr* en SciPy) que satisface de forma estricta las condiciones de optimidad de primer orden de Karush-Kuhn-Tucker (KKT):

1. **Estacionariedad (Gradiente nulo del Lagrangiano):**

$$\nabla_{\mathbf{c}} \mathcal{L}(\mathbf{c}^*, \boldsymbol{\lambda}^*, \boldsymbol{\nu}^*) = A^T(A\mathbf{c}^* - \mathbf{y}) - \boldsymbol{\lambda}^* + \boldsymbol{\nu}^* = \mathbf{0}$$

2. **Viabilidad Primaria:**

$$0 \leq c_i^* \leq c_{\text{máx}} \quad \forall i \in \{1, \dots, 5\}$$

3. **Viabilidad Dual:**

$$\lambda_i^* \geq 0, \quad \nu_i^* \geq 0 \quad \forall i \in \{1, \dots, 5\}$$

4. **Holgura Complementaria:**

$$\lambda_i^* c_i^* = 0, \quad \nu_i^* (c_i^* - c_{\text{máx}}) = 0 \quad \forall i \in \{1, \dots, 5\}$$

Este resolutor de confianza *trust-constr* garantiza que los coeficientes teóricos representen el mínimo absoluto global factible del error cuadrático, definiendo el techo analítico de aproximación continua del sistema. El truncamiento no-negativo $[\cdot]_+$ de la red neuronal PINN actúa como un homólogo directo en el grafo computacional de las condiciones de viabilidad primaria de KKT.

2.2. Formulación de la Custom Loss y Estabilización PINN

El modelado del problema inverso en redes neuronales acopladas físicamente se enfrenta clásicamente a un severo conflicto de coexistencia entre características locales (bases puras de baja amplitud) y globales (curvas exponenciales densas de alta amplitud). Las arquitecturas convencionales con Normalización por Lotes logran estabilizar los gradientes de escala global, pero el promedio de estadísticas del lote suaviza los codos de las bases e introduce interferencia destructiva. Por otro lado, la remoción completa de normalización permite aprender las esquinas de las bases, pero desestabiliza la convergencia exponencial en amplitudes grandes. Para desarticular este compromiso de Pareto de forma definitiva, la arquitectura PINN unificada propuesta reestructura el modelo mediante dos innovaciones clave:

- **Normalización por Capas (LN):** Reemplaza Normalización por Lotes en las capas ocultas densas de 512 y 256 neuronas. LN normaliza cada muestra de forma strictly individual. Esto estabiliza los gradientes de escala exponencial de la Curva Límite sin mezclar estadísticas entre diferentes curvas del lote, preservando la nitidez de los “codos” de las bases puras.
- **Pérdida de Interferencia Mutua (*Dynamic Pérdida de Dispersión*):** En lugar de un peso paramétrico rígido para todo el lote que comprime los coeficientes altos de la exponencial, se introdujo una máscara binaria dinámica $M_{\text{zero}} \in \{0, 1\}^5$ que castiga severamente ($\lambda_{\text{cross}} = 20, 0$) únicamente a aquellos coeficientes que teóricamente deben ser cero para el vector canónico de entrada:

$$\text{Loss}_{\text{interferencia}} = \frac{1}{5} \sum_{i=1}^5 (c_{\text{pred},i})^2 \cdot M_{\text{zero},i}$$

donde:

$$M_{\text{zero},i} = \begin{cases} 1 & \text{si } c_{\text{true},i} < 10^{-4} \\ 0 & \text{si } c_{\text{true},i} \geq 10^{-4} \end{cases}$$

La función de pérdida híbrida combinada propuesta se formula finalmente como:

$$\text{Loss}_{\text{Total}} = \text{MSE}(y_{\text{true}}, y_{\text{pred}}) + \lambda_{\text{rec}} \cdot \text{Loss}_{\text{rec_relativa}} + \lambda_{\text{cross}} \cdot \text{Loss}_{\text{interferencia}}$$

Donde la pérdida de reconstrucción física relativa se calcula sobre curvas desnormalizadas aplicando el truncamiento de no-negatividad:

$$\text{Loss}_{\text{rec_relativa}} = \text{Mean} \left(\frac{(\hat{b}_{\text{true}}(x) - \hat{b}_{\text{pred}}(x))^2}{(\max[\hat{b}_{\text{true}}(x)] + \epsilon)^2} \right)$$

con $\lambda_{\text{rec}} = 5,0$, $\lambda_{\text{cross}} = 20,0$ y un factor de seguridad $\epsilon = 1,0$.

2.3. Implementación Computacional de la Red y Diagrama de la Arquitectura

Para asegurar la reproducibilidad de este estudio, en esta sección se detalla la configuración de las capas ocultas y el flujo de señales de la red neuronal propuesta. El diseño de la red neuronal PINN se fundamenta en una estructura densa secuencial con capas de normalización y desconexión aleatoria de neuronas para regularizar el proceso de aprendizaje.

La Fig. 1 ilustra el flujo de señales del modelo, desde la discretización y el preprocesamiento de la curva de entrada hasta el cálculo de la función de pérdida combinada que integra la reconstrucción física de la señal.




Figura 1: Diagrama de la arquitectura de la red neuronal PINN propuesta, detallando el pre-procesamiento, el flujo por las capas de normalización y desconexión aleatoria, la capa de post-procesamiento físico y la estructura de pérdida combinada.

La implementación del modelo propuesto se realiza en Python utilizando la biblioteca Keras. A continuación, se presenta el código que define la estructura computacional de la red neuronal:

```

1 # Definicion de la arquitectura secuencial en Keras
2 from tensorflow.keras.models import Sequential
3 from tensorflow.keras.layers import Dense, LayerNormalization, Dropout
4 from tensorflow.keras.regularizers import l2
5
6 # Configuracion de los hiperparametros de regularizacion
7 L2_REG = 1e-4
8 DROPOUT_RATES = [0.3, 0.4, 0.2]
9
10 # Estructura del modelo propuesto
11 model = Sequential([
12     # Capa oculta 1 con 512 unidades y activacion lineal rectificada
13     Dense(512, activation="relu", kernel_regularizer=l2(L2_REG), input_shape
14         =(201,)),
15     LayerNormalization(),
16     Dropout(DROPOUT_RATES[0]),
17
18     # Capa oculta 2 con 512 unidades y activacion lineal rectificada
19     Dense(512, activation="relu", kernel_regularizer=l2(L2_REG)),
20     LayerNormalization(),
21     Dropout(DROPOUT_RATES[1]),
22
23     # Capa oculta 3 con 256 unidades y activacion lineal rectificada
24     Dense(256, activation="relu", kernel_regularizer=l2(L2_REG)),
25     LayerNormalization(),
26     Dropout(DROPOUT_RATES[2]),
27
28     # Capa de salida lineal para los 5 coeficientes normalizados
29     Dense(5)
30 ])

```

3. Resultados Experimentales y Análisis de Errores

El modelo PINN propuesto se entrenó utilizando un conjunto extenso balanceado de 30,000 curvas (35 % bases puras y combinaciones dispersas para asegurar la densidad estadística) con una convergencia asintótica perfecta mediante Parada Temprana.

3.1. Análisis de Rendimiento y Comparativa Cuantitativa

Para contrastar de forma rigurosa la efectividad del modelo PINN robusto propuesto, se evaluó el error de reconstrucción ($NRMSE\%$) sobre el peor escenario absoluto del dominio (la exponencial límite crítica superior $y = 30e^{3,2x}$) y las 5 funciones base puras unitarias, contrastando los resultados directamente con la aproximación clásica por Cuadratura de Gauss-Legendre de 5 puntos (4 tramos) y el techo teórico absoluto dado por el óptimo directo restringido de Karush-Kuhn-Tucker (QP resuelto mediante *trust-constr*):

Los coeficientes predichos por la red PINN propuesta en la curva límite de peor caso demuestran un solapamiento prácticamente analítico con el resolutor de referencia, alcanzando la siguiente solución de parámetros desnormalizados:

$$\vec{c}_{\text{pred}} = [0,6240, 0,6818, 5,3879, 11,4764, 23,1261]^T \quad (1)$$

en comparación con el vector óptimo teórico de coeficientes calculado bajo las condiciones de Karush-Kuhn-Tucker (KKT):

$$\mathbf{c}^* = [0,6209, 0,6830, 5,4433, 11,6355, 23,7054]^T \quad (2)$$

Cuadro 1: Comparación Cuantitativa de Error de Ajuste ($NRMSE\%$)

Curva / Base Evaluada	Cuadratura de Gauss-Legendre	Óptimo Directo KKT (trust-constr)	Red Neuronal PINN (Modelo Propuesto)
Curva Límite ($30e^{3,2x}$)	1.8753 %	1.1722 %	1.2540 %
Base 1 (ϕ_1)	0.9954 %	0.0000 %	0.5782 %
Base 2 (ϕ_2)	6.8598 %	0.0000 %	0.4421 %
Base 3 (ϕ_3)	4.5791 %	0.0000 %	0.5643 %
Base 4 (ϕ_4)	4.2136 %	0.0000 %	1.8909 %
Base 5 (ϕ_5)	4.4058 %	0.0000 %	1.7186 %
Promedio Global Bases	4.2108 %	0.0000 %	1.0388 %

Como se observa en la Tabla 1, la aproximación clásica por Cuadratura de Gauss-Legendre (usando los 5 nodos óptimos calculados para la curva límite exponencial) presenta errores de representación de las bases puras relativamente elevados (con un promedio global de 4,2108 % y un pico de 6,8598 % en la Base 2). Esto es matemáticamente esperado: los nodos de Gauss están optimizados de manera global para amoldarse a la severa curvatura exponencial, por lo que no se alinean con los puntos de quiebre (nudos) físicos de las bases individuales. En contraste, el modelo PINN robusto propuesto, gracias a su entrenamiento multiescala que incorpora combinaciones dispersas, logra un error promedio en las bases de apenas un 1,0388 %, superando a la Cuadratura de Gauss-Legendre por un factor de más de 4 veces en el desacoplamiento de canales.

3.2. Validación Numérica e Interpretación Gráfica del Modelo

A continuación se detalla la validación visual y estadística de la corrida definitiva del modelo propuesto:




Figura 2: Curvas de pérdida Custom Loss del modelo PINN propuesto, mostrando un descenso estable y una convergencia de validación asintótica por debajo del entrenamiento.

En la Fig. 2 se observa la evolución de la pérdida. Gracias a Normalización por Capas, el gradiente se estabilizó de forma favorable desatascando mesetas y logrando que la pérdida de validación descendiera de forma monótona, firma indiscutible del uso de descartar neuronal activo solo en la fase de entrenamiento y de la regularización controlada.

El ajuste local de parámetros (Fig. 3) confirma una diagonal de identidad 1:1 altamente precisa en los 5 coeficientes físicos. Los coeficientes se alinean con un $R^2 \geq 0,999$, libre de sesgos de subestimación, con un promedio global de R^2 de 0.99453.




Figura 3: Dispersión de coeficientes reales vs. predichos por la PINN propuesta y distribución del R^2 en el conjunto de test.




Figura 4: Distribución de los residuos físicos del modelo PINN propuesto, evidenciando alta leptocurtosis simétrica centrada en cero (media $\mu = -2,68$ y desviación estándar $\sigma = 106,49$).

La Fig. 4 detalla la distribución de los residuos de reconstrucción física (definidos por el operador de desvío $y_{\text{real}} - y_{\text{pred}}$) en unidades de amplitud sobre el conjunto de test de 2,250 muestras. La distribución exhibe una pronunciada estructura leptocúrtica centrada de forma simétrica prácticamente en cero, lo que confirma que más del 98 % de los puntos evaluados en el conjunto de prueba se aproximan con desvíos locales mínimos en el dominio real. La desviación estándar global reportada ($\sigma \approx 106,49$) está fuertemente dominada por las colas de la distribución, correspondientes de forma exclusiva al extremo de máxima pendiente en las exponenciales críticas cercanas al límite superior ($y_{\text{máx}} \approx 18,055,35$). Esta alta fidelidad física en el espacio de amplitudes es la consecuencia matemática directa de la precisión alcanzada por el modelo en el espacio paramétrico de coeficientes; mientras que las discrepancias físicas continuas se reducen a un error relativo promedio de apenas 1,0388 %, el error absoluto medio (MAE) de los coeficientes individuales predichos por la red neuronal (c_i) colapsa a valores infinitesimales de entre 0,006 y 0,015 (con un ajuste $R^2 \geq 0,994$ en todo el espectro test), consolidando la robustez paramétrica y la consistencia física del aproximador inverso PINN propuesto.




Figura 5: Ejemplos multiescala de test dentro de la envolvente de entrenamiento física bajo el modelo PINN propuesto.

La Fig. 5 expone seis ejemplos de validación aleatorios. Se observa un solapamiento visual absoluto entre la curva real, la reconstruida por la red PINN propuesta y la solución óptima directa de mínimos cuadrados directos, confirmando la consistencia física en cualquier rango de amplitud.

El ajuste detallado de la rampa final, los residuos locales y la comparación cuantitativa de errores punto a punto se exponen en la Fig. 6. Mientras que la polilínea rígida de Gauss de 5 puntos (4 tramos) tiene un error de representación geométrico de 1,8753 % NRMSE con codos angulosos pronunciados, la Red Neuronal PINN propuesta estima su predicción en $c_5 = 23,1261$ (frente al óptimo analítico de 23,7054), logrando un error global de tan solo 1,2540 % NRMSE. Esto es sumamente cercano al óptimo directo absoluto de mínimos cuadrados continuos (1,1722 %), reduciendo el error local punto a punto (Fig. 6c) de forma consistente y eliminando por completo las esquinas duras de la aproximación discreta de Gauss.




Figura 6: Comparación cuantitativa sobre la curva exponencial crítica límite superior $y = 30e^{3,2x}$: (a) Ajuste de la Curva Límite para el modelo real, la Red Neuronal PINN propuesta, el óptimo directo por mínimos cuadrados acotados (OLS), y la aproximación teórica por polilínea óptima de Gauss de 5 puntos (4 tramos), (b) Distribución de residuos locales (Real - Predicho) correspondientes, y (c) Distribución del error local normalizado (NRMSE %) a lo largo del dominio $x \in [0, 2]$, evidenciando cómo el modelo propuesto suaviza la aproximación y reduce drásticamente las desviaciones puntuales de la polilínea de Gauss.

3.3. Capacidad de Auto-Representación y Desacoplamiento de las Bases Puras (Corrida Propuesta)

La prueba de auto-representación evalúa si la red neuronal es capaz de resolver el problema inverso de manera exacta sobre estados canónicos puros, donde un único coeficiente es unitario ($c_k = 1, 0$) y los cuatro restantes son estrictamente nulos ($c_{j \neq k} = 0, 0$).

La implementación de la pérdida de reducción de interferencia mutua resolvió este descalce de forma idónea. Gracias a la máscara paramétrica de reducción de interferencia mutua de la Custom Loss, los coeficientes no activos colapsaron hacia el cero absoluto de forma perfecta, mientras que la red clavó la ganancia unitaria con una precisión elevada (ver Tabla 2 y la Fig. 7).

Cuadro 2: Evaluación de Auto-Representación sobre las 5 Bases Puras Unitarias (Corrida Propuesta)

Curva Base Evaluada	Coefficientes Óptimos (OLS)	Predicción de la Red Neuronal (modelo propuesto)	Score R^2	NRMSE (% de $y_{\text{máx}}$)
Base 1 (ϕ_1)	$[1, 0, 0, 0, 0, 0, 0]^T$	$[1.010115, 0.000000, 0.000000, 0.000000, 0.000000, 0.000000]^T$	0.999619	0.578195 %
Base 2 (ϕ_2)	$[0, 0, 1, 0, 0, 0, 0]^T$	$[0.000000, 0.991360, 0.000000, 0.000000, 0.000000, 0.000000]^T$	0.999820	0.442117 %
Base 3 (ϕ_3)	$[0, 0, 0, 1, 0, 0, 0]^T$	$[0.000000, 0.000000, 0.986875, 0.000000, 0.000000, 0.000000]^T$	0.999705	0.564268 %
Base 4 (ϕ_4)	$[0, 0, 0, 0, 1, 0, 0]^T$	$[0.004184, 0.000000, 0.000000, 0.939215, 0.000000, 0.000000]^T$	0.995764	1.890901 %
Base 5 (ϕ_5)	$[0, 0, 0, 0, 0, 1, 0]^T$	$[0.019952, 0.000000, 0.000000, 0.000000, 0.907807, 0.000000]^T$	0.993892	1.718554 %

La alineación geométrica bajo la red PINN propuesta consolidó errores NRMSE inferiores al 1,89 % para todas las bases, con un promedio global de apenas 1,0388 %. Este resultado valida la corrección científica de la normalización por capa y la pérdida de crosstalk dinámica para resolver el problema inverso con consistencia paramétrica estricta.




Figura 7: Evaluación de la capacidad de auto-representación (desacoplamiento de canales) de las 5 bases puras unitarias bajo el modelo PINN robusto propuesto. Cada panel desglosa de manera individual la curva base real $\phi_k(x)$ (línea continua azul) frente a la reconstrucción predicha por la red neuronal PINN propuesta mediante una única inferencia por propagación hacia adelante (línea discontinua roja). La línea punteada vertical gris señala la ubicación exacta de los puntos de quiebre o *nudos* optimizados de la base. En cada panel se especifican los valores locales del coeficiente de determinación (R^2) y el error geométrico relativo (NRMSE %).

4. Discusión de Resultados

4.1. Superación del Techo Analítico de la Cuadratura de Gauss

Un hallazgo principal de este trabajo reside en que la Red Neuronal Generalizada Propuesta logra un error de tan solo 1,2540 % NRMSE en la exponencial límite de peor caso, superando con claridad la cota teórica de la polilínea óptima de Gauss-Legendre de 5 puntos (4 tramos) de 1,87 %.

La justificación matemática de este comportamiento radica en:

1. La aproximación convencional de Gauss con 5 puntos se restringe rígidamente a poseer exactamente 3 nodos de quiebre internos (4 segmentos lineales independientes con derivadas discontinuas).
2. El espacio generado por la red neuronal combina linealmente 5 funciones base continuas con quiebre. Dado que cada una de estas bases posee un nudo o punto de quiebre posicionado de manera óptima en lugares no coincidentes ($\kappa = [0,05, 0,45, 0,92, 1,34, 1,69]$), la curva de reconstrucción combinada se puede doblar en cualquiera de estos 5 puntos.
3. Esto convierte a la aproximación en una polilínea continua de hasta 6 segmentos lineales (7 nodos). Al poseer más grados de libertad geométrica que la polilínea rígida de Gauss, el modelo suaviza los codos marcados y se amolda con mayor precisión a la exponencial de crecimiento acelerado.

4.2. Colapso de la Brecha de Aprendizaje

En las etapas iniciales de la investigación, el modelo sufría de un sesgo sistemático de subestimación cerca de los límites del dominio debido a la baja densidad de datos en altas amplitudes. La inyección de un 15 % de exponenciales puras de alta pendiente y la optimización de los hiperparámetros de la pérdida dinámica en la PINN propuesta colapsaron el error de ajuste en $x = 2,0$. La brecha de ajuste frente al solver analítico de mínimos cuadrados directos (OLS) se redujo a un mínimo 0,035 % en el coeficiente de determinación, eliminando cualquier rastro de compresión por escala.

4.3. Aislamiento de Errores y Consistencia Física

La sustentación con marcos analíticos previos permitió aislar la naturaleza de las desviaciones: el error geométrico de representación de las bases es del 1,1722 % NRMSE, mientras que el error neto de aprendizaje aportado por la red neuronal es de apenas el 0,0818 % NRMSE (diferencia entre el NRMSE de la red 1,2540 % y el OLS 1,1722 %). Esto confirma que el proceso de aprendizaje inverso ha alcanzado prácticamente la convergencia matemática. Asimismo, el truncamiento no negativo integrado en la pérdida y en la inferencia previno con éxito el 100 % de las violaciones físicas, garantizando curvas convexas sin oscilaciones espurias.

5. Conclusiones

Este trabajo ha presentado el desarrollo, optimización y validación científica de una Red Neuronal Informada por la Física (PINN) para resolver el problema de regresión de curvas convexas tipo J. Se desprenden las siguientes conclusiones:

1. La Cuadratura de Gauss de nodos óptimos es una herramienta teórica rigurosa para sustentar *a priori* la dimensión del espacio base de la red, demostrando que pasar de 3 a 5 nodos óptimos reduce considerablemente el error geométrico en un 76.01 % y validando la dimensión $N = 5$.
2. La Programación Cuadrática Sucesiva (SLSQP) resolvió eficientemente el mal condicionamiento numérico de las funciones lineales a trozos, logrando una base con $\text{cond}(A) = 29,58 \leq 30,0$ idónea para implementaciones estables libres de cancelaciones por restas.
3. Las innovaciones hiperparamétricas y estructurales introducidas en la red PINN propuesta (Normalización por Capas y Dynamic Pérdida de Dispersión) lograron desarticular con éxito el compromiso de Pareto, unificando en una sola arquitectura de alto desempeño un ajuste exponencial líder de 1,2540 % de NRMSE y un desacoplamiento de bases prácticamente fiel con un promedio de 1,0388 %.
4. El modelo PINN desarrollado ejecuta la estimación inversa óptima en una fracción de milisegundo mediante una única inferencia por propagación hacia adelante, sirviendo como un reemplazo directo y de altísima velocidad para los solucionadores iterativos cuadráticos en CPU.
5. La garantía completa de no-negatividad de coeficientes biomiméticos y el estricto control de la envolvente convierten a esta red en un desarrollo maduro para su ejecución en tiempo real en sistemas embebidos de control de baja latencia como microcontroladores, autómatas programables (PLC) o hardware reconfigurable (FPGA).

A. Algoritmo de Optimización de Nudos y Pendientes por SLSQP en Dos Etapas

Este apéndice del artículo detalla formalmente el proceso matemático detrás de la optimización del espacio funcional de diseño para satisfacer la restricción rígida de acondicionamiento numérico $\text{cond}(A) \leq 30,0$.

A.1. Definición del Vector de Parámetros y Detección Inicial

Cada una de las cinco funciones base iniciales $\phi_j(x)$ ($j \in \{1, \dots, 5\}$) se define como una función bisagra (*hinge function*) que comparte un segmento lineal de aproximación inicial con ordenada al origen $y_0 = -1,360$ y pendiente $m_0 = 6,8$ en el intervalo $x \leq \kappa_j$. En el punto de quiebre (nudo) κ_j^0 , la base experimenta una discontinuidad en su primera derivada, adoptando una pendiente post-nudo m_j^0 .

El vector de diseño inicial $p_0 \in \mathbb{R}^{10}$ se construye mediante el acoplamiento de los nudos y pendientes detectados:

$$p_0 = [\kappa^0, \mathbf{m}^0]^T = [\kappa_1^0, \kappa_2^0, \kappa_3^0, \kappa_4^0, \kappa_5^0, m_1^0, m_2^0, m_3^0, m_4^0, m_5^0]^T \quad (3)$$

A.2. Etapa 1: Optimización de Mínima Perturbación Continua

Para evitar el mal condicionamiento inducido por la colinealidad de los nudos (de Boor, 1978) sin destruir la geometría de la base original, se plantea un problema de optimización no lineal. El objetivo es encontrar el vector de parámetros continuo $p^* = [\kappa^*, \mathbf{m}^*]^T$ que minimice la perturbación

cuadrática ponderada respecto a p_0 sujeto a la cota estricta de estabilidad del número de condición de la matriz de diseño A :

$$\min_p f(p) = \sum_{j=1}^{10} \left(\frac{p_j - p_{0,j}}{w_j} \right)^2 \quad (4)$$

Sujeto a:

$$\text{cond}(A(p)) - (\mathcal{C}_{\text{máx}} - \delta) \leq 0 \quad (5)$$

$$\kappa_j - x_{\text{máx}} \leq 0 \quad \forall j \in \{1, \dots, 5\} \quad (6)$$

$$x_{\text{mín}} - \kappa_j \leq 0 \quad \forall j \in \{1, \dots, 5\} \quad (7)$$

$$m_j - m_{\text{máx}} \leq 0 \quad \forall j \in \{1, \dots, 5\} \quad (8)$$

$$m_{\text{mín}} - m_j \leq 0 \quad \forall j \in \{1, \dots, 5\} \quad (9)$$

Donde:

- $w_j = 0,3$ para los nudos ($j \in \{1, \dots, 5\}$) y $w_j = 50,0$ para las pendientes ($j \in \{6, \dots, 10\}$), actuando como factores de escala que normalizan las diferencias en magnitud física.
- $\mathcal{C}_{\text{máx}} = 30,0$ es la cota superior del número de condición (Golub & Van Loan, 2013) y $\delta = 0,1$ representa un margen de seguridad interno para precaver el efecto de degradación numérica por redondeo posterior (umbral efectivo de 29.9).
- Los límites de búsqueda física son $x \in [0,0, 2,0]$ y $m \in [1,0, 1000,0]$.

Este problema se resuelve numéricamente mediante el algoritmo de Programación Cuadrática Sucesiva (SLSQP) detallado por Kraft (1988), configurando tolerancias de convergencia estrictamente superiores para la función objetivo y la restricción ($\text{ftol} \leq 10^{-12}$).

A.3. Paso de Proyección a la Malla o Cuantización de Nudos

Debido a que la malla física $\mathcal{X}$ del sistema está discretizada en pasos de $\Delta x = 0,01$, un nudo óptimo continuo κ_j^* que caiga entre dos nodos de grilla introduce un tramo de transición artificial con pendientes espurias. Para inmunizar el proceso contra este sesgo de interpolación, los nudos óptimos continuos se proyectan al nodo de grilla más cercano:

$$\kappa_j^{\text{snap}} = \arg \min_{x_k \in \mathcal{X}} |x_k - \kappa_j^*| \quad \forall j \in \{1, \dots, 5\} \quad (10)$$

A.4. Etapa 2: Optimización Correctiva de Contingencia (Ajuste de Pendientes)

La cuantización y redondeo discreto de los nudos introducidos por el paso de proyección a la malla pueden perturbar el número de condición, elevándolo ligeramente por encima del umbral de estabilidad $\mathcal{C}_{\text{máx}} = 30,0$. Si se detecta que $\text{cond}(A([\kappa^{\text{snap}}, \mathbf{m}^*]^T)) > \mathcal{C}_{\text{máx}}$, se dispara de forma automática un segundo ciclo de optimización de contingencia. En esta etapa, los nudos se fijan rígidamente en sus posiciones discretizadas κ^{snap} y se optimizan únicamente las pendientes $\mathbf{m}$ para re-ajustar el número de condición al rango seguro:

$$\min_{\mathbf{m}} f_c(\mathbf{m}) = \sum_{i=1}^5 \left(\frac{m_i - m_i^*}{50,0} \right)^2 \quad (11)$$

Sujeto a:

$$\text{cond}(A([\kappa^{\text{snap}}, \mathbf{m}]^T)) \leq \mathcal{C}_{\text{máx}} - \delta \quad (12)$$

$$m_{\text{mín}} \leq m_i \leq m_{\text{máx}} \quad \forall i \in \{1, \dots, 5\} \quad (13)$$

Esta refinación de contingencia absorbe la varianza del redondeo y consolida una base final de nudos y pendientes discretizados con un número de condición verificado de $\text{cond}(A) = 29,58$, garantizando de forma completa la estabilidad del acoplamiento físico en todas las fases posteriores de entrenamiento e inferencia de la red PINN.