Diseño de injertos vasculares de pared gruesa con láminas enteras: ajuste no lineal, minimax entero y el papel de una red neuronal como arranque

Pablo

2 de noviembre de 2026

Resumen

Se diseña un injerto vascular multicapa (una capa por material, cada material una recta truncada, con un preestiramiento común) que reproduzca la curva presión–estiramiento de cada una de las 41 carótidas de Masson et al. [15], con la presión que soporta la pared íntima–media, $P_i - P_a$, entre 60 y 200 mmHg. El injerto se modela como un tubo de pared gruesa incompresible, de modo que la curva depende de forma no lineal de los espesores y del preestiramiento. El diseño fabricable es un número entero de láminas de 0,025 mm de cada material y se juzga por su peor punto contra la curva verdadera (meta: ≤ 3 % del rango de estiramiento). Se comparan tres caminos (V46) y luego un procedimiento único de tres pasos con dos arranques (V47): (i) arranque, por mínimos cuadrados lineales con el modelo de pared delgada o por una red neuronal; (ii) mínimos cuadrados no lineales con el modelo de pared gruesa (región de confianza reflexiva); (iii) búsqueda entera minimax no lineal contra la curva ajustada. Con curvas limpias todos los caminos cumplen la meta en 40–41 de 41 pacientes. Con curvas medidas, la red como arranque evita los diseños que fallan (6 materiales, 10 presiones: peor error 468,7 % sin red y 2,3 % con red) y aumenta los pacientes dentro de la meta con ruido de 0,3 % (31 contra 23). Elegir las láminas contra la curva ajustada, en lugar de contra la curva medida, cuesta 0,2 puntos de mediana con curvas limpias y triplica los pacientes dentro de la meta con ruido. El diseño lineal de pared delgada, usado solo, no cumple en ningún paciente.

Índice

1. Introducción **2**

2. Modelo **2**
2.1. Curvas objetivo . . . 2
2.2. Injerto de pared gruesa . . . 2
2.3. Métrica . . . 3

3. Métodos de diseño **3**
3.1. Variables reales y enteras . . . 3
3.2. Algoritmos . . . 3
3.3. Los caminos comparados . . . 5
3.4. Curvas medidas . . . 5

4. Resultados **6**
4.1. V46: tres caminos . . . 6
4.2. V47: un procedimiento, dos arranques . . . 7
4.3. Curva de referencia para las láminas . . . 9
4.4. Diseño lineal de pared delgada usado solo . . . 10

5. Discusión **10**

6. Conclusiones **10**

1. Introducción

Un injerto vascular biomimético debe distenderse con la presión como la arteria que reemplaza. Si el injerto se arma con capas de distintos materiales, el problema de diseño es elegir el espesor de cada capa. En pared delgada (ley de Laplace) la presión es una combinación lineal de los espesores y el diseño es un problema lineal (mínimos cuadrados o programación lineal entera). En pared gruesa, el estiramiento cambia a través del espesor y cada capa influye en el estiramiento de las demás: el problema es no lineal y, al exigir un número entero de láminas, es un problema no lineal entero.

Este trabajo responde dos preguntas: (1) si una red neuronal entrenada para proponer diseños mejora el resultado cuando se usa como punto de partida de la optimización, y (2) contra qué curva deben elegirse las láminas cuando la curva del paciente viene medida con ruido o en pocas presiones.

2. Modelo

2.1. Curvas objetivo

Para cada paciente se usa la ley constitutiva de Masson et al. [15] (elastina, cuatro familias de colágeno y tono muscular; Tablas 2 y 4) con su geometría: radio del borde media–adventicia R_m, semiángulo de apertura Θ_0 y estiramiento axial λ_z. El espesor íntima–media h es la mediana de referencia de Engelen et al. [9] para la edad y el sexo. Por equilibrio radial de un cilindro de pared gruesa incompresible [13], Masson et al. escriben la presión de la sangre como

$$P_i = P_a + \int_{r_i}^{r_m} \frac{\sigma_{\theta\theta} - \sigma_{rr}}{r}\, dr,$$

donde P_a es la presión que ejercen la adventicia y el tejido perivascular sobre la íntima–media. En este trabajo se usa la integral, es decir **la presión que soporta la íntima–media,** $P = P_i - P_a$; P_a no se incluye (con los parámetros de Masson, en el radio diastólico vale entre 1 y 46 mmHg según el paciente). La relación se invierte para obtener la curva objetivo $\lambda(P_k)$ en $K = 141$ valores de $P_i - P_a$ equiespaciados entre 60 y 200 mmHg; λ es el estiramiento circunferencial en el borde media–adventicia. En todas las figuras, la ordenada es $P_i - P_a$.

2.2. Injerto de pared gruesa

El injerto es un tubo cerrado, incompresible y sin alargamiento axial, con $N = 5$ o 6 capas, una por material, ordenadas de adentro hacia afuera por nudo creciente y centradas en $R_{\mathrm{ref}} = 3{,}421$ mm (mediana de $\Theta_0 R_m/\pi$ de los 41 pacientes). Cada material es una recta truncada, $\sigma_j = E_j\, \mathrm{máx}(0, \lambda_{\mathrm{loc}} - \kappa_j)$. El diseño es

$$\theta = (h_1, \ldots, h_N, \delta), \qquad 0 \le h_j \le 3 \text{ mm}, \quad |\delta| \le 0{,}25,$$

donde δ es un preestiramiento común: κ_j es el estiramiento local del centro de la capa j cuando la mitad de la pared alcanza $\lambda = k_j + \delta$. Los nudos k_j son los de V41 y los módulos E_j se calibraron para que, en pared delgada, el paciente de entrenamiento que más necesita de cada material use 0,2 mm de él. La presión es

$$P(\lambda; \theta) = \sum_{j=1}^{N} \int_{r_{j-1}}^{r_j} \frac{\sigma_j}{r}\, dr,$$

integrada en cada capa con cuadratura de Gauss–Legendre de 8 nodos [8]. P se calcula en 651 valores de λ entre 0,80 y 1,45 y se invierte por interpolación lineal para obtener la curva del injerto $\lambda_{\text{inj}}(P_k;\theta)$. Esta función es **no lineal** en θ: los espesores fijan los límites de integración y los κ_j, y δ entra dentro del máx$(0,\cdot)$.

2.3. Métrica

Para una curva objetivo $y_k = \lambda(P_k)$ con rango $\Delta = \text{máx}_k\, y_k - \text{mín}_k\, y_k$:

$$e_{\text{máx}}(\theta) = \frac{100}{\Delta}\, \max_k \left|\lambda_{\text{inj}}(P_k;\theta) - y_k\right| \quad [\,\%].$$

Meta de fabricación: $e_{\text{máx}} \le 3$ %. Todo diseño entero se evalúa contra la curva **verdadera** del paciente.

3. Métodos de diseño

3.1. Variables reales y enteras

En los pasos intermedios los espesores h_j son **números reales**. El diseño que se fabrica es **entero**: $h_j = n_j\, e$, con $n_j \in \{0, 1, 2, \dots\}$ láminas de espesor $e = 0{,}025\,\text{mm}$; δ sigue siendo real. Encontrar los n_j es un problema **no lineal entero mixto**.

3.2. Algoritmos

La Tabla 1 resume los cinco bloques con que se arman todos los caminos.

Tabla 1: Bloques de cálculo. "Lineal" se refiere a la dependencia del modelo respecto de las incógnitas.

Bloque	Variables	¿Lineal?	Algoritmo	Implementación
A1 MCO lineal (pared delgada)	reales	sí (para δ fijo)	mínimos cuadrados lineales por SVD; δ por grilla y búsqueda de Brent	`numpy.linalg.lstsq` [12, 11]; `minimize_scalar` [7, 16]
A2 MCO no lineal (pared gruesa)	reales	no	región de confianza reflexiva con cotas (TRF)	`scipy.optimize.least_squares` [6, 16]
A3 Minimax no lineal continuo	reales	no	continuación en norma p ($p = 8, 16, 32, 64$), cada etapa con TRF	`least_squares` [5, 6]
A4 Minimax no lineal entero	enteros + δ real	no	enumeración piso/techo, δ por Brent acotado y búsqueda local	propio; `minimize_scalar` [7]
A5 Red neuronal	reales	no (una evaluación)	perceptrón multicapa, optimización amortizada	TensorFlow/Keras [4], Adam [14]

A1 · MCO lineal de pared delgada. Con la ley de Laplace y δ fijo, la presión es lineal en los coeficientes $c_j = E_j h_j / R_{\text{ref}}$:

$$P_k \approx \sum_j c_j\, \text{máx}(0,\ y_k - k_j - \delta).$$

Para cada δ de una grilla de 101 valores en $[-0{,}25; 0{,}25]$ se resuelve el sistema por mínimos cuadrados lineales (descomposición en valores singulares, LAPACK `gelsd`) [11, 12]; el residuo en presión se pasa a λ con la pendiente local de la curva. Se elige el δ de menor peor error y se refina con el método de Brent acotado en $\pm 0{,}005$ [7]. Los espesores son $h_j = \text{clip}(c_j R_{\text{ref}}/E_j; 0; 3)$. Es rápido pero ignora el gradiente de estiramiento en el espesor.

A2 · MCO no lineal de pared gruesa. Minimiza

$$F(\theta) = \sum_{k=1}^{K} \Big(\frac{\lambda_{\text{inj}}(P_k;\theta) - y_k}{\Delta} \Big)^2, \qquad \theta_{\text{mín}} \le \theta \le \theta_{\text{máx}},$$

con el método de región de confianza reflexiva (*Trust Region Reflective*, TRF) de `scipy.optimize.least_squares` [6, 16]. En cada iteración TRF aproxima F por un modelo cuadrático con el jacobiano (calculado por diferencias finitas), lo minimiza dentro de una región donde ese modelo es confiable y "refleja" los pasos que salen de las cotas, de modo que siempre respeta $0 \le h_j \le 3$ y $|\delta| \le 0{,}25$. Parámetros: escalas por variable $\text{máx}(h_j^{(0)}; 0{,}02)$ y 0,01 para δ, tolerancias 10^{-10}, a lo sumo 300 evaluaciones. Encuentra un mínimo *local*: el resultado depende del arranque $\theta^{(0)}$.

A3 · Minimax no lineal continuo. El criterio de fabricación es el peor punto, $\text{mín}_\theta \, \text{máx}_k \, |r_k(\theta)|$, que no es derivable. Se aproxima por la norma p, $\big(\sum_k |r_k|^p\big)^{1/p} \to \text{máx}_k \, |r_k|$ cuando $p \to \infty$ [5], con continuación $p = 8 \to 16 \to 32 \to 64$: cada etapa arranca del resultado de la anterior y se resuelve con TRF pasando como residuos $(|r_k|/s)^{p/2}$, cuya suma de cuadrados es $\sum_k (|r_k|/s)^p$ (s: peor error actual, para escalar). Se acepta una etapa solo si no empeora el peor error. Con $p = 64$ y $K = 141$, la norma p difiere del máximo en un factor $\le 141^{1/64} \approx 1{,}08$.

A4 · Minimax no lineal entero. A partir de un diseño real $\theta^\star = (h^\star, \delta^\star)$ y de una curva de referencia $\tilde{y}$:

1. Para cada material, $n_j \in \{\lfloor h_j^\star/e \rfloor, \lceil h_j^\star/e \rceil\}$: se evalúan las 2^N combinaciones (64 con 6 materiales) con $\delta^\star$ y se ordenan por $e_{\text{máx}}$ contra $\tilde{y}$.
2. Para las 8 mejores se reajusta δ minimizando $e_{\text{máx}}$ en $[\delta^\star - 0{,}03;\ \delta^\star + 0{,}03]$ con el método de Brent acotado [7] (`minimize_scalar`, tolerancia 10^{-5}).
3. Búsqueda local [1]: se prueban los vecinos que suman o restan una lámina a un material ($2N$) o pasan una lámina de un material a otro ($N(N-1)$); para los 8 mejores se reajusta δ y se acepta el mejor si baja el peor error. Se repite hasta que no mejora (a lo sumo 20 veces).

Es una heurística: no garantiza el óptimo entero global, pero cada paso solo acepta mejoras.

A5 · Red neuronal. Perceptrón multicapa $141 \to 256 \to 128 \to 64 \to N{+}1$ con ReLU y normalización por capa [3] y regularización L2 (10^{-5}). Entrada: la curva $\lambda(P_k)$ estandarizada; salida: el diseño θ estandarizado. Datos (V43): 6000 injertos con diseño sorteado (etiqueta exacta) y 9000 arterias sintéticas generadas con la ley de Masson a partir de los 31 pacientes de entrenamiento (etiqueta: ajuste A2); los 10 pacientes de prueba no se usan. Partición 11 220 / 1530 / 2250 (entrenamiento / validación / prueba). Entrenamiento con Adam [14] (tasa 10^{-3}, recorte de gradiente 1, lotes de 256), error cuadrático medio, ruido nuevo en cada época (0 a 1 % del rango de λ), parada temprana y reducción de la tasa en meseta: 425 épocas (6 materiales) y 629 (5 materiales). Una evaluación toma milisegundos. Se usa como *optimización amortizada* [2]: la red aprende a dar un buen punto de partida, no el diseño final.

3.3. Los caminos comparados

Tabla 2: Caminos de V46 y V47. Para cada bloque: con qué números trabaja (reales = espesores continuos; enteros = láminas de 0,025 mm, con δ real) y si el modelo es lineal. Todos terminan en láminas enteras (A4).

Camino	1.º bloque	2.º bloque	3.º bloque (se fabrica)	Curva de referencia de A4
V46 · 1) Minimax directo	A1 · reales · lineal	A3 · reales · no lineal	A4 · **enteros** · no lineal	la curva tal como viene
V46 · 2) MCO no lineal	A1 · reales · lineal	A2 · reales · no lineal	A4 · **enteros** · no lineal	la curva tal como viene
V46 · 3) Red + minimax	A5 · reales · red	A3 · reales · no lineal	A4 · **enteros** · no lineal	la curva tal como viene
V47 · A) Sin red	A1 · reales · lineal	A2 · reales · no lineal	A4 · **enteros** · no lineal	la curva ajustada por A2
V47 · B) Con red	A5 · reales · red	A2 · reales · no lineal	A4 · **enteros** · no lineal	la curva ajustada por A2

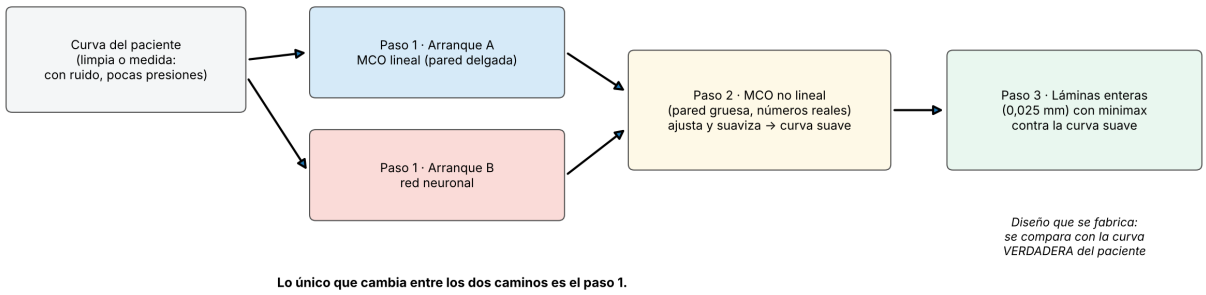


Figura 1: Procedimiento de V47. Los dos caminos solo difieren en el arranque.

En palabras

En todos los caminos los números son reales hasta el último bloque: solo A4 trabaja con enteros, y es el único resultado que se fabrica y se compara con la curva verdadera. En V47 el paso 2 (A2) cumple dos funciones: ajusta el diseño a la curva y, si la curva viene medida, la suaviza, porque la curva de un injerto no puede tener los saltos del ruido. El paso 3 (A4) elige las láminas contra esa curva suave. En V46, en cambio, A4 apuntaba a la curva tal como venía, con su ruido.

3.4. Curvas medidas

Para simular la medición, a la curva verdadera se le aplica: (a) ruido gaussiano proporcional, $\tilde{y}_k = y_k(1+\varepsilon_k)$, $\varepsilon_k \sim \mathcal{N}(0; 0{,}003^2)$; (b) muestreo en 10 presiones equiespaciadas e interpolación cúbica monótona (PCHIP) [10] a las 141; (c) ambas, con ruido de 0,2 %. Una realización por paciente y caso (semilla fija). Como $\lambda \approx 1{,}1$ y su rango es de unos 0,07, un ruido de 0,3 % de λ equivale a alrededor del 5 % del rango: mayor que la meta.

4. Resultados

4.1. V46: tres caminos

Tabla 3: V46, curvas limpias: peor error contra la curva original (%), 41 pacientes.

	6 materiales			5 materiales		
Camino	mediana	peor	cumplen	mediana	peor	cumplen
1) Minimax directo	0,85	2,47	41/41	1,30	1,87	41/41
2) MCO no lineal	0,91	2,39	41/41	1,35	2,25	41/41
3) Red + minimax	0,85	1,64	41/41	1,30	1,91	41/41

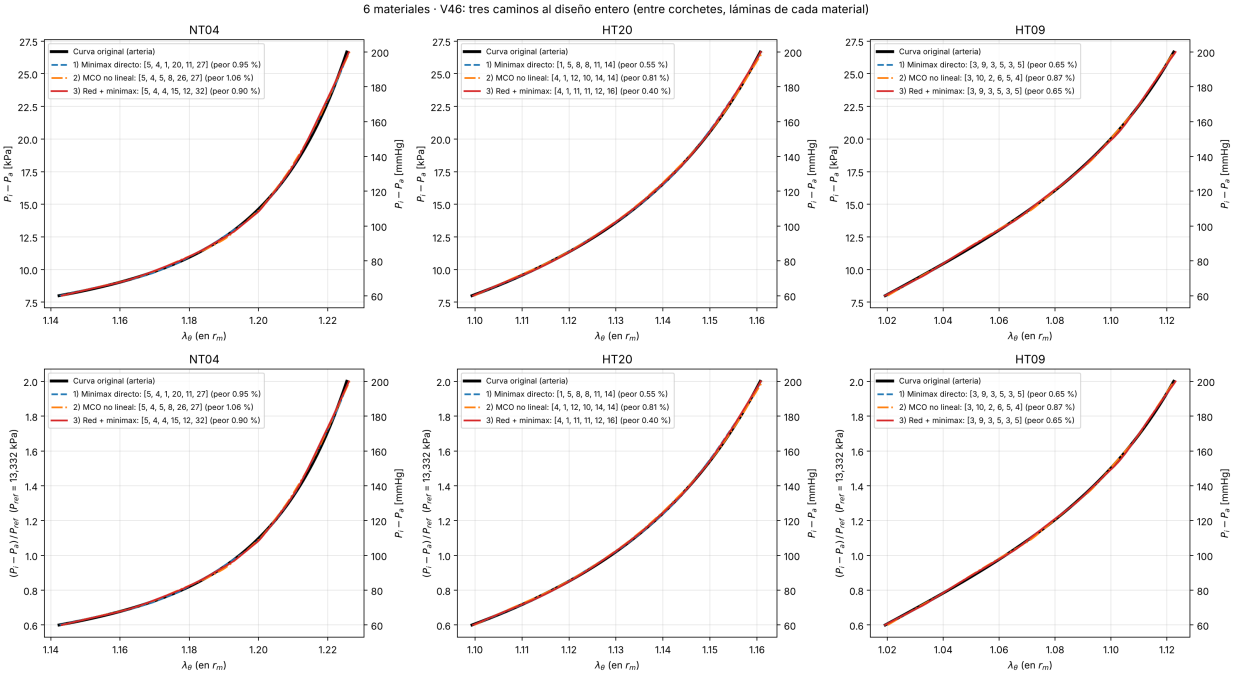


Figura 2: V46, 6 materiales: tres pacientes (el más blando, uno intermedio y el más rígido). Ordenada: $P_i - P_a$; arriba en kPa, abajo $(P_i - P_a)/P_{\text{ref}}$ con $P_{\text{ref}} = 13{,}332\,\text{kPa}$; a la derecha, en mmHg. Negra: curva original. Entre corchetes, láminas de cada material.

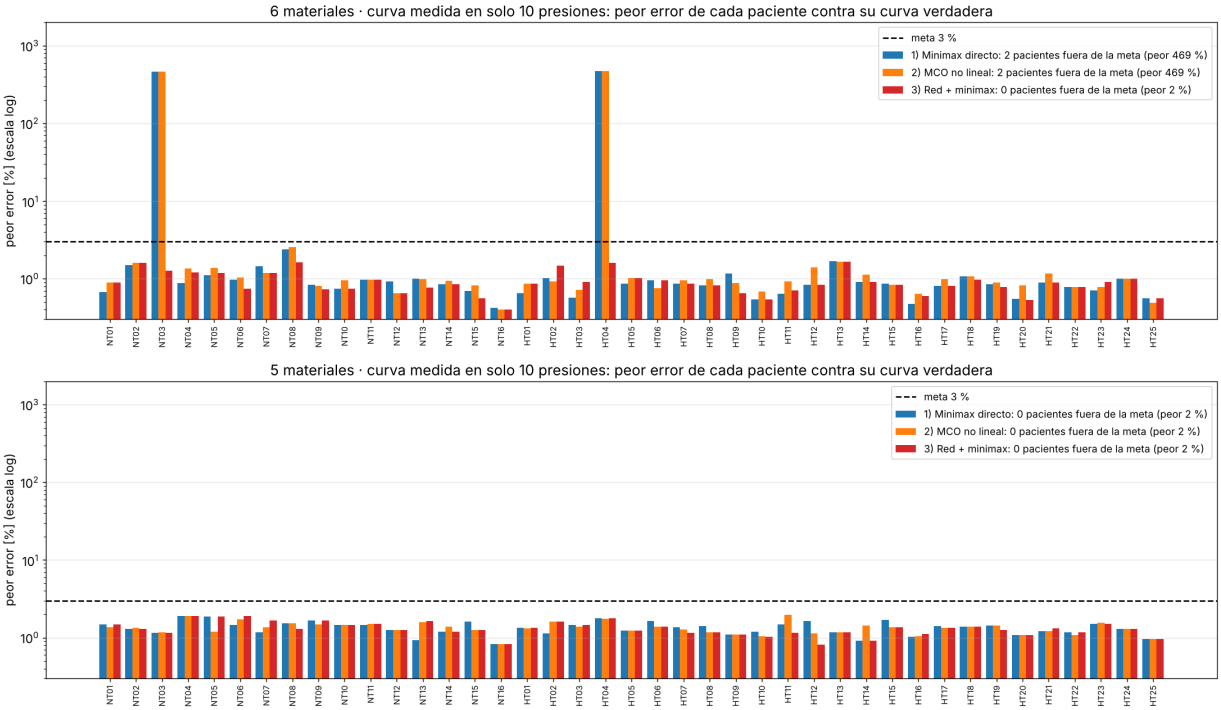


Figura 3: V46, curva medida en 10 presiones: peor error de cada paciente (escala logarítmica). Con 6 materiales, los caminos sin red fallan en NT03 y HT04 (468,7 %).

Con ruido de 0,3 % ningún camino de V46 cumplió en más de 6 de los 41 pacientes: A4 persigue el peor punto, que con ruido es un salto del ruido.

4.2. V47: un procedimiento, dos arranques

Tabla 4: V47: peor error contra la curva verdadera (%), 41 pacientes.

		6 materiales			5 materiales		
Curva	Camino	mediana	peor	cumplen	mediana	peor	cumplen
limpia	sin red	1,13	3,26	40/41	1,69	3,21	40/41
	con red	1,14	2,19	41/41	1,68	3,19	40/41
10 presiones	sin red	1,26	468,7	38/41	1,62	3,13	40/41
	con red	1,19	2,27	41/41	1,61	2,70	41/41
ruido 0,3 %	sin red	2,67	11,87	23/41	2,66	7,52	25/41
	con red	2,19	6,59	31/41	2,32	9,24	32/41
10 pres. + ruido 0,2 %	sin red	4,36	8,07	8/41	4,62	8,77	6/41
	con red	3,78	8,54	8/41	4,75	10,35	6/41

Tiempo por paciente: 0,2 a 0,5 s con cualquiera de los dos arranques (V46: 0,3 a 1,5 s).

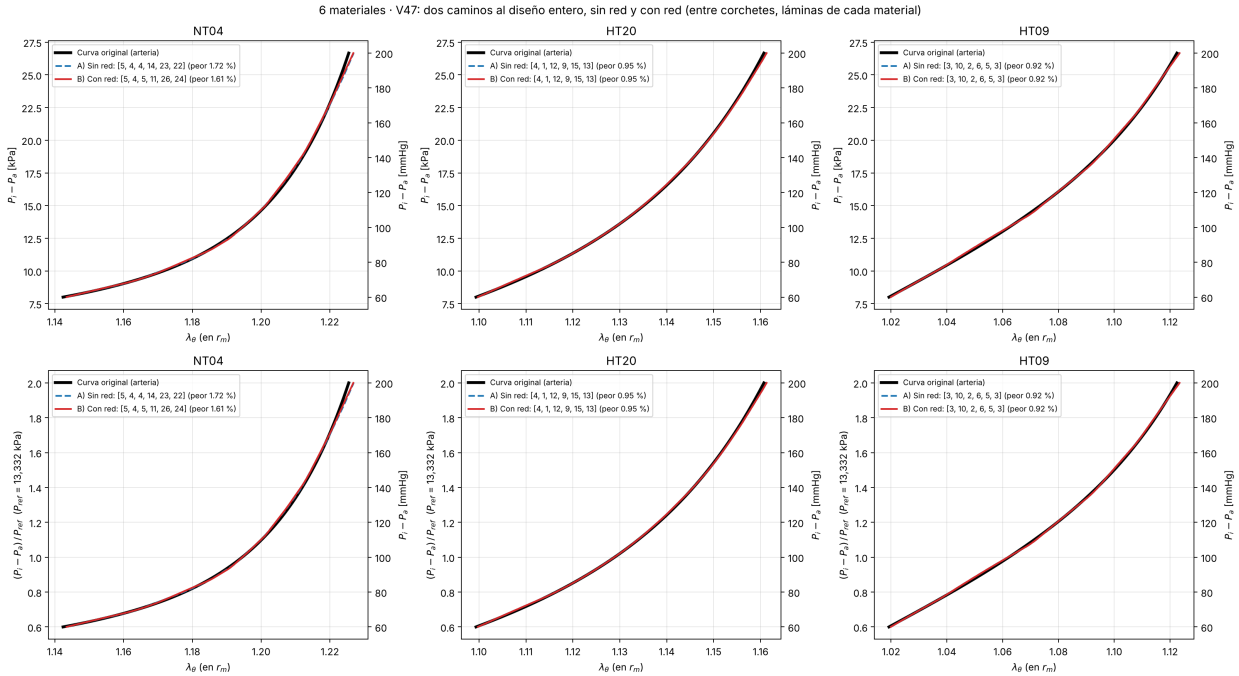


Figura 4: V47, 6 materiales, curvas limpias: azul sin red, roja con red. Ordenada: $P_i - P_a$ (arriba en kPa, abajo relativa a 13,332 kPa; a la derecha, mmHg).



Figura 5: V47, 6 materiales, curvas medidas: peor error de cada paciente (azul sin red, rojo con red; punteada: meta).

4.3. Curva de referencia para las láminas

Se repitió V47 eligiendo las láminas (A4) contra la curva tal como viene, en lugar de contra la curva ajustada por A2.

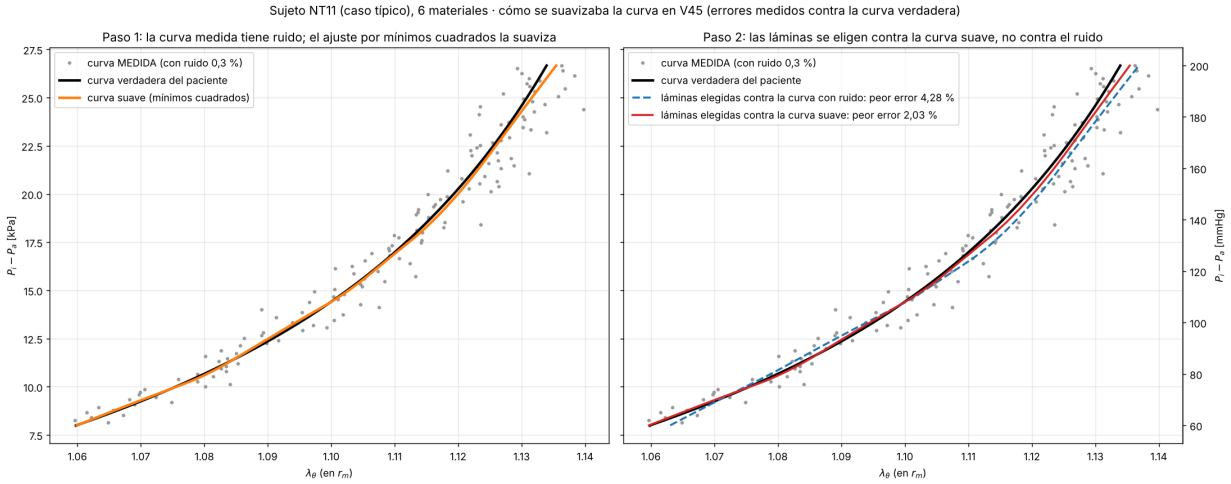


Figura 6: Paciente NT11 (caso típico), 6 materiales, ruido de 0,3 %; ordenada $P_i - P_a$. Izquierda: la curva ajustada por A2 (naranja) pasa por el medio de la curva medida (gris). Derecha: láminas elegidas contra la curva medida (azul, $e_{\text{máx}} = 4{,}28$ %) y contra la ajustada (roja, 2,03 %).

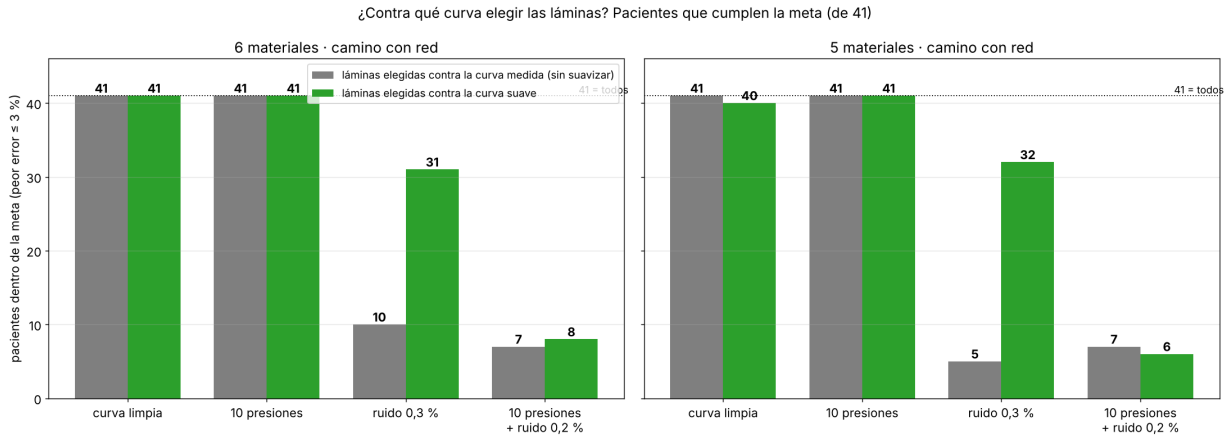


Figura 7: Camino con red: pacientes dentro de la meta según la curva de referencia de A4.

Tabla 5: 6 materiales: láminas elegidas contra la curva **medida** (sin suavizar) o contra la curva **suave**. Peor error contra la curva verdadera, en % del rango de λ; meta ≤ 3 %.

		contra la curva medida			contra la curva suave		
Curva	Camino	mediana	peor	cumplen	mediana	peor	cumplen
curva limpia	sin red	0,91	2,39	41/41	1,13	3,26	40/41
	con red	0,90	1,63	41/41	1,14	2,19	41/41
10 presiones	sin red	0,95	469	39/41	1,26	469	38/41
	con red	0,94	1,82	41/41	1,19	2,27	41/41
ruido 0,3 %	sin red	4,90	13,08	5/41	2,67	11,87	23/41
	con red	4,06	11,20	10/41	2,19	6,59	31/41
10 presiones + ruido 0,2 %	sin red	4,15	7,91	5/41	4,36	8,07	8/41
	con red	3,90	7,41	7/41	3,78	8,54	8/41

Tabla 6: 5 materiales: láminas elegidas contra la curva **medida** (sin suavizar) o contra la curva **suave**. Peor error contra la curva verdadera, en % del rango de λ; meta ≤ 3 %.

		contra la curva medida			contra la curva suave		
Curva	Camino	mediana	peor	cumplen	mediana	peor	cumplen
curva limpia	sin red	1,35	2,25	41/41	1,69	3,21	40/41
	con red	1,35	1,91	41/41	1,68	3,19	40/41
10 presiones	sin red	1,34	1,98	41/41	1,62	3,13	40/41
	con red	1,34	1,92	41/41	1,61	2,70	41/41
ruido 0,3 %	sin red	4,21	11,12	6/41	2,66	7,52	25/41
	con red	4,62	10,39	5/41	2,32	9,24	32/41
10 presiones + ruido 0,2 %	sin red	4,70	9,74	7/41	4,62	8,77	6/41
	con red	4,57	8,78	7/41	4,75	10,35	6/41

4.4. Diseño lineal de pared delgada usado solo

El diseño A1, sin pasos posteriores, evaluado con el modelo de pared gruesa: peor error mediano 27,3 % (6 materiales) y 29,9 % (5 materiales), peor caso 39,2 y 46,6 %, ningún paciente dentro de la meta. Con una versión de Laplace que usa la geometría deformada ($P = \sum E_j h_j \,\mathrm{máx}(0, \cdot)/(\lambda^2 R)$) y δ elegido por grilla contra el modelo de pared gruesa, la mediana baja a 20,5 % (6 materiales), todavía sin ningún paciente dentro de la meta.

5. Discusión

La red como arranque. Sola (V43), la red da diseños aproximados: 18 de 41 pacientes dentro de la meta y peor caso 89,6 %. Como punto de partida de A2 cumple otra función: A2 es un método local y, si arranca lejos, puede quedar en un mínimo local muy malo. Es lo que ocurre sin red en NT03 y HT04 con 10 presiones (468,7 % en V46 y V47); con la red como arranque esos fallos desaparecen. Con ruido de 0,3 % la red además aumenta los pacientes dentro de la meta (31 contra 23 con 6 materiales; 32 contra 25 con 5). Con 5 materiales el peor caso con ruido no mejora (9,24 contra 7,52 %), y con 10 presiones y ruido ambos arranques quedan igual. La ventaja de la red es, entonces, de robustez y no de velocidad: el tiempo lo dominan A2 y A4.

Curva de referencia. Elegir las láminas contra la curva ajustada introduce un error propio de A2 (mediana 0,90 contra 1,14 % con red y 6 materiales, curvas limpias), pero evita que A4 persiga el ruido: con ruido de 0,3 %, 31 contra 10 pacientes dentro de la meta (6 materiales) y 32 contra 5 (5 materiales). Como toda curva medida tiene ruido, se adopta la curva ajustada.

Límites del estudio. (1) A4 es heurístico. (2) Una sola realización de ruido por paciente y caso. (3) Con 10 presiones y ruido, ninguna variante supera 8 de 41 pacientes: el ruido de 0,2–0,3 % de λ ya es comparable a la meta. (4) Quedan abiertas cuestiones del modelo: la presión perivascular P_a de Masson (no incluida: las curvas usan $P_i - P_a$, y la presión de la sangre correspondiente es mayor en P_a), la medida que se copia (estiramiento del borde media–adventicia de la arteria frente al de la mitad de la pared del injerto con R_{ref} común), la fabricabilidad de nudos referidos a la mitad de la pared, y el espesor arterial fijo al variar la presión.

6. Conclusiones

1. En pared gruesa el diseño es un problema no lineal entero; el diseño lineal de pared delgada no alcanza (0 de 41 pacientes dentro de la meta).

2. El procedimiento de tres pasos de V47 (arranque, mínimos cuadrados no lineales con TRF, minimax entero contra la curva ajustada) cumple la meta en 40–41 de 41 pacientes con curvas limpias, en 0,2–0,5 s por paciente.
3. La red neuronal se justifica como arranque: evita los mínimos locales que producen diseños inservibles con curvas medidas y mejora el número de pacientes dentro de la meta con ruido; la ventaja es clara con 6 materiales y menor con 5.
4. Las láminas deben elegirse contra la curva ajustada (suave), no contra la medida.

Referencias

[1] Aarts, E., Lenstra, J. K. (eds.) (1997). *Local Search in Combinatorial Optimization*. Wiley.

[2] Amos, B. (2023). Tutorial on amortized optimization. *Found. Trends Mach. Learn.* 16(5), 592–732.

[3] Ba, J. L., Kiros, J. R., Hinton, G. E. (2016). Layer normalization. arXiv:1607.06450.

[4] Abadi, M., et al. (2016). TensorFlow: a system for large-scale machine learning. *Proc. 12th USENIX OSDI*, 265–283.

[5] Boyd, S., Vandenberghe, L. (2004). *Convex Optimization*. Cambridge University Press.

[6] Branch, M. A., Coleman, T. F., Li, Y. (1999). A subspace, interior, and conjugate gradient method for large-scale bound-constrained minimization problems. *SIAM J. Sci. Comput.* 21(1), 1–23.

[7] Brent, R. P. (1973). *Algorithms for Minimization without Derivatives*. Prentice-Hall.

[8] Davis, P. J., Rabinowitz, P. (1984). *Methods of Numerical Integration*, 2.ª ed. Academic Press.

[9] Engelen, L., et al. (2013). Reference intervals for common carotid intima-media thickness measured with echotracking: relation with risk factors. *Eur. Heart J.* 34(30), 2368–2380.

[10] Fritsch, F. N., Carlson, R. E. (1980). Monotone piecewise cubic interpolation. *SIAM J. Numer. Anal.* 17(2), 238–246.

[11] Golub, G. H., Van Loan, C. F. (2013). *Matrix Computations*, 4.ª ed. Johns Hopkins University Press.

[12] Harris, C. R., et al. (2020). Array programming with NumPy. *Nature* 585, 357–362.

[13] Humphrey, J. D. (2002). *Cardiovascular Solid Mechanics: Cells, Tissues, and Organs*. Springer.

[14] Kingma, D. P., Ba, J. (2015). Adam: a method for stochastic optimization. *Proc. ICLR*.

[15] Masson, I., Beaussier, H., Boutouyrie, P., Laurent, S., Humphrey, J. D., Zidi, M. (2011). Carotid artery mechanical properties and stresses quantified using in vivo data from normotensive and hypertensive humans. *Biomech. Model. Mechanobiol.* 10(6), 867–882.

[16] Virtanen, P., et al. (2020). SciPy 1.0: fundamental algorithms for scientific computing in Python. *Nat. Methods* 17, 261–272.