Del número real al número entero de láminas: métodos de redondeo

Pablo

24 de octubre de 2026

Resumen

El método de diseño da el número de láminas de cada material como un número real; un injerto se fabrica con números enteros. Se comparan tres maneras de pasar de uno a otro: redondeo simple, redondeo conjunto (mínimos cuadrados enteros) y redondeo minimax (programación lineal entera). Todas las aproximaciones se miden contra la curva original con dos números: el error cuadrático medio E_{rms} y el error en el peor punto $e_{\text{máx}}$. Cada redondeo es el mejor en su propia medida: el conjunto minimiza E_{rms} y el minimax minimiza $e_{\text{máx}}$, que es la medida del criterio de diseño.

Índice

1. Definiciones **1**

2. Las aproximaciones **2**

3. Redondeo conjunto: MCO con enteros **2**
3.1. Por qué no alcanza con redondear cada número 3
3.2. Método 1: ventana de ±3 3
3.3. Método 2: Schnorr–Euchner 4

4. Redondeo minimax: programación lineal entera **5**

5. Resultados con $C_{LAM} = 20$ **5**
5.1. Tres curvas 5
5.2. Los 41 sujetos 8
5.3. Espacio de trabajo 8

6. Conclusiones **9**

1. Definiciones

- **Curva objetivo** y: presión de la arteria en función del estiramiento circunferencial $\lambda \in [1{,}02;\ 1{,}16]$, en 999 puntos $\lambda_1, \ldots, \lambda_{999}$. Rango: $\Delta y = \max y - \min y$.
- **Lámina** del material j: aporta $A_j(\lambda) = S_j \max(0, \lambda - k_j)$, con nudo k_j y pendiente S_j.
- **Base** $A \in \mathbb{R}^{999 \times N}$: una columna por material ($N = 5$ o 6).
- **Diseño**: láminas de cada material; $c \in \mathbb{R}^N$ si es real, $z \in \mathbb{Z}^N_{\geq 0}$ si es entero. Curva del injerto: Az.

- **Errores** contra la curva original, en % de Δy:

$$E_{\mathrm{rms}}(z) = \frac{100}{\Delta y}\sqrt{\frac{1}{999}\sum_i \left(y_i - (Az)_i\right)^2}, \qquad e_{\mathrm{máx}}(z) = \frac{100}{\Delta y}\max_i |y_i - (Az)_i|.$$

  E_{rms} es el apartamiento típico; $e_{\mathrm{máx}}$, el peor punto. Siempre $E_{\mathrm{rms}} \le e_{\mathrm{máx}}$.
- **Criterios** (en $e_{\mathrm{máx}}$): método, con láminas reales, ≤ 3 %; injerto fabricable, con láminas enteras, ≤ 4 %.
- **Escala** C_{LAM}: $S_j = \texttt{PEND_MAX}_j / C_{LAM}$, de modo que $0 \le c_j \le C_{LAM}$ en toda la franja. Se adopta $C_{LAM} = 20$.

La escala no cambia la curva. Pasar de C a C' divide cada pendiente por C'/C y multiplica cada coeficiente por C'/C: el producto $c_j S_j$, y por lo tanto la curva, no cambia. Es una identidad exacta. Con láminas enteras sí cambia: los saltos de una lámina se achican y el redondeo mejora.

Curvas usadas. 41 sujetos de Masson et al. [1]; tres curvas de ejemplo (y_2, la más rígida; Mean HT, media de los 25 hipertensos; y_1, la más blanda), y las 22 500 curvas del espacio de trabajo, entre y_1 e y_2.

Tabla 1: Bases. S_j con $C_{LAM} = 20$.

	5 materiales		6 materiales	
j	k_j	S_j [kPa]	k_j	S_j [kPa]
1	0,8291	1,92	0,8271	1,90
2	1,0231	9,32	1,0219	9,07
3	1,0942	12,06	1,0867	9,08
4	1,1273	24,78	1,1197	19,60
5	1,1472	40,72	1,1391	28,24
6	–	–	1,1531	40,28

2. Las aproximaciones

Aproximación	Qué da	Referencia
MCO (reales)	el diseño real de menor E_{rms}: $c_{MCO} = A^+ y$	[2, 3]
Red neuronal (reales)	aproxima c_{MCO} en una sola evaluación	informe de la red
Redondeo simple	cada coeficiente de la red al entero más cercano	–
Redondeo conjunto	el entero de menor E_{rms}	[4, 5]
Redondeo minimax	el entero de menor $e_{\mathrm{máx}}$	[6, 8, 9]

El MCO es el piso de E_{rms}: ningún entero lo mejora. A^+ es la seudoinversa de Moore–Penrose [2].

3. Redondeo conjunto: MCO con enteros

$$z_{conj} = \arg\min_{z \in \mathbb{Z}^N_{\ge 0}} E_{\mathrm{rms}}(z).$$

Es un problema de mínimos cuadrados enteros (punto más cercano de un retículo [4]).

Atajo de Pitágoras. El residuo del MCO es ortogonal a las columnas de A (ecuaciones normales, $A^{\mathsf{T}}(y - Ac_{MCO}) = 0$) [3]. Por eso

$$\boxed{E_{\text{rms}}(z)^2 = E_{\text{rms}}(c_{MCO})^2 + D(z)}, \qquad D(z) = (z - c_{MCO})^{\mathsf{T}}\,\widetilde{M}\,(z - c_{MCO}), \quad \widetilde{M} = \frac{10^4}{999\,\Delta y^2} A^{\mathsf{T}}A.$$

El primer término es fijo; minimizar E_{rms} es minimizar D, una cuenta con una matriz de $N \times N$.

3.1. Por qué no alcanza con redondear cada número

Ejemplo: y_2, 6 materiales. $c_{MCO} = (19{,}78;\ 8{,}43;\ 14{,}98;\ 20{,}00;\ 13{,}79;\ 10{,}68)$, $E_{\text{rms}}(c_{MCO})^2 = 0{,}2422$ ($E_{\text{rms}} = 0{,}492$ %) y

$$\widetilde{M} = \begin{pmatrix} 0{,}9197 & 1{,}2120 & 0{,}3683 & 0{,}2492 & 0{,}0988 & 0{,}0158 \\ 1{,}2120 & 1{,}8565 & 0{,}6477 & 0{,}4641 & 0{,}1897 & 0{,}0310 \\ 0{,}3683 & 0{,}6477 & 0{,}2792 & 0{,}2234 & 0{,}0962 & 0{,}0162 \\ 0{,}2492 & 0{,}4641 & 0{,}2234 & 0{,}2166 & 0{,}1044 & 0{,}0187 \\ 0{,}0988 & 0{,}1897 & 0{,}0962 & 0{,}1044 & 0{,}0630 & 0{,}0132 \\ 0{,}0158 & 0{,}0310 & 0{,}0162 & 0{,}0187 & 0{,}0132 & 0{,}0047 \end{pmatrix}.$$

Tabla 2: y_2, 6 materiales: tres combinaciones enteras. $E_{\text{rms}} = \sqrt{0{,}2422 + D}$.

Combinación	z	$D(z)$	E_{rms} [%]
Redondeo de c_{MCO}	20, 8, 15, 20, 14, 11	0,1253	0,606
Mejor piso/techo ($2^6 = 64$ pruebas)	20, 8, 15, 21, 13, 11	0,0523	0,543
Óptimo	**20, 8, 16, 20, 13, 11**	**0,0230**	**0,515**

El óptimo tiene $z_3 = 16$, fuera del piso (14) y del techo (15) de 14,98. Una lámina más del material 3 y una menos del 4 casi se compensan en el dominio, así que el óptimo puede desplazarse en esa dirección.

3.2. Método 1: ventana de ±3

1. Calcular c_{MCO} y redondear cada coeficiente.
2. Tomar 7 candidatos por material: el redondeo y 3 enteros a cada lado (sin negativos).
3. Evaluar las 7^N combinaciones ($7^5 = 16\,807$; $7^6 = 117\,649$) con $D(z)$.
4. Quedarse con la de menor D, es decir, de menor E_{rms}.

¿Por qué ±3? Se midió, en las 22 500 curvas, cuántas veces cada ventana contiene al óptimo exacto (Tabla 3). ±3 es la menor que nunca falla. Es una comprobación empírica; el Método 2 es exacto siempre.

Tabla 3: Espacio de trabajo (22 500 curvas), $C_{LAM} = 20$: curvas en que cada ventana contiene al óptimo.

Ventana	5 materiales	6 materiales
±0 (redondear sin buscar)	15 %	5 %
±1	88 %	65 %
±2	100 %	98,6 %
±3	**100 %**	**100 %**

3.3. Método 2: Schnorr–Euchner

Algoritmo exacto de búsqueda en árbol para el punto más cercano de un retículo [5, 4]. Con la descomposición de Cholesky $\widetilde{M} = R^{\mathsf{T}}R$ [3],

$$D(z) = \sum_{k=1}^{N} R_{kk}^2\,(z_k - s_k)^2, \qquad s_k = c_k - \frac{1}{R_{kk}} \sum_{l>k} R_{kl}(z_l - c_l).$$

El término k depende solo de $z_k, \ldots, z_N$, y cada término es ≥ 0. Por eso:

1. Presupuesto inicial: la D del redondeo.
2. Se elige z_N, luego z_{N-1}, …, probando cada uno del más cercano a su centro s_k al más lejano.
3. Si la suma parcial supera el presupuesto, la rama se descarta sin completarla.
4. Cada combinación completa mejor baja el presupuesto. Al terminar, la mejor es el óptimo exacto.

Ejemplo con dos materiales (Mean HT, 6 materiales, $C_{LAM} = 10$, materiales 1–4 fijos; Fig. 1). Centro efectivo (3,81; 2,59), $R = \begin{pmatrix} 0{,}9171 & 0{,}1927 \\ 0 & 0{,}1602 \end{pmatrix}$.

Tabla 4: Traza de Schnorr–Euchner. Unidades: (% del rango)^2.

Inicio	Redondeo $(3, 3)$: presupuesto 0,4445.
$z_6 = 3$	Parcial 0,0043; $s_5 = 3{,}72$. $z_5 = 4$: total 0,0687, **nueva mejor**. $z_5 = 3$: 0,4445, no mejora.
$z_6 = 2$	Parcial 0,0089; $s_5 = 3{,}93$. $z_5 = 4$: total 0,0126, **nueva mejor**.
$z_6 = 4, 1, 5, 0, 6$	Parciales 0,051; 0,065; 0,149; 0,172; 0,299, todas $>$ 0,0126: **se descartan**.
Resultado	Óptimo $(4, 2)$ con 3 combinaciones completas evaluadas.

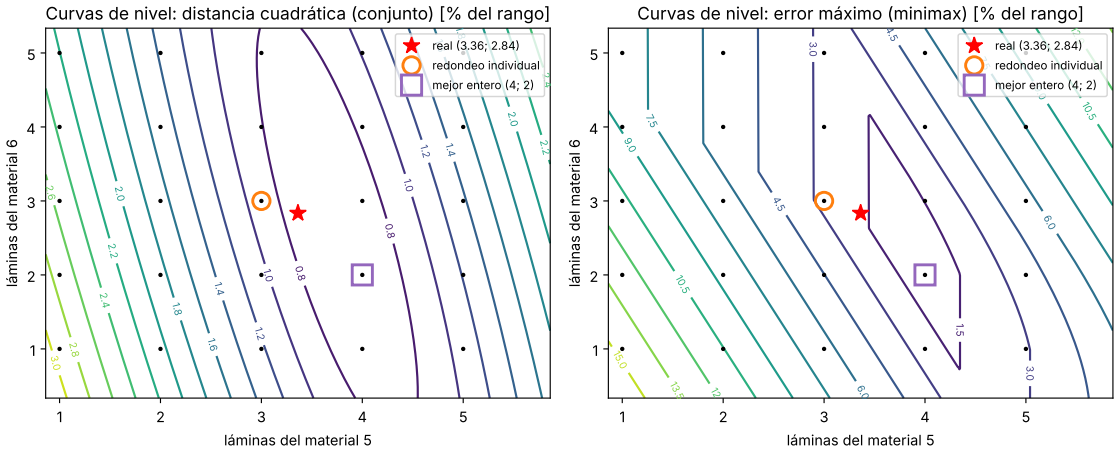


Figura 1: Mean HT, 6 materiales, $C_{LAM} = 10$, materiales 1–4 fijos. Curvas de nivel de E_{rms} (izquierda) y $e_{\text{máx}}$ (derecha) en función de las láminas de los materiales 5 y 6. Estrella: MCO; círculo: redondeo; cuadrado: mejor entero.

Verificación. Los Métodos 1 y 2 dan la misma combinación en las 22 500 curvas y en las 44 curvas de los sujetos y ejemplos, con 5 y 6 materiales.

4. Redondeo minimax: programación lineal entera

La idea: el túnel

Se dibuja un túnel de semiancho τ alrededor de la arteria. Se busca el túnel más angosto dentro del cual entra la curva del injerto; su semiancho es el peor error. Estar dentro del túnel en cada punto son dos desigualdades lineales; con enteros, el problema se resuelve por ramificación y acotación.

$$\min_{z\in\mathbb{Z}^N_{\geq 0}} \max_i |y_i - (Az)_i| \iff \min_{z,\tau} \tau \quad \text{s.a.} \quad \begin{pmatrix} A & -\mathbf{1} \\ -A & -\mathbf{1} \end{pmatrix} \begin{pmatrix} z \\ \tau \end{pmatrix} \leq \begin{pmatrix} y \\ -y \end{pmatrix}, \; z \in \mathbb{Z}^N_{\geq 0}.$$

- Con z real es un programa lineal: la aproximación de Chebyshev (norma del máximo) [6], que el símplex resuelve exactamente [7].
- Con z entero es un programa lineal entero mixto, resuelto por ramificación y acotación [8]: si un z_j sale fraccionario (por ejemplo 15,66), se abren dos ramas, $z_j \leq 15$ y $z_j \geq 16$; toda rama cuya cota supera la mejor solución entera se descarta.
- Implementación: HiGHS [9] vía `scipy.optimize.milp` [10], con 500 puntos (uno de cada dos) y verificación en los 999. Unos 0,07 s por curva.

Ejemplo (y_2, 6 materiales): con z real, $\tau = 1{,}20$ %; con z entero, $z = (20, 8, 17, 18, 16, 9)$ y $\tau = 1{,}29$ % (Fig. 2).

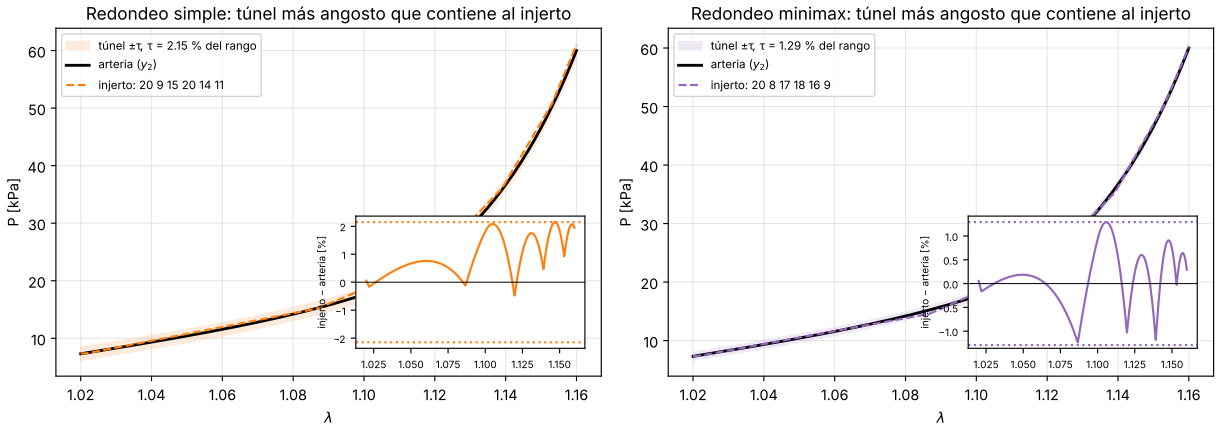


Figura 2: y_2, 6 materiales, $C_{LAM} = 20$: túnel más angosto que contiene al injerto con el redondeo simple ($\tau = 2{,}15$ %) y con el minimax ($\tau = 1{,}29$ %).

5. Resultados con $C_{LAM} = 20$

5.1. Tres curvas

En negrita, el menor E_{rms} y el menor $e_{\text{máx}}$ entre las filas enteras.

Tabla 5: y_2. Errores contra la curva original [% del rango].

Mat.	Aproximación	c_1	c_2	c_3	c_4	c_5	c_6	E_{rms}	$e_{\text{máx}}$
5	MCO (sin redondear)	19,77	8,53	17,31	20,00	11,60	–	0,673	2,25
	Red neuronal (sin redondear)	19,74	8,68	17,17	21,06	11,56	–	0,845	2,11
	Redondeo simple (de la red)	20	9	17	21	12	–	1,246	2,93
	Método 1: ventana ±3	20	8	18	20	12	–	**0,717**	2,46
	Método 2: Schnorr–Euchner	20	8	18	20	12	–	**0,717**	2,46
	Minimax	19	9	18	20	10	–	0,807	**1,70**
6	MCO (sin redondear)	19,78	8,43	14,98	20,00	13,79	10,68	0,492	1,68
	Red neuronal (sin redondear)	19,72	8,68	14,71	20,04	14,16	11,12	0,551	1,48
	Redondeo simple (de la red)	20	9	15	20	14	11	1,134	2,15
	Método 1: ventana ±3	20	8	16	20	13	11	**0,515**	1,59
	Método 2: Schnorr–Euchner	20	8	16	20	13	11	**0,515**	1,59
	Minimax	20	8	17	18	16	9	0,570	**1,29**

Tabla 6: Mean HT.

Mat.	Aproximación	c_1	c_2	c_3	c_4	c_5	c_6	E_{rms}	$e_{\text{máx}}$
5	MCO (sin redondear)	9,52	8,23	7,99	7,27	6,30	–	0,509	1,31
	Red neuronal (sin redondear)	9,51	8,25	8,01	7,26	6,28	–	0,511	1,27
	Redondeo simple (de la red)	10	8	8	7	6	–	0,682	2,21
	Método 1: ventana ±3	10	8	8	7	7	–	**0,639**	**1,52**
	Método 2: Schnorr–Euchner	10	8	8	7	7	–	**0,639**	**1,52**
	Minimax	10	8	8	7	7	–	**0,639**	**1,52**
6	MCO (sin redondear)	9,52	8,10	7,94	6,74	6,72	5,67	0,368	0,96
	Red neuronal (sin redondear)	9,55	8,12	7,93	6,75	6,73	5,67	0,376	0,87
	Redondeo simple (de la red)	10	8	8	7	7	6	0,945	2,27
	Método 1: ventana ±3	9	9	6	8	6	5	**0,591**	1,23
	Método 2: Schnorr–Euchner	9	9	6	8	6	5	**0,591**	1,23
	Minimax	10	8	8	6	8	4	0,665	**1,17**

Tabla 7: y_1.

Mat.	Aproximación	c_1	c_2	c_3	c_4	c_5	c_6	E_{rms}	$e_{\text{máx}}$
5	MCO (sin redondear)	0,85	5,97	0,96	0,95	0,69	–	0,210	1,49
	Red neuronal (sin redondear)	0,85	5,94	0,95	0,93	0,57	–	0,432	1,59
	Redondeo simple (de la red)	1	6	1	1	1	–	1,302	3,35
	Método 1: ventana ±3	1	6	1	1	0	–	**1,041**	**2,03**
	Método 2: Schnorr–Euchner	1	6	1	1	0	–	**1,041**	**2,03**
	Minimax	1	6	1	1	0	–	**1,041**	**2,03**
6	MCO (sin redondear)	0,72	6,12	0,93	0,91	0,78	0,62	0,140	0,97
	Red neuronal (sin redondear)	0,67	6,13	0,98	0,86	0,76	0,46	0,229	0,82
	Redondeo simple (de la red)	1	6	1	1	1	0	1,036	2,04
	Método 1: ventana ±3	1	6	1	1	0	2	**0,876**	**2,02**
	Método 2: Schnorr–Euchner	1	6	1	1	0	2	**0,876**	**2,02**
	Minimax	1	6	1	1	0	2	**0,876**	**2,02**

- Métodos 1 y 2 coinciden siempre y dan el menor E_{rms} entero; el minimax da el menor $e_{\text{máx}}$.
- El redondeo simple es siempre el peor: en Mean HT con 6 materiales, $E_{\text{rms}} = 0{,}945$ % contra 0,591 % del conjunto.
- El minimax puede bajar el $e_{\text{máx}}$ del propio MCO (y_2, 6 materiales: 1,29 contra 1,68 %), porque el MCO minimiza E_{rms}, no el peor punto.

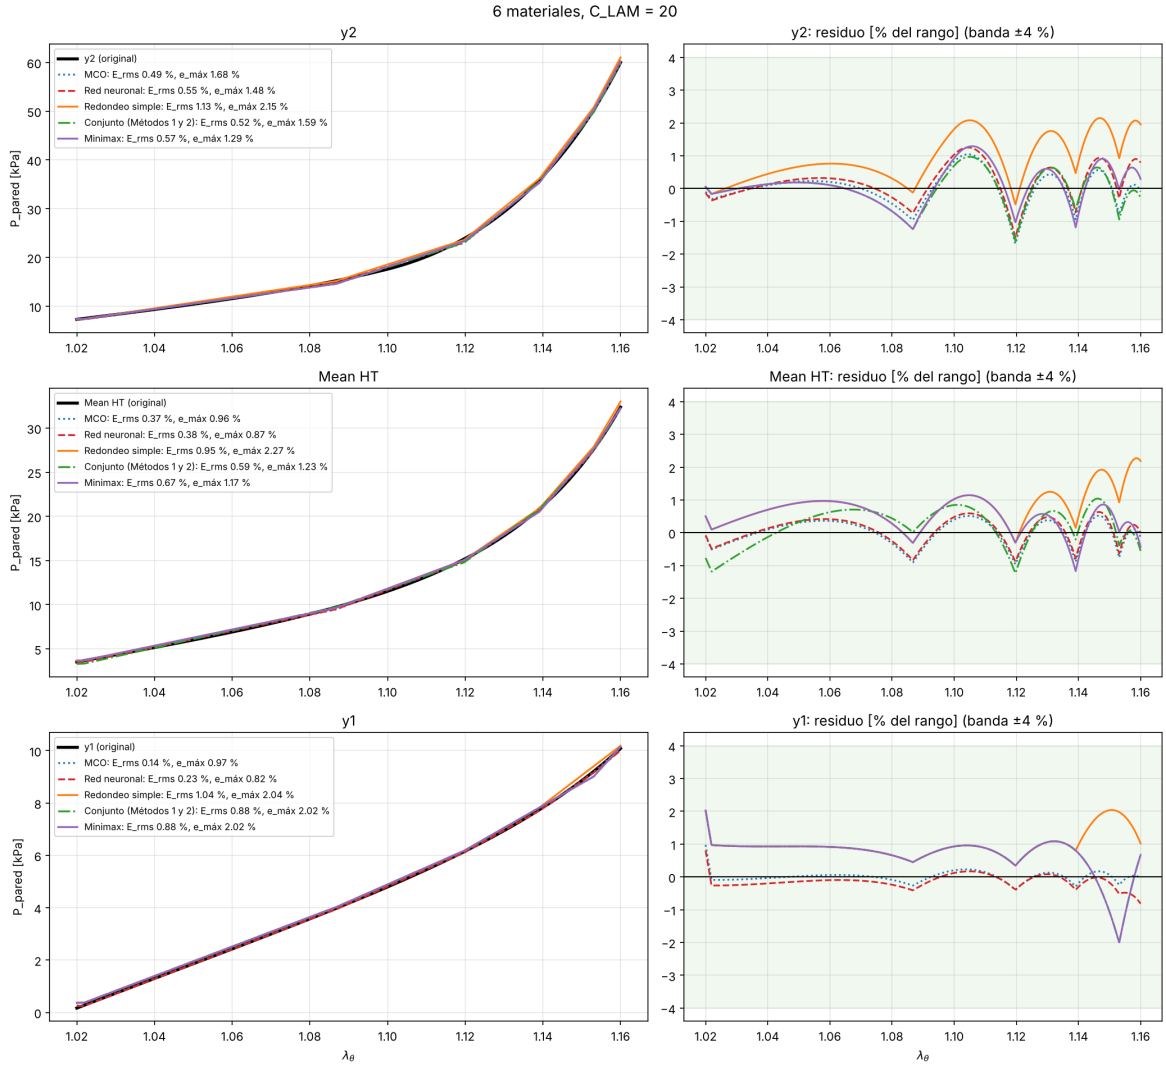


Figura 3: 6 materiales: curvas y residuos [% del rango] de las seis aproximaciones. Banda verde: ±4 %.

5.2. Los 41 sujetos

Tabla 8: Sujetos que cumplen el 3 % y el 4 % de $e_{\text{máx}}$, y peor $e_{\text{máx}}$ [%].

		Cumplen el 3 %			Cumplen el 4 %			Peor $e_{\text{máx}}$ [%]		
Mat.	C_{LAM}	simple	conj.	minimax	simple	conj.	minimax	simple	conj.	minimax
5	10	9	28	31	19	33	35	42,72	8,79	8,79
	20	30	38	39	35	40	41	21,75	4,07	3,84
	30	33	41	41	38	41	41	5,07	2,56	2,56
	40	37	41	41	40	41	41	4,60	2,60	2,43
	50	37	41	41	39	41	41	7,57	2,01	1,51
6	10	10	34	36	18	38	38	43,72	8,54	8,54
	20	26	38	39	32	41	41	23,46	3,41	3,41
	30	37	41	41	39	41	41	7,10	2,52	2,27
	40	36	41	41	38	41	41	10,13	2,11	2,11
	50	39	41	41	39	41	41	5,54	1,52	1,33

Con $C_{LAM} = 20$ el minimax cumple el 4 % en los 41 sujetos con 5 y con 6 materiales (peor caso 3,84 y 3,41 %). En E_{rms}, el conjunto nunca es superado por el minimax en ningún sujeto; en $e_{\text{máx}}$, el minimax nunca es superado por el conjunto.

5.3. Espacio de trabajo

Tabla 9: 22 500 curvas: porcentaje que cumple el 3 % y el 4 % de $e_{\text{máx}}$, y peor caso. Minimax en negrita: curva por curva; resto de las escalas: 2000 curvas al azar.

		Cumplen el 3 % [%]			Cumplen el 4 % [%]			Peor $e_{\text{máx}}$ [%]		
Mat.	C_{LAM}	simple	conj.	minimax	simple	conj.	minimax	simple	conj.	minimax
5	10	27,13	61,16	76,35	44,39	85,89	92,65	49,78	12,81	9,75
	20	61,04	94,97	**98,56**	78,83	99,36	**99,88**	27,32	6,38	**6,26**
	30	79,54	99,45	**99,95**	91,69	99,98	**100**	14,47	4,64	**3,89**
	40	89,98	99,95	100	96,77	100	100	10,30	3,21	2,12
	50	94,44	100	100	98,55	100	100	12,11	3,02	1,90
6	10	31,11	80,02	86,75	47,16	93,36	96,35	50,63	11,89	8,87
	20	67,03	98,47	**99,48**	81,86	99,83	**99,96**	28,54	5,98	**5,98**
	30	84,79	99,88	**99,98**	93,42	100	**100**	15,35	4,13	**3,48**
	40	92,99	100	100	97,70	100	100	13,63	3,01	1,96
	50	96,69	100	100	99,04	100	100	9,55	2,70	1,69

Tabla 10: 22 500 curvas, $C_{LAM} = 20$: mediana, percentil 99 y peor caso [% del rango].

		E_{rms}			$e_{\text{máx}}$		
Mat.	Aproximación	mediana	p99	peor	mediana	p99	peor
5	MCO	0,46	0,62	0,68	1,23	1,65	2,06
	Red	0,46	0,62	1,12	1,23	1,68	3,74
	Redondeo simple	1,06	4,72	11,71	2,58	9,95	27,32
	Conjunto (Mét. 1 y 2)	0,68	1,71	3,70	1,91	3,78	6,38
	Minimax	0,80	1,91	3,70	1,56	3,14	6,26
6	MCO	0,33	0,45	0,49	0,89	1,18	1,38
	Red	0,34	0,47	1,53	0,86	1,26	4,50
	Redondeo simple	1,01	4,72	12,50	2,31	10,14	28,54
	Conjunto (Mét. 1 y 2)	0,54	1,46	3,28	1,47	3,19	5,98
	Minimax	0,64	1,65	3,70	1,24	2,69	5,98

Con $C_{LAM} = 20$ y el 4 %, el minimax deja fuera 28 (5 materiales) y 10 (6 materiales) de las 22 500 curvas, todas del extremo blando de la franja. Con $C_{LAM} = 30$ cumplen todas. El minimax optimiza sobre 500 puntos; medido en 999, en menos del 1,5 % de las curvas el conjunto lo supera en $e_{\text{máx}}$, por a lo sumo 0,05 puntos.

6. Conclusiones

1. Todas las aproximaciones se comparan contra la curva original con E_{rms} y $e_{\text{máx}}$.
2. El redondeo conjunto es el MCO con enteros; por Pitágoras se reduce a minimizar una forma cuadrática de $N \times N$. La ventana ± 3 y Schnorr–Euchner dan el mismo óptimo en todas las curvas evaluadas.
3. El redondeo minimax minimiza el peor punto, la medida del criterio. Es un programa lineal entero, exacto y rápido. **Es el método recomendado.**
4. El redondeo simple no es recomendable.
5. Con $C_{LAM} = 20$ el minimax cumple el 4 % en los 41 sujetos y en el 99,88 % (5 materiales) y 99,96 % (6) de la franja.
6. La escala de láminas es una elección de unidades para los coeficientes reales. Al fijar el espesor de cada capa, el diseño entero se obtiene con los mismos métodos.

Referencias

[1] Masson, I., Beaussier, H., Boutouyrie, P., Laurent, S., Humphrey, J. D., Zidi, M. (2011). Carotid artery mechanical properties and stresses quantified using in vivo data from normotensive and hypertensive humans. *Biomech. Model. Mechanobiol.* 10(6), 867–882. https://doi.org/10.1007/s10237-010-0279-6

[2] Penrose, R. (1955). A generalized inverse for matrices. *Math. Proc. Cambridge Philos. Soc.* 51(3), 406–413. https://doi.org/10.1017/S0305004100030401

[3] Trefethen, L. N., Bau, D. (1997). *Numerical Linear Algebra*. SIAM (mínimos cuadrados, SVD, Cholesky). https://doi.org/10.1137/1.9780898719574

[4] Agrell, E., Eriksson, T., Vardy, A., Zeger, K. (2002). Closest point search in lattices. *IEEE Trans. Inf. Theory* 48(8), 2201–2214. https://doi.org/10.1109/TIT.2002.800499

[5] Schnorr, C. P., Euchner, M. (1994). Lattice basis reduction: improved practical algorithms and solving subset sum problems. *Math. Programming* 66, 181–199. https://doi.org/10.1007/BF01581144

[6] Boyd, S., Vandenberghe, L. (2004). *Convex Optimization*. Cambridge Univ. Press, Sec. 6.1 (aproximación en norma ℓ_∞ como programa lineal). https://web.stanford.edu/~boyd/cvxbook/

[7] Dantzig, G. B. (1963). *Linear Programming and Extensions*. Princeton Univ. Press. https://doi.org/10.1515/9781400884179

[8] Land, A. H., Doig, A. G. (1960). An automatic method of solving discrete programming problems. *Econometrica* 28(3), 497–520. https://doi.org/10.2307/1910129

[9] Huangfu, Q., Hall, J. A. J. (2018). Parallelizing the dual revised simplex method. *Math. Programming Computation* 10, 119–142. https://doi.org/10.1007/s12532-017-0130-5. Software HiGHS: https://highs.dev

[10] Virtanen, P. et al. (2020). SciPy 1.0: fundamental algorithms for scientific computing in Python. *Nature Methods* 17, 261–272. https://doi.org/10.1038/s41592-019-0686-2. Función `milp`: https://docs.scipy.org/doc/scipy/reference/generated/scipy.optimize.milp.html