Diseño de injertos vasculares biomiméticos con una red neuronal

Pablo

24 de octubre de 2026

Resumen

Se presenta un método para diseñar un injerto vascular multicapa que reproduzca la curva presión–estiramiento de una arteria. Cada capa es un material cuyas fibras se tensan a partir de un estiramiento propio, el nudo; su aporte se idealiza como una recta truncada. El injerto es una suma de esas rectas, y la cantidad de cada material se obtiene por mínimos cuadrados (MCO). Una red neuronal aprende a dar esas cantidades en una sola evaluación. La base (los nudos) se elige una vez, para que el MCO sin restricciones cumpla el criterio de diseño en toda la franja de arterias. Se evalúa con 5 y 6 materiales sobre 41 carótidas humanas [1] y 22 500 curvas sintéticas.

Índice

1. El problema **1**

2. Las curvas **2**

3. La base de materiales **2**
3.1. Una capa, una recta truncada 2
3.2. Las cantidades: mínimos cuadrados 3
3.3. Elección de los nudos 3

4. La red neuronal **4**

5. Resultados **5**

6. Escalado al espesor de cada capa **6**

7. Conclusiones **6**

1. El problema

- **Curva objetivo** $y(\lambda)$: presión de pared P [kPa] en función del estiramiento circunferencial λ (proporcional al diámetro), en $\lambda \in [1{,}02;\ 1{,}16]$, discretizada en 999 puntos.
- **Injerto**: superposición de capas de N materiales ($N = 5$ o 6). Cada material aporta presión solo después de su nudo k_j.
- **Incógnita**: la cantidad c_j de cada material.
- **Errores** contra la curva original, en % del rango $\Delta y = \max y - \min y$:

$$E_{\text{rms}} = \frac{100}{\Delta y}\sqrt{\frac{1}{999}\sum_i r_i^2}, \qquad e_{\text{máx}} = \frac{100}{\Delta y}\max_i |r_i|, \qquad r_i = y(\lambda_i) - P_{inj}(\lambda_i).$$

- **Criterio de diseño**: $e_{\text{máx}} \leq 3\ \%$.

Dividir por el rango hace el criterio igual de exigente con una arteria blanda que con una rígida.

2. Las curvas

Sujetos. Las curvas de 41 carótidas humanas (16 normotensas y 25 hipertensas) se calculan con la ley constitutiva y los parámetros publicados por Masson et al. [1]: matriz neo-Hookeana, cuatro familias de fibras de colágeno [2] y tono muscular activo [3]. La presión de pared sale de integrar el equilibrio radial de un cilindro de pared gruesa [1]. Diez sujetos se reservan para test.

Franja de trabajo. Dos curvas límite encierran a los 41 sujetos (Fig. 1):

- y_2 (superior): el sujeto más rígido, extendido hasta 60 kPa;
- y_1 (inferior): una curva de la misma ley, con parámetros dentro del rango de los sujetos, que parte de la menor presión medida y queda debajo de todos.

El **espacio de trabajo** son 22 500 curvas sintéticas de la ley de Masson, con parámetros mezclados, perturbados o sorteados a partir de los sujetos de entrenamiento, aceptadas solo si son positivas, monótonas, convexas y quedan dentro de la franja.

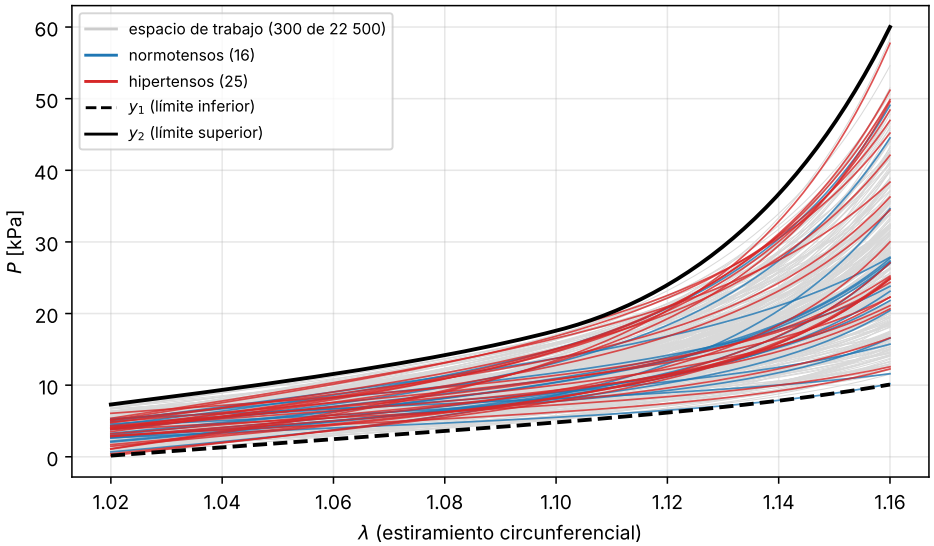


Figura 1: Los 41 sujetos, las curvas límite y una muestra del espacio de trabajo.

3. La base de materiales

3.1. Una capa, una recta truncada

Una capa unitaria del material j aporta

$$A_j(\lambda) = S_j\,\text{máx}(0,\ \lambda - k_j)\ :$$

nada hasta el nudo k_j y luego una recta de pendiente S_j. El injerto es la suma

$$P_{inj}(\lambda) = \sum_{j=1}^{N} c_j\,A_j(\lambda) = (Ac)(\lambda),$$

una poligonal con un quiebre en cada nudo. $A \in \mathbb{R}^{999\times N}$ es la **base**: una columna por material.

3.2. Las cantidades: mínimos cuadrados

Con la base fija, el injerto es lineal en c, y el mejor ajuste cuadrático es

$$c_{MCO} = \arg\min_{c} \ \|y - Ac\|_2^2 = A^{+}y,$$

con A^{+} la seudoinversa de Moore–Penrose [4], calculada por descomposición en valores singulares [5]. Es exacto, único e instantáneo. El MCO se aplica *sin restricciones*: la base se elige para que no hagan falta.

3.3. Elección de los nudos

Los nudos entran en forma no lineal. Se eligen una sola vez minimizando una función objetivo $J(k)$ que reúne tres exigencias sobre todo el espacio de trabajo:

1. **Precisión**: la media del peor 1 % de los $e_{\text{máx}}$ del MCO (CVaR 99 % [6]). Mira solo las peores curvas, pero no depende de una sola.
2. **Estabilidad**: número de condición $\text{cond}(A) < 25$ (columnas normalizadas) [5]. Un $\text{cond}(A)$ alto amplifica el ruido de la curva en las cantidades: $\|\delta c\|/\|c\| \lesssim \text{cond}(A)\, \|\delta y\|/\|y\|$.
3. **Signo**: penalización por cantidades negativas, que no son fabricables.

J se minimiza con evolución diferencial [7], una búsqueda global por población, y se refina con Nelder–Mead [8]. Ninguno de los dos necesita derivadas.

Pendientes. Fijados los nudos, $S_j = \texttt{PEND_MAX}_j / C_{LAM}$, con $\texttt{PEND_MAX}_j$ la mayor pendiente que el material j debe aportar en la franja. Así $0 \le c_j \le C_{LAM}$ en toda la franja. C_{LAM} es solo una escala: la curva depende de $c_j S_j$, no de cada factor por separado (Sec. 6).

Tabla 1: Bases adoptadas y desempeño del MCO.

	5 materiales	6 materiales
Nudos k_j	0,8291; 1,0231; 1,0942; 1,1273; 1,1472	0,8271; 1,0219; 1,0867; 1,1197; 1,1391; 1,1531
$\text{cond}(A)$	17,97	23,98
MCO, peor $e_{\text{máx}}$: 41 sujetos / espacio de trabajo	1,64 / 2,06 %	1,17 / 1,38 %
MCO, mediana de E_{rms} en el espacio de trabajo	0,46 %	0,33 %
Cantidades negativas (sujetos y espacio de trabajo)	ninguna	ninguna

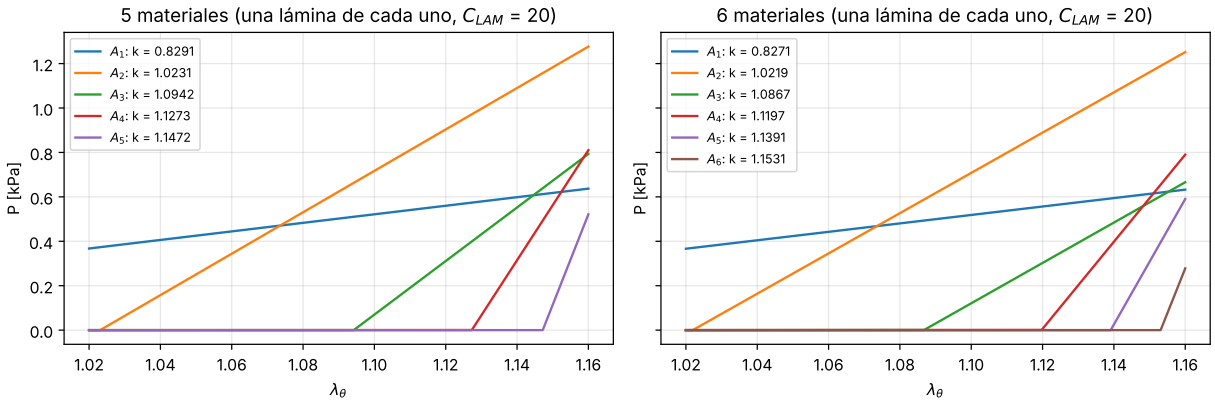


Figura 2: Una capa unitaria de cada material ($C_{LAM} = 20$). Los nudos se agrupan hacia λ alto, donde la curva arterial se curva más.

4. La red neuronal

La red recibe la curva y devuelve las N cantidades: aprende la función $y \mapsto A^{+}y$ para la clase de curvas de interés.

Datos. 50 000 curvas en siete familias:

- *de bases* (40 %): sumas de capas de la propia base, que enseñan qué hace cada material por separado;
- *fisiológicas* (60 %): ley de Masson con parámetros mezclados, perturbados o sorteados; otra ley exponencial; los sujetos de entrenamiento con ruido.

Se agrega ruido gaussiano del 0,5 o 1 % para imitar errores de medición. La etiqueta de cada curva es su c_{MCO}. Partición estratificada: 35 000 de entrenamiento, 5 000 de validación, 10 000 de test.

Arquitectura. Perceptrón multicapa [9]:

- entrada: la curva en 999 puntos, como $\log(y+5)$ y estandarizada punto a punto [10];
- tres capas densas de 256, 128 y 64 neuronas, con activación ReLU [11], normalización de capa [12] y regularización L_2 (10^{-5});
- salida lineal con las N cantidades estandarizadas (unos 298 000 parámetros).

Pérdida.

$$L = \underbrace{\mathrm{MSE}(\hat{c}, c)}_{\text{cantidades}} + 5\ \underbrace{\mathrm{media}\left(\frac{A(\hat{c}-c)}{\max Ac}\right)^{2}}_{\text{curva reconstruida}} + 5\ \underbrace{\mathrm{media}(m \odot \hat{c}^{\,2})}_{\text{crosstalk}},$$

donde $m = 1$ marca los materiales ausentes en las curvas de bases: penaliza que la red asigne cantidad a un material que no está.

Entrenamiento. Optimizador Adam [13] (tasa inicial 10^{-3}, recorte del gradiente [14]), lotes de 64, reducción de la tasa a la mitad tras 30 épocas sin mejora (hasta 10^{-6}) y parada temprana tras 80 [15]. Implementado en TensorFlow/Keras [16].

Control de clase. Antes de usar la red se verifica que la curva admita una aproximación no negativa con 40 rectas truncadas (NRMSE ≤ 2 %), calculada por mínimos cuadrados no negativos [17]. Una curva que no la admite no tiene forma de J y no se puede reproducir con capas.

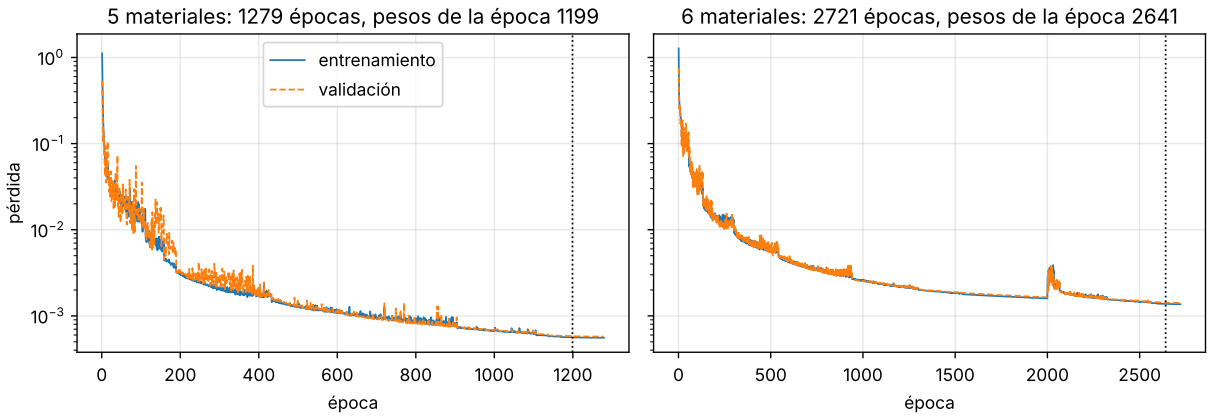


Figura 3: Pérdida de entrenamiento y validación. Las dos terminan juntas: no hay sobreajuste.

5. Resultados

Medidas. *Óptimo*: el MCO. *Exceso* = $\mathrm{NRMSE}_{red}/\mathrm{NRMSE}_{MCO} - 1$, donde NRMSE es el E_{rms} en %.

Entrenamiento. 5 materiales: 1279 épocas, pesos de la época 1199. 6 materiales: 2721 épocas, pesos de la época 2641 (Fig. 3).

Tabla 2: 41 sujetos: red sola (sin pulido) frente al MCO.

	5 materiales			6 materiales		
	Todos	Entren.	Test	Todos	Entren.	Test
NRMSE MCO [%]	0,462	0,453	0,489	0,334	0,328	0,354
NRMSE red [%]	0,466	0,455	0,501	0,350	0,336	0,392
Exceso	+1,0 %	+0,5 %	+2,3 %	+4,8 %	+2,7 %	+10,7 %
Peor $e_{\mathrm{máx}}$ de la red [%]	1,58	1,56	1,58	1,15	1,13	1,15
Cumplen $e_{\mathrm{máx}} \leq 3$ %	41/41	31/31	10/10	41/41	31/31	10/10

- Con 6 materiales el MCO es más preciso (0,334 contra 0,462 %) y la red también, aunque se aparta más del MCO (exceso +4,8 %). El peor caso de test es NT08: NRMSE 0,433 contra 0,221 % del MCO (+96 %), con $e_{\mathrm{máx}} = 0{,}81$ %, lejos del criterio.
- En las cuatro curvas medias de Masson la red cumple con $e_{\mathrm{máx}} \leq 1{,}36$ % (5 materiales) y $\leq 1{,}13$ % (6).

Tabla 3: Test (10 000 curvas) por familia. Exceso de la red y porcentaje de curvas en que la red cumple $e_{\mathrm{máx}} \leq 3$ % (el MCO cumple en todas, salvo 2 curvas exponenciales fuera de la franja con 5 materiales).

		5 materiales		6 materiales	
Familia	n	Exceso	Red cumple	Exceso	Red cumple
constitutiva	2000	+0,4 %	100 %	+1,5 %	100 %
amplia	1500	+0,7 %	99,93 %	+1,9 %	99,87 %
uniforme	1000	+0,7 %	100 %	+1,9 %	100 %
exponencial	1000	+1,2 %	99,70 %	+3,2 %	99,70 %
pacientes	500	+0,4 %	100 %	+1,2 %	100 %
pura (de bases)	2000	+25,6 %	99,45 %	+35,8 %	98,35 %
combinada (de bases)	2000	+37,7 %	99,15 %	+63,3 %	98,80 %

- **Familias fisiológicas** (forma arterial): la red está prácticamente sobre el MCO. Las pocas curvas que no cumplen están fuera de la franja (la familia exponencial no se filtra) o en su borde.
- **Familias de bases**: el exceso relativo es alto sobre óptimos muy bajos (NRMSE 0,24–0,32 %). Son poligonales de muy poca presión, que no representan arterias; un paso de MCO (*pulido*) las lleva al óptimo exacto.

Ley nunca vista. En 300 curvas de una ley exponencial tipo Fung [18], ausente del entrenamiento, el exceso es +1,3 % (5 materiales) y +10,0 % (6), con $R^2 \geq 0{,}994$. El control de clase las acepta todas y rechaza el 95,7 % de las curvas que dejan de tener forma de J.

Materiales aislados. Con una sola capa de entrada, la cantidad asignada a los materiales ausentes (*crosstalk*) es a lo sumo 0,008 ($C_{LAM} = 20$).

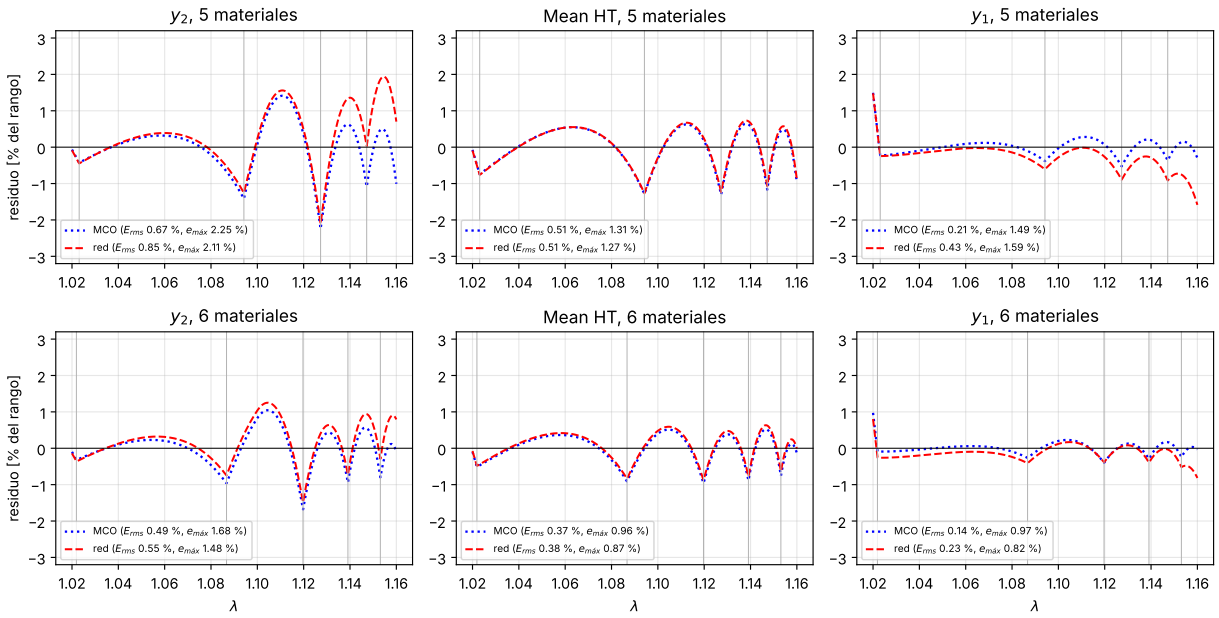


Figura 4: Residuo (aproximación − curva) del MCO y de la red en tres curvas, $C_{LAM} = 20$. Líneas grises: nudos. Los picos caen en los nudos: es el piso de la base, no de la red.

6. Escalado al espesor de cada capa

La cantidad c_j es adimensional: lo que fija la curva es el producto $c_j S_j$. Por eso:

- **Cambio de escala**: con C' en lugar de C, $S'_j = S_j\, C/C'$ y $c'_j = c_j\, C'/C$; la curva no cambia. La red entrenada con una escala sirve para cualquier otra multiplicando su salida.
- **Espesor de capa**: por la ley de Laplace para un tubo de pared delgada [18], una capa de espesor h_j y módulo equivalente E_j aporta $\dfrac{E_j h_j}{R\, k_j^2}\,\text{máx}(0, \lambda - k_j)$, con R el radio de referencia. Igualando con $c_j S_j$,

$$h_j = \frac{c_j\, S_j\, R\, k_j^2}{E_j}.$$

Elegidos los materiales (E_j), la misma solución da el espesor de cada capa. Si las capas se fabrican con láminas de espesor fijo, las cantidades deben ser enteras: ver el informe de métodos de redondeo.

7. Conclusiones

1. El injerto se modela como suma de rectas truncadas; las cantidades se obtienen por MCO sin restricciones.
2. La exigencia se traslada a la base, elegida una vez (CVaR 99 %, $\text{cond}(A) < 25$, signo; evolución diferencial y Nelder–Mead). Con 5 y 6 materiales, el MCO cumple el criterio en los 41 sujetos y en las 22 500 curvas, sin cantidades negativas.
3. La red reproduce el MCO en una sola evaluación: en los 41 sujetos el exceso es +1,0 % (5 materiales) y +4,8 % (6), y todos cumplen el criterio; en las familias fisiológicas, entre +0,4 y +3,2 %. La red con 5 materiales sigue más de cerca al MCO; la de 6 es más precisa en valor absoluto.
4. El método escala a cualquier espesor de capa con una relación lineal.

Referencias

[1] Masson, I., Beaussier, H., Boutouyrie, P., Laurent, S., Humphrey, J. D., Zidi, M. (2011). Carotid artery mechanical properties and stresses quantified using in vivo data from normotensive and hypertensive humans. *Biomech. Model. Mechanobiol.* 10(6), 867–882. https://doi.org/10.1007/s10237-010-0279-6

[2] Holzapfel, G. A., Gasser, T. C., Ogden, R. W. (2000). A new constitutive framework for arterial wall mechanics and a comparative study of material models. *J. Elasticity* 61, 1–48. https://doi.org/10.1023/A:1010835316564

[3] Rachev, A., Hayashi, K. (1999). Theoretical study of the effects of vascular smooth muscle contraction on strain and stress distributions in arteries. *Ann. Biomed. Eng.* 27, 459–468. https://doi.org/10.1114/1.191

[4] Penrose, R. (1955). A generalized inverse for matrices. *Math. Proc. Cambridge Philos. Soc.* 51(3), 406–413. https://doi.org/10.1017/S0305004100030401

[5] Trefethen, L. N., Bau, D. (1997). *Numerical Linear Algebra*. SIAM (mínimos cuadrados, SVD, número de condición). https://doi.org/10.1137/1.9780898719574

[6] Rockafellar, R. T., Uryasev, S. (2000). Optimization of conditional value-at-risk. *J. Risk* 2(3), 21–41. https://doi.org/10.21314/JOR.2000.038

[7] Storn, R., Price, K. (1997). Differential evolution: a simple and efficient heuristic for global optimization over continuous spaces. *J. Global Optim.* 11, 341–359. https://doi.org/10.1023/A:1008202821328

[8] Nelder, J. A., Mead, R. (1965). A simplex method for function minimization. *Computer J.* 7(4), 308–313. https://doi.org/10.1093/comjnl/7.4.308

[9] Goodfellow, I., Bengio, Y., Courville, A. (2016). *Deep Learning*. MIT Press. https://www.deeplearningbook.org

[10] Pedregosa, F. et al. (2011). Scikit-learn: machine learning in Python. *JMLR* 12, 2825–2830 (estandarización, `StandardScaler`). https://jmlr.org/papers/v12/pedregosa11a.html

[11] Nair, V., Hinton, G. E. (2010). Rectified linear units improve restricted Boltzmann machines. *ICML 2010*. https://icml.cc/Conferences/2010/papers/432.pdf

[12] Ba, J. L., Kiros, J. R., Hinton, G. E. (2016). Layer normalization. https://arxiv.org/abs/1607.06450

[13] Kingma, D. P., Ba, J. (2015). Adam: a method for stochastic optimization. *ICLR 2015*. https://arxiv.org/abs/1412.6980

[14] Pascanu, R., Mikolov, T., Bengio, Y. (2013). On the difficulty of training recurrent neural networks. *ICML 2013*, PMLR 28 (recorte del gradiente). https://proceedings.mlr.press/v28/pascanu13.html

[15] Prechelt, L. (1998). Early stopping — but when? En *Neural Networks: Tricks of the Trade*, LNCS 1524, 55–69. https://doi.org/10.1007/3-540-49430-8_3

[16] Abadi, M. et al. (2016). TensorFlow: large-scale machine learning on heterogeneous distributed systems. https://arxiv.org/abs/1603.04467. Keras: https://keras.io

[17] Lawson, C. L., Hanson, R. J. (1995). *Solving Least Squares Problems*. SIAM (mínimos cuadrados no negativos). https://doi.org/10.1137/1.9781611971217

[18] Fung, Y. C. (1993). *Biomechanics: Mechanical Properties of Living Tissues*, 2.ª ed. Springer (ley de Laplace; ley exponencial de Fung). https://doi.org/10.1007/978-1-4757-2257-4