Diseño de injertos vasculares biomiméticos con una red neuronal

Pablo

24 de octubre de 2026

Resumen

Se presenta un método para diseñar un injerto vascular multicapa que reproduzca la curva presión–estiramiento de una arteria. Cada capa es un material cuyas fibras se tensan a partir de un estiramiento propio, el nudo; su aporte se idealiza como una recta truncada. El injerto es una suma de esas rectas, y la cantidad de cada material se obtiene por mínimos cuadrados (MCO). Una red neuronal aprende a dar esas cantidades en una sola evaluación. La base (los nudos) se elige una vez, para que el MCO sin restricciones cumpla el criterio de diseño en toda la franja de arterias. Se evalúa con 5 y 6 materiales sobre 41 carótidas humanas [1] y 22 500 curvas sintéticas.

Índice

1. El problema **1**

2. Las curvas **2**

3. La base de materiales **3**
3.1. Una capa, una recta truncada 3
3.2. Las cantidades: mínimos cuadrados 3
3.3. Elección de los nudos 3

4. La red neuronal **4**

5. Resultados **5**

6. Escalado al espesor de cada capa **7**

7. Conclusiones **7**

A. La ley de Masson y los datos de partida **7**

B. Glosario de métodos y términos **13**

1. El problema

- **Curva objetivo** $y(\lambda)$: presión de pared P [kPa] en función del estiramiento circunferencial λ (proporcional al diámetro), en $\lambda \in [1{,}02;\ 1{,}16]$, discretizada en 999 puntos.
- **Injerto**: superposición de capas de N materiales ($N = 5$ o 6). Cada material aporta presión solo después de su nudo k_j.
- **Incógnita**: la cantidad c_j de cada material.

- **Errores** contra la curva original, en % del rango $\Delta y = \max y - \min y$:

$$E_{\text{rms}} = \frac{100}{\Delta y}\sqrt{\frac{1}{999}\sum_i r_i^2}, \qquad e_{\text{máx}} = \frac{100}{\Delta y}\max_i |r_i|, \qquad r_i = y(\lambda_i) - P_{inj}(\lambda_i).$$

- **Criterio de diseño**: $e_{\text{máx}} \leq 3$ %.

Dividir por el rango hace el criterio igual de exigente con una arteria blanda que con una rígida.

2. Las curvas

Ley de Masson. Masson et al. [1] midieron in vivo el diámetro y la presión de la carótida común de 16 sujetos normotensos y 25 hipertensos, y ajustaron a cada uno una ley constitutiva de la pared, que en este informe se llama *ley de Masson*. La ley suma tres aportes: la elastina (respuesta casi lineal), cuatro familias de fibras de colágeno (respuesta exponencial, que da la forma de J) [2] y el tono del músculo liso [3]. Con los parámetros publicados de cada sujeto y el equilibrio radial de un cilindro de pared gruesa se obtiene su curva $P(\lambda)$. El Anexo A da las ecuaciones, las tablas de los 41 sujetos y la validación contra las Figs. 5a y 7a del artículo.

Sujetos. Son las curvas $P(\lambda)$ de las 41 carótidas. Diez se reservan para test.

Franja de trabajo. Dos curvas límite encierran a los 41 sujetos (Fig. 1):

- y_2 (superior): el sujeto más rígido, extendido hasta 60 kPa;
- y_1 (inferior): una curva de la misma ley, con parámetros dentro del rango de los sujetos, que parte de la menor presión medida y queda debajo de todos.

El **espacio de trabajo** son 22 500 curvas sintéticas de la ley de Masson, con parámetros mezclados, perturbados o sorteados a partir de los sujetos de entrenamiento, aceptadas solo si son positivas, monótonas, convexas y quedan dentro de la franja.

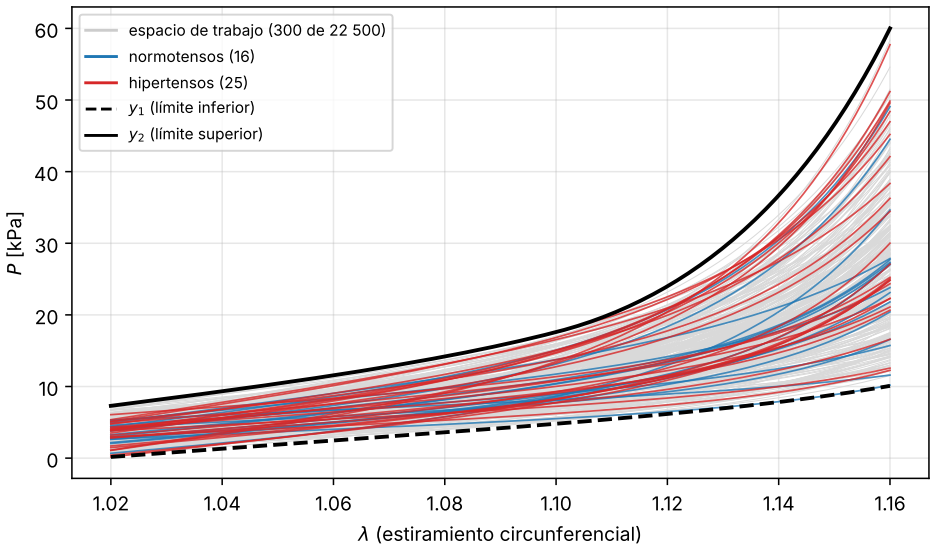


Figura 1: Los 41 sujetos, las curvas límite y una muestra del espacio de trabajo.

3. La base de materiales

3.1. Una capa, una recta truncada

Una capa unitaria del material j aporta

$$A_j(\lambda) = S_j \,\mathrm{máx}(0,\ \lambda - k_j)\ :$$

nada hasta el nudo k_j y luego una recta de pendiente S_j. El injerto es la suma

$$P_{inj}(\lambda) = \sum_{j=1}^{N} c_j\, A_j(\lambda) = (Ac)(\lambda),$$

una poligonal con un quiebre en cada nudo. $A \in \mathbb{R}^{999\times N}$ es la **base**: una columna por material.

3.2. Las cantidades: mínimos cuadrados

Con la base fija, el injerto es lineal en c, y el mejor ajuste cuadrático es

$$c_{MCO} = \arg\min_{c}\ \|y - Ac\|_2^2 = A^{+}y,$$

con A^{+} la *seudoinversa de Moore–Penrose* [4]: la matriz que resuelve mínimos cuadrados; si las columnas de A son independientes, $A^{+} = (A^{\mathsf{T}}A)^{-1}A^{\mathsf{T}}$. Se calcula con la descomposición en valores singulares [5] (Anexo B). Es exacto, único e instantáneo. El MCO se aplica *sin restricciones*: la base se elige para que no hagan falta.

3.3. Elección de los nudos

Los nudos entran en forma no lineal. Se eligen una sola vez minimizando una función objetivo $J(k)$ que reúne tres exigencias sobre todo el espacio de trabajo:

1. **Precisión: CVaR 99 %** [6]. Se calcula el $e_{\mathrm{máx}}$ del MCO en cada curva, se ordenan de mayor a menor y se promedia el 1 % peor (con 2532 curvas de optimización, las 25 peores). Mira solo la cola de peores casos, pero no depende de una sola curva, como pasaría con el máximo.
2. **Estabilidad: cond**$(A) < 25$ [5]. El *número de condición* es el cociente entre el mayor y el menor valor singular de A. Acota cuánto se amplifica un error de la curva en las cantidades: $\|\delta c\|/\|c\| \lesssim \mathrm{cond}(A)\,\|\delta y\|/\|y\|$. Crece cuando dos columnas se parecen (dos nudos muy próximos). Se calcula con las columnas *normalizadas* (cada una dividida por su máximo), para que dependa solo de los nudos.
3. **Signo**: penalización por cantidades negativas, que no son fabricables.

Juntas forman la función objetivo

$$J(k) = \mathrm{CVaR}_{99} + 0{,}25\,\overline{\mathrm{NRMSE}} + 50\,\mathrm{máx}\left(0, \mathrm{cond}(A) - 24\right) + 1000\,\overline{\mathrm{neg}} + 100\,\max_{i}\mathrm{neg}_i,$$

con $\mathrm{neg}_i = \sum_j \mathrm{máx}(0, -c_{ij})$ la parte negativa de las cantidades de la curva i. Los tres últimos términos valen cero si se cumplen la estabilidad y el signo, y son muy grandes si no: actúan como restricciones.

J se minimiza en dos etapas, con métodos que solo necesitan evaluar J (sin derivadas):

1. **Evolución diferencial** [7] (búsqueda global): una población de juegos de nudos repartida en todo el rango se mejora generación tras generación combinando sus miembros ($v = x_{mejor} + F(x_a - x_b)$) y quedándose con el mejor de cada par.
2. **Nelder–Mead** [8] (refinamiento local): un simplex de $N+1$ puntos se refleja, expande o contrae hasta el mínimo más cercano.

El Anexo B detalla los dos métodos.

Pendientes. Fijados los nudos, $S_j = \texttt{PEND_MAX}_j / C_{LAM}$, con $\texttt{PEND_MAX}_j$ la mayor pendiente que el material j debe aportar en la franja. Así $0 \le c_j \le C_{LAM}$ en toda la franja. C_{LAM} es solo una escala: la curva depende de $c_j S_j$, no de cada factor por separado (Sec. 6).

Tabla 1: Bases adoptadas y desempeño del MCO.

	5 materiales	6 materiales
Nudos k_j	0,8291; 1,0231; 1,0942; 1,1273; 1,1472	0,8271; 1,0219; 1,0867; 1,1197; 1,1391; 1,1531
cond(A)	17,97	23,98
MCO, peor $e_{\text{máx}}$: 41 sujetos / espacio de trabajo	1,64 / 2,06 %	1,17 / 1,38 %
MCO, mediana de E_{rms} en el espacio de trabajo	0,46 %	0,33 %
Cantidades negativas (sujetos y espacio de trabajo)	ninguna	ninguna

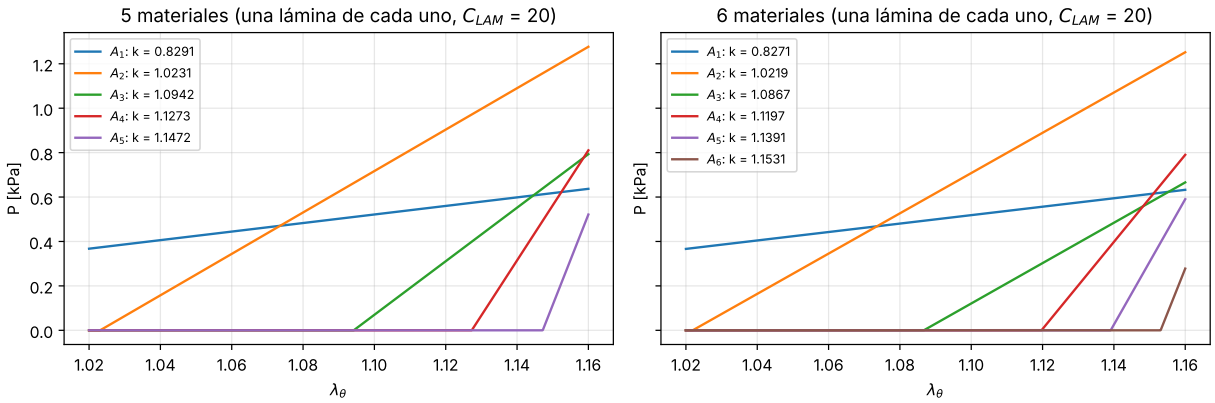


Figura 2: Una capa unitaria de cada material ($C_{LAM} = 20$). Los nudos se agrupan hacia λ alto, donde la curva arterial se curva más.

4. La red neuronal

La red recibe la curva y devuelve las N cantidades: aprende la función $y \mapsto A^{+}y$ para la clase de curvas de interés.

Datos. 50 000 curvas en siete familias:

- *de bases* (40 %): sumas de capas de la propia base, que enseñan qué hace cada material por separado;
- *fisiológicas* (60 %): ley de Masson con parámetros mezclados, perturbados o sorteados; otra ley exponencial; los sujetos de entrenamiento con ruido.

Se agrega ruido gaussiano del 0,5 o 1 % para imitar errores de medición. La etiqueta de cada curva es su c_{MCO}. Partición estratificada: 35 000 de entrenamiento, 5 000 de validación, 10 000 de test.

Arquitectura. Perceptrón multicapa [9]:

- entrada: la curva en 999 puntos, como $\log(y + 5)$ y estandarizada punto a punto [10];
- tres capas densas de 256, 128 y 64 neuronas, con activación ReLU [11], normalización de capa [12] y regularización L_2 (10^{-5});
- salida lineal con las N cantidades estandarizadas (unos 298 000 parámetros).

Pérdida.

$$L = \underbrace{\mathrm{MSE}(\hat{c}, c)}_{\text{cantidades}} + 5\ \underbrace{\mathrm{media}\left(\frac{A(\hat{c}-c)}{\max Ac}\right)^2}_{\text{curva reconstruida}} + 5\ \underbrace{\mathrm{media}(m \odot \hat{c}^2)}_{\text{crosstalk}},$$

donde $m = 1$ marca los materiales ausentes en las curvas de bases: penaliza que la red asigne cantidad a un material que no está.

Entrenamiento. Optimizador Adam [13] (tasa inicial 10^{-3}, recorte del gradiente [14]), lotes de 64, reducción de la tasa a la mitad tras 30 épocas sin mejora (hasta 10^{-6}) y parada temprana tras 80 [15]. Implementado en TensorFlow/Keras [16].

Control de clase. Antes de usar la red se verifica que la curva admita una aproximación no negativa con 40 rectas truncadas (NRMSE ≤ 2 %), calculada por mínimos cuadrados no negativos [17]. Una curva que no la admite no tiene forma de J y no se puede reproducir con capas.

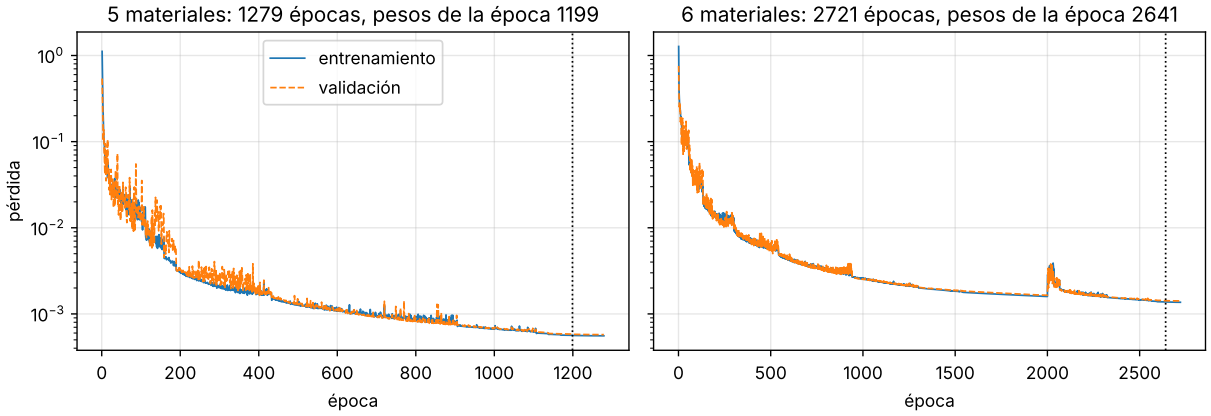


Figura 3: Pérdida de entrenamiento y validación. Las dos terminan juntas: no hay sobreajuste.

5. Resultados

Medidas. *Óptimo*: el MCO. *Exceso* = $\mathrm{NRMSE}_{red}/\mathrm{NRMSE}_{MCO} - 1$, donde NRMSE es el E_{rms} en %.

Entrenamiento. 5 materiales: 1279 épocas, pesos de la época 1199. 6 materiales: 2721 épocas, pesos de la época 2641 (Fig. 3).

Tabla 2: 41 sujetos: red sola (sin pulido) frente al MCO.

	5 materiales			6 materiales		
	Todos	Entren.	Test	Todos	Entren.	Test
NRMSE MCO [%]	0,462	0,453	0,489	0,334	0,328	0,354
NRMSE red [%]	0,466	0,455	0,501	0,350	0,336	0,392
Exceso	+1,0 %	+0,5 %	+2,3 %	+4,8 %	+2,7 %	+10,7 %
Peor $e_{\mathrm{máx}}$ de la red [%]	1,58	1,56	1,58	1,15	1,13	1,15
Cumplen $e_{\mathrm{máx}} \leq 3$ %	41/41	31/31	10/10	41/41	31/31	10/10

- Con 6 materiales el MCO es más preciso (0,334 contra 0,462 %) y la red también, aunque se aparta más del MCO (exceso +4,8 %). El peor caso de test es NT08: NRMSE 0,433 contra 0,221 % del MCO (+96 %), con $e_{\mathrm{máx}} = 0{,}81$ %, lejos del criterio.

- En las cuatro curvas medias de Masson la red cumple con $e_{\text{máx}} \leq 1{,}36$ % (5 materiales) y $\leq 1{,}13$ % (6).

Tabla 3: Test (10 000 curvas) por familia. Exceso de la red y porcentaje de curvas en que la red cumple $e_{\text{máx}} \leq 3$ % (el MCO cumple en todas, salvo 2 curvas exponenciales fuera de la franja con 5 materiales).

		5 materiales		6 materiales	
Familia	n	Exceso	Red cumple	Exceso	Red cumple
constitutiva	2000	+0,4 %	100 %	+1,5 %	100 %
amplia	1500	+0,7 %	99,93 %	+1,9 %	99,87 %
uniforme	1000	+0,7 %	100 %	+1,9 %	100 %
exponencial	1000	+1,2 %	99,70 %	+3,2 %	99,70 %
pacientes	500	+0,4 %	100 %	+1,2 %	100 %
pura (de bases)	2000	+25,6 %	99,45 %	+35,8 %	98,35 %
combinada (de bases)	2000	+37,7 %	99,15 %	+63,3 %	98,80 %

- **Familias fisiológicas** (forma arterial): la red está prácticamente sobre el MCO. Las pocas curvas que no cumplen están fuera de la franja (la familia exponencial no se filtra) o en su borde.
- **Familias de bases**: el exceso relativo es alto sobre óptimos muy bajos (NRMSE 0,24–0,32 %). Son poligonales de muy poca presión, que no representan arterias; un paso de MCO (*pulido*) las lleva al óptimo exacto.

Ley nunca vista. En 300 curvas de una ley exponencial tipo Fung [18], ausente del entrenamiento, el exceso es +1,3 % (5 materiales) y +10,0 % (6), con $R^2 \geq 0{,}994$. El control de clase las acepta todas y rechaza el 95,7 % de las curvas que dejan de tener forma de J.

Materiales aislados. Con una sola capa de entrada, la cantidad asignada a los materiales ausentes (*crosstalk*) es a lo sumo 0,008 ($C_{LAM} = 20$).

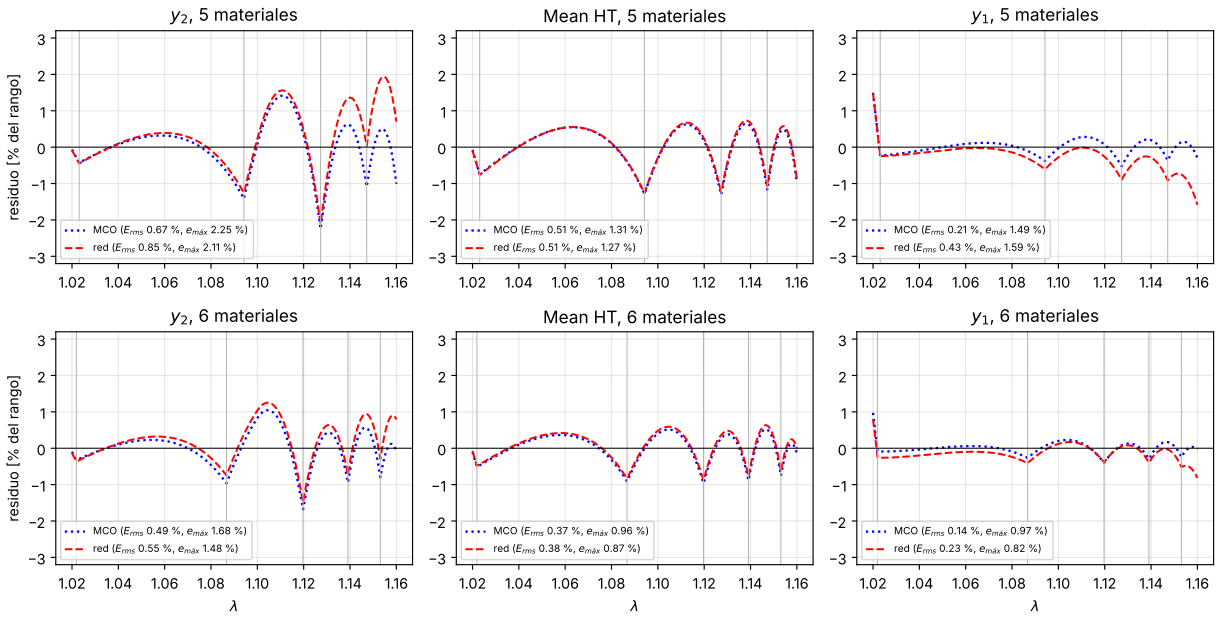


Figura 4: Residuo (aproximación − curva) del MCO y de la red en tres curvas, $C_{LAM} = 20$. Líneas grises: nudos. Los picos caen en los nudos: es el piso de la base, no de la red.

6. Escalado al espesor de cada capa

La cantidad c_j es adimensional: lo que fija la curva es el producto $c_j S_j$. Por eso:

- **Cambio de escala**: con C' en lugar de C, $S'_j = S_j\, C/C'$ y $c'_j = c_j\, C'/C$; la curva no cambia. La red entrenada con una escala sirve para cualquier otra multiplicando su salida.
- **Espesor de capa**: por la ley de Laplace para un tubo de pared delgada [18], una capa de espesor h_j y módulo equivalente E_j aporta $\dfrac{E_j h_j}{R\, k_j^2}\,\text{máx}(0, \lambda - k_j)$, con R el radio de referencia. Igualando con $c_j S_j$,

$$h_j = \frac{c_j\, S_j\, R\, k_j^2}{E_j}.$$

  Elegidos los materiales (E_j), la misma solución da el espesor de cada capa. Si las capas se fabrican con láminas de espesor fijo, las cantidades deben ser enteras: ver el informe de métodos de redondeo.

7. Conclusiones

1. El injerto se modela como suma de rectas truncadas; las cantidades se obtienen por MCO sin restricciones.
2. La exigencia se traslada a la base, elegida una vez (CVaR 99 %, cond(A) < 25, signo; evolución diferencial y Nelder–Mead). Con 5 y 6 materiales, el MCO cumple el criterio en los 41 sujetos y en las 22 500 curvas, sin cantidades negativas.
3. La red reproduce el MCO en una sola evaluación: en los 41 sujetos el exceso es +1,0 % (5 materiales) y +4,8 % (6), y todos cumplen el criterio; en las familias fisiológicas, entre +0,4 y +3,2 %. La red con 5 materiales sigue más de cerca al MCO; la de 6 es más precisa en valor absoluto.
4. El método escala a cualquier espesor de capa con una relación lineal.

A. La ley de Masson y los datos de partida

Este anexo reúne lo que el método toma de Masson et al. [1], para que el informe sea autocontenido.

Qué midieron. Los autores midieron in vivo, en forma no invasiva y a lo largo del ciclo cardíaco, el diámetro y la presión de la carótida común de 16 sujetos normotensos (NT) y 25 hipertensos tratados (HT). A cada sujeto le ajustaron un modelo constitutivo de la pared arterial y publicaron sus parámetros (Tablas 4 y 5).

La ley constitutiva ("ley de Masson"). La pared es un material incompresible cuya energía de deformación tiene tres partes [1]:

- **Elastina**: material neo-Hookeano de módulo c, de respuesta casi lineal.
- **Colágeno**: cuatro familias de fibras con respuesta exponencial (extensión del modelo de Holzapfel, Gasser y Ogden [2]): axial, circunferencial y dos diagonales a $\pm\alpha$. Una fibra no aporta mientras no se estira y luego se rigidiza muy rápido: es lo que da la forma de J.
- **Tono muscular activo** (modelo de Rachev y Hayashi [3]): tensión máxima T_m y estiramientos característicos λ_0 (sin tensión activa) y λ_m (tensión máxima).

Con estiramiento axial fijo λ_z e incompresibilidad ($\lambda_r = 1/(\lambda_\theta \lambda_z)$), la diferencia de tensiones circunferencial y radial es

$$\sigma_{\theta\theta} - \sigma_{rr} = \underbrace{c\left(\lambda_\theta^2 - \lambda_r^2\right)}_{\text{elastina}} + \underbrace{\lambda_\theta^2 \sum_{k=1}^{4} c_{1,k}\, E_k\, e^{\,c_{2,k} E_k^2} \sin^2 \varphi_k}_{\text{colágeno}} + \underbrace{T_m \lambda_\theta \left[1 - \left(\frac{\lambda_m - \lambda_\theta}{\lambda_m - \lambda_0}\right)^2\right]}_{\text{tono activo}},$$

con $E_k = \lambda_k^2 - 1$:

Familia	Ángulo φ_k (desde el eje)	Estiramiento λ_k	$c_{1,k}$	$c_{2,k}$
axial	0	λ_z	c_1	c_2
circunferencial	90°	λ_θ	c_1^{circ}	c_2^{circ}
diagonales	$\pm\alpha$	$\sqrt{\lambda_\theta^2 \sin^2\alpha + \lambda_z^2 \cos^2\alpha}$	c_1	c_2

La familia axial no aporta en la dirección circunferencial ($\sin 0 = 0$).

Cinemática. La configuración libre de tensiones es un sector anular abierto (ángulo de apertura Θ_0, radio medio R_m), que representa las tensiones residuales. Un punto de radio R pasa al radio r en la arteria cerrada; por incompresibilidad,

$$R^2 = R_m^2 - \frac{\pi \lambda_z}{\Theta_0}\left(r_m^2 - r^2\right), \qquad \lambda_\theta(r) = \frac{\pi r}{\Theta_0 R}.$$

La abscisa de todas las curvas es el estiramiento en el radio medio, $\lambda = \lambda_\theta(r_m) = r_m/R_{ref}$, con $R_{ref} = \Theta_0 R_m/\pi$: es proporcional al diámetro.

De la tensión a la presión. El equilibrio radial de un cilindro de pared gruesa, $\partial\sigma_{rr}/\partial r + (\sigma_{rr} - \sigma_{\theta\theta})/r = 0$, integrado sobre el espesor de la pared, da la presión que soporta la pared [1]:

$$P(\lambda) = P_i - P_a = \int_{r_i}^{r_m} \frac{\sigma_{\theta\theta} - \sigma_{rr}}{r}\, dr,$$

con P_i la presión interna y P_a la presión perivascular, que no interviene. La integral se calcula con la regla del trapecio. Repitiendo el cálculo en los 999 puntos de λ se obtiene la curva $P(\lambda)$ de cada sujeto (Fig. 7).

Validación. Las Figs. 5a y 7a del artículo grafican la tensión circunferencial $\sigma_{\theta\theta}$ en r_m. Recalculada con la ley y los parámetros de las tablas, reproduce las curvas medias publicadas con un error cuadrático medio de 1,2 a 1,7 % de su valor medio (Figs. 5 y 6), del orden del error de digitalización de las figuras.

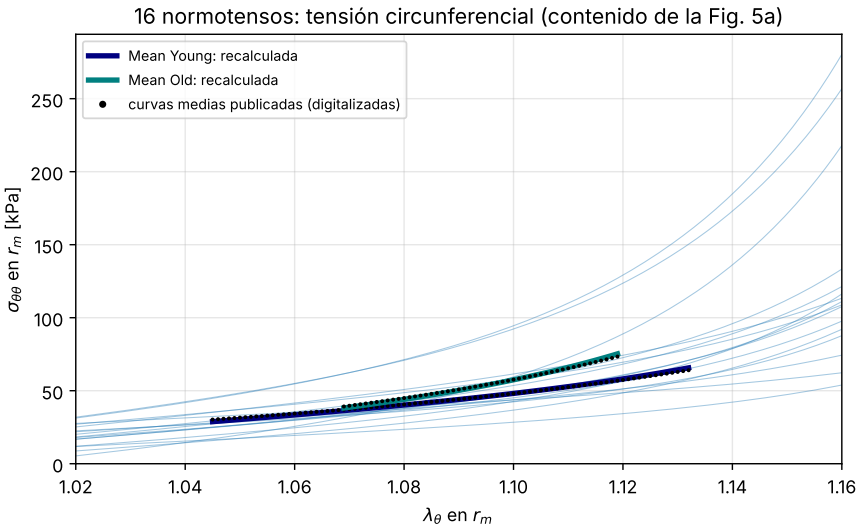


Figura 5: Contenido de la Fig. 5a de Masson et al. [1], recalculado: tensión circunferencial de los 16 normotensos (finas) y curvas medias de jóvenes (edad ≤ 42) y mayores (edad ≥ 53). Puntos: curvas medias publicadas, digitalizadas.

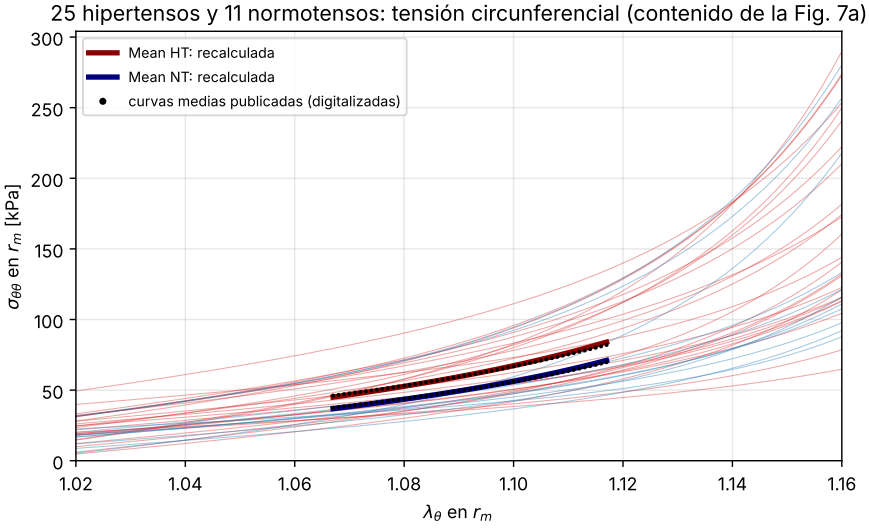


Figura 6: Contenido de la Fig. 7a de Masson et al. [1], recalculado: 25 hipertensos (rojo) y 11 normotensos de edad comparable (azul), con sus medias. Puntos: curvas medias publicadas, digitalizadas.

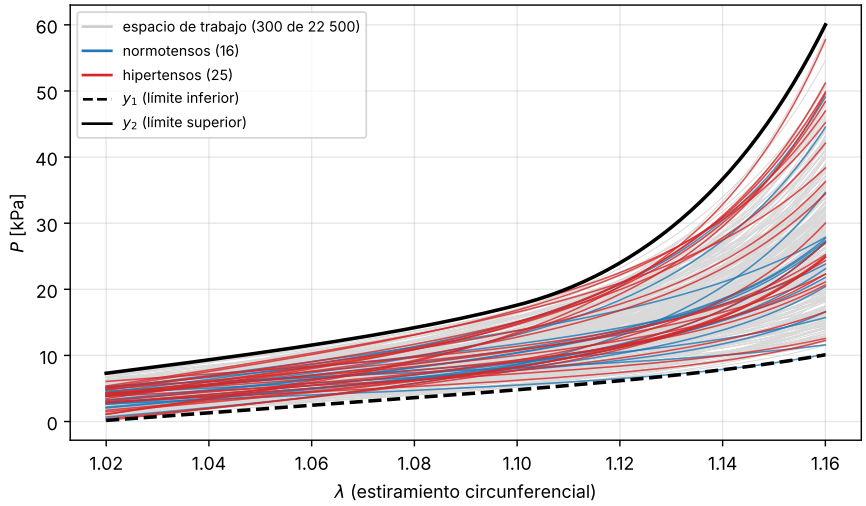


Figura 7: Resultado: presión $P(\lambda)$ de los 41 sujetos, que son las curvas objetivo, con las curvas límite y_1, y_2 y una muestra del espacio de trabajo.

Parámetros de las tablas.

- Geometría: R_m, Θ_0 (configuración libre de tensiones) y λ_z (estiramiento axial in vivo).
- Elastina: c. Colágeno: c_1, c_2 (axiales y diagonales), c_1^{circ}, c_2^{circ} (circunferenciales) y α (ángulo de las diagonales).
- Tono activo: T_m, λ_0, λ_m. Presión perivascular: a, b (no intervienen en P).

Los sujetos marcados con † son los 10 reservados para test.

Tabla 4: Tabla 2 de Masson et al. [1]: parámetros de los 16 sujetos normotensos. †: sujeto reservado para test. RMSE: error del ajuste del modelo a los datos, informado por los autores.

Sujeto	Edad [años]	Sexo	R_m [mm]	Θ_0 [°]	λ_z	c [kPa]	c_1 [kPa]	c_2	c_1^{circ} [kPa]	c_2^{circ}	α [°]	T_m [kPa]	λ_0	λ_m	a [kPa]	b	RMSE [kPa]
NT01	62	F	4,261	128,7	1,11	29,82	9,44	14,14	16,13	15,11	65,74	39,73	0,96	1,70	0,122	3,52	0,174
NT02†	60	M	4,691	128,9	1,08	20,42	8,47	13,10	14,16	15,12	44,46	41,84	0,68	1,92	0,126	3,40	0,288
NT03	31	M	4,305	132,2	1,09	27,23	10,34	13,10	7,01	12,82	48,62	43,37	0,82	1,65	0,139	3,57	0,131
NT04	31	M	4,672	133,9	1,10	23,59	6,58	11,77	6,38	10,69	32,04	39,81	0,68	1,59	0,118	3,53	0,146
NT05	34	F	4,203	130,1	1,10	35,68	13,62	13,18	13,38	13,17	50,72	50,07	0,86	1,62	0,103	3,58	0,123
NT06	53	F	3,957	130,1	1,11	33,37	11,38	13,63	13,30	14,26	57,14	46,59	0,95	1,69	0,093	3,44	0,269
NT07	21	F	3,827	132,0	1,10	44,28	21,79	13,17	8,27	12,73	51,15	53,58	0,92	1,62	0,111	3,58	0,215
NT08†	25	M	4,856	133,2	1,07	23,25	6,34	12,93	8,11	13,17	42,93	31,90	0,82	1,77	0,173	3,57	0,367
NT09	42	F	4,506	129,5	1,10	34,90	16,14	13,58	19,64	13,89	57,21	47,01	0,93	1,65	0,084	3,55	0,209
NT10†	55	M	4,770	129,1	1,10	38,57	36,31	13,31	56,88	13,61	54,22	46,36	0,89	1,66	0,006	3,75	0,652
NT11†	64	M	5,566	129,5	1,10	34,89	40,16	13,45	66,88	13,53	54,54	41,12	0,85	1,79	0,005	3,23	0,375
NT12	60	F	4,876	130,1	1,09	33,94	10,78	13,95	12,79	15,42	60,97	45,77	0,93	1,73	0,099	3,37	0,362
NT13	61	F	4,924	130,6	1,09	35,15	17,69	13,43	18,40	13,22	55,04	45,59	0,94	1,66	0,085	3,51	0,240
NT14	39	F	3,539	131,5	1,09	28,97	8,22	13,13	19,02	13,16	50,22	41,30	0,89	1,67	0,105	3,53	0,262
NT15	58	F	3,922	132,4	1,08	26,71	15,79	13,36	16,68	13,11	53,60	35,32	0,95	1,71	0,166	3,60	0,302
NT16	60	M	5,718	129,7	1,10	27,79	28,23	13,46	57,77	13,63	55,73	36,50	1,05	1,77	0,141	3,58	0,283

Tabla 5: Tabla 4 de Masson et al. [1]: parámetros de los 25 sujetos hipertensos tratados. †: sujeto reservado para test. RMSE: error del ajuste del modelo a los datos, informado por los autores.

Sujeto	Edad [años]	Sexo	R_m [mm]	Θ_0 [°]	λ_z	c [kPa]	c_1 [kPa]	c_2	c_1^{circ} [kPa]	c_2^{circ}	α [°]	T_m [kPa]	λ_0	λ_m	a [kPa]	b	RMSE [kPa]
HT01	68	M	4,965	130,9	1,10	35,91	12,57	14,08	15,52	14,91	67,18	48,42	0,99	1,66	0,098	3,50	0,300
HT02	54	M	4,927	129,8	1,10	38,20	16,40	13,20	16,44	13,20	51,11	52,44	0,86	1,62	0,137	3,58	0,213
HT03†	64	F	4,869	129,5	1,10	36,01	14,55	13,96	18,35	14,48	62,66	47,02	1,00	1,74	0,113	3,62	0,419
HT04	58	F	4,574	131,2	1,09	22,42	8,57	13,03	6,43	13,36	46,38	38,53	0,81	1,68	0,099	3,51	0,346
HT05†	62	F	4,779	130,1	1,10	48,19	35,06	13,23	43,19	13,03	53,24	52,86	0,91	1,63	0,033	3,56	0,218
HT06	66	F	5,062	129,1	1,10	39,78	37,75	13,35	60,89	13,45	56,01	46,44	0,91	1,64	0,004	3,54	0,349
HT07	54	F	4,298	129,6	1,11	50,45	25,51	13,32	39,43	13,24	53,47	64,91	0,93	1,66	0,078	3,72	0,341
HT08	63	F	4,436	129,0	1,10	34,44	30,62	13,29	60,33	13,21	54,67	44,94	0,93	1,65	0,084	3,56	0,518
HT09	68	M	5,090	128,2	1,12	51,48	33,77	13,17	44,26	13,49	51,83	66,41	0,84	1,62	0,023	3,55	0,277
HT10	55	F	4,300	129,0	1,10	37,04	12,32	14,13	15,04	14,93	65,14	48,19	1,04	1,71	0,114	3,47	0,270
HT11	69	M	5,545	131,2	1,08	29,64	9,76	13,23	9,10	15,12	48,16	37,83	0,83	1,74	0,115	3,59	0,263
HT12	54	M	5,426	131,8	1,09	32,23	17,81	13,35	14,03	12,15	53,73	44,93	0,92	1,65	0,090	3,58	0,185
HT13†	61	M	5,169	128,4	1,11	30,45	15,87	13,08	23,03	13,84	47,86	52,58	0,75	1,61	0,009	3,49	0,315
HT14†	60	M	4,640	129,9	1,10	30,43	13,74	13,45	18,01	13,35	54,90	42,43	0,91	1,66	0,088	3,52	0,158
HT15	53	M	4,649	130,4	1,10	40,83	28,98	13,36	31,16	12,62	54,44	49,57	0,93	1,65	0,085	3,63	0,311
HT16	54	M	4,713	129,6	1,10	45,26	29,27	14,00	33,48	14,82	67,16	67,68	1,02	1,65	0,039	3,52	0,194
HT17	53	M	5,043	130,0	1,10	37,25	39,18	13,24	66,29	13,15	54,90	48,26	0,91	1,64	0,099	3,60	0,252
HT18	52	M	4,922	129,7	1,10	29,28	10,50	13,21	19,76	13,39	50,96	46,42	0,85	1,63	0,094	3,56	0,200
HT19†	57	F	4,270	130,3	1,10	33,49	14,47	13,22	17,35	13,27	53,18	46,18	0,90	1,64	0,097	3,55	0,228
HT20	61	F	5,143	129,2	1,10	40,09	15,72	14,09	16,78	14,83	65,17	53,40	1,04	1,70	0,100	3,47	0,265
HT21	57	F	4,881	129,9	1,10	35,31	14,57	13,26	15,58	13,30	52,07	48,97	0,87	1,63	0,094	3,57	0,442
HT22	44	F	4,170	131,0	1,10	55,25	35,78	13,23	19,51	12,55	52,36	59,58	0,93	1,61	0,097	3,61	0,335
HT23	51	M	4,827	130,6	1,08	30,77	12,80	13,60	41,10	14,20	49,79	41,06	0,87	1,90	0,094	3,56	0,337
HT24†	65	M	4,565	129,6	1,10	38,91	25,76	13,20	35,01	13,20	51,94	50,28	0,87	1,62	0,043	3,58	0,212
HT25	67	F	4,718	129,2	1,10	40,29	31,78	13,75	60,40	14,29	63,50	46,06	1,03	1,72	0,025	3,46	0,412

B. Glosario de métodos y términos

Definiciones breves, en orden alfabético. Cada una remite a una referencia que la desarrolla.

Término	Definición	Ref.
A^+ (seudoinversa de Moore–Penrose)	Matriz que da la solución de mínimos cuadrados: si las columnas de A son independientes, $A^+ = (A^\mathsf{T}A)^{-1}A^\mathsf{T}$, y $c = A^+y$ es el vector que minimiza $\|y - Ac\|_2$. Generaliza la inversa a matrices rectangulares. Se calcula con la SVD.	[4, 5]
Adam	Algoritmo de entrenamiento de redes: descenso por gradiente en el que cada peso tiene su propio tamaño de paso, ajustado con promedios móviles del gradiente y de su cuadrado.	[13]
cond(A) (número de condición)	Cociente entre el mayor y el menor valor singular de A, s_1/s_N. Mide cuánto puede amplificarse un error relativo en la curva al pasar a las cantidades: $\|\delta c\|/\|c\| \lesssim \mathrm{cond}(A)\,\|\delta y\|/\|y\|$. Vale 1 si las columnas son ortogonales y crece cuando dos columnas se parecen (dos nudos muy próximos). *Columnas normalizadas*: antes de calcularlo, cada columna se divide por su máximo, para que cond(A) dependa solo de los nudos y no de las pendientes. Se exige cond(A) < 25: un error del 1 % en la curva mueve las cantidades a lo sumo un 25 %.	[5]
Crosstalk	Cantidad que la red asigna a un material ausente de la curva ("fuga" entre materiales).	–
CVaR 99 % (*conditional value at risk*)	Promedio del 1 % de los valores más grandes de una lista. Aquí: se calcula el error $e_{\text{máx}}$ del MCO en cada curva del conjunto de optimización, se ordenan de mayor a menor y se promedian las peores $n/100$. Ejemplo: con 2532 curvas, es el promedio de las 25 peores. Mide la cola de peores casos sin depender de una sola curva, como haría el máximo. Viene de la gestión de riesgo financiero (pérdida media en el peor 1 % de los escenarios).	[6]
Ecuaciones normales	$A^\mathsf{T}Ac = A^\mathsf{T}y$: condición que cumple el mínimo de mínimos cuadrados; equivale a que el residuo $y - Ac$ sea perpendicular a todas las columnas de A.	[5]
Época, lote	Época: una pasada por todas las curvas de entrenamiento. Lote: grupo de curvas (64) tras el cual se corrigen los pesos.	[9]
Estandarizar	Restar la media y dividir por el desvío estándar (calculados en el entrenamiento), para que todas las entradas tengan escala comparable.	[10]
Evolución diferencial	Método de optimización *global* sin derivadas. Mantiene una población de candidatos (aquí, juegos de nudos) repartida en todo el rango. En cada generación, para cada miembro x: (1) *mutación*: arma $v = x_{mejor} + F(x_a - x_b)$ con dos miembros al azar; (2) *cruza*: mezcla coordenadas de v y x; (3) *selección*: el candidato reemplaza a x si tiene menor J. La diferencia $x_a - x_b$ da pasos grandes cuando la población está dispersa y chicos cuando converge.	[7]
Exceso	Cuánto peor ajusta la red que el MCO: $\mathrm{NRMSE}_{red}/\mathrm{NRMSE}_{MCO} - 1$.	–
$J(k)$ (función objetivo de los nudos)	Número que califica un juego de nudos k; la búsqueda elige el de menor J: $$J = \mathrm{CVaR}_{99} + 0{,}25\,\overline{\mathrm{NRMSE}} + 50\,\mathrm{máx}\left(0, \mathrm{cond}(A) - 24\right) + 1000\,\overline{\mathrm{neg}} + 100\,\max_i \mathrm{neg}_i,$$ con $\mathrm{neg}_i = \sum_j \mathrm{máx}(0, -c_{ij})$ la parte negativa de las cantidades MCO de la curva i. El primer término es la precisión; el segundo desempata; el tercero y los dos últimos valen cero si se cumplen cond(A) < 24 y el signo, y son muy grandes si no, así que actúan como restricciones.	[6, 5]

Término	Definición	Ref.
Ley de Laplace	En un tubo de pared delgada, la fuerza de la pared por unidad de largo es igual a la presión por el radio.	[18]
Ley de Masson	Ley constitutiva de la pared de la carótida: elastina neo-Hookeana, cuatro familias de fibras de colágeno y tono muscular activo, con parámetros para 41 sujetos. Ver Anexo A.	[1]
MCO	Mínimos cuadrados ordinarios: las cantidades que minimizan la suma de los cuadrados de las diferencias entre la curva y el injerto en los 999 puntos. Solución exacta: $c = A^{+}y$.	[5]
Nelder–Mead	Método de optimización *local* sin derivadas. Con N variables usa un *simplex* de $N + 1$ puntos (un triángulo en 2D). En cada paso reemplaza el peor vértice por su *reflejo* a través del centro de los demás; si mejora mucho, se *expande*; si no, se *contrae*; si nada mejora, achica todo el simplex hacia el mejor. El simplex "rueda" cuesta abajo hasta el mínimo más cercano. Aquí refina el resultado de la evolución diferencial.	[8]
NNLS	Mínimos cuadrados no negativos: MCO con la restricción de que todos los coeficientes sean ≥ 0.	[17]
Normalización de capa	Reescala las salidas de cada capa de la red a media 0 y desvío 1; estabiliza el entrenamiento.	[12]
NRMSE, E_{rms}	Raíz del error cuadrático medio, dividida por el rango de la curva (%). Mide el error típico.	–
Parada temprana	Detener el entrenamiento cuando la pérdida de validación deja de mejorar y quedarse con los mejores pesos.	[15]
Perceptrón multicapa	Red neuronal formada por capas densas: cada neurona hace una suma ponderada de la capa anterior y le aplica una función no lineal.	[9]
Recorte del gradiente	Limitar la norma del gradiente en cada paso para evitar correcciones demasiado grandes.	[14]
Regularización L_2	Término que suma a la pérdida el cuadrado de los pesos, multiplicado por un coeficiente chico (10^{-5}); evita pesos grandes.	[9]
ReLU	Función no lineal $\max(0, x)$.	[11]
SVD (valores singulares)	Toda matriz se escribe $A = U\Sigma V^{\mathsf{T}}$; los valores singulares $s_1 \geq \cdots \geq s_N$ (diagonal de Σ) son los factores por los que A estira cada dirección principal.	[5]
Sobreajuste	La red memoriza las curvas de entrenamiento y empeora en curvas nuevas.	[9]
Tasa de aprendizaje	Tamaño de cada corrección de los pesos.	[9]
Entrenamiento, validación, test	Conjuntos disjuntos de curvas: para ajustar los pesos, para controlar el entrenamiento y para la evaluación final.	[9]

Referencias

[1] Masson, I., Beaussier, H., Boutouyrie, P., Laurent, S., Humphrey, J. D., Zidi, M. (2011). Carotid artery mechanical properties and stresses quantified using in vivo data from normotensive and hypertensive humans. *Biomech. Model. Mechanobiol.* 10(6), 867–882. https://doi.org/10.1007/s10237-010-0279-6

[2] Holzapfel, G. A., Gasser, T. C., Ogden, R. W. (2000). A new constitutive framework for arterial wall mechanics and a comparative study of material models. *J. Elasticity* 61, 1–48. https://doi.org/10.1023/A:1010835316564

[3] Rachev, A., Hayashi, K. (1999). Theoretical study of the effects of vascular smooth muscle contraction on strain and stress distributions in arteries. *Ann. Biomed. Eng.* 27, 459–468. https://doi.org/10.1114/1.191

[4] Penrose, R. (1955). A generalized inverse for matrices. *Math. Proc. Cambridge Philos. Soc.* 51(3), 406–413. https://doi.org/10.1017/S0305004100030401

[5] Trefethen, L. N., Bau, D. (1997). *Numerical Linear Algebra*. SIAM (mínimos cuadrados, SVD, número de condición). https://doi.org/10.1137/1.9780898719574

[6] Rockafellar, R. T., Uryasev, S. (2000). Optimization of conditional value-at-risk. *J. Risk* 2(3), 21–41. https://doi.org/10.21314/JOR.2000.038

[7] Storn, R., Price, K. (1997). Differential evolution: a simple and efficient heuristic for global optimization over continuous spaces. *J. Global Optim.* 11, 341–359. https://doi.org/10.1023/A:1008202821328

[8] Nelder, J. A., Mead, R. (1965). A simplex method for function minimization. *Computer J.* 7(4), 308–313. https://doi.org/10.1093/comjnl/7.4.308

[9] Goodfellow, I., Bengio, Y., Courville, A. (2016). *Deep Learning*. MIT Press. https://www.deeplearningbook.org

[10] Pedregosa, F. et al. (2011). Scikit-learn: machine learning in Python. *JMLR* 12, 2825–2830 (estandarización, `StandardScaler`). https://jmlr.org/papers/v12/pedregosa11a.html

[11] Nair, V., Hinton, G. E. (2010). Rectified linear units improve restricted Boltzmann machines. *ICML 2010*. https://icml.cc/Conferences/2010/papers/432.pdf

[12] Ba, J. L., Kiros, J. R., Hinton, G. E. (2016). Layer normalization. https://arxiv.org/abs/1607.06450

[13] Kingma, D. P., Ba, J. (2015). Adam: a method for stochastic optimization. *ICLR 2015*. https://arxiv.org/abs/1412.6980

[14] Pascanu, R., Mikolov, T., Bengio, Y. (2013). On the difficulty of training recurrent neural networks. *ICML 2013*, PMLR 28 (recorte del gradiente). https://proceedings.mlr.press/v28/pascanu13.html

[15] Prechelt, L. (1998). Early stopping — but when? En *Neural Networks: Tricks of the Trade*, LNCS 1524, 55–69. https://doi.org/10.1007/3-540-49430-8_3

[16] Abadi, M. et al. (2016). TensorFlow: large-scale machine learning on heterogeneous distributed systems. https://arxiv.org/abs/1603.04467. Keras: https://keras.io

[17] Lawson, C. L., Hanson, R. J. (1995). *Solving Least Squares Problems*. SIAM (mínimos cuadrados no negativos). https://doi.org/10.1137/1.9781611971217

[18] Fung, Y. C. (1993). *Biomechanics: Mechanical Properties of Living Tissues*, 2.ª ed. Springer (ley de Laplace; ley exponencial de Fung). https://doi.org/10.1007/978-1-4757-2257-4