Reconstrucción de curvas presión–estiramiento en forma de J mediante una red neuronal generalizada con restricciones físicas: análisis matemático, estructural y físico de la identificabilidad de los coeficientes

Pablo Silvoni*
Proyecto *Biomimesis*

Octubre de 2026

Resumen

Se estudia la reconstrucción de curvas de presión intraluminal $P(\lambda)$ en forma de J, típicas de la pared arterial, como combinaciones lineales no negativas y acotadas, $P(\lambda) \approx \sum_{j=1}^{N} c_j A_j(\lambda)$ con $c_j \in [0, 6]$, de una familia de $N = 4$ funciones base lineales por tramos. Los datos proceden de un modelo de pared gruesa incompresible con ley constitutiva exponencial de tipo Fung, calibrado para una población normotensa joven (Tabla 3) y otra hipertensa tratada (Tabla 6). La región admisible se describe mediante la envolvente inferior/superior de ambas curvas. Se presentan cuatro resultados. *(i)* Una cota estructural exacta: si las columnas del operador de diseño son no negativas y $c \geq 0$, entonces $A\boldsymbol{c} \geq 0$ y, por tanto, toda curva-objetivo con tramo negativo impone un suelo irreducible al error cuadrático; para la envolvente inferior original, que es negativa en el 31,7 % de la malla, $R^2 \leq 0{,}8675$. *(ii)* La corrección consiste en recortar las curvas a presión ≥ 0 antes de formar la envolvente, con lo que $R^2 \geq 0{,}9962$ con las mismas bases y número de condición 13,90. *(iii)* Una demostración de que el mapa de datos, que recorta la curva $A\boldsymbol{c}$ a la envolvente, no es inyectivo en c_1 (saturación para $c_1 \geq 4{,}0756$) ni en c_4 (para $c_4 \leq 1{,}2084$), de modo que el predictor óptimo en sentido de mínimos cuadrados es una media condicional y no el coeficiente verdadero; esto explica cuantitativamente la meseta observada en $c_1 \approx 4{,}95$ (predicción teórica 5,04). *(iv)* Un diagnóstico de cobertura distribucional: el generador original de envolventes casi nunca produce saltos de proporción $\alpha(\lambda)$ cercanos a 1 (0,115 % de las muestras con salto $> 0{,}5$), mientras que las curvas físicas y_1, y_2 equivalen a saltos de exactamente 1; ello explica el error de generalización de 8,27 % (NRMSE) en y_1 frente a 1,01 % del óptimo de mínimos cuadrados. Se propone una familia de entrenamiento con transiciones abruptas y un protocolo de validación fuera de distribución. Los resultados experimentales de la versión corregida (V12) se declaran explícitamente como pendientes de medición.

Palabras clave: pared arterial; curva J; ley de Fung; mínimos cuadrados con cotas; condiciones KKT; identificabilidad; redes neuronales informadas por la física; media condicional; cobertura distribucional.

Índice

1 Introducción **3**

*Correspondencia: pablosilvoni@yahoo.com. Afiliación institucional: *[completar]*.

2 Modelo físico **3**
2.1 Cinemática de la pared gruesa incompresible . . . 3
2.2 Equilibrio y presión . . . 3
2.3 Ley constitutiva de tipo Fung . . . 4
2.4 Envolvente y dominio . . . 4

3 Representación por funciones base **4**
3.1 Definición . . . 4
3.2 Matriz de diseño y acondicionamiento . . . 5

4 El problema de mínimos cuadrados con cotas **5**
4.1 Planteamiento . . . 5
4.2 Relajación y coeficiente de determinación . . . 6

5 Limitación estructural: cota universal de R^2 **6**
5.1 Resultado . . . 6
5.2 Localización del error . . . 7
5.3 Alternativas evaluadas . . . 7
5.4 Justificación física del recorte . . . 7

6 Generación de datos y no inyectividad del mapa **8**
6.1 Esquema de generación de la versión original . . . 8
6.2 No inyectividad . . . 8
6.3 Consecuencia estadística: el sesgo a la media condicional . . . 8
6.4 Solución adoptada (V11–V12) . . . 9

7 Red neuronal informada por la física **9**
7.1 Preprocesamiento . . . 9
7.2 Arquitectura . . . 9
7.3 Función de pérdida compuesta . . . 10

8 Cobertura distribucional **10**
8.1 Parametrización por proporción $\alpha(\lambda)$ . . . 10
8.2 Diagnóstico . . . 10
8.3 Familia de transiciones (V12) . . . 11

9 Resultados **11**
9.1 Versión V11 (con recorte de rango limitado) . . . 11
9.2 Verificación de las bases (Celda 1, V11) . . . 12
9.3 Versión V12: protocolo de validación (resultados pendientes) . . . 12

10 Discusión **12**

11 Conclusiones **13**

1 Introducción

La relación entre la presión intraluminal y la deformación circunferencial de una arteria es no lineal y presenta la conocida forma de "J": una zona inicial blanda dominada por la elastina, seguida de un endurecimiento brusco al reclutarse las fibras de colágeno [1–3]. Cambios en esta curva distinguen tejidos sanos de hipertensos y sirven de biomarcador mecánico.

Una estrategia de reconstrucción consiste en aproximar cualquier curva $P(\lambda)$ dentro de la región delimitada por dos curvas de referencia mediante una combinación lineal de N funciones base conocidas, con coeficientes no negativos y acotados (para conservar la interpretación mecánica de cada término como una contribución rígida ≥ 0 de magnitud acotada). La inversión se realiza con una red neuronal "generalizada" (RN generalizada) que, dada la curva muestreada en una malla, devuelve el vector de coeficientes $\boldsymbol{c} \in [0, 6]^N$.

Este trabajo documenta el análisis matemático, estructural y físico necesario para que dicho esquema sea *bien planteado* y *entrenable*. El hilo conductor es la pregunta: *¿qué parte del error observado es atribuible a la red, y qué parte es una limitación del problema?* Mostramos que una fracción dominante pertenece a la segunda categoría y es corregible a nivel de formulación, no de arquitectura.

Contribuciones.

1. Se formaliza el problema como mínimos cuadrados con cotas (Sec. 4) y se dan condiciones KKT necesarias y suficientes, unicidad y acondicionamiento exacto.
2. Se demuestra una cota superior de R^2 válida para *cualquier* método (Proposición 2), y se identifica su origen físico (presiones negativas fuera de rango fisiológico).
3. Se demuestra la no inyectividad del mapa de datos y se deduce el valor teórico del sesgo de la red (Proposición 3).
4. Se cuantifica la brecha de cobertura entre el generador de datos y las curvas físicas y se propone una corrección con protocolo de validación.

2 Modelo físico

2.1 Cinemática de la pared gruesa incompresible

Sea una arteria cilíndrica de radio interno R_i y espesor H en configuración de referencia, con $h_0 = H/R_i$. En la configuración deformada, con radio interno r_i y espesor h, se define el estiramiento circunferencial interno $\lambda = r_i/R_i$. Con deformación axial nula, la incompresibilidad impone la conservación del área de la sección,

$$(r_i + h)^2 - r_i^2 = (R_i + H)^2 - R_i^2. \tag{1}$$

Dividiendo por $r_i^2 = \lambda^2 R_i^2$,

$$\left(1 + \frac{h}{r_i}\right)^2 = 1 + \frac{(1+h_0)^2 - 1}{\lambda^2} \quad \Longrightarrow \quad \frac{h}{r_i}(\lambda) = \sqrt{1 + \frac{(1+h_0)^2 - 1}{\lambda^2}} - 1. \tag{2}$$

La ecuación (2) es decreciente en λ: al inflar, la pared se adelgaza relativamente.

2.2 Equilibrio y presión

El equilibrio radial integrado en el espesor da, para la presión transmural,

$$P_i - P_e = \int_{r_i}^{r_i+h} \frac{\sigma_{\theta\theta} - \sigma_{rr}}{r}\, dr. \tag{3}$$

Aproximando la tensión circunferencial por su promedio de pared $\bar{\sigma}_{\theta\theta}$ y despreciando σ_{rr} frente a $\sigma_{\theta\theta}$ (hipótesis de pared de espesor moderado), resulta la ley de Laplace generalizada

$$P(\lambda) = \bar{\sigma}_{\theta\theta}(\lambda)\, \ln\!\Big(1 + \frac{h}{r_i}(\lambda)\Big) + P_a, \tag{4}$$

donde P_a es una presión de referencia (offset) de calibración.

2.3 Ley constitutiva de tipo Fung

La tensión promedio sigue la forma exponencial

$$\bar{\sigma}_{\theta\theta}(\lambda) = a\big(e^{\,b(\lambda-1)} - 1\big), \qquad a > 0,\ b > 0, \tag{5}$$

que produce el endurecimiento exponencial característico de la J [1]. Los parámetros de las dos poblaciones se recogen en la Tabla 1.

Tabla 1: Parámetros del modelo (2)–(5) para las dos curvas de referencia.

Curva	a [kPa]	b	h_0	P_a [kPa]
y_1 (Tabla 3, normotensos jóvenes)	39,87012495	7,91934038	0,1703	5,63
y_2 (Tabla 6, hipertensos tratados)	73,37535695	10,40342667	0,2197	5,98

2.4 Envolvente y dominio

Se trabaja en $\lambda \in [0{,}84,\ 1{,}20]$ discretizado en $M = 999$ puntos equiespaciados $\lambda_1 < \cdots < \lambda_M$. Las envolventes son

$$y_{\min}(\lambda) = \min\{y_1(\lambda), y_2(\lambda)\}, \qquad y_{\max}(\lambda) = \max\{y_1(\lambda), y_2(\lambda)\}. \tag{6}$$

Las dos curvas se cruzan en $\lambda_\times \approx 0{,}9962$ (Figura 1); a la izquierda domina y_1 como cota superior y a la derecha y_2. A $\lambda = 1{,}2$, $y_1 = 23{,}27\,\text{kPa}$ y $y_2 = 80{,}99\,\text{kPa}$.

Presiones negativas. Como $\bar{\sigma}_{\theta\theta} < 0$ para $\lambda < 1$ y $P_a \approx 6\,\text{kPa}$ es pequeño, (4) produce presiones negativas cuando λ es suficientemente menor que 1: $y_2(0{,}84) = -9{,}65\,\text{kPa}$. La envolvente inferior es negativa en el 31,7 % de la malla y cruza el cero en $\lambda \approx 0{,}9543$. Una presión transmural negativa corresponde a un vaso colapsado, fuera del protocolo de inflado fisiológico; como se verá, esta región no solo carece de sentido fisiológico sino que es matemáticamente inalcanzable para el modelo de bases.

3 Representación por funciones base

3.1 Definición

Se utilizan $N = 4$ rampas lineales por tramos con nodos $(k_1, k_2, k_3) = (0{,}95;\ 1{,}05;\ 1{,}1679)$ y pendientes $(m_1, \ldots, m_4) = (0{,}552;\ 1{,}2183;\ 2{,}0;\ 6{,}0)$:

$$A_1(\lambda) = s\, m_1(\lambda - 0{,}84), \tag{7}$$

$$A_j(\lambda) = s\, m_j\ (\lambda - k_{j-1})_+, \quad j = 2, 3, 4, \tag{8}$$

con $(u)_+ = \max(0, u)$ y factor global $s = 100$. Cada A_j es no negativa, no decreciente y continua; sus valores en $\lambda = 1{,}2$ son $A(1{,}2) = (19{,}872;\ 30{,}4575;\ 30{,}0;\ 19{,}26)$. La estructura recuerda a la J: el término j "se enciende" en k_{j-1} y aporta rigidez creciente.

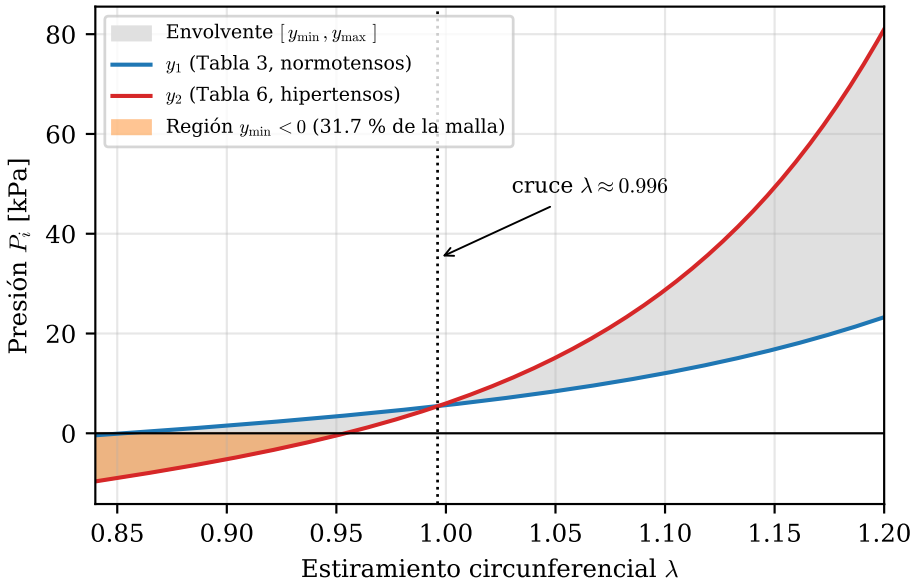


Figura 1: Curvas y_1, y_2 y su envolvente. La región sombreada en naranja es donde $y_{\min} < 0$ (31,7 % de la malla).

3.2 Matriz de diseño y acondicionamiento

Sea $A \in \mathbb{R}^{M \times N}$ con $A_{ij} = A_j(\lambda_i)$. Los valores singulares son

$$\sigma(A) = (671{,}38;\ 154{,}37;\ 76{,}22;\ 48{,}30), \qquad \operatorname{cond}_2(A) = \frac{\sigma_{\max}}{\sigma_{\min}} = 13{,}90. \tag{9}$$

Observación 1. El número de condición es invariante frente al escalado global s, pues $\operatorname{cond}(sA) = \operatorname{cond}(A)$; por tanto s solo fija las unidades y el rango numérico de los coeficientes ($c_j \in [0, 6]$ cubre pendientes efectivas $s\, m_j c_j$).

Como $\sigma_{\min} > 0$, A tiene rango columna completo, hecho que se usa en la Sec. 4 para garantizar unicidad.

4 El problema de mínimos cuadrados con cotas

4.1 Planteamiento

Para una curva-objetivo $\boldsymbol{b} \in \mathbb{R}^M$ (los valores de P en la malla), el coeficiente *verdadero* (etiqueta) se define como

$$\boldsymbol{c}^\star(\boldsymbol{b}) = \underset{\boldsymbol{c} \in [0, C]^N}{\arg\min}\ \tfrac{1}{2}\, \|A\boldsymbol{c} - \boldsymbol{b}\|_2^2, \qquad C = 6. \tag{10}$$

Proposición 1 (Existencia, unicidad y KKT)**.** *El problema* (10) *tiene solución única. Un punto factible* $\boldsymbol{c}$ *es solución si y solo si, con* $\boldsymbol{g} = A^\top(A\boldsymbol{c} - \boldsymbol{b})$*,*

$$g_j \geq 0 \ \textit{si}\ c_j = 0, \qquad g_j \leq 0 \ \textit{si}\ c_j = C, \qquad g_j = 0 \ \textit{si}\ 0 < c_j < C. \tag{11}$$

Proof. El conjunto factible es un cubo compacto y la función es continua, luego existe mínimo. Como $\sigma_{\min}(A) > 0$, el hessiano $A^\top A \succ 0$ y la función es estrictamente convexa, de donde la unicidad. La función es convexa y diferenciable y el conjunto es un politopo, de modo que las condiciones KKT son necesarias y suficientes [4]: el multiplicador asociado a $c_j \geq 0$ es $\mu_j = g_j \geq 0$ cuando la cota está activa, y el de $c_j \leq C$ es $-g_j \geq 0$; la complementariedad conduce a las tres condiciones enunciadas. □

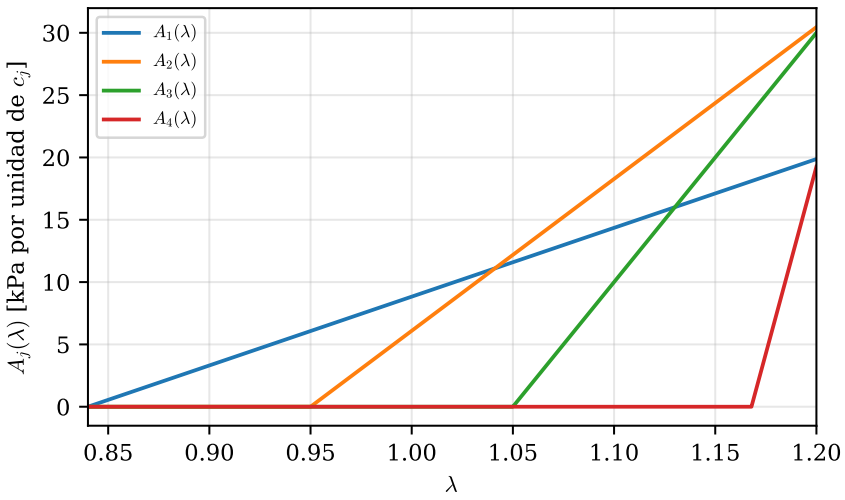


Figura 2: Funciones base $A_j(\lambda)$.

El problema de mínimos cuadrados con variables acotadas se resuelve de forma robusta con métodos de región de confianza reflexiva [5, 6]; en la implementación se emplea `lsq_linear`, y la verificación de optimalidad se hace independientemente evaluando las condiciones anteriores (con el método `trust-constr` para contraste).

4.2 Relajación y coeficiente de determinación

Se definen $\mathrm{SSE}(\boldsymbol{c}) = \|A\boldsymbol{c} - \boldsymbol{b}\|^2$, $\mathrm{SST} = \left\|\boldsymbol{b} - \bar{b}\mathbf{1}\right\|^2$ y $R^2 = 1 - \mathrm{SSE}\,/\,\mathrm{SST}$. Sea $\boldsymbol{c}^{\mathrm{rel}}$ la solución sin cotas (mínimos cuadrados ordinarios, vía SVD). Como la cota restringe el conjunto de búsqueda,

$$R^2_{\mathrm{real}} \;\le\; R^2_{\mathrm{rel}}. \tag{12}$$

La diferencia mide el costo de exigir coeficientes en $[0, 6]^N$ (interpretabilidad mecánica).

5 Limitación estructural: cota universal de R^2

5.1 Resultado

Sea $\boldsymbol{b}_w = (1-w)\,\boldsymbol{y}_{\min} + w\,\boldsymbol{y}_{\max}$, $w \in [0, 1]$, la familia que interpola entre la envolvente inferior y la superior.

Proposición 2 (Cota estructural)**.** *Si todas las columnas de A son no negativas, entonces para todo $\boldsymbol{c} \ge 0$ se cumple $A\boldsymbol{c} \ge 0$ componente a componente y*

$$\mathrm{SSE}(\boldsymbol{c}) \;\ge\; S_-(\boldsymbol{b}) := \sum_{i=1}^{M} (b_i)_-^2\,, \qquad R^2 \;\le\; 1 - \frac{S_-(\boldsymbol{b})}{\mathrm{SST}(\boldsymbol{b})}, \tag{13}$$

con $(u)_- = \max(0, -u)$. La cota vale para cualquier algoritmo (red neuronal, evolutivo o exacto), pues solo usa la geometría del conjunto $\{A\boldsymbol{c} : \boldsymbol{c} \ge 0\}$.

Proof. Sea $v_i = (A\boldsymbol{c})_i \ge 0$. Si $b_i \ge 0$, el residuo cumple $(b_i - v_i)^2 \ge 0 = (b_i)_-^2$. Si $b_i < 0$, entonces $b_i - v_i \le b_i < 0$, de donde $(b_i - v_i)^2 \ge b_i^2 = (b_i)_-^2$. Sumando sobre i se obtiene el primer enunciado; el segundo sigue de la definición de R^2. □

Corolario 2.1. *Para $w = 0$ (envolvente inferior original) se obtiene $S_- = 11\,142{,}5$ kPa^2 y $\mathrm{SST} = 84\,122{,}5$ kPa^2, por lo que*

$$R^2 \le 1 - \frac{11\,142{,}5}{84\,122{,}5} = 0{,}8675. \tag{14}$$

El valor máximo alcanzado numéricamente (con cotas) es $R^2 = 0{,}8648$ y el relajado (sin cotas) 0,8839; este último puede superar a la cota porque admite $\boldsymbol{c}$ con signos negativos, fuera de las hipótesis de la Proposición 2.

5.2 Localización del error

Del residuo del ajuste sin restricción de signo en $w = 0$, el 82,1 % del SSE se concentra en $\lambda \in [0{,}84; 0{,}90)$, el 12,7 % en $[0{,}90; 0{,}9962)$ y solo el 5,2 % en $\lambda > \lambda_\times$. Si se ajusta únicamente en $\lambda \geq 0{,}90$, el R^2 relajado sube a 0,9722. Es decir, *el mal ajuste no es un defecto de la forma de las bases en el rango fisiológico, sino de pretender reproducir presiones negativas con funciones no negativas.*

5.3 Alternativas evaluadas

1. **Recortar el dominio a $\lambda \geq 0{,}90$.** Con las bases actuales el número de condición en el subdominio sube a 26,1 (> 25, umbral de diseño) y $R^2_{\min} = 0{,}965$.

2. **Mantener el dominio completo y recortar la envolvente a presión ≥ 0** (opción adoptada). Se definen

$$\tilde{y}_k = (y_k)_+ , \quad \tilde{y}_{\min} = \min\{\tilde{y}_1, \tilde{y}_2\}, \quad \tilde{y}_{\max} = \max\{\tilde{y}_1, \tilde{y}_2\}. \tag{15}$$

   Entonces $\left(\tilde{b}_i\right)_- = 0$ y la cota (13) se vuelve trivial (≤ 1).

Una búsqueda evolutiva sobre los nodos y pendientes de las bases no produjo ganancia relevante de R^2, lo que confirma que el cuello de botella no estaba en las bases (Tabla 2).

Tabla 2: R^2 del ajuste de mínimos cuadrados con cotas, frente al peso w de $\boldsymbol{b}_w$. V11: envolvente original; V12: envolvente recortada a ≥ 0. La columna "cota" es $1 - S_- / \mathrm{SST}$ (Prop. 2).

	V11 (sin recorte)			V12 (recorte)
w	R^2_{rel}	R^2_{real}	cota	R^2_{real}
0,0	0,8839	0,8648	0,8675	0,9962
0,1	0,9250	0,9151	0,9173	0,9975
0,2	0,9518	0,9471	0,9492	0,9979
0,3	0,9692	0,9674	0,9696	0,9980
0,4	0,9805	0,9800	0,9824	0,9980
0,5	0,9877	0,9876	0,9904	0,9978
0,6	0,9921	0,9921	0,9952	0,9977
0,7	0,9948	0,9948	0,9979	0,9975
0,8	0,9963	0,9963	0,9993	0,9973
0,9	0,9969	0,9969	0,9999	0,9972
1,0	0,9970	0,9970	1,0000	0,9970

5.4 Justificación física del recorte

Fijar $\tilde{y} = (y)_+$ no distorsiona la zona fisiológica: $y_{\min} \geq 0$ para $\lambda \geq 0{,}9543$ y toda la envolvente superior es positiva en $\lambda \geq \lambda_\times$. Solo se modifica un tramo en el que el modelo (4) predice colapso. En el 31,7 % de la malla la curva recortada se mantiene en cero, interpretable como ausencia de rigidez medible bajo presión transmural nula.

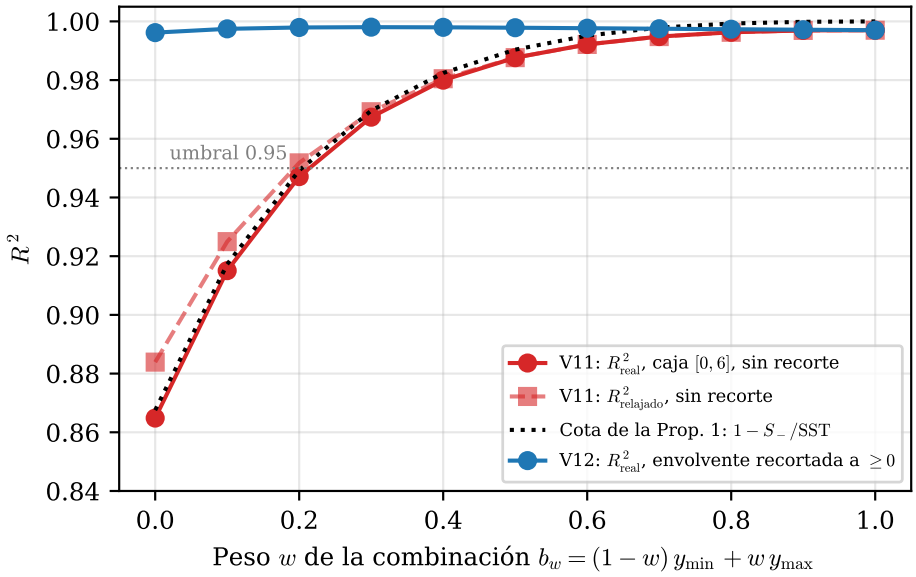


Figura 3: R^2 frente a w. El recorte a ≥ 0 eleva el mínimo de 0,8648 a 0,9962 con las mismas bases. Las curvas de V11 permanecen por debajo de la cota de la Proposición 2.

6 Generación de datos y no inyectividad del mapa

6.1 Esquema de generación de la versión original

En el esquema original (V10) se construía una curva de entrada como

$$\boldsymbol{x}(\boldsymbol{c}) = \operatorname{clip}\big(A\boldsymbol{c},\ \boldsymbol{y}_{\min},\ \boldsymbol{y}_{\max}\big), \qquad \operatorname{clip}(u, \ell, h) = \min\{\max\{u, \ell\}, h\}, \tag{16}$$

con la intención de que la curva presentada a la red estuviera siempre dentro de la envolvente, y se utilizaba $\boldsymbol{c}$ como etiqueta. Esto es matemáticamente inconsistente porque *la etiqueta no es función de la entrada*: distintos $\boldsymbol{c}$ producen exactamente la misma $\boldsymbol{x}$.

6.2 No inyectividad

Proposición 3 (Saturación). *Sean $A_j \geq 0$ y $\Phi_j(c) = \operatorname{clip}(cA_j, \boldsymbol{y}_{\min}, \boldsymbol{y}_{\max})$ la curva de entrada generada por la base j sola.*

(a) Si $c \geq c_j^+ := \max_{i:\,A_{ij}>0}\ y_{\max,i}/A_{ij}$, entonces $\Phi_j(c) = \Phi_j(c_j^+)$.

(b) Si $c \leq c_j^- := \min_{i:\,A_{ij}>0}\ y_{\min,i}/A_{ij}$, entonces $\Phi_j(c) = \Phi_j(c_j^-)$.

Proof. (a) Para $c \geq c_j^+$ y $A_{ij} > 0$ se tiene $cA_{ij} \geq y_{\max,i}$, luego $\operatorname{clip}(cA_{ij}, y_{\min,i}, y_{\max,i}) = y_{\max,i}$, independiente de c. Si $A_{ij} = 0$ la salida es $\operatorname{clip}(0, y_{\min,i}, y_{\max,i})$, también independiente de c. (b) es análogo con $cA_{ij} \leq y_{\min,i}$. □

Numéricamente: $c_1^+ = 4{,}0756$ (base 1) y $c_4^- = 1{,}2084$ (base 4). Con $c_1 \in [4{,}0756;\ 6]$ la salida es idéntica (diferencia verificada 0,000 kPa), igual que para $c_4 \in [0;\ 1{,}2084]$ (Figura 4). Aproximadamente 32 % del rango de c_1 y 20 % del de c_4 son indistinguibles para cualquier regresor.

6.3 Consecuencia estadística: el sesgo a la media condicional

Para pérdida cuadrática, el predictor óptimo es la esperanza condicional $\hat{c}(\boldsymbol{x}) = \mathbb{E}[c \mid \boldsymbol{x}]$ [7]. En el conjunto saturado, $\boldsymbol{x}$ es constante y $\hat{c}_1 = \mathbb{E}[c_1 \mid c_1 \geq c_1^+]$. Si c_1 se muestrea uniformemente en

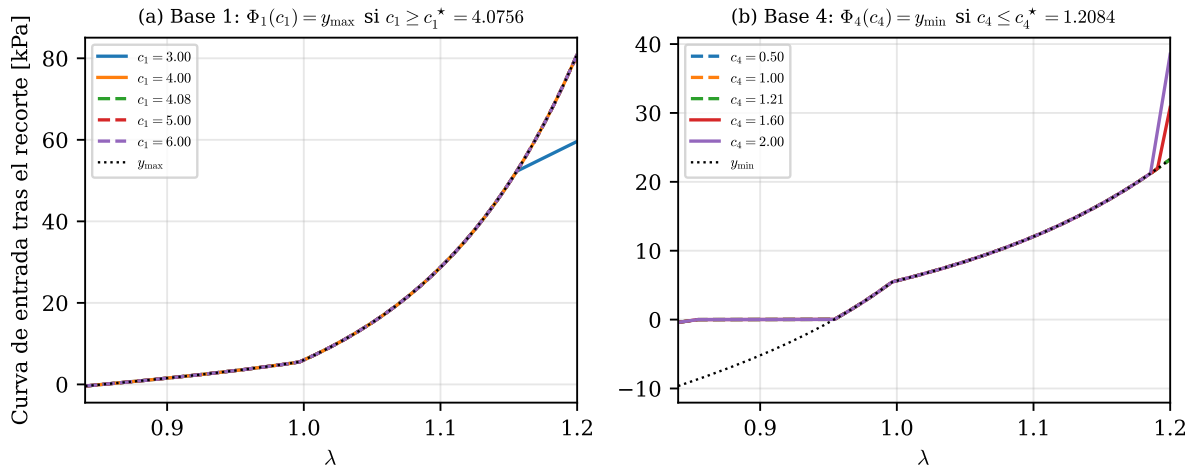


Figura 4: No inyectividad del mapa de datos. (a) Para $c_1 \geq c_1^+ = 4{,}0756$ las curvas coinciden con $y_{\max}$. (b) Para $c_4 \leq c_4^- = 1{,}2084$ coinciden con $y_{\min}$.

$[0, 6]$ en esa región, resulta

$$\hat{c}_1 = \frac{c_1^+ + 6}{2} = \frac{4{,}0756 + 6}{2} = 5{,}04, \tag{17}$$

en buen acuerdo con la meseta observada $\approx 4{,}95$ en la Celda 12 de V10 (la diferencia de 0,09 es compatible con la mezcla de familias y el sesgo de regularización). Análogamente, $\hat{c}_4 \leq c_4^-$ y la salida de la red para c_4 forma un escalón cerca de 1,2. Por tanto la meseta *no es un fallo de entrenamiento*: es el óptimo del problema mal planteado.

6.4 Solución adoptada (V11–V12)

Se eliminó el recorte entre la entrada y la etiqueta. La etiqueta se obtiene como $\boldsymbol{c}^\star(\boldsymbol{b})$ de (10), función determinista de la curva de entrada $\boldsymbol{b}$ (única por la Proposición 1), con lo que el mapa $\boldsymbol{b} \mapsto \boldsymbol{c}^\star$ es una función bien definida y el objetivo de aprendizaje es identificable. En V12 las curvas se recortan a ≥ 0 *antes* de calcular la etiqueta (Sec. 5).

7 Red neuronal informada por la física

7.1 Preprocesamiento

La entrada $\boldsymbol{x} \in \mathbb{R}^{999}$ se transforma con $\tilde{x}_i = \ln(x_i + \delta)$, $\delta = \left|\min_i y_{\min,i}\right| + 5$ (en V12, $\delta = 5$ pues $\tilde{y}_{\min} \geq 0$), de modo que el argumento del logaritmo sea estrictamente positivo, y luego se estandariza (`StandardScaler`). Las salidas se estandarizan igualmente. Los escaladores se ajustan *solo* con el conjunto de entrenamiento para evitar fugas de información; la partición estratificada por familia es 70/10/20 % (entrenamiento/validación/prueba).

7.2 Arquitectura

Perceptrón multicapa $999 \to 256 \to 128 \to 64 \to 4$ con activación ReLU, normalización de capa [8] y regularización L_2 (10^{-5}); 298 308 parámetros. Optimizador Adam [9] con tasa 10^{-3} y recorte de gradiente (norma 1). La salida se acota a $[0, 6]$ en la evaluación.

7.3 Función de pérdida compuesta

Se sigue la idea de incorporar restricciones físicas en la función objetivo de la red [10]. Sea $\hat{\boldsymbol{c}} = f_\theta(\boldsymbol{x})$. La pérdida es

$$\mathcal{L} = \lambda_1 \underbrace{\frac{1}{N}\,\|\hat{\boldsymbol{c}} - \boldsymbol{c}^\star\|^2}_{\mathcal{L}_{\text{coef}}} + \lambda_2 \underbrace{\frac{\|A\hat{\boldsymbol{c}} - A\boldsymbol{c}^\star\|}{\|A\boldsymbol{c}^\star\| + \epsilon}}_{\mathcal{L}_{\text{rec}}} + \lambda_3 \underbrace{\frac{1}{|\mathcal{Z}|}\sum_{j\in\mathcal{Z}} \hat{c}_j^2}_{\mathcal{L}_{\text{cruce}}}, \quad (\lambda_1, \lambda_2, \lambda_3) = (1, 5, 20), \tag{18}$$

donde $\mathcal{Z} = \{j : c_j^\star < 10^{-4}\}$ es el conjunto de coeficientes "apagados" (máscara) y $\mathcal{L}_{\text{cruce}}$ penaliza la contaminación cruzada (*crosstalk*): activar bases que el etiquetado exacto deja en cero. El término $\mathcal{L}_{\text{rec}}$ es el componente "informado por la física": exige que la curva reconstruida con la matriz A sea correcta, no solo los coeficientes. Dado que $\text{cond}(A) = 13{,}9$, un error relativo ε en $\boldsymbol{c}$ puede amplificarse hasta $\sim 14\,\varepsilon$ en la reconstrucción y recíprocamente, por lo que ambos términos son complementarios.

8 Cobertura distribucional

8.1 Parametrización por proporción $\alpha(\lambda)$

Las curvas de entrenamiento de la familia "envolvente" se generan como

$$\boldsymbol{b} = (1 - \boldsymbol{\alpha}) \odot \boldsymbol{y}_{\min} + \boldsymbol{\alpha} \odot \boldsymbol{y}_{\max}, \qquad \alpha_i \in [-0{,}05;\ 1{,}05], \tag{19}$$

con $\boldsymbol{\alpha}$ de variación suave (cosenos de baja frecuencia). Las curvas físicas son casos extremos: $y_1 = y_{\min}$ si $\lambda > \lambda_\times$ y $y_{\max}$ si $\lambda < \lambda_\times$ (y al revés para y_2), es decir, $\alpha(\lambda)$ es un *escalón* entre 0 y 1 (Figura 5).

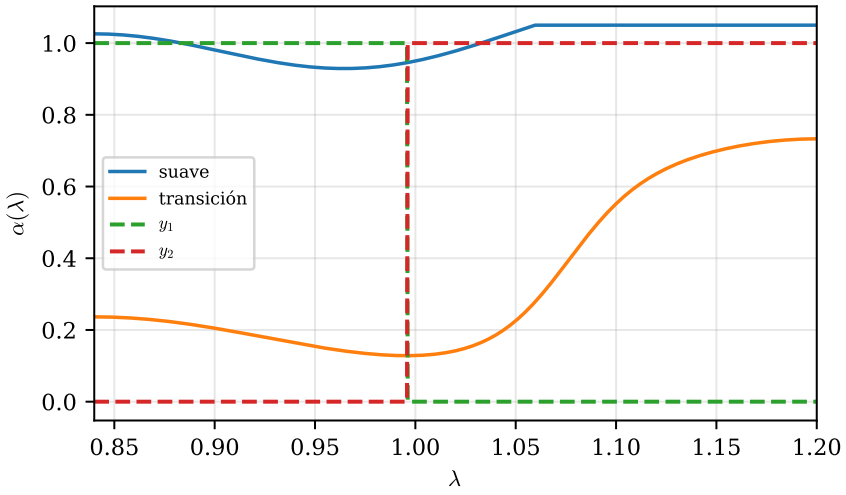


Figura 5: Perfiles $\alpha(\lambda)$ típicos del generador (suave y con transición) frente a los escalones que definen y_1 e y_2.

8.2 Diagnóstico

Se define el salto $\Delta\alpha = \left|\overline{\alpha}_{\lambda<0{,}95} - \overline{\alpha}_{\lambda>1{,}05}\right|$. Para y_1, y_2, $\Delta\alpha = 1$. En el generador de V11 (envolvente suave) el percentil 99 de $\Delta\alpha$ es 0,39, el máximo 0,63 y solo el 0,115 % de las muestras supera 0,5; ninguna supera 0,8. Por tanto y_1, y_2 están *fuera de la distribución de entrenamiento* y el error de generalización era esperable aunque la red sea óptima dentro de su soporte. La Tabla 4 confirma el patrón: error de 8,27 % en y_1.

8.3 Familia de transiciones (V12)

Se añadió una cuarta familia, `env_transicion`, con

$$\alpha(\lambda) = \alpha_L + (\alpha_R - \alpha_L)\,\varsigma\!\left(\frac{\lambda - \lambda_0}{w}\right) + \text{perturbación suave}, \quad \varsigma(u) = \frac{1}{1+e^{-u}}, \tag{20}$$

con $\lambda_0 \sim U(0{,}88;\, 1{,}15)$, ancho $w = 10^{U(-2{,}7;\,-1{,}1)}$ y, en el 50 % de los casos, saltos extremos $0 \leftrightarrow 1$ ($\alpha_{L,R}$ cerca de 0 y 1). Una simulación del muestreador (Figura 6) da 48 % de muestras con $\Delta\alpha > 0{,}5$ y 19,7 % con $\Delta\alpha > 0{,}8$, frente a 0,115 % y 0 % de la versión anterior.

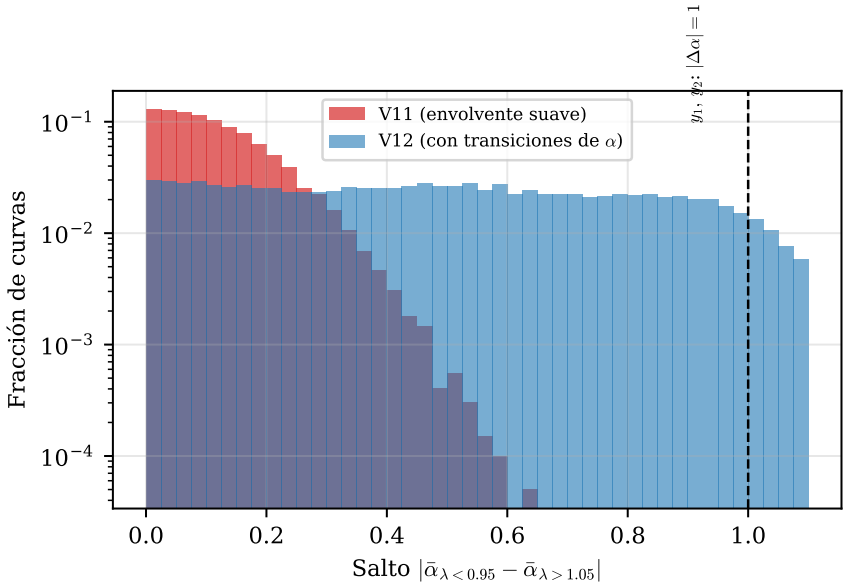


Figura 6: Distribución del salto $|\Delta\alpha|$ (escala logarítmica) en V11 y V12 (réplica del muestreador, 2×10^4 curvas cada una). La línea discontinua marca el valor de y_1, y_2.

9 Resultados

9.1 Versión V11 (con recorte de rango limitado)

La Tabla 3 resume la recuperación de coeficientes sobre el conjunto de prueba, y la Tabla 4 el desempeño sobre las curvas físicas.

Tabla 3: V11, conjunto de prueba: recuperación de coeficientes.

	c_1	c_2	c_3	c_4
R^2	0,99993	0,99992	0,99990	0,99985
MAE	0,00538	0,00628	0,00682	0,00897

R^2 curva reconstruida frente a etiqueta	0,999846
R^2 frente a la entrada	0,986629
MAE / RMSE [kPa]	0,0949 / 0,2193
NRMSE	0,1097 %

Por familias, el R^2 de la reconstrucción es 0,99993 (pura), 0,99979 (combinada) y 0,96678 (envolvente), lo que ubica el error remanente en la familia más difícil, coherentemente con la

Sec. 8. El entrenamiento requirió 21,08 min (500 épocas); la mejor época fue la última (500) con val_loss = 0,001852 y MAE de validación 0,006769: el entrenamiento *no había convergido*.

Tabla 4: V11, curvas físicas. KKT: óptimo de mínimos cuadrados con cotas. PINN: salida de la red.

Curva	Método	(c_1, c_2, c_3, c_4)	R^2	NRMSE
y_1	KKT	(0,5225; 0,1637; 0,1916; 0,1217)	0,998657	1,0090 %
y_1	PINN	(0,5494; 0,0990; 0,0857; 0,0649)	0,909797	8,2687 %
y_2	KKT	(0; 1,0328; 1,1895; 0,7718)	0,978606	3,9033 %
y_2	PINN	(0; 0,8561; 1,2030; 0,5576)	0,964414	5,0341 %

9.2 Verificación de las bases (Celda 1, V11)

$\mathrm{cond}(A) = 13{,}90$; R^2_{real} por peso w entre 0,8648 y 0,9970, con media 0,9672; el mínimo cae bajo el umbral 0,95, coherente con la Proposición 2 y resuelto por el recorte (Tabla 2).

9.3 Versión V12: protocolo de validación (resultados pendientes)

Los resultados de entrenamiento completo de V12 aún no han sido medidos y no se afirma aquí ningún valor. Se verificó únicamente que el cuaderno ejecuta de extremo a extremo con un entrenamiento reducido (conjunto reducido, 3 épocas), y que el ajuste de mínimos cuadrados cumple la Tabla 2. El protocolo a ejecutar es:

1. **Convergencia.** 1000 épocas con `EarlyStopping` (paciencia 35); criterio: mejor época estrictamente anterior a la última.

2. **Curvas físicas.** NRMSE de y_1 y y_2 frente al óptimo KKT; criterio de éxito: brecha $\lesssim 1$ punto porcentual (para y_1 V11 fue 7,26 puntos).

3. **Fuera de distribución (Celda 12b).** Perfiles α de doble transición y senoidales; métrica: brecha $\mathrm{NRMSE}_{\mathrm{PINN}} - \mathrm{NRMSE}_{\mathrm{KKT}}$.

4. **Por familia.** MAE y R^2 en las cuatro familias (`pura`, `combinada`, `env_suave`, `env_transicion`).

10 Discusión

Qué era limitación del problema y qué del modelo. El suelo $R^2 \leq 0{,}8675$ (Prop. 2) y la saturación de c_1, c_4 (Prop. 3) son propiedades del planteamiento: ninguna red, por grande que fuera, las evitaría. La brecha en y_1 es, en cambio, un problema de datos (cobertura) corregible por muestreo. Esta distinción evita gastar esfuerzo en cambiar la arquitectura.

Límites del recorte a ≥ 0. Un coeficiente solo puede interpretarse como contribución mecánica en el rango donde la presión es ≥ 0. Los valores de $\lambda < 0{,}954$ pierden información (todas las curvas coinciden con cero en la zona cercana a 0,84), y la identificabilidad de c_1 en esa zona depende solo de la zona $\lambda \geq 0{,}954$.

Hipótesis a revisar. (i) La aproximación $\sigma_{rr} \approx 0$ y el promedio de pared en (4). (ii) La hipótesis uniforme en $c_1 \in [0, 6]$ usada para el valor teórico 5,04. (iii) La interpretación del offset P_a.

Mejoras posibles. Una pérdida de reconstrucción ponderada por el escalón (mayor peso en λ alto), un programa de tasa de aprendizaje con decaimiento para asegurar convergencia, y un modelo de salida con proyección explícita al cubo $[0, 6]^4$.

11 Conclusiones

1. Con coeficientes no negativos y bases no negativas, $R^2 \leq 1 - S_-/\mathrm{SST}$ para cualquier método; en la envolvente original esto implica $R^2 \leq 0{,}8675$. Recortar las curvas a presión ≥ 0 lo elimina y produce $R^2 \geq 0{,}9962$ con las mismas bases (número de condición 13,90).

2. El mapa $\boldsymbol{c} \mapsto \mathrm{clip}(A\boldsymbol{c}, \boldsymbol{y}_{\min}, \boldsymbol{y}_{\max})$ no es inyectivo para $c_1 \geq 4{,}0756$ y $c_4 \leq 1{,}2084$; la red óptima devuelve medias condicionales (5,04 para c_1), lo que explica cuantitativamente la meseta observada. Etiquetar con el óptimo KKT de la curva de entrada elimina la inconsistencia.

3. El generador original no cubría los escalones α que definen y_1 e y_2 (0,115 % de las muestras con $\Delta\alpha > 0{,}5$); la familia con transiciones eleva esa fracción a $\sim 48\,\%$ (simulación). La mejora efectiva en y_1 y y_2 queda por medir en V12.

Disponibilidad de datos y código

El cuaderno `curva_j_entrenamiento_v12.ipynb` contiene el generador, el etiquetado KKT, el entrenamiento y las evaluaciones descritas.

Referencias

[1] Fung, Y.C. (1967). Elasticity of soft tissues in simple elongation. *Am. J. Physiol.* 213(6):1532–1544.

[2] Humphrey, J.D. (2002). *Cardiovascular Solid Mechanics: Cells, Tissues, and Organs.* Springer.

[3] Holzapfel, G.A., Gasser, T.C., Ogden, R.W. (2000). A new constitutive framework for arterial wall mechanics and a comparative study of material models. *J. Elasticity* 61:1–48.

[4] Boyd, S., Vandenberghe, L. (2004). *Convex Optimization.* Cambridge University Press.

[5] Stark, P.B., Parker, R.L. (1995). Bounded-variable least-squares: an algorithm and applications. *Comput. Stat.* 10:129–141.

[6] Branch, M.A., Coleman, T.F., Li, Y. (1999). A subspace, interior, and conjugate gradient method for large-scale bound-constrained minimization problems. *SIAM J. Sci. Comput.* 21(1):1–23.

[7] Bishop, C.M. (2006). *Pattern Recognition and Machine Learning.* Springer.

[8] Ba, J.L., Kiros, J.R., Hinton, G.E. (2016). Layer normalization. *arXiv:1607.06450.*

[9] Kingma, D.P., Ba, J. (2015). Adam: a method for stochastic optimization. *ICLR.*

[10] Raissi, M., Perdikaris, P., Karniadakis, G.E. (2019). Physics-informed neural networks. *J. Comput. Phys.* 378:686–707.